

硕士学位论文

(学术学位论文)

基于输运蒙特卡洛方法的滤波算法研究

THE RESEARCH OF FILTERING
ALGORITHM BASED ON TRANSPORT
MONTE CARLO

刘桐

哈尔滨工业大学

2024 年 1 月

国内图书分类号：O1
国际图书分类号：51

学校代码：10213
密级：公开

硕士学位论文

基于输运蒙特卡洛方法的滤波算法研究

硕士研究生：刘桐

导师：严质彬教授

申请学位：理学硕士

学科：数学

所在单位：哈尔滨工业大学（深圳）

答辩日期：2024年1月

授予学位单位：哈尔滨工业大学

Classified Index: O1

U.D.C: 51

Dissertation for the Master Degree

THE RESEARCH OF FILTERING ALGORITHM BASED ON TRANSPORT MONTE CARLO

Candidate:	Liu Tong
Supervisor:	Prof. Yan Zhibin
Academic Degree Applied for:	Master of Science
Specialty:	Mathematics
Affiliation:	Harbin Institute of Technology, Shenzhen
Date of Defense:	January, 2024
Degree-Conferring-Institution:	Harbin Institute of Technology

摘 要

滤波问题的本质是根据系统状态的观测量得到对系统状态本身的最优估计。对于较为常见的非线性滤波问题，贝叶斯框架提供了此类问题的一般解法。但在贝叶斯递推过程中，经常涉及到反函数、雅克比行列式和高维积分的问题，这导致了很难得到对应问题的解析表达式。人们通常使用 Monte Carlo 方法规避对此类问题的计算。在滤波问题这一具体的领域中，人们通常使用序贯 Monte Carlo (Sequential Monte Carlo, SMC) 来对目标函数进行抽样，这种方法也被称为粒子滤波，随着时间演进而不断的迭代更新离散样本及其权重并通过样本值和权重得到状态的估计值就是粒子滤波的核心思想。但在具体的应用中，随着时间演进，往往会发生大部分样本的权重不断减小导致的粒子退化现象。这是序贯 Monte Carlo 方法的主要问题。

本文拟使用一种新的 Monte Carlo 方法减缓非线性滤波中的样本退化问题：通过运输蒙特卡洛 (Transport Monte Carlo, TMC) 作为粒子滤波问题中的采样器，用于近似在重要性采样 (Importance Sample) 中的最优重要性函数，并通过该最优重要性函数获得样本。在粒子滤波中，通过使用更好的重要性函数，就可以获得更有效的样本，从而抑制粒子退化问题。本文首先给出了 TMC 方法的基本原理，并根据 TMC 设计了新的粒子滤波算法。通过利用两个仿真实例来对比标准粒子滤波算法 (PF) 和本文重新设计的运输粒子滤波算法 (Transport PF, TPF) 的滤波效果，并发现改进后的 TPF 可以减少滤波的粒子退化现象并在一定程度上提高滤波的精度。

关键词：运输 Monte Carlo；最优重要性函数；粒子滤波；无穷混合；Monge 和 Kantorovich 运输

Abstract

The essence of a filtering problem is to obtain an optimal estimate of the system state itself based on observations of the system state. For the more common nonlinear filtering problems, the Bayesian framework provides a general solution to such problems. However, the Bayesian recursion process often involves inverse functions, Jacobi determinants, and higher dimensional integrals, which makes it difficult to obtain analytic expressions for the corresponding problems. One usually circumvents the computation of such problems by using Monte Carlo methods. In the specific field of filtering problems, it is common to use Sequential Monte Carlo (SMC) to sample the objective function and compute the approximate integral, which is also known as particle filtering. The core idea of particle filtering is to obtain an estimate of the state by updating the discrete samples and their weights. However, in specific applications, as time evolves, the particle degradation phenomenon caused by the decreasing weights of most of the samples often occurs. This is the main problem of the sequential Monte Carlo method.

In this paper, we propose to use a new Monte Carlo method to mitigate the sample degradation problem in nonlinear filtering: the Transport Monte Carlo (TMC) is used as a sampler in the particle filtering problem, which is used to approximate the optimal importance function in the Importance Sample and obtain samples through this optimal importance function. Importance Function to obtain the sample. By using a better importance function in particle filtering, more efficient samples can be obtained, thus suppressing the particle degradation problem. In this paper, the basic principle of the TMC method is firstly given and a new particle filtering algorithm is designed according to the TMC. Two simulation examples are used to compare the filtering effect of the standard particle filtering algorithm (PF) and the redesigned transport particle filtering algorithm (Transport PF, TPF) in this paper, and it is found that the improved TPF can reduce the particle degradation phenomenon of the filtering and improve the accuracy of the filtering to some extent.

Keywords: transport monte carlo, optimal importance function, particle filter, infinite mixture, monge and kantorovich transport

目 录

摘 要	I
Abstract	II
 第 1 章 绪论	 1
1.1 课题背景与意义	1
1.2 国内外研究现状	2
1.3 本文主要研究内容	5
第 2 章 Bayesian 滤波与序贯 Monte Carlo	6
2.1 动态系统	6
2.2 Bayesian 滤波框架	7
2.3 基于 Monte Carlo 方法的近似 Bayesian 滤波	10
2.4 重要性抽样	10
2.5 序贯重要性抽样	12
2.6 序贯重要性重采样	14
2.7 最优重要性密度函数	17
2.8 次优重要性函数	20
2.8.1 基于局部线性化的次优重要性函数	20
2.8.2 先验重要性函数	20
2.8.3 固定重要性函数	21
2.9 本章小结	21
第 3 章 输运 Monte Carlo 与粒子滤波	23
3.1 确定性与随机性输运	23
3.2 确定性输运的简述	24
3.2.1 输运的定义与评价标准	24
3.2.2 最优映射的构建	27
3.3 随机性输运的简述	28
3.4 随机 TMC 算法的一般框架	31
3.4.1 初始化	31
3.4.2 优化	32

3.5 基于 TMC 的粒子滤波算法	33
3.5.1 TMC 近似的函数	33
3.5.2 算法设计	35
3.6 本章小结.....	37
第 4 章 仿真实验	38
4.1 单变量非平稳增长模型.....	38
4.2 四阶混合线性/非线性系统.....	42
4.3 本章小结.....	47
结 论	48
参考文献	49
哈尔滨工业大学学位论文原创性声明和使用权限	54
致 谢	55

第 1 章 绪论

1.1 课题背景与意义

滤波，即从带有扰动的信息中采集到有用信息的过程，具有很广泛的应用场景。目前，Kalman 滤波及相关的衍生算法已在信号处理和控制问题的滤波领域中占统治地位超过了半个世纪。但如果系统噪声不服从 Gauss 分布，或者系统本身不满足线性系统这一条件，则 Kalman 滤波将难以应用^[1]。因此，这一类非线性非 Gauss 系统的滤波问题还是拥有着较高的研究价值。

Kalman 滤波就是线性 Gauss 动态系统在 Bayesian 滤波体系下的最优滤波，但完全的线性系统在实际应用中较为少见。众所周知，计算 Jacobi 行列式、高维的函数积分和反函数求解等问题在实际中通常都无法得到闭式解而只能使用数值解来取得一个近似，而以上这一系列问题在对非线性非 Gauss 统计特征的动态系统而言是无法回避的。因而，数值方法应用的困难使得对非线性非 Gauss 系统直接使用 Bayesian 滤波也难以应用。在实际处理上面提到的非线性非 Gauss 系统时，可以选择的近似方法主要有两种：其中一种是基于线性近似的扩展 Kalman 滤波 (Extend Kalman Filter, EKF)；另一种则是序贯 Monte Carlo (SMC) 的粒子滤波，通过 Monte Carlo 方法获取大量的样本来获取对应的解的近似^[2]。在本文中，第二种方法是研究的重点，作为一种近似的 Monte Carlo 方法，粒子滤波对系统本身性质的要求较少，但该方法提出的早期，因计算和存储资源发展不充分和粒子退化问题的限制使其没有得到很多重视。但在目前，因为计算机存储和计算成本的不断降低，粒子滤波方法已经在许多领域中得到了良好的应用，例如：目标定位跟踪^[3-4]、电池寿命预测^[5-6]、天气预报^[7]、交通管理^[8]、金融预测^[9]。具备着较大的研究价值。

从原理上说，如果可以采集可数个样本，则对后验密度的近似就可以达到相当充分的精度。但在实际应用中，由于多方面的限制，我们只能采集有限个样本，当随着迭代次数的增加后，样本的权重将不可避免的发生集中，也就是绝大多数的样本的权重变为零，对系统状态估计的贡献越来越小，这种权重方差随着迭代次数增加而增大的现象也被称为粒子退化现象。粒子退化现象的轻重很大程度上决定了滤波算法的精度和滤波算法的稳定性。因此，为了尽可能的提高滤波的精度，设计更加合理的滤波算法来获得更高的采样效率用以对抗

粒子退化现象是很有必要的。而对抗粒子退化问题的一大核心关键就是在采样过程中重要性函数本身的性质，如果可以选择较好的重要性函数，使得重要性函数与目标函数的差距尽可能的小，则就可以极大程度的抑制粒子退化现象。本文的主要研究内容就是通过优化方法获得更好的重要性函数，从而对抗粒子退化现象。

1.2 国内外研究现状

滤波问题的最早起源一般被认为是 Legendre 和 Gauss 在 18 世纪末到 19 世纪初提出的最小二乘法^[10]。尽管具有实现条件比较简单的优点，但最小二乘法的主要准则是得到基于测量误差方差最小的滤波值，只是将观测信号视为一个固定的值而非一个随机变量，因此在实际应用中的性能并不理想。通过将统计特性引入系统状态和量测数据，利用数理统计理论对系统状态和量测数据进行分析，再结合线性系统理论，Wiener 滤波理论在上世纪 40 年代由 Wiener (美国) 和 Kolmogorov (苏联) 相继提出^[11-12]。首先在 1941 年，针对离散时间系统，由 Kolmogorov 进行了综合性的论述。一年后的 1942 年，Wiener 给出了连续时间系统滤波问题的推导过程，并在实际应用中为火控系统提供了一种比较成功的解决方案。Wiener 滤波作为一种典型的频域算法，也具有频域算法的一般缺陷：观测数据必须宽平稳、每一次滤波都需要使用过去所有时刻的观测数据等。这本质上代表了 Wiener 滤波器是一种非递推的滤波器，仍然具有改进的必要。

作为一种频域算法，Wiener 滤波天然的缺陷让人们将目光转向了时域滤波算法设计。1960 年，离散时间的 Kalman 滤波被首次提出^[13]，结合状态空间的概念并加以数理统计的相关理论，再利用状态方程和观测方程对动态系统进行数学建模就得到了描述系统的演化过程和观测过程的数学模型，在此条件下得到最小均方误差估计的过程，就是所谓的离散时间的 Kalman 滤波。随后，针对连续时间的滤波问题，Kalman 和 Bucy 在一年后给出了连续时间的 Kalman-Bucy 滤波^[14]。由于具有时域下递推的优良性质，这使得 Kalman 滤波在时变、非平稳随机过程和多维信号的估计中具有着很广泛的应用场景。由于 Kalman 滤波具有在计算机上易于实现的、实时性强的特性，因而一经提出就对工程界产生了深远影响。直到今天，Kalman 滤波及其衍生算法仍旧有着广泛的应用，在跟踪问题、通信问题、机器学习、经济金融都发挥着重要的作用。作为对应的代价，只有系统的初始状态服从 Gauss 分布的统计特性并且本身是一个线性系统时，Kalman 滤波才适用。为了让 Kalman 滤波器具有更广泛的应用场景，能够

适用非线性非 Gauss 系统，对 Kalman 滤波的改进一直在进行着。

作为一种推导过程很优美的滤波器，在状态转移噪声和观测噪声都是加性 Gauss 噪声且转移方程和观测方程都是线性的时候，Kalman 滤波就是可以解析求解的最小方差条件下的无偏最优滤波器。但在现实世界的系统中，具有非线性-非 Gauss 分布特性的系统占据了绝大多数。因此，尽管系统的非线性、非 Gauss 特性使得相关研究带来了很大的困难，对非线性滤波理论的进一步研究，不但具有重要的理论价值，在应用上也拥有广泛的前景，在 Kalman 滤波提出后，非线性滤波的研究直到现在仍是一个研究热点。20 世纪 60 年代后，对非线性滤波系统的研究主要有两个方向：第一个方向是比较理论的，主要是想要通过概率方法建立一种通用的非线性滤波理论；另一个方向则是从实际出发，开发出实用的非线性滤波算法。无迹 Kalman 滤波 (Unscented Kalman Filter, UKF)^[15]、扩展 Kalman 滤波 (Extended Kalman Filter, EKF)^[16] 和粒子滤波 (Particle Filter, PF)^[17] 等多种滤波方法都是第二个方向上比较经典的代表性成果。

对于序贯蒙特卡洛方法（粒子滤波）的研究可以追溯到 20 世纪 50 年代^[18]，但受样本退化问题和当时计算资源不够丰富等客观因素影响，使得该方法没有得到重视，从而影响了该方法的大规模应用。Gordon 等人^[17]于 1993 年将多项式重采样步骤引入序贯采样过程，通过重采样的方法来对抗粒子退化，这让粒子滤波方法在一定程度上摆脱了粒子退化的限制，具有了一定的应用价值。在 Gordon 的重采样方法之后，包括 Liu^[19]提出的残差重采样、Carpenter^[20]提出的分层重采样等，这一系列用于克服粒子退化问题的重采样方法大大的提升了粒子滤波算法的实用性。但此时我们仍旧需要一种方法来对粒子退化的程度进行定量分析，因为如果无限制的进行重采样，会导致粒子的多样性下降，使得算法整体的健壮性变低。在这一需求的刺激下，有效粒子数这一概念被 Geweke、Kong、Liu 等^[21-23]开发出来，可以用来度量样本多样性的减少程度，从而减少重采样步骤的使用，增加算法的健壮性。除了使用重采样方法，Berzuni 等人^[24]也开发了利用 Markov 链 Monte Carlo (MCMC) 方法进行抽样，因为使用这类方法得到的样本族服从的分布更加接近于后验概率密度，也就降低了使用重采样方法的必要性。另外，利用优化方法进行重采样来提高粒子多样性、提升估计精度同样也是对抗粒子退化问题的有力方法^[25-28]。

2000 年，Doucet 等人^[29]提出了对时间序列通用的 Bayesian 滤波的基础性框架，也就是序贯重要性抽样的一般框架，并在数学上证明了随着时间演进，粒子退化问题是不可避免的。Doucet 同时在该文献中指出，可以采用如下方法对抗粒子退化问题：对粒子进行重采样以及选取与后验分布更加接近的较好的重

要性函数。在最小权重方差的含义下, Doucet 还在该文献中给出了最优重要性函数的形式上的表达式。

为了从各种形状的后验密度中采样, 人们设计了各种方法以绕过 MCMC 而获取独立的随机样本。如: 近似 Bayesian 计算拒绝算法^[30]、变分 Bayesian^[30] 等方法。在以上方法中, 一种相当独特的方法为“输运映射”, 也就是后验分布和参考分布之间的可逆映射, 这里, 参考分布是一个很容易采样的分布, 例如正态分布或者均匀分布。在 2012 年, Moselhy 和 Marzouk^[31] 提出了这项开创性的工作。通过将输运映射参数化为单调函数, 可以通过变量代换得到参考分布的闭式表达。对于参数的实际工作效果, 可以通过最小化目标后验分布和变换的参考分布之间的差别来进行估计。与其他方法相比, 此方法的一个主要优点是, 如果确实存在可逆解, 那么从理论上讲, 不存在近似误差, 并且该算法将具有非常高的精度。

此问题的核心在于寻找到足够灵活的参数化可逆变换, 这一问题催生了一大批有趣的工作。Parno 和 Marzouk^[32] 在 2018 年提出通过使用下三角映射 (也就是第 k 个输出变量只与前 k 个输入变量有关) 来参数化可逆变换, 这个映射近似于两个概率测度之间的 Knothe-Rosenblatt 重排变换; Spantini 等人^[33] 在 2018 年进一步提出在这些输运映射上补充了稀疏或可分解的结构, 假设两个高维变量之间存在低维耦合; Doucet 等人^[34] 提出使用常微分方程来参数化输运映射, 同时, 在此篇文献中也提出了该方法可以用作 SMC 的采样器。

将 TMC 方法应用在滤波问题上而言, Riech^[35] (2013) 最先在基于离散样本的条件下提出了一种滤波算法; Pulido^[36] 在 2019 年提出了一种基于局部最优变换的粒子滤波算法; Taghvaei^[37] 提出了一种最优输运形式的集合 Kalman 滤波; Graham^[38] 提出了一种基于最优输运的局部粒子滤波; Kang C H^[39] 等人基于正则化的最优输运提出了一种粒子滤波算法; Das^[40] 提出了一种基于最优输运的受到非线性状态等式约束的滤波算法; 在 2021 年, Corenflos^[41] 提出了基于集合输运这一思想的可微粒子滤波方法, 其主要思想是通过变换若干样本来获得对后验分布的估计; Kang J^[42] 提出了一种关于相关性噪声的粒子滤波算法; Al-Jarrah 与 Taghvaei^[43-44] 基于最优输运提出了一种基于 Bayes 定理的非线性滤波算法。就目前而言, 基于最优输运的滤波算法已有很多, 本文的主要研究内容为: 为一种新的基于 Kantorovich 输运的 Monte Carlo 方法设计了对应的滤波算法, 并从粒子退化和预测稳定性的角度分析了该方法相比传统粒子滤波算法的优势。

1.3 本文主要研究内容

在归纳总结了已有的研究成果的基础上, 本文将一种新的基于 Kantorovich 输运的输运 Monte Carlo 方法应用到了传统的序贯 Monte Carlo 方法上, 将传统的以状态转移函数作为重要性函数的粒子滤波算法改进为使用输运 Monte Carlo 方法作为重要性函数的粒子滤波算法, 并将设计的算法实际应用于两个数值仿真算例, 实验结果表明了改进后的滤波算法的可行性和有效性。本文整体的结构安排如下:

(1) 首先在绪论部分给出了本课题的研究背景和研究意义, 并重点描述了粒子滤波的发展历程和现有的粒子滤波算法在应用上的困难。其次, 简要描述了现有的基于最优输运设计的粒子滤波算法的研究现状进行了总结, 并介绍了本文研究内容的创新点。最后, 给出了本文整体的结构安排;

(2) 介绍了一些必要的前置知识, 包括动态系统的定义、Bayesian 滤波框架的推导过程和实际应用 Bayesian 滤波的主要困难并进而给出了利用 Monte Carlo 方法近似 Bayesian 滤波的具体原理。针对后验分布难以采样的问题, 介绍了重要性采样来获得样本; 针对粒子退化问题, 详细介绍了几种重采样方法和重采样的核心思想。同时给出了最小方差意义下最优重要性函数选取的理论依据和在最优重要性函数无法应用时的备选次优重要性函数;

(3) 介绍了两种基于优化的输运 Monte Carlo 方法, 分别是确定性输运和随机性输运。并选取随机性输运作为实际应用的方法, 给出了使用随机输运进行优化的目标, 并进一步设计了相应的粒子滤波算法;

(4) 将本文提出的算法应用于具有较强非线性性的单变量非平稳增长模型和四阶的混合线性/非线性 Gauss 系统模型上去, 并与传统的使用状态转移函数作为重要性函数的粒子滤波算法进行了比对。实验结果表明, 本文提出的算法有效的对抗了粒子退化现象并在一定程度上提高了预测的精度。

第 2 章 Bayesian 滤波与序贯 Monte Carlo

2.1 动态系统

对于一般的滤波问题而言, 需要观测的系统通常可以使用两个方程组成的系统进行描述: 其中一个是状态转移方程, 描述了系统状态转移的规律; 另一个是观测方程, 描述了系统状态是如何被映射为观测量的。具体的表达形式如下:

$$\begin{cases} x_k = f_k(x_{k-1}, \omega_{k-1}) \\ z_k = h_k(x_k, \nu_k), \end{cases} \quad (2-1)$$

因为在滤波问题中往往涉及到时序问题, 为了方便, 我们记 $\mathbf{X}_{0:k} = \{x_0, \dots, x_k\}$, $\mathbf{Z}_{0:k} = \{z_0, z_1, \dots, z_k\}$ 分别表示从 0 到 k 时刻的所有系统状态和量测的集合, f_k 和 h_k 分别是状态转移函数和观测函数, 下标的 k 表示状态转移函数和观测函数有可能随着时间而变化。此方程通常要满足如下几个条件:

(1) 系统的初始状态 x_0 服从一个概率密度函数 $p(x_0)$, $x_0 \sim p(x_0)$, 该初始密度应当是已知的;

(2) 过程噪声 $\{\omega_k\}$ 和观测噪声 $\{\nu_k\}$ 互相独立, 而过程噪声和观测噪声自身也应当满足独立同分布条件;

(3) $x_0, \{\omega_k\}, \{\nu_k\}$ 相互独立。

根据以上条件, 可以得出结论如下:

(1) 状态转移方程满足 $p(x_k | \mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k-1}) = p(x_k | x_{k-1})$;

(2) 对于观测量的条件概率密度, 有 $p(z_k | \mathbf{X}_{0:k}, \mathbf{Z}_{0:k-1}) = p(z_k | x_k)$ 。

上面两条结论的主要来源是 x_k 的所有信息包含在 x_{k-1}, ω_{k-1} 之中, z_k 的所有信息包含在 x_k 和 ν_k 之中, 而系统状态包含着所有的对应的观测量的信息。如果一个模型满足上面的条件, 则该模型通常被称为隐 Markov 模型。因此, 人们也将条件 (1) 和 (2) 称为隐 Markov 条件。在此条件下, 我们有:

$$\begin{aligned} p(\mathbf{X}_{0:k}) &= p(x_k | \mathbf{X}_{0:k-1}) p(\mathbf{X}_{0:k-1}) \\ &= p(x_k | x_{k-1}) p(\mathbf{X}_{0:k-1}) \\ &= p(x_0) \prod_{i=1}^k p(x_i | x_{i-1}), \end{aligned} \quad (2-2)$$

上式的第一行到第二行运用了结论 (1)，第二行到第三行为递推的使用这一结论。类似的，也有

$$\begin{aligned}
 p(\mathbf{Z}_{0:k}|\mathbf{X}_{0:k}) &= \frac{p(z_k|\mathbf{Z}_{0:k-1}, \mathbf{X}_{0:k})p(\mathbf{Z}_{0:k-1}, \mathbf{X}_{0:k})}{p(\mathbf{X}_{0:k})} \\
 &= p(z_k|x_k)p(\mathbf{Z}_{0:k-1}|\mathbf{X}_{0:k}) \\
 &= p(z_k|x_k)p(\mathbf{Z}_{0:k-1}|\mathbf{X}_{0:k-1}) \\
 &= \prod_{i=0}^k p(z_i|x_i),
 \end{aligned} \tag{2-3}$$

再进一步，有

$$\begin{aligned}
 p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) &= \frac{p(z_k|\mathbf{X}_{0:k}, \mathbf{Z}_{0:k-1})p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k-1})}{p(z_k|\mathbf{Z}_{0:k-1})} \\
 &= \frac{p(z_k|\mathbf{X}_{0:k}, \mathbf{Z}_{0:k-1})p(x_k|\mathbf{X}_{0:k-1}, \mathbf{X}_{0:k-1})}{p(z_k|\mathbf{Z}_{0:k-1})} \times p(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k-1}) \\
 &= \frac{p(z_k|x_k)p(x_k|x_{k-1})}{p(z_k|\mathbf{Z}_{0:k-1})} \times p(\mathbf{X}_{0:k-1}|\mathbf{Y}_{0:k-1}).
 \end{aligned} \tag{2-4}$$

对于一般的滤波框架体系，动态系统模型包含如下含义：

- (1) 状态方程就是系统的当前状态转移到下一时刻状态时遵循的某种规律的函数形式的描述；
- (2) 系统状态不可观测的前提下，只能通过观测函数获得系统状态部分信息的某些映射。

2.2 Bayesian 滤波框架

假设 k 时刻为系统的最新时刻，则在 Bayesian 框架中，到此时刻为止的所有系统状态 $\mathbf{X}_{0:k}$ 的所有可观测的信息，都包含在 k 时刻为止累计的全部观测 $\mathbf{Z}_{0:k}$ 中。用条件概率的形式表示就是条件概率密度 $P(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 包含了系统状态到时刻 k 为止的所有可知的信息。从最本质的观点来说，Bayesian 滤波就是在获得观测信息之前，利用描述系统状态转移过程的函数方程得到先验概率密度函数，通过该先验概率密度函数得到对应的系统状态预测值；当观测测量到达之后，再利用量测信息将先验密度函数更新为后验密度函数并进一步通过后验密度函数得到更新后的系统状态的校正值的预测-校正两步过程。在理想状况下求解滤波问题的关键为获得 $P(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 的解析表达式，尤其是它的边缘密度函数 $P(x_k|\mathbf{Z}_{0:k})$ 。

对于 (2-1) 中提到的离散动态系统，假设其中 $x_k \in \mathbb{R}^n$ ，状态转移函数 $f(\cdot)$ ：

$\mathbb{R}^n \rightarrow \mathbb{R}^n$, 系统噪声 $\omega_k \in \mathbb{R}^p$, 量测 $z_k \in \mathbb{R}^m$, 量测噪声 $v_k \in \mathbb{R}^q$ 。假定:

- (1) $x_0 \sim p(x_0)$, $\omega_k \sim p_{\omega_k}$ 和 $v_k \sim p_{v_k}$ 均为已知;
- (2) 对一切 $k = 0, 1, 2, \dots$ 成立:

$$\text{Cov}(x_0, \omega_k) = 0, \quad \text{Cov}(x_0, v_k) = 0.$$

这一条件表示系统的初始状态与噪声不相关。同时对一切的 $k, j = 0, 1, 2, \dots$ 还应当成立条件

$$\text{Cov}(w_k, w_j) = Q_k \delta_{kj}, \quad \text{Cov}(v_k, v_j) = R_k \delta_{kj}, \quad \text{Cov}(w_k, v_j) = 0,$$

其中 δ_{ij} 为 Kronecker 符号, 在以上条件下我们有 2.1 节的两个推论:

- (1) $\{x_k\}$ 服从 Markov 过程, 也就是

$$p(x_k | x_{k-1}, x_{k-2}, \dots, x_0) = p(x_k | x_{k-1});$$

- (2) z_k 仅与 x_k 相关, 也就是

$$p(z_k | x_k, x_{k-1}, \dots, x_0) = p(z_k | x_k).$$

此时后验概率密度函数 $p(\mathbf{X}_{0:k} | \mathbf{Z}_{0:k})$ 提供了关于 $\mathbf{X}_{0:k}$ 的所有可观测信息。从概率的角度来说, 在知道了 $p(\mathbf{X}_{0:k} | \mathbf{Z}_{0:k})$ 以后就可以选择合适的评价度量来得到关于 $\mathbf{X}_{0:k}$ 在此度量标准下的最优估计。Bayesian 滤波的核心在于通过已有的观测信息 $\mathbf{Z}_{0:k-1}$ 得到预测状态 $p(\mathbf{X}_{0:k} | \mathbf{Z}_{0:k-1})$ 的预测步骤和通过新得到的量测向量 z_k 对这一估计进行校正的校正步骤。在最小方差的含义下, 通过计算 $\mathbf{X}_{0:k}$ 的后验密度 $p(\mathbf{X}_{0:k} | \mathbf{Z}_{0:k})$ 就可以实现校正步骤。具体的计算过程可以简述如下:

- (1) 预测: 假设 $p(\mathbf{X}_{0:k-1} | \mathbf{Z}_{0:k-1})$ 已知, 也就是 $k-1$ 时刻的后验密度函数已知, 利用系统状态的一阶 Markov 性, 有推导如下:

$$\begin{aligned} p(\mathbf{X}_{0:k} | \mathbf{Z}_{0:k-1}) &= \frac{p(x_k, \mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k-1})}{p(\mathbf{Z}_{0:k-1})} \\ &= \frac{p(x_k | \mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k-1}) p(\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k-1})}{p(\mathbf{Z}_{0:k-1})} \\ &= p(x_k | x_{k-1}) p(\mathbf{X}_{0:k-1} | \mathbf{Z}_{0:k-1}), \end{aligned} \tag{2-5}$$

上式中的第三行使用了系统状态一阶 Markov 性的条件, 其中的 $p(x_k | x_{k-1})$ 表示为状态转移的概率密度函数。

- (2) 校正: 当最新的量测信息 z_k 在 k 时刻到达并被获得后, 通过如下 Bayes 公式:

$$\begin{aligned}
 p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) &= \frac{p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k-1})p(z_k|\mathbf{X}_{0:k},\mathbf{Z}_{0:k-1})}{p(z_k|\mathbf{Z}_{0:k-1})} \\
 &= \frac{p(x_k|\mathbf{Z}_{0:k-1})p(z_k|x_k,\mathbf{X}_{0:k-1})}{\int p(z_k,\mathbf{X}_{0:k}|\mathbf{Z}_{0:k-1})d\mathbf{X}_{0:k}} \\
 &= \frac{p(x_k|\mathbf{Z}_{0:k-1})p(z_k|x_k,\mathbf{X}_{0:k-1})}{\int p(z_k|\mathbf{X}_{0:k},\mathbf{Z}_{0:k-1})p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k-1})d\mathbf{X}_{0:k}} \\
 &= \frac{p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k-1})p(z_k|x_k)}{\int p(z_k|x_k)p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k-1})d\mathbf{X}_{0:k}},
 \end{aligned} \tag{2-6}$$

计算得到系统最新的后验概率密度函数。上述推导中的最后两行运用了 Markov 性条件，同时可以计算对应的滤波概率密度函数 $p(x_k|\mathbf{Z}_{0:k})$ 的递推公式

(1) 预测：

$$p(x_k|\mathbf{Z}_{0:k-1}) = \int p(x_k|x_{k-1})p(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k-1})d\mathbf{X}_{0:k-1}. \tag{2-7}$$

(2) 校正：

$$\begin{aligned}
 p(x_k|\mathbf{Z}_{0:k}) &= \frac{p(x_k|\mathbf{Z}_{0:k-1})p(z_k|x_k,\mathbf{X}_{0:k-1})}{p(z_k|\mathbf{Z}_{0:k-1})} \\
 &= \frac{p(x_k|\mathbf{Z}_{0:k-1})p(z_k|x_k)}{\int p(z_k|x_k)p(x_k|\mathbf{Z}_{0:k-1})dx_k}.
 \end{aligned} \tag{2-8}$$

此处 $p(z_k|x_k)$ 为似然函数，具体的推导与 (2-6) 类似，此处不再重复。

如果在 (2-1) 中表示的系统满足线性系统和噪声 Gauss 分布的条件，则该系统就是服从 Kalman 滤波要求的一个系统，此时利用 Bayesian 滤波进行滤波问题的求解得到的结果其实就是 Kalman 滤波。因此，可以认为 Kalman 滤波其实就是 Bayesian 滤波在线性 Gauss 条件下的一种特殊情况。在这一条件下如果忽略矩阵求逆的复杂性等问题，则 (2-7) 和 (2-8) 可以在理论上解析计算出来。但当系统本身是非线性系统或系统的噪声不服从 Gauss 分布时，(2-7) 和 (2-8) 的计算就必须要进行密度变换：

$$\begin{cases} p(x_k|x_{k-1}) = p_{\omega_k}(f_k^{-1}(x_k, x_{k-1})) \left| \frac{\partial f_k^{-1}}{\partial x_k} \right| \\ p(y_k|x_k) = p_{\nu_k}(h_k^{-1}(y_k, x_k)) \left| \frac{\partial h_k^{-1}}{\partial y_k} \right|, \end{cases} \tag{2-9}$$

此处的 p_{ν_k}, p_{ω_k} 分别表示观测噪声和量测噪声服从的分布。由于 (2-7) 和 (2-8) 的积分计算的维度会随着时间呈线性增长，而在 (2-9) 的计算中也产生了反函数的存在性和导函数的存在性与对应的计算问题。在相当一大部分的情况下，这些问题的存在性本身都是问题，更不要谈计算它们了。即使想通过数值解法绕过解析上的问题直接得到近似的积分值，计算的复杂性仍然是一个巨大的挑

战。所以, Bayesian 滤波的框架只是在形式上给出了一个求解的方法, 而在实际问题的解决中, 必然要受到有限的算力和存储空间条件的限制, 使得 Bayesian 方法的直接应用仍旧存在困难。因此, Bayesian 滤波需要某些改进以适应实际应用的需要。

2.3 基于 Monte Carlo 方法的近似 Bayesian 滤波

在 Bayesian 体系下的滤波问题, 本质上就是在求取不可观测的系统状态在有限观测的条件下的条件期望的问题。这一条件期望问题可以描述为积分形状如下:

$$\mathbb{E}[g(x_k)|\mathbf{Z}_{0:k}] = \int g(x_k)p(x_k|\mathbf{Z}_{0:k})dx_k. \quad (2-10)$$

如果将最小均方误差矩阵作为我们评判估计优劣的标准, 则该条件期望就是系统状态的最优估计。在这一积分计算问题中, 如果我们有大量的服从后验概率密度函数 $p(x_k|\mathbf{Z}_{0:k})$ 的样本, 则可以用这些样本构建 $p(x_k|\mathbf{Z}_{0:k})$ 的基于 Dirac 函数的近似, 从而获得经验均值作为条件期望 $\mathbb{E}[g(x_k)|\mathbf{Z}_{0:k}]$ 的估计, 这就是用以规避直接计算积分的 Monte Carlo 方法。

在理想情况下的 Monte Carlo 近似中, 如果从后验分布 $p(x_k|\mathbf{Z}_{0:k})$ 中随机获得 N 个独立同分布的样本 $x_k^{(i)} \sim p(x_k|\mathbf{Z}_{0:k})$, 则期望的估计形如:

$$\hat{I} \approx \frac{1}{N} \sum_{i=1}^N g(x_k^{(i)}). \quad (2-11)$$

此方法的主要优势在于, 根据中心极限定律, Monte Carlo 方法的收敛速度不受状态 x_k 的维数影响, 误差项始终为 $O(N^{-1/2})$, 当状态 x_k 的维数较高时, 这种方法可以在一定程度上避免维数灾, 使得这一方法在理论上对比其他数值方法具有一定的优势。虽然限于现实应用的复杂性, 这一结论并不能保证在任何情况下都成立, 但至少该方法有着数学理论上的支持^[45]。

2.4 重要性抽样

当我们要在实践中利用系统状态的后验概率密度函数 $p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 及对应的边缘概率密度函数 $p(x_k|\mathbf{Z}_{0:k})$ 来获得系统状态在最小方差意义下的估计时, 面对的直接问题就是这两个密度函数通常都是难以直接抽样或在一定程度上未知的, 为了能够从这两个分布函数中获得样本, 人们设计了一种名为重要性采样 (Importance Sample, IS) 的方法。该方法的核心思想是: 不再直接面对从后

验密度中采样这一困难，而是首先从一个容易在计算机中进行采样的密度函数 $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 中抽取 N 个独立同分布的样本，并通过调整获得样本的权重来近似作为目标的后验概率密度 $p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 。在这一方法中， $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 常用的称呼包括重要性函数 (Importance Function) 和建议分布 (Proposal Distribution)。一般而言，与难以采样的后验概率密度函数 $p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 对应，被选中的 $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 往往具有如下的优良性质^[46]：

(1) 重要性函数 $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 容易采样且对应的概率密度容易计算；

(2) 重要性函数 $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 的支撑集应当与后验概率密度函数 $p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 的支撑集相同或更大。

在从 $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 中选取 N 个独立同分布的样本 $\{\mathbf{X}_{0:k}^{(i)}\} \in \pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$, $i = 1, \dots, N$ 后，可以得到 $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 的一个经验近似：

$$\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) \approx \frac{1}{N} \sum_{i=1}^N \delta_{\mathbf{X}_{0:k}^{(i)}}(\mathbf{X}_{0:k}). \quad (2-12)$$

此处 $\delta(\cdot)$ 为 Dirac Delta 函数。对于条件期望 (2-10)，我们可以将其改写为

$$\begin{aligned} \mathbb{E}_{p(\mathbf{x}_k|\mathbf{Z}_{0:k})}(g(x_k)) &= \int g(x_k) \frac{p(x_k|\mathbf{Z}_{0:k})}{\pi(x_k|\mathbf{Z}_{0:k})} \pi(x_k|\mathbf{Z}_{0:k}) dx_k \\ &= \mathbb{E}_{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})} \left[g(\mathbf{X}_{0:k}) \frac{p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})} \right], \end{aligned} \quad (2-13)$$

进一步定义

$$w(\mathbf{X}_{0:k}) \triangleq \frac{p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})} \propto \frac{p(\mathbf{Z}_{0:k}|\mathbf{X}_{0:k})p(\mathbf{X}_{0:k})}{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}.$$

对其关于 $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 求期望，可以得到

$$\mathbb{E}_{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})} [w(\mathbf{X}_{0:k})] = \int \frac{p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})} \pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) d\mathbf{X}_{0:k} = 1.$$

上式成立的原因在于 π 的支撑集是大于等于 p 的支撑集的，所以可以在 p 的所有支撑集上进行积分。对于每个具体的样本 $\mathbf{X}_{0:k}^{(i)}$ ，定义重要性权重

$$w_k^{(i)} \triangleq \frac{p(\mathbf{Z}_{0:k}|\mathbf{X}_{0:k}^{(i)})p(\mathbf{X}_{0:k}^{(i)})}{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}, \quad (2-14)$$

由于此时的权重尚不满足一个概率测度的性质，所以对其进行归一化，就可以得到

$$\bar{w}(\mathbf{X}_{0:k}^{(i)}) \triangleq \bar{w}_k^{(i)} = \frac{w_k^{(i)}}{\sum_{i=1}^N w_k^{(i)}},$$

此时利用 (2-12) 中对重要性函数 $\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 的近似可以得到对后验分布

$p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 的近似:

$$\begin{aligned}
 p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) &= w(\mathbf{X}_{0:k})\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) \\
 &= \frac{w(\mathbf{X}_{0:k})\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}{\mathbb{E}_{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}[w(\mathbf{X}_{0:k})]} \\
 &\approx \frac{\frac{1}{N} \sum_{i=1}^N w_k^{(i)} \delta_{\mathbf{X}_{0:k}}^{(i)}(\mathbf{X}_{0:k})}{\frac{1}{N} \sum_{i=1}^N w_k^{(i)}} \\
 &\approx \sum_{i=1}^N \bar{w}_k^{(i)} \delta_{\mathbf{X}_{0:k}}^{(i)}(\mathbf{X}_{0:k}),
 \end{aligned} \tag{2-15}$$

利用 (2-15), 我们就得到了对应的边缘化的滤波函数的近似:

$$p(x_k|\mathbf{Z}_{0:k}) \approx \int \sum_{i=1}^N \bar{w}_k^{(i)} \delta_{\mathbf{X}_{0:k}}^{(i)}(\mathbf{X}_{0:k}) d\mathbf{X}_{0:k-1} = \sum_{i=1}^N \bar{w}_k^{(i)} \delta_{\mathbf{X}_{0:k}}^{(i)}(\mathbf{X}_{0:k}). \tag{2-16}$$

对于随机变量 x_k 和它的任意可积函数 $g(x_k)$, 我们有:

$$\begin{aligned}
 \bar{g}_k &= \mathbb{E}_{p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}[g(x_k)] \\
 &\approx \int g(x_k) \sum_{i=1}^N \bar{w}_k^{(i)} \delta_{\mathbf{X}_{0:k}}^{(i)}(\mathbf{X}_{0:k}) d\mathbf{X}_{0:k} = \sum_{i=1}^N \bar{w}_k^{(i)} g(x_k^{(i)}) = \bar{g}_k^N.
 \end{aligned} \tag{2-17}$$

对最小均方误差估计 (LMSE) $\hat{x}_{k|k}^{\text{LMSE}}$, 可以在 (2-17) 中简单令 $g(x_k) = x_k$ 得到; 而均方误差阵估计 (MSEM) $P_{k|k}^{\text{MSEM}}$, 可以直接令 $g(x_k) = (x_k - \hat{x}_{k|k}^{\text{LMSE}})(x_k - \hat{x}_{k|k}^{\text{LMSE}})^T$. 对应的公式如下:

$$\hat{x}_{k|k}^{\text{LMSE}} \approx \sum_{i=1}^N \bar{w}_k^{(i)} x_k^{(i)}, \tag{2-18}$$

$$P_{k|k}^{\text{MSEM}} \approx \sum_{i=1}^N \bar{w}_k^{(i)} (x_k - \hat{x}_{k|k}^{\text{LMSE}})(x_k - \hat{x}_{k|k}^{\text{LMSE}})^T. \tag{2-19}$$

2.5 序贯重要性抽样

虽然 IS 方法很巧妙的规避了后验分布难以采样的问题, 使它成为了一种很有竞争力的积分 Monte Carlo 方法。但因为在滤波问题中, 观测数据会随着时间不断累积, 单纯的 IS 方法无法直接应用。其直接问题在于, 当在 $k-1$ 时刻对 $p(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k-1})$ 进行估计时, 需要用到到 $k-1$ 时刻为止的所有量测数据 $\mathbf{Z}_{0:k-1}$ 。当最新的观测 z_k 到达后, 尽管看起来对 k 时刻的权重的更新的内容只有一小部分, 但却仍然需要将所有的系统状态 $\mathbf{X}_{0:k-1}$ 与观测量纳入计算过程中。也就是说, 随着迭代步数的增长, 总体的计算成本将达到时间序列的平方级别。

为了让重要性抽样能够适应时序特性且保证计算量不发生巨大的增加，人们将序贯（Sequential）这一概念引入重要性采样之中，获得了序贯重要性采样方法（Sequential Importance Sample, SIS）。

SIS 的主要思想是：通过对 $k-1$ 时刻的 N 个样本 $\{\mathbf{X}_{0:k-1}^{(i)}\}_{i=1}^N$ 进行延伸来得到 k 时刻的样本 $\mathbf{X}_{0:k}^{(i)} = \{\mathbf{X}_{0:k-1}^{(i)}, x_k^{(i)}\}$ ，并通过对 $k-1$ 时刻的权重 $\{\bar{w}_{k-1}^{(i)}\}_{i=1}^N$ 进行局部更新来获得 k 时刻的权重 $\{\bar{w}_k^{(i)}\}_{i=1}^N$ 。根据 Bayes 公式，对于重要性函数，我们有如下分解

$$\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) = \pi(x_k|\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k})\pi(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k}). \quad (2-20)$$

如果我们选取我们的建议分布具有如下性质：

$$\pi(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k}) = \pi(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k-1}), \quad (2-21)$$

则

$$\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) = \pi(x_0|z_0) \prod_{i=0}^{k-1} \pi(x_{i+1}|\mathbf{X}_{0:i}, \mathbf{Z}_{0:i+1}). \quad (2-22)$$

也就是说，当 k 时刻的最新量测 z_k 到达后，从 $\pi(x_k|\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k})$ 中获得样本 $x_k^{(i)}$ ，记 $\mathbf{X}_{0:k}^{(i)} = \{\mathbf{X}_{0:k-1}^{(i)}, x_k^{(i)}\}$ ，此时可以计算最新的重要性权重

$$\begin{aligned} w(\mathbf{X}_{0:k}) &= \frac{p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})} \\ &\propto \frac{p(\mathbf{Z}_{0:k}|\mathbf{X}_{0:k})p(\mathbf{X}_{0:k})}{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})} \\ &= \frac{p(z_k|x_k)p(x_k|x_{k-1})}{\pi(x_k|\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k})} \frac{p(\mathbf{Z}_{0:k-1}|\mathbf{X}_{0:k-1})p(\mathbf{X}_{0:k-1})}{\pi(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k-1})} \\ &= \frac{p(z_k|x_k)p(x_k|x_{k-1})}{\pi(x_k|\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k})} w(\mathbf{X}_{0:k-1}), \end{aligned} \quad (2-23)$$

此时我们就可以得到更新后的权重为

$$w_k^{(i)} = w_{k-1}^{(i)} \frac{p(z_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{\pi(x_k^{(i)}|\mathbf{X}_{0:k-1}^{(i)}, \mathbf{Z}_{0:k})}. \quad (2-24)$$

将此权重重新归一化后，我们有

$$\bar{w}_k^{(i)} = \frac{w_k^{(i)}}{\sum_{i=1}^N w_k^{(i)}},$$

并且可以得到对 $p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 的近似

$$p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) \approx \sum_{i=1}^N \bar{w}_k^{(i)} \delta_{X_k^{(i)}}(\mathbf{X}_{0:k}).$$

在有了以上结论后，我们可以给出 SIS 算法如下：

算法 2-1 序贯 Monte Carlo 算法

Algo.2-1 Sequential Monte Carlo Algorithm

- 1 在 $k = 0$ 时刻，从初始分布 $p(x_0)$ 中抽取 N 个样本
 $x_0^{(i)} \sim p(x_0), i = 1, \dots, N$ ，令 $\{\mathbf{X}_0^{(i)} = x_0^{(i)}\}$ ，计算初始权重
 $w_0^{(i)} = p(z_0|x_0^{(i)})$ 和归一化权重 $\bar{w}_k^{(i)} = \frac{w_0^{(i)}}{\sum_{i=1}^N w_0^{(i)}}$ （也可以直接在初始步中
 为所有样本赋权 $\frac{1}{N}$ ）；
- 2 对 $1 \leq k \leq K$ ，在 k 时刻，从 $\pi(x_k|\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k})$ 中抽取 N 个独立同分布样
 本 $x_k^{(i)} \sim \pi(x_k|\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k})$ ，更新样本为 $\mathbf{X}_{0:k}^{(i)} = \{\mathbf{X}_{0:k-1}^{(i)}, x_k^{(i)}\}$ ；
- 3 计算 $w_k^{(i)} = w_{k-1}^{(i-1)} \frac{p(z_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{\pi(x_k^{(i)}|\mathbf{X}_{0:k-1}^{(i)}, \mathbf{Z}_{0:k})}$ ，和对应的归一化权重 $\bar{w}_k^{(i)} = \frac{w_k^{(i)}}{\sum_{i=1}^N w_k^{(i)}}$ ；
- 4 在得到权重和新的样本后，就可以计算状态估计：

$$\hat{x}_k = \mathbb{E}[x_k|\mathbf{Z}_{0:k}] \approx \sum_{i=1}^N \bar{w}_k^{(i)} x_k^{(i)}$$

再令 $k = k + 1$ ，回到 2。

$p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 以及 $p(x_k|\mathbf{Z}_{0:k})$ 的经验近似可以利用 (2-15) 和 (2-16) 得到。

2.6 序贯重要性重采样

通过将时序特性引入 IS 方法得到的 SIS 方法，在没有带来随着时间演进逐步增加的计算复杂性的情况下解决了滤波问题实时更新的问题。但已经正如前文所说，随着时间演进，除少数粒子外，大部分粒子的权重都会逐渐收敛到 0、使得总体权重的方差逐渐增大，这一现象会导致大部分粒子对于系统状态的估计在本质上没有起到作用。这一不可避免的现象被称作粒子退化，参考文献 [22] 中有相关的详细证明。

解决以上问题的一个常见方法为重采样。重采样就是以现有样本的重要性权重构成的离散分布为依据，从中重新抽取 N 个样本。这一方法的本质思想为：将权重较小的粒子舍弃、空缺的粒子通过复制权重较大的粒子来补充，让新样本集对系统状态的估计值更加准确。详细描述可见算法 2-2。

尽管不会对样本的理论分布产生影响，但重采样过程本身会导致方差额外的增大。分层重采样在方差意义下，是目前已有的诸多重采样方法中最优的。但为了实现简单，本文拟采用的重采样方法是相对简单且容易实施的多项式重采样算法^[17]。

算法 2-2 重采样

Algo.2-2 Resampling

- 1 将 k 时刻第 i 个样本 $X_k^{(i)}$ 对应的归一化权重 $\bar{w}_k^{(i)}$ 作为该样本对应的概率构建一个离散分布 $\Pi(X_k^{(i)}) = \bar{w}_k^{(i)}$;
- 2 从离散分布 $\Pi(X_k^{(i)}) = \bar{w}_k^{(i)}$ 中抽取 N 个新的样本 $\tilde{X}_k^{(i)}$ 代替旧的样本 $X_k^{(i)}$;
- 3 更新新样本的归一化权重为 $\bar{w}_k^{(i)} = \frac{1}{N}$ 。

算法 2-3 多项式重采样

Algo.2-3 Multinomial Resampling

- 1 从均匀分布 $\mathcal{U}(0, 1]$ 中获得样本 u_i ;
- 2 若存在 $\sum_{i=0}^{M-1} \bar{w}_k^{(i)} < u_i \leq \sum_{i=0}^M \bar{w}_k^{(i)}$, 则让 $\tilde{X}_k^{(i)} = X_k^{(M)}$ (这里额外定义 $\bar{w}_k^{(0)} = 0, M = 1, 2, \dots, N$);
- 3 按顺序重复步骤 1 和步骤 2 共 N 次, 得到新的样本集合 $\{\tilde{X}_k^{(i)}\}_{i=1}^N$;
- 4 更新归一化权重为 $\bar{w}_k^{(i)} = \frac{1}{N}$ 。

序贯重要性重采样算法 (SIR) 就是通过在算法 2-1 中加入一步重采样得到的。但因为经过了一步重采样, 显然, 此时的样本不再是独立同分布的样本了。同时, 因为权重高的粒子会被赋予更大的重采样概率, 这一过程会导致粒子多样性的下降。为了最大限度的保证粒子的多样性, 在 SIR 算法中, 人们需要再引入一个度量方法来判断是否有必要进行重采样步骤。Kong^[22] 提出了一种重采样方法, 该方法具有自适应的特性, 主要是通过引入 “有效粒子数” 来判断重采样的进行时机。该方法中有效样本数的定义如下:

$$N_{eff} = \frac{N}{1 + \text{Var}_{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}(w(\mathbf{X}_{0:k}))} = \frac{N}{E_{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}[(w(\mathbf{X}_{0:k}))^2]} \leq N. \quad (2-25)$$

在实际应用中, 一般无法直接求出精确的 N_{eff} , 所以通常利用强大数定律给出 N_{eff} 的一个估计 $\hat{N}_{eff}$ 作为替代, 根据:

$$1 = \mathbb{E}_{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}[w(\mathbf{X}_{0:k})] \approx \frac{1}{N} \sum_{i=1}^N w_k^{(i)}$$

可知

$$N \approx \sum_{i=1}^N w_k^{(i)}.$$

同样的, 根据

$$\mathbb{E}_{\pi(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})}[(w(\mathbf{X}_{0:k}))^2] \approx \frac{1}{N} \sum_{i=1}^N (w_k^{(i)})^2,$$

我们有

$$N_{eff} \approx \frac{N}{\frac{1}{N} \sum_{i=1}^N (w_k^{(i)})^2} = \frac{N^2}{\sum_{i=1}^N (w_k^{(i)})^2} \approx \frac{\left(\sum_{i=1}^N w_k^{(i)} \right)^2}{\sum_{i=1}^N (w_k^{(i)})^2} = \frac{1}{\sum_{i=1}^N (\bar{w}_k^{(i)})^2} \triangleq \hat{N}_{eff},$$

就得到了精确有效粒子数的一个近似。

在有了有效粒子数后，可以通过设定阈值的方法来决定是否进行重采样。也就是设定一个位于区间 $(0, 1)$ 内的值 l ，当 $\hat{N}_{eff}/N < l$ 时，就执行重采样步骤，反之则直接进行状态估计。在目前的实际应用中，这个阈值通常选取 0.5 到 0.9 之间的某个常数。这时，我们就有了如下的算法 2-4，这是一个通用的粒子滤波框架。

算法 2-4 序贯重要性重采样

Algo.2-4 Sequential Importance Resample

- 1 $k = 0$ 时，抽取 N 个独立同分布的初始样本 $x_0^{(i)} \sim p(x_0)$ ，再令 $\{\mathbf{X}_0^{(i)} = x_0^{(i)}\}_{i=1}^N$ ，计算初始权重 $w_0^{(i)} = p(z_0|x_0^{(i)})$ ，并归一化权重 $\bar{w}_0^{(i)} = \frac{w_0^{(i)}}{\sum_{i=1}^N w_0^{(i)}}$ ；
 - 2 对于 $0 \leq k \leq K$ ，计算 $\hat{N}_{eff}$ ，当 $\hat{N}_{eff}/N \leq l$ 时，进行重采样步骤，并更新权重为 $w_k^{(i)} = \frac{1}{N}$ ；当 $\hat{N}_{eff}/N > l$ 时，跳过重采样，令 $k = k + 1$ ；
 - 3 对 $1 \leq k \leq K$ ，抽取 N 个独立同分布的样本 $x_k^{(i)} \sim \pi(x_k|\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k})$ ，令 $\mathbf{X}_{0:k}^{(i)} = \{\mathbf{X}_{0:k-1}^{(i)}, x_k^{(i)}\}$ ；
 - 4 计算更新后的权重 $w_k^{(i)} = w_{k-1}^{(i)} \frac{p(z_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{\pi(x_k^{(i)}|\mathbf{X}_{0:k-1}^{(i)}, \mathbf{Z}_{0:k})}$ 并归一化 $\bar{w}_k^{(i)} = \frac{w_k^{(i)}}{\sum_{i=1}^N w_k^{(i)}}$ ，回到步骤 2。
-

算法 2-5 标准粒子滤波算法

Algo.2-5 Standard Particle Filter

- 1 在初始时刻 $k = 0$ 时，从先验概率密度函数中抽取 N 个独立同分布初始样本 $x_0^{(i)} \sim p(x_0)$ ，令 $\{\mathbf{X}_0^{(i)} = x_0^{(i)}\}_{i=1}^N$ ，将初始权重初始化为 $w_0^{(i)} = \frac{1}{N}$ ；
 - 2 在 $0 \leq k \leq K$ 的情况下进行执行重采样步骤；
 - 3 当 $1 \leq k \leq K$ 时，在 k 时刻，以状态转移概率函数作为重要性密度函数，从中抽取 N 个独立同分布的样本 $x_k^{(i)} \sim p(x_k|x_{k-1}^{(i)})$ ，并将原有样本延伸为 $\mathbf{X}_{0:k}^{(i)} = \{\mathbf{X}_{0:k-1}^{(i)}, x_k^{(i)}\}$ ；
 - 4 重新计算重要性权重 $w_k^{(i)} = p(z_k|x_k^{(i)})\bar{w}_{k-1}^{(i)}$ 并对权重进行归一化 $\bar{w}_k^{(i)} = \frac{w_k^{(i)}}{\sum_{i=1}^N w_k^{(i)}}$ ，并返回 2。
-

利用 (2-15) 和 (2-16), 我们可以得到 SIR 算法对 $p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k})$ 和对应边缘密度 $p(x_k|\mathbf{Z}_{0:k})$ 的经验估计。从前面的论述中可以看出, 在 SIR 算法的表现中, 重要密度函数选取的优劣起到了核心的作用。接下来, 我们将会给出最小权重方差意义下的最优重要性函数和几种替代的次优重要性函数的选取方法。作为一个例子, 算法 2-5 是一种最常用的 SIR 算法—标准粒子滤波算法 (Particle Filter, PF), 这种算法也被称为自举粒子滤波算法。PF 算法选取状态转移密度函数 $p(x_k|x_{k-1})$ 作为重要性密度函数, 具有实现简单的优点。但因为 $p(x_k|x_{k-1})$ 没有使用可以从量测 z_k 得到的信息, 因此对异常值具有较高的敏感性且计算效率偏低。因此, 为了保证此方法获得足够的健壮性, 需要提供较多的粒子数。同时, 因为在传统的 PF 算法在执行时, 每一次都需要重采样, 也会导致计算负担的增加和粒子多样性的损伤。

2.7 最优重要性密度函数

根据前面的讨论我们知道, 不管是基本的 IS, 还是添加了序贯特性的 SIS 或增加了重采样步骤的 SIR, 重要性密度函数都起着最核心的作用。但是对重要性函数的选择理论上没有任何限制使得重要性函数的选取存在着一定的困难。确定哪种重要性函数最好的一种度量方法是最小化权重的方差, 在这一度量标准下, Doucet 在形式上给出了的最优重要性函数 (Optimal Importance Function, OIF) 表达式和具有较高可行性的几种次优重要性函数 (Suboptimal Importance Function, SOIF) 的备选方案^[29]。关于最小权重方差的最优重要性函数, 我们有结论: 在给定 $\mathbf{X}_{0:k-1}^{(i)}$ 和 $\mathbf{Z}_{0:k}$ 时, $\pi(x_k|\mathbf{X}_{0:k-1}^{(i)}, \mathbf{Z}_{0:k}) = p(x_k|x_{k-1}^{(i)}, z_k)$ 是使重要性权重 $w_k^{(i)}$ 方差最小的重要性函数。

当选取 $\pi(x_k|\mathbf{X}_{0:k-1}^{(i)}, \mathbf{Z}_{0:k}) = p(x_k|x_{k-1}^{(i)}, z_k)$ 时, 在权重更新过程中, 我们有:

$$w_k^{(i)} = w_{k-1}^{(i)} \frac{p(z_k|x_k)p(x_k|x_{k-1}^{(i)})}{p(x_k|x_{k-1}^{(i)}, z_k)}.$$

对 $p(x_k|x_{k-1}^{(i)}, z_k)$ 进行分解并利用系统的一阶 Markov 性就有

$$\begin{aligned} p(x_k|x_{k-1}^{(i)}, z_k) &= \frac{p(x_k, x_{k-1}^{(i)}, z_k)}{p(x_{k-1}^{(i)}, z_k)} \\ &= \frac{p(z_k|x_k, x_{k-1}^{(i)})p(x_k|x_{k-1}^{(i)})}{p(z_k|x_{k-1}^{(i)})} \\ &= \frac{p(z_k|x_k)p(x_k|x_{k-1}^{(i)})}{p(z_k|x_{k-1}^{(i)})}. \end{aligned}$$

从上面的推导可以看出，如果我们令 $\pi(x_k|\mathbf{X}_{0:k-1}^{(i)}, \mathbf{Z}_{0:k}) = p(x_k|x_{k-1}^{(i)}, z_k)$ ，则此时的 $w_k^{(i)} = w_k^{(i-1)}p(z_k|x_{k-1}^{(i)})$ 就只与已经确定的样本 $\mathbf{X}_{0:k-1}^{(i)}$ 与观测量 $\mathbf{Z}_{0:k}$ 相关，而与最新时刻 k 的系统状态 x_k 无关。此时的样本权重的更新量就是 $p(z_k|x_{k-1}^{(i)})$ 。通过计算 $w_k^{(i)}$ 的方差如下

$$\begin{aligned} & \text{Var}_{\pi(x_k|\mathbf{X}_{0:k-1}^{(i)}, \mathbf{Z}_{0:k})} [w_k^{(i)}] \\ &= \left(w_{k-1}^{(i)}\right)^2 \left[\int p^2(z_k|x_{k-1}^{(i)})p(x_k|x_{k-1}^{(i)}, z_k)dx_k - p^2(z_k|x_{k-1}^{(i)}) \right] \\ &= 0. \end{aligned} \quad (2-26)$$

因此 $p(x_k|x_{k-1}^{(i)}, z_k)$ 就被称为在方差最小意义下的最优重要性密度函数，也称为最优重要性密度函数。而从上面的证明过程中可以发现， k 时刻的重要性权重 $w_k^{(i)}$ 并不依赖于 k 时刻的样本 $\{x_k^{(i)}\}_{i=1}^N$ ，可以在得到 k 时刻的样本 $\{x_k^{(i)}\}_{i=1}^N$ 之前就计算出来。但如果要使用 OIF，则必须要能够在 $p(x_k|x_{k-1}^{(i)}, z_k)$ 中抽样；同时在对重要性权重进行更新时有： $w_k^{(i)} = w_{k-1}^{(i)}p(z_k|x_{k-1}^{(i)})$ ，也就是说，我们必须能够计算

$$p(z_k|x_{k-1}^{(i)}) = \int p(z_k|x_k)p(x_k|x_{k-1}^{(i)})dx_k. \quad (2-27)$$

一般而言，我们很难满足这两个条件。一种可以使用最优重要性函数的情形是：对于状态序列 $\{x_k, k \in \mathbb{N}\}$ 具有有限状态且是一个 Markov 链时，可以做到直接从 $p(x_k|x_{k-1}^{(i)}, z_k)$ 中抽取样本，而且此时 (2-27) 中积分计算的困难也消失了（积分计算变为求和计算）。

例 2-1 非线性 Gauss 状态空间模型：

$$\begin{aligned} \mathbf{x}_k &= f(\mathbf{x}_{k-1}) + \mathbf{v}_k, \quad \mathbf{v}_k \sim \mathcal{N}(\mathbf{0}_{n_v \times 1}, \Sigma_v) \\ \mathbf{y}_k &= \mathbf{C}\mathbf{x}_k + \mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(\mathbf{0}_{n_w \times 1}, \Sigma_w). \end{aligned} \quad (2-28)$$

其中 $f: \mathbb{R}^{n_x} \rightarrow \mathbb{R}^{n_x}$ ， $\mathbf{C}^{n_y \times n_x}$ 是观测矩阵， $\mathbf{w}_k, \mathbf{v}_k$ 是互相独立的独立同分布 Gauss 噪声，其中 $\Sigma_v > 0, \Sigma_w > 0$ ， Σ_v 和 Σ_w 都是已知的。在 (2-28) 中可观察到，噪声都是加性的，因此可以直接写出状态转移函数 $p(\mathbf{x}_k|\mathbf{x}_{k-1})$ 和似然函数 $p(\mathbf{y}_k|\mathbf{x}_{k-1})$ ：

$$p(\mathbf{x}_k|\mathbf{x}_{k-1}) = \mathcal{N}(f(\mathbf{x}_{k-1}), \Sigma_v), \quad (2-29)$$

$$p(\mathbf{y}_k|\mathbf{x}_k) = \mathcal{N}(\mathbf{C}\mathbf{x}_k, \Sigma_w). \quad (2-30)$$

利用隐 Markov 条件，我们有 $p(\mathbf{y}_k|\mathbf{x}_k, \mathbf{x}_{k-1}) = p(\mathbf{y}_k|\mathbf{x}_k)$ ，我们可以将条件分布写为：

$$p(\mathbf{x}_k, \mathbf{y}_k | \mathbf{x}_{k-1}) = \mathcal{N} \left(\begin{bmatrix} f(\mathbf{x}_{k-1}) \\ \mathbf{C}f(\mathbf{x}_{k-1}) \end{bmatrix}, \begin{bmatrix} \Sigma_v & \Sigma_v \mathbf{C}^T \\ \mathbf{C}\Sigma_v & \mathbf{C}\Sigma_v \mathbf{C}^T + \Sigma_w \end{bmatrix} \right), \quad (2-31)$$

$$p(\mathbf{y}_k | \mathbf{x}_{k-1}) = \mathcal{N}(\mathbf{C}f(\mathbf{x}_{k-1}), \mathbf{C}\Sigma_v \mathbf{C}^T + \Sigma_w).$$

定义分块矩阵

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} = \begin{bmatrix} \Sigma_v & \Sigma_v \mathbf{C}^T \\ \mathbf{C}\Sigma_v & \mathbf{C}\Sigma_v \mathbf{C}^T + \Sigma_w \end{bmatrix} \quad (2-32)$$

直接观察可知 $A_{22} - A_{21}A_{11}^{-1}A_{12} = \Sigma_w$, 定义 $\Sigma = A_{11} - A_{12}A_{22}^{-1}A_{21}$, 根据矩阵反演公式

$$(A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1} = A_{11}^{-1} + A_{11}^{-1}A_{12}(A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1}A_{21}A_{11}^{-1}$$

我们有

$$\Sigma^{-1} = A_{11}^{-1} + A_{11}^{-1}A_{12}(A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1}A_{21}A_{11}^{-1}, \quad (2-33)$$

计算后有

$$\Sigma^{-1} = \Sigma_v^{-1} + \mathbf{C}^T \Sigma_w^{-1} \mathbf{C}. \quad (2-34)$$

同样根据矩阵反演公式

$$A_{11}^{-1}A_{12}(A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1} = (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1}A_{12}A_{22}^{-1}$$

有

$$\begin{aligned} A_{12}A_{22}^{-1} &= (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1}A_{12}A_{22}^{-1}(A_{22} - A_{21}A_{11}^{-1}A_{12}) \\ &= \Sigma \mathbf{C}^T \Sigma_w^{-1}, \end{aligned} \quad (2-35)$$

于是就有

$$\begin{aligned} \mathbf{m}_k &= f(\mathbf{x}_{k-1}) + A_{12}A_{22}^{-1}(\mathbf{y}_k - \mathbf{C}f(\mathbf{x}_{k-1})) \\ &= \Sigma((\Sigma^{-1} - \mathbf{C}^T \Sigma_w \mathbf{C})f(\mathbf{x}_{k-1}) + \mathbf{C}^T \Sigma_w^{-1} \mathbf{y}_k) \\ &= \Sigma(\Sigma_v^{-1} f(\mathbf{x}_{k-1}) + \mathbf{C}^T \Sigma_w^{-1} \mathbf{y}_k). \end{aligned} \quad (2-36)$$

就有

$$\mathbf{x}_k | (\mathbf{x}_{k-1}, \mathbf{y}_k) \sim \mathcal{N}(\mathbf{m}_k, \Sigma), \quad (2-37)$$

以及

$$p(\mathbf{y}_k | \mathbf{x}_{k-1}) \propto \exp \left(-\frac{1}{2} (\mathbf{y}_k - \mathbf{C}f(\mathbf{x}_{k-1}))^T (\Sigma_v + \mathbf{C}\Sigma_w \mathbf{C}^T)^{-1} \times (\mathbf{y}_k - \mathbf{C}f(\mathbf{x}_{k-1})) \right). \quad (2-38)$$

2.8 次优重要性函数

当我们无法获得最优重要性函数的解析表达式或者最优重要性函数难以应用（比如难以采样）时，我们需要使用一个容易计算且容易采样的函数来近似最优重要性函数，这样的函数也被称为次优重要性函数，本节将给出几个在粒子滤波中比较常见的次优重要性函数，并简单阐述它们的性质，并选用一个作为对照组来对比本文中提出的粒子滤波算法的效果。

2.8.1 基于局部线性化的次优重要性函数

例 2-2 考虑如下模型

$$\begin{aligned}\mathbf{x}_k &= f(\mathbf{x}_{k-1}) + \mathbf{v}_k, \quad \mathbf{v}_k \sim \mathcal{N}(\mathbf{0}_{n_v \times 1}, \Sigma_v) \\ \mathbf{y}_k &= g(\mathbf{x}_k) + \mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(\mathbf{0}_{n_w \times 1}, \Sigma_w).\end{aligned}\tag{2-39}$$

其中 $f: \mathbb{R}^{n_x} \rightarrow \mathbb{R}^{n_x}$, $g: \mathbb{R}^{n_x} \rightarrow \mathbb{R}^{n_y}$ 都是可微的非线性函数。 $\mathbf{w}_k, \mathbf{v}_k$ 是互相独立的独立同分布 Gauss 噪声，其中 $\Sigma_v > 0, \Sigma_w > 0$ 并且 Σ_v 和 Σ_w 都是已知的。通过对观测方程进行精确到一阶导数的近似^[47]，可以得到

$$\mathbf{y}_k = g(\mathbf{x}_k) + \mathbf{w}_k \approx g(f(\mathbf{x}_{k-1})) + \left. \frac{\partial g(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k=f(\mathbf{x}_{k-1})} + \mathbf{w}_k.\tag{2-40}$$

我们现在通过在 $\mathbf{x}_k = f(\mathbf{x}_{k-1})$ 处对 $g(\mathbf{x}_k)$ 进行了一阶 Taylor 展开定义了一个对原观测方程的线性近似，此时我们就有了一个与 (2-28) 形状相同的，具有线性观测方程的状态-观测方程，因此此时我们可以将在例 2-1 中给出的计算应用在线性化以后的方程上。尽管在线性化观测方程后的模型不再具有一阶隐 Markov 性，即 $p(y_k | x_k, x_{k-1}) \neq p(y_k | x_k)$ ，但二者仍然有着相似的结构，因此也就得到了一个重要性函数。本质上说，就是通过使用一个线性函数近似观测方程来并将该近似系统的最优重要性函数作为原始系统的次优重要性函数。

2.8.2 先验重要性函数

2.8.1 中提出的次优重要性函数的计算方法的主要缺陷在于，需要对观测函数 g 求导数，而在很多情况下，观测函数的导数往往是不存在的。此时我们往往可以考虑一种相对简单的选择：将隐 Markov 模型的先验分布（状态转移函数）作为重要性函数。这种重要性函数的选择来自于 Handschin 与 Mayne^[48] 与 Handschin^[49] 开创性的提出。在这种情况下，我们有 $\pi(\mathbf{x}_k | \mathbf{X}_{0:k}, \mathbf{Z}_{0:k}) = p(x_k | x_{k-1})$ ，且 $\omega_k^{(i)} = \omega_{k-1}^{(i)} p(z_k | x_k^{(i)})$ 。这一方法的主要优点包括：

(1) 权重的更新量仅为似然函数 $p(z_k | x_k^{(i)})$ ，在观测方程已知的情况下，似然

函数作为权重的更新量是很容易计算的；

(2) 以该函数作为重要性函数的粒子滤波算法计算量小，因为该重要性函数的获得不需要对状态转移方程或观测方程求导数；

(3) 适用范围广，该函数对状态-观测方程的性质几乎没有要求，这使得几乎所有所有的观测方程和状态转移方程已知的模型都可以使用这一状态转移函数作为重要性函数。

2.8.3 固定重要性函数

在某些更为极端的情况下，即便是先验的状态转移函数也难以应用，此时一种更简单的解决方案是直接让重要性函数同过去的系统状态和观测数据完全独立。在这种情况下，我们有 $\pi(\mathbf{x}_k|\mathbf{X}_{0:k}, \mathbf{Z}_{0:k}) = \pi(x_k)$ ，而此时的权重更新的计算式可以重写为：

$$\omega_k^{(i)} = \omega_{k-1}^{(i)} \frac{p(z_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{\pi(x_k^{(i)})}. \quad (2-41)$$

这一类函数的主要的选取目标包括均匀分布、Gauss 分布、Gauss 混合分布以及其他任意容易采样且容易计算的概率密度函数。可以看出，该函数的主要优点是对于状态-观测方程模型的本身性质不具备任何要求，对于后验分布的了解也只需要精确到归一化常数上。但是由于此类重要性函数本身不包含任何状态-观测的任何信息，这使得采样的效率会很差，很难取得充足的有效样本数量。如果我们可以先验的知道某些关于目标函数的模态的信息，则可以通过在高后验密度区多采样的方式来获得一个比较好的采样效率，但这通常都是不太容易实现的。

2.9 本章小结

本章给出了一些滤波问题方面的预备知识，描述了隐 Markov 模型和动态系统模型。对最通用的一般动态系统，基于 Bayes 定理给出了对应 Bayesian 滤波框架的推导过程，同时也给出了在实际应用中，Bayesian 滤波的主要难点包括：计算高维积分、求解反函数和函数求导等。

接下来，本章给出了 Bayesian 滤波问题本质上就是求取条件期望 $\mathbb{E}[g(x_k)|\mathbf{Z}_{0:k}] = \int g(x_k)p(x_k|\mathbf{Z}_{0:k})dx_k$ 这一论断，从而将滤波问题简化为更加直观的积分问题。在具备直接从 $p(x_k|\mathbf{Z}_{0:k})$ 中抽取样本的条件时，积分问题的一个比较精确的近似解可以直接使用 Monte Carlo 方法得到。对于难以直接

采样的 $p(x_k|\mathbf{Z}_{0:k})$ ，给出了使用来自其他分布的样本，通过调整权重来估计积分值的 IS 方法。而单纯的 IS 方法在更新重要性权重时需要存储过去的所有状态导致计算量和空间存储会随着时间的无限延展而无限延展，这对于有限的计算和存储空间而言是不可接受的，为了克服这一缺点，人们引入了 SIS 方法，这种方法可以显著降低计算复杂性，作为代价，将不可避免的引入粒子退化问题，关于粒子退化不可避免问题的证明，本章也给出了参考文献。本章同样给出了为了对抗粒子退化问题而引入的重采样步骤的本质思想，并简要介绍了 SIR 算法的基本框架，其中重点讨论了较易实施的多项式重采样方法和对应的经典标准粒子滤波算法。在本章末尾，从退化分布的观点出发证明了 OIF 为 $p(x_k|x_{k-1}^{(i)}, z_k)$ ，并给出了几种在 OIF 难以获得或应用时的替代的 SOIF。

第 3 章 输运 Monte Carlo 与粒子滤波

3.1 确定性与随机性输运

为了能较好的引入 TMC 方法, 定义一些相关符号并给出相关输运概念的简单回顾。这里, 不拘泥于单纯的滤波问题中的系统状态 x , 考虑更典型的参数估计问题: $\theta \in \Theta$, 记 $\Pi_0(\theta)$ 为先验密度/质量函数, y 为对应的观测数据并记对应的似然函数为 $L(y; \theta)$ 。在这一记号下, 我们有后验分布:

$$\Pi(\theta; y) = \frac{L(y; \theta)\Pi_0(\theta)}{z(y)}. \quad (3-1)$$

记相关的测度 $\mu_\theta : \mathcal{B}(\Theta) \rightarrow \mathbb{R}^+$, 其中 $\mathcal{B}$ 代表了 Borel σ -代数, $z(y)$ 是对应的归一化常数, 在连续情形写作: $z(y) = \int_{\Theta} L(y; \theta)\Pi_0(\theta)d\theta$; 离散情形写作: $z(y) = \sum_{\Theta} L(y; \theta)\Pi_0(\theta)$ 。在绝大多数关于系统状态和参数估计的研究中, 我们感兴趣的的就是服从该后验分布的随机变量 $\theta \sim \Pi(\theta; y)$ 。而在实际的研究中, 从这个后验分布的样本通常很难得到, 为了能快速得到大量服从后验分布的样本, 人们引入了输运 Monte Carlo 方法。通过额外引入一个来自于被称为参考分布 (reference distribution) 的随机变量 $\beta \in \beta$:

$$\beta \sim \Pi_r(\beta).$$

这里, $\Pi_r(\beta)$ 是来自另一个测度 $\mu_\beta : \mathcal{B}(\beta) \rightarrow \mathbb{R}^+$ 的密度/质量函数。通过将 β 映射为 θ 得到服从后验分布的随机变量的过程就被称为输运过程。

最初的输运灵感来自于土方运输问题: 将服从离散分布的随机变量想象为一系列土堆, 在位置 β 上土的质量为 $\Pi_r(\beta)$ (这一想象对于离散的密度质量函数比较容易, 对于连续分布, 可以将位置 β 的质量想象为该位置的密度乘以一个小的体积邻域)。输运的思想就是让我们将原来处于位置 β 的所有土堆按照某种策略移动到位置 θ 处, 使得每个位置 θ 包含质量 $\Pi(\theta; y)$, 这样, 我们就可以从容易采样的参考分布 Π_r 中获得难以采样的后验分布的随机变量 θ 。一种较为朴素的输运策略是 Monge 输运^[50]: 在参考分布 Π_r 的支撑集全体 β 上, 将每一处 β 所有的质量一次性移动到新的位置 $\theta = T(\beta)$ 处, 此处 T 是一个确定性的映射 $T : \beta \rightarrow \Theta$ 使得 $\mu_\theta(\mathcal{A}) = \mu_\beta[\{x : T(x) \in \mathcal{A}\}]$ 对一切 $\mathcal{A} \in \mathcal{B}(\Theta)$ 成立。这种确定性的映射方法的问题主要在于:

- (1) 对参考分布和目标分布本身的性质有一定的要求, 而当参考分布和目

标分布不满足这些性质时, Monge 输运策略是不存在的, 也就是没有可行的映射 T 使得 $\mu_\theta(\mathcal{A}) = \mu_\beta[\{x : T(x) \in \mathcal{A}\}]$ 成立, 一个很经典的例子就是: 对于一个确定性的映射而言, 将一个质量点分布映射为伯努利分布 (以概率 p_1 取值 1, $1 - p_1$ 取值 0) 是不可能的;

(2) 对映射 T 的参数化往往缺少足够好、具有足够灵活性的方案, 这在一定程度上限制了确定性输运方案的灵活性。同时, 如果 $\Pi(\theta; y)$ 具有比较复杂的结构的话, 对其参数化的难度也会进一步提升。

因为 Monge 输运的限制, 促使人们开发了另一种名为 Kantorovich 输运^[51]的输运策略, 其主要思路为: 在位置 β , 我们并不将所有质量按照相同的方法进行输运, 而是构建一个条件概率分布 $\Pi(\theta|\beta)$, 根据这个条件概率分布选择不同的输运映射, 使得即便 β 是固定的值, 我们仍旧会在每一次输运中得到不同的可能的取值 $\theta_1, \theta_2, \theta_3 \dots$, 这一过程可以被理解为将 β 处的质量分割为更小的单位并输运到对应的位置上去。对于之前提到的: 从质量点到伯努利分布的输运, 我们可以取条件分布 $\text{pr}(\theta = 1|\beta = 0) = p_1$ 和 $\text{pr}(\theta = 0|\beta = 0) = 1 - p_1$ 来解决传统确定性输运无法胜任的问题。

与确定性输运需要对参考分布和目标分布的性质进行某些限制不同, Kantorovich 输运的存在性是必然的。因为它等价于寻找一个 θ 和 β 的联合分布, 该分布也被称为输运计划 (transport plan):

$$(\theta, \beta) \text{ 使得 } \int_{\beta} \Pi(\theta, \beta) d\beta = \Pi(\theta; y), \quad \int_{\theta} \Pi(\theta, \beta) d\theta = \Pi_r(\beta). \quad (3-2)$$

这一公式是描述的是连续情形下的输运计划, 对于离散的情况, 我们将积分号替换为求和号即可。这里为了符号的简洁, 在 $\Pi(\theta, \beta)$ 中对于观测量 y 的条件符号被略去了。

3.2 确定性输运的简述

3.2.1 输运的定义与评价标准

对确定性输运而言, 其最初的主要目标是将先验测度映射为后验测度, 也就是对目标测度 $\mu, \theta \sim \mu$ 和参考测度 $\mu_0, \beta \sim \mu_0$, 寻找映射 f 满足

$$\theta = f(\beta), \beta \sim \mu_0, \theta \sim \mu.$$

这样一个映射就是在概率测度之间引入了一个确定性的耦合。在本文的记号中, 也就是将密度函数 $\Pi(\theta; y)$ 映射为 Π_0 :

$$\tilde{\Pi}_0(\theta) = z(y)^{-1} L(y; T(\theta; y)) \Pi(T(\theta)) |\det D_\theta T|. \quad (3-3)$$

此处的 $z(y)$ 为归一化常数。此时，我们可以很自然的引入一个对于输运映射 T 的好坏的度量标准，因为在理想的情况下， T 应当满足：

$$\tilde{\Pi}_0 = \Pi_0. \quad (3-4)$$

此时，我们将问题转化为寻找一个映射 T 使得：

$$\frac{[L \circ T](\theta) [\Pi_0 \circ T](\theta)}{z(y)} |\det D_\theta T| = \Pi_0(\theta) \quad (3-5)$$

成立。在很多情况下（比如似然函数或先验函数具有指数部分），我们可以将 (3-5) 进一步转化为加法形式：

$$\log(L \circ T) + \log(\Pi_0 \circ T) - \log(z(y)) + \log |\det D_\theta T| - \log \Pi_0 = 0, \quad (3-6)$$

可以看出，尽管在上式中出现了归一化常数 $\log(z(y))$ ，但在求解过程中，我们实际上并不需要任何归一化常数的相关信息。

上面的推论主要是在理想情形下进行的，在现实中，为了对 T 进行合适的参数化，我们通常无法得到 T 的精确解，我们面对的通常是一个寻找使得近似先验分布 $\tilde{\Pi}_0$ 和真实先验分布 Π_0 之间的差距最小的 T 的优化问题。对于这个差距的表示，我们主要有 Kullback-Leibler 散度和两个概率密度 p 和 $\tilde{p}$ 之间的 Hellinger 距离 $Q(p, \tilde{p})$ 两种度量：

$$\begin{aligned} Q(p, \tilde{p}) &= \frac{1}{2} \int \left(\sqrt{p(x)} - \sqrt{\tilde{p}(x)} \right)^2 dx \\ &= \frac{1}{2} \int p(x) + \tilde{p}(x) - 2\sqrt{p(x)\tilde{p}(x)} dx \\ &= \int 1 - \sqrt{p(x)\tilde{p}(x)} dx \\ &= 1 - \int p(x) \sqrt{\frac{\tilde{p}(x)}{p(x)}} dx \\ &= 1 - \mathbb{E} \left[\sqrt{\frac{\tilde{p}(x)}{p(x)}} \right]. \end{aligned} \quad (3-7)$$

类似的， p 和 $\tilde{p}$ 之间的 Kullback-Leibler (KL) 散度可以重写为

$$D_{KL}(p \parallel \tilde{p}) = \int p(x) \log \frac{p(x)}{\tilde{p}(x)} dx = -\mathbb{E} \left[\log \frac{\tilde{p}(x)}{p(x)} \right]. \quad (3-8)$$

(3-7) 中的平方根和 (3-8) 中的对数函数都是上凸函数，根据 Jensen 不等式，对任意上凸函数 Φ ，我们有

$$\mathbb{E} \left[\Phi \left(\frac{\tilde{p}}{p} \right) \right] \leq \Phi \left(\mathbb{E} \left[\frac{\tilde{p}}{p} \right] \right), \quad (3-9)$$

因此, 最小化 (3-7) 和 (3-8) 也就是要让 (3-9) 的左侧最大化, 也就是说需要让 (3-9) 中的小于等于号取到等号。但我们知道, 在 Jensen 不等式中等号成立当且仅当 $\tilde{p}/p$ 对一切 x 为一个常数^[52]。重写 (3-5) 后, 我们得到归一化常数的表达式

$$z(y) = \frac{[L \circ T](\theta)[\Pi_0 \circ T](\theta)}{\Pi_0(\theta)} |\det D_\theta T|. \quad (3-10)$$

对上式取对数, 就有

$$\text{Dis}(\theta; T) := \log(L \circ T) + \log(\Pi_0 \circ T) + \log |\det D_\theta T| - \log \Pi_0 = \log(z(y)). \quad (3-11)$$

它表明 $\text{Dis}(\theta; T)$ 对先验分布的支撑集应当是一个常数。而如果 Dis 为一个常数, 就将问题转化为

$$T^* = \arg \min_T \text{Var}[\text{Dis}(\theta; T)], \quad (3-12)$$

此处 $\theta \sim \Pi_0$ 。这是因为当 $\text{Dis}(\theta; T)$ 为一个常数时, 它的方差为 0, 而方差总是大于等于 0 的。因此, 也可以说 (3-11) 给出了问题的优化目标, 也就是输运 Monte Carlo 方法的基础。

在实际应用中, 如果 T 的候选函数空间足够丰富的话, 则 (3-12) 的最小值 0 在理论上是可以取得的。从之前的论述也可以看出, 对 (3-12) 的最小化本质上就是在最小化目标密度函数 p 和近似的密度函数 $\tilde{p}$ 之间差异的度量函数。虽然 $z(y)$ 并没有在 Dis 中出现, 使得我们在求取 T 时无法得到归一化常数 $z(y)$ 的信息。不过, 可以通过公式

$$z(y) = \exp(\mathbb{E}[\text{Dis}(\theta; T)]) \quad (3-13)$$

得到 $z(y)$ 的估计值。类似的, 对于 KL 散度, 我们可以得到一个类似的优化问题

$$D_{\text{KL}}(p \parallel \tilde{p}) = -\mathbb{E} \left[\log \frac{\tilde{p}(X)}{p(X)} \right] = \log(z(y)) - \mathbb{E}[\text{Dis}(T)]. \quad (3-14)$$

因为 $z(y)$ 在这里是常数, 所以最小化 $D_{\text{KL}}(p \parallel \tilde{p})$ 也就等价于寻找

$$T^* = \arg \max_T \mathbb{E}[\text{Dis}(\theta; T)]. \quad (3-15)$$

这个问题与采用 Hellinger 距离度量的优化问题不同, (3-15) 并没有一个已知的、理论上的最优值, 但根据 $\text{Var}[\text{Dis}]$ 来评估收敛性仍然是可行的。

3.2.2 最优映射的构建

多元映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 一般具有如下形式:

$$\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{bmatrix} = \begin{bmatrix} T_1(x_1, x_2, \dots, x_n) \\ T_2(x_1, x_2, \dots, x_n) \\ \vdots \\ T_n(x_1, x_2, \dots, x_n) \end{bmatrix},$$

其中 T_i 是 T 的分量。根据一些比较经典的测度变换文献^[52-53] 可知, 一个将测度 μ_0 映射为 μ 的映射在相对弱的条件下是存在但不唯一的。为了确保所求结果的唯一性, 来保证实际的优化过程中不发生“震荡”, 往往需要引入额外的限制或惩罚。一种比较常见的限制为:

$$\min_T \mathbb{E} [\|X - T(X)\|^2] \quad s.t. \mu = T_{\#}\mu_0. \quad (3-16)$$

这种限制可以大致理解为: 在确保可以将测度 μ_0 映射为 μ 的前提下, 选择总的移动距离最短的一种映射。可以证明^[53], 在相当普遍的条件下, 这个优化问题有唯一解且这个解是单调的。此时, 存在性和唯一性条件的本质是要求测度 μ_0 不含有任何原子。此问题可以重述如下^[31]。

定理 3-1 令 μ_0 和 μ 是 $\mathbb{R}^n$ 上的概率测度, 并且在 Hausdorff 维度小于等于 $n-1$ 的子集上 μ_0 消失。则优化问题 (3-15) 有在 μ_0 上几乎处处唯一确定的解 T 。该映射是一个凸函数的梯度, 因此是单调的。

对此定理的证明可以参考^[54]。

与直接施加额外的等式 (3-16) 的限制不同, 还有一种基于 Rosenblatt 变换^[55-56] 的确保最优映射唯一性的方法, 此时 T 的第 i 个分量仅依赖于前 i 个输入 (使得映射具有“三角形”结构):

$$\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{bmatrix} = \begin{bmatrix} T_1(x_1) \\ T_2(x_1, x_2) \\ \vdots \\ T_n(x_1, x_2, \dots, x_n) \end{bmatrix}. \quad (3-17)$$

在没有额外的惩罚项的情况下, 问题的限制由映射的三角结构提供也可以确保解的唯一性。事实上, 已经证明^[57], 存在唯一的单调映射 T 具有 (3-17) 的形状且满足 $\mu = T_{\#}\mu_0$ 。这一映射被称为 Knothe-Rosenblatt 重排。

如果想要直接计算 Rosenblatt 重排, 则会涉及到一系列的边缘累计条件分

布的求逆和计算问题，这一过程往往涉及计算大量的高维积分，使得直接计算 Rosenblatt 重排具有一定的困难。作为替代，一种更加实际的备选方案是计算最小方差：

$$T^* = \arg \min_T \text{Var}[\text{Dis}[X]]. \quad (3-18)$$

其中 T 受到条件 (3-17) 的约束。

3.3 随机性输运的简述

与确定性的输运映射相对的，也就是随机性的输运映射，也是本文中将要使用的输运映射方案。为了使讨论容易进行，对于接下来讨论的问题，我们假定：我们对目标分布的了解精确到归一化常数，参考分布 Π_r 是一个相对容易采样的已知密度，此时唯一未知的部分就是输运计划。为了更加集中的讨论，我们再这一节集中讨论 β 和 θ 作为连续随机变量的情形。不失一般性，我们假设 θ 和 β 具有相同的维数 p 。

根据 3.1 节对 Kantorovich 输运的描述，对于随机性输运，我们面临的主要任务有两个：寻找输运计划 $\Pi(\beta, \theta)$ 以及构建输运映射集合。对于输运计划而言，其备选实际上是无限的，因为我们可以任意的构建两个随机变量之间的联合分布，对于输运计划 $\Pi(\beta, \theta)$ 而言，我们面临的主要问题是：对于某一 $\beta \sim \Pi_r$ 而言，应当存在某种策略来从备选的输运集合中选择特定的某一个。也就是说，对于某个给定的 β ，存在的条件概率 $\Pi(\theta|\beta)$ 应当以某种概率将 β 映射为不同的 $\theta_1 = T_1(\beta), \theta_2 = T_2(\beta), \dots$ 。直觉上，我们第一时间可能会想直接得到对 $\Pi(\theta|\beta)$ 的近似 $\tilde{\Pi}(\theta|\beta)$ （为了加以区分，我们使用 $\tilde{\Pi}(\cdot)$ 来表示）后立刻就能得到对输运计划的近似 $\tilde{\Pi}(\beta, \theta)$ ，并进一步通过积分得到关于 θ 的边缘分布 $\tilde{\Pi}(\theta; y)$ ，使其近似于后验（目标）分布 $\Pi(\theta; y)$ ，但想要对 $\Pi(\theta|\beta)$ 进行参数化的难度是比较高的。这种难度主要体现在，假如我们对 $\Pi(\theta|\beta)$ 进行某种参数化，得到其近似 $\tilde{\Pi}(\theta|\beta)$ ，则我们根据 Bayes 公式，就有：

$$\tilde{\Pi}(\theta, \beta) = \tilde{\Pi}(\theta|\beta) \cdot \Pi_r(\beta),$$

则此时通过对 β 进行积分，就有

$$\int \tilde{\Pi}(\theta, \beta) d\beta = \tilde{\Pi}(\theta; y).$$

此时，我们想要获得一个评估参数好坏的优劣标准就必须计算期望：

$$\mathbb{E}_{\Pi(\theta; y)} [\text{dis}(\tilde{\Pi}(\theta; y), \Pi(\theta; y))],$$

此处的 $\text{dis}(\cdot, \cdot)$ 是两个概率密度函数之间差异的一个度量, 其具体的形式在 3.2.1 节提供了两个例子。也就是说, 此时我们将陷入循环论证, 我们需要获得对 $\Pi(\theta; y)$ 的近似来获取样本, 然而我们却需要先计算基于密度函数 $\Pi(\theta; y)$ 的期望, 但如果我们能计算基于 $\Pi(\theta; y)$ 的期望, 则构建两个概率密度之间输运这一行为就变得没有意义了。

作为替代, 另一种方法是: 从精确到归一化常数的后验分布 $\Pi(\theta; y)$ 开始, 利用参数化近似条件密度 $\Pi(\beta|\theta)$ 。根据 Bayes 定理, 我们有

$$\Pi(\theta|\beta) = \frac{\Pi(\theta, \beta)}{\Pi_r(\beta)} = \frac{\Pi(\beta|\theta) \cdot \Pi(\theta; y)}{\Pi_r(\beta)}. \quad (3-19)$$

也就是说, $\Pi(\theta|\beta)$ 与后验密度 $\Pi(\theta; y)$ 之间成比例, 因为在此处我们首先获得的是 β , 而 β 已经是一个固定的值。如果我们能够获得 $\Pi(\beta|\theta)$ 的某个近似 $\tilde{\Pi}(\beta|\theta)$, 则根据 Bayes 公式, 我们有 $\tilde{\Pi}_r(\beta) = \int_{\Theta} \tilde{\Pi}(\beta|\theta) \Pi(\theta; y) d\theta$, 而 $\Pi_r(\beta)$ 是一个我们预先选择的、容易采样的概率密度函数, 衡量 $\tilde{\Pi}_r$ 和 Π_r 之间的区别是相对比较容易的。因此, 随机 TMC 方法应当将参数化 $\Pi(\beta|\theta)$ 作为目标。

我们在直觉上, 受到条件密度的贝叶斯非参数近似的启发^[58], 直觉上会使用一个无穷混合来近似精确的条件核 $\Pi(\beta|\theta)$:

$$\tilde{\Pi}(\beta|\theta) = \sum_{k=1}^{\infty} \omega_k(\theta) \delta\{\beta - T_k^{-1}(\theta)\}, \quad (3-20)$$

其中 δ 表示 Dirac delta 函数; $\omega_k(\theta) \geq 0$ 且 $\sum_{k=1}^{\infty} \omega_k(\theta) = 1$ 。实际上, 通过这种 Dirac 函数来近似概率密度的方案, 在本质上与粒子滤波通过样本来近似目标函数的思想是一样的。与条件密度贝叶斯非参数近似相比, 此方法中对 β 获得方式的选择更加广泛, 此处的 β 并不是基于线性变换的预测 $x^T \theta$, 这里的 T_k 是一些可逆且可微的变换。

对于随机变量 $\beta \sim \tilde{\Pi}(\beta|\theta)$ 来说, 我们可以这样理解: 对于来自目标函数的随机变量 θ 而言, 它可能是 β 由 $T_1, T_2, \dots$ 中的任意一个映射过来的, 反过来也就是说, 对于一个 β 而言, 它可能是由 θ 经逆变换 $\{T_k^{-1}\}_{k=1}^{\infty}$ 中的某一个得到的, 对应的概率为 $\omega_k(\theta)$ 。尽管条件分布 $\tilde{\Pi}(\beta|\theta)$ 是一个离散分布, 在直觉上会觉得这种无穷混合可能具有某些不好的性质, 但实际上通过对它进行积分, 我们得到的边缘分布是连续的:

$$\begin{aligned} \tilde{\Pi}(\beta) &= \int_{\Theta} \tilde{\Pi}(\beta|\theta) \Pi(\theta; y) d\theta \\ &= \sum_{k=1}^{\infty} \omega_k \{T_k(\beta)\} \Pi\{T_k(\beta); y\} |\det \nabla T_k(\beta)| \mathbb{I}\{T_k(\beta) \in \Theta\}, \end{aligned} \quad (3-21)$$

在第二行中使用了 Dirac 函数的变量变换 $\delta\{\beta - T_k^{-1}(\theta)\} = |\det \nabla T_k(\beta)| \cdot \delta\{\theta - T_k(\beta)\}$ 、Dirac 函数积分公式 $\int_X f(x)\delta(x-y)dx = f(y)\mathbb{I}(y \in X)$ 和用于交换积分和求和次序的 Fubini 定理。此外, 如果 $y \notin X: f(y) = \infty$, 我们有 $\int_X f(x)\delta(x-y)dx = 0$ 。进一步使用 Bayes 定理, 我们有给定 β 时获取样本 θ 的逆条件分布 $\Pi\{\theta|\beta\}$ 的近似 $\tilde{\Pi}\{\theta|\beta\}$:

$$\begin{aligned} & \tilde{\Pi}\{\theta = T_k(\beta)|\beta\} \\ &= \frac{\Pi(\theta; y)\tilde{\Pi}(\beta|\theta)\mathbb{I}\{\theta = T_k(\beta)\}}{\tilde{\Pi}(\beta)} \\ &= \frac{\omega_k\{T_k(\beta)\}\Pi\{T_k(\beta); y\}|\det \nabla T_k(\beta)|\mathbb{I}\{T_k(\beta) \in \Theta\}}{\sum_{l=1}^{\infty} \omega_l\{T_l(\beta)\}\Pi\{T_l(\beta); y\}|\det \nabla T_l(\beta)|\mathbb{I}\{T_l(\beta) \in \Theta\}} \\ &:= v_k(\beta). \end{aligned} \quad (3-22)$$

这个分布本质上就是从 $\{T_k(\beta)\}_k$ 中采样的离散分布, 出于简化, 我们将这一条件概率表示为 $v_k(\beta)$ 。在实践中, T_k 的值域的并集并不需要覆盖整个参数空间 Θ , 但是要包含高后验密度区域; 且 (3-22) 也是对 y 取条件的, 但是我们为了表达的简略省略了 y 。

此时, 我们就已经有了 TMC 算法的大体目标了, 通过优化 $\{(\omega_k, T_k)\}_k$ 的工作参数, 使得 $\tilde{\Pi}_r \approx \Pi_r$, 则此时 (β, θ) 的采样过程大致如下:

$$\begin{aligned} & \beta \sim \Pi_r, \quad (\text{i.i.d}); \\ & c \sim \text{概率为}\{v_1(\beta), v_2(\beta), \dots\}\text{的下标的分布}; \\ & \theta = T_c(\beta). \end{aligned} \quad (3-23)$$

也就是说 $(\beta, \theta) \sim \Pi_r(\beta)\tilde{\Pi}(\theta|\beta)$, 且这里的 θ 是完全独立的。

注释 3-1 倘若我们可以直接从 $\beta \sim \tilde{\Pi}(\beta)$ 中进行采样, 则我们就可以得到精确的边缘密度 $\int \tilde{\Pi}(\beta)\tilde{\Pi}(\theta|\beta)d\beta = \Pi(\theta; y)$ 。但实际上我们使用 Π_r 而不是 $\tilde{\Pi}_r$ 获得了服从参考分布的随机变量 β , 所以来自于 (3-20) 的密度是后验分布的一个近似, 误差的主要来源是 $\Pi_r(\beta)$ 和 $\tilde{\Pi}_r(\beta)$ 的差距。

接下来的目标主要就是参数化 $\omega_k(\theta)$ 和 $T_k(\beta)$ 来获得易于优化的近似形式。根据 (3-22) 中的推导, 相对于使用很复杂的 T_k , 我们可以选择使用一些非常简单的 T_k 的形式, 简单的 T_k 参数化可以减少实际优化中的计算量, 也可以提升理论分析的可行性。在本文中, 我们使用逐点局部缩放变换^[59]:

$$T_k(\beta) = s_k \odot \beta + m_k, \quad (3-24)$$

其中 $s_k \in \mathbb{R}_+^p, m_k \in \mathbb{R}^p$, 其中 $\odot$ 是逐点乘积。因此, Jacobian 行列式是 $\det \nabla T_k(\beta)$

$= \prod_{j=1}^p s_{k,j}$, 其中 $(s_{k,1}, \dots, s_{k,p}) = s_k$ 。显然, 采用这种简单的变换也同时保证了前面叙述的三角形映射的性质, 同时具有 Jacobian 行列式容易计算等优点。

对混合权重, 为了在权重与 θ 相关时仍然满足 $\sum_{k=1}^{\infty} \omega_k(\theta) = 1$, 我们使用 Logistic 函数^[59]

$$\omega_k(\theta) = \frac{b_k \exp(a_k^T \theta)}{\sum_{k'=1}^{\infty} b_{k'} \exp(a_{k'}^T \theta)}, \quad (3-25)$$

因为对 $b_{k'}$ 进行等比缩放不影响 (3-25) 的值, 因此我们进一步限制 $\sum_{k'=1}^{\infty} b_{k'} = 1$, 使得 $(b_1, b_2, \dots)$ 为一概率向量。通过将 $(b_1, b_2, \dots)$ 视为来自狄利克雷过程的权重, 使得我们可以处理这一无穷维性质, 等价于有限 K 元狄利克雷分布在 $K \rightarrow \infty$ 的极限形式:

$$(b_1, \dots, b_K) \sim \text{Dir}(\alpha/K, \dots, \alpha/K).$$

其中 $\alpha > 0$ 是浓度参数 (concentration parameter)。作为狄利克雷过程的一个普遍性质, $(b_1, b_2, \dots)$ 将只有有限个元素不为零, 因此 ω_k 的大部分元素都将收敛到零, 使得真正被使用的只有少量 T_k 。

3.4 随机 TMC 算法的一般框架

对于本文中采用的方法而言, TMC 算法的设计主要分为三个阶段:

1. 初始化;
2. 优化步: 用于得到混合权重和缩放-位移变换中的工作参数;
3. 采样步: 在得到对应的 ω_k, T_k 后, 独立采样 β , 再使用随机输运得到 θ 。

现在, 将这两个部分分开讨论。

3.4.1 初始化

对几乎一切的优化问题而言, 对工作参数进行良好的初始化对于优化的效果都有着非常重要的作用。出于容易采样和计算的考虑, 我们选择均匀分布 $\mathcal{U}\{(0, 1)^p\}$ 作为获取 β 的参考分布。对于参数化 $\omega_k(\theta)$ 的参数 a_k, b_k 而言, 采用将所有的 T_k 的选择概率初始化为相同的概率, 具体的做法就是将对应 logistic 函数中的 a_k 和 b_k 设置为 0。对于位移参数 m_k 而言, 最理想的方案是将 m_k 初始化为后验分布 θ 的高后验密度区, 对于但模态的后验分布 (目标分布) 而言, 可以选择在初始化前先计算其后验模态 $\hat{\theta}$, 然后通过对 $\hat{\theta}$ 添加服从某些分布的噪声来初始化 m_k 。如果目标分布是多模态的, 则这种计算会比较困难, 特别是当各个模态之间相聚比较远时。此时, 在无法获得目标函数模态的信息时, 我

们可以通过对 θ 的支撑集内均匀的生成 m_k 来获得对应的初始化。对于缩放因子 s_k ，目前尚无很好的初始化方案，一种比较主流的选择就是取某一区间内的均匀分布随机变量作为初始化的方案（本文的选择是 $[-1, 1]$ ）。

3.4.2 优化

假设 $\{\omega_k, T_k\}$ 是充分参数化的，在本节中，我们选择通过最小化 KL 散度 $\mathbb{E}_{\beta \sim \Pi_r(\beta)} \log\{\Pi_r(\beta)/\tilde{\Pi}(\beta)\}$ ，来获得最小的 $\Pi_r(\beta)$ 和 $\tilde{\Pi}(\beta)$ 之间的距离，从而使得 $\tilde{\Pi}_r(\beta) \approx \Pi_r(\beta)$ ，这种优化的可行性来自于 3.2.2 节的论述，因为对于三角形映射而言，这一优化的解是唯一的。

整体的损失函数除了包括了 KL 散度之外，也包括了狄利克雷过程在 b_k 上的正则化的整体损失，其具体的表达式可以写为^[59]：

$$\begin{aligned} Loss &= \mathbb{E}_{\beta \sim \Pi_r(\beta)} \log\{\Pi_r(\beta)/\tilde{\Pi}(\beta)\} - (\alpha/K - 1) \sum_k \log b_k \\ &= -\mathbb{E}_{\beta \sim \Pi_r(\beta)} \log \sum_{k=1}^K \omega_k \{T_k(\beta)\} L\{y; T_k(\beta)\} \\ &\quad \Pi_0\{T_k(\beta)\} \Pi_{j=1}^p s_{k,j} \mathbb{I}\{T_k(\beta) \in \Theta\} - \sum_{k=1}^K (\alpha/K - 1) \log b_k + \text{constant}, \end{aligned} \quad (3-26)$$

在这里，需要优化的参数包括 $\{s_k, m_k, a_k, b_k\}_k$ ，其中 s_k, m_k, b_k 都是 p 维向量， b_k 是标量。为了能够在计算机上以合适的成本处理原本无穷的参数，我们在 K 处进行截断作为对无穷维狄利克雷分布的近似^[60]。

在关于损失函数的优化问题上，可以选择的方法有随机梯度下降法。不过在实际应用过程中，对应的期望可能没有解析解，这对梯度下降法的应用存在着一定的干扰，对应的实际解决方案是通过批量抽取样本 $\beta_l \sim \Pi_r(\beta), l = 1, \dots, n_b$ 后在批处理的基础上计算梯度，对参数进行梯度下降步；然后再在下一步中重新抽取 $\beta_l \sim \Pi_r(\beta)$ ，因为可以从 $\Pi_r(\beta)$ 中抽取无穷数量的样本，这一过程在本质上就是在一个无限大的训练样本集上进行随机梯度下降，这一类方法在变分推断^[61]上有非常广泛的应用，在防止因为训练样本有限而导致的过拟合问题上有着很好的效果。

采样

在优化收敛过后， θ 的样本可以通过 (3-23) 来生成，严格的说， θ 并不是来自于 $\Pi(\theta; y)$ ，而是来自于它的一个近似，因为在第一行中 β 来自于 $\Pi_r(\beta)$ 而不是 $\tilde{\Pi}_r(\beta)$ 。

3.5 基于 TMC 的粒子滤波算法

上一节中简述的随机 TMC 算法是一种单纯的 Monte Carlo 方法，在粒子滤波这一具体的情景中，需要在时序上选择综合计算成本和预测精度下最好的目标函数。本文以^[59]提出的 TMC 方法为基础，提出了基于粒子滤波场景下的随机性输运粒子滤波（Transport Particle Filtering, TPF）算法。

3.5.1 TMC 近似的函数

为了将 TMC 算法应用到粒子滤波中，我们首先需要确定的是究竟使用 TMC 方法来近似哪个采样函数。我们的第一直觉会选择 $p(x_k|\mathbf{Z}_{0:k})$ 作为我们的采样函数，其理论上的计算公式可以写成下述积分形式：

$$p(x_k|\mathbf{Z}_{0:k}) = \int p(x_k, x_{k-1}|\mathbf{Z}_{0:k}) dx_{k-1}. \quad (3-27)$$

对于被积函数 $p(x_k, x_{k-1}|\mathbf{Z}_{0:k})$ ，我们有如下推导：

$$\begin{aligned} p(x_k, x_{k-1}|\mathbf{Z}_{0:k}) &= \frac{p(z_k|x_k)p(x_k, x_{k-1}, \mathbf{Z}_{0:k-1})}{p(\mathbf{Z}_{0:k})} \\ &= \frac{p(z_k|x_k)p(x_k|x_{k-1})p(x_{k-1}, \mathbf{Z}_{0:k-1})}{p(\mathbf{Z}_{0:k})} \\ &= \frac{p(z_k|x_k)p(x_k|x_{k-1})p(x_{k-1}|\mathbf{Z}_{0:k-1})}{p(z_k|\mathbf{Z}_{0:k-1})} \\ &\propto p(z_k|x_k)p(x_k|x_{k-1})p(x_{k-1}|\mathbf{Z}_{0:k-1}). \end{aligned}$$

也就是说

$$p(x_k|\mathbf{Z}_{0:k}) \propto \int p(z_k|x_k)p(x_k|x_{k-1})p(x_{k-1}|\mathbf{Z}_{0:k-1}) dx_{k-1}. \quad (3-28)$$

从上述推断可以看出，虽然对于采样的函数 $p(x_k|\mathbf{Z}_{0:k})$ 而言，存在着递推的表达式，这一表达式可以精确到归一化常数，使得采样在理论上称为可能。但在使用随机 TMC 方法对其近似时，由于上式中的积分项往往很难计算出解析表达式，这使得对该积分函数的近似存在着较大的困难，这一困难主要体现在计算量方面。在对该函数进行近似时，首先需要近似被积函数 $p(z_k|x_k)p(x_k|x_{k-1})p(x_{k-1}|\mathbf{Z}_{0:k-1})$ ，取得若干个关于 x_{k-1} 积分的样本点，再通过这些样本点计算积分值，才能进行对 $p(x_k|\mathbf{Z}_{0:k})$ 一个点的近似，而每更换一个 x_k 的值，都意味着 $p(z_k|x_k)p(x_k|x_{k-1})p(x_{k-1}|\mathbf{Z}_{0:k-1})$ 需要重新近似一次。除去上述的问题外，积分的计算还有如下问题：虽然这一过程在形式上有着迭代的形状，但在实际中 $p(x_{k-1}|\mathbf{Z}_{0:k-1})$ 往往也是没有解析表达式的，这会带来进一步的计算

成本；在随机 TMC 算法中，往往对一个目标函数的优化需要的样本点个数往往数以万计；对于结构越复杂的函数，对其近似需要的优化次数就越多，这使得需要的样本点个数进一步的增加才可以达到收敛的地步，这样的计算成本在实际应用中往往是不可接受的；在对 $p(z_k|x_k)p(x_k|x_{k-1})p(x_{k-1}|\mathbf{Z}_{0:k-1})$ 近似中，随着时间的演进，该函数的变量将不断增多，使得对该函数的计算的成本和近似所需要的输运个数也会随着时间成线性增长。这几个方面的计算复杂性使得利用随机 TMC 方法近似 $p(x_k|\mathbf{Z}_{0:k})$ 的计算成本很难接受。因此，我们需要选择一个更加简单且容易近似的目标函数。

而根据 3.5 节关于最优重要性函数的论述可知，我们可以使用 TMC 近似的重要性函数就应当是 $p(x_k|x_{k-1}^{(i-1)}, z_k)$ 。使用这一函数作为目标函数的主要优点为：该函数的变量个数是固定的、且可以直接求出其精确到归一化常数的解析表达式，使得优化更加容易进行；且因为函数结构总体固定，使得输运的个数可以选择一个相对固定的值；在确定了粒子数之后，每一步的计算成本是一个固定的值，不会因为收敛判定等原因出现较大的波动。

为了设计算法，首先给出马尔可夫状态独立性和观测独立性条件下的后验分布的递推式：

$$\begin{aligned}
 p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k}) &= \frac{p(\mathbf{X}_{0:k}, \mathbf{Z}_{0:k})}{p(z_k, \mathbf{Z}_{0:k-1})} \\
 &= \frac{p(z_k, \mathbf{X}_{0:k}, \mathbf{Z}_{0:k-1})}{p(z_k|\mathbf{Z}_{0:k-1})p(\mathbf{Z}_{0:k-1})} \\
 &= \frac{p(z_k|\mathbf{X}_{0:k}, \mathbf{Z}_{0:k-1})p(x_k, \mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k-1})}{p(z_k|\mathbf{Z}_{0:k-1})p(\mathbf{Z}_{0:k-1})} \\
 &= \frac{p(z_k|\mathbf{X}_{0:k}, \mathbf{Z}_{0:k-1})p(x_k|\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k-1})p(\mathbf{X}_{0:k-1}, \mathbf{Z}_{0:k-1})}{p(z_k|\mathbf{Z}_{0:k-1})p(\mathbf{Z}_{0:k-1})} \\
 &\propto p(z_k|x_k)p(x_k|x_{k-1})p(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k-1}).
 \end{aligned} \tag{3-29}$$

上式的最后一行中 $p(z_k|x_k)$ 代表似然函数， $p(x_k|x_{k-1})$ 为状态转移函数， $p(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k-1})$ 为 $k-1$ 时刻的后验分布。采用类似的推导，可以得到预测步骤的分布形如

$$p(\mathbf{X}_{0:k}|\mathbf{Z}_{0:k-1}) \propto p(x_k|x_{k-1})p(\mathbf{X}_{0:k-1}|\mathbf{Z}_{0:k-1}). \tag{3-30}$$

不难看出，在每一步的递推过程中，前一时刻的后验分布与预测步的分布相差一个 $p(x_k|x_{k-1})$ ，预测步与当前时刻的后验分布相差一个 $p(z_k|x_k)$ 。

而根据定理前面关于最优重要性函数的映射的论述，我们知道，在选择 $\pi(x_k|\mathbf{X}_{0:k-1}^{(i)}, \mathbf{Z}_{0:k}) = p(x_k|x_{k-1}^{(i-1)}, z_k)$ 后，重要性权重的更新公式为

$$w_k^{(i)} = w_{k-1}^{(i)} p(z_k | x_{k-1}^{(i)}), \quad (3-31)$$

可以看出重要性权重的更新量为 $p(z_k | x_{k-1}^{(i)})$ ，虽然 $p(z_k | x_{k-1}^{(i)})$ 的解析表达式在大部分情况下很难写出，不过在 Markov 条件下，根据公式：

$$\begin{aligned} p(x_k | x_{k-1}, z_k) &= \frac{p(x_k, x_{k-1}, z_k)}{p(x_{k-1}, z_k)} \\ &= \frac{p(z_k | x_k, x_{k-1}) p(x_k, x_{k-1})}{p(z_k, x_{k-1})} \\ &= \frac{p(z_k | x_k) p(x_k | x_{k-1}) p(x_{k-1})}{p(z_k, x_{k-1})} \\ &= \frac{p(z_k | x_k) p(x_k | x_{k-1})}{p(z_k | x_{k-1})}, \end{aligned} \quad (3-32)$$

以及概率密度函数的积分公式

$$\int p(x_k | x_{k-1}, z_k) dx_k = 1, \quad (3-33)$$

在固定 $x_{k-1} = x_{k-1}^{(i)}$ ， z_k 固定为观测值的情况下，我们就有

$$\int \frac{p(z_k | x_k) p(x_k | x_{k-1}^{(i)})}{p(z_k | x_{k-1}^{(i)})} dx_k = \frac{\int p(z_k | x_k) p(x_k | x_{k-1}^{(i)}) dx_k}{p(z_k | x_{k-1}^{(i)})} = 1, \quad (3-34)$$

也就是说

$$\int p(z_k | x_k) p(x_k | x_{k-1}^{(i)}) dx_k = p(z_k | x_{k-1}^{(i)}). \quad (3-35)$$

在一般情形下，对 (3-35) 左侧的积分进行数值计算往往是存在一定的困难的，但在 TPF 算法中，由于算法本身只对目标密度函数要求精确到归一化常数就可以从中取得样本，因此在对目标函数的选择中，可以选择 $p(z_k | x_k) p(x_k | x_{k-1}^{(i)})$ 作为优化的目标函数，而在优化完成后，就可以从比较容易采样的参考分布 $\Pi_r(\beta)$ 中取得大量的样本。同时因为 $p(z_k | x_k) p(x_k | x_{k-1}^{(i)})$ 本身与目标函数只相差一个常数，这导致了从目标函数中取得样本的概率与 $p(z_k | x_k) p(x_k | x_{k-1}^{(i)})$ 是相同的，因为在目标函数的高后验密度区， $p(z_k | x_k) p(x_k | x_{k-1}^{(i)})$ 也有着相对较大的值，也就是在积分过程中对积分的贡献较大，而由于样本是从目标函数中取得的，从而在这些对积分值贡献大的区域取得的样本也会较多；而在 $p(z_k | x_k) p(x_k | x_{k-1}^{(i)})$ 较小的区域，目标函数的值相对也是较小的，在这些区域上取得的样本数也是较少的。这种采样方法明显的提升了积分的效率。

3.5.2 算法设计

在明确了近似的目标函数后，具体的算法设计如下：

算法 3-1 输运粒子滤波算法

Algo.3-1 Transport Particle Filtering

- 1 初始化参数：将 logistic 函数的参数 a_k, b_k 设置为 0，使得初始权重相等且初始的损失函数为无穷大。位移参数 m_k 设置为 x 的高后验密度区，如果不知道 x 的高后验密度区，则在后验分布的支撑集上均匀设置；
- 2 对于初始系统状态 x_0 ，从先验分布 $p_0(x_0)$ 中取得对应的粒子数 N 个样本 $\{x_0^{(i)}, i = 1, \dots, N$ ，并设置重要性权重为 $w_0^{(i)} = 1/N, i = 1, 2, \dots, N$ ，计算出对初始状态的估计 $\bar{x}_0$ 。
- 3 对 $k = 1, 2, \dots$ 的情况，我们从 $p(x_k|x_{k-1}^{(i)}, y_k), i = 1, 2, \dots, N$ 中采样，获得新的粒子 $x_k^{(i)}$ ，并根据 (3-31)

$$w_k^{(i)} = w_{k-1}^{(i)} p(y_k|x_{k-1}^{(i)})$$

更新对应的重要性权重。对于重要性权重的更新量 $p(y_k|x_{k-1}^{(i)})$ ，我们通过在近似的函数 $p(x_k|x_{k-1}^{(i)}, y_k)$ 中采样来进行数值近似

$$\int p(y_k|x_k) p(x_k|x_{k-1}^{(i)}) dx_k = p(y_k|x_{k-1}^{(i)}).$$

- 4 得到更新后的重要性权重和样本后，根据

$$N_{eff} = 1 / \sum_{i=1}^N (w_k^{(i)})^2$$

计算有效粒子数，并采用一个人为设定的阈值 l (l 一般在 0.5 到 0.9 之间，本文采用 0.6 或 0.7 作为阈值)，如果

$$N_{eff}/N < l,$$

则执行重采样步骤，本文使用多项式重采样作为重采样方法，并将权重更新为 $w_k^{(i)} = 1/N$ 。如果

$$N_{eff}/N \geq l,$$

则直接进入下一步。

- 5 得到最终的重要性权重和新的样本后，根据

$$\bar{x}_k = \sum_{i=1}^N w_k^{(i)} x_k^{(i)} \quad (3-36)$$

计算系统在 k 时刻状态 x_k 的估计值 $\bar{x}_k$ 。

- 6 在预先设定的停止时刻到来之前，不断重复步骤 3 和 4，直至停止。

3.6 本章小结

本章主要介绍了通过输运来获得对后验分布的近似的两种方法：确定性输运和随机性输运；在随后给出了确定性与随机性输运的简要介绍，并给出了基于输运的采样方法的基本原理；最后介绍了具体的 TMC 算法。给出了一般的随机性 TMC 方法的一般框架，在将随机性 TMC 方法应用到粒子滤波上时的目标函数选择问题，并在最后给出了基于随机输运 Monte Carlo 方法的具体粒子滤波算法。

第 4 章 仿真实验

4.1 单变量非平稳增长模型

但变量非平稳增长模型具有较强的非线性性，是一个被广泛使用的用于验证非线性滤波与平滑算法性能的标准问题。其状态方程和观测方程可以描述如下^[17,29]：

$$\begin{aligned} x_{k+1} &= 0.5x_k + 25 \frac{x_k}{1+x_k^2} + 8 \cos(1.2k) + \omega_k \\ z_k &= \frac{x_k^2}{20} + \nu_k. \end{aligned} \quad (4-1)$$

其中，系统的初始状态满足 $x_0 \sim \mathcal{N}(0, 1)$ ，系统噪声 $\{\omega_k, k \in \mathbb{N}\}$ 与量测噪声 $\{\nu_k, k \in \mathbb{N}_+\}$ 是相互独立的，并且满足 $\omega_k \sim \mathcal{N}(0, 1)$ 和 $\nu_k \sim \mathcal{N}(0, 1)$ 。具体的参数选择为：粒子数 $N = 50$ ，迭代次数为 $T = 200$ ，一共进行 $K = 50$ 次 Monte Carlo 仿真，初始状态从其初始分布中随机生成。作为对比的算法为，选择使用较为容易生成样本的状态转移函数 $p(x_k|x_{k-1})$ 作为重要性函数的粒子滤波。关于重采样的方法，重采样的判定方法选用有效粒子数方法，有效粒子数阈值设定为 0.6，重采样方法选择多项式重采样。同时，对于标准的以状态转移函数 $p(x_k|x_{k-1})$ 为重要性函数的粒子滤波而言，需要在每一步都进行重采样，为了能够对粒子退化现象进行一定的度量，将为以 $p(x_k|x_{k-1})$ 为重要性函数的标准粒子滤波算法引入重采样判定，判定阈值同样设置为 0.6。在本章中使用的算法将有三种：

- (1) 标准粒子滤波算法，简称为 SPF (Standard Particle Filter)；
- (2) 为了能够在实施粒子滤波算法时获得对粒子退化现象的定量结论，将重采样判定步骤引入标准粒子滤波算法，与标准粒子滤波加以区分，简称为 PF；
- (3) 使用输运 Monte Carlo 方法近似最优重要性函数的改进后的粒子滤波算法，简称为 TPF (Transport Particle Filter)；

此处约定的简写对后面的仿真实例也是通用的。

为了更好的度量预测效果的优劣，引入时间均方误差 (TARMSE) 来评估 PF 和 TPF 算法的性能差异，首先，预测的均方误差 (RMSE) 公式如下：

$$\text{RMSE} = \sqrt{\frac{1}{K} \sum_{i=1}^K (\bar{x}_k^{(i)} - x_k)^2}. \quad (4-2)$$

其中 $\bar{x}_k^{(i)}$ 表示第 $i, i = 1, 2, \dots, K$ 次仿真时, 时刻 k 的估计状态, x_k 表示第 k 时刻的系统的真实状态, 由此, 可以给出 TARMSE 的计算公式^[62]

$$\text{TARMSE} = \frac{1}{T} \sum_{t=1}^T \sqrt{\frac{1}{K} \sum_{k=1}^K (\bar{x}_t^k - x_t^k)^2}. \quad (4-3)$$

其中 $k = 1, 2, \dots, K$ 为仿真次数, 第 k 仿真状态序列 $\{x_t^k\}_{t=1}^T$ 的估计序列为 $\{\bar{x}_t^k\}_{t=1}^T$ 。




图 4-1 TPF 与 PF 算法的 RMSE 对比图

从图 4-1 和图 4-3 可以看出, 与传统的采用状态转移函数作为重要性函数的 PF 算法和 SPF 算法相比, TPF 方法中, 预测误差较大的步数明显减少了。同时, 根据直方图 4-2 可以看出, 在 50 次仿真中, TPF 算法产生较大误差的点明显减少, 其平均误差主要分布在 $[1.4, 2.0]$ 之间, 且总体的分布要比传统的 PF 算法更加集中, 可见本文提出的 TPF 算法具有较好的预测稳定性。

表 4-1 TPF, PF, SPF 三种算法的 TARMSE 和重采样次数

	TPF	PF	SPF
TARMSE	2.7433	3.0142	3.0068
平均重采样次数	61.8	103.98	199

表 4-1 给出了 TPF 算法和 PF 算法的 TARMSE 和重采样次数, 可以看出, 在




图 4-2 TPF 与 PF50 次仿真的平均误差分布图

采用了更好的重要性函数后，TARMSE 和重采样次数均有所下降，其中重采样次数下降的较为明显，在 200 步的仿真中，平均重采样次数下降了超过 40 次。可以看出，对于一维情形，TPF 算法可以有效的对抗粒子退化并提高预测精度。对于标准的 SPF 算法而言，可以看出，其 RMSE 并无明显提升并且重采样步数永远为 $T-1$ 次，此处 T 是迭代次数，这本质上就是因为在这一步都进行了重采样导致了粒子多样性下降从而导致的预测稳定性并无明显提升。




图 4-3 TPF 与 SPF 算法的 RMSE 对比图




图 4-4 TPF 与 SPF50 次仿真的平均误差分布图

结合图 4-2 和图 4-4 可以看出，因为 SPF 在每一次迭代中都进行了重采样，故而 SPF 算法的粒子多样性会有所下降，从平均误差的对比图可以看出，虽然就总体的平均误差而言，SPF 与 PF 相差不大，但就预测的平均误差的稳定性而言，SPF 算法的平均误差呈现出有着更大的方差的趋势，这显然是因为每一步都进行重采样而导致粒子多样性降低而引起的；作为对比，TPF 算法在平均误差的绝对大小和总体误差的分布情况上而言，呈现出了比 PF 和 SPF 更加优异的表现。可以证明，在实际应用中，通过输运 Monte Carlo 近似最优重要性函数是可以在一定程度上对抗粒子退化并提高粒子滤波算法预测的精度和稳定性的。

关于三种算法的 50 次仿真的平均误差散点图和平均误差表可以参考图 4-5 和表 4-2。从图 4-5 中可以看出，与 SPF 和 PF 算法相比，TPF 算法的预测误差的分布更加集中、稳定，且平均误差较大的点比较少。从以上的一系列讨论和对比可以看出，粒子多样性对于预测的稳定性起着重要的作用，同时 TPF 方法在对抗粒子退化的角度上是有一定的实用价值的。

表 4-2 TPF, PF, SPF 三种算法的总平均误差

	TPF	PF	SPF
平均误差	1.7208	1.8807	1.8414




图 4-5 三种算法的平均误差散点图

4.2 四阶混合线性/非线性系统





该系统可以表述为如下形式:^[63]:

$$\begin{aligned} X_{k+1} &= \begin{bmatrix} \arctan x_k^p + z_k^1 \\ z_k^1 + 0.3z_k^2 \\ 0.92z_k^2 - 0.3z_k^3 \\ 0.3z_k^2 + 0.92z_k^3 \end{bmatrix} + \omega_k \\ Z_k &= \begin{bmatrix} 0.1(x_k^p)^2 \text{sign}(x_k^p) \\ z_k^1 - z_k^2 + z_k^3 \end{bmatrix} + v_k. \end{aligned} \quad (4-4)$$

其中:系统状态为 $X_k = [x_k^p, z_k^1, z_k^2, z_k^3]^T$, 系统的初始状态分布为 $X_0 \sim \delta_{m_0}(X_0)$, $m_0 = [0.1, 0.15, 0.2, 0.25]$; 系统噪声为 $w_k \sim \mathcal{N}(0, Q)$, $Q = 0.01I_{4 \times 4}$, 量测噪声为 $v_k \sim \mathcal{N}(0, R)$, $R = 0.1I_{2 \times 2}$ 。

在这一节中, 我们所采用的仿真指标为: 迭代次数 $T = 100$, 仿真次数为 $K = 100$, 粒子数 $N = 50$ 。与上一节相同, 对于这个具体的问题, 本节也同样采用了 TPF, PF, SPF 三种滤波算法。与上一节不同的是, 本节中的重采样判定的有效粒子数的阈值选定为 0.7。

从图 4-6 到 4-9 可以看出, PF 与 TPF 方法对比下, 在选取了更优的重要性函数后, 对于系统状态的各个分量的预测精度或稳定性都有所上升, 其中 x 和


 图 4-6 PF 和 TPF 算法的 $RMSE(x_k^p)$

 图 4-7 PF 和 TPF 算法的 $RMSE(z_k^1)$

 图 4-8 PF 和 TPF 算法的 $RMSE(z_k^2)$

 图 4-9 PF 和 TPF 算法的 $RMSE(z_k^3)$





z_1 两个维度的准确性上升较为明显，虽然 z_2 和 z_3 从准确性的角度来看只有较小的提升，但从预测稳定性的角度来看，提升很大。因而可以认为，通过输运 Monte Carlo 近似最优重要性函数对于多维系统而言也是可行的。

表 4-3 TPF, PF, SPF 三种算法的 TARMSE

	x_k^p	z_k^1	z_k^2	z_k^3
TPF	0.5108	0.3239	0.2437	0.1899
PF	0.6279	0.3722	0.2530	0.1982
SPF	0.6159	0.3852	0.2612	0.2064

通过对比图 4-10 到 4-13 和表 4-3 可以看出与 SPF 方法相对比下，TPF 预测的准确性也是有所提升的，其中以 x 和 z_1 最为明显，同时在稳定性上，可以看出四个维度预测的稳定性都有所上升。这也同样是因为：由于每一步都需要进行重采样，SPF 实际上在一定程度上是导致了粒子的多样性下降的，从而降低了算法的健壮性，导致了预测误差相对而言更不稳定。就实际的基于最小 TARMSE 的标准来看，针对本节的混合线性/非线性高 Gauss 系统模型而言，PF 和 SPF 算法并没有明显的优劣。

针对 TPF 算法在对抗粒子退化问题上的性能，具体可以参考表 4-4。从表 4-4 中的重采样次数也可以看出，在采用了更优的重要性函数后，在 100 次仿真






 图 4-10 SPF 和 TPF 算法的 $RMSE(x_k^p)$

 图 4-11 SPF 和 TPF 算法的 $RMSE(z_k^1)$

 图 4-12 SPF 和 TPF 算法的 $RMSE(z_k^2)$

 图 4-13 SPF 和 TPF 算法的 $RMSE(z_k^3)$

中重采样的次数平均减少了约 9 次，可以看出，通过随机性 TMC 方法来近似理论最优重要性函数是可以提高粒子多样性并对抗粒子退化现象在高维的情况下也是成立的。

表 4-4 TPF, PF, SPF 三种算法的平均重采样次数



	TPF	PF	SPF
平均重采样次数	67.71	76.51	99

针对 TPF, PF 和 SPF 算法的预测的稳定性的问题而言，本文完成的 100 次仿真每个维度的平均误差散点图可见图 4-14 至图 4-17。从散点图的分布来看，可以明显看出，在 100 次仿真中，TPF 的误差分布更加集中且有更好的稳定性，而 PF 和 SPF 因为采用的重要性函数相对较差，这种稳定性较差在前三个维度上体现的比较明显，在最后一个维度上虽然看起来三者相差不大，但这主要是因为该维度的绝对值总体本身就较小，实际上还是可以看出，即便是在最后一个维度上，TPF 方法的稳定性也是有较好的优势的。从以上分析可以看出，在预测误差的稳定性上 PF 和 SPF 方法相对 TPF 方法而言是较低的，在图中的具体体现就是在 x_k^p 维度、 z_k^1 维度和 z_k^2 维度上有几次仿真的平均误差较大，产生了较大的“飘移”。


 图 4-14 三种算法的平均误差 (x_k^p)

 图 4-15 三种算法的平均误差 (z_k^1)

 图 4-16 三种算法的平均误差 (z_k^2)

 图 4-17 三种算法的平均误差 (z_k^3)

更具体的关于预测误差的分布的柱状图，可以参考图 4-18 至图 4-25。其中图 4-18 到图 4-21 为 PF 和 TPF 平均误差的柱状图，可以看出，TPF 算法的 100 次模拟的误差主要集中在较低的区间。图 4-22 至图 4-25 为 SPF 和 TPF 平均误差的柱状图，可以看出，由于每一步都会进行重采样，这导致了粒子的多样性的下降，使得预测误差的稳定性变得更差了，在低误差的部分相对更加不集中。

而通过表 4-5 也可以看出，在平均误差方面，虽然 SPF 算法会在每一步都选择权重最高的一部分粒子用于状态估计，但因为粒子的多样性下降，实际上的预测精度并无明显提升，而采用了最优重要性函数的近似的 TPF 算法，则在一定程度上降低了预测的整体平均误差。


 图 4-18 PF 和 TPF 的平均误差柱状图 (x_k^p)

 图 4-19 PF 和 TPF 的平均误差柱状图 (z_k^1)




图 4-20 PF 和 TPF 算法的平均误差 (z_k^2)




图 4-21 PF 和 TPF 算法的平均误差 (z_k^3)




图 4-22 SPF 和 TPF 的平均误差柱状图 (x_k^p)




图 4-23 SPF 和 TPF 的平均误差柱状图 (z_k^1)




图 4-24 PF 和 TPF 算法的平均误差 (z_k^2)




图 4-25 SPF 和 TPF 算法的平均误差 (z_k^3)

表 4-5 TPF, PF, SPF 三种算法的平均误差

	x_k^p	z_k^1	z_k^2	z_k^3
TPF	0.3770	0.2562	0.1939	0.1520
PF	0.4129	0.2749	0.1978	0.1565
SPF	0.4128	0.2853	0.2055	0.1640

4.3 本章小结

为了对比本文提出的算法在对抗粒子退化上的作用,本文首先通过改进标准粒子滤波算法,为标准粒子滤波算法也引入了有效粒子数判定来获得在传统次优重要性函数下的重采样次数。

本章通过两个仿真实验:分别是1维的单变量非平稳增长模型和4维的混合线性/非线性 Gauss 系统模型验证了通过输运 Monte Carlo 近似最优重要性函数作为序贯 Monte Carlo 算法采样器的性能。

在单变量非平稳增长模型中,可以看出,在通过输运 Monte Carlo 方法给出了更好的重要性函数后,与采用传统重要性函数的 PF 和 SPF 算法相比而言,TPF 算法给出了更好的滤波精度和滤波稳定性。

在混合线性/非线性 Gauss 系统模型中,同样通过对比 TPF、PF、SPF 三种算法,验证了本文提出算法在多维情形下仍旧提高了滤波的精度和稳定性,表明了本文提出的算法在多维情形下仍然有效。

最后,对于本文提出的两个样例,本文在重采样次数的角度上也证明了,本文提出的算法在对抗粒子退化上有一定的作用。

结 论

本文通过将从一个容易采样的分布中得到的样本映射为服从难于采样的在最小方差意义下的最优重要性函数的样本，从而保证了在粒子滤波中粒子较高的多样性，并可以在一定程度上缓解粒子退化现象。本文的研究成果主要如下：

(1) 本文首先给出了在权重方差最小标准下的粒子滤波的最优重要性函数，针对其难以计算，特别是其归一化常数难以计算的问题，通过采用优化的手段来对最优重要性函数进行近似，可以快速获得服从目标分布的大量样本点；

(2) 单纯的输运 Monte Carlo 方法在应用到滤波问题上时需要明确近似的具体目标，本文将最优重要性函数作为近似目标，设计了基于随机 TMC 方法的滤波算法；

(3) 本文通过两个数值样例，证明了将输运 Monte Carlo 方法应用到粒子滤波方法上的可行性，并主要通过分析重采样次数和平均误差的分布证明了基于输运 Monte Carlo 方法的粒子滤波算法相比传统的粒子滤波算法在滤波的精度和稳定性上都具有一定的优势。

在本文的基础上，后续的研究方向主要包括以下几点：

(1) 由于输运 Monte Carlo 方法主要是基于优化的一种方法，因此其速度相比传统的粒子滤波是偏慢的，可以通过更新算法的设计来减少 TPF 与传统 PF 算法速度上的差距，主要的方法有：优化算法的设计，采用更高效的优化算法等；

(2) 本文讨论的问题主要集中在较为理想的滤波环境中，而在实际的滤波问题中，观测信号往往存在一定的延迟，因此可以将现有算法针对具有随机延迟的滤波问题进行改进；

(3) 本文主要通过随机选择线性函数的方法对最优重要性函数进行近似，而在输运 Monte Carlo 方法中还包括通过多项式、三角函数多项式等方法对目标分布进行近似，因此，可以尝试使用其他方式对后验分布进行近似。

参考文献

- [1] ALSPACH D, SORENSON H. Nonlinear Bayesian Estimation Using Gaussian Sum Approximations[J]. IEEE Transactions on Automatic Control, 2003, 17(4): 439-448.
- [2] 朱志宇. 粒子滤波算法及其应用[M]. 科学出版社, 2010: 3-8.
- [3] KOK M, SOLIN A. Scalable Magnetic Field SLAM in 3D Using Gaussian Process Maps[C]//2018 21st international conference on information fusion (FUSION). IEEE, 2018: 1353-1360.
- [4] GRAMI T, TLILI A S. Indoor Mobile Robot Localization Based on a Particle Filter Approach[C]//2019 19th International Conference on Sciences and Techniques of Automatic Control and Computer Engineering (STA). IEEE, 2019: 47-52.
- [5] XU W, XU J, YAN X. Lithium-Ion Battery State of Charge and Parameters Joint Estimation Using Cubature Kalman Filter and Particle Filter[J]. Journal of Power Electronics, 2020, 20: 292-307.
- [6] MA Y, CHEN Y, ZHOU X, et al. Remaining Useful Life Prediction of Lithium-Ion Battery Based on Gauss-Hermite Particle Filter[J]. IEEE Transactions on Control Systems Technology, 2018, 27(4): 1788-1795.
- [7] POTERJOY J, WICKER L, BUEHNER M. Progress Toward the Application of a Localized Particle Filter for Numerical Weather Prediction[J]. Monthly Weather Review, 2019, 147(4): 1107-1126.
- [8] WEI L, WANG Y, CHEN P. A Particle Filter-Based Approach for Vehicle Trajectory Reconstruction Using Sparse Probe Data[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(5): 2878-2890.
- [9] NTEMI M, KOTROPOULOS C. A Dynamic Dyadic Particle Filter for Price Prediction[J]. Signal Processing, 2020, 167: 107334.
- [10] STIGLER S M. Gauss and the Invention of Least Squares[J]. the Annals of Statistics, 1981: 465-474.
- [11] KOLMOGOROV A N. Interpolation and Extrapolation of Stationary Random Sequences[J]. Izv. Akad. Nauk USSR, ser. Math., 1941, 5(5): 68-83.

- [12] WIENER N. Extrapolation, Interpolation, and Smoothing of Stationary Time Series: with Engineering Applications: volume 113[M]. Cambridge, MA: MIT press, 1949.
- [13] KALMAN R E, et al. A New Approach to Linear Filtering and Prediction Problems[J]. Journal of basic Engineering, 1960, 82(1): 35-45.
- [14] KALMAN R E, BUCY R S. New Results in Linear Filtering and Prediction Theory[J]. J. Basic Engrg. ASME, Ser. D, 1961, 83: 95-108.
- [15] JULIER S J, UHLMANN J K. Unscented Filtering and Nonlinear Estimation[J]. Proceedings of the IEEE, 2004, 92(3): 401-422.
- [16] JAZWINSKI A H. Stochastic Processes and Filtering Theory[M]. New York: Academic Press, 1970.
- [17] GORDON N J, SALMOND D J, SMITH A F. Novel Approach to Nonlinear/Non-Gaussian Bayesian State Estimation[C]//IEE proceedings F (radar and signal processing): volume 140. IET, 1993: 107-113.
- [18] HAMMERSLEY J M, MORTON K W. Poor Man' s Monte Carlo[J]. Journal of the Royal Statistical Society Series B: Statistical Methodology, 1954, 16(1): 23-38.
- [19] LIU J S, CHEN R. Sequential Monte Carlo Methods for Dynamic Systems[J]. Journal of the American statistical association, 1998, 93(443): 1032-1044.
- [20] CARPENTER J, CLIFFORD P, FEARNHEAD P. Improved Particle Filter for Nonlinear Problems[J]. IEE Proceedings-Radar, Sonar and Navigation, 1999, 146(1): 2-7.
- [21] GEWEKE J. Bayesian Inference in Econometric Models Using Monte Carlo Integration[J]. Econometrica: Journal of the Econometric Society, 1989: 1317-1339.
- [22] KONG A, LIU J S, WONG W H. Sequential Imputations and Bayesian Missing Data Problems[J]. Journal of the American statistical association, 1994, 89(425): 278-288.
- [23] LIU J S. Metropolized Independent Sampling with Comparisons to Rejection Sampling and Importance Sampling[J]. Statistics and computing, 1996, 6: 113-119.
- [24] BERZUINI C, BEST N G, GILKS W R, et al. Dynamic Conditional Independence Models and Markov Chain Monte Carlo Methods[J]. Journal of the American Statistical Association, 1997, 92(440): 1403-1412.

- [25] DHABAL S, VENKATESWARAN P, et al. Two-Dimensional IIR Filter Design Using Simulated Annealing Based Particle Swarm Optimization[J]. Journal of Optimization, 2014, 2014.
- [26] BOUDJELABA K, ROS F, CHIKOUCHE D. Potential of Particle Swarm Optimization and Genetic Algorithms for FIR Filter Design[J]. Circuits, Systems, and Signal Processing, 2014, 33: 3195-3222.
- [27] 莫以为, 萧德云. 进化粒子滤波算法及其应用[J]. 控制理论与应用, 2005, 22(2): 269-272.
- [28] 方正, 佟国峰, 徐心和. 基于粒子群优化的粒子滤波定位方法[J]. 控制理论与应用, 2008, 25(3): 533-537.
- [29] DOUCET A, GODSILL S, ANDRIEU C. On Sequential Monte Carlo Sampling Methods for Bayesian Filtering[J]. Statistics and computing, 2000, 10: 197-208.
- [30] BEAUMONT M A, CORNUET J M, MARIN J M, et al. Adaptive Approximate Bayesian Computation[J]. Biometrika, 2009, 96(4): 983-990.
- [31] EL MOSELHY T A, MARZOUK Y M. Bayesian Inference with Optimal Maps [J]. Journal of Computational Physics, 2012, 231(23): 7815-7850.
- [32] PARNO M D, MARZOUK Y M. Transport Map Accelerated Markov Chain Monte Carlo[J]. SIAM/ASA Journal on Uncertainty Quantification, 2018, 6(2): 645-682.
- [33] SPANTINI A, BIGONI D, MARZOUK Y. Inference via Low-Dimensional Couplings[J]. The Journal of Machine Learning Research, 2018, 19(1): 2639-2709.
- [34] HENG J, DOUCET A, POKERN Y. Gibbs Flow for Approximate Transport with Applications to Bayesian Computation[J]. Journal of the Royal Statistical Society Series B: Statistical Methodology, 2021, 83(1): 156-187.
- [35] REICH S. A Nonparametric Ensemble Transform Method for Bayesian Inference [J]. SIAM Journal on Scientific Computing, 2013, 35(4): A2013-A2024.
- [36] PULIDO M, VAN LEEUWEN P J. Sequential Monte Carlo with Kernel Embedded Mappings: The Mapping Particle Filter[J]. Journal of Computational Physics, 2019, 396: 400-415.
- [37] TAGHVAEI A, MEHTA P G. An Optimal Transport Formulation of the Ensemble Kalman Filter[J]. IEEE Transactions on Automatic Control, 2020, 66(7): 3052-3067.

- [38] GRAHAM M M, THIERY A H. A Scalable Optimal-Transport Based Local Particle Filter[A]. 2019.
- [39] KANG C H, KIM S Y, CHOE Y, et al. Ensemble Transform Particle Filter Using Regularized Optimal Transport and Measure of Nonlinearity[J]. Measurement, 2019, 146: 363-371.
- [40] DAS N, BHATTACHARYA R. Optimal Transport Based Filtering with Nonlinear State Equality Constraints[J]. IFAC-PapersOnLine, 2020, 53(2): 2373-2378.
- [41] CORENFLOS A, THORNTON J, DELIGIANNIDIS G, et al. Differentiable Particle Filtering via Entropy-Regularized Optimal Transport[C]//International Conference on Machine Learning. PMLR, 2021: 2100-2111.
- [42] KANG J, CHEN X, TAO Y, et al. Optimal Transportation Particle Filter for Linear Filtering Systems with Correlated Noises[J]. IEEE Transactions on Aerospace and Electronic Systems, 2022, 58(6): 5190-5203.
- [43] TAGHVAEI A, HOSSEINI B. An Optimal Transport Formulation of Bayes' Law for Nonlinear Filtering Algorithms[C]//2022 IEEE 61st Conference on Decision and Control (CDC). IEEE, 2022: 6608-6613.
- [44] AL-JARRAH M, HOSSEINI B, TAGHVAEI A. Optimal Transport Particle Filters[A]. 2023.
- [45] SÄRKKÄ S, SVENSSON L. Bayesian Filtering and Smoothing: volume 17[M]. Cambridge university press, 2023.
- [46] DOUCET A, DE FREITAS N, GORDON N. An Introduction to Sequential Monte Carlo Methods[J]. Sequential Monte Carlo methods in practice, 2001: 3-14.
- [47] ANDERSON B D, MOORE J B. Optimal Filtering[M]. Courier Corporation, 2012.
- [48] HANDSCHIN J E, MAYNE D Q. Monte Carlo Techniques to Estimate the Conditional Expectation in Multi-Stage Non-Linear Filtering[J]. International journal of control, 1969, 9(5): 547-559.
- [49] HANDSCHIN J. Monte Carlo Techniques for Prediction and Filtering of Non-linear Stochastic Processes[J]. Automatica, 1970, 6(4): 555-563.
- [50] MONGE G. Mémoire Sur la Théorie des Déblais et des Remblais[J]. Histoire de l' Académie Royale des Sciences de Paris, 1781: 666-704.
- [51] KANTOROVICH L V. On the Translocation of Masses[C]//Dokl. Akad. Nauk. USSR (NS): volume 37. 1942: 199-201.

- [52] BRENIER Y. Polar Factorization and Monotone Rearrangement of Vector-Valued Functions[J]. Communications on pure and applied mathematics, 1991, 44(4): 375-417.
- [53] MCCANN R J. Existence and Uniqueness of Monotone Measure-Preserving Maps[Z]. 1995.
- [54] VILLANI C, et al. Optimal Transport: Old and New: volume 338[M]. Springer, 2009.
- [55] ROSENBLATT M. Remarks on a Multivariate Transformation[J]. The annals of mathematical statistics, 1952, 23(3): 470-472.
- [56] KNOTHE H. Contributions to the Theory of Convex Bodies[J]. Michigan Mathematical Journal, 1957, 4(1): 39-52.
- [57] CARLIER G, GALICHON A, SANTAMBROGIO F. From Knothe's Transport to Brenier's Map and a Continuation Method for Optimal Transport[J]. SIAM Journal on Mathematical Analysis, 2010, 41(6): 2554-2576.
- [58] DUNSON D B, PILLAI N, PARK J H. Bayesian Density Regression[J]. Journal of the Royal Statistical Society Series B: Statistical Methodology, 2007, 69(2): 163-183.
- [59] DUAN L L. Transport Monte Carlo: High-Accuracy Posterior Approximation via Random Transport[J]. Journal of the American Statistical Association, 2021: 1-12.
- [60] ISHWARAN H, ZAREPOUR M. Exact and Approximate Sum Representations for the Dirichlet Process[J]. Canadian Journal of Statistics, 2002, 30(2): 269-283.
- [61] KINGMA D P, WELING M. Auto-encoding Variational Bayes[A]. 2013.
- [62] LINDSTEN F. Rao-Blackwellised Particle Methods for Inference and Identification[D]. Linköping University Electronic Press, 2011.
- [63] BERNTORP K, ROBERTSSON A, et al. Rao-Blackwellized Particle Filters with out-of-Sequence Measurement Processing[J]. IEEE Transactions on Signal Processing, 2014, 62(24): 6454-6467.

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于输运蒙特卡洛的滤波算法研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名： 日期： 年 月 日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

(1) 学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；(2) 学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；(3) 研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。
本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名： 日期： 年 月 日

导师签名： 日期： 年 月 日

致 谢

在工大深圳的两年半马上就要过去了，在工大的回忆还是历历在目。在即将离开工大的这个时刻，不舍之情不断的浮上心头。

首先，由衷感谢我的导师严质彬在硕士期间对我的悉心指导。在研究生的两年半中，严老师不论在学习上还是思想上都对我帮助颇多。在研究遇到问题时，严老师往往能立即指出问题的关键，并在大方向上给我非常简练而深入的指导，帮助我快速克服研究上的问题。同时，在生活方面，不论是严老师对待知识的态度、还是在生活上对我和组内师兄师姐无微不至的关心，都极大的帮助了我在工大的求学之旅，给予了我无穷的动力。

感谢实验室的师兄师姐和同门在我科研过程中给我提供的帮助。感谢一直以来和我一起互相帮助、互相排解压力的舍友和同窗。

感谢父母和家人对我的养育和支持，让我在远走他乡求学之时感受到家的温暖，可以以最好的状态投入到科研和生活中去。

最后，感谢哈工大 L^AT_EX 论文模板 HiThesis 在撰写论文方面提供的帮助。