

硕士学位论文

(学术学位论文)

联合优化下的非线性滤波：神经网络与运输 方法

NONLINEAR FILTERING THROUGH JOINT OPTIMIZATION: NEURAL NETWORKS AND TRANSPORT METHODS

张守信

哈尔滨工业大学
提交年月待填写

国内图书分类号：O1

国际图书分类号：51

学校代码：10213

密级：公开

硕士学位论文

联合优化下的非线性滤波：神经网络与输运方法

硕士研究生：张守信

导师：严质彬教授

申请学位：理学硕士

学科：数学

所在单位：哈尔滨工业大学（深圳）

答辩日期：答辩日期待填写

授予学位单位：哈尔滨工业大学

Classified Index: O1

U.D.C: 51

Dissertation for the Master Degree

NONLINEAR FILTERING THROUGH JOINT OPTIMIZATION: NEURAL NETWORKS AND TRANSPORT METHODS

Candidate:	Zhang Shouxin
Supervisor:	Prof. Yan Zhibin
Academic Degree Applied for:	Master of Science
Specialty:	Mathematics
Affiliation:	Harbin Institute of Technology, Shenzhen
Date of Defense:	Date to Be Confirmed
Degree-Confering-Institution:	Harbin Institute of Technology

摘 要

〔待补充〕原中期报告未包含独立摘要。本稿已迁移研究背景、非线性滤波与最优输运理论、算法分析、仿真实验及后续研究安排。请在毕业论文研究完成后，依据最终方法、结果和贡献撰写摘要。

关键词：非线性滤波；粒子滤波；最优输运；集合输运粒子滤波

Abstract

[To be completed.] The source midterm report did not contain a standalone abstract. Write the English abstract after the final methods, results, and contributions have been established.

Keywords: Nonlinear filtering, Particle filtering, Optimal transport, Ensemble transform particle filter

摘 要	I
ABSTRACT	II
第 1 章 研究背景与阶段进展	1
1.1 课题主要研究内容	1
1.2 核心工作进度介绍	3
第 2 章 非线性滤波与最优输运基础	4
2.1 非线性滤波问题	4
2.2 Bayes 滤波	4
2.3 粒子滤波：经验测度近似	5
2.4 最优输运与重采样	8
2.4.1 从 Monge 映射到 Kantorovich 耦合	8
2.4.2 离散耦合、条件概率与边缘约束	9
2.4.3 熵正则化与 Sinkhorn 迭代	10
2.4.4 回到粒子重采样：条件均值与位置变换	11
第 3 章 算法分析	12
3.1 自举粒子滤波	12
3.2 集合输运粒子滤波	13
3.3 均方误差的四项分解	14
第 4 章 仿真实验	16
4.1 模型与实验简介	16
4.2 时序误差分析	17
4.3 粒子数，正则强度与计算开销	18
4.4 零过程噪声 Logistic 模型：粒子贫化与稳健性	19
第 5 章 后续研究安排与可行性分析	20
5.1 后期拟完成的研究工作及进度安排	20
5.2 存在问题、困难及其解决方案	20
5.3 如期完成全部论文工作的可能性	21
结 论	22
人工智能使用声明	23
参考文献	24

附录 A 补充理论与证明	27
A.1 符号定义与说明.....	27
A.2 无记忆性引理的离散情形证明.....	28
A.3 Bayes 更新公式的证明.....	29
A.4 离散 Monge 映射的存在条件.....	30
攻读硕士学位期间取得创新性成果	32
哈尔滨工业大学学位论文原创性声明和使用权限	33
致 谢	34
个人简历	35

第 1 章 研究背景与阶段进展

1.1 课题主要研究内容

1993 年, Gordon、Salmond 和 Smith 提出 Bootstrap 粒子滤波, 在不依赖线性化或高斯假设的条件下实现了递推贝叶斯状态估计^[1]。1994 年, Kong 和 Liu 围绕序贯重要性采样框架讨论了权重退化、粒子耗尽及有效粒子数等问题^[2]。1996 年, Kitagawa 在重采样步骤中引入分层采样思想^[3]。

1998 年, Isard 和 Blake 提出 Condensation 算法, 将粒子滤波用于视觉目标轮廓的实时跟踪^[4]。同年, Liu 和 Chen 提出 SIR (Sequential Importance Re-sampling) 框架^[5]用以解决粒子退化问题。1999 年, Pitt 和 Shephard 引入辅助粒子滤波 (APF)^[6]。APF 通过在采样时引入辅助变量, 根据当前观测对粒子进行预筛选, 从而使用更接近后验的重要性分布, 有效缓解了观测值突变时权重高度不平衡的问题。2000 年, Rudolph van der Merwe 等人提出了无迹粒子滤波 (Unscented PF)^[7], UPF 结合了无迹卡尔曼滤波 (UKF)^[8]的思想, 在重要性采样阶段使用一组无迹变换生成的 sigma 点来近似状态分布, 从而构造出利用当前观测信息的重要性提议分布。Doucet 等主编的文集 [9] 系统总结了粒子滤波及其变体, 其中包括 Rao-Blackwellized 粒子滤波 (RBPF)。RBPF 对部分变量进行粒子采样, 利用其余变量的条件可解析结构实施边缘化, 例如对条件线性高斯部分采用 Kalman 滤波, 对有限状态部分采用 HMM 递推, 以减少采样维度和方差。这类分解也用于 SLAM 等复杂问题^[10]。

Gilks 和 Berzuini 提出重采样-移动 (Resample-Move) 算法, 在重采样后通过 Markov 链 Monte Carlo (MCMC) 更新粒子位置, 以增加粒子多样性、缓解粒子贫化^[11]。2006 年, Doucet 等人提出区块采样 (block sampling) 方法, 每隔 L 步对最近 L 个时刻的粒子状态进行联合 MCMC 更新, 从而降低单步退化对整段轨迹的影响^[12]。上述融合 MCMC 的策略有效缓解了退化, 但计算代价较高^[13]。另一类方法通过核密度平滑构造重采样分布。Musso 等研究的正则化粒子滤波 (RPF) 先对粒子集合进行核密度估计, 再从所得连续分布中重新采样^[14]。2005 年, Chang 和 Ansari 提出的核均值漂移粒子滤波 (KPF) 进一步借助 mean-shift 迭代, 将粒子向后验密度的高峰方向移动, 相当于在滤波过程中执行聚类 and 梯度上升, 使粒子更集中于高概率区域^[15]。但是这些方法仅仅适用于低维单峰平滑问题, 因而具有很大的局限性。

Moselhy 等研究了基于最优输运的贝叶斯推断, 通过构造从先验分布到后验分布的确定性映射, 将先验样本变换为后验样本, 为贝叶斯采样提供了不同于 MCMC

链式采样的实现思路^[16]。2013 年, Reich 基于最优传输理论提出了一种新的非参数数集同化变换方法 (Ensemble Transform, ET), 弥补了 EnKF^[17] 在一致性上的不足。2021 年, 在 Reich 的 OT 粒子滤波思想基础上, Corenflos 结合 Cuturi 的熵正则化 OT^[18], 提出了首个完全可微的粒子滤波方法 (DPF)^[19], 解决了长期困扰 PF 的不可微重采样问题。Al-Jarrah 等将 Bayes 更新表述为从预测分布到后验分布的条件最优输运问题, 并利用神经网络近似观测条件下的 Brenier 映射, 为非线性滤波的后验更新提供了基于输运映射的实现途径^[20]。

自 2015 年以来, 深度学习与卡尔曼滤波相结合的研究引起了广泛关注。2015 年, Krishnan 等人提出了 Deep Kalman Filter (DKF)^[21], 用神经网络参数化状态转移和观测分布, 突破了线性假设。同年 Shixiang Gu 等人提出了 “Neural Adaptive Sequential Monte Carlo” 方法, 提出训练一个关于提议分布和真实分布 KL 散度最优的 RNN 模型^[22], 进而用于改进传统算法的粒子贫化。Karl 等提出深度变分贝叶斯滤波 (DVBF), 通过贯穿状态演化过程的反向传播学习潜在马尔可夫状态空间模型, 从高维观测中提取用于描述系统动态的隐空间表示^[23]。2017 年, Krishnan 等人提出面向非线性状态空间模型的结构化推断网络, 以神经网络参数化转移和观测分布, 并通过结构化变分近似联合学习生成模型与推断网络^[24]。Hafner 等结合循环神经网络与变分推断构建非线性状态空间模型, 并将其用于基于像素观测的模型式强化学习^[25]。2021 年, Revach 等人提出 KalmanNet 框架^[26], 保留经典滤波递推结构, 以神经网络学习 Kalman 增益, 并在所测试的非线性与模型失配场景中提高估计精度。2023 年, Greenberg 等人针对过往神经网络优化的非线性滤波器, 对 KF 做出了新的优化基线 OKF, 并指出在优化 KF 的超参数 Q, R 后, 神经网络反而未必优于传统 KF 算法^[27]。

Liu 等人提出 LLM-Filter, 将带噪观测嵌入为文本原型, 并通过 System-as-Prompt 引导冻结大语言模型完成状态估计, 强调学习型滤波器在未见系统上的上下文泛化能力^[28]。Xiao 等人提出 LD-EnSF, 将集合评分滤波与潜空间动力学结合, 使同化过程在紧凑潜空间中演化, 从而减少高维稀疏观测场景中的全空间数值模拟开销^[29]。与滤波问题相邻, Stöckl 等人的 local prediction-learning 研究表明, 局部下一观测预测可以在高维表示空间中形成可用于规划的认知地图^[30]。

本课题围绕非线性系统的状态估计问题, 研究如何根据含噪观测递推估计系统状态, 以最优输运方法在粒子滤波后验更新中的应用为重点。当前阶段的工作主要包括: 梳理贝叶斯滤波、粒子近似与最优输运之间的数学联系, 整理输运式粒子更新的算法步骤与误差分析, 并通过仿真实验比较其与自举粒子滤波等方法的估计精度、粒子多样性及计算成本。在此基础上, 后续拟进一步分析输运式粒

子更新的适用条件与计算开销，探索相应的算法改进，进行对照实验。最终形成可复用的理论资料、算法实现与可复现实验结果，明确所研究方法的优势、局限及适用条件。

1.2 核心工作进度介绍

目前已完成不包含神经网络部分的理论梳理、算法实现与基线实验，具体进展如下：

(1) **理论整理**：统一 Bayes 递推、粒子近似与输运重采样的表述，整理四项均方误差分解及零过程噪声下的贫化证明。

(2) **算法实现**：完成 BPF、原始与熵正则化 ETPF，并与扩展 Kalman 滤波、集合 Kalman 滤波对照。

(3) **实验评估**：Gordon 基准上两类粒子滤波精度接近，但输运成本较高；零过程噪声 Logistic 实验中，ETPF 缓解了所测试运行中的单点贫化。

神经网络相关研究尚未开展，后续拟通过文献学习评估其与输运滤波结合的可行性，具体方案尚待确定。

第 2 章 非线性滤波与最优输运基础

2.1 非线性滤波问题

本文从状态空间模型与 Bayes 递推出发, 梳理粒子滤波及最优输运重采样的数学关系, 并给出算法实现与仿真比较。经典滤波框架与序贯蒙特卡罗方法分别参考文献[9,31]。

本文约定: 凡使用密度公式时, 均假设相应密度存在, 以相应空间的体积测度为参考测度, 密度等式按几乎处处理解。状态空间的体积测度记为 ν_X 。第 4.4 节的零过程噪声模型使用 Dirac 转移核, 预测按测度推前理解。

设概率空间为 $(\Omega, \mathcal{F}, \mathbb{P})$, 状态空间为 $(\mathcal{X}, \mathcal{B}(\mathcal{X}))$, 观测空间为 $(\mathcal{Y}, \mathcal{B}(\mathcal{Y}))$, 其中 $\mathcal{X} = \mathbb{R}^{n_x}$, $\mathcal{Y} = \mathbb{R}^{n_y}$, $\mathcal{B}$ 表示 Borel 集合族。状态与观测满足

$$\begin{aligned} X_k &= f(X_{k-1}, N_{x,k}), \\ Y_k &= h(X_k, N_{y,k}), \quad k \geq 1. \end{aligned} \quad (2-1)$$

其中 $X_k : \Omega \rightarrow \mathcal{X}$, $Y_k : \Omega \rightarrow \mathcal{Y}$ 为可测映射, f, h 为已知可测函数。 $\mathbb{P}$ 定义在 Ω 上, 状态分布 $\mathbb{P}_{X_k} = (X_k)_* \mathbb{P}$ 与滤波后验分布定义在 $\mathcal{X}$ 上。

条件:

- 所有时刻的过程噪声与观测噪声彼此独立, 并与 X_0 独立, 亦即 $X_0, N_{x,k}, N_{y,k}$ 作为随机变量独立。

- 观测条件密度 $p_{Y_k|X_k}(y | x)$ 可计算, 对实际观测, Bayes 更新的归一化常数有限且严格为正。

输入: 模型 f, h , 初始分布 $\mathbb{P}_{X_0}$, 噪声分布 $\mathbb{P}_{N_x}, \mathbb{P}_{N_y}$, 依次到达的观测值 $y_1, y_2, \dots$ 。

输出: 逐个收到观测 y_k , 递推求解当前状态的后验概率密度函数 $p_{X_k|Y_{1:k}}(x_k | y_{1:k})$ 。

2.2 Bayes 滤波

引理 2.1 无记忆性 在上述状态方程与噪声独立性条件下, 给定 X_{k-1} 后, X_k 的条件分布不再依赖更早的状态与历史观测; 给定 X_k 后, Y_k 的条件分布不再依赖过去的状态与观测。对 $k \geq 1$ 有

$$\begin{aligned} p_{X_k|X_{0:k-1}, Y_{1:k-1}}(x_k | x_{0:k-1}, y_{1:k-1}) &= p_{X_k|X_{k-1}}(x_k | x_{k-1}), \\ p_{Y_k|X_{0:k}, Y_{1:k-1}}(y_k | x_{0:k}, y_{1:k-1}) &= p_{Y_k|X_k}(y_k | x_k). \end{aligned} \quad (2-2)$$

$k = 1$ 时历史观测为空。第一式给出状态的一阶 Markov 性，第二式给出观测的条件独立性，分别用于下述预测与更新。

证明 离散情形的证明及一般情形的推广说明见第 A.2 节。 $\square$

固定观测记录 $y_{1:k} = (y_1, \dots, y_k)^T$ ，以 p_{X_0} 初始化， $k = 1$ 时不含历史观测条件。

预测：由上一时刻的后验与状态转移密度，求当前状态在收到 y_k 前的条件密度。

$$\begin{aligned} & p_{X_k|Y_{1:k-1}}(x_k | y_{1:k-1}) \\ &= \int_{\mathcal{X}} p_{X_k|X_{k-1}}(x_k | x_{k-1}) p_{X_{k-1}|Y_{1:k-1}}(x_{k-1} | y_{1:k-1}) dv_X(x_{k-1}). \end{aligned} \quad (2-3)$$

更新：收到 y_k 后，用观测似然对预测密度加权，再归一化，证明见定理 A.1。

$$\begin{aligned} & p_{X_k|Y_{1:k}}(x_k | y_{1:k}) \\ &= \frac{p_{Y_k|X_k}(y_k | x_k) p_{X_k|Y_{1:k-1}}(x_k | y_{1:k-1})}{\int_{\mathcal{X}} p_{Y_k|X_k}(y_k | x) p_{X_k|Y_{1:k-1}}(x | y_{1:k-1}) dv_X(x)}. \end{aligned} \quad (2-4)$$

分母就是观测的预测密度 $p_{Y_k|Y_{1:k-1}}(y_k | y_{1:k-1})$ ，要求其有限且严格为正。更新所得后验作为下一步预测的输入，这两步构成精确的 Bayes 滤波递推。

2.3 粒子滤波：经验测度近似

以下以 Gordon 等提出的自举粒子滤波为基础^[1]，采用序贯蒙特卡罗的经验测度表示^[9]。粒子滤波的理论框架、主要算法与多目标跟踪应用已有系统的中文综述^[32]。

固定观测记录，用 $-$ 与 $+$ 分别表示预测与后验，记

$$\begin{aligned} \mathbb{P}_{X_k}^- &:= \mathbb{P}_{X_k|Y_{1:k-1}}(y_{1:k-1}, \cdot), \\ \mathbb{P}_{X_k}^+ &:= \mathbb{P}_{X_k|Y_{1:k}}(y_{1:k}, \cdot), \\ \mathbb{P}_{X_0}^+ &:= \mathbb{P}_{X_0}. \end{aligned} \quad (2-5)$$

从预测公式出发，以下使用条件密度的简写 $p(x_k | y_{1:k-1}) = p_{X_k|Y_{1:k-1}}(x_k | y_{1:k-1})$ ，其他条件密度同理：

$$\begin{aligned} & p(x_k | y_{1:k-1}) \\ &= \int_{\mathcal{X}} p(x_k | x_{k-1}) p(x_{k-1} | y_{1:k-1}) dv_X(x_{k-1}). \end{aligned} \quad (2-6)$$

固定 x_k ，这个积分就是函数 $x_{k-1} \mapsto p(x_k | x_{k-1})$ 关于上一时刻后验分布

的平均。因此，先假设能够从 $p(x_{k-1} | y_{1:k-1})$ 独立抽取 N 个样本，记实现值为 $x_{k-1}^{+, (1)}, \dots, x_{k-1}^{+, (N)}$ ，其中 $+$ 表示这些样本来自后验分布。

由简单抽样得到等权经验测度，每个样本占 $1/N$ 的质量：

$$\hat{\mathbb{P}}_{N; X_{k-1}}^+ := \frac{1}{N} \sum_{i=1}^N \delta_{x_{k-1}^{+, (i)}}. \quad (2-7)$$

用这一经验测度替换预测积分中的后验测度 $p(x_{k-1} | y_{1:k-1}) dv_X(x_{k-1})$ ，得到

$$\begin{aligned} & p(x_k | y_{1:k-1}) \\ & \approx \int_{\mathcal{X}} p(x_k | x_{k-1}) d\hat{\mathbb{P}}_{N; X_{k-1}}^+(x_{k-1}) \\ & = \frac{1}{N} \sum_{i=1}^N \int_{\mathcal{X}} p(x_k | x_{k-1}) d\delta_{x_{k-1}^{+, (i)}}(x_{k-1}). \end{aligned} \quad (2-8)$$

最后使用 Dirac 测度的积分性质 $\int \varphi(x) d\delta_a(x) = \varphi(a)$ ，每个积分都变成在对应样本处的函数值：

$$p(x_k | y_{1:k-1}) \approx \frac{1}{N} \sum_{i=1}^N p(x_k | x_{k-1}^{+, (i)}). \quad (2-9)$$

这样，后验分布下的积分被样本平均近似，预测密度成为 N 个转移密度的等权混合。

提议分布：在生成新粒子时，需要指定实际用于抽样的分布，其密度称为提议密度，记为 q 。它可以依赖旧粒子与当前观测，抽样操作写作

$$x_k^{-, (i)} \sim q(\cdot | x_{k-1}^{+, (i)}, y_k). \quad (2-10)$$

当前要对上面的预测混合分布进行采样，我们选择每个成分本身的转移密度作为提议密度：

$$q(x_k | x_{k-1}^{+, (i)}, y_k) = p(x_k | x_{k-1}^{+, (i)}). \quad (2-11)$$

这一选择在生成粒子时不使用当前观测 y_k ，正是自举滤波采用的转移先验提议。

分层采样：以混合成分的编号 i 作为分层依据，第 i 层对应密度 $p(x_k | x_{k-1}^{+, (i)})$ ，在混合分布中占 $1/N$ 的质量。因此每层分配一个样本，给定上一时刻的粒子后，各层独立抽取预测粒子：

$$x_k^{-, (i)} \sim p(\cdot | x_{k-1}^{+, (i)}), i = 1, \dots, N. \quad (2-12)$$

这里 $\sim$ 表示抽样操作， $x_k^{-, (i)}$ 记抽得的实现值。由状态方程，这一操作可以通过独立抽取过程噪声实现值 $n_{x,k}^{(i)}$ 完成：

$$x_k^{-,(i)} = f(x_{k-1}^{+,(i)}, n_{x,k}^{(i)}). \quad (2-13)$$

在上述转移先验提议下，每个样本代表所在层的 $1/N$ 质量，因此将这些预测粒子合并，得到预测分布的等权经验测度：

$$\hat{\mathbb{P}}_{N;X_k}^- := \frac{1}{N} \sum_{i=1}^N \delta_{x_k^{-,(i)}} \approx \mathbb{P}_{X_k}^-. \quad (2-14)$$

这一步用有限个点质量进一步近似前面得到的混合分布。给定旧粒子后，各层样本独立，但各自服从对应的转移分布。

更新： - 与 + 分别表示使用当前观测前后的预测与后验阶段，此处只更新权重。对任意可测集合 A ，将 Bayes 公式中的预测测度替换为等权经验测度，再用 Dirac 积分性质展开；假设样本似然总和有限且严格为正，约去 $1/N$ 后得到后验近似：

$$\begin{aligned} & \mathbb{P}_{X_k}^+(A) \\ &= \int_A \frac{p(y_k | x) p(x | y_{1:k-1})}{\int_X p(y_k | z) p(z | y_{1:k-1}) dv_X(z)} dv_X(x) \\ &= \frac{\int_A p(y_k | x) d\mathbb{P}_{X_k}^-(x)}{\int_X p(y_k | x) d\mathbb{P}_{X_k}^-(x)}, \\ \Rightarrow \hat{\mathbb{P}}_{N;X_k}^+(A) &:= \frac{\int_A p(y_k | x) d\hat{\mathbb{P}}_{N;X_k}^-(x)}{\int_X p(y_k | x) d\hat{\mathbb{P}}_{N;X_k}^-(x)} \\ &= \sum_{i=1}^N w_k^{+,(i)} \delta_{x_k^{-,(i)}}(A), \\ w_k^{+,(i)} &:= \frac{p(y_k | x_k^{-,(i)})}{\sum_{j=1}^N p(y_k | x_k^{-,(j)})}, i = 1..N. \end{aligned} \quad (2-15)$$

重采样： 粗略地说，重采样是对粒子位置的更新。因此，和上一步的概率测度更新应该联为一体，同属于预测 $\rightarrow$ 更新的大步骤。粒子矩阵按列排列为 $X_k^\pm := x_k^{\pm,(1..N)} \in \mathbb{R}^{n_x \times N}$ 。用 $\mathbf{\Pi}_k$ 表示联合概率矩阵， $\mathbf{T}_k$ 表示位置变换矩阵， $\mathbf{n}_k$ 表示各粒子的复制次数， $(\mathbf{T}_k)_{ij}$ 表示源粒子 i 对目标粒子 j 的贡献系数。经典重采样中该系数为 $\mathbb{I}_{\{A_j=i\}}$ ，其中 A_j 是目标粒子 j 抽取的索引：

$$\begin{aligned} X_k^+ &= X_k^- T_k = N X_k^- \Pi_k, \quad T_k = N \Pi_k \geq 0, \\ T_k^T \mathbf{1}_N &= \mathbf{1}_N, \quad T_k \mathbf{1}_N = \mathbf{n}_k, \quad \mathbb{E}[\mathbf{n}_k | \mathbf{w}_k^+] = N \mathbf{w}_k^+. \end{aligned} \quad (2-16)$$

重采样就是按后验权重，从已有预测粒子中有放回地抽取 N 次。先把各粒子的权重依次累加，将 $[0, 1)$ 划成 N 段，每段长度就是对应粒子的权重。每次独立抽一个均匀随机数，落在哪一段，就复制哪一个粒子；重复 N 次，得到后验粒子。因而，权重越大的粒子越容易被多次保留，权重小的粒子可能一次也选不到。将新粒子的权重统一设为 $1/N$ ，原来由权重表达的质量差异，就改由复制次数表达。这样， T_k 的第 j 列记录新粒子 j 复制了谁， $\mathbf{n}_k$ 记录每个旧粒子被复制了几次。单次重采样会产生随机误差；固定原粒子与权重后，对重采样随机性取平均，所得经验测度等于原加权测度。

2.4 最优输运与重采样

经典重采样通过随机复制选择耦合矩阵，其源边缘为实际复制比例，只有对重采样随机性取平均后才恢复后验权重：

$$\Pi_k \mathbf{1}_N = \frac{\mathbf{n}_k}{N}, \quad \Pi_k^T \mathbf{1}_N = \frac{1}{N} \mathbf{1}_N, \quad \mathbb{E}_{\mathbf{n}_k \sim \mathbb{P}_{\mathbf{n}_k | \mathbf{w}_k^+}} \left[\frac{\mathbf{n}_k}{N} \right] = \mathbf{w}_k^+. \quad (2-17)$$

另一种选择是直接约束源边缘为 $\mathbf{w}_k^+$ ，并按粒子间的移动代价选择耦合。为此，先从输运映射出发，建立联合分布、条件概率与离散耦合矩阵之间的关系。

2.4.1 从 Monge 映射到 Kantorovich 耦合

本节采用最优输运的标准映射与耦合表述^[18,33]；其基本理论、离散模型与正则化方法亦可参见马丽涛、边伟的中文综述^[34]。

本节暂用 X, Y 表示一般输运问题的源、目标随机变量， Y 不特指滤波观测。给定边缘分布 $\mathbb{P}_X, \mathbb{P}_Y$ 与非负代价函数 c ，Monge 问题寻找可测映射 T ，使

$$\begin{aligned} Y &= T(X), \quad T_* \mathbb{P}_X = T_* X_* \mathbb{P} = \mathbb{P}_Y, \\ \inf_{T: T_* \mathbb{P}_X = \mathbb{P}_Y} \int_X c(x, T(x)) d\mathbb{P}_X(x) &= \inf_{T: T_* \mathbb{P}_X = \mathbb{P}_Y} \mathbb{E}_{X \sim \mathbb{P}_X} [c(X, T(X))]. \end{aligned} \quad (2-18)$$

确定性绑定 $Y = T(X)$ 使条件分布退化为 $\mathbb{P}_{Y|X=x} = \delta_{T(x)}$ ：一个源点的质量只能整体送往一个目标点，不能拆分。离散边缘因而可能不存在这样的映射；均匀离散分布的整除条件见第 A.4 节。

耦合松弛：解除函数绑定，允许任意满足两个边缘约束的联合分布。记坐标投影 $\pi_1(x, y) = x$ 、 $\pi_2(x, y) = y$ ，定义

$$\Pi(\mathbb{P}_X, \mathbb{P}_Y) := \{\mu \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y}) : (\pi_1)_*\mu = \mathbb{P}_X, (\pi_2)_*\mu = \mathbb{P}_Y\}. \quad (2-19)$$

输运目标于是成为联合分布上的期望最小化：

$$\inf_{\mu \in \Pi(\mathbb{P}_X, \mathbb{P}_Y)} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\mu(x, y) = \inf_{\mathbb{P}_{(X,Y)} \in \Pi(\mathbb{P}_X, \mathbb{P}_Y)} \mathbb{E}_{(X,Y) \sim \mathbb{P}_{(X,Y)}} [c(X, Y)]. \quad (2-20)$$

在这里的欧氏状态空间上，联合分布可通过条件转移核写成半直积 $\mathbb{P}_{(X,Y)} = \mathbb{P}_X \ltimes \mathbb{P}_{Y|X}$ ；独立乘积 $\mathbb{P}_X \otimes \mathbb{P}_Y$ 是其中一个特例。

2.4.2 离散耦合、条件概率与边缘约束

设两组支撑点各自互异， $\mathbf{a} \in \Delta^{m-1}$ 、 $\mathbf{b} \in \Delta^{n-1}$ ，且暂取 $a_i, b_j > 0$ ；符号定义见第 A.1 节。记

$$\begin{aligned} \mathbb{P}_X &= \langle \mathbf{a}, \delta_{x_{1..m}} \rangle, & \mathbb{P}_Y &= \langle \mathbf{b}, \delta_{y_{1..n}} \rangle, \\ \Pi_{ij} &:= \mathbb{P}_{(X,Y)}(\{(x_i, y_j)\}), & \mathbb{P}_{(X,Y)} &= \sum_{i=1}^m \sum_{j=1}^n \Pi_{ij} \delta_{x_i} \otimes \delta_{y_j}. \end{aligned} \quad (2-21)$$

这里 $\otimes$ 表示测度的乘积。对点质量作坐标推前，就得到边缘的行和、列和：

$$\begin{aligned} (\pi_1)_*(\delta_{x_i} \otimes \delta_{y_j}) &= \delta_{x_i}, & (\pi_2)_*(\delta_{x_i} \otimes \delta_{y_j}) &= \delta_{y_j}, \\ (\pi_1)_*\mathbb{P}_{(X,Y)} &= \sum_{i=1}^m \left(\sum_{j=1}^n \Pi_{ij} \right) \delta_{x_i} = \mathbb{P}_X, \\ (\pi_2)_*\mathbb{P}_{(X,Y)} &= \sum_{j=1}^n \left(\sum_{i=1}^m \Pi_{ij} \right) \delta_{y_j} = \mathbb{P}_Y. \end{aligned} \quad (2-22)$$

函数与测度的对偶配对记为 $\langle f, \mu \rangle_S := \int_S f(s) d\mu(s)$ ，下标标明测度所在空间。对于一般情况（假使需要讨论连续而非离散），等价地，用推前与拉回对偶，对任意 Borel 集合 $A \subseteq \mathcal{X}$ 有

$$\begin{aligned} \langle \mathbb{I}_A \otimes \mathbf{1}_Y, \mathbb{P}_{(X,Y)} \rangle_{\mathcal{X} \times \mathcal{Y}} &= \langle \pi_1^* \mathbb{I}_A, \mathbb{P}_{(X,Y)} \rangle_{\mathcal{X} \times \mathcal{Y}} \\ &= \langle \mathbb{I}_A, (\pi_1)_*\mathbb{P}_{(X,Y)} \rangle_{\mathcal{X}} = \langle \mathbb{I}_A, \mathbb{P}_X \rangle_{\mathcal{X}}. \end{aligned} \quad (2-23)$$

更一般地，每个坐标分别满足 $(\pi_i)_*\mathbb{P}_{X_{1..N}} = \mathbb{P}_{X_i}$ ；全部边缘组成的族应写为 $((\pi_i)_*\mathbb{P}_{X_{1..N}})_{i=1}^N = (\mathbb{P}_{X_i})_{i=1}^N$ 。

条件概率：条件概率矩阵标明条件方向，联合概率矩阵统一记为 Π ：

$$\begin{aligned} P_{Y|X;i,j} &:= \mathbb{P}_{Y|X=x_i}(\{y_j\}) = \frac{\Pi_{ij}}{a_i}, & P_{X|Y;j,i} &:= \mathbb{P}_{X|Y=y_j}(\{x_i\}) = \frac{\Pi_{ij}}{b_j}, \\ \Pi &= \text{diag}(\mathbf{a}) P_{Y|X} = P_{X|Y}^T \text{diag}(\mathbf{b}), \\ P_{Y|X} \mathbf{1}_n &= \mathbf{1}_m, & P_{Y|X}^T \mathbf{a} &= \mathbf{b}. \end{aligned} \quad (2-24)$$

条件矩阵以条件变量的取值编号为行、被条件化变量的取值编号为列。

离散输运：令 $C_{ij} = c(x_i, y_j)$ ，连续耦合约束化为输运多面体，目标化为有限求和：

$$U(\mathbf{a}, \mathbf{b}) := \{\mathbf{\Pi} \in \mathbb{R}_+^{m \times n} : \mathbf{\Pi} \mathbf{1}_n = \mathbf{a}, \mathbf{\Pi}^T \mathbf{1}_m = \mathbf{b}\},$$

$$\min_{\mathbf{\Pi} \in U(\mathbf{a}, \mathbf{b})} \langle \mathbf{\Pi}, \mathbf{C} \rangle_F, \quad \langle \mathbf{\Pi}, \mathbf{C} \rangle_F := \sum_{i=1}^m \sum_{j=1}^n \Pi_{ij} C_{ij}. \quad (2-25)$$

独立联合分布对应 $\mathbf{\Pi} = \mathbf{a} \mathbf{b}^T \in U(\mathbf{a}, \mathbf{b})$ 。

2.4.3 熵正则化与 Sinkhorn 迭代

采用 Cuturi 的熵正则化离散输运方案^[35]，推导及数值实现参考文献^[18]。

正则化：给定 $\varepsilon > 0$ ，以独立联合分布为参考测度，考虑

$$\mathbb{P}_{(X,Y)}^\varepsilon = \operatorname{argmin}_{\mu \in \Pi(\mathbb{P}_X, \mathbb{P}_Y)} \left\{ \int c(x, y) d\mu(x, y) + \varepsilon D_{\text{KL}}(\mu \| \mathbb{P}_X \otimes \mathbb{P}_Y) \right\}. \quad (2-26)$$

在离散边缘固定时，KL 项与负熵仅相差一个常数；以下采用 $0 \log 0 = 0$ ：

$$D_{\text{KL}}(\mathbf{\Pi} \| \mathbf{a} \mathbf{b}^T) = \sum_{i=1}^m \sum_{j=1}^n \Pi_{ij} \log \frac{\Pi_{ij}}{a_i b_j}$$

$$= \sum_{i=1}^m \sum_{j=1}^n \Pi_{ij} \log \Pi_{ij} - \sum_{i=1}^m a_i \log a_i - \sum_{j=1}^n b_j \log b_j. \quad (2-27)$$

因此，所求矩阵等价地满足

$$\mathbf{\Pi}^\varepsilon = \operatorname{argmin}_{\mathbf{\Pi} \in U(\mathbf{a}, \mathbf{b})} \left\{ \langle \mathbf{\Pi}, \mathbf{C} \rangle_F + \varepsilon \sum_{i=1}^m \sum_{j=1}^n \Pi_{ij} (\log \Pi_{ij} - 1) \right\}. \quad (2-28)$$

这里额外减去 $\varepsilon \sum_{i,j} \Pi_{ij} = \varepsilon$ 也是常数，使求导后的表达更简洁。

对偶条件：取 $\alpha \in \mathbb{R}^m$ 、 $\beta \in \mathbb{R}^n$ ，构造拉格朗日函数：

$$\mathcal{L}(\mathbf{\Pi}, \alpha, \beta) = \langle \mathbf{\Pi}, \mathbf{C} \rangle_F + \varepsilon \sum_{i=1}^m \sum_{j=1}^n \Pi_{ij} (\log \Pi_{ij} - 1)$$

$$+ \alpha^T (\mathbf{\Pi} \mathbf{1}_n - \mathbf{a}) + \beta^T (\mathbf{\Pi}^T \mathbf{1}_m - \mathbf{b}). \quad (2-29)$$

有限代价与严格正边缘下，最优矩阵各元素严格为正；一阶条件给出

$$\frac{\partial \mathcal{L}}{\partial \Pi_{ij}} = C_{ij} + \varepsilon \log \Pi_{ij} + \alpha_i + \beta_j = 0,$$

$$K_{ij} := \exp(-C_{ij}/\varepsilon), \quad u_i := \exp(-\alpha_i/\varepsilon), \quad v_j := \exp(-\beta_j/\varepsilon), \quad (2-30)$$

$$\Pi_{ij}^\varepsilon = u_i K_{ij} v_j, \quad \mathbf{\Pi}^\varepsilon = \operatorname{diag}(\mathbf{u}) \mathbf{K} \operatorname{diag}(\mathbf{v}).$$

交替缩放：将矩阵分解代回边缘约束，得到

$$\begin{aligned} \mathbf{u} \odot (\mathbf{K}\mathbf{v}) &= \mathbf{a}, & \mathbf{v} \odot (\mathbf{K}^T\mathbf{u}) &= \mathbf{b}, \\ \mathbf{v}^{(0)} &= \mathbf{1}_n, & \mathbf{u}^{(\ell+1)} &= \mathbf{a} \oslash (\mathbf{K}\mathbf{v}^{(\ell)}), \\ \mathbf{v}^{(\ell+1)} &= \mathbf{b} \oslash (\mathbf{K}^T\mathbf{u}^{(\ell+1)}), \\ \mathbf{\Pi}^{(\ell+1)} &= \text{diag}(\mathbf{u}^{(\ell+1)})\mathbf{K}\text{diag}(\mathbf{v}^{(\ell+1)}). \end{aligned} \quad (2-31)$$

其中 $\odot, \oslash$ 分别表示逐元素乘、除。每次先校正行边缘，再校正列边缘；以两侧边缘残差共同判断停止：

$$\max\{\|\mathbf{\Pi}^{(\ell)}\mathbf{1}_n - \mathbf{a}\|_1, \|(\mathbf{\Pi}^{(\ell)})^T\mathbf{1}_m - \mathbf{b}\|_1\} \leq \tau. \quad (2-32)$$

严格正核下，迭代趋向唯一的正则化最优耦合。

2.4.4 回到粒子重采样：条件均值与位置变换

该构造沿用 Reich 的集合变换方法^[36]，并用熵正则化耦合近似未正则化的输运解。

沿用离散输运中的边际记号 $\mathbf{a}, \mathbf{b}$ ，当前时刻的代价矩阵记为 $\mathbf{C}_k \in \mathbb{R}^{N \times N}$ ，令

$$\begin{aligned} \mathbf{a} &= \mathbf{w}_k^+, \quad \mathbf{b} = \frac{1}{N}\mathbf{1}_N, \quad (\mathbf{C}_k)_{ij} := \|x_k^{-,(i)} - x_k^{-,(j)}\|^2, \\ \mathbf{\Pi}_k &\in U(\mathbf{a}, \mathbf{b}), \quad \mathbf{\Pi}_k\mathbf{1}_N = \mathbf{w}_k^+, \quad \mathbf{\Pi}_k^T\mathbf{1}_N = \frac{1}{N}\mathbf{1}_N. \end{aligned} \quad (2-33)$$

这里 $i, j = 1, \dots, N$ ，第 i 行对应后验权重为 $w_k^{+, (i)}$ 的预测粒子，第 j 列对应等权的目标参考位置 $x_k^{-, (j)}$ 。源边际为加权后验经验测度，目标边际为等权预测经验测度。将 $\mathbf{a}, \mathbf{b}, \mathbf{C}_k$ 代入式 (2-28) 的熵正则化目标，用 Sinkhorn 求解 $\mathbf{\Pi}_k$ ；正则化参数 ε 保留在求解目标中。

位置变换矩阵 $\mathbf{T}_k \in \mathbb{R}^{N \times N}$ 按行对应源粒子 i ，按列对应目标粒子 j ，定义为

$$\begin{aligned} (\mathbf{T}_k)_{ij} &:= N(\mathbf{\Pi}_k)_{ij}, \quad \mathbf{T}_k = N\mathbf{\Pi}_k, \\ \mathbf{T}_k^T\mathbf{1}_N &= \mathbf{1}_N, \quad \mathbf{T}_k\mathbf{1}_N = N\mathbf{w}_k^+. \end{aligned} \quad (2-34)$$

每列的变换系数非负且和为 1，据此取源粒子的加权平均，得到新粒子：

$$\begin{aligned} x_k^{+, (j)} &:= \sum_{i=1}^N (\mathbf{T}_k)_{ij} x_k^{-, (i)} = N \sum_{i=1}^N (\mathbf{\Pi}_k)_{ij} x_k^{-, (i)}, \\ X_k^+ &= X_k^- \mathbf{T}_k = N X_k^- \mathbf{\Pi}_k. \end{aligned} \quad (2-35)$$

第 3 章 算法分析

本节先给出每个时刻都有观测的基本算法。输入观测序列 $y_{1:T} = (y_1, \dots, y_T)$, 其中 y_k 是时刻 k 实际获得的观测值, T 是总时间步数。已知状态转移模型 f , 过程噪声分布 $\mathbb{P}_{N_x}$ 与观测条件密度 $p_{Y_k|X_k}(y|x)$; 收到 y_k 后定义似然函数

$$g_k(x) := p_{Y_k|X_k}(y_k|x). \quad (3-1)$$

两种算法都从初始密度 $p(x_0)$ 采样, 每轮依次预测粒子, 用当前观测更新权重, 再生成供下一轮使用的等权粒子。假设每轮的粒子似然总和有限且严格为正。

初始化与第一次迭代 第一次观测到达时, 精确的预测与更新为

$$\begin{aligned} p(x_1) &= \int p(x_1|x_0)p(x_0)dx_0, \\ p(x_1|y_1) &= \frac{g_1(x_1)p(x_1)}{\int g_1(z)p(z)dz}. \end{aligned} \quad (3-2)$$

对应的粒子近似是

$$\begin{aligned} x_0^{+, (i)} &\sim p(x_0), n_{x,1}^{(i)} \sim \mathbb{P}_{N_x}, x_1^{-, (i)} = f(x_0^{+, (i)}, n_{x,1}^{(i)}), \\ w_1^{+, (i)} &= \frac{g_1(x_1^{-, (i)})}{\sum_j g_1(x_1^{-, (j)})}, \hat{\mathbb{P}}_{N;X_1}^+ = \sum_i w_1^{+, (i)} \delta_{x_1^{-, (i)}} \approx \mathbb{P}_{X_1|Y_1=y_1}. \end{aligned} \quad (3-3)$$

随后 BPF 按权重随机复制粒子, ETPF 通过最优输运取重心, 所得 $x_1^{+, (i)}$ 均作为第二轮预测的输入。

3.1 自举粒子滤波

基本 BPF 采用转移先验提议与独立重采样, 即 Gordon 等^[1] 的预测与抽样更新。给定权重后, 每个新粒子独立选取一个旧粒子, 第 i 个旧粒子被选中的概率为 $w_k^{+, (i)}$; 复制次数因此服从多项分布。

算法 3-1 的权重更新由 Bayes 公式得到; 重采样只改变粒子的位置及复制次数; 每轮总是从等权粒子开始 (亦即, 总是暴力重采样而不考虑有效粒子数)。

间隔观测 若只在 $O \subseteq \{1, \dots, T\}$ 提供观测, 输入改为带时刻的观测记录 $\{(k, y_k) : k \in O\}$ 。在 $k \notin O$ 时, 两种算法均只执行预测, 令 $x_k^{+, (i)} = x_k^{-, (i)}$, 输出 $\hat{x}_k = N^{-1} \sum_i x_k^{-, (i)}$, 然后进入下一时刻。每隔 m 步观测对应 $O = \{m, 2m, \dots\} \cap \{1, \dots, T\}$ 。

算法 3-1 BPF: 预测、似然加权与独立重采样

输入: 初始密度 $p(x_0)$, 粒子数 N , 模型 f , 噪声分布 $\mathbb{P}_{N_x}$, 观测条件密度, 观测序列 $y_{1:T}$
输出: 后验均值估计 $\hat{x}_{1:T}$; 每轮更新后的等权粒子 $\{x_k^{+, (j)}\}_{j=1}^N$

- 1 独立采样 $x_0^{+, (i)} \sim p(x_0)$, 权重均为 $1/N, i = 1, \dots, N$
- 2 **for** $k = 1, \dots, T$ **do**
- 3 独立采样 $n_{x,k}^{(i)} \sim \mathbb{P}_{N_x}$, 令 $x_k^{-, (i)} = f(x_{k-1}^{+, (i)}, n_{x,k}^{(i)})$
- 4 读取 y_k , 计算 $g_k(x_k^{-, (i)}) = p_{Y_k|X_k}(y_k | x_k^{-, (i)})$
- 5 $w_k^{+, (i)} = \frac{g_k(x_k^{-, (i)})}{\sum_{r=1}^N g_k(x_k^{-, (r)})}, i = 1, \dots, N$
- 6 输出后验均值估计 $\hat{x}_k = \sum_{i=1}^N w_k^{+, (i)} x_k^{-, (i)}$
- 7 给定 w_k^+ , 独立抽取 $A_1, \dots, A_N$, 其中 $\mathbb{P}(A_j = i | w_k^+) = w_k^{+, (i)}$
- 8 $x_k^{+, (j)} \leftarrow x_k^{-, (A_j)}$, 新粒子权重均置为 $1/N, j = 1, \dots, N$
- 9 **end**

3.2 集合输运粒子滤波

Reich 的原始 ETPF^[36] 共享 BPF 的预测与权重更新, 通过离散最优输运替换随机重采样。令 $\mathbf{a} = \mathbf{w}_k^+$, $\mathbf{b} = \mathbf{1}_N/N$, $C_{ij} = \|x_k^{-, (i)} - x_k^{-, (j)}\|^2$, 求解线性规划

$$\mathbf{\Pi}_k \in \operatorname{argmin}_{\mathbf{\Pi} \in U(\mathbf{a}, \mathbf{b})} \langle \mathbf{\Pi}, \mathbf{C} \rangle_F. \quad (3-4)$$

目标槽位 j 的参考位置为 $x_k^{-, (j)}$ 。由于列和为 $1/N$, $N\Pi_{k;ij}$ 是该槽位对应的条件权重, 新粒子取其加权平均。

算法 3-2 ETPF: 最优输运与重心变换

输入: 与算法 3-1 相同的输入
输出: 后验均值估计 $\hat{x}_{1:T}$; 每轮变换后的等权粒子 $\{x_k^{+, (j)}\}_{j=1}^N$

- 1 独立采样 $x_0^{+, (i)} \sim p(x_0)$, 权重均为 $1/N, i = 1, \dots, N$
- 2 **for** $k = 1, \dots, T$ **do**
- 3 独立采样 $n_{x,k}^{(i)} \sim \mathbb{P}_{N_x}$, 令 $x_k^{-, (i)} = f(x_{k-1}^{+, (i)}, n_{x,k}^{(i)})$
- 4 读取 y_k , 计算 $g_k(x_k^{-, (i)}) = p_{Y_k|X_k}(y_k | x_k^{-, (i)})$
- 5 $w_k^{+, (i)} = \frac{g_k(x_k^{-, (i)})}{\sum_{r=1}^N g_k(x_k^{-, (r)})}, i = 1, \dots, N$
- 6 输出后验均值估计 $\hat{x}_k = \sum_{i=1}^N w_k^{+, (i)} x_k^{-, (i)}$
- 7 $\mathbf{a} \leftarrow \mathbf{w}_k^+, \mathbf{b} \leftarrow \mathbf{1}_N/N, C_{ij} \leftarrow \|x_k^{-, (i)} - x_k^{-, (j)}\|^2$
- 8 求解式 (3-4), 得到最优耦合 $\mathbf{\Pi}_k$
- 9 $x_k^{+, (j)} \leftarrow \sum_{i=1}^N \Pi_{k;ij} x_k^{-, (i)}$, 权重均置为 $1/N, j = 1, \dots, N$
- 10 **end**

熵正则化版本与基本 Sinkhorn 迭代 使用式 (2-28) 的熵正则化问题^[35] 近似上述线性规划, 将算法 3-2 中的耦合求解替换为算法 3-3, 再执行相同的重心变换。固定 $\varepsilon > 0$ 时得到的是正则化 ETPF, 与原始 ETPF 的输运目标有所不同。达到迭代上

限时仍可返回近似耦合, 其边际误差由 r 表示。

算法 3-3 基本 Sinkhorn 迭代: 求解正则化耦合

输入: 边际 $\mathbf{a}, \mathbf{b}$, 代价矩阵 $\mathbf{C}$, $\varepsilon > 0$, 容差 $\tau > 0$, 最大迭代次数 $L_{\max} \geq 1$
输出: 近似耦合 Π 、边际残差 r 及收敛标志 $r \leq \tau$

```

1  $K_{ij} \leftarrow \exp(-C_{ij}/\varepsilon), \mathbf{v} \leftarrow \mathbf{1}_N$ 
2 for  $\ell = 1, \dots, L_{\max}$  do
3    $\mathbf{u} \leftarrow \mathbf{a} \oslash (\mathbf{K}\mathbf{v})$ 
4    $\mathbf{v} \leftarrow \mathbf{b} \oslash (\mathbf{K}^T\mathbf{u})$ 
5    $\Pi \leftarrow \text{diag}(\mathbf{u})\mathbf{K}\text{diag}(\mathbf{v})$ 
6    $r \leftarrow \max\{\|\Pi\mathbf{1}_N - \mathbf{a}\|_1, \|\Pi^T\mathbf{1}_N - \mathbf{b}\|_1\}$ 
7   if  $r \leq \tau$  then
8     | 退出迭代
9   end
10 end
11 返回  $\Pi$ , 残差  $r$  与是否满足  $r \leq \tau$ 
    
```

3.3 均方误差的四项分解

令 $\mathcal{H} = L^2(\Omega, \mathcal{F}, \mathbb{P}; \mathbb{R}^{n_x})$, 概率空间包含真实系统与算法随机性。记 $\mathcal{Y}_k \subseteq \mathcal{H}$ 为所有关于 $\sigma(Y_{1:k})$ 可测的随机变量构成的闭子空间, $\mathcal{P}_{\mathcal{Y}_k} X_k$ 是利用全部历史观测的最优均方估计。本节记 $\hat{X}_k = X_k^+ \mathbf{1}_N / N$ 为重采样后均值; 算法 3-1 与 3-2 的在线输出 $X_k^- \mathbf{w}_k^+$ 是重采样前的加权均值。

定理 3.1 四项误差分解 假设所涉及随机变量平方可积, 算法随机源与真实系统独立。对每步使用新的随机数进行多项重采样的 BPF, 或满足精确边际约束的 ETPF, 有

$$\begin{aligned}
 & \|X_k - \hat{X}_k\|_{\mathcal{H}}^2 \\
 &= \underbrace{\|\mathcal{P}_{\mathcal{Y}_k}^\perp X_k\|_{\mathcal{H}}^2}_{\text{不可约 Bayes 误差}} + \underbrace{\|\mathcal{P}_{\mathcal{Y}_k}(X_k - X_k^- \mathbf{w}_k^+)\|_{\mathcal{H}}^2}_{\text{算法偏差平方}} \\
 &\quad + \underbrace{\|\mathcal{P}_{\mathcal{Y}_k}^\perp (X_k^- \mathbf{w}_k^+)\|_{\mathcal{H}}^2}_{\text{算法随机波动}} + \underbrace{\|X_k^- \mathbf{w}_k^+ - \hat{X}_k\|_{\mathcal{H}}^2}_{\text{当前重采样扰动}}.
 \end{aligned} \tag{3-5}$$

证明 令 $\mathcal{Z}_k$ 为截至当前的观测 $Y_{1:k}$ 与本步重采样前全部算法随机源生成的 L^2 子空间; 加权均值 $X_k^- \mathbf{w}_k^+$ 对相应的 σ 代数可测, 属于该子空间。随机源独立性给出 $\mathcal{P}_{\mathcal{Z}_k} X_k = \mathcal{P}_{\mathcal{Y}_k} X_k$; 重采样的条件无偏性给出 $\mathcal{P}_{\mathcal{Z}_k} \hat{X}_k = X_k^- \mathbf{w}_k^+$, ETPF 则逐次精确相等。当前重采样使用新的独立随机数, 故其扰动与 X_k 及 $\mathcal{Z}_k$ 正交。 $\square$

多项重采样 BPF 的最后一项可以直接计算:

$$\|X_k^- \mathbf{w}_k^+ - \hat{X}_k\|_{\mathcal{H}}^2 = \frac{1}{N} \sum_{i=1}^N \left\| \sqrt{w_k^{+, (i)}} (x_k^{-, (i)} - X_k^- \mathbf{w}_k^+) \right\|_{\mathcal{H}}^2. \quad (3-6)$$

ETPF 由 $\Pi_k \mathbf{1}_N = \mathbf{w}_k^+$ 得到 $X_k^+ \mathbf{1}_N / N = X_k^- \Pi_k \mathbf{1}_N = X_k^- \mathbf{w}_k^+$, 因此最后一项为零。

不过, 质心守恒并不能消除算法偏差与随机波动; 有限次 Sinkhorn 迭代的边界残差也可能破坏精确守恒。因而实际数值结果会与理想计算有所不同。

定理 3.2 零过程噪声下的粒子贫化 固定 $N \geq 2$, 预测为确定性映射, 每步权重有效且使用新的随机数进行多项重采样。固定合法观测记录, 记 $D_k := \#\{x_k^{+, (i)} : i = 1..N\}$, 则

$$1 \leq \mathbb{E}[D_k] \leq 1 + (N-1)(1 - N^{1-N})^k, \quad \lim_{k \rightarrow \infty} \mathbb{E}[D_k] = 1. \quad (3-7)$$

证明 确定性预测与复制使 D_k 不增, 单点状态为吸收态。每次全部选中同一祖先的条件概率为 $\sum_i (w_k^{+, (i)})^N \geq N^{1-N}$ 。因此 $\mathbb{P}(D_k > 1) \leq (1 - N^{1-N})^k$, 再由 $D_k - 1 \leq (N-1)\mathbb{I}_{\{D_k > 1\}}$ 得证。 $\square$

更多关于粒子谱系合并的相关结果见 Jacob、Murray 与 Rubenthaler 的研究^[37]; 式 (3-7) 是上面的直接估计。

第 4 章 仿真实验

本节先汇报 Gordon 基准冻结数据集上的滤波对照、参数消融与串行计时结果，再通过零过程噪声 Logistic 模型考察粒子贫化与误差分解；运行环境见表 4-1。

表 4-1 运行环境

项目	配置
CPU	AMD Ryzen 9 9955HX3D, 16 核 32 线程
系统可见内存	60.50 GiB
操作系统	Ubuntu 24.04.4 LTS
数值内核	C++17 / Eigen 3.4.0
数值精度	双精度

4.1 模型与实验简介

采用 Gordon 等的一维非线性基准^[1]，并按本实验设置选取初始分布：

$$\begin{aligned}
 X_k &= \frac{1}{2}X_{k-1} + \frac{25X_{k-1}}{1 + X_{k-1}^2} + 8 \cos(1.2(k-1)) + N_{x,k}, \\
 Y_k &= X_k^2/20 + N_{y,k}, \quad X_0 \sim \mathcal{N}(0, 2), \quad N_{x,k} \sim \mathcal{N}(0, 10), \quad N_{y,k} \sim \mathcal{N}(0, 1).
 \end{aligned} \tag{4-1}$$

高斯记号 $\mathcal{N}(\mu, \sigma^2)$ 的第二参数表示方差。状态每步演化，仅在 $k \in m\mathbb{N}$ 时提供观测， m 表示观测间隔。

本次仿真实验中，不同算法与间隔复用同一批冻结真值和全量观测。实验中的 BPF 采用系统重采样^[9]，ETPF 采用熵正则化输运；数值实现使用稳定化 Sinkhorn^[38] 与边际修正^[39]，表中的结果对应这些实现。对照方法包括扩展 Kalman 滤波 (EKF)^[31]、自举粒子滤波 (BPF)^[1]、集合 Kalman 滤波 (EnKF)^[17] 及熵正则化集合变换粒子滤波 (ETPF)^[35,36]。

本实验取 $B = 8$ 条轨迹，每条含 $K = 100$ 个状态步。记第 b 条轨迹的真值为 $x_k^{(b)}$ ，在线估计为 $\hat{x}_k^{+, (b)}$ ；缺测步取预测均值。定义

$$\begin{aligned}
 \text{RMSE}_k &= \sqrt{\frac{1}{B} \sum_{b=1}^B (\hat{x}_k^{+, (b)} - x_k^{(b)})^2}, \quad \text{RMSE} = \sqrt{\frac{1}{K} \sum_{k=1}^K \text{RMSE}_k^2}, \\
 S_X &= \sqrt{\frac{1}{BK} \sum_{b,k} (x_k^{(b)})^2}, \quad \text{NRMSE} = 100 \text{RMSE}/S_X (\%).
 \end{aligned} \tag{4-2}$$

EKF 最快但误差最大；BPF 在该设置下兼具较低误差与计算成本。ETPF 每步约 28.29 ms，远高于 BPF 的 38.01 μs 。

表 4-2 精度与串行计算开销, $m = 1, N = 500$, ETPF 取 $\varepsilon = 1$ 。时间为每条轨迹三次重复的中位数, 再对 8 条轨迹取均值 $\pm$ 样本标准差

算法	每步内核时间 $\downarrow$ (μs)	相对误差 $\downarrow$ (%)	未收敛率 $\downarrow$
EKF	0.104 $\pm$ 0.003	167.87	—
BPF	38.013 $\pm$ 0.100	43.83	—
EnKF	49.680 $\pm$ 0.125	48.32	—
ETPF	28293.091 $\pm$ 2576.275	44.43	23.13%


表 4-2 的未收敛率指 Sinkhorn 在 1000 次迭代内未达到边缘容差 10^{-8} 的观测更新次数占比, 收敛率为其补数。

4.2 时序误差分析

表 4-3 与图 4-1 显示, 本组数据中 BPF 与 ETPF 精度接近, EnKF 略差。

 表 4-3 全时域 RMSE $\downarrow$, 括号内为 NRMSE $\downarrow$ 。上下标为整条轨迹 bootstrap (1000 次) 所得 95% 区间相对中心值的偏移; 按未舍入值标粗每列最优。

算法	$m = 1$	$m = 2$	$m = 4$	$m = 8$
EKF	17.80 ^{+1.38} _{-1.74} (167.87%)	22.80 ^{+2.61} _{-3.26} (215.01%)	40.85 ^{+25.07} _{-24.81} (385.27%)	16.67 ^{+3.07} _{-3.19} (157.17%)
BPF	4.65 ^{+0.59} _{-0.58} (43.83 %)	6.44 ^{+0.59} _{-0.57} (60.76%)	7.46 ^{+0.22} _{-0.34} (70.34 %)	8.14 ^{+0.37} _{-0.45} (76.78%)
EnKF	5.12 ^{+0.61} _{-0.62} (48.32%)	6.71 ^{+0.65} _{-0.58} (63.26%)	7.94 ^{+0.31} _{-0.29} (74.85%)	8.39 ^{+0.23} _{-0.26} (79.16%)
ETPF	4.71 ^{+0.66} _{-0.66} (44.43%)	6.41 ^{+0.56} _{-0.56} (60.43 %)	7.50 ^{+0.22} _{-0.36} (70.76%)	8.14 ^{+0.35} _{-0.45} (76.76 %)


 图 4-1 逐时刻跨轨迹 RMSE, $N = 500, \varepsilon = 1$ 。各子图采用相同对数纵轴。




图 4-2 首条轨迹的状态与观测， $m = 1$ ；下图对照 y_k 与 $x_k^2/20$ 。

4.3 粒子数，正则强度与计算开销




图 4-3 单因素切片均取 $m = 1$ 。(a) 固定 $\varepsilon = 1$ 比较 N ；(b) 比较 ETPF 的 ε ；(c) 相同冻结数据上的串行单核每步内核耗时，对 ETPF 固定 $\varepsilon = 1$ 。

在所测试的三个粒子数量下，BPF 的 RMSE 随 N 增大而下降；固定 $\varepsilon = 1$ 时，ETPF 的 RMSE 未呈严格单调下降。该现象限于本组有限轨迹与参数设置，尚不能据此判断两者相对 Bayes 最优估计的渐近差距。在本次消融范围内，正则化强度 ε 对相对误差的影响较小，其选择仍需结合计算开销和收敛情况。




图 4-4 首条轨迹的后验密度估计， $m = 1, N = 500, \varepsilon = 1$ 。

图 4-4 中， $k = 11$ 时 BPF 与 ETPF 均呈双峰，而 EKF 的高斯近似仅保留单峰。 $k = 21$ 时各估计的主峰位置接近，但峰宽仍有差异。在上述 Gordon 基准及当前参数设置下，ETPF 继承了 PF 的非高斯表示能力，但更高的计算开销未带来明显精度优势。

4.4 零过程噪声 Logistic 模型：粒子贫化与稳健性

考虑确定性混沌状态演化与非线性观测：

$$\begin{aligned} X_k &= 4X_{k-1}(1 - X_{k-1}), \quad X_k \in [0, 1], \\ Y_k &= h(X_k) + N_{y,k}, \quad h(x) = x^2, \quad X_0 \sim U[0, 1], \quad N_{y,k} \sim \mathcal{N}(0, 0.1). \end{aligned} \quad (4-3)$$

每步均有观测，取 $N = 128$ ，共 64 条独立观测路径，每条 1000 步，每条路径独立运行算法 32 次。观测噪声方差为 0.1；BPF 采用每步多项重采样，ETPF 采用一维无正则最优输运。不同粒子位置数按双精度数值精确去重统计。

图 4-5 比较两种算法的误差与粒子多样性，四项误差统计见表 4-4。

表 4-4 Logistic 模型的四项误差与实测总 MSE，第 1-1000 步平均。

误差项	BPF	ETPF
不可约 Bayes 误差	0.048755	0.048755
算法偏差平方	0.075192	0.002376
算法随机波动	0.123494	0.021038
当前重采样扰动	4.48×10^{-6}	5.03×10^{-31}
实测总 MSE	0.247544	0.072128

表4-4评估了重采样后均值 $\hat{X}_k = X_k^* \mathbf{1}_N / N$ ，四项对应式 (3-5)。理论分解是总体期望恒等式；表中各项为有限路径与重复运行的估计，Bayes 风险由数值参考后验近似，因此，四项之和与实测总 MSE 未必逐位相等。




图 4-5 同一批运行的误差与粒子多样性。(a) 每 20 步分段平均的 MSE 与 Bayes 参考风险；(b) 重采样后不同位置数的跨运行平均，横轴取对数以显示早期贫化。

BPF 的 2048 次运行均贫化为单点；ETPF 在这批运行中没有单点贫化，末步平均保留 69.67 个不同位置，总 MSE 较 BPF 降低 70.9%。这说明 ETPF 在本例中对无过程噪声下的粒子贫化更稳健。

第 5 章 后续研究安排与可行性分析

5.1 后期拟完成的研究工作及进度安排

后续研究拟在现有理论整理与基线实验的基础上，围绕神经网络与非线性滤波的结合，分两个阶段推进：

(1) **2026 年 9–10 月：文献学习与理论总结。**学习神经网络相关的滤波论文，重点梳理网络在状态预测、后验更新及输运映射中的作用，分析模型假设、优化目标与算法步骤。总结代表性方法的数学原理、适用条件和局限性，形成文献笔记与算法对照，为后续设计确定研究切入点。

(2) **2026 年 11–12 月：仿真环境选择与算法验证。**根据前期分析筛选合适的仿真环境，明确状态转移、观测模型、噪声设置与评价指标。针对选定问题设计并实现相应的滤波算法，开展必要的训练、基线对比与消融实验，分析估计精度、计算成本和稳定性，形成“问题建模—算法设计—仿真验证—结果分析与改进”的研究闭环。

5.2 存在问题、困难及其解决方案

当前的主要困难是，需要在有限时间内深入理解神经网络与非线性滤波相关内容，并将其沉淀为准确、系统且可复用的知识库资料。针对学习与整理耗时较长、实际进度存在不确定性的问题，拟采取以下措施：

(1) **精读文献与独立思考** 围绕核心论文反复阅读、独立推导，重点核对模型假设、数学原理与算法逻辑，对尚未理解的问题持续追踪，逐步深化认识。

(2) **结构化整理与知识复用** 按研究问题、模型假设、推导过程和算法步骤整理知识条目，保留文献出处及适用条件，通过复核与修订形成可供后续研究使用的资料。

(3) **量化记录与进度调整** 坚持每日制定计划和总结复盘，记录有效工作时长、疲劳程度自评及可核查成果。依据实际完成情况调整任务优先级与工作量，为难点理解和反复验证预留时间，合理估计阶段进度。

5.3 如期完成全部论文工作的可能性

从已有基础看，目前已完成非线性滤波与最优输运的基础理论整理、代表性算法实现及初步对照实验，形成了可供后续研究使用的推导资料、程序与评价基线。这些工作为进一步学习神经网络滤波方法、选择研究问题和验证算法提供了基础，有助于减少重复准备工作。

从后续安排看，9-10月以文献学习和数学原理总结为重点，11-12月围绕选定的仿真环境开展算法设计与实验验证，前后阶段具有明确的衔接关系。研究过程中同步整理文献综述、方法推导与实验分析，逐步形成论文内容，避免将资料整理和论文撰写全部集中于研究末期。

主要风险仍在于理论理解、算法调试和实验分析所需时间存在不确定性。为此，拟将研究范围限定于能够充分分析和验证的具体问题，依据每日记录与阶段总结评估实际进展，优先完成支撑论文核心论证的工作，并为结果复核和论文修改预留时间。若实验效果未达预期，应及时分析原因与适用边界，调整技术方案，避免在缺乏证据支持的方向上持续投入。

综合而言，现有工作已具备继续推进的基础；在合理控制研究范围、落实阶段目标并根据实际进展及时调整安排的前提下，如期完成全部论文工作具有可行性。

结 论

〔待补充〕原中期报告未包含毕业论文的最终结论。阶段性研究结果已保留在正文中；请在后续研究完成后，总结最终结论、创新点与局限。

人工智能使用声明

为透明说明工具使用情况，我们披露大语言模型（LLM）在本文稿准备过程中发挥了重要作用。作者对所有内容承担全部责任，包括这些模型生成的任何文本，并已仔细审阅和编辑所有输出，以保证准确性、原创性和科学完整性。

使用的模型包括: GPT 6, Gemini 3.8 flash。其中，GPT 6 主要用于文献综述调研与算法仿真。其余模型用于辅助审核论文结果，理解相关概念和术语。

参考文献

- [1] Gordon N J, Salmond D J, Smith A F M. Novel approach to nonlinear/non-Gaussian Bayesian state estimation[J]. IEE Proceedings F (Radar and Signal Processing), 1993, 140(2): 107-113. DOI: 10.1049/ip-f-2.1993.0015.
- [2] Kong A, Liu J S, Wong W H. Sequential imputations and Bayesian missing data problems[J]. Journal of the American statistical association, 1994, 89(425): 278-288.
- [3] Kitagawa G. Monte Carlo filter and smoother for non-Gaussian nonlinear state space models[J]. Journal of computational and graphical statistics, 1996, 5(1): 1-25.
- [4] Isard M, Blake A. Condensation—conditional density propagation for visual tracking[J]. International journal of computer vision, 1998, 29(1): 5-28.
- [5] Liu J S, Chen R. Sequential Monte Carlo methods for dynamic systems[J]. Journal of the American statistical association, 1998, 93(443): 1032-1044.
- [6] Pitt M K, Shephard N. Filtering via simulation: Auxiliary particle filters[J]. Journal of the American statistical association, 1999, 94(446): 590-599.
- [7] van der Merwe R, Doucet A, de Freitas N, et al. The unscented particle filter[C] // Advances in Neural Information Processing Systems: Vol 13. 2000.
- [8] Julier S J, Uhlmann J K. New extension of the Kalman filter to nonlinear systems[C] // Signal processing, sensor fusion, and target recognition VI: Vol 3068. 1997: 182-193.
- [9] Doucet A, De Freitas N, Gordon N J, et al. Sequential Monte Carlo methods in practice: Vol 1[M]. New York: Springer, 2001.
- [10] Montemerlo M, Thrun S, Koller D, et al. FastSLAM: A factored solution to the simultaneous localization and mapping problem[C] // Proceedings of the Eighteenth National Conference on Artificial Intelligence. 2002: 593-598.
- [11] Gilks W R, Berzuini C. Following a moving target—Monte Carlo inference for dynamic Bayesian models[J]. Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2001, 63(1): 127-146.
- [12] Doucet A, Briers M, Sénécal S. Efficient block sampling strategies for sequential Monte Carlo methods[J]. Journal of Computational and Graphical Statistics, 2006, 15(3): 693-711.

- [13] Li Y, Coates M. Particle filtering with invertible particle flow[J]. IEEE Transactions on Signal Processing, 2017, 65(15) : 4102-4116.
- [14] Musso C, Oudjane N, Le Gland F. Improving regularised particle filters[G] // Sequential Monte Carlo methods in practice. New York : Springer, 2001 : 247-271.
- [15] Chang C, Ansari R. Kernel particle filter for visual tracking[J]. IEEE signal processing letters, 2005, 12(3) : 242-245.
- [16] El Moselhy T A, Marzouk Y M. Bayesian inference with optimal maps[J]. Journal of Computational Physics, 2012, 231(23) : 7815-7850.
- [17] Evensen G. The ensemble Kalman filter: Theoretical formulation and practical implementation[J]. Ocean dynamics, 2003, 53(4) : 343-367.
- [18] Peyré G, Cuturi M. Computational optimal transport: With applications to data science[J]. Foundations and Trends® in Machine Learning, 2019, 11(5-6) : 355-607.
- [19] Corenflos A, Thornton J, Deligiannidis G, et al. Differentiable particle filtering via entropy-regularized optimal transport[C] // International Conference on Machine Learning. 2021 : 2100-2111.
- [20] Al-Jarrah M, Jin N, Hosseini B, et al. Nonlinear filtering with Brenier optimal transport maps[C] // Proceedings of Machine Learning Research, Vol 235 : Proceedings of the 41st International Conference on Machine Learning. 2024 : 813-839.
- [21] Krishnan R G, Shalit U, Sontag D. Deep Kalman filters[EB/OL]. arXiv, 2015 (2015-11-25) [2026-09-15]. <https://arxiv.org/abs/1511.05121>.
- [22] Gu S, Ghahramani Z, Turner R E. Neural adaptive sequential Monte Carlo[C] // Advances in Neural Information Processing Systems : Vol 28. 2015.
- [23] Karl M, Soelch M, Bayer J, et al. Deep variational Bayes filters: Unsupervised learning of state space models from raw data[C/OL] // International Conference on Learning Representations. 2017 [2026-09-15]. <https://openreview.net/forum?id=HyTqHL5xg>.
- [24] Krishnan R, Shalit U, Sontag D. Structured inference networks for nonlinear state space models[C] // Proceedings of the AAAI conference on artificial intelligence : Vol 31. 2017.
- [25] Hafner D, Lillicrap T, Fischer I, et al. Learning latent dynamics for planning from pixels[C] // International conference on machine learning. 2019 : 2555-2565.

- [26] Revach G, Shlezinger N, Ni X, et al. KalmanNet: Neural network aided Kalman filtering for partially known dynamics[J]. IEEE Transactions on Signal Processing, 2022, 70 : 1532-1547.
- [27] Greenberg I, Yannay N, Mannor S. Optimization or architecture: How to hack Kalman filtering[C] //Advances in Neural Information Processing Systems : Vol 36. 2023 : 50482-50505.
- [28] Liu S, Cao W, Liu C, et al. One Filters All: A Generalist Filter for State Estimation[C] // Advances in Neural Information Processing Systems. 2025.
- [29] Xiao P, Si P, Chen P. LD-EnSF: Synergizing Latent Dynamics with Ensemble Score Filters for Fast Data Assimilation with Sparse Observations[C] //International Conference on Learning Representations. 2026.
- [30] Stöckl C, Yang Y, Maass W. Local prediction-learning in high-dimensional spaces enables neural networks to plan[J]. Nature Communications, 2024, 15(1): 2344.
- [31] Bar-Shalom Y, Li X R, Kirubarajan T. Estimation with applications to tracking and navigation: theory algorithms and software[M]. New York : John Wiley & Sons, 2001.
- [32] 李天成, 范红旗, 孙树栋. 粒子滤波理论、方法及其在多目标跟踪中的应用[J]. 自动化学报, 2015, 41(12): 1981-2002. DOI: 10.16383/j.aas.2015.c150426.
- [33] Villani C. Grundlehren der mathematischen Wissenschaften, Vol 338 : Optimal Transport: Old and New[M]. Berlin : Springer, 2009.
- [34] 马丽涛, 边伟. 最优传输理论在图像处理中的应用[J]. 运筹学学报, 2019, 23(3): 109-125. DOI: 10.15960/j.cnki.issn.1007-6093.2019.03.008.
- [35] Cuturi M. Sinkhorn distances: Lightspeed computation of optimal transport[C] // Advances in Neural Information Processing Systems : Vol 26. 2013 : 2292-2300.
- [36] Reich S. A nonparametric ensemble transform method for Bayesian inference[J]. SIAM Journal on Scientific Computing, 2013, 35(4): A2013-A2024.
- [37] Jacob P E, Murray L M, Rubenthaler S. Path storage in the particle filter[J]. Statistics and Computing, 2015, 25 : 487-496. DOI: 10.1007/s11222-013-9445-x.
- [38] Schmitzer B. Stabilized Sparse Scaling Algorithms for Entropy Regularized Transport Problems[J]. SIAM Journal on Scientific Computing, 2019, 41(3): A1443-A1481. DOI: 10.1137/16M1106018.
- [39] Altschuler J, Weed J, Rigollet P. Near-linear time approximation algorithms for optimal transport via Sinkhorn iteration[C/OL] // Advances in Neural Information Processing Systems : Vol 30. 2017 [2026-09-08]. https://papers.nips.cc/paper_files/paper/2017/hash/491442df5f88c6aa018e86dac21d3606-Abstract.html.

附录 A 补充理论与证明

A.1 符号定义与说明

概率单纯形与全一向量：对正整数 n , $\mathbb{R}_+ = [0, \infty)$, 定义

$$\Delta^{n-1} := \left\{ \mathbf{w} \in \mathbb{R}_+^n : \sum_{i=1}^n w_i = 1 \right\}, \quad \mathbf{1}_n := (1, \dots, 1)^T.$$

Δ^{n-1} 是 n 个概率权重组成的集合, 上标表示其维数; 允许零权重, 严格正权重需另行说明。

Dirac 测度与示性函数：对 $x \in \mathcal{S}$ 和可测集合 $A \subseteq \mathcal{S}$,

$$\delta_x(A) := \mathbb{I}_A(x) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A, \end{cases} \quad \int_{\mathcal{S}} f(s) d\delta_x(s) = f(x).$$

δ_x 是集中于 x 的概率测度, 与表示概率单纯形的大写 Δ 不同。

概率测度与经验测度： $\mathcal{B}(\mathcal{S})$ 表示 Borel 集合族, $\mathcal{M}(\mathcal{S})$ 表示其上的全体测度; 概率测度全体记为 $\mathcal{M}_+^1(\mathcal{S}) := \{\mu \in \mathcal{M}(\mathcal{S}) : \mu \geq 0, \mu(\mathcal{S}) = 1\}$ 。对 $\mathbf{w} \in \Delta^{N-1}$,

$$\langle \mathbf{w}, \delta_{x_{1..N}} \rangle := \sum_{i=1}^N w_i \delta_{x_i}, \quad \hat{\mathbb{P}}_{N, \mathbf{w}; X} := \sum_{i=1}^N w_i \delta_{x_i}, \quad \hat{\mathbb{P}}_{N; X} := \frac{1}{N} \sum_{i=1}^N \delta_{x_i}.$$

这里 x_i 是样本实现值; 权重与测度族的尖括号表示线性组合, 其结果仍为测度。

样本排列与滤波阶段： $X_i \in \mathbb{R}^{d \times 1}$ 为样本列向量,

$$X_{1..N} := (X_1, \dots, X_N) \in \mathbb{R}^{d \times N}, \quad \mathbb{P}_{X_{1..N}} \text{ 为该样本族的联合分布.}$$

上标 $-$ 、 $+$ 分别表示预测、后验阶段。位置变换中的 X_k 表示按列拼接的粒子矩阵, 每列是一个 n_x 维粒子:

$$X_k := x_k^{(1..N)} := [x_k^{(1)}, \dots, x_k^{(N)}] \in \mathbb{R}^{n_x \times N}, \\ X_k^\pm := x_k^{\pm, (1..N)} \in \mathbb{R}^{n_x \times N}.$$

$(T_k)_{ij}$ 表示源粒子 i 对目标粒子 j 的贡献系数, 故 $X_k^+ = X_k^- T_k$, $T_k = N \Pi_k$ 。概率分布下标中的 X_k 仍表示状态随机变量, 由上下文区分。

推前、拉回与对偶配对：对可测映射 $T : \mathcal{X} \rightarrow \mathcal{Y}$,

$$(T_* \mu)(B) := \mu(T^{-1}(B)), \quad T^* f := f \circ T, \\ \langle f, \mu \rangle_{\mathcal{S}} := \int_{\mathcal{S}} f(s) d\mu(s), \quad \langle f, T_* \mu \rangle_{\mathcal{Y}} = \langle T^* f, \mu \rangle_{\mathcal{X}}.$$

其中 $B \in \mathcal{B}(\mathcal{Y})$, 积分对有界可测或相应可积函数使用。 π_i 表示取第 i 个分量的坐标投影, $\mathbb{P}_X = X_*\mathbb{P}$ 。

联合概率矩阵与条件概率矩阵: 在正质量离散支撑上, 记

$$\begin{aligned} a_i &:= \mathbb{P}_X(\{x_i\}), & b_j &:= \mathbb{P}_Y(\{y_j\}), & \Pi_{ij} &:= \mathbb{P}_{(X,Y)}(\{(x_i, y_j)\}), \\ P_{Y|X;i,j} &:= \mathbb{P}_{Y|X=x_i}(\{y_j\}) = \Pi_{ij}/a_i, & P_{X|Y;j,i} &:= \mathbb{P}_{X|Y=y_j}(\{x_i\}) = \Pi_{ij}/b_j. \end{aligned}$$

条件矩阵的行标识条件变量, 列标识被条件化变量; Π 是联合概率矩阵。 $\Pi(\mathbb{P}_X, \mathbb{P}_Y)$ 表示具有指定边缘的耦合测度集合, $U(\mathbf{a}, \mathbf{b})$ 为其离散矩阵表示, 见式 (2-19)、(2-25)。

代价矩阵与矩阵运算: $C_{ij} := c(x_i, y_j)$, $\mathbf{C} = (C_{ij})$; $\langle \mathbf{A}, \mathbf{B} \rangle_F := \sum_{i,j} A_{ij} B_{ij}$ 为实矩阵的 Frobenius 内积。 $\text{diag}(\mathbf{u})$ 将向量放在矩阵对角线上, $\odot$ 、 $\oslash$ 表示逐元素乘、除, $\|\mathbf{z}\|_1 := \sum_i |z_i|$, $\|\mathbf{z}\|$ 表示欧氏范数。

乘积与正则化: $\mu \otimes \nu$ 表示乘积测度, $\mu \ltimes K$ 表示由边缘测度与条件转移核构成的半直积测度, $\otimes_k$ 表示矩阵 Kronecker 积。 $D_{\text{KL}}(\mu \parallel \nu) := \int \log(d\mu/d\nu) d\mu$ ($\mu \ll \nu$ 时), 否则为 $+\infty$; $\varepsilon > 0$ 为熵正则化参数, $\tau > 0$ 为边缘残差容差。

A.2 无记忆性引理的离散情形证明

证明 (引理 2.1 的证明 (离散情形)) 沿用引理 2.1 的模型与独立性条件, 设 X_0 和各噪声取有限或可数个值, p 表示相对于计数测度的概率质量函数。以下仅考虑概率为正的条件取值, 求和遍历相应噪声的所有可能取值。

由递推关系, $(X_{0:k-1}, Y_{1:k-1})$ 是 $(X_0, N_{x,1:k-1}, N_{y,1:k-1})$ 的函数, 因此与 $N_{x,k}$ 独立。固定历史取值后, $X_{k-1} = x_{k-1}$, 先按噪声取值分解, 再依次使用 $X_k = f(X_{k-1}, N_{x,k})$ 与噪声独立性:

$$\begin{aligned} & p_{X_k|X_{0:k-1}, Y_{1:k-1}}(x_k \mid x_{0:k-1}, y_{1:k-1}) \\ &= \sum_n p_{(X_k, N_{x,k})|X_{0:k-1}, Y_{1:k-1}}(x_k, n \mid x_{0:k-1}, y_{1:k-1}) \\ &= \sum_n \mathbb{I}_{\{f(x_{k-1}, n) = x_k\}} p_{N_{x,k}|X_{0:k-1}, Y_{1:k-1}}(n \mid x_{0:k-1}, y_{1:k-1}) \\ &= \sum_n \mathbb{I}_{\{f(x_{k-1}, n) = x_k\}} p_{N_{x,k}}(n) \\ &= p_{X_k|X_{k-1}}(x_k \mid x_{k-1}). \end{aligned}$$

最后一步同样利用 $N_{x,k}$ 与 X_{k-1} 独立, 故只给定 X_{k-1} 时得到相同的求和式。

同理, $(X_{0:k}, Y_{1:k-1})$ 是 $(X_0, N_{x,1:k}, N_{y,1:k-1})$ 的函数, 因此与 $N_{y,k}$ 独立。由 $Y_k = h(X_k, N_{y,k})$ 得

$$\begin{aligned}
 & p_{Y_k|X_{0:k}, Y_{1:k-1}}(y_k | x_{0:k}, y_{1:k-1}) \\
 &= \sum_n \mathbb{I}_{\{h(x_k, n)=y_k\}} p_{N_{y,k}}(n) \\
 &= p_{Y_k|X_k}(y_k | x_k).
 \end{aligned}$$

这里最后一步利用 $N_{y,k}$ 与 X_k 独立。 $k=1$ 时将历史观测视为空，即得引理的两个等式。

一般情形对任意 Borel 集合写条件概率，将上述求和替换为对噪声分布的积分，即得相同的条件分布等式；在正文的密度存在假设下，进一步得到几乎处处成立的密度等式。□

A.3 Bayes 更新公式的证明

定理 A.1 Bayes 更新公式 在本文约定与模型条件下，对 $k \geq 1$ ，给定历史观测 $y_{1:k-1}$ 并收到当前观测 y_k 后，状态后验密度满足

$$\begin{aligned}
 & p_{X_k|Y_{1:k}}(x_k | y_{1:k}) \\
 &= \frac{p_{Y_k|X_k}(y_k | x_k) p_{X_k|Y_{1:k-1}}(x_k | y_{1:k-1})}{\int_{\mathcal{X}} p_{Y_k|X_k}(y_k | x) p_{X_k|Y_{1:k-1}}(x | y_{1:k-1}) dv_X(x)}. \tag{A-1}
 \end{aligned}$$

证明 先固定历史观测 $y_{1:k-1}$ 。收到 y_k 后，要求的是在这些历史观测的基础上，再给定 $Y_k = y_k$ 时的状态密度。按条件密度公式，将条件联合密度除以新观测的条件边缘密度：

$$\begin{aligned}
 & p_{X_k|Y_{1:k}}(x_k | y_{1:k}) \\
 &= \frac{p_{(X_k, Y_k)|Y_{1:k-1}}(x_k, y_k | y_{1:k-1})}{p_{Y_k|Y_{1:k-1}}(y_k | y_{1:k-1})}. \tag{A-2}
 \end{aligned}$$

对分子使用密度的乘法公式，按“先取状态，再给定状态取观测”的顺序分解。两个因子都保留历史观测条件，其中状态因子正是预测步骤已求得的密度：

$$\begin{aligned}
 & p_{(X_k, Y_k)|Y_{1:k-1}}(x_k, y_k | y_{1:k-1}) \\
 &= p_{Y_k|X_k, Y_{1:k-1}}(y_k | x_k, y_{1:k-1}) p_{X_k|Y_{1:k-1}}(x_k | y_{1:k-1}). \tag{A-3}
 \end{aligned}$$

将这一分解代入上一式，就是以历史观测为条件的 Bayes 公式。

接着应用无记忆性引理中的观测条件独立性。给定当前状态 X_k 后，历史观测不再影响 Y_k 的条件分布，因此观测因子可以直接使用模型给出的似然：

$$p_{Y_k|X_k, Y_{1:k-1}}(y_k | x_k, y_{1:k-1}) = p_{Y_k|X_k}(y_k | x_k). \tag{A-4}$$

这里仅消去了观测因子中的历史条件，预测密度仍依赖历史观测。

分母由条件联合密度对状态变量积分得到，这是条件全概率公式。再代入上面的乘法分解与条件独立关系，就将观测的预测密度写成似然关于状态预测分布的平均：

$$\begin{aligned} & p_{Y_k|Y_{1:k-1}}(y_k | y_{1:k-1}) \\ &= \int_{\mathcal{X}} p_{(X_k, Y_k)|Y_{1:k-1}}(x, y_k | y_{1:k-1}) d\nu_X(x) \\ &= \int_{\mathcal{X}} p_{Y_k|X_k}(y_k | x) p_{X_k|Y_{1:k-1}}(x | y_{1:k-1}) d\nu_X(x). \end{aligned} \quad (\text{A-5})$$

其中 x 是积分变量，覆盖整个状态空间。按前述条件，这个分母有限且严格为正，可以用于归一化。

最后，将得到的分子与分母代回最初的条件密度公式，即得定理中的更新式。分母是似然加权后预测密度的总积分，因此相除后得到积分为 1 的后验密度。 $\square$

A.4 离散 Monge 映射的存在条件

原子质量守恒： 设 $x_1, \dots, x_m$ 各自互异， $y_1, \dots, y_n$ 各自互异， $a_i, b_j > 0$ 。若 $T_*\mathbb{P}_X = \mathbb{P}_Y$ ，则

$$\begin{aligned} b_j &= \mathbb{E}_{Y \sim \mathbb{P}_Y} [\mathbb{I}_{\{y_j\}}(Y)] = \mathbb{E}_{X \sim \mathbb{P}_X} [\mathbb{I}_{\{y_j\}}(T(X))] \\ &= \int_{\mathcal{X}} \mathbb{I}_{\{y_j\}}(T(x)) d\left(\sum_{i=1}^m a_i \delta_{x_i}\right)(x) = \sum_{\{i: T(x_i)=y_j\}} a_i. \end{aligned} \quad (\text{A-6})$$

每个正质量源点必然映入目标支撑，因为

$$\mathbb{P}_Y(\{T(x_i)\}) = \mathbb{P}_X(T^{-1}(\{T(x_i)\})) \geq a_i > 0. \quad (\text{A-7})$$

因此其条件概率矩阵为逐行单点选择，联合概率矩阵则带有源权重：

$$P_{Y|X;i,j} = \mathbb{I}_{\{y_j\}}(T(x_i)) \in \{0, 1\}, \quad \sum_{j=1}^n P_{Y|X;i,j} = \delta_{T(x_i)}\left(\bigcup_{j=1}^n \{y_j\}\right) = 1, \quad (\text{A-8})$$

$$P_{Y|X} \mathbf{1}_n = \mathbf{1}_m, \quad P_{Y|X}^T \mathbf{a} = \mathbf{b}, \quad \mathbf{\Pi} = \text{diag}(\mathbf{a}) P_{Y|X}.$$

同一质量关系也可以完全用推前与拉回对偶表达：

$$\begin{aligned} b_j &= \langle \mathbb{I}_{\{y_j\}}, \mathbb{P}_Y \rangle_{\mathcal{Y}} = \langle \mathbb{I}_{\{y_j\}}, T_*\mathbb{P}_X \rangle_{\mathcal{Y}} = \langle T^*\mathbb{I}_{\{y_j\}}, \mathbb{P}_X \rangle_{\mathcal{X}} \\ &= \langle T^*\mathbb{I}_{\{y_j\}}, \langle \mathbf{a}, \delta_{x_{1..m}} \rangle \rangle_{\mathcal{X}} = \sum_{i=1}^m a_i P_{Y|X;i,j}. \end{aligned} \quad (\text{A-9})$$

定理 A.2 均匀离散分布的整除条件 设源、目标分布分别均匀分布于 m 个与 n 个互异支撑点。存在可测映射 T 满足 $T_*\mathbb{P}_X = \mathbb{P}_Y$ ，当且仅当 $n \mid m$ 。

证明 必要性：由式 (A-6)，每个目标点的原像必须含有 m/n 个源点：

$$\frac{1}{n} = \frac{1}{m} \#\{i : T(x_i) = y_j\} \implies \frac{m}{n} \in \mathbb{N}. \quad (\text{A-10})$$

充分性：若 $m = nq$ ，将每 q 个源点分配给一个目标点。用 Kronecker 积写为

$$\begin{aligned} \mathbf{P}_{Y|X} &= \mathbf{I}_n \otimes_k \mathbf{1}_q \in \{0, 1\}^{m \times n}, \quad \mathbf{\Pi} = \frac{1}{m} \mathbf{P}_{Y|X}, \\ \mathbf{P}_{Y|X} \mathbf{1}_n &= (\mathbf{I}_n \otimes_k \mathbf{1}_q)(\mathbf{1}_n \otimes_k 1) = \mathbf{1}_n \otimes_k \mathbf{1}_q = \mathbf{1}_m, \\ \mathbf{P}_{Y|X}^T \frac{\mathbf{1}_m}{m} &= \frac{(\mathbf{I}_n \otimes_k \mathbf{1}_q^T)(\mathbf{1}_n \otimes_k \mathbf{1}_q)}{m} = \frac{q}{m} \mathbf{1}_n = \frac{1}{n} \mathbf{1}_n. \end{aligned} \quad (\text{A-11})$$

以矩阵每行的唯一非零元素确定 $T(x_i)$ ，并在有限源支撑之外任取常值延拓，即得到所需可测映射。 $\square$

攻读硕士学位期间取得创新性成果

[待补充] 原中期报告未包含成果清单，请按实际情况填写。

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《联合优化下的非线性滤波：神经网络与输运方法》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：

日期： 年 月 日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

(1) 学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；(2) 学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；(3) 研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：

日期： 年 月 日

导师签名：

日期： 年 月 日

致 谢

[待补充] 原中期报告未包含致谢，请按实际情况填写。

个人简历

[待补充] 原中期报告未包含个人简历，请按实际情况填写。