

关于用于贝叶斯滤波的序贯蒙特卡洛采样方法

ARNAUD DOUCET、SIMON GODSILL 和 CHRISTOPHE ANDRIEU

University of Cambridge 工程系信号处理组,

Trumpington Street, CB2 1PZ Cambridge, UK

ad2@eng.cam.ac.uk, sjg@eng.cam.ac.uk, ca226@eng.cam.ac.uk

1998 年 7 月收到, 1999 年 8 月接受

摘要

本文概述了从后验分布进行序贯模拟的方法。对于通常具有非线性、非高斯特征的离散时间动态模型, 这些方法在贝叶斯滤波中尤其重要。本文建立了一个通用的重要性采样框架, 将过去几十年间多个不同科学领域所提出的许多方法统一起来。本文还提出了对现有方法的新扩展。特别地, 我们说明了如何引入与确定性滤波文献中既有方法相似的局部线性化方法; 这些方法可以得到非常有效的重要性分布。此外, 我们还介绍了一种使用 Rao-Blackwellisation 的方法, 以利用若干重要状态空间模型类别中存在的解析结构。在最后一节中, 我们为动态模型中的预测、平滑以及似然评估设计了相应算法。

关键词: 贝叶斯滤波, 非线性非高斯状态空间模型, 序贯蒙特卡洛方法, 粒子滤波, 重要性采样, Rao-Blackwellised 估计

0960-3174 © 2000 Kluwer Academic Publishers

1 引言

应用统计、统计信号处理、时间序列分析和计量经济学中的许多问题都可以表示为如下状态空间形式。状态转移方程描述隐 Markov 过程 $\{\mathbf{x}_k; k \in \mathbb{N}\}$ 的先验分布, 该过程称为隐状态过程; 观测方程描述观测 $\{\mathbf{y}_k; k \in \mathbb{N}\}$ 的似然, 其中 k 是离散时间下标。在贝叶斯框架下, 给定截至并包括时刻 k 的观测, 关于 $\{\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_k\}$ 的全部相关信息都可以从后验分布 $p(\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_k \mid \mathbf{y}_0, \mathbf{y}_1, \dots, \mathbf{y}_k)$ 获得。在许多应用中, 我们关心的是随时间递归估计该分布, 特别是它的一个边缘分布, 即所谓的滤波分布 $p(\mathbf{x}_k \mid \mathbf{y}_0, \mathbf{y}_1, \dots, \mathbf{y}_k)$ 。给定滤波分布以后, 便可以常规地得到滤波点估计, 例如状态的后验众数或后验均值。这一问题称为贝叶斯滤波问题或最优滤波问题。实际应用包括目标跟踪 [1]、数字通信信道的盲反卷积 [2,3]、随机波动率估计 [4], 以及语音和音频信号的数字增强 [5]。

除少数特殊情形外, 包括线性高斯状态空间模型 (Kalman 滤波器) 和隐有限状态空间 Markov 链, 这些分布无法进行解析计算。自 20 世纪 60 年代中期以来, 人们投入了大量精力来近似这些

滤波分布，例如可参见 [6]。最常用的算法，即扩展 Kalman 滤波器和高斯和滤波器，依赖解析近似 [7]。20 世纪 60 年代和 70 年代，自动控制领域曾采用序贯 Monte Carlo (MC) 积分方法开展了一些颇有意义的工作，参见文献 [8,9,10,11]。可能由于当时计算能力的严重限制，这些 Monte Carlo 算法在近年来以前一直基本未受重视。20 世纪 80 年代后期，计算能力的大幅提升使得用于贝叶斯滤波的数值积分方法重新兴起 [12]。当前研究已转向 MC 积分方法；这类方法具有一项重要优点，即不受模型线性或高斯性假设的约束。相关工作包括文献 [1,13,14,15,16]。

本文的主要目标，是将多个应用科学领域中彼此独立提出的许多早期和近期算法纳入一个统一框架。相关研究 [16,17,18] 均强调了序贯重要性采样在贝叶斯滤波中的核心作用。不过，与文献 [16] 所强调的把重要性采样与 Markov Chain Monte Carlo (MCMC) 元素结合起来的混合方案不同，本文关注计算代价更低的替代方案。我们还说明了如何利用 Rao-Blackwellisation，针对一类有用的动态模型改进当前已有的方法。最后，我们说明如何扩展这些方法，以计算预测分布、固定区间平滑分布以及似然。

本文其余部分组织如下。第 2 节简要回顾贝叶斯滤波问题，并提出使用经典贝叶斯重要性采样来求解该问题。随后，我们给出该方法的序贯版本，由此得到一种通用的递归 MC 滤波器，即序贯重要性采样 (SIS) 滤波器。以重要性权重的条件方差最小为准则，我们得到了该方法的最优重要性函数。遗憾的是，对于大多数实际感兴趣的模型，最优重要性函数会导致无法解析计算的重要性权重；因此，我们提出若干次优分布，并说明如何把文献中的许多算法作为其特例得到。首先，我们考虑状态空间模型或最优重要性函数的局部线性化方法，并给出若干重要示例。对于这类问题，这些线性化方法似乎是一条很有前景的途径。其次，我们考虑若干简单的重要性函数，它们会导出文献中目前已有的算法。第 3 节使用重采样方案，在实践中限制算法的退化。第 4 节把 Rao-Blackwellisation 方法应用于 SIS，得到高效的解析/MC 混合滤波器。第 5 节说明如何利用 MC 滤波器计算预测分布、固定区间平滑分布以及似然。最后，第 6 节给出仿真结果。

2 通过序贯重要性采样进行滤波

A. 预备知识：状态空间模型的滤波

假设状态序列 $\{\mathbf{x}_k; k \in \mathbb{N}\}$ (其中 $\mathbf{x}_k \in \mathbb{R}^{n_x}$) 是一个不可观测的 (隐) Markov 过程，其初始分布为 $p(\mathbf{x}_0)$ (为便于记号，下文将其记作 $p(\mathbf{x}_0 | \mathbf{x}_{-1})$)，转移分布为 $p(\mathbf{x}_k | \mathbf{x}_{k-1})$ ，其中 n_x 是状态向量的维数。给定过程 $\{\mathbf{x}_k; k \in \mathbb{N}\}$ ，观测 $\{\mathbf{y}_k; k \in \mathbb{N}\}$ (其中 $\mathbf{y}_k \in \mathbb{R}^{n_y}$) 条件独立，其分布为 $p(\mathbf{y}_k | \mathbf{x}_k)$ ，而 n_y 是观测向量的维数。综上，该模型是由下式描述的隐 Markov (或状态空间) 模型 (HMM)：

$$p(\mathbf{x}_k | \mathbf{x}_{k-1}) \quad k \geq 0 \quad (1)$$

$$p(\mathbf{y}_k | \mathbf{x}_k) \quad k \geq 0. \quad (2)$$

我们分别用 $\mathbf{x}_{0:n} \triangleq \{\mathbf{x}_0, \dots, \mathbf{x}_n\}$ 和 $\mathbf{y}_{0:n} \triangleq \{\mathbf{y}_0, \dots, \mathbf{y}_n\}$ 表示截至时刻 n 的状态序列和观测。我们的目标是随时间递归估计分布 $p(\mathbf{x}_{0:n} | \mathbf{y}_{0:n})$ 及其相关特征，其中包括 $p(\mathbf{x}_n | \mathbf{y}_{0:n})$ 和如下形式的

期望：

$$I(f_n) = \int f_n(\mathbf{x}_{0:n}) p(\mathbf{x}_{0:n} | \mathbf{y}_{0:n}) d\mathbf{x}_{0:n} \quad (3)$$

其中, $f_n: \mathbb{R}^{(n+1) \times n_x} \rightarrow \mathbb{R}$ 是任意关于 $p(\mathbf{x}_{0:n} | \mathbf{y}_{0:n})$ 可积的函数。 $p(\mathbf{x}_{0:n} | \mathbf{y}_{0:n})$ 的递推公式为：

$$p(\mathbf{x}_{0:n+1} | \mathbf{y}_{0:n+1}) = p(\mathbf{x}_{0:n} | \mathbf{y}_{0:n}) \frac{p(\mathbf{y}_{n+1} | \mathbf{x}_{n+1}) p(\mathbf{x}_{n+1} | \mathbf{x}_n)}{p(\mathbf{y}_{n+1} | \mathbf{y}_{0:n})}. \quad (4)$$

该表达式的分母通常无法解析计算, 因此除了前述特殊情形外, 解析方法是不可行的。下文将假设: 可以很容易地从 $p(\mathbf{x}_k | \mathbf{x}_{k-1})$ 抽取样本, 并且可以逐点计算 $p(\mathbf{x}_k | \mathbf{x}_{k-1})$ 和 $p(\mathbf{y}_k | \mathbf{x}_k)$ 。

B. 贝叶斯序贯重要性采样 (SIS)

由于通常无法直接从状态后验分布 $p(\mathbf{x}_{0:n} | \mathbf{y}_{0:n})$ 采样, 我们采用重要性采样 (IS) 方法。假设样本 $\{\mathbf{x}_{0:n}^{(i)}; i = 1, \dots, N\}$ 独立地抽取自己归一化的重要性函数 $\pi(\mathbf{x}_{0:n} | \mathbf{y}_{0:n})$, 且该函数的支撑集包含状态后验分布的支撑集。那么, 使用贝叶斯 IS [19], 后验期望 $I(f_n)$ 的估计 $\hat{I}_N(f_n)$ 为:

$$\hat{I}_N(f_n) = \sum_{i=1}^N f_n(\mathbf{x}_{0:n}^{(i)}) \tilde{w}_n^{(i)}, \quad \tilde{w}_n^{(i)} = \frac{w_n^{*(i)}}{\sum_{j=1}^N w_n^{*(j)}} \quad (5)$$

其中, $w_n^{*(i)} = p(\mathbf{y}_{0:n} | \mathbf{x}_{0:n}) p(\mathbf{x}_{0:n}) / \pi(\mathbf{x}_{0:n} | \mathbf{y}_{0:n})$ 是未归一化的重要性权重。在较弱的假设下, $\hat{I}_N(f_n)$ 收敛到 $I(f_n)$, 例如参见 [19]。然而, 该方法不是递归的。下面说明如何使用贝叶斯 IS 得到序贯 MC 滤波器。

假设选取如下形式的重要性函数:

$$\pi(\mathbf{x}_{0:n} | \mathbf{y}_{0:n}) = \pi(\mathbf{x}_0 | \mathbf{y}_0) \prod_{k=1}^n \pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}, \mathbf{y}_{0:k}). \quad (6)$$

当后续观测 $\mathbf{y}_k$ 依次获得时, 这种重要性函数使得重要性权重可以随时间递归计算。由此直接得到序贯重要性采样滤波器。

算法：序贯重要性采样 (SIS)

对于时刻 $k = 0, 1, 2, \dots$

- 对 $i = 1, \dots, N$, 采样 $\mathbf{x}_k^{(i)} \sim \pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}^{(i)}, \mathbf{y}_{0:k})$, 并令 $\mathbf{x}_{0:k}^{(i)} \triangleq (\mathbf{x}_{0:k-1}^{(i)}, \mathbf{x}_k^{(i)})$ 。
- 对 $i = 1, \dots, N$, 在相差一个归一化常数的意义下计算重要性权重:

$$w_k^{*(i)} = w_{k-1}^{*(i)} \frac{p(\mathbf{y}_k | \mathbf{x}_k^{(i)}) p(\mathbf{x}_k^{(i)} | \mathbf{x}_{k-1}^{(i)})}{\pi(\mathbf{x}_k^{(i)} | \mathbf{x}_{0:k-1}^{(i)}, \mathbf{y}_{0:k})}. \quad (7)$$

- 对 $i = 1, \dots, N$, 对重要性权重进行归一化:

$$\tilde{w}_k^{(i)} = \frac{w_k^{*(i)}}{\sum_{j=1}^N w_k^{*(j)}}. \quad (8)$$

相关工作 [9,10] 在 1969 年提出了该算法的一个特例。后文还将说明，文献中提出的许多其他算法同样是这一通用（且简单）算法的特例。重要性函数的选择当然至关重要；若重要性函数选择不当，性能就会很差。下一小节将讨论这一问题。

C. 算法的退化

如果把贝叶斯 IS 解释为 Monte Carlo 采样方法而非 Monte Carlo 积分方法，那么重要性函数的最佳选择当然是后验分布本身，即 $p(\mathbf{x}_{0:k} | \mathbf{y}_{0:k})$ 。理想情况下，我们希望接近这一情形。然而，对于式 (6) 形式的重要性函数，重要性权重的方差随时间只能（随机地）增大。

命题 1. 重要性权重的无条件方差，即把观测 $\mathbf{y}_{0:k}$ 视为随机变量时的方差，随时间增大。

该命题的证明，是把 Kong-Liu-Wong 定理 [15] 直接扩展到式 (6) 形式的重要性函数。因此，退化现象无法避免。在实践中，算法经过少数几次迭代后，除一个归一化重要性权重外，其余权重都非常接近零；大量计算工作因而被用于更新那些对最终估计贡献几乎为零的轨迹。

D. 重要性函数的选择

为了限制算法退化，一种自然策略是在给定模拟轨迹 $\mathbf{x}_{0:k-1}^{(i)}$ 和观测 $\mathbf{y}_{0:k}$ 的条件下，选择使重要性权重方差最小的重要性函数。

命题 2. $\pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}^{(i)}, \mathbf{y}_{0:k}) = p(\mathbf{x}_k | \mathbf{x}_{k-1}^{(i)}, \mathbf{y}_k)$ 是在给定 $\mathbf{x}_{0:k-1}^{(i)}$ 和 $\mathbf{y}_{0:k}$ 条件下，使重要性权重 $w_k^{*(i)}$ 的方差最小的重要性函数。

证明： 直接计算可得

$$\begin{aligned} \text{var}_{\pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}^{(i)}, \mathbf{y}_{0:k})} [w_k^{*(i)}] \\ = \left(w_{k-1}^{*(i)}\right)^2 \left[\int \frac{\left(p(\mathbf{y}_k | \mathbf{x}_k)p(\mathbf{x}_k | \mathbf{x}_{k-1}^{(i)})\right)^2}{\pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}^{(i)}, \mathbf{y}_{0:k})} d\mathbf{x}_k - p^2(\mathbf{y}_k | \mathbf{x}_{k-1}^{(i)}) \right]. \end{aligned}$$

当 $\pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}^{(i)}, \mathbf{y}_{0:k}) = p(\mathbf{x}_k | \mathbf{x}_{k-1}^{(i)}, \mathbf{y}_k)$ 时，该方差为零。 □

1. 最优重要性函数

最优重要性函数 $p(\mathbf{x}_k | \mathbf{x}_{k-1}^{(i)}, \mathbf{y}_k)$ 最初在文献 [11,20] 的特殊情形中提出。近期，文献 [3,15,21] 也使用了这一重要性函数。对于该分布，由式 (7) 得到重要性权重 $w_k^{*(i)} = w_{k-1}^{*(i)}p(\mathbf{y}_k | \mathbf{x}_{k-1}^{(i)})$ 。最优重要性函数有两个主要缺点。它要求能够从 $p(\mathbf{x}_k | \mathbf{x}_{k-1}^{(i)}, \mathbf{y}_k)$ 采样，并能够计算 $p(\mathbf{y}_k | \mathbf{x}_{k-1}^{(i)}) = \int p(\mathbf{y}_k | \mathbf{x}_k)p(\mathbf{x}_k | \mathbf{x}_{k-1}^{(i)}) d\mathbf{x}_k$ 。一般情况下，该积分没有解析形式。不过，对于下文给出的一类重要模型，即转移方程为非线性的高斯状态空间模型，可以进行解析计算。

示例 3. 非线性高斯状态空间模型。考虑如下模型：

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}) + \mathbf{v}_k, \quad \mathbf{v}_k \sim \mathcal{N}(\mathbf{0}_{n_v \times 1}, \Sigma_v) \quad (9)$$

$$\mathbf{y}_k = \mathbf{C}\mathbf{x}_k + \mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(\mathbf{0}_{n_w \times 1}, \Sigma_w) \quad (10)$$

其中, $f: \mathbb{R}^{n_x} \rightarrow \mathbb{R}^{n_x}$ 是实值非线性函数, $\mathbf{C} \in \mathbb{R}^{n_y \times n_x}$ 是观测矩阵, $\mathbf{v}_k$ 和 $\mathbf{w}_k$ 是相互独立的 i.i.d. 高斯序列, 且 $\Sigma_v > 0$, $\Sigma_w > 0$; 假设 $\mathbf{C}$, Σ_v 和 Σ_w 已知。定义

$$\Sigma^{-1} = \Sigma_v^{-1} + \mathbf{C}^t \Sigma_w^{-1} \mathbf{C} \quad (11)$$

$$\mathbf{m}_k = \Sigma \left(\Sigma_v^{-1} f(\mathbf{x}_{k-1}) + \mathbf{C}^t \Sigma_w^{-1} \mathbf{y}_k \right) \quad (12)$$

可得

$$\mathbf{x}_k | (\mathbf{x}_{k-1}, \mathbf{y}_k) \sim \mathcal{N}(\mathbf{m}_k, \Sigma) \quad (13)$$

以及

$$\begin{aligned} p(\mathbf{y}_k | \mathbf{x}_{k-1}) &\propto \exp\left(-\frac{1}{2}(\mathbf{y}_k - \mathbf{C}f(\mathbf{x}_{k-1}))^t (\Sigma_v + \mathbf{C}\Sigma_w\mathbf{C}^t)^{-1} \right. \\ &\quad \left. \times (\mathbf{y}_k - \mathbf{C}f(\mathbf{x}_{k-1}))\right). \end{aligned} \quad (14)$$

对于许多其他模型, 这类计算是不可能的。下面给出能够近似最优重要性函数的次优方法。已有若干 Monte Carlo 方法被提出, 用来近似重要性函数以及与之对应的重要性权重; 这些方法基于重要性采样 [17,18] 和 Markov chain Monte Carlo [16,22]。这些迭代算法的计算量很大, 而且缺乏理论收敛结果。不过, 当非迭代方案失效时, 它们可能有用。事实上, SIS 的一般框架使我们能够考虑其他重要性函数, 通过构造这些函数来解析近似最优重要性函数。这种替代方法的优点是: 其计算代价低于 Monte Carlo 方法, 而且贝叶斯重要性采样的标准收敛结果仍然成立。构造次优重要性函数并不存在通用方法, 必须依据所研究的模型逐例构造。为此, 可以把次优滤波领域的既有工作 [7,23] 作为这些推导的基础; 下一小节将讨论这一思路。

2. 通过局部线性化获得的重要性分布

一种简单选择, 是把重要性函数 $\pi(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{y}_k)$ 选为参数分布 $\pi(\mathbf{x}_k | \boldsymbol{\theta}(\mathbf{x}_{k-1}, \mathbf{y}_k))$; 其有限维参数为 $\boldsymbol{\theta}$ ($\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^{n_\theta}$), 由 $\mathbf{x}_{k-1}$ 和 $\mathbf{y}_k$ 确定, 其中 $\boldsymbol{\theta}: \mathbb{R}^{n_x} \times \mathbb{R}^{n_y} \rightarrow \Theta$ 是确定性映射。基于这一思想可以采用许多策略。为说明这类方法, 本文给出两种新方案; 它们都得到高斯重要性函数, 而函数的参数则使用局部线性化来计算, 也就是说, 这些参数依赖模拟轨迹 $i = 1, \dots, N$ 。对于许多能够方便且低成本地进行线性化的模型, 这种方法似乎是一条很有前景的途径。在辅助变量框架 [4] 中, 作者提出了相关的“次优”重要性分布, 以便从近似滤波分布的有限混合分布中高效采样。本文采用另一种方法, 直接近似滤波分布, 而不借助辅助指示变量。

状态空间模型的局部线性化。 我们提出采用与扩展 Kalman 滤波器相似的方式对模型进行局部线性化。不过在本文中, 线性化的目的是得到重要性函数; 在重要性函数的常规假设下, 由此得到的算法仍渐近收敛到所需的滤波分布。

示例 4. 考虑如下模型：

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}) + \mathbf{v}_k, \quad \mathbf{v}_k \sim \mathcal{N}(\mathbf{0}_{n_v \times 1}, \Sigma_v) \quad (15)$$

$$\mathbf{y}_k = g(\mathbf{x}_k) + \mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(\mathbf{0}_{n_w \times 1}, \Sigma_w) \quad (16)$$

其中, $f: \mathbb{R}^{n_x} \rightarrow \mathbb{R}^{n_x}$ 、 $g: \mathbb{R}^{n_x} \rightarrow \mathbb{R}^{n_y}$ 可微, $\mathbf{v}_k$ 和 $\mathbf{w}_k$ 是两个相互独立的 i.i.d. 序列, 且 $\Sigma_v > 0$ 、 $\Sigma_w > 0$ 。对观测方程作一阶近似 [7], 得到

$$\begin{aligned} \mathbf{y}_k &= g(\mathbf{x}_k) + \mathbf{w}_k \\ &\simeq g(f(\mathbf{x}_{k-1})) + \left. \frac{\partial g(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k=f(\mathbf{x}_{k-1})} (\mathbf{x}_k - f(\mathbf{x}_{k-1})) + \mathbf{w}_k. \end{aligned} \quad (17)$$

至此, 我们定义了一个新模型; 它具有与式 (15) 类似的演化方程, 但观测方程是线性高斯方程 (17), 该方程通过在 $f(\mathbf{x}_{k-1})$ 处线性化 $g(\mathbf{x}_k)$ 得到。由于式 (17) 依赖 $\mathbf{x}_{k-1}$, 该模型不是 Markov 模型。不过, 它具有式 (9)-(10) 的形式, 因而可进行类似计算, 得到高斯重要性函数 $\pi(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{y}_k) \sim \mathcal{N}(\mathbf{m}_k, \Sigma_k)$; 对于每条轨迹 $i = 1, \dots, N$, 其均值 $\mathbf{m}_k$ 和协方差 Σ_k 使用下式计算:

$$\begin{aligned} \Sigma_k^{-1} &= \Sigma_v^{-1} + \left[\left. \frac{\partial g(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k=f(\mathbf{x}_{k-1})} \right]^t \Sigma_w^{-1} \\ &\quad \times \left. \frac{\partial g(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k=f(\mathbf{x}_{k-1})}. \end{aligned} \quad (18)$$

$$\mathbf{m}_k = \Sigma_k \left(\Sigma_v^{-1} f(\mathbf{x}_{k-1}) + \left[\left. \frac{\partial g(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k=f(\mathbf{x}_{k-1})} \right]^t \Sigma_w^{-1} \right. \quad (19)$$

$$\left. \times \left(\mathbf{y}_k - g(f(\mathbf{x}_{k-1})) + \left. \frac{\partial g(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k=f(\mathbf{x}_{k-1})} f(\mathbf{x}_{k-1}) \right) \right). \quad (20)$$

相应的重要性权重使用式 (7) 计算。

最优重要性函数的局部线性化。 这里假设 $l(\mathbf{x}_k) \triangleq \log p(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{y}_k)$ 在 $\mathbb{R}^{n_x}$ 上关于 $\mathbf{x}_k$ 二次可微。定义:

$$l'(\mathbf{x}) \triangleq \left. \frac{\partial l(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k=\mathbf{x}} \quad (21)$$

$$l''(\mathbf{x}) \triangleq \left. \frac{\partial^2 l(\mathbf{x}_k)}{\partial \mathbf{x}_k \partial \mathbf{x}_k^t} \right|_{\mathbf{x}_k=\mathbf{x}}. \quad (22)$$

在 $\mathbf{x}$ 处使用二阶 Taylor 展开, 得到:

$$l(\mathbf{x}_k) \simeq l(\mathbf{x}) + [l'(\mathbf{x})]^t (\mathbf{x}_k - \mathbf{x}) + \frac{1}{2} (\mathbf{x}_k - \mathbf{x})^t l''(\mathbf{x}) (\mathbf{x}_k - \mathbf{x}). \quad (23)$$

展开点 $\mathbf{x}$ 是任意的 (但由 $\mathbf{x}_{k-1}$ 和 $\mathbf{y}_k$ 的确定性映射给出)。进一步假设 $l''(\mathbf{x})$ 为负定矩阵; 当 $l(\mathbf{x}_k)$ 为凹函数时, 该假设成立。此时令

$$\Sigma(\mathbf{x}) = -l''(\mathbf{x})^{-1} \quad (24)$$

$$\mathbf{m}(\mathbf{x}) = \Sigma(\mathbf{x})l'(\mathbf{x}) \quad (25)$$

可得

$$\begin{aligned} [l'(\mathbf{x})]^t(\mathbf{x}_k - \mathbf{x}) + \frac{1}{2}(\mathbf{x}_k - \mathbf{x})^t l''(\mathbf{x})(\mathbf{x}_k - \mathbf{x}) \\ = \text{常数} - \frac{1}{2}(\mathbf{x}_k - \mathbf{x} - \mathbf{m}(\mathbf{x}))^t \Sigma^{-1}(\mathbf{x})(\mathbf{x}_k - \mathbf{x} - \mathbf{m}(\mathbf{x})). \end{aligned} \quad (26)$$

这表明可以采用如下重要性函数：

$$\pi(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{y}_k) = \mathcal{N}(\mathbf{m}(\mathbf{x}) + \mathbf{x}, \Sigma(\mathbf{x})). \quad (27)$$

若 $p(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{y}_k)$ 是单峰分布，则把 $\mathbf{x}$ 取为 $p(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{y}_k)$ 的众数是合理的，此时 $\mathbf{m}(\mathbf{x}) = \mathbf{0}_{n_x \times 1}$ 。相应的重要性权重使用式 (7) 计算。

示例 5. 线性高斯动态模型/观测服从指数族分布。假设演化方程满足：

$$\mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{v}_k \quad \text{其中} \quad \mathbf{v}_k \sim \mathcal{N}(\mathbf{0}_{n_v \times 1}, \Sigma_v) \quad (28)$$

其中 $\Sigma_v > 0$ ，观测服从指数族中的某个分布，即

$$p(\mathbf{y}_k | \mathbf{x}_k) = \exp(\mathbf{y}_k^t \mathbf{C}\mathbf{x}_k - b(\mathbf{C}\mathbf{x}_k) + c(\mathbf{y}_k)) \quad (29)$$

其中， $\mathbf{C}$ 是实 $n_y \times n_x$ 矩阵， $b: \mathbb{R}^{n_y} \rightarrow \mathbb{R}$ ， $c: \mathbb{R}^{n_y} \rightarrow \mathbb{R}$ 。这类模型有许多应用，并允许考虑 Poisson 或二项观测，例如参见 [23]。有

$$l(\mathbf{x}_k) = \text{常数} + \mathbf{y}_k^t \mathbf{C}\mathbf{x}_k - b(\mathbf{C}\mathbf{x}_k) - \frac{1}{2}(\mathbf{x}_k - \mathbf{A}\mathbf{x}_{k-1})^t \Sigma_v^{-1}(\mathbf{x}_k - \mathbf{A}\mathbf{x}_{k-1}). \quad (30)$$

由此得到

$$\begin{aligned} l''(\mathbf{x}) &= - \left. \frac{\partial^2 b(\mathbf{C}\mathbf{x}_k)}{\partial \mathbf{x}_k \partial \mathbf{x}_k^t} \right|_{\mathbf{x}_k = \mathbf{x}} - \Sigma_v^{-1} \\ &= -b''(\mathbf{x}) - \Sigma_v^{-1}. \end{aligned} \quad (31)$$

然而， $b''(\mathbf{x})$ 是在 $\mathbf{x}_k = \mathbf{x}$ 时 $\mathbf{y}_k$ 的协方差矩阵，因此 $l''(\mathbf{x})$ 为负定矩阵。可以采用迭代 Newton-Raphson 方法求得该分布的众数 $\mathbf{x} = \mathbf{x}^*$ ；该方法以 $\mathbf{x}_{(0)} = \mathbf{x}_{k-1}$ 初始化，并在第 j 次迭代满足：

$$\mathbf{x}_{(j+1)} = \mathbf{x}_{(j)} - [l''(\mathbf{x}_{(j)})]^{-1} l'(\mathbf{x}_{(j)}). \quad (32)$$

下面给出两个更简单的重要性函数，它们会导出此前已经出现在文献中的算法。

3. 先验重要性函数

一种简单选择，是把隐 Markov 模型的先验分布用作重要性函数。相关奠基性工作 [9,10] 采用了这一选择。这也是文献 [24] 近期提出的方法之一。在这种情况下，有 $\pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}, \mathbf{y}_{0:k}) = p(\mathbf{x}_k | \mathbf{x}_{k-1})$ ，且 $w_k^{*(i)} = w_{k-1}^{*(i)} p(\mathbf{y}_k | \mathbf{x}_k^{(i)})$ 。由于对状态空间的探索完全不利用观测信息，该方法在仿真中通常效率不高。它对离群点尤为敏感。不过，该方法确实具有重要性权重易于计算的优点。先验重要性函数的使用与 Bootstrap 滤波器方法 [1] 密切相关，参见第 III 节。

4. 固定重要性函数

一个更为简单的选择，是固定一个既不依赖模拟轨迹、也不依赖观测的重要性函数。在这种情况下，有 $\pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}, \mathbf{y}_{0:k}) = \pi(\mathbf{x}_k)$ ，并且

$$w_k^{*(i)} = w_{k-1}^{*(i)} \frac{p(\mathbf{y}_k | \mathbf{x}_k^{(i)})p(\mathbf{x}_k^{(i)} | \mathbf{x}_{k-1}^{(i)})}{\pi(\mathbf{x}_k^{(i)})}. \quad (33)$$

文献 [25,26] 采用了这一重要性函数，并把该方法作为数值积分方法 [12] 的一种随机替代方案。由于既没有考虑模型的动态，也没有考虑观测，所得结果可能相当差，并且在多数情况下会导致无界的（未归一化）重要性权重 [19]。

3 重采样

如前所示，SIS 算法的退化不可避免。重采样方法的基本思想是淘汰归一化重要性权重较小的轨迹，并将注意力集中到权重较大的轨迹上。相关工作 [15,27] 引入的有效样本量 N_{eff} 是衡量算法退化程度的一个合适指标，其定义为：

$$N_{\text{eff}} = \frac{N}{1 + \text{var}_{\pi(\cdot | \mathbf{y}_{0:k})}(w^*(\mathbf{x}_{0:k}))} = \frac{N}{\mathbb{E}_{\pi(\cdot | \mathbf{y}_{0:k})}[(w^*(\mathbf{x}_{0:k}))^2]} \leq N. \quad (34)$$

无法精确计算 N_{eff} ，但可以用下式给出 N_{eff} 的估计 $\hat{N}_{\text{eff}}$ ：

$$\hat{N}_{\text{eff}} = \frac{1}{\sum_{i=1}^N (\tilde{w}_k^{(i)})^2}. \quad (35)$$

当 $\hat{N}_{\text{eff}}$ 低于固定阈值 N_{thres} 时，采用 SIR 重采样过程 [28]。注意，利用经典算法 [29, 第 96 页] 及相关实现 [4,17,18,30]，可以用 $O(N)$ 次运算精确实现 SIR 过程。其他能够减小 MC 变异的重采样过程，例如分层采样 [30,31] 和残差重采样 [16,32]，也可以作为 SIR 的替代方法。

在时刻 k ，一个基于 SIR 方案的适当算法如下。

算法：SIS/重采样蒙特卡洛滤波器

1. 重要性采样

- 对 $i = 1, \dots, N$ ，采样 $\tilde{\mathbf{x}}_k^{(i)} \sim \pi(\mathbf{x}_k | \mathbf{x}_{0:k-1}^{(i)}, \mathbf{y}_{0:k})$ ，并令 $\tilde{\mathbf{x}}_{0:k}^{(i)} \triangleq (\mathbf{x}_{0:k-1}^{(i)}, \tilde{\mathbf{x}}_k^{(i)})$ 。
- 对 $i = 1, \dots, N$ ，计算重要性权重（相差一个归一化常数）：

$$w_k^{*(i)} = w_{k-1}^{*(i)} \frac{p(\mathbf{y}_k | \tilde{\mathbf{x}}_k^{(i)})p(\tilde{\mathbf{x}}_k^{(i)} | \tilde{\mathbf{x}}_{k-1}^{(i)})}{\pi(\tilde{\mathbf{x}}_k^{(i)} | \tilde{\mathbf{x}}_{0:k-1}^{(i)}, \mathbf{y}_{0:k})}. \quad (36)$$

- 对 $i = 1, \dots, N$, 归一化重要性权重:

$$\tilde{w}_k^{(i)} = \frac{w_k^{*(i)}}{\sum_{j=1}^N w_k^{*(j)}}. \quad (37)$$

- 利用式 (35) 计算 $\hat{N}_{\text{eff}}$ 。

2. 重采样

若 $\hat{N}_{\text{eff}} \geq N_{\text{thres}}$,

- 对 $i = 1, \dots, N$, 令 $\mathbf{x}_{0:k}^{(i)} = \tilde{\mathbf{x}}_{0:k}^{(i)}$ 。

否则,

- 对 $i = 1, \dots, N$, 从一个含 N 个元素、满足 $\Pr\{j(i) = l\} = \tilde{w}_k^{(l)}$ ($l = 1, \dots, N$) 的离散分布中采样索引 $j(i)$ 。
- 对 $i = 1, \dots, N$, 令 $\mathbf{x}_{0:k}^{(i)} = \tilde{\mathbf{x}}_{0:k}^{j(i)}$, 且 $w_k^{(i)} = 1/N$ 。

若 $\hat{N}_{\text{eff}} \geq N_{\text{thres}}$, 则第 II-B 小节给出的算法不作修改; 若 $\hat{N}_{\text{eff}} < N_{\text{thres}}$, 则应用 SIR 算法。在时刻 k 可得:

$$\hat{P}(d\mathbf{x}_{0:k} \mid \mathbf{y}_{0:k}) = \frac{1}{N} \sum_{i=1}^N \delta_{\mathbf{x}_{0:k}^{(i)}}(d\mathbf{x}_{0:k}). \quad (38)$$

重采样过程从算法上缓解了退化问题, 但也引入了实际和理论问题。从理论角度看, 经过一次重采样后, 模拟轨迹不再统计独立, 因此会失去前文给出的简单收敛结果。不过, 近期研究 [22] 已经为每次迭代都应用 SIR 过程时得到的 $I(f_k)$ 估计建立了中心极限定理。从实际角度看, 重采样方案要求将所有粒子汇集起来, 因而限制了并行化机会, 尽管 IS 步骤仍可并行实现。此外, 具有较大重要性权重 $\tilde{w}_k^{(i)}$ 的轨迹 $\{\tilde{\mathbf{x}}_{0:k}^{(i)}, i = 1, \dots, N\}$ 会在统计意义上被多次选中。在式 (38) 中, 当 $i_1 \neq i_2 \in [1, \dots, N]$ 时, 许多轨迹 $\mathbf{x}_{0:k}^{(i_1)}$ 与 $\mathbf{x}_{0:k}^{(i_2)}$ 实际上相同。因此会损失“多样性”。为解决这一问题, 人们提出了多种启发式方法 [1, 32]。

4 序贯重要性采样的 Rao-Blackwell 化

本节介绍方差缩减方法, 这些方法旨在充分利用所研究模型中的任意结构。为减小 MC 估计的方差, 人们已经提出许多方法, 包括对偶采样 [9, 10] 和控制变量法 [8, 10]。这里采用 Rao-Blackwell 化方法; 关于该主题的一般性介绍, 可参见文献 [33]。在序贯框架下, 类似思想已应用于 Dirichlet 过程模型 [34], 并用于固定参数估计 [15, 16]。本文聚焦于它在动态模型中的应用。我们将说明如何把该方法成功应用于一类重要的状态空间模型, 并得到混合滤波器: 其中一部分计算以解析方式完成, 另一部分使用 MC 方法完成。

当状态 $\mathbf{x}_k$ 可以划分为 $(\mathbf{x}_k^1, \mathbf{x}_k^2)$, 且能以解析方式将其中一个分量 (例如 $\mathbf{x}_k^2$) 边缘化时, 下面的方法非常有用。例如, 如例 6 所示, 若划分中的一个分量是条件线性高斯状态空间模型, 则所有积分都可利用 Kalman 滤波器在线解析完成。定义 $\mathbf{x}_{0:n}^j \triangleq (\mathbf{x}_0^j, \dots, \mathbf{x}_n^j)$ 。可以用边缘量重写后验期望 $I(f_n)$:

$$\begin{aligned} I(f_n) &= \frac{\int g(\mathbf{x}_{0:n}^1) p(\mathbf{x}_{0:n}^1) d\mathbf{x}_{0:n}^1}{\int \left[\int p(\mathbf{y}_{0:n} | \mathbf{x}_{0:n}^1, \mathbf{x}_{0:n}^2) p(\mathbf{x}_{0:n}^2 | \mathbf{x}_{0:n}^1) d\mathbf{x}_{0:n}^2 \right] p(\mathbf{x}_{0:n}^1) d\mathbf{x}_{0:n}^1} \\ &= \frac{\int g(\mathbf{x}_{0:n}^1) p(\mathbf{x}_{0:n}^1) d\mathbf{x}_{0:n}^1}{\int p(\mathbf{y}_{0:n} | \mathbf{x}_{0:n}^1) p(\mathbf{x}_{0:n}^1) d\mathbf{x}_{0:n}^1}, \end{aligned}$$

其中

$$g(\mathbf{x}_{0:n}^1) \triangleq \int f_n(\mathbf{x}_{0:n}^1, \mathbf{x}_{0:n}^2) p(\mathbf{y}_{0:n} | \mathbf{x}_{0:n}^1, \mathbf{x}_{0:n}^2) p(\mathbf{x}_{0:n}^2 | \mathbf{x}_{0:n}^1) d\mathbf{x}_{0:n}^2. \quad (39)$$

假设在给定 $\mathbf{x}_{0:n}^1$ 的一个实现时, $g(\mathbf{x}_{0:n}^1)$ 和 $p(\mathbf{y}_{0:n} | \mathbf{x}_{0:n}^1)$ 均可解析计算, 则基于 IS 可以得到 $I(f_n)$ 的两种估计。第一种 “经典” 估计使用 $\pi(\mathbf{x}_{0:n}^1, \mathbf{x}_{0:n}^2 | \mathbf{y}_{0:n})$ 作为重要性分布:

$$\hat{I}_N(f_n) = \frac{\sum_{i=1}^N f_n(\mathbf{x}_{0:n}^{1,(i)}, \mathbf{x}_{0:n}^{2,(i)}) w^*(\mathbf{x}_{0:n}^{1,(i)}, \mathbf{x}_{0:n}^{2,(i)})}{\sum_{i=1}^N w^*(\mathbf{x}_{0:n}^{1,(i)}, \mathbf{x}_{0:n}^{2,(i)})}. \quad (40)$$

其中

$$w^*(\mathbf{x}_{0:n}^{1,(i)}, \mathbf{x}_{0:n}^{2,(i)}) \propto \frac{p(\mathbf{x}_{0:n}^{1,(i)}, \mathbf{x}_{0:n}^{2,(i)} | \mathbf{y}_{0:n})}{\pi(\mathbf{x}_{0:n}^{1,(i)}, \mathbf{x}_{0:n}^{2,(i)} | \mathbf{y}_{0:n})}.$$

第二种 “Rao-Blackwell 化” 估计通过解析积分消去 $\mathbf{x}_{0:n}^2$, 并采用重要性分布 $\pi(\mathbf{x}_{0:n}^1 | \mathbf{y}_{0:n}) = \int \pi(\mathbf{x}_{0:n}^1, \mathbf{x}_{0:n}^2 | \mathbf{y}_{0:n}) d\mathbf{x}_{0:n}^2$ 。新的估计为:

$$\hat{\hat{I}}_N(f_n) = \frac{\sum_{i=1}^N g(\mathbf{x}_{0:n}^{1,(i)}) w^*(\mathbf{x}_{0:n}^{1,(i)})}{\sum_{i=1}^N w^*(\mathbf{x}_{0:n}^{1,(i)})}. \quad (41)$$

其中

$$w^*(\mathbf{x}_{0:n}^{1,(i)}) \propto \frac{p(\mathbf{x}_{0:n}^{1,(i)} | \mathbf{y}_{0:n})}{\pi(\mathbf{x}_{0:n}^{1,(i)} | \mathbf{y}_{0:n})}.$$

利用方差分解, 不难证明 Rao-Blackwell 化得到的重要性权重方差小于直接 Monte Carlo 方法 (40) 得到的方差, 例如可参见文献 [17, 18, 34]。该方法可用于估计 $I(f_n)$ 及 $p(\mathbf{x}_{0:n}^1 | \mathbf{y}_{0:n})$ 等边缘量。

将前几节发展的 MC 方法应用于边缘状态空间 $\mathbf{x}_k^1$ 时必须谨慎。事实上, 即使观测 $\mathbf{y}_{0:n}$ 在给定 $(\mathbf{x}_{0:n}^1, \mathbf{x}_{0:n}^2)$ 时相互独立, 在仅给定过程 $\mathbf{x}_{0:n}^1$ 时它们通常也不再独立。不过, 所需修改是直接的。例

如, $p(\mathbf{x}_k^1 | \mathbf{y}_{0:k}, \mathbf{x}_{0:k-1}^1)$ 是最优重要性函数, $p(\mathbf{y}_k | \mathbf{y}_{0:k-1}, \mathbf{x}_{0:k-1}^1)$ 是相应的重要性权重。下面给出这一一般方法的两个重要应用。

例 6 (条件线性高斯状态空间模型)。考虑如下模型

$$p(\mathbf{x}_k^1 | \mathbf{x}_{k-1}^1) \quad (42)$$

$$\mathbf{x}_k^2 = \mathbf{A}_k(\mathbf{x}_k^1) \mathbf{x}_{k-1}^2 + \mathbf{B}_k(\mathbf{x}_k^1) \mathbf{v}_k \quad (43)$$

$$\mathbf{y}_k = \mathbf{C}_k(\mathbf{x}_k^1) \mathbf{x}_k^2 + \mathbf{D}_k(\mathbf{x}_k^1) \mathbf{w}_k \quad (44)$$

其中 $\mathbf{x}_k^1$ 是 Markov 过程, $\mathbf{v}_k \sim \mathcal{N}(\mathbf{0}_{n_v \times 1}, \mathbf{I}_{n_v})$, 且 $\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}_{n_w \times 1}, \mathbf{I}_{n_w})$ 。我们希望估计 $p(\mathbf{x}_{0:n}^1 | \mathbf{y}_{0:n})$ 、 $\mathbb{E}(f(\mathbf{x}_n^1) | \mathbf{y}_{0:n})$ 、 $\mathbb{E}(\mathbf{x}_n^2 | \mathbf{y}_{0:n})$ 和 $\mathbb{E}(\mathbf{x}_n^2 (\mathbf{x}_n^2)^t | \mathbf{y}_{0:n})$ 。可以采用基于 Rao-Blackwell 化的 MC 滤波器。事实上, 在给定 $\mathbf{x}_{0:n}^1$ 时, $\mathbf{x}_{0:n}^2$ 是线性高斯状态空间模型, Rao-Blackwell 化所需的积分可利用 Kalman 滤波器完成。

在 $\mathbf{x}_k^1$ 为齐次标量有限状态空间 Markov 链这一特殊情形下, 该算法以 RSA (Random Sampling Algorithm, 随机采样算法) 之名被引入 [20,35]。在这种情况下, 作者采用最优重要性函数 $p(\mathbf{x}_k^1 | \mathbf{y}_{0:k}, \mathbf{x}_{0:k-1}^1)$ 。事实上, 可以从这一离散分布采样, 并利用 Kalman 滤波器计算重要性权重 $p(\mathbf{y}_k | \mathbf{y}_{0:k}, \mathbf{x}_{0:k-1}^1)$ [20]。针对这一特殊情形也有类似发展 [16,36,37]。文献 [3] 提出的盲反卷积算法也是该方法的一个特例, 其中 $\mathbf{x}_k^2 = \mathbf{h}$ 是具有高斯先验分布的时不变信道。在此框架下使用 Rao-Blackwell 化尤其有吸引力, 因为尽管 $\mathbf{x}_k$ 含有一些连续分量, 我们只需探索离散状态空间。

例 7 (有限状态空间 HMM)。考虑如下模型

$$p(\mathbf{x}_k^1 | \mathbf{x}_{k-1}^1) \quad (45)$$

$$p(\mathbf{x}_k^2 | \mathbf{x}_k^1, \mathbf{x}_{k-1}^2) \quad (46)$$

$$p(\mathbf{y}_k | \mathbf{x}_k^1, \mathbf{x}_k^2) \quad (47)$$

其中 $\mathbf{x}_k^1$ 是 Markov 过程, $\mathbf{x}_k^2$ 是有限状态空间 Markov 链, 并且它在时刻 k 的参数依赖于 $\mathbf{x}_k^1$ 。我们希望估计 $p(\mathbf{x}_{0:n}^1 | \mathbf{y}_{0:n})$ 、 $\mathbb{E}(f(\mathbf{x}_n^1) | \mathbf{y}_{0:n})$ 和 $\mathbb{E}(f(\mathbf{x}_n^2) | \mathbf{y}_{0:n})$ 。可以采用 “Rao-Blackwell 化” MC 滤波器。事实上, 在给定 $\mathbf{x}_{0:n}^1$ 时, $\mathbf{x}_{0:n}^2$ 是参数已知的有限状态空间 Markov 链, 因此 Rao-Blackwell 化所需的积分可以解析完成 [7]。

5 预测、平滑与似然

基于 SIS 对联合分布 $p(\mathbf{x}_{0:k} | \mathbf{y}_{0:k})$ 的估计, 在实际中会与重采样过程结合以限制退化; 该估计在任意时刻 k 都具有如下形式:

$$\hat{P}(d\mathbf{x}_{0:k} | \mathbf{y}_{0:k}) = \sum_{i=1}^N \tilde{w}_k^{(i)} \delta_{\mathbf{x}_{0:k}^{(i)}}(d\mathbf{x}_{0:k}). \quad (48)$$

下面说明如何基于该分布得到预测分布、平滑分布以及似然的近似。

5.1 预测

基于滤波分布的近似 $\hat{P}(d\mathbf{x}_k | \mathbf{y}_{0:k})$ ，我们希望估计 p 步超前预测分布，其中 $p \geq 2 \in \mathbb{N}^*$ ；该分布为：

$$p(\mathbf{x}_{k+p} | \mathbf{y}_{0:k}) = \int p(\mathbf{x}_k | \mathbf{y}_{0:k}) \left[\prod_{j=k+1}^{k+p} p(\mathbf{x}_j | \mathbf{x}_{j-1}) \right] d\mathbf{x}_{k:k+p-1}. \quad (49)$$

其中 $\mathbf{x}_{i:j} \triangleq \{\mathbf{x}_i, \mathbf{x}_{i+1}, \dots, \mathbf{x}_j\}$ 。用式 (48) 得到的近似替换式 (49) 中的 $p(\mathbf{x}_k | \mathbf{y}_{0:k})$ ，可得：

$$\sum_{i=1}^N \tilde{w}_k^{(i)} \int p(\mathbf{x}_{k+1} | \mathbf{x}_k^{(i)}) \prod_{j=k+2}^{k+p} p(\mathbf{x}_j | \mathbf{x}_{j-1}) d\mathbf{x}_{k+1:k+p-1}. \quad (50)$$

为计算这些积分，只需利用演化方程延拓轨迹 $\mathbf{x}_{0:k}^{(i)}$ 。

算法： p 步超前预测

- 对 $j = 1$ 到 p
 - 对 $i = 1, \dots, N$ ，采样 $\mathbf{x}_{k+j}^{(i)} \sim p(\mathbf{x}_{k+j} | \mathbf{x}_{k+j-1}^{(i)})$ ，并令 $\mathbf{x}_{0:k+j}^{(i)} \triangleq (\mathbf{x}_{0:k+j-1}^{(i)}, \mathbf{x}_{k+j}^{(i)})$ 。

得到随机样本 $\{\mathbf{x}_{0:k+p}^{(i)}; i = 1, \dots, N\}$ 。 $\hat{P}(d\mathbf{x}_{0:k+p} | \mathbf{y}_{0:k})$ 的一个估计为

$$\hat{P}(d\mathbf{x}_{0:k+p} | \mathbf{y}_{0:k}) = \sum_{i=1}^N \tilde{w}_k^{(i)} \delta_{\mathbf{x}_{0:k+p}^{(i)}}(d\mathbf{x}_{0:k+p}).$$

因此

$$\hat{P}(d\mathbf{x}_{k+p} | \mathbf{y}_{0:k}) = \sum_{i=1}^N \tilde{w}_k^{(i)} \delta_{\mathbf{x}_{k+p}^{(i)}}(d\mathbf{x}_{k+p}). \quad (51)$$

5.2 固定滞后平滑

我们希望估计固定滞后平滑分布 $p(\mathbf{x}_k | \mathbf{y}_{0:k+p})$ ，其中 $p \in \mathbb{N}^*$ 为滞后长度。在时刻 $k+p$ ，MC 滤波器给出 $p(\mathbf{x}_{0:k+p} | \mathbf{y}_{0:k+p})$ 的如下近似：

$$\hat{P}(d\mathbf{x}_{0:k+p} | \mathbf{y}_{0:k+p}) = \sum_{i=1}^N \tilde{w}_{k+p}^{(i)} \delta_{\mathbf{x}_{0:k+p}^{(i)}}(d\mathbf{x}_{0:k+p}). \quad (52)$$

通过边缘化，得到固定滞后平滑分布的估计：

$$\hat{P}(d\mathbf{x}_k | \mathbf{y}_{0:k+p}) = \sum_{i=1}^N \tilde{w}_{k+p}^{(i)} \delta_{\mathbf{x}_k^{(i)}}(d\mathbf{x}_k). \quad (53)$$

当 p 较大时，这种近似的表现通常很差。

5.3 固定区间平滑

给定 $\mathbf{y}_{0:n}$ ，我们希望对任意 $k = 0, \dots, n$ 估计 $p(\mathbf{x}_k | \mathbf{y}_{0:n})$ 。在时刻 n ，滤波算法给出 $p(\mathbf{x}_{0:n} | \mathbf{y}_{0:n})$ 的如下近似：

$$\hat{P}(d\mathbf{x}_{0:n} | \mathbf{y}_{0:n}) = \sum_{i=1}^N \tilde{w}_n^{(i)} \delta_{\mathbf{x}_{0:n}^{(i)}}(d\mathbf{x}_{0:n}). \quad (54)$$

因此，理论上可以通过边缘化该分布得到任意 k 对应的 $p(\mathbf{x}_k | \mathbf{y}_{0:n})$ 。实际上，一旦 $(n - k)$ 较大，该方法就无法使用，因为退化问题要求采用重采样算法。在时刻 n ，模拟轨迹 $\{\mathbf{x}_{0:n}^{(i)}; i = 1, \dots, N\}$ 通常已被重采样多次：所以在 $k \ll n$ 的时刻 k ，只有少量互异轨迹，以上对 $p(\mathbf{x}_k | \mathbf{y}_{0:n})$ 的近似表现很差。对于每个时刻都进行重采样的 bootstrap 滤波器，该问题更为严重。

有必要提出另一种算法。本文提出一种原创算法来解决该问题。该算法基于下式 [12]：

$$p(\mathbf{x}_k | \mathbf{y}_{0:n}) = p(\mathbf{x}_k | \mathbf{y}_{0:k}) \int \frac{p(\mathbf{x}_{k+1} | \mathbf{y}_{0:n}) p(\mathbf{x}_{k+1} | \mathbf{x}_k)}{p(\mathbf{x}_{k+1} | \mathbf{y}_{0:k})} d\mathbf{x}_{k+1}. \quad (55)$$

这里寻求如下形式的固定区间平滑分布近似：

$$\hat{P}(d\mathbf{x}_k | \mathbf{y}_{0:n}) \triangleq \sum_{i=1}^N \tilde{w}_{k|n}^{(i)} \delta_{\mathbf{x}_k^{(i)}}(d\mathbf{x}_k). \quad (56)$$

即， $\hat{P}(d\mathbf{x}_k | \mathbf{y}_{0:n})$ 与滤波分布 $\hat{P}(d\mathbf{x}_k | \mathbf{y}_{0:k})$ 具有相同的支撑集 $\{\mathbf{x}_k^{(i)}; i = 1, \dots, N\}$ ，但二者权重不同。求取这些权重 $\{\tilde{w}_{k|n}^{(i)}; i = 1, \dots, N\}$ 的算法如下。

算法：固定区间平滑

1. 在时刻 $k = n$ 初始化。
 - 对 $i = 1, \dots, N$ ，令 $\tilde{w}_{n|n}^{(i)} = \tilde{w}_n^{(i)}$ 。
2. 对 $k = n - 1, \dots, 0$ 。
 - 对 $i = 1, \dots, N$ ，计算重要性权重

$$\tilde{w}_{k|n}^{(i)} = \sum_{j=1}^N \tilde{w}_{k+1|n}^{(j)} \frac{\tilde{w}_k^{(i)} p(\mathbf{x}_{k+1}^{(j)} | \mathbf{x}_k^{(i)})}{\sum_{l=1}^N \tilde{w}_k^{(l)} p(\mathbf{x}_{k+1}^{(j)} | \mathbf{x}_k^{(l)})}. \quad (57)$$

该算法可由如下论证得到。用近似 (56) 替换 $p(\mathbf{x}_{k+1} | \mathbf{y}_{0:n})$ ，得到

$$\int \frac{p(\mathbf{x}_{k+1} | \mathbf{y}_{0:n}) p(\mathbf{x}_{k+1} | \mathbf{x}_k)}{p(\mathbf{x}_{k+1} | \mathbf{y}_{0:k})} d\mathbf{x}_{k+1} \simeq \sum_{i=1}^N \tilde{w}_{k+1|n}^{(i)} \frac{p(\mathbf{x}_{k+1}^{(i)} | \mathbf{x}_k)}{p(\mathbf{x}_{k+1}^{(i)} | \mathbf{y}_{0:k})}. \quad (58)$$

其中, 由式 (48), $p(\mathbf{x}_{k+1}^{(i)} | \mathbf{y}_{0:k})$ 可近似为

$$\begin{aligned} p(\mathbf{x}_{k+1}^{(i)} | \mathbf{y}_{0:k}) &= \int p(\mathbf{x}_{k+1}^{(i)} | \mathbf{x}_k) p(\mathbf{x}_k | \mathbf{y}_{0:k}) d\mathbf{x}_k \\ &\simeq \sum_{j=1}^N \tilde{w}_k^{(j)} p(\mathbf{x}_{k+1}^{(i)} | \mathbf{x}_k^{(j)}). \end{aligned} \quad (59)$$

因此, $p(\mathbf{x}_k | \mathbf{y}_{0:n})$ 的一个近似 $\hat{P}(d\mathbf{x}_k | \mathbf{y}_{0:n})$ 为

$$\begin{aligned} \hat{P}(d\mathbf{x}_k | \mathbf{y}_{0:n}) &= \left[\sum_{i=1}^N \tilde{w}_k^{(i)} \delta_{\mathbf{x}_k^{(i)}}(d\mathbf{x}_k) \right] \sum_{j=1}^N \tilde{w}_{k+1|n}^{(j)} \frac{p(\mathbf{x}_{k+1}^{(j)} | \mathbf{x}_k)}{\sum_{l=1}^N \tilde{w}_k^{(l)} p(\mathbf{x}_{k+1}^{(j)} | \mathbf{x}_k^{(l)})} \\ &= \sum_{i=1}^N \tilde{w}_k^{(i)} \left[\sum_{j=1}^N \tilde{w}_{k+1|n}^{(j)} \frac{p(\mathbf{x}_{k+1}^{(j)} | \mathbf{x}_k^{(i)})}{\sum_{l=1}^N \tilde{w}_k^{(l)} p(\mathbf{x}_{k+1}^{(j)} | \mathbf{x}_k^{(l)})} \right] \delta_{\mathbf{x}_k^{(i)}}(d\mathbf{x}_k) \\ &\triangleq \sum_{i=1}^N \tilde{w}_{k|n}^{(i)} \delta_{\mathbf{x}_k^{(i)}}(d\mathbf{x}_k). \end{aligned} \quad (60)$$

由此便得到上述算法。

该算法要求存储所有 $k \in \{0, \dots, n\}$ 时刻的边缘分布 $\hat{P}(d\mathbf{x}_k | \mathbf{y}_{0:k})$ (权重和支撑点)。所需存储量为 $O(nN)$, 复杂度为 $O(nN^2)$; 由于 $N \gg 1$, 该计算量相当大。不过, 它的复杂度略低于相关方法 [24, 31], 因为它不需要任何新的模拟步骤。

5.4 似然

在一些应用中, 尤其是模型选择 [12, 31], 我们可能希望估计数据的似然

$$p(\mathbf{y}_{0:n}) = \int w_n^* \pi(\mathbf{x}_{0:n} | \mathbf{y}_{0:n}) d\mathbf{x}_{0:n}.$$

因此, 似然的一个简单估计为

$$\hat{P}(\mathbf{y}_{0:n}) = \frac{1}{N} \sum_{j=1}^N w_n^{*(j)}. \quad (61)$$

在实际中, 重采样步骤的引入再次使这种方法不可行。我们将使用似然的另一种分解:

$$p(\mathbf{y}_{0:n}) = p(\mathbf{y}_0) \prod_{k=1}^n p(\mathbf{y}_k | \mathbf{y}_{0:k-1}). \quad (62)$$

其中:

$$p(\mathbf{y}_k | \mathbf{y}_{0:k-1}) = \int p(\mathbf{y}_k | \mathbf{x}_k) p(\mathbf{x}_k | \mathbf{y}_{0:k-1}) d\mathbf{x}_k \quad (63)$$

$$= \int p(\mathbf{y}_k | \mathbf{x}_{k-1}) p(\mathbf{x}_{k-1} | \mathbf{y}_{0:k-1}) d\mathbf{x}_{k-1}. \quad (64)$$

利用式 (63), 该量的一个估计为

$$\hat{P}(\mathbf{y}_k | \mathbf{y}_{0:k-1}) = \sum_{i=1}^N p(\mathbf{y}_k | \hat{\mathbf{x}}_k^{(i)}) \tilde{w}_{k-1}^{(i)}. \quad (65)$$

其中, 样本 $\{\hat{\mathbf{x}}_k^{(i)}; i = 1, \dots, N\}$ 是利用一步超前预测得到的, 该预测基于 $p(\mathbf{x}_{k-1} | \mathbf{y}_{0:k-1})$ 的近似 $\hat{P}(d\mathbf{x}_{k-1} | \mathbf{y}_{0:k-1})$ 。利用表达式 (64), 若能够解析求得 $p(\mathbf{y}_k | \mathbf{x}_{k-1}^{(i)})$, 就可以避免一次 MC 积分:

$$\hat{P}(\mathbf{y}_k | \mathbf{y}_{0:k-1}) = \sum_{i=1}^N p(\mathbf{y}_k | \mathbf{x}_{k-1}^{(i)}) \tilde{w}_{k-1}^{(i)}. \quad (66)$$

6 仿真

本节将前文所发展的方法应用于一个线性高斯状态空间模型和一个经典非线性模型。对这两个模型, 我们分别进行 $M = 100$ 次长度为 $n = 500$ 的仿真, 并计算由 MC 方法获得的滤波估计 $x_{k|k} = \mathbb{E}[x_k | \mathbf{y}_{0:k}]$ 的经验标准差:

$$\sqrt{\text{VAR}(x_{k|l})} = \frac{1}{n} \sum_{k=1}^n \left(\frac{1}{M} \sum_{j=1}^M (x_{k|l}^j - x_k^j)^2 \right)^{1/2}.$$

其中:

- x_k^j 是第 j 次仿真的真实模拟状态, $j = 1, \dots, M$ 。
- $x_{k|l}^j \triangleq \sum_{i=1}^N \tilde{w}_{k|l}^{(i)} x_k^{j,(i)}$ 是第 j 个测试信号的 $\mathbb{E}[x_k | \mathbf{y}_{0:l}]$ 的 MC 估计, $x_k^{j,(i)}$ 是与信号 j 相关联的第 i 条模拟轨迹, $i = 1, \dots, N$ 。(我们定义 $\tilde{w}_{k|k}^{(i)} \triangleq \tilde{w}_k^{(i)}$ 。)

上述计算分别取 $N = 100, 250, 500, 1000, 2500$ 和 5000 。所实现的滤波算法包括 bootstrap 滤波器、采用先验重要性函数的 SIS, 以及采用最优或次优重要性函数的 SIS。随后计算与这些 SIS 滤波器相对应的固定区间平滑器。

对于基于 SIS 的算法, 当 $\hat{N}_{\text{eff}} < N_{\text{thres}} = N/3$ 时采用 SIR 过程。我们给出每种重要性函数中使用 SIR 步骤的迭代次数百分比。

6.1 线性高斯模型

考虑如下模型

$$x_k = x_{k-1} + v_k, \quad (67)$$

$$y_k = x_k + w_k, \quad (68)$$

其中, $x_0 \sim \mathcal{N}(0, 1)$, v_k 和 w_k 是相互独立的高斯白噪声, $v_k \sim \mathcal{N}(0, \sigma_v^2)$, $w_k \sim \mathcal{N}(0, \sigma_w^2)$, 且 $\sigma_v^2 = \sigma_w^2 = 1$ 。对于该模型, 最优滤波器是 Kalman 滤波器 [7]。

表 1. MC 滤波器：线性高斯模型

$\sqrt{\text{VAR}(x_{k k})}$	Bootstrap	先验分布	最优分布
$N = 100$	0.80	0.86	0.83
$N = 250$	0.81	0.81	0.80
$N = 500$	0.79	0.80	0.79
$N = 1000$	0.79	0.79	0.79
$N = 2500$	0.79	0.79	0.79
$N = 5000$	0.79	0.79	0.79

表 2. SIR 步骤百分比：线性高斯模型

SIR 百分比	先验分布	最优分布
$N = 100$	40	16
$N = 250$	23	10
$N = 500$	20	8
$N = 1000$	15	6
$N = 2500$	13	5
$N = 5000$	11	4

6.1.1 最优重要性函数

最优重要性函数为

$$x_k \mid (x_{k-1}, y_k) \sim \mathcal{N}(m_k, \sigma_k^2), \quad (69)$$

其中

$$\sigma_k^{-2} = \sigma_w^{-2} + \sigma_v^{-2}, \quad (70)$$

$$m_k = \sigma_k^2 \left(\frac{x_{k-1}}{\sigma_v^2} + \frac{y_k}{\sigma_w^2} \right). \quad (71)$$

相应的重要性权重正比于

$$p(y_k \mid x_{k-1}) \propto \exp \left[-\frac{1}{2} \frac{(y_k - x_{k-1})^2}{\sigma_v^2 + \sigma_w^2} \right]. \quad (72)$$

6.1.2 结果

对于 Kalman 滤波器，我们得到 $\sqrt{\text{VAR}(x_{k|k})} = 0.79$ 。不同 MC 滤波器的结果见表 1 和表 2。当采用 $N = 500$ 条轨迹时，MC 方法得到的估计与 Kalman 滤波器的结果相近。SIS 算法以较小的计算代价获得了与 bootstrap 滤波器相近的性能。最值得关注的算法基于最优重要性函数，它显著限制了重采样步骤的次数。

6.2 非线性序列

这里考虑如下非线性参考模型 [1, 12, 24]:

$$\begin{aligned} x_k &= f(x_{k-1}) + v_k \\ &= \frac{1}{2}x_{k-1} + 25\frac{x_{k-1}}{1 + (x_{k-1})^2} + 8\cos(1.2k) + v_k, \end{aligned} \quad (73)$$

$$\begin{aligned} y_k &= g(x_k) + w_k \\ &= \frac{(x_k)^2}{20} + w_k. \end{aligned} \quad (74)$$

其中, $x_0 \sim \mathcal{N}(0, 5)$, v_k 和 w_k 是相互独立的高斯白噪声, $v_k \sim \mathcal{N}(0, \sigma_v^2)$, $w_k \sim \mathcal{N}(0, \sigma_w^2)$, 且 $\sigma_v^2 = 10$ 、 $\sigma_w^2 = 1$ 。在此情形下, 既无法解析计算 $p(y_k | x_{k-1})$, 也无法简单地从 $p(x_k | x_{k-1}, y_k)$ 中采样。我们采用 II-2 小节所述的方法, 即对观测方程进行局部线性化。

6.2.1 由局部线性化得到的重要性函数

可得

$$\begin{aligned} y_k &\simeq g(f(x_{k-1})) + \left. \frac{\partial g(x_k)}{\partial x_k} \right|_{x_k=f(x_{k-1})} (x_k - f(x_{k-1})) + w_k \\ &= -\frac{f^2(x_{k-1})}{20} + \frac{f(x_{k-1})}{10}x_k + w_k. \end{aligned} \quad (75)$$

于是得到线性化重要性函数

$$\pi(x_k | x_{k-1}, y_k) = \mathcal{N}(x_k; m_k, (\sigma_k)^2),$$

其中

$$(\sigma_k)^{-2} = \sigma_v^{-2} + \sigma_w^{-2} \frac{f^2(x_{k-1})}{100}, \quad (76)$$

且

$$m_k = (\sigma_k)^2 \left[\sigma_v^{-2} f(x_{k-1}) + \sigma_w^{-2} \frac{f(x_{k-1})}{10} \left(y_k + \frac{f^2(x_{k-1})}{20} \right) \right]. \quad (77)$$

6.2.2 结果

在此情形下, 无法估计最优滤波器。MC 滤波器的结果见表 3, SIR 步骤的平均百分比见表 4。

该模型需要比前一个模型模拟更多样本。事实上, 动态噪声方差更为显著, 需要更多轨迹来探索状态空间。最值得关注的是采用次优重要性函数的 SIS 算法: 与先验重要性函数相比, 它显著减少了重采样步骤的次数, 同时避免了计算最优重要性函数所需的一次 MC 积分。对此可以作出粗略解释: 观测噪声很小, 因而 y_k 含有高度信息, 可以限制所探索的区域。

表 3. MC 滤波器：非线性时间序列

$\sqrt{\text{VAR}(x_{k k})}$	Bootstrap	先验分布	线性化分布
$N = 100$	5.67	6.01	5.54
$N = 250$	5.32	5.65	5.46
$N = 500$	5.27	5.59	5.23
$N = 1000$	5.11	5.36	5.05
$N = 2500$	5.09	5.14	5.02
$N = 5000$	5.04	5.07	5.01

表 4. SIR 步骤百分比：非线性时间序列

SIR 百分比	先验分布	线性化分布
$N = 100$	22.4	8.9
$N = 250$	19.6	7.5
$N = 500$	17.7	6.5
$N = 1000$	15.6	5.9
$N = 2500$	13.9	5.2
$N = 5000$	12.3	5.3

7 结论

本文综述了用于一般状态空间模型贝叶斯滤波的序贯仿真方法。在 SIS 的统一框架内，我们纳入了过去 30 年间文献中相互独立提出的多种方法。本文还介绍了若干原创扩展，其中包括利用局部线性化技术构造更有效的重要性分布。我们也说明了如何利用 Rao-Blackwell 化，充分发挥某些重要动态模型中所存在的解析结构，并给出了预测、固定滞后平滑和似然计算的过程。

这些方法虽有效，但仍存在若干缺点。首先，随着时间推进，本文所述所有方法都不可避免地出现样本耗竭。基于 MCMC 步骤的样本再生方法很可能改善这一情形 [34]。第二个问题是固定超参数的模拟，例如在本文示例中假定已知的协方差矩阵和噪声方差。本文所述方法无法为这些非动态参数再生新值，因此可以预期样本集会极快地贫化。同样，将现有技术与 MCMC 步骤结合可能有所帮助，Rao-Blackwell 化方法也可能发挥作用，相关思路可参见文献 [16]。

该问题仍然带来的技术挑战，加之范围广泛的重要应用以及快速增长的计算能力，应会在未来几年推动这一领域出现令人振奋的新发展。

参考文献

- [1] Gordon N.J., Salmond D.J., and Smith A.F.M. 1993. Novel approach to nonlinear/non-Gaussian Bayesian state estimation. *IEEE-Proceedings-F* 140: 107–113.
- [2] Clapp T.C. and Godsill S.J. 1999. Fixed-lag smoothing using sequential importance sampling. In: Bernardo J.M., Berger J.O., Dawid A.P., and Smith A.F.M. (Eds.), *Bayesian Statistics*, Vol. 6, Oxford University Press, pp. 743–752.
- [3] Liu J.S. and Chen R. 1995. Blind deconvolution via sequential imputation. *Journal of the American Statistical Association* 90: 567–576.
- [4] Pitt M.K. and Shephard N. 1999. Filtering via simulation: Auxiliary particle filters. *Journal of the American Statistical Association* 94: 590–599.
- [5] Godsill S.J. and Rayner P.J.W. 1998. *Digital audio restoration—A statistical model-based approach*. Berlin: Springer-Verlag.
- [6] Jazwinski A.H. 1970. *Stochastic Processes and Filtering Theory*. Academic Press.
- [7] Anderson B.D.O. and Moore J.B. 1979. *Optimal Filtering*. Englewood Cliffs.
- [8] Akashi H. and Kumamoto H. 1975. Construction of discrete-time nonlinear filter by Monte Carlo methods with variance-reducing techniques. *Systems and Control* 19: 211–221 (in Japanese).
- [9] Handschin J.E. and Mayne D.Q. 1969. Monte Carlo techniques to estimate the conditional expectation in multi-stage non-linear filtering. *International Journal of Control* 9: 547–559.
- [10] Handschin J.E. 1970. Monte Carlo techniques for prediction and filtering of non-linear stochastic processes. *Automatica* 6: 555–563.
- [11] Zaritskii V.S., Svetnik V.B., and Shimelevich L.I. 1975. Monte Carlo technique in problems of optimal data processing. *Automation and Remote Control* 12: 95–103.
- [12] Kitagawa G. 1987. Non-Gaussian state-space modeling of nonstationary time series. *Journal of the American Statistical Association* 82: 1032–1063.
- [13] Müller P. 1992. Posterior integration in dynamic models. *Computing Science and Statistics* 24: 318–324.
- [14] West M. 1993. Mixtures models, Monte Carlo, Bayesian updating and dynamic models. *Computer Science and Statistics* 24: 325–333.
- [15] Kong A., Liu J.S., and Wong W.H. 1994. Sequential imputations and Bayesian missing data problems. *Journal of the American Statistical Association* 89: 278–288.
- [16] Liu J.S. and Chen R. 1998. Sequential Monte Carlo methods for dynamic systems. *Journal of the American Statistical Association* 93: 1032–1044.
- [17] Doucet A. 1997. Monte Carlo methods for Bayesian estimation of hidden Markov models. Application to radiation signals. Ph.D. Thesis, University Paris-Sud Orsay (in French).

- [18] Doucet A. 1998. On sequential simulation-based methods for Bayesian filtering. Technical Report, University of Cambridge, Dept. of Engineering, CUED-F-ENG-TR310. Available on the MCMC preprint service at <http://www.stats.bris.ac.uk/MCMC/>.
- [19] Geweke J. 1989. Bayesian inference in Econometrics models using Monte Carlo integration. *Econometrica* 57: 1317–1339.
- [20] Akashi H. and Kumamoto H. 1977. Random sampling approach to state estimation in switching environments. *Automatica* 13: 429–434.
- [21] Chen R. and Liu J.S. 1996. Predictive updating methods with application to Bayesian classification. *Journal of the Royal Statistical Society B* 58: 397–415.
- [22] Berzuini C., Best N., Gilks W., and Larizza C. 1997. Dynamic conditional independence models and markov chain Monte Carlo methods. *Journal of the American Statistical Association* 92: 1403–1412.
- [23] West M. and Harrison J.F. 1997. Bayesian forecasting and dynamic models, 2nd edn. Springer Verlag Series in Statistics.
- [24] Tanizaki H. and Mariano R.S. 1998. Nonlinear and non-Gaussian state-space modeling with Monte-Carlo simulations. *Journal of Econometrics* 83: 263–290.
- [25] Tanizaki H. 1993. *Nonlinear Filters: Estimation and Applications*. Springer. Berlin, Lecture Notes in Economics and Mathematical Systems, Vol. 400.
- [26] Tanizaki H. and Mariano R.S. 1994. Prediction, filtering and smoothing in non-linear and non-normal cases using Monte Carlo integration. *Journal of Applied Econometrics* 9: 163–179.
- [27] Liu J.S. 1996. Metropolized independent sampling with comparison to rejection sampling and importance sampling. *Statistics and Computing* 6: 113–119.
- [28] Rubin D.B. 1988. Using the SIR algorithm to simulate posterior distributions. In: Bernardo J.M., DeGroot M.H., Lindley D.V., and Smith A.F.M. (Eds.), *Bayesian Statistics*, Vol. 3, Oxford University Press. 395–402.
- [29] Ripley B.D. 1987. *Stochastic Simulation*. New York, Wiley.
- [30] Carpenter J., Clifford P., and Fearnhead P. 1997. An improved particle filter for nonlinear problems. Technical Report, University of Oxford, Dept. of Statistics.
- [31] Kitagawa G. and Gersch G. 1996. *Smoothness Priors Analysis of Time Series*. Springer. Lecture Notes in Statistics, Vol. 116.
- [32] Higuchi T. 1997. Monte Carlo filtering using the genetic algorithm operators. *Journal of Statistical Computation and Simulation* 59: 1–23.
- [33] Casella G. and Robert C.P. 1996. Rao-Blackwellisation of sampling schemes. *Biometrika* 83: 81–94.
- [34] MacEachern S.N., Clyde M., and Liu J.S. 1999. Sequential importance sampling for nonparametric Bayes models: The next generation. *Canadian Journal of Statistics* 27: 251–267.

- [35] Tugnait J.K. 1982. Detection and Estimation for abruptly changing systems. *Automatica* 18: 607–615.
- [36] Svetnik V.B. 1986. Applying the Monte Carlo method for optimum estimation in systems with random disturbances. *Automation and Remote Control* 47: 818–825.
- [37] Billio M. and Monfort A. 1998. Switching state-space models: Likelihood function, filtering and smoothing. *Journal of Statistical Planning and Inference* 68: 65–103.
- [38] Gordon N.J. 1997. A hybrid bootstrap filter for target tracking in clutter. *IEEE Transactions on Aerospace and Electronic Systems* 33: 353–358.
- [39] Müller P. 1991. Monte Carlo integration in general dynamic models. *Contemporary Mathematics* 115: 145–163.
- [40] Smith A.F.M. and Gelfand A.E. 1992. Bayesian statistics without tears: A sampling-resampling perspective. *The American Statistician* 46: 84–88.
- [41] Stewart L. and McCarty P. 1992. The use of Bayesian belief networks to fuse continuous and discrete information for target recognition, tracking and situation assessment. *Proceeding Conference SPIE* 1699: 177–185.