

通过生成式预训练提升语言理解能力

Improving Language Understanding
by Generative Pre-Training

Alec Radford Karthik Narasimhan

Tim Salimans Ilya Sutskever

OpenAI

Alec Radford alec@openai.com

Karthik Narasimhan karthikn@openai.com

Tim Salimans tim@openai.com

Ilya Sutskever ilyasu@openai.com

摘要

自然语言理解涵盖众多不同任务，例如文本蕴含、问答、语义相似度评估和文档分类。虽然大规模无标注文本语料十分丰富，但用于学习这些具体任务的标注数据仍然稀缺，这使得以判别式方式训练的模型难以取得足够好的表现。我们表明，先在多样化的无标注文本语料上对语言模型进行生成式预训练，再针对每个具体任务进行判别式微调，可以在这些任务上获得大幅提升。与以往方法不同，我们在微调时采用面向任务的输入变换，在仅需对模型架构作极少修改的情况下实现有效迁移。我们在广泛的自然语言理解基准上验证了这一方法的有效性。我们提出的通用、任务无关模型，优于那些为每个任务专门设计架构并以判别式方式训练的模型，在研究的 12 个任务中的 9 个上显著提升了最佳水平。例如，我们在常识推理（Stories Cloze Test）、问答（RACE）和文本蕴含（MultiNLI）上分别取得了 8.9%、5.7% 和 1.5% 的绝对提升。

预印本。研究工作仍在进行中。

1 引言

有效地从原始文本中学习，是减轻自然语言处理（NLP）对监督学习依赖的关键。多数深度学习方法需要大量人工标注数据，这限制了它们在许多缺乏标注资源的领域中的适用性 [61]。在这种情况下，能够从无标注数据中利用语言信息的模型，为收集更多标注提供了一种有价值的替代方案，因为后者可能既耗时又昂贵。此外，即使有相当丰富的监督信息，以无监督方式学习良好表示仍然可以显著提升性能。迄今最有说服力的证据，是预训练词嵌入 [10, 39, 42] 已被广泛用于提升一系列 NLP 任务的性能 [8, 11, 26, 45]。

然而，从无标注文本中利用超越词级的信息，主要面临两个挑战。首先，尚不清楚哪类优化目标最能有效学到有助于迁移的文本表示。近期研究考察了语言建模 [44]、机器翻译 [38] 和篇章连贯性 [22] 等不同目标，但不同方法在不同任务上各有所长¹。其次，对于如何最有效地将这些学到的表示迁移到目标任务，目前尚无共识。现有技术结合了多种做法，包括对模型架构作任务特定的修改 [43, 44]、使用复杂的学习方案 [21]，以及添加辅助学习目标 [50]。这些不确定性使得开发有效的半监督语言处理方法变得困难。

本文探索一种面向语言理解任务的半监督方法，将无监督预训练与有监督微调相结合。我们的目标是学习一种通用表示，使其只需少量适配就能迁移到广泛的任务。我们假设可以获得一个大规模无标注文本语料，以及若干包含人工标注训练样本的数据集（目标任务）。我们的设置不要求这些目标任务与无标注语料属于同一领域。我们采用两阶段训练流程：首先，在无标注数据上使用语言建模目标，学习神经网络模型的初始参数；随后，利用相应的监督目标，将这些参数适配到目标任务。

模型架构采用 *Transformer* [62]，它已在机器翻译 [62]、文档生成 [34] 和句法分析 [29] 等多种任务中展现出强大性能。与循环网络等替代方案相比，这一模型选择为我们提供了更具结构性的记忆，以处理文本中的长期依赖，从而在多样化任务上获得稳健的迁移性能。迁移时，我们采用由遍历式方法 [52] 衍生的任务特定输入适配，将结构化文本输入处理为单一、连续的词元序列。正如实验所示，这些适配使我们只需对预训练模型架构作极少改动，就能进行有效微调。

我们在四类语言理解任务上评估该方法：自然语言推理、问答、语义相似度和文本分类。我们提出的通用、任务无关模型，优于采用为各任务专门设计架构的判别式训练模型，在研究的 12 个任务中的 9 个上显著提升了最佳水平。例如，在常识推理 (Stories Cloze Test) [40]、问答 (RACE) [30]、文本蕴含 (MultiNLI) [66] 以及近期提出的 GLUE 多任务基准 [64] 上，我们分别取得了 8.9%、5.7%、1.5% 和 5.5% 的绝对提升。我们还分析了预训练模型在四种不同设置下的零样本行为，表明它获得了对下游任务有用的语言知识。

2 相关工作

面向 NLP 的半监督学习 我们的工作总体上属于自然语言半监督学习范畴。这一范式已引起广泛关注，并应用于序列标注 [24, 33, 57] 和文本分类 [41, 70] 等任务。早期方法利用无标注数据计算词级或短语级统计量，再将其用作监督模型的特征 [33]。过去几年中，研究者证明了使用在无标注语料上训练的词嵌入 [11, 39, 42]，能够提高多种任务的性能 [8, 11, 26, 45]。然而，这些方法主要迁移词级信息，而我们希望捕获更高层次的语义。

近期方法开始研究从无标注数据中学习并利用超越词级的语义。可以利用无标注语料训练的短语级或句子级嵌入，已被用于将文本编码成适用于不同目标任务的向量表示 [28, 32, 1, 36, 22, 12, 56, 31]。

¹<https://gluebenchmark.com/leaderboard>

无监督预训练 无监督预训练是半监督学习的一种特殊情形，其目标是寻找良好的初始化点，而不是修改监督学习目标。早期工作探索了这一技术在图像分类 [20, 49, 63] 和回归任务 [3] 中的应用。后续研究 [15] 表明，预训练起到正则化方案的作用，使神经网络具有更好的泛化能力。近期，这一方法已被用于辅助训练多种任务上的神经网络，例如图像分类 [69]、语音识别 [68]、实体消歧 [17] 和机器翻译 [48]。

与我们的工作最接近的一类研究，是使用语言建模目标预训练神经网络，再利用监督信息在目标任务上微调。Dai 等人 [13] 以及 Howard 和 Ruder [21] 采用这种方法改进文本分类。然而，尽管预训练阶段有助于捕获部分语言信息，他们使用 LSTM 模型，限制了其预测能力所能覆盖的距离。相比之下，如实验所示，我们选择 Transformer 网络，能够捕获距离更长的语言结构。此外，我们还在更广泛的任务上展示了模型的有效性，包括自然语言推理、复述检测和故事补全。其他方法 [43, 44, 38] 在训练目标任务的监督模型时，将预训练语言模型或机器翻译模型的隐藏表示作为辅助特征。这需要为每个独立的目标任务引入大量新参数，而我们在迁移时仅需对模型架构作极少修改。

辅助训练目标 添加辅助性的无监督训练目标，是半监督学习的另一种形式。Collobert 和 Weston 的早期工作 [10] 使用了多种辅助 NLP 任务，例如词性标注、组块分析、命名实体识别和语言建模，以改进语义角色标注。近期，Rei [50] 在目标任务的目标函数上添加辅助语言建模目标，并在序列标注任务上获得了性能提升。我们的实验同样使用辅助目标，但正如我们将展示的，无监督预训练本身已经学会了与目标任务相关的若干语言特征。

3 框架

训练流程包含两个阶段。第一阶段是在大规模文本语料上学习一个高容量语言模型。随后进入微调阶段，使用带标注的数据，将模型适配到判别式任务。

3.1 无监督预训练

给定无监督词元语料 $\mathcal{U} = \{u_1, \dots, u_n\}$ ，我们使用标准语言建模目标，最大化以下似然：

$$L_1(\mathcal{U}) = \sum_i \log P(u_i \mid u_{i-k}, \dots, u_{i-1}; \Theta) \quad (1)$$

其中， k 为上下文窗口大小，条件概率 P 由参数为 Θ 的神经网络建模。这些参数通过随机梯度下降 [51] 训练。

实验中，我们使用多层 *Transformer* 解码器 [34] 作为语言模型，它是 Transformer [62] 的一种变体。该模型对输入上下文词元执行多头自注意力操作，然后通过逐位置前馈层，产生目标词元的

输出分布：

$$\begin{aligned} h_0 &= UW_e + W_p \\ h_l &= \text{transformer_block}(h_{l-1}) \quad \forall l \in [1, n] \\ P(u) &= \text{softmax}(h_n W_e^T) \end{aligned} \quad (2)$$

其中， $U = (u_{-k}, \dots, u_{-1})$ 是词元的上下文向量， n 为层数， W_e 为词元嵌入矩阵， W_p 为位置嵌入矩阵。

3.2 有监督微调

使用式 (1) 中的目标训练模型后，我们将参数适配到有监督的目标任务。假设有一个带标注的数据集 $\mathcal{C}$ ，其中每个样本由输入词元序列 $x^1, \dots, x^m$ 及标签 y 组成。输入经过预训练模型，得到最后一个 Transformer 块的激活 h_l^m ，再将其送入新增的、参数为 W_y 的线性输出层，以预测 y ：

$$P(y \mid x^1, \dots, x^m) = \text{softmax}(h_l^m W_y). \quad (3)$$

由此得到下述需要最大化的目标：

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y \mid x^1, \dots, x^m). \quad (4)$$

我们还发现，在微调时将语言建模纳入辅助目标，可以通过以下两方面促进学习：(a) 改善监督模型的泛化能力；(b) 加快收敛。这与以往工作 [50, 43] 一致，后者也观察到了此类辅助目标带来的性能提升。具体而言，我们优化下述目标，其中权重为 λ ：

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C}) \quad (5)$$

总体而言，微调时唯一需要的额外参数是 W_y ，以及分隔词元的嵌入（见下文第 3.3 节）。

3.3 任务特定的输入变换

对于文本分类等任务，可以直接按上述方式微调模型。另一些任务，例如问答或文本蕴含，其输入具有结构性，如有序句子对，或由文档、问题和答案构成的三元组。由于预训练模型是在连续文本序列上训练的，要将其应用于这些任务，需要作一些修改。以往工作提出，在迁移得到的表示之上学习任务特定的架构 [44]。这种方法重新引入了大量任务特定的定制，而这些额外的架构组件并未利用迁移学习。我们转而采用遍历式方法 [52]，将结构化输入转换成预训练模型可以处理的有序序列。这些输入变换使我们避免了在不同任务之间对架构作大幅修改。下文简要介绍这些变换，图 1 给出了直观说明。所有变换都会添加随机初始化的起始和结束词元 ($\langle s \rangle$ 、 $\langle e \rangle$)。

文本蕴含 对于蕴含任务，我们将前提 p 与假设 h 的词元序列拼接起来，在两者之间加入分隔词元 ($\$$)。




图 1. 左：本文使用的 Transformer 架构与训练目标。右：针对不同任务进行微调时的输入变换。我们把所有结构化输入转换成词元序列，交由预训练模型处理，然后接上线性层与 softmax 层。

相似度 在相似度任务中，被比较的两个句子没有内在的先后顺序。为体现这一点，我们修改输入序列，使其包含两种可能的句子顺序（中间加入分隔符），并分别独立处理，得到两个序列表示 h_l^m 。将这两个表示逐元素相加后，再送入线性输出层。

问答与常识推理 对于这些任务，给定上下文文档 z 、问题 q 和候选答案集合 $\{a_k\}$ 。我们将文档上下文和问题分别与每个候选答案拼接，在中间添加分隔词元，得到 $[z; q; \$; a_k]$ 。模型独立处理每条序列，然后通过 softmax 层归一化，产生候选答案上的输出分布。

4 实验

4.1 设置

无监督预训练 我们使用 BooksCorpus 数据集 [71] 训练语言模型。该数据集包含超过 7000 本不同的未出版书籍，涵盖冒险、奇幻、爱情等多种体裁。关键在于，它包含长段连续文本，使生成模型能够学习以长距离信息为条件进行建模。另一种数据集是 1B Word Benchmark，类似方法 ELMo [44] 使用了它；其规模大致相同，但在句子级进行了打乱，破坏了长距离结构。我们的语言模型在该语料上取得了低至 18.4 的词元级困惑度。

模型规格 我们的模型基本沿用最初的 Transformer 工作 [62]。我们训练了一个仅含解码器的 12 层 Transformer，采用带掩码的自注意力头（状态维度为 768，注意力头数为 12）。逐位置前馈网络的内部状态维度为 3072。我们使用 Adam 优化方案 [27]，最大学习率为 $2.5e-4$ 。学习率在前 2000 次更新中从零线性增加，然后按余弦调度退火至 0。我们训练 100 个轮次，每个小批次由随机抽样的 64 条连续序列组成，每条序列包含 512 个词元。由于整个模型广泛使用层归一化 [2]，简单地

表 1. 实验中使用的不同任务与数据集。

任务	数据集
自然语言推理	SNLI [5], MultiNLI [66], Question NLI [64], RTE [4], SciTail [25]
问答	RACE [30], Story Cloze [40]
句子相似度	MSR Paraphrase Corpus [14], Quora Question Pairs [9], STS Benchmark [6]
分类	Stanford Sentiment Treebank-2 [54], CoLA [65]

以 $N(0, 0.02)$ 初始化权重就已足够。我们采用经过 40000 次合并的字节对编码 (BPE) 词表 [53], 并对残差、嵌入和注意力应用比例为 0.1 的 `dropout`, 以进行正则化。我们还采用文献 [37] 提出的改进版 L2 正则化, 对所有非偏置、非增益权重设置 $w = 0.01$ 。激活函数使用高斯误差线性单元 (GELU) [18]。我们使用可学习的位置嵌入, 而非原工作提出的正弦版本。我们使用 *ftfy* 库²清理 BooksCorpus 中的原始文本, 规范部分标点和空白, 并使用 *spaCy* 分词器³。

微调细节 除非另有说明, 我们复用无监督预训练阶段的超参数设置。在分类器中加入比例为 0.1 的 `dropout`。对于多数任务, 我们采用 $6.25e-5$ 的学习率和 32 的批大小。模型微调很快, 多数情况下训练 3 个轮次就已足够。我们采用线性学习率衰减方案, 并在训练开始的 0.2% 阶段进行预热。 λ 设为 0.5。

4.2 有监督微调

我们在多种有监督任务上开展实验, 包括自然语言推理、问答、语义相似度和文本分类。其中一些任务属于近期发布的 GLUE 多任务基准 [64], 我们使用了该基准。图 1 提供了所有任务和数据集的概览。

自然语言推理 自然语言推理 (NLI) 也称为文本蕴含识别, 要求阅读一对句子, 并将两者关系判断为蕴含、矛盾或中立之一。尽管近期该任务受到广泛关注 [58, 35, 44], 但由于存在词汇蕴含、共指, 以及词汇和句法歧义等多种现象, 它仍然具有挑战性。我们在五个来源多样的数据集上评估, 包括图像描述 (SNLI), 语音转录、通俗小说和政府报告 (MNLI), 维基百科文章 (QNLI), 科学考试 (SciTail), 以及新闻文章 (RTE)。

表 2 详细列出了我们的模型与以往最佳方法在不同 NLI 任务上的结果。我们的方法在五个数据集上的四个上显著超过基线, 相对于此前最佳结果, 在 MNLI、SciTail、QNLI 和 SNLI 上分别取得了最高 1.5%、5%、5.8% 和 0.6% 的绝对提升。这表明, 我们的模型能够更好地对多个句子进行推理, 并处理语言歧义的若干方面。RTE 是评估中较小的数据集之一 (2490 个样本), 我们在其上取得了 56% 的准确率, 低于多任务 biLSTM 模型报告的 61.7%。考虑到我们的方法在更大规模 NLI

²<https://ftfy.readthedocs.io/en/latest/>

³<https://spacy.io/>

数据集上的强劲表现，模型很可能也会受益于多任务训练，但目前我们尚未对此展开探索。

表 2. 自然语言推理任务的实验结果：将本文模型与当前最佳方法比较。5x 表示由 5 个模型组成的集成。所有数据集均以准确率为评价指标。

方法	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	<u>89.3</u>	-	-	-
CAFE [58] (5x)	80.2	79.0	<u>89.3</u>	-	-	-
Stochastic Answer Network [35] (3x)	<u>80.6</u>	<u>80.1</u>	-	-	-	-
CAFE [58]	78.7	77.9	88.5	<u>83.3</u>	-	-
GenSen [64]	71.4	71.3	-	-	<u>82.3</u>	59.2
多任务 BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	61.7
微调 Transformer LM (本文)	82.1	81.4	89.9	88.3	88.1	56.0

表 3. 问答与常识推理结果：将本文模型与当前最佳方法比较。9x 表示由 9 个模型组成的集成。

方法	Story Cloze	RACE-m	RACE-h	RACE
val-LS-skip [55]	76.5	-	-	-
Hidden Coherence Model [7]	<u>77.6</u>	-	-	-
Dynamic Fusion Net [67] (9x)	-	55.6	49.4	51.2
BiAttention MRU [59] (9x)	-	<u>60.2</u>	<u>50.3</u>	<u>53.3</u>
微调 Transformer LM (本文)	86.5	62.9	57.4	59.0

问答与常识推理 问答是另一类需要单句和多句推理能力的任务。我们使用近期发布的 RACE 数据集 [30]，它由初中和高中考试中的英语篇章及相关问题组成。已有研究表明，与 CNN[19] 或 SQuAD[47] 等数据集相比，该语料包含更多推理型问题，因此非常适合评估我们这种被训练来处理长距离上下文的模型。此外，我们还在 Story Cloze Test[40] 上进行评估，该任务要求从两个选项中为多句故事选择正确结尾。在这些任务上，我们的模型再次大幅超越此前最佳结果：Story Cloze 上最高提升 8.9%，RACE 总体提升 5.7%。这表明模型能够有效处理长距离上下文。

语义相似度 语义相似度（或复述检测）任务要求预测两个句子在语义上是否等价。其挑战在于识别概念的不同表述、理解否定，以及处理句法歧义。我们为任务使用了三个数据集：从新闻来源收集的 Microsoft Paraphrase Corpus (MRPC) [14]、Quora Question Pairs (QQP) [9]，以及 Semantic Textual Similarity Benchmark (STS-B) [6]。我们在三个语义相似度任务中的两个上获得

了最佳结果（表 4），其中 STS-B 的绝对增益为 1 分。QQP 上的性能差距也很显著，相对于单任务 BiLSTM + ELMo + Attn，绝对提升达到 4.2%。

分类 最后，我们还评估了两种不同的文本分类任务。Corpus of Linguistic Acceptability (CoLA) [65] 包含专家对句子是否符合语法的判断，用于检验训练后模型内在的语言偏置。另一方面，Stanford Sentiment Treebank (SST-2) [54] 是一项标准的二分类任务。我们的模型在 CoLA 上得到 45.4 分，相对于此前最佳的 35.0 分有特别显著的提升，体现了模型学到的内在语言偏置。模型在 SST-2 上还取得了 91.3% 的准确率，与最佳结果具有竞争力。我们在 GLUE 基准上获得了 72.8 的总体得分，显著优于此前最佳的 68.9。

表 4. 语义相似度与分类结果：将本文模型与当前最佳方法比较。本表所有任务均通过 GLUE 基准评估。（*mc*: Mathews 相关系数，*acc*: 准确率，*pc*: Pearson 相关系数。）

方法	分类		语义相似度			GLUE
	CoLA	SST2	MRPC	STSB	QQP	
	(<i>mc</i>)	(<i>acc</i>)	(F1)	(<i>pc</i>)	(F1)	
Sparse byte mLSTM [16]	-	93.2	-	-	-	-
TF-KLD [23]	-	-	86.0	-	-	-
ECNU (混合集成) [60]	-	-	-	<u>81.0</u>	-	-
单任务 BiLSTM + ELMo + Attn [64]	<u>35.0</u>	90.2	80.2	55.5	<u>66.1</u>	64.8
多任务 BiLSTM + ELMo + Attn [64]	18.9	91.6	83.5	72.8	63.3	<u>68.9</u>
微调 Transformer LM (本文)	45.4	91.3	82.3	82.0	70.3	72.8

总体而言，我们的方法在评估的 12 个数据集中的 9 个上达到了新的最佳水平，并在许多情况下超越了集成模型。结果还表明，该方法在不同规模的数据集上都表现良好，从 STS-B 这样较小的数据集（约 5.7 千个训练样本），到最大的 SNLI（约 55 万个训练样本），均是如此。

5 分析

迁移层数的影响 我们考察了将不同数量的层从无监督预训练迁移到有监督目标任务时的影响。图 2（左）展示了该方法在 MultiNLI 和 RACE 上的性能随迁移层数的变化。我们观察到了通常预期的结果：迁移嵌入会提高性能，而每个 Transformer 层都能带来进一步收益，在 MultiNLI 上完整迁移时，提升最高可达 9%。这表明，预训练模型中的每一层都包含有助于解决目标任务的功能。

零样本行为 我们希望更好地理解，为什么对 Transformer 进行语言模型预训练是有效的。一种假设是：为了提升语言建模能力，底层生成模型学会了执行我们评估的许多任务；而与 LSTM 相比，




图 2. 左：从预训练语言模型迁移越来越多的层，对 RACE 和 MultiNLI 的影响。右：不同任务的零样本性能随语言模型预训练更新次数的变化。每个任务的性能在随机猜测基线与当前单模型最佳水平之间进行归一化。

Transformer 更具结构性的注意力记忆有助于迁移。我们设计了一系列启发式方案，利用底层生成模型，在不进行有监督微调的情况下执行任务。图 2（右）展示了这些启发式方案在生成式预训练过程中的有效性。我们观察到，这些启发式方法的性能稳定，并随着训练持续提高，这表明生成式预训练支持学习多种与任务相关的功能。我们还观察到 LSTM 的零样本性能方差更大，这说明 Transformer 架构的归纳偏置有助于迁移。

对于 CoLA（语言可接受性），我们以生成模型赋予样本的平均词元对数概率作为分数，通过设定阈值作出预测。对于 SST-2（情感分析），我们在每个样本之后追加词元 *very*，并将语言模型的输出分布限制在 *positive* 和 *negative* 两个词上，以模型赋予概率更高的词元作为预测。对于 RACE（问答），我们选择在给定文档和问题的条件下，生成模型赋予最高平均词元对数概率的答案。对于 DPRD[46]（Winograd 图式），我们分别用两个可能的指代对象替换定指代词，并选择这样一种消解：替换之后，生成模型对序列其余部分赋予的平均词元对数概率更高。

表 5. 不同任务上的模型消融分析。平均分为所有结果的未加权平均。（*mc*: Mathews 相关系数, *acc*: 准确率, *pc*: Pearson 相关系数。）

方法	平均分	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	MNLI (acc)	QNLI (acc)	RTE (acc)
Transformer + 辅助 LM (完整)	74.7	45.4	91.3	82.3	82.0	70.3	81.8	88.1	56.0
Transformer, 无预训练	59.9	18.9	84.0	79.4	30.9	65.5	75.7	71.2	53.8
Transformer, 无辅助 LM	75.0	47.9	92.0	84.9	83.2	69.8	81.1	86.9	54.4
LSTM + 辅助 LM	69.1	30.3	90.5	83.2	71.8	68.1	73.7	81.1	54.6

消融研究 我们进行了三项不同的消融研究（表 5）。首先，考察在微调期间不使用辅助语言模型 (LM) 目标时的性能。我们观察到，辅助目标有助于 NLI 任务和 QQP。总体趋势表明，更大的数据集会受益于辅助目标，而较小的数据集不会。其次，我们在同一框架中，将 Transformer 与包含 2048 个单元的单层 LSTM 比较，以分析 Transformer 的作用。使用 LSTM 替代 Transformer 时，平均分下降了 5.6。LSTM 仅在一个数据集 (MRPC) 上优于 Transformer。最后，我们还与不进行预训练、直接在有监督目标任务上训练的 Transformer 架构比较。我们观察到，缺少预训练会损害所有任务的性能，与完整模型相比下降了 14.8%。

6 结论

我们提出了一个框架，通过生成式预训练和判别式微调，使单一的、任务无关的模型获得强大的自然语言理解能力。在包含长段连续文本的多样化语料上进行预训练，使模型获得了丰富的世界知识和处理长距离依赖的能力；这些能力随后成功迁移到问答、语义相似度评估、蕴含判定和文本分类等判别式任务，在研究的 12 个数据集中的 9 个上提升了最佳水平。长期以来，利用无监督（预）训练提升判别式任务性能，一直是机器学习研究的重要目标。我们的工作表明，实现显著的性能增益确实是可能的，并为哪些模型 (Transformer) 和数据集（具有长距离依赖的文本）最适合这种方法提供了线索。我们希望，这能促进自然语言理解及其他领域的无监督学习新研究，进一步加深我们对无监督学习如何起效、何时起效的理解。

参考文献

- [1] S. Arora, Y. Liang, and T. Ma. A simple but tough-to-beat baseline for sentence embeddings. 2016.
- [2] J. L. Ba, J. R. Kiros, and G. E. Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- [3] Y. Bengio, P. Lamblin, D. Popovici, and H. Larochelle. Greedy layer-wise training of deep networks. In *Advances in neural information processing systems*, pages 153–160, 2007.
- [4] L. Bentivogli, P. Clark, I. Dagan, and D. Giampiccolo. The fifth pascal recognizing textual entailment challenge. In *TAC*, 2009.
- [5] S. R. Bowman, G. Angeli, C. Potts, and C. D. Manning. A large annotated corpus for learning natural language inference. *EMNLP*, 2015.
- [6] D. Cer, M. Diab, E. Agirre, I. Lopez-Gazpio, and L. Specia. Semeval-2017 task 1: Semantic textual similarity-multilingual and cross-lingual focused evaluation. *arXiv preprint arXiv:1708.00055*, 2017.
- [7] S. Chaturvedi, H. Peng, and D. Roth. Story comprehension for predicting what happens next. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 1603–1614, 2017.
- [8] D. Chen and C. Manning. A fast and accurate dependency parser using neural networks. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pages 740–750, 2014.
- [9] Z. Chen, H. Zhang, X. Zhang, and L. Zhao. Quora question pairs. <https://data.quora.com/First-Quora-Dataset-Release-Question-Pairs>, 2018.
- [10] R. Collobert and J. Weston. A unified architecture for natural language processing: Deep neural networks with multitask learning. In *Proceedings of the 25th international conference on Machine learning*, pages 160–167. ACM, 2008.
- [11] R. Collobert, J. Weston, L. Bottou, M. Karlen, K. Kavukcuoglu, and P. Kuksa. Natural language processing (almost) from scratch. *Journal of Machine Learning Research*, 12(Aug):2493–2537, 2011.
- [12] A. Conneau, D. Kiela, H. Schwenk, L. Barrault, and A. Bordes. Supervised learning of universal sentence representations from natural language inference data. *EMNLP*, 2017.
- [13] A. M. Dai and Q. V. Le. Semi-supervised sequence learning. In *Advances in Neural Information Processing Systems*, pages 3079–3087, 2015.
- [14] W. B. Dolan and C. Brockett. Automatically constructing a corpus of sentential paraphrases. In *Proceedings of the Third International Workshop on Paraphrasing (IWP2005)*, 2005.
- [15] D. Erhan, Y. Bengio, A. Courville, P.-A. Manzagol, P. Vincent, and S. Bengio. Why does unsupervised pre-training help deep learning? *Journal of Machine Learning Research*, 11(Feb):625–660, 2010.
- [16] S. Gray, A. Radford, and K. P. Diederik. Gpu kernels for block-sparse weights. 2017.
- [17] Z. He, S. Liu, M. Li, M. Zhou, L. Zhang, and H. Wang. Learning entity representation for entity disambiguation. In *Proceedings of the 51st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, volume 2, pages 30–34, 2013.
- [18] D. Hendrycks and K. Gimpel. Bridging nonlinearities and stochastic regularizers with gaussian error linear units. *arXiv preprint arXiv:1606.08415*, 2016.
- [19] K. M. Hermann, T. Kocisky, E. Grefenstette, L. Espeholt, W. Kay, M. Suleyman, and P. Blunsom. Teach-

- ing machines to read and comprehend. In *Advances in Neural Information Processing Systems*, pages 1693–1701, 2015.
- [20] G. E. Hinton, S. Osindero, and Y.-W. Teh. A fast learning algorithm for deep belief nets. *Neural computation*, 18(7):1527–1554, 2006.
- [21] J. Howard and S. Ruder. Universal language model fine-tuning for text classification. *Association for Computational Linguistics (ACL)*, 2018.
- [22] Y. Jernite, S. R. Bowman, and D. Sontag. Discourse-based objectives for fast unsupervised sentence representation learning. *arXiv preprint arXiv:1705.00557*, 2017.
- [23] Y. Ji and J. Eisenstein. Discriminative improvements to distributional sentence similarity. In *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing*, pages 891–896, 2013.
- [24] F. Jiao, S. Wang, C.-H. Lee, R. Greiner, and D. Schuurmans. Semi-supervised conditional random fields for improved sequence segmentation and labeling. In *Proceedings of the 21st International Conference on Computational Linguistics and the 44th annual meeting of the Association for Computational Linguistics*, pages 209–216. Association for Computational Linguistics, 2006.
- [25] T. Khot, A. Sabharwal, and P. Clark. Scitail: A textual entailment dataset from science question answering. In *Proceedings of AAAI*, 2018.
- [26] Y. Kim. Convolutional neural networks for sentence classification. *EMNLP*, 2014.
- [27] D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [28] R. Kiros, Y. Zhu, R. R. Salakhutdinov, R. Zemel, R. Urtasun, A. Torralba, and S. Fidler. Skip-thought vectors. In *Advances in neural information processing systems*, pages 3294–3302, 2015.
- [29] N. Kitaev and D. Klein. Constituency parsing with a self-attentive encoder. *ACL*, 2018.
- [30] G. Lai, Q. Xie, H. Liu, Y. Yang, and E. Hovy. Race: Large-scale reading comprehension dataset from examinations. *EMNLP*, 2017.
- [31] G. Lample, L. Denoyer, and M. Ranzato. Unsupervised machine translation using monolingual corpora only. *ICLR*, 2018.
- [32] Q. Le and T. Mikolov. Distributed representations of sentences and documents. In *International Conference on Machine Learning*, pages 1188–1196, 2014.
- [33] P. Liang. *Semi-supervised learning for natural language*. PhD thesis, Massachusetts Institute of Technology, 2005.
- [34] P. J. Liu, M. Saleh, E. Pot, B. Goodrich, R. Sepassi, L. Kaiser, and N. Shazeer. Generating wikipedia by summarizing long sequences. *ICLR*, 2018.
- [35] X. Liu, K. Duh, and J. Gao. Stochastic answer networks for natural language inference. *arXiv preprint arXiv:1804.07888*, 2018.
- [36] L. Logeswaran and H. Lee. An efficient framework for learning sentence representations. *ICLR*, 2018.
- [37] I. Loshchilov and F. Hutter. Fixing weight decay regularization in adam. *arXiv preprint arXiv:1711.05101*, 2017.
- [38] B. McCann, J. Bradbury, C. Xiong, and R. Socher. Learned in translation: Contextualized word vectors. In *Advances in Neural Information Processing Systems*, pages 6297–6308, 2017.

- [39] T. Mikolov, I. Sutskever, K. Chen, G. S. Corrado, and J. Dean. Distributed representations of words and phrases and their compositionality. In *Advances in neural information processing systems*, pages 3111–3119, 2013.
- [40] N. Mostafazadeh, M. Roth, A. Louis, N. Chambers, and J. Allen. Lsdsem 2017 shared task: The story cloze test. In *Proceedings of the 2nd Workshop on Linking Models of Lexical, Sentential and Discourse-level Semantics*, pages 46–51, 2017.
- [41] K. Nigam, A. McCallum, and T. Mitchell. Semi-supervised text classification using em. *Semi-Supervised Learning*, pages 33–56, 2006.
- [42] J. Pennington, R. Socher, and C. Manning. Glove: Global vectors for word representation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pages 1532–1543, 2014.
- [43] M. E. Peters, W. Ammar, C. Bhagavatula, and R. Power. Semi-supervised sequence tagging with bidirectional language models. *ACL*, 2017.
- [44] M. E. Peters, M. Neumann, M. Iyyer, M. Gardner, C. Clark, K. Lee, and L. Zettlemoyer. Deep contextualized word representations. *NAACL*, 2018.
- [45] Y. Qi, D. S. Sachan, M. Felix, S. J. Padmanabhan, and G. Neubig. When and why are pre-trained word embeddings useful for neural machine translation? *NAACL*, 2018.
- [46] A. Rahman and V. Ng. Resolving complex cases of definite pronouns: the winograd schema challenge. In *Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning*, pages 777–789. Association for Computational Linguistics, 2012.
- [47] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang. Squad: 100,000+ questions for machine comprehension of text. *EMNLP*, 2016.
- [48] P. Ramachandran, P. J. Liu, and Q. V. Le. Unsupervised pretraining for sequence to sequence learning. *arXiv preprint arXiv:1611.02683*, 2016.
- [49] M. Ranzato, C. Poultney, S. Chopra, and Y. LeCun. Efficient learning of sparse representations with an energy-based model. In *Advances in neural information processing systems*, pages 1137–1144, 2007.
- [50] M. Rei. Semi-supervised multitask learning for sequence labeling. *ACL*, 2017.
- [51] H. Robbins and S. Monro. A stochastic approximation method. *The annals of mathematical statistics*, pages 400–407, 1951.
- [52] T. Rocktäschel, E. Grefenstette, K. M. Hermann, T. Kočiský, and P. Blunsom. Reasoning about entailment with neural attention. *arXiv preprint arXiv:1509.06664*, 2015.
- [53] R. Sennrich, B. Haddow, and A. Birch. Neural machine translation of rare words with subword units. *arXiv preprint arXiv:1508.07909*, 2015.
- [54] R. Socher, A. Perelygin, J. Wu, J. Chuang, C. D. Manning, A. Ng, and C. Potts. Recursive deep models for semantic compositionality over a sentiment treebank. In *Proceedings of the 2013 conference on empirical methods in natural language processing*, pages 1631–1642, 2013.
- [55] S. Srinivasan, R. Arora, and M. Riedl. A simple and effective approach to the story cloze test. *arXiv preprint arXiv:1803.05547*, 2018.
- [56] S. Subramanian, A. Trischler, Y. Bengio, and C. J. Pal. Learning general purpose distributed sentence representations via large scale multi-task learning. *arXiv preprint arXiv:1804.00079*, 2018.

- [57] J. Suzuki and H. Isozaki. Semi-supervised sequential labeling and segmentation using giga-word scale unlabeled data. *Proceedings of ACL-08: HLT*, pages 665–673, 2008.
- [58] Y. Tay, L. A. Tuan, and S. C. Hui. A compare-propagate architecture with alignment factorization for natural language inference. *arXiv preprint arXiv:1801.00102*, 2017.
- [59] Y. Tay, L. A. Tuan, and S. C. Hui. Multi-range reasoning for machine comprehension. *arXiv preprint arXiv:1803.09074*, 2018.
- [60] J. Tian, Z. Zhou, M. Lan, and Y. Wu. Ecnv at semeval-2017 task 1: Leverage kernel-based traditional nlp features and neural networks to build a universal model for multilingual and cross-lingual semantic textual similarity. In *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017)*, pages 191–197, 2017.
- [61] Y. Tsvetkov. Opportunities and challenges in working with low-resource languages. *CMU*, 2017.
- [62] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 6000–6010, 2017.
- [63] P. Vincent, H. Larochelle, Y. Bengio, and P.-A. Manzagol. Extracting and composing robust features with denoising autoencoders. In *Proceedings of the 25th international conference on Machine learning*, pages 1096–1103. ACM, 2008.
- [64] A. Wang, A. Singh, J. Michael, F. Hill, O. Levy, and S. R. Bowman. Glue: A multi-task benchmark and analysis platform for natural language understanding. *arXiv preprint arXiv:1804.07461*, 2018.
- [65] A. Warstadt, A. Singh, and S. R. Bowman. Corpus of linguistic acceptability. <http://nyu-ml1.github.io/cola>, 2018.
- [66] A. Williams, N. Nangia, and S. R. Bowman. A broad-coverage challenge corpus for sentence understanding through inference. *NAACL*, 2018.
- [67] Y. Xu, J. Liu, J. Gao, Y. Shen, and X. Liu. Towards human-level machine reading comprehension: Reasoning and inference with multiple strategies. *arXiv preprint arXiv:1711.04964*, 2017.
- [68] D. Yu, L. Deng, and G. Dahl. Roles of pre-training and fine-tuning in context-dependent dbn-hmms for real-world speech recognition. In *Proc. NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2010.
- [69] R. Zhang, P. Isola, and A. A. Efros. Split-brain autoencoders: Unsupervised learning by cross-channel prediction. In *CVPR*, volume 1, page 6, 2017.
- [70] X. Zhu. Semi-supervised learning literature survey. 2005.
- [71] Y. Zhu, R. Kiros, R. Zemel, R. Salakhutdinov, R. Urtasun, A. Torralba, and S. Fidler. Aligning books and movies: Towards story-like visual explanations by watching movies and reading books. In *Proceedings of the IEEE international conference on computer vision*, pages 19–27, 2015.