

非线性/非高斯贝叶斯状态估计的一种新方法

N. J. Gordon

D. J. Salmond

A. F. M. Smith

IEE Proceedings-F, Vol. 140, No. 2, April 1993

重建说明。本文档由扫描版 PDF 重建为可编辑的现代 TeX，并非出版社官方源码；公式、图和参考文献均按扫描页核对。

索引词: *Kalman filter*, *Sequential estimation*, *Bayesian filter*

摘要

本文提出一种用于实现递归贝叶斯滤波的算法，即 *bootstrap filter*。所需的状态向量密度由一组随机样本表示，这些样本由算法进行更新和传播。该方法不受线性或高斯噪声假设的限制，可用于任意状态转移模型或测量模型。文中给出了 *bearings-only tracking* 问题的仿真实例。该仿真还包含若干提高基本算法效率的方案。在该例中，*bootstrap filter* 的性能显著优于标准扩展 Kalman 滤波器。

出版说明。 Paper 9241F (E5)，首次收到于 1992 年 4 月 27 日，修订稿收到于 1992 年 10 月 8 日。N. J. Gordon 与 D. J. Salmond 当时任职于英国 Farnborough 的 Defence Research Agency；A. F. M. Smith 任职于伦敦 Imperial College 统计系。本文工作得到 DRA Farnborough 支持。

1 引言

贝叶斯方法为动态状态估计问题提供了严格的一般框架。贝叶斯方法的思路，是基于所有可用信息构造状态的概率密度函数 (PDF)。对于线性高斯估计问题，所需 PDF 在滤波器每次迭代中都保持为高斯分布，Kalman 滤波关系则递推并更新该分布的均值和协方差。对于非线性或非高斯问题，通常不存在所需 PDF 的一般解析（闭式）表达。

扩展 Kalman 滤波器 (EKF) 是递归非线性估计中最常用的方法 [1]。在这里，估计问题围绕预测状态线性化，从而可以应用 Kalman 滤波器。在这种情况下，所需 PDF 仍被近似为一个高斯分布；这可能严重扭曲真实的底层结构，并可能导致滤波发散。其他解析近似包括 Gaussian sum filter [2]，以及基于近似密度前两阶矩的方法 [3, 4]。更直接的数值方法是在状态空间中的网格上计算所需 PDF [5–9]。选择高效网格并不容易，而且在多维状态空间中可能需要非常大量的网格点。在每个网格点上都必须进行显著计算。

本文提出一种新的方法，用于表示并递归生成状态 PDF 的近似。核心思想是将所需 PDF 表示为一组随机样本，而不是状态空间上的一个函数 [10–12]。当样本数变得很大时，它们实际上给出了所需 PDF 的一种精确、等价的表示。状态向量 PDF 的矩估计（如均值和协方差）以及分位数估计可以直接从样本得到。如有必要，也可以从样本构造 PDF 的函数估计 [13]，并由此得到最高后验密度（HPD）区间或众数的估计。参考文献 11 提出了一种自适应重要性抽样算法。这会产生大的混合分布，并且该技术计算代价很高。

本文提出并在第 3 节论证一种递归算法，我们称之为 **bootstrap filter**，用于针对离散时间问题（见第 2 节）传播并更新这些样本。该滤波器之所以如此命名，是因为算法的关键更新阶段（Bayes 规则）通过加权 **bootstrap** 实现。这受到 Smith 和 Gelfand [14] 一个结果的启发。Muller [12] 的论文中描述了一种相关算法。这些抽样技术避免了在状态空间中定义网格的需要；样本会自然集中在高概率密度区域。它们还有一个很大的优点，即能够处理任意函数非线性，以及任意分布的系统噪声或测量噪声。

第 4 节给出两个仿真实例。第二个实例是 **bearings-only tracking** 问题。文中将 **bootstrap filter** 的性能与 EKF 的性能进行比较。

2 递归贝叶斯估计

我们关注离散时间估计问题。假设状态向量 $x_k \in \mathbb{R}^n$ 按如下系统模型演化：

$$x_{k+1} = f_k(x_k, w_k) \quad (1)$$

其中 $f_k : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^n$ 是系统转移函数， $w_k \in \mathbb{R}^m$ 是零均值白噪声序列，并且与过去和当前状态独立。假设 w_k 的 PDF 已知。在离散时刻，测量 $y_k \in \mathbb{R}^p$ 可获得。这些测量通过观测方程与状态向量相联系：

$$y_k = h_k(x_k, v_k) \quad (2)$$

其中 $h_k : \mathbb{R}^n \times \mathbb{R}^r \rightarrow \mathbb{R}^p$ 是测量函数， $v_k \in \mathbb{R}^r$ 是另一个具有已知 PDF 的零均值白噪声序列，并且与过去和当前状态以及系统噪声独立。假设状态向量的初始 PDF $p(x_1 | D_0) \equiv p(x_1)$ 已知，同时 $i = 1, \dots, k$ 的函数形式 f_i 和 h_i 也已知。时刻 k 可用的信息是测量集合 $D_k = \{y_i : i = 1, \dots, k\}$ 。

目标是在给定所有可用信息的情况下，构造当前状态 x_k 的 PDF： $p(x_k | D_k)$ 。原则上，该 PDF 可通过两个阶段递归获得：预测和更新。假设时刻 $k-1$ 所需的 PDF $p(x_{k-1} | D_{k-1})$ 已知。那么利用系统模型，可以得到时刻 k 状态的先验 PDF：

$$p(x_k | D_{k-1}) = \int p(x_k | x_{k-1}) p(x_{k-1} | D_{k-1}) dx_{k-1}. \quad (3)$$

这里，状态演化的概率模型 $p(x_k | x_{k-1})$ 是一个 Markov 模型，由系统方程和 w_{k-1} 的已知统计特性定义：

$$p(x_k | x_{k-1}) = \int p(x_k | x_{k-1}, w_{k-1}) p(w_{k-1} | x_{k-1}) dw_{k-1}.$$

由于假设 $p(w_{k-1} | x_{k-1}) = p(w_{k-1})$, 于是有

$$p(x_k | x_{k-1}) = \int \delta(x_k - f_{k-1}(x_{k-1}, w_{k-1})) p(w_{k-1}) dw_{k-1} \quad (4)$$

其中 $\delta(\cdot)$ 是 Dirac delta 函数。之所以出现 delta 函数, 是因为如果 x_{k-1} 和 w_{k-1} 已知, 则 x_k 由纯确定性的关系 (式 (1)) 得到。随后在时刻 k , 测量 y_k 可用, 并可通过 Bayes 规则用于更新先验:

$$p(x_k | D_k) = \frac{p(y_k | x_k) p(x_k | D_{k-1})}{p(y_k | D_{k-1})} \quad (5)$$

其中归一化分母为

$$p(y_k | D_{k-1}) = \int p(y_k | x_k) p(x_k | D_{k-1}) dx_k. \quad (6)$$

给定 x_k 时 y_k 的条件 PDF, 即 $p(y_k | x_k)$, 由测量模型和 v_k 的已知统计特性定义:

$$p(y_k | x_k) = \int \delta(y_k - h_k(x_k, v_k)) p(v_k) dv_k. \quad (7)$$

在更新方程式 (5) 中, 测量 y_k 被用来修正来自前一时间步的预测先验, 从而得到所需的状态后验。

式 (3) 和式 (5) 的递推关系构成了贝叶斯递归估计问题的形式解。对于该问题, 解析解只适用于相对很小且受限的系统和测量模型选择, 其中最重要的是 Kalman 滤波器; 它假设 f_k 和 h_k 是线性的, 且 w_k 和 v_k 是已知方差的加性高斯噪声 (例如见参考文献 15 或 16)。现实性方面的考虑表明, 这些假设对许多应用是不合理的。因此, 需要找到一种实现方法, 使模型能够按现实需要而不是按方便性来构造。

3 贝叶斯 Bootstrap Filter

3.1 滤波算法

假设已有来自 PDF $p(x_{k-1} | D_{k-1})$ 的一组随机样本 $\{x_{k-1}(i) : i = 1, \dots, N\}$ 。Bootstrap filter 是一种传播并更新这些样本的算法, 用以获得一组数值 $\{x_k(i) : i = 1, \dots, N\}$, 它们近似服从 $p(x_k | D_k)$ 。因此, 该滤波器是式 (3) 和式 (5) 中关系的一种近似机械化实现 (仿真)。

预测: 将每个样本通过系统模型, 以获得时刻 k 的先验样本:

$$x_k^*(i) = f_{k-1}(x_{k-1}(i), w_{k-1}(i)),$$

其中 $w_{k-1}(i)$ 是从系统噪声 PDF $p(w_{k-1})$ 中抽取的样本。

更新: 收到测量 y_k 后, 计算每个先验样本的似然, 并为每个样本得到一个归一化权重

$$q_i = \frac{p(y_k | x_k^*(i))}{\sum_{j=1}^N p(y_k | x_k^*(j))}. \quad (8)$$

这样就在 $\{x_k^*(i) : i = 1, \dots, N\}$ 上定义了一个离散分布，其中元素 i 对应的概率质量为 q_i 。现在从该离散分布中重采样 N 次，生成样本 $\{x_k(i) : i = 1, \dots, N\}$ ，使得对任意 j ,

$$\Pr\{x_k(j) = x_k^*(i)\} = q_i.$$

上述预测和更新步骤构成递归算法的一次迭代。为启动算法，从已知先验 $p(x_1)$ 中抽取 N 个样本 $x_1^*(i)$ 。这些样本直接进入滤波器的更新阶段。我们认为样本 $x_k(i)$ 近似服从所需 PDF $p(x_k | D_k)$ 。

3.2 论证

预测：算法的预测阶段在直觉上是合理的。如果 $x_{k-1}(i)$ 是来自 $p(x_{k-1} | D_{k-1})$ 的样本，且 $w_{k-1}(i)$ 是来自 $p(w_{k-1})$ 的样本，那么 $x_k^*(i) = f_{k-1}(x_{k-1}(i), w_{k-1}(i))$ 就按 $p(x_k | D_{k-1})$ 分布。对 N 个样本 $x_{k-1}(i)$ 依次重复这一过程，就得到 $\{x_k^*(i) : i = 1, \dots, N\}$ ，这些值独立地按 $p(x_k | D_{k-1})$ 分布。

更新：更新阶段的论证依赖 Smith 和 Gelfand [14] 的一个结果。他们表明，Bayes 定理可以实现为加权 bootstrap。假设已有来自连续密度函数 $G(x)$ 的样本 $\{x_k^*(i) : i = 1, \dots, N\}$ ，而需要的是从与 $L(x)G(x)$ 成比例的 PDF 中抽样，其中 $L(x)$ 是已知函数。该定理说明：从 $\{x_k^*(i) : i = 1, \dots, N\}$ 上的离散分布抽取一个样本，并在 $x_k^*(i)$ 上赋予概率质量

$$\frac{L(x_k^*(i))}{\sum_j L(x_k^*(j))},$$

则当 N 趋于无穷时，该样本的分布趋于所需密度。如果将 $G(x)$ 识别为 $p(x_k | D_{k-1})$ （先验），并将 $L(x)$ 识别为 $p(y_k | x_k)$ （似然），那么该定理就为更新过程提供了论证。

3.3 讨论

如前所述，该技术的巨大优点在于，它不对函数 f_k 和 h_k ，也不对系统噪声或测量噪声的分布施加限制。唯一要求是：

- (a) $p(x_1)$ 可用于抽样；
- (b) 似然 $p(y_k | x_k)$ 是已知的函数形式；
- (c) $p(w_k)$ 可用于抽样。

此外，基本算法非常简单，也很容易编程。重采样更新阶段通过从 $(0, 1]$ 上的均匀分布抽取随机样本 u_i 来完成。选择与

$$\sum_{j=0}^{M-1} q_j < u_i \leq \sum_{j=0}^M q_j$$

相对应的值 $x_k^*(M)$ 作为后验样本，其中 $q_0 = 0$ 。该过程对 $i = 1, \dots, N$ 重复。将该算法实现在大规模并行计算机上也会相当直接，这带来了使用很大样本集进行实时操作的可能性。

算法输出的是所需后验的一组样本，这对许多应用都很方便。例如，可以通过计算落入任意感兴趣区域内的样本比例，来估计状态落入该区域的后验概率。同样，如果有充分理由相信后验是单

峰的，则容易估计状态向量每个分量的 HPD 区域（即各边际分布的 HPD 区域）。获得状态均值和协方差的估计也很直接，甚至可以估计状态的任意函数。

第 3.2 节给出的 **bootstrap filter** 论证基于渐近结果。对于有限样本数，很难证明任何一般性结果。同样，对于“需要多少样本才能给出足够好的密度表示以供滤波运行”这一关键问题，也很难作出精确且可证明的陈述。不过可以明确的是，所需样本数 N 至少依赖三个因素：

- (a) 状态空间维度；
- (b) 先验与似然之间典型的“重叠”程度；
- (c) 所需时间步数。

先看第一个因素，必须预期 N 会随空间维度快速上升。上升速度受状态向量各分量之间相互依赖关系的支配。在最温和的情形，即各分量独立时，所需状态向量样本数不应随空间维度增加。

N 对因素 (b) 和 (c) 的依赖，是滤波器重采样更新阶段的直接后果。如果似然 $p(y_k | x_k)$ 取显著值的状态空间区域，相比先验 $p(x_k | D_{k-1})$ 显著的区域很小，那么许多样本 $x_k^*(i)$ 会获得很小的权重 q_i ，并且不会在重采样过程中被选中。因此，远离似然区域的先验样本实际上被浪费，而靠近似然区域的样本会被多次重新选中。如果似然落在先验密度较低的区域，这一问题会更加严重，因为那里样本相对较少（另见参考文献 14）。通过这一过程，PDF 的表示可能在几个时间步内变得非常不足。事实上，如果没有系统噪声，全部 N 个样本可能会迅速塌缩到单个值。原则上，可以通过使用巨大样本数的“蛮力”办法克服这一困难。然而，要为有意义的问题发展实用滤波器，就需要更微妙的方法。在第 4.2 节的仿真实例中，我们为此提出并实现了对基本算法的两项修改：一种 **roughening** 过程，用来抖动重采样后的值；以及一种 **prior editing** 方案，用来增加显著似然附近的先验样本数。在发展此类基本算法修正以提高效率方面，仍有大量研究空间。

Muller [12] 提出的抽样技术在更新阶段不同于我们的方法；预测阶段则相同。Muller 的更新方案是一个接受/拒绝过程。每个先验样本 $x_k^*(i)$ 被依次考虑。它以与 $p(y_k | x_k^*(i))$ 成比例的概率被接受为后验样本，否则被拒绝。该方案的一个缺点是样本量是随机的并且会下降。参考文献 12 的主要主题是一种通过从拟合到原始先验样本的包络密度中重采样来扩展先验样本的算法。

4 仿真

本文给出两个例子，用以说明 **bootstrap filter** 的运行。估计性能与标准 EKF 进行比较。第一个例子是来自参考文献 8 和 10 的一元非平稳增长模型。第二个例子是一个实际的 **bearings-only tracking** 问题，状态空间为四维。

4.1 一维非线性例子

考虑如下非线性模型 [8]:

$$x_k = 0.5x_{k-1} + \frac{25x_{k-1}}{1 + x_{k-1}^2} + 8\cos(1.2(k-1)) + w_k, \quad (9)$$

$$y_k = \frac{x_k^2}{20} + v_k. \quad (10)$$

其中 w_k 和 v_k 为零均值高斯白噪声，方差分别为 10.0 和 1.0。该例在系统方程和测量方程中都具有严重非线性。注意，似然 $p(y_k | x_k)$ 的形式给问题增加了一个有趣的变化。对于测量 $y_k < 0$ ，似然在零处单峰，并关于零对称。然而，对于正测量，似然关于零对称，并在 $\pm(20y_k)^{1/2}$ 处有模态。

初始状态取为 $x_0 = 0.1$ ，图 1 给出式 (9) 的 50 步实现。EKF 和 bootstrap filter 都用先验 PDF $p(x_0) = N(0, 2)$ 初始化。图 2 给出了将 EKF 应用于由式 (10) 生成的 50 个测量时的结果。




图 1. 式 (9) 的 50 点实现。初始状态 $x_0 = 0.1$ 。

真实状态用星号表示，EKF 均值用实线给出，虚线给出 95% 概率区域（注意，为方便起见，我们把 2.5 和 97.5 百分位点之间的区间称为 95% 概率区域）。图形在 ± 40 处被裁剪。实际状态值只有大约 30% 的时候位于 95% 概率区域内。

图 3 显示了直接应用第 3.1 节 bootstrap 算法且样本量为 $N = 500$ 的结果。实线给出后验样本均值，虚线估计 95% 概率区域。这些区间未必表示真正的 95% HPD 区域，因为如图 4 所示，该例中的后验可能是双峰的。在几个时间步上，实际状态刚好位于这些分位数估计之外，并且它经常接近其中一个边界。不过，大多数时候实际状态非常接近后验均值，性能显然远优于 EKF。使用更大样本集运行 bootstrap filter 得到的结果与图 3 难以区分，这被视为样本集规模足够的确认。相对较高的系统噪声可能解释了基本算法仅用 500 个样本仍有合理性能的原因：系统噪声会自动 roughen




图 2. EKF 后验均值估计。星号为真实状态，实线为滤波器后验均值，虚线为估计的 95% 概率区域。




图 3. Bootstrap filter 后验均值估计。星号为真实状态，实线为滤波器后验均值，虚线为估计的 95% 概率区域。

先验样本。

图 4 给出了 $k = 21$ 时 bootstrap filter 和 EKF 的后验密度估计。Bootstrap PDF 是从后验样本重建的核密度估计 [13]。它具有双峰结构， x_{21} 的真实值位于较大模态附近。来自 EKF 的高斯 PDF 在这一时间步远离真实状态值。




图 4. 时刻 21 的估计后验 PDF。实线：bootstrap 估计；虚线：EKF 估计。

4.2 Bearings-Only Tracking 例子

在该例中，目标在 $x - y$ 平面内按标准二阶模型运动：

$$x_k = \Phi x_{k-1} + \Gamma w_k \quad (11)$$

其中 $x_k = (x, \dot{x}, y, \dot{y})_k^\top$, $w_k = (w_x, w_y)_k^\top$,

$$\Phi = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad \Gamma = \begin{bmatrix} 0.5 & 0 \\ 1 & 0 \\ 0 & 0.5 \\ 0 & 1 \end{bmatrix}.$$

这里 x 和 y 表示目标的 Cartesian 坐标；这不应与前面对滤波器一般讨论中的状态向量和测量向量记号混淆。系统噪声是零均值高斯白噪声过程，协方差为 Q : $E[w_k w_j^\top] = Q \delta_{jk}$, 其中 $Q = qI_2$, I_2 为 2×2 单位矩阵。位于平面原点的固定观测器对目标方位进行含噪测量 z_k :

$$z_k = \tan^{-1}(y_k/x_k) + v_k. \quad (12)$$

测量噪声是零均值高斯白噪声过程，方差为 r : $E[v_k v_j] = r \delta_{kj}$ 。在 $k = 1$ 取得测量之前，假设初始状态向量服从均值 $\bar{x}_1$ 已知、协方差如下的高斯分布：

$$M_1 = \begin{bmatrix} \sigma_1^2 & 0 & 0 & 0 \\ 0 & \sigma_2^2 & 0 & 0 \\ 0 & 0 & \sigma_3^2 & 0 \\ 0 & 0 & 0 & \sigma_4^2 \end{bmatrix}.$$

根据式 (11) 和式 (12)，使用如下参数值（任意单位）生成了 24 个时间步的目标轨迹及相应测量： $\sqrt{q} = 0.001$ 、 $\sqrt{r} = 0.005$ ，目标的实际初始状态为

$$x_1 = (-0.05, 0.001, 0.7, -0.055)^\top.$$

图 5 给出了目标在 $x - y$ 平面内的路径，每个时间步的目标位置用三角形表示。观测器位于原点，并用十字表示。注意，在这一次轨迹实现中，目标最初沿平缓曲线运动，然后以相当直的路线经过观测器。




图 5. $x - y$ 平面中的真实目标轨迹。三角形：目标位置；十字：观测器位置。

先验分布参数设为 $\bar{x}_1 = (0.0, 0.0, 0.4, -0.05)^\top$ ，并且 $\sigma_1 = 0.5$ 、 $\sigma_2 = 0.005$ 、 $\sigma_3 = 0.3$ 、 $\sigma_4 = 0.01$ 。应用 EKF 和使用 4000 个样本的 bootstrap filter 的结果见图 6。

连续线显示来自 bootstrap filter 的轨迹估计（后验 PDF 的均值），虚线给出 EKF 估计。在初始不确定阶段之后，bootstrap filter 很快锁定目标，而 EKF 迅速发散。在该例中，bootstrap filter 的性能显然优于 EKF。

虽然后验分布的均值被选作目标状态的点估计，但 bootstrap filter 当然还能提供更多信息。图 7 即说明了这一点：它显示了时间步 24 时后验 PDF 中 4000 个样本里的 500 个样本的 (x, y) 坐标。真实状态用三角形表示。样本向右下角偏斜的性质突出了该 PDF 的非高斯性。




图 6. $x - y$ 平面中目标轨迹的后验均值估计。三角形：目标位置；实线：bootstrap 估计；虚线：EKF 估计。




图 7. 来自 $p(x_{24} | D_{24})$ 的 500 个 bootstrap $x - y$ 样本散点图。三角形：目标位置。

关于 x 和 $\dot{x}$ 坐标的滤波性能, 更详细的分析见图 8 和图 9 (bootstrap filter), 以及图 10 和图 11 (EKF)。对于 bootstrap filter, 实际坐标值几乎总是位于 95% 概率区域内。




图 8. Bootstrap 后验均值和 95% 概率区域估计: x 坐标。




图 9. Bootstrap 后验均值和 95% 概率区域估计: $\dot{x}$ 坐标。

然而, EKF 对其跟踪性能始终过于乐观, 并且在 $k = 13$ 之后发生严重发散。

用适中的样本数实现该例中的 bootstrap filter 需要一些技巧。原因如第 3.3 节所讨论: 在轨迹开始时以及目标接近观测器时, 先验与似然之间只有很小的“重叠”。为对抗真正不同样本值数量随之减少的问题, 文中实现了两个方案。

Roughening: 第一个方案是 roughening 过程。在更新过程中, 对每个抽得的样本加入一个独立扰动 c_i 。 c_i 是来自 $N(0, J_k)$ 的样本, 其中 J_k 是对角协方差矩阵。对应状态向量某一特定分量的高斯扰动标准差 σ 给定为

$$\sigma = KEN^{-1/d},$$

其中 E 是该分量样本最大值与最小值之间的区间长度 (roughening 之前), d 是状态空间维度, K




图 10. EKF 后验均值和 95% 概率区域估计: x 坐标。




图 11. EKF 后验均值和 95% 概率区域估计: $\dot{x}$ 坐标。

是常数调节参数。通过令扰动标准差与样本数的 d 次方根成反比，**roughening** 的程度被归一化到对应的、含 N 个点的均匀矩形网格节点间距上。在本例中，选择 $K = 0.2$ 。因此，高斯扰动的标准差是等效矩形网格节点间距的 20%。显然， K 的选择是一种折中。过大的值会模糊分布，而过小的值会在原始样本周围产生紧密点簇。

Prior editing: 第二个过程人为增加似然附近的先验样本数。如果愿意将状态估计延迟一个时间步，则可以通过对更新阶段的样本施加一种粗糙、实用的接受检验来实现这一点（该检验实际上编辑了先验）：

- (a) 取样本 $x_k(i)$ ，将其通过 **roughening** 过程和系统模型，生成 $x_{k+1}^*(i)$ 。
- (b) 假设下一时间步的测量已经可用，计算 $v_{k+1}(i) = z_{k+1} - h(x_{k+1}^*(i))$ 。
- (c) 如果 $|v_{k+1}(i)| > 6\sqrt{r}$ ，则样本 $x_{k+1}^*(i)$ 远离似然，因此在第 $k+1$ 次更新阶段极不可能被选中。在这种情况下，拒绝样本 $x_k(i)$ ，并重复步骤 (a)，从更新阶段 k 抽取一个替代样本。否则接受 $x_k(i)$ ，令 i 增加，并在 $i \leq N$ 时重复。

注意，该过程对样本 $x_k(i)$ 具有一种粗糙的单阶段平滑操作效果。因此，被接受的样本 $x_k(i)$ 多少按 $p(x_k | D_{k+1})$ 分布。不过，图 8 和图 9 中给出的 **bootstrap** 结果来自未经过接受检验编辑的样本，因此正确表示未平滑的 PDF $p(x_k | D_k)$ 。

通过使用 **roughening** 和仅接受“有用”样本这些技术，文中结果只需传播 $N = 4000$ 个样本即可得到。在四维空间中，这种规模的网格在每个坐标上大约只有 8 个点。注意，**prior editing** 检验所拒绝的样本数在某种意义上是测量中有效信息量的度量。目标飞越观测器时取得的少数测量最具信息量，在这些时间步中，被拒绝样本数上升到约 100000。在 **fly-past** 阶段之前和之后，目标大致沿观测器的半径向量运动，因此观测到的目标方位几乎恒定。在这些时期，被拒绝样本数很低（约 10 到 100 之间），因为连续测量贡献的新信息很少。这一效应在图 8 中也很明显：95% 概率区域的界限在 **fly-past** 期间收敛。EKF 在时间步 15 之后的性能尤其差，因为滤波器严重误解了 **fly-past** 时有价值的测量。

需要注意的是，EKF 结果来自于将滤波器直接应用于给定系统和测量模型的朴素方式。如果使用修正极坐标对问题重新参数化（见 Aidala 和 Hammel [17]），以帮助分离状态中的可观测和不可观测元素，表现很可能会更好。此外，**bootstrap filter** 中使用的 **prior editing** 检验在 EKF 形式中没有直接等价物。不过，可以对每个 bearing measurement 执行 gating test。例如，如果 EKF innovation 异常大，可以忽略对应测量。当接受阈值设为 ± 3 个标准差时，在目标经过观测器之后，有 10 个方位测量被忽略。虽然此时 EKF 仅作为预测器运行，估计误差却大大降低。然而，实际状态仍然很少位于 95% 概率区域内。

5 结论

本文提出了一种用于实现递归贝叶斯滤波的新算法，即 **bootstrap filter**。所需后验分布以一组样本的形式产生，该方法不受解析可处理性方面考虑的限制。

然而，对于许多有意义的问题，样本集中真正不同的值的数量可能迅速塌缩。为补救这一困难，本文提出了两种有些特设的方案（**roughening** 和 **prior editing** 过程）。这些过程已经在一个具有四维状态向量的非线性 **bearings-only tracking** 问题仿真中实现。仿真表明，即使样本数适中，**bootstrap filter** 也远优于标准扩展 Kalman 滤波器。

还需要进一步工作，以推导具有严格理论基础的实用方法，避免样本集中不同值数量的塌缩。同时，制定一些关于达到令人满意的 **bootstrap** 性能所需样本数的指南，也会非常有用。还应开展进一步的 Monte Carlo 仿真研究，以便对重要非线性问题中的滤波性能给出定量评估。

6 参考文献

- [1] JAZWINSKI, A.H.: 'Stochastic processes and filtering theory' (Academic Press, New York, 1970)
- [2] ALSPACH, D.L., and SORENSON, H.W.: 'Nonlinear Bayesian estimation using Gaussian sum approximation', *IEEE Trans. Auto. Control*, 1972, 17, pp. 439–447
- [3] MASRELIEZ, C.J.: 'Approximate non-Gaussian filtering with linear state and observation relations', *IEEE Trans. Auto. Control*, 1975, 20, pp. 107–110
- [4] WEST, M., HARRISON, P.J., and MIGON, H.S.: 'Dynamic generalised linear models and Bayesian forecasting (with discussion)', *J. Amer. Statistical Assoc.*, 1985, 80, pp. 73–97
- [5] BUCY, R.S.: 'Bayes theorem and digital realization for nonlinear filters', *J. Astronaut. Sci.*, 1969, 17, pp. 80–94
- [6] KRAMER, S.C., and SORENSON, H.W.: 'Recursive Bayesian estimation using piece-wise constant approximations', *Automatica*, 1988, 24, (6), pp. 789–801
- [7] SORENSON, H.W.: 'Recursive estimation for nonlinear dynamic systems', in SPALL, J.C. (Ed.): 'Bayesian analysis of time series and dynamic models' (Dekker, 1988)
- [8] KITTAGAWA, G.: 'Non-Gaussian state-space modelling of non-stationary time series (with discussion)', *J. Amer. Statistical Assoc.*, 1987, 82, pp. 1032–1063
- [9] POLE, A., and WEST, M.: 'Efficient numerical integration in dynamic models', Research report, 136, Department of statistics, University of Warwick, 1988
- [10] CARLIN, B.P., POLSON, N.G., and STOFFER, D.S.: 'A Monte-Carlo approach to nonnormal and nonlinear state space modelling', *J. Amer. Statistical Assoc.*, 1992, 87, pp. 493–500
- [11] WEST, M.: 'Modelling with mixtures (with discussion)', in BERNARDO, J.M., BERGER, J.O., DAWID, A.P., and SMITH, A.F.M. (Eds.): 'Bayesian statistics 4' (Oxford University Press, 1992), pp. 503–524
- [12] MULLER, P.: 'Monte Carlo integration in general dynamic models', *Contemp. Math.*, 1991, 115, pp. 145–163
- [13] SILVERMAN, B.W.: 'Density estimation for statistics and data analysis' (Chapman & Hall, London, 1986)
- [14] SMITH, A.F.M., and GELFAND, A.E.: 'Bayesian statistics without tears: a sampling-resampling perspective', *Amer. Stat.*, 1992, 46, pp. 84–88

- [15] HO, Y.C., and LEE, R.C.K.: 'A Bayesian approach to problems in stochastic estimation and control', *IEEE Trans. Auto. Control*, 1964, 9, pp. 333–339
- [16] HARRISON, P.J., and STEVENS, C.F.: 'Bayesian forecasting (with discussion)', *J. R. Stat. Soc. B*, 1976, 38, pp. 205–247
- [17] AIDALA, V.J., and HAMMEL, S.E.: 'Utilization of modified polar coordinates for bearings-only tracking', *IEEE Trans. Auto. Control*, 1983, AC-28, (3), pp. 283–294