

二阶精确的集合变换粒子滤波器

Walter Acevedo*

Jana de Wiljes*

Sebastian Reich[†]

arXiv:1608.08179v3

摘要

粒子滤波器（也称序贯蒙特卡洛方法）广泛用于非线性演化方程背景下的状态与参数估计问题。近期提出的集合变换粒子滤波器（ETPF）（S. Reich, *A non-parametric ensemble transform method for Bayesian inference*, SIAM J. Sci. Comput., 35 (2013), A2013–A2024）用线性变换取代标准粒子滤波器的重采样步骤，由此可将粒子滤波器与集合卡尔曼滤波器混合，并使所得混合滤波器适用于空间扩展系统。然而，线性变换步骤计算开销很大，而且在集合规模较小或中等时会低估集合离散度。本文通过构造 ETPF 的二阶精确扩展，同时解决这两个缺点。特别地，这些扩展允许用 Sinkhorn 近似取代线性输运问题的精确解。我们还证明，非线性集合变换滤波器（NETF）是该一般框架的一个特例。本文在混沌 Lorenz-63、Lorenz-96 模型以及动态场景观看模型上展示二阶精确滤波器的性能。Lorenz-63 与 Lorenz-96 的数值结果表明，对于较小到中等的集合规模，与标准集合卡尔曼滤波器及 ETPF 相比可以显著提高精度。另一方面，场景观看模型的数值结果揭示，二阶修正可能产生与后验参数分布在统计上不一致的样本。

关键词：贝叶斯推断，数据同化，粒子滤波器，集合卡尔曼滤波器，Sinkhorn 近似

AMS (MOS) 主题分类： 65C05, 62M20, 93E11, 62F15, 86A22

1 引言

数据同化（DA）泛指将演化模型与底层动力过程的部分观测相结合的问题 [10, 15, 22]。数据同化算法可采用变分方法和/或基于集合的方法 [15]。本文关注基于集合的数据同化方法及其稳健、高效的实现。集合卡尔曼滤波器（EnKF）[10] 是迄今最流行的集合数据同化方法，并已在地球科学中得到广泛应用。然而，对于部分观测的非线性过程，EnKF 会给出不相合的近似。相反，粒子滤波器（PF，也称序贯蒙特卡洛方法）[8] 能给出相合近似，但为了跟踪底层参考过程，通常需要远大于 EnKF 的集合规模 [2]。

*德国波茨坦大学数学研究所, Karl-Liebknecht-Str. 24/25, D-14476 Potsdam, Germany。

[†]德国波茨坦大学数学研究所, Karl-Liebknecht-Str. 24/25, D-14476 Potsdam, Germany (sreich@math.uni-potsdam.de) ; 英国雷丁大学数学与统计系, Whiteknights, PO Box 220, Reading RG6 6AX, UK。

为了克服这些缺点, 当前一个明显趋势是采用混合滤波器: 将 EnKF 与 PF 结合, 使其在集合规模较小或中等时仍适用于强非线性系统。相关方法包括高斯混合滤波器 (例如 [24])、秩直方图滤波器 [1, 19]、矩匹配集合滤波器 [28, 16, 25]、集合卡尔曼粒子滤波器 [11] 以及混合集合变换粒子滤波器 [6]。

本文关注集合变换粒子滤波器 (ETPF) [21, 22] 的改进实现及其与 EnKF 的混合 [6]。ETPF 在每个同化步骤都要求解一个线性输运问题, 因此计算开销显著高于 EnKF。Sinkhorn 近似 [7] 等具有计算吸引力的替代方案会因集合离散度不足而导致实现不稳定。为此, 我们引入一种 ETPF 变体: 不论底层最优输运问题采用何种实际求解过程, 该变体均为二阶精确。若集合滤波器的后验均值与协方差矩阵和贝叶斯推断步骤的相应重要性采样估计一致, 则称其为二阶精确。二阶精确粒子滤波器最早由 [28] 提出, 此后又发展出若干变体 [16, 25]。本文则研究对 ETPF 的二阶修正。这类修正需要求解连续时间代数 Riccati 方程 [27, 14]。当集合规模趋于无穷时, 修正项趋于零, 这与 ETPF 的相合性 [21] 一致。

本文结构如下。第 2 节概述集合变换滤波器的一般框架。第 3 节总结 ETPF 并引入二阶修正步骤。第 4 节讨论相应连续时间代数 Riccati 方程的数值求解过程。第 5 节介绍 ETPF 最优输运问题的 Sinkhorn 近似, 第 6 节总结 ETPF 的整体二阶精确实现。第 7 节给出数值结果, 在高度非线性且混沌的 Lorenz-63[17] 与 Lorenz-96[18] 模型上展示新方法的行为。我们重复 [6] 中的实验, 但用基于底层最优输运问题 Sinkhorn 近似的二阶精确变体替代 ETPF。最后, 我们还展示新滤波器在场景观看模型 SceneWalk[9] 参数估计中的表现。

2 基于集合的预报-数据同化系统

假设在时刻 t_k ($k = 1, \dots, K$) 可获得观测 $\mathbf{y}^{\text{obs}}(t_k) \in \mathbb{R}^{N_y}$, 并且这些观测通过似然函数与演化模型

$$\mathbf{z}(t_k) = \mathcal{M}(\mathbf{z}(t_{k-1})) \quad (1)$$

的状态变量 $\mathbf{z} \in \mathbb{R}^{N_z}$ 相关:

$$\pi(\mathbf{y} | \mathbf{z}) = \frac{1}{(2\pi)^{N_y/2} |\mathbf{R}|^{1/2}} \exp \left[-\frac{1}{2} (h(\mathbf{z}) - \mathbf{y})^\top \mathbf{R}^{-1} (h(\mathbf{z}) - \mathbf{y}) \right], \quad (2)$$

其中 $\mathbf{R} \in \mathbb{R}^{N_y \times N_y}$ 表示测量误差协方差矩阵。

在任意 t_k , 基于集合的预报-数据同化 (FOR-DA) 系统都会产生两个规模为 M 的集合。首先, 预报集合 $\{\mathbf{z}_i^f\}_{i=1}^M$ 近似条件分布 $\pi(\mathbf{z}, t_k | \mathbf{y}_{1:k-1}^{\text{obs}})$; 其次, 分析集合 $\{\mathbf{z}_i^a\}_{i=1}^M$ 近似条件分布 $\pi(\mathbf{z}, t_k | \mathbf{y}_{1:k}^{\text{obs}})$ 。这里

$$\mathbf{y}_{1:l}^{\text{obs}} = (\mathbf{y}^{\text{obs}}(t_1), \mathbf{y}^{\text{obs}}(t_2), \dots, \mathbf{y}^{\text{obs}}(t_l)) \in \mathbb{R}^{N_y \times l} \quad (3)$$

表示从 $t = t_1$ 到 $t = t_l$ 的全部观测。还应注意

$$\mathbf{z}_i^f(t_k) = \mathcal{M}(\mathbf{z}_i^a(t_{k-1})), \quad (4)$$

而不同 FOR-DA 系统的主要差别在于所采用的数据同化算法。

本文考虑的数据同化算法均具有线性集合变换滤波器 (LETF) [22] 的形式:

$$\mathbf{z}_j^a(t_k) = \sum_{i=1}^M \mathbf{z}_i^f(t_k) d_{ij}(t_k), \quad (5)$$

其中, $M \times M$ 变换矩阵 $\mathbf{D}(t_k) = \{d_{ij}(t_k)\}$ 的元素满足约束

$$\sum_{i=1}^M d_{ij}(t_k) = 1 \quad (6)$$

($j = 1, \dots, M$)。换言之, 当 $M \leq N_z$ 时, 分析集成员 $\mathbf{z}_j^a(t_k)$ 位于由 $i \in \{1, \dots, M\}$ 的预报集合 $\mathbf{z}_i^f(t_k)$ 张成的 $(M-1)$ 维超平面中。注意, $\mathbf{D}$ 的元素可以为负, 参见 [22]。

具有 LETF 结构的一类著名数据同化算法是 EnKF 族 [10, 22]。人们早已认识到 EnKF 非常稳健, 但其底层高斯性与线性假设限制了它对更一般系统的适用性。为克服 EnKF 等传统技术的缺点, 研究者提出了适用于非线性模型场景、并且在高维系统中计算可行的其他算法。例如, [28, 25] 的非线性集合变换滤波器 (NETF) 是一种具有 LETF 形式的粒子滤波器, 它以归一化重要性权重

$$w_i(t_k) := \frac{\hat{w}_i(t_k)}{\sum_{j=1}^M \hat{w}_j(t_k)} \quad (7)$$

为基础, 其中 $\hat{w}_i(t_k) = \pi(\mathbf{y}(t_k) | \mathbf{z}_i^f(t_k))$, 并能再现后验分布的一阶矩与二阶矩。

不过, 本文主要关注 ETPF。ETPF 同样可写成式 (5) 的形式 [10, 22], 其中 $\mathbf{D}(t_k) = \{d_{ij}(t_k)\}$ 通过最小化代价泛函

$$J(\mathbf{D}(t_k)) = \sum_{i,j=1}^M d_{ij}(t_k) \|\mathbf{z}_i^f(t_k) - \mathbf{z}_j^f(t_k)\|^2 \quad (8)$$

确定, 并满足 $d_{ij}(t_k) \geq 0$ 、式 (6) 以及

$$\frac{1}{M} \sum_{j=1}^M d_{ij}(t_k) = w_i(t_k) \quad (9)$$

这些约束 [21]。ETPF 的核心思想, 是近似从服从 $\pi_{Z^f}(\mathbf{z}, t_k)$ 的随机变量 $Z^f(t_k)$ 到与 $\pi_{Z^a}(\mathbf{z}, t_k)$ 相关联的随机变量 $Z^a(t_k)$ 的输运映射。该映射诱导两个相应密度之间的耦合; 从最小化两个随机变量期望距离的意义上说, 这一耦合是最优的, 即

$$\mu_Z^* = \arg \inf_{\mu \in \Pi(\pi_{Z^f}, \pi_{Z^a})} \sqrt{\mathbb{E} \|Z^f(t_k) - Z^a(t_k)\|^2}. \quad (10)$$

直观而言, 优化式 (10) 会增大预报随机变量与分析随机变量之间的相关性, 从而在先验与后验之间建立紧密联系。由于该滤波器只依赖重要性权重, 它也适用于非高斯似然函数。

借助局部化思想 [5], ETPF 还可用于空间扩展系统, 并已通过混合方法与 EnKF 结合 [6]。当 $M \rightarrow \infty$ 时, ETPF 收敛到真实后验分布 [21]; 一般而言, EnKF 与 NETF 并不具备这一性质。然而, ETPF 计算开销较大, 而且在有限集合规模下会低估集合离散度 (协方差矩阵; 参见 [22] 的例 8.11)。第 3 节和第 5 节提出的 LETF 将同时处理这两个缺点。

3 二阶精确的 LETF

下面推导二阶精确的 LETF。这里的二阶精确，是指严格再现重要性采样方法给出的一阶矩与二阶矩。

定义 3.1. 若 LETF (5) 的分析均值满足

$$\bar{\mathbf{z}}^a(t_k) = \frac{1}{M} \sum_{i=1}^M \mathbf{z}_i^a(t_k) = \sum_{i=1}^M w_i(t_k) \mathbf{z}_i^f(t_k), \quad (11)$$

并且分析协方差矩阵

$$\hat{\mathbf{P}}^a(t_k) = \frac{1}{M} \sum_{i=1}^M (\mathbf{z}_i^a(t_k) - \bar{\mathbf{z}}^a(t_k)) (\mathbf{z}_i^a(t_k) - \bar{\mathbf{z}}^a(t_k))^T \quad (12)$$

等于由重要性权重定义的协方差矩阵，即

$$\mathbf{P}^a(t_k) = \sum_{i=1}^M w_i(t_k) (\mathbf{z}_i^f(t_k) - \bar{\mathbf{z}}^a(t_k)) (\mathbf{z}_i^f(t_k) - \bar{\mathbf{z}}^a(t_k))^T, \quad (13)$$

则称该 LETF 是二阶精确的。

备注 3.1. 在等权 $w_i = 1/M$ 的情形下，由重要性采样得到的协方差矩阵 (13) 以 M 为分母。与此一致，本文采用经验协方差 (12) 的有偏版本。另一种选择是在式 (13) 中引入因子 $M/(M-1)$ ，从而得到无偏变体（例如 NETF 就采用这种做法，参见 [25]）。

本节及后续各节只考虑 FOR-DA 系统的数据同化步骤，因此从现在起为简化记号而省略显式时间依赖。定义预报集合的 $N_z \times M$ 矩阵

$$\mathbf{Z}^f = (\mathbf{z}_1^f, \mathbf{z}_2^f, \dots, \mathbf{z}_M^f) \in \mathbb{R}^{N_z \times M}, \quad (14)$$

并类似地定义分析集合矩阵

$$\mathbf{Z}^a = (\mathbf{z}_1^a, \mathbf{z}_2^a, \dots, \mathbf{z}_M^a) \in \mathbb{R}^{N_z \times M}. \quad (15)$$

于是，LETF (5) 可写为

$$\mathbf{Z}^a = \mathbf{Z}^f \mathbf{D}. \quad (16)$$

再定义向量 $\mathbf{1} = (1, 1, \dots, 1)^T \in \mathbb{R}^{M \times 1}$ 、归一化重要性权重 (7) 的向量

$$\mathbf{w} = (w_1, \dots, w_M)^T \in \mathbb{R}^{M \times 1} \quad (17)$$

以及对角矩阵 $\mathbf{W} = \text{diag}(\mathbf{w}) \in \mathbb{R}^{M \times M}$ 。由式 (11) 可知，若

$$\frac{1}{M} \mathbf{Z}^a \mathbf{1} = \mathbf{Z}^f \mathbf{w}, \quad (18)$$

则 LETF 是一阶精确的。当 $\mathbf{D}$ 满足式 (9)，即

$$\frac{1}{M} \mathbf{D} \mathbf{1} = \mathbf{w}, \quad (19)$$

时, 式 (18) 成立。回顾变换矩阵还受式 (6) 约束, 该约束等价于 $D^T \mathbf{1} = \mathbf{1}$ [22]。以下关注由变换矩阵 D 刻画的一阶精确 LETF 类

$$\mathcal{D}_1 = \left\{ D \in \mathbb{R}^{M \times M} \mid D^T \mathbf{1} = \mathbf{1}, D \mathbf{1} = M \mathbf{w} \right\}. \quad (20)$$

例如, 变换矩阵

$$D_0 = \mathbf{w} \mathbf{1}^T \quad (21)$$

满足这些条件, 并给出分析集合

$$\mathbf{Z}^a = \bar{\mathbf{z}}^a \mathbf{1}^T. \quad (22)$$

备注 3.2. EnKF 同样会产生式 (16) 形式的变换, 其相应的 D_{EnKF} 满足 $D_{\text{EnKF}}^T \mathbf{1} = \mathbf{1}$, 但一般不满足式 (19) [22]。因此通常有 $D_{\text{EnKF}} \notin \mathcal{D}_1$ 。简单修正

$$\widehat{D}_{\text{EnKF}} = D_{\text{EnKF}} \left(I - \frac{1}{M} \mathbf{1} \mathbf{1}^T \right) + D_0 \quad (23)$$

会使 $\widehat{D}_{\text{EnKF}} \in \mathcal{D}_1$ 。

注意, 对于任意 $D \in \mathcal{D}_1$, 分析协方差矩阵 (12) 可等价地写为

$$\widehat{P}^a = \frac{1}{M} \mathbf{Z}^f (D - \mathbf{w} \mathbf{1}^T) (D - \mathbf{w} \mathbf{1}^T)^T (\mathbf{Z}^f)^T. \quad (24)$$

为了达到二阶精确, 式 (24) 必须等于后验协方差矩阵 (13) 的重要性采样估计, 后者现可写成

$$P^a = \mathbf{Z}^f (\mathbf{W} - \mathbf{w} \mathbf{w}^T) (\mathbf{Z}^f)^T. \quad (25)$$

因此, 本文考虑的二阶精确 LETF 类由集合

$$\mathcal{D}_2 = \left\{ D \in \mathcal{D}_1 \mid (D - \mathbf{w} \mathbf{1}^T) (D - \mathbf{w} \mathbf{1}^T)^T = \mathbf{W} - \mathbf{w} \mathbf{w}^T \right\} \quad (26)$$

刻画。

备注 3.3. 存在一个重要子类 $\mathcal{D}_1^+ \subset \mathcal{D}_1$, 它还满足 $d_{ij} \geq 0$, 即

$$\mathcal{D}_1^+ = \{ D \in \mathcal{D}_1 \mid d_{ij} \geq 0, i, j = 1, \dots, M \}. \quad (27)$$

于是 $D \in \mathcal{D}_1^+$ 是左随机矩阵, 因而可解释为重采样方案: 对于 $j \in \{1, \dots, M\}$, 依据 D 第 j 列的转移概率生成实现 $\mathbf{z}_j^a$ 。然而, 如果像 ETPF 那样确定性地使用这类随机矩阵来产生分析集合, 则粒子 $\mathbf{z}_j^a$ 对应于 D 第 j 列所诱导随机变量的期望。以式 (21) 给出的简单变换矩阵 $D_0 \in \mathcal{D}_1^+$ 为例, 此时对所有 $j \in \{1, \dots, M\}$ 均有 $\mathbf{z}_j^a = \bar{\mathbf{z}}^a$, 由此得到的分析协方差矩阵 (24) 恒等于零。这显然不可取, 并且 $D_0 \notin \mathcal{D}_2$ 。ETPF 的设计使这一效应最小化, 并在 $M \rightarrow \infty$ 时渐近消失 [21, 22]。更一般地说, 通常有 $\mathcal{D}_1^+ \cap \mathcal{D}_2 = \emptyset$ 。

下面提出一种一般方法, 将变换矩阵 $D \in \mathcal{D}_1$ 转化为 $\widehat{D} \in \mathcal{D}_2$ 。从如下试探形式出发:

$$\widehat{D} = D + \Delta, \quad (28)$$

其中 $D \in \mathcal{D}_1$, $\Delta \in \mathbb{R}^{M \times M}$ 满足 $\Delta \mathbf{1} = \mathbf{0}$, $\Delta^\top \mathbf{1} = \mathbf{0}$, 且 $P^a = \widehat{P}^a$, 这里

$$\widehat{P}^a = \frac{1}{M} Z^f (\widehat{D} - w \mathbf{1}^\top) (\widehat{D} - w \mathbf{1}^\top)^\top (Z^f)^\top. \quad (29)$$

条件

$$\mathbf{0} = P^a - \widehat{P}^a = Z^f \left\{ W - w w^\top - \frac{1}{M} (\widehat{D} - w \mathbf{1}^\top) (\widehat{D} - w \mathbf{1}^\top)^\top \right\} (Z^f)^\top \quad (30)$$

与式 (28) 共同导出关于修正项 Δ 的二次方程

$$\begin{aligned} M(W - w w^\top) - (D - w \mathbf{1}^\top)(D - w \mathbf{1}^\top)^\top \\ = (D - w \mathbf{1}^\top)\Delta^\top + \Delta(D - w \mathbf{1}^\top)^\top + \Delta\Delta^\top. \end{aligned} \quad (31)$$

如果还要求 Δ 对称, 则特殊情形 (21) 给出

$$M(W - w w^\top) = \Delta\Delta, \quad (32)$$

而式 (31) 的一个解就是对称平方根

$$\Delta = \sqrt{M}(W - w w^\top)^{1/2}, \quad (33)$$

由此恢复 NETF[25, 28]。注意, 若 Q 是满足 $Q\mathbf{1} = \mathbf{1}$ 的 $M \times M$ 正交矩阵, 且 $D = w \mathbf{1}^\top$, 那么 ΔQ 同样给出式 (31) 的解。¹ 下面的引理说明如何以最优方式选择正交矩阵 Q 。

引理 3.1. 设 Δ 为任意 $M \times M$ 矩阵, 满足 (i) $\Delta \mathbf{1} = \mathbf{0}$, 以及 (ii)

$$\frac{1}{M} \Delta \Delta^\top = W - w w^\top, \quad (34)$$

并假设 $M \leq N_z + 1$ 。定义 $M \times M$ 正交矩阵

$$Q_{\text{opt}} := U_{\text{opt}} V_{\text{opt}}^\top, \quad (35)$$

其中两个 $M \times M$ 正交矩阵 U_{opt} 和 V_{opt} 来自 $M \times M$ 矩阵

$$S = \Delta(\widehat{Z}^f)^\top \widehat{Z}^f, \quad \widehat{Z}^f := Z^f - \frac{1}{M} Z^f \mathbf{1} \mathbf{1}^\top \quad (36)$$

的奇异值分解, 即 $S = U_{\text{opt}} \Lambda_{\text{opt}} V_{\text{opt}}^\top$ 。那么, 变换矩阵

$$D_{\text{opt}} = w \mathbf{1}^\top + \Delta Q_{\text{opt}} \quad (37)$$

给出一个二阶精确 LETF, 并在所有二阶精确变换矩阵 $D \in \mathcal{D}_2$ 中最小化

$$\widehat{J}(D) = \frac{1}{M} \sum_{i=1}^M \|z_i^a - z_i^f\|^2. \quad (38)$$

¹[25] 提出的 NETF 使用满足 $Q\mathbf{1} = \mathbf{1}$ 的随机正交矩阵, 而 [28] 的 NETF 则基于 $W - w w^\top$ 的非对称平方根。

证明. 由于 $\hat{\mathbf{Z}}^f \mathbf{1} = \mathbf{0}$, 矩阵 $\mathbf{S}$ 除满足 $\mathbf{S}^\top \mathbf{1} = \mathbf{0}$ 外还满足 $\mathbf{S} \mathbf{1} = \mathbf{0}$ 。这意味着 $\mathbf{Q}_{\text{opt}} \mathbf{1} = \mathbf{1}$, 因而式 (37) 是二阶精确的。还应注意

$$\begin{aligned} & \left(\Delta (\hat{\mathbf{Z}}^f)^\top \hat{\mathbf{Z}}^f (\hat{\mathbf{Z}}^f)^\top \hat{\mathbf{Z}}^f \Delta \right)^{-1/2} \Delta (\hat{\mathbf{Z}}^f)^\top \hat{\mathbf{Z}}^f \\ &= (\mathbf{S} \mathbf{S}^\top)^{-1/2} \mathbf{S} = \left(\mathbf{U}_{\text{opt}} \Lambda_{\text{opt}}^{-1} \mathbf{U}_{\text{opt}}^\top \right) \mathbf{U}_{\text{opt}} \Lambda_{\text{opt}} \mathbf{V}_{\text{opt}}^\top. \end{aligned} \quad (39)$$

文献 [20] 已证明: 对于给定的预报与分析均值及协方差矩阵, 上式最小化式 (38)。于是 $\mathbf{Q}_{\text{opt}} = \mathbf{U}_{\text{opt}} \mathbf{V}_{\text{opt}}^\top$ 的最优性成立。另见 [22]。□

关于引理 3.1 中的要求 $M \leq N_z + 1$, 有两点需要说明。首先, 若样本数 M 超过状态空间维数 N_z , 则从计算角度更宜将最优变换实现为

$$\mathbf{z}_i^a = \bar{\mathbf{z}}^a + \mathbf{T}(\mathbf{z}_i^f - \bar{\mathbf{z}}^f), \quad (40)$$

其中 $\mathbf{T} \in \mathbb{R}^{N_z \times N_z}$ 是适当定义的对称矩阵 [20, 22]。其次, 仍可按式 (35) 继续计算, 但应从右侧将 $\mathbf{Q}_{\text{opt}}$ 乘以投影矩阵 $\mathbf{I} - \mathbf{1}\mathbf{1}^\top/M$, 以保持所得变换矩阵 (37) 的均值, 即 $\mathbf{D}_{\text{opt}} \mathbf{1} = \mathbf{w}$ 。之所以需要这一附加操作, 是因为矩阵 $\mathbf{S}$ 将具有多个零奇异值。

4 连续时间代数 Riccati 方程

现在回到一阶精确变换矩阵 $\mathbf{D}$ 的一般情形。此时, 式 (31) 导出关于对称修正 Δ 的连续时间代数 Riccati 方程。更具体地, 引入

$$\mathbf{B} = \mathbf{D} - \mathbf{w}\mathbf{1}^\top, \quad \mathbf{A} = M(\mathbf{W} - \mathbf{w}\mathbf{w}^\top) - \mathbf{B}\mathbf{B}^\top, \quad (41)$$

并假设 Δ 对称, 则式 (31) 可写成连续时间代数 Riccati 方程

$$\mathbf{A} = \mathbf{B}\Delta + \Delta\mathbf{B}^\top + \Delta\Delta. \quad (42)$$

注意, 式 (42) 是动态 Riccati 方程

$$\frac{d}{d\tau} \Delta = -\mathbf{B}\Delta - \Delta\mathbf{B}^\top + \mathbf{A} - \Delta\Delta \quad (43)$$

的平稳解。由于式 (43) 可控 [27], 以 $\Delta(0) = \mathbf{0}$ 为初始条件的解 $\Delta(\tau)$ 在 $\tau \rightarrow \infty$ 时将收敛到式 (42) 的一个解 [4]。因此, 对式 (43) 采用显式 Euler 法推进足够多次, 便可得到式 (42) 的近似解。本文后续数值结果即采用这一方法。

备注 4.1. 作为另一种选择, 可以采用 [14] 的 Schur 向量方法求解式 (42)。该方法基于扩展 Hamilton 矩阵

$$\mathbf{H} = \begin{pmatrix} \mathbf{B}^\top & \mathbf{I} \\ \mathbf{A} & -\mathbf{B} \end{pmatrix} \quad (44)$$

及其上三角 *Schur* 分解

$$U^\top H U = \begin{pmatrix} S_{11} & S_{12} \\ \mathbf{0} & S_{22} \end{pmatrix}, \quad (45)$$

其中 S_{11} 谱的实部为负，而 S_{22} 谱的实部为正。相应地对正交矩阵 U 分块，则式 (31) 的解为

$$\Delta = U_{21} U_{11}^{-1}. \quad (46)$$

该计算方法要求矩阵对 $(A^{1/2}, B)$ 可检测 [27, 14]。由于式 (42) 未必总满足这一条件，我们建议通过式 (43) 求取式 (42) 的近似解。也可以利用 [12] 所讨论的更一般的 *Lagrange* 不变子空间技术。

现在可以使用 ETPF 的 D 来导出 ETPF 的二阶精确版本；也可以先计算最优输运问题 (8) 的近似解 $D \in \mathcal{D}_1^+$ ，再将其转化为二阶精确 PF。第 5 节将更详细地讨论后一方面。

5 最优输运问题的 Sinkhorn 近似

由代价泛函 (8) 和 $D \in \mathcal{D}_1^+$ 定义的最优输运问题，其 Sinkhorn 近似由正则化代价泛函

$$D_{\min}(\lambda) = \arg \min J_{\text{SH}}(D) = \sum_{i,j=1}^M \left\{ d_{ij} \|z_i^f - z_j^f\|^2 + \frac{1}{\lambda} d_{ij} \ln \frac{d_{ij}}{d_{ij}^0} \right\} \quad (47)$$

给出，其中 $\lambda > 0$ 是正则化参数， d_{ij}^0 是式 (21) 所定义矩阵 D_0 的元素。每个 λ 都对应一个特定的 $D_{\min}(\lambda) \in \mathcal{D}_1^+$ ，且 $\lambda \rightarrow \infty$ 时回到原代价函数 (8)。另一方面， $\lambda \rightarrow 0$ 时，式 (21) 成为唯一极小化解。这是因为正则项在 $d_{ij} = d_{ij}^0$ 时取最小值，即 $\lim_{\lambda \rightarrow 0} D_{\min}(\lambda) = D_0$ 。

备注 5.1. 确定 $D_{\min}(\lambda)$ 后，可以加入相应的适当二阶修正项 $\Delta(\lambda)$ ；不同的 λ 会产生不同的二阶精确粒子滤波器。例如， $\lambda \rightarrow 0$ 给出 NETF，而 $\lambda \rightarrow \infty$ 给出二阶修正 ETPF。换言之，改变 λ 可以在 NETF 与二阶修正 ETPF 之间自然过渡。

存在一种求取式 (47) 极小化解的直接迭代方法。首先注意到，极小化解具有形式

$$D_{\min}(\lambda) = \text{diag}(\mathbf{u}) \mathbf{K} \text{diag}(\mathbf{v}), \quad (48)$$

其中 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^{M \times 1}$ 是两个非负向量，而 $\mathbf{K}$ 的元素为

$$k_{ij} = e^{-\lambda \|z_i^f - z_j^f\|^2}. \quad (49)$$

未知向量 $\mathbf{u}$ 与 $\mathbf{v}$ 可通过 Sinkhorn 不动点迭代计算：

$$\{M w_i / (\mathbf{K} \mathbf{v})_i\} \rightarrow \mathbf{u}, \quad \{1 / (\mathbf{K} \mathbf{u})_i\} \rightarrow \mathbf{v}. \quad (50)$$

Sinkhorn 近似需要 $\mathcal{O}(M^2)$ 次运算。高效实现及更多细节参见 [7]。

分别以 $\mathbf{u}^l$ 和 $\mathbf{v}^l$ 表示 $\mathbf{u}$ 与 $\mathbf{v}$ 的迭代值，并且总是先按照式 (50) 左侧公式更新 $\mathbf{u}$ 。相应的

$$D^l = \text{diag}(\mathbf{u}^l) \mathbf{K} \text{diag}(\mathbf{v}^l) \quad (51)$$

满足 $(\mathbf{D}^l)^\top \mathbf{1} = \mathbf{1}$ ，而权重

$$\mathbf{w}^l = \frac{1}{M} \mathbf{D}^l \mathbf{1} \quad (52)$$

在 $l \rightarrow \infty$ 时收敛到 $\mathbf{w}$ 。若在指标 l_* 处停止迭代，则将相应变换矩阵定义为

$$\mathbf{D} = \mathbf{D}^{l_*} - (\mathbf{w}^{l_*} + \mathbf{w}) \mathbf{1}^\top. \quad (53)$$

指标 l_* 可由条件

$$\|\mathbf{w}^{l_*} - \mathbf{w}\| \leq \varepsilon \quad (54)$$

确定，其中 $\varepsilon > 0$ 足够小，例如 $\varepsilon = 10^{-8}$ 。

6 算法概要

下面总结基于最优输运问题 Sinkhorn 近似的二阶精确 ETPF 实现步骤。当然，也可以用任意可用的最优输运直接求解器代替 Sinkhorn 近似。

假设已给定预报集合成员矩阵 $\mathbf{Z}^f$ 和重要性权重向量 $\mathbf{w}$ ，则执行以下步骤：

- (i) 为最优输运算法的 Sinkhorn 近似选择正则化参数 $\lambda > 0$ 。根据式 (49) 计算矩阵 $\mathbf{K}$ ，并对 $\mathbf{K}$ 的元素进行归一化，使所有元素都满足 $-\lambda^{-1} \ln k_{ij} \leq 1$ 。根据更新公式 (50) 递归计算向量 $\mathbf{u}^l$ 和 $\mathbf{v}^l$ ，从 $\mathbf{v}^0 = \mathbf{1}$ 开始。持续迭代，直至变换矩阵 (51) 及其相应权重向量 (52) 满足式 (54)。注意，在每次迭代中，式 (51) 均应满足 $\mathbf{1}^\top \mathbf{D}^l = \mathbf{1}^\top$ 。本文实验采用 $\varepsilon = 10^{-8}$ 。最后利用式 (53) 得到变换矩阵 $\mathbf{D}$ 。
- (ii) 通过显式 Euler 法求解动态 Riccati 方程 (43)，从而求得 Riccati 方程 (42) 的修正项 Δ 。步长为 $\Delta\tau = 0.1$ ，初始条件为 $\Delta(0) = \mathbf{0}$ 。当

$$\|\Delta((k+1)\Delta\tau) - \Delta(k\Delta\tau)\|_\infty \leq 10^{-3} \quad (55)$$

时停止迭代，并令 $\Delta = \Delta((k+1)\Delta\tau)$ 。

- (iii) 分析集合由下式给出：

$$\mathbf{Z}^a = \mathbf{Z}^f \widehat{\mathbf{D}} = \mathbf{Z}^f (\mathbf{D} + \Delta). \quad (56)$$

所提出的二阶精确 ETPF 可以替代 [6] 所述混合滤波器中的标准 ETPF；应用于空间扩展系统时，还可以与局部化结合。更具体地，混合滤波器将似然 (2) 分解为

$$\pi(\mathbf{y} | \mathbf{z}) = \pi(\mathbf{y} | \mathbf{z})^\alpha \times \pi(\mathbf{y} | \mathbf{z})^{1-\alpha}, \quad (57)$$

并对两个因子分别应用不同的滤波器。另一方面， R -局部化会在计算域的每个网格点 x_k 产生不同的变换矩阵 $\mathbf{D}(x_k)$ 。更多细节参见 [5, 22]。




图 1. 在 Lorenz-63 模型上，不同二阶精确 LETF 与 ETPF、ESRF 的比较：RMS 误差（左）和 CRPS（右）随集合规模 M 的变化。图中还给出了采用重采样、集合规模为 $M = 1000$ 的标准粒子滤波器所得到的 RMS 误差与 CRPS。

7 数值算例

下面展示第 6 节所总结的二阶精确 ETPF 的数值表现。前两个实验分别采用 Lorenz-63 和 Lorenz-96 模型，并沿用 [6] 的数据同化设置。最后，将二阶精确滤波器用于场景观看模型 *SceneWalk*[9] 的参数估计。

7.1 Lorenz-63

采用标准参数 $\sigma = 10$ 、 $\rho = 28$ 和 $\beta = 8/3$ 的混沌 Lorenz-63 系统 [17]。以 $\Delta t_{\text{obs}} = 0.12$ 的观测间隔观测该三维系统的第一个分量，观测误差方差为 $R = 8$ ，总计执行 $K = 500,000$ 个同化步骤。由于模型动力学是确定性的，采用粒子再生

$$z_j^a \rightarrow z_j^a + \sum_{i=1}^M (z_i^f - \bar{z}^f) \frac{\beta \xi_{ij}}{\sqrt{M-1}}, \quad (58)$$

其中 $\beta = 0.2$ ， ξ_{ij} 是均值为零、方差为一的独立同分布高斯随机变量。采用 $\beta = 0.15$ 和 $\beta = 0.25$ 的模拟与本文报告结果相近。[6, 5] 已经使用过这一数据同化设置，因为它会产生非高斯的预报与分析分布，并且在集合规模很大时，粒子滤波器能够优于 EnKF。

标准重采样粒子滤波器、EnKF 和 ETPF 的比较见 [5]。本文则关注二阶精确滤波器在 $M \in \{15, 20, \dots, 35\}$ 的小集合规模下的性能。所得时间平均 RMS 误差见图 1。可以清楚看到，当 $M \geq 25$ 时，二阶修正 ETPF 和采用最优旋转矩阵的 NETF 得到最小 RMS 误差；对于更小的集合规模，标准集合平方根滤波器 (ESRF) [10] 最优。除 $M = 35$ 外，标准 ETPF 都缺乏竞争力。对 Lorenz-63 系统观测分量计算的连续秩概率评分 (CRPS) [3] 也得到相同结论，结果同样见图 1。

图 1 还给出了两种 NETF 实现的 RMS 误差：一种按照 [25] 的建议随机选择正交矩阵 Q ，另一




图 2. 应用于 Lorenz-63 模型的混合滤波器：标准 ETPF（左）与二阶精确 ETPF（右）。图中给出时间平均 RMS 误差随桥接参数 α 的变化。注意， $\alpha = 0$ 对应标准 ESRF； $\alpha = 1$ 在左右两图中分别对应 ETPF 与二阶修正 ETPF。




图 3. 应用于 Lorenz-63 模型的二阶混合 ETPF-ESRF 与混合 NETF-ESRF。左图用 $\lambda = 10$ 的 Sinkhorn 近似求解最优输运问题；右图的混合 NETF-ESRF 采用式 (35) 定义的正交矩阵 Q 。图中给出时间平均 RMS 误差随桥接参数 α 的变化。

种取 $Q = I$ 。可以看出，两种选择都会显著增大 RMS 误差。

接下来在 [6] 提出的混合滤波器框架内测试二阶精确变换滤波器。具体而言，对 $M = 15$ 到 $M = 35$ 的不同集合规模，实现 [6] 的混合滤波器，并首先应用二阶精确变换滤波器。混合方法的桥接参数 α 这样选择： $\alpha = 0$ 对应标准 ESRF， $\alpha = 1$ 对应纯二阶精确 ETPF。我们对固定桥接参数 $\alpha \in \{0, 0.1, 0.2, \dots, 0.9, 1.0\}$ 进行实验，并在图 2 中将所得 RMS 误差与基于标准 ETPF 的混合方法比较。二阶修正带来的改进清晰可见。在这两种情况下，ETPF 都使用底层最优输运问题的直接求解器实现。




图 4. 应用于 Lorenz-96 模型的二阶混合 ETPF-LETKF 与混合 NETF-LETKF。左图以 $\lambda = 10$ 的 Sinkhorn 近似求解最优输运问题；右图在各网格点采用式 (35) 定义的正交矩阵 $\mathbf{Q}$ 。图中给出时间平均 RMS 误差随桥接参数 α 的变化； $\alpha = 0$ 对应 LETKF。

随后，用正则化参数 $\lambda = 10$ 和 $\lambda = 40$ 的 Sinkhorn 近似取代最优输运问题的直接求解器。 $\lambda = 10$ 时所得混合滤波器的 RMS 误差见图 3； $\lambda = 40$ 时，RMS 误差非常接近图 2 右图中基于最优输运直接求解器的结果。

我们还实现 [6] 的混合滤波器，但用旋转矩阵 $\mathbf{Q}$ 按式 (35) 定义的二阶精确 NETF 替代 ETPF，并将该混合滤波器称为 NETF-ESRF。数值结果同样见图 3。总体而言，就 RMS 误差而言，二阶修正的混合 ETPF-ESRF 与采用最优旋转矩阵的 NETF-ESRF 性能相当；相应 CRPS 也有同样结论（未绘出）。

7.2 Lorenz-96

现在实现空间扩展的 Lorenz-96 系统 [18]，采用 $p = 40$ 个网格点、强迫 $F = 8$ 的标准参数设置。以 $\Delta t_{\text{obs}} = 0.11$ 的观测间隔观测每隔一个的网格点，观测误差方差为 $R = 8$ ，总计执行 $K = 50,000$ 个同化步骤。应用局部化 [22]，令局部化半径 r_{loc} 等于四个网格点，并在每个网格点 $x_k = k$ ($k = 1, \dots, 40$) 分别计算变换矩阵 $\mathbf{D}(x_k)$ 。该测试问题的集合规模 $M \in \{20, 25, 30\}$ 小于网格点数 $p = 40$ ，因此必须采用局部化。[5, 6] 已经使用过这一特定数据同化设置。

比较两种由二阶精确滤波器与局部集合变换卡尔曼滤波器 (LETKF) [13] 组合而成的混合方法。所有滤波器均使用 R -局部化 [13, 22]，每个网格点 $x_k = k$ ($k = 1, \dots, 40$) 处的输运代价为

$$J(\mathbf{D}(x_k)) = \sum_{i,j=1}^M d_{ij}(x_k) |u_i^f(x_k) - u_j^f(x_k)|^2, \quad (59)$$

其中 $u_i^f(x_k) \in \mathbb{R}$ 表示集合成员 $\mathbf{z}_i^f \in \mathbb{R}^{40}$ 在网格点 x_k 的预报值， $\mathbf{D}(x_k) = \{d_{ij}(x_k)\} \in \mathbb{R}^{M \times M}$ 。

混合 NETF-LETKF 与混合二阶修正 ETPF-LETKF 的结果见图 4。混合二阶修正 ETPF-LETKF 使用 $\lambda = 10$ 的 Sinkhorn 近似实现，相比混合 NETF-LETKF 以及 [6] 的混合 ETPF-LETKF 都有显

著改进。CRPS 给出了定性相似的评价。

7.3 动态场景观看模型的参数估计

[9] 近期提出的场景观看模型 *SceneWalk*，为场景观看期间的眼睛注视序列提供了一个相对简单的数学模型。该模型动态演化下一个注视目标的二维概率数组 $\pi_{ij}(t)$ ，并以过去的注视为条件。更具体地说，模型包含两组常微分方程

$$\frac{dA_{ij}(t)}{dt} = -\omega_A A_{ij}(t) + \omega_A \frac{S_{ij} G_A(x_i, y_j; x_f, y_f)}{\sum_{kl} S_{kl} G_A(x_k, y_l; x_f, y_f)}, \quad (60)$$

$$\frac{dF_{ij}(t)}{dt} = -\omega_F F_{ij}(t) + \omega_F \frac{G_F(x_i, y_j; x_f, y_f)}{\sum_{kl} G_F(x_k, y_l; x_f, y_f)}, \quad (61)$$

它们分别描述空间注意与注视；同时还有一组变换规则

$$u_{ij}(t) = \frac{[A_{ij}(t)]^\lambda}{\sum_{kl} [A_{kl}(t)]^\lambda} - c_{\text{inhib}} \frac{[F_{ij}(t)]^\gamma}{\sum_{kl} [F_{kl}(t)]^\gamma}, \quad (62)$$

$$u^*(u) = \begin{cases} u, & u > \eta, \\ \eta e^{(u-\eta)/\eta}, & u \leq \eta, \end{cases} \quad (63)$$

最终产生所需的注视概率数组

$$\pi_{ij}(t) = (1 - \zeta) \frac{u_{ij}^*(t)}{\sum_{kl} u_{kl}^*(t)} + \zeta \frac{1}{\sum_{kl} 1}. \quad (64)$$

式 (60)–(61) 中的函数 $G_{A/F}$ 是如下高斯函数：

$$G_{A/F}(x, y; x_f, y_f) = \frac{1}{2\pi\sigma_{A/F}^2} \exp \left[-\frac{(x - x_f)^2 + (y - y_f)^2}{2\sigma_{A/F}^2} \right], \quad (65)$$

而 $\{S_{ij}\}$ 是静态显著性图。模型的详细说明见 [9, 23]。SceneWalk 模型包含 9 个参数，[23] 已使用极大似然估计对其进行估计。这里估计式 (65) 中的 σ_F 与式 (61) 中的 ω_F ，其余七个参数取 [23] 中的值。第一个变量采用区间 [1, 5] 上的均匀先验，第二个变量采用区间 [8, 16] 上的均匀先验。

实验首先在给定的一组注视路径下，计算每个先验样本的重要性权重；随后使用 LETF 将这些样本变换为后验参数分布的等权样本。我们希望从统计相合性及后验样本分布两方面展示不同 LETF 的影响。

对给定扫描路径集合和来自先验分布的 $M = 500$ 个样本，所得重要性权重见图 5；有效样本量约为 90。

实现以下方法： $\mathbf{Q} = \mathbf{I}$ 的 NETF（对称 NETF）、采用最优 $\mathbf{Q}$ 的 NETF（最优 NETF）、ETPF 以及二阶精确 ETPF。两个参数各自的变换后样本值与先验样本值的分布见图 6。最优 NETF 使先验样本与变换后样本之间呈近似线性关系，而对称 NETF 则产生相当不规则的结构。与此同时，二阶精确 ETPF 会使变换后样本出现大幅波动，其中一些样本甚至超出先验范围。由于这种行为违反贝叶斯定律，必须将其视为强制满足严格二阶精确所产生的不良效应。先验样本与变换后样本对应的二维散点图见图 7，它更清楚地表明，二阶精确方法可能产生违反贝叶斯定律的变换后样本。尽管如此，所有方法都从定性上捕捉到了后验分布。




图 5. 对于 *SceneWalk* 模型二维参数空间中的 $M = 500$ 个样本，其重要性权重如图所示。有效样本量为 $M_{\text{eff}} \approx 90$ 。




图 6. *SceneWalk* 模型的先验样本与后验样本：最优 NETF（左图上行）、对称 NETF（右图上行）。两图还分别给出二阶修正 ETPF（左图下行）与 ETPF（右图下行）以供比较。最优 NETF 与 ETPF 均给出相对集中的样本集，并呈近似线性关系。




图 7. *SceneWalk* 模型的先验样本与后验样本：最优 NETF（左）与对称 NETF（右）。两图还分别给出二阶修正 ETPF 与 ETPF 以供比较。可以清楚看到，对称 NETF 和二阶修正 ETPF 产生了超出先验样本范围的后验样本。

8 结论

本文提出并测试了 ETPF 的二阶变体。这些修正在计算上很有吸引力，因为它们允许用 Sinkhorn 近似取代计算代价高昂的最优输运问题求解。此外，若将 Sinkhorn 近似中的正则化参数 λ 置为零，则可恢复 NETF[25]，其采用式 (35) 中最优选择的正交矩阵 $\mathbf{Q}_{\text{opt}}$ ；而 $\lambda \rightarrow \infty$ 时，则在形式上回到 ETPF 的最优输运实现。作为附带结果，我们还发现，与 [25] 建议的随机选择相比，采用最优正交矩阵 $\mathbf{Q}$ 的 NETF 会得到更小的 RMSE。

二阶精确 ETPF 可以纳入 [6] 的混合集合变换粒子滤波框架，也可以按 Lorenz-96 模型这类空间扩展演化方程的需要，与局部化 [10, 22, 5] 结合。

Lorenz-63 和 Lorenz-96 模型上的数值结果证实，本文提出的方法与 [6] 的混合方法相结合，为执行序贯数据同化提供了一个强有力的框架。还应指出，本文考虑的所有方法都可以与其他提议分布结合，以产生更均衡的重要性权重 (7)[26]。

不过，二阶精确需要付出代价：变换矩阵 $\widehat{\mathbf{D}}$ 的元素不一定像 ETPF 变换矩阵 $\mathbf{D}$ 那样非负。因此，分析集合未必包含在预报集合所张成的凸包内。当状态只能取有界区间或半区间中的值时，这会造成非物理状态；SceneWalk 模型已经展示了这一点。

致谢

感谢 Hans-Rudolf Künsch 和 Sylvain Robert 就线性集合变换滤波器的二阶修正所作的讨论。还要感谢 Ralf Engbert 和 Heiko Schütt 提供第 7.3 节所用数据集。本研究部分得到德国科学基金会 (DFG) CRC 1114 项目“复杂系统中的尺度级联” (Scaling Cascades in Complex Systems) 之子项目 (A02) “大气流动的多尺度数据与渐近模型同化” (Multiscale data and asymptotic model assimilation for atmospheric flows) 的资助。

参考文献

- [1] J. ANDERSON, *A non-Gaussian ensemble filter update for data assimilation*, Monthly Weather Review, 138 (2010), pp. 4186–4198.
- [2] T. BENGTTSSON, P. BICKEL, AND B. LI, *Curse of dimensionality revisited: Collapse of the particle filter in very large scale systems*, in IMS Lecture Notes - Monograph Series in Probability and Statistics: Essays in Honor of David F. Freedman, vol. 2, Institute of Mathematical Sciences, 2008, pp. 316–334.
- [3] J. BRÖCKER, *Evaluating raw ensembles with the continuous ranked probability score*, Q.J.R. Meteor. Soc., 138 (2012), pp. 1611–1617.
- [4] R. BUCY AND P. JOSEPH, *Filtering for stochastic processes with applications to guidance*, AMS Chelsea Publishing, Providence, Rhode Island, 2nd ed., 1987.
- [5] Y. CHEN AND S. REICH, *Assimilating data into scientific models: An optimal coupling perspective*, in Frontiers in Applied Dynamical Systems: Reviews and Tutorials, vol. 2, Springer-Verlag, New York, 2015, pp. 75–118.
- [6] N. CHUSTAGULPROM, S. REICH, AND M. REINHARDT, *A hybrid ensemble transform filter for nonlinear and spatially extended dynamical systems*, SIAM/ASA J. Uncertainty Quantification, 4 (2016), pp. 592–608.
- [7] M. CUTURI, *Sinkhorn distances: Lightspeed computation of optimal transport*, in NIPS 2013, 2013.
- [8] A. DOUCET, N. DE FREITAS, AND N. G. (EDS.), *Sequential Monte Carlo methods in practice*, Springer-Verlag, Berlin Heidelberg New York, 2001.
- [9] R. ENGBERT, H. A. TRUKENBROD, S. BARTHELMÉ, AND F. A. WICHMANN, *Spatial statistics and attentional dynamics in scene viewing*, Journal of Vision, 15 (2015).
- [10] G. EVENSEN, *Data assimilation. The ensemble Kalman filter*, Springer-Verlag, New York, 2006.
- [11] M. FREI AND H. KÜNSCH, *Bridging the ensemble Kalman and particle filters*, Biometrika, 100 (2013), pp. 781–800.
- [12] G. FREILING, V. MEHRMANN, AND H. XU, *Existence, uniqueness, and parametrization of Lagrangian invariant subspaces*, SIAM J. Matrix Anal. Appl., 23 (2002), pp. 1045–1069.
- [13] B. HUNT, E. KOSTELICH, AND I. SZUNYOGH, *Efficient data assimilation for spatialtemporal chaos: A local ensemble transform Kalman filter*, Physica D, 230 (2007), pp. 112–137.
- [14] A. LAUB, *A Schur method for solving algebraic Riccati equations*, IEEE Trans. Automatic Control, 24 (1979), pp. 913–921.
- [15] K. LAW, A. STUART, AND K. ZYGALAKIS, *Data Assimilation: A Mathematical Introduction*, Springer-Verlag, New York, 2015.
- [16] J. LEI AND P. BICKEL, *A moment matching ensemble filter for nonlinear and non-Gaussian data assimilation*, Mon. Weath. Rev., 139 (2011), pp. 3964–3973.
- [17] E. LORENZ, *Deterministic non-periodic flows*, J. Atmos. Sci., 20 (1963), pp. 130–141.
- [18] ———, *Predictability: A problem partly solved*, in Proc. Seminar on Predictability, vol. 1, ECMWF, Reading, Berkshire, UK, 1996, pp. 1–18.
- [19] S. METREF, E. COSME, C. SNYDER, AND P. BRASSEUR, *A non-Gaussian analysis scheme using rank histograms for ensemble data assimilation*, Nonlinear Processes in Geophysics, 21 (2013), pp. 869–885.

- [20] I. OLKIN AND F. PUKELSHEIM, *The distance between two random vectors with given dispersion matrices*, Linear Algebra and its Applications, 48 (1982), pp. 257–263.
- [21] S. REICH, *A nonparametric ensemble transform method for Bayesian inference*, SIAM J. Sci. Comput., 35 (2013), pp. A2013–A2024.
- [22] S. REICH AND C. COTTER, *Probabilistic Forecasting and Bayesian Data Assimilation*, Cambridge University Press, Cambridge, 2015.
- [23] H. SCHÜTT, L. ROTHKEGEL, H. TRUKENBROD, S. REICH, F. WICHMANN, AND R. ENGBERT, *Likelihood-based parameter estimation and comparison of dynamical cognitive models*, Tech. Rep. ArXiv:1606.07309, accepted for publication in Psychological Review, University of Potsdam, 2016.
- [24] A. STORDAL, H. KARLSEN, G. NÆVDAL, H. SKAUG, AND B. VALLÉS, *Bridging the ensemble Kalman filter and particle filters: the adaptive Gaussian mixture filter*, Comput. Geosci., 15 (2011), pp. 293–305.
- [25] J. TÖDTER AND B. AHRENS, *A second-order exact ensemble square root filter for nonlinear data assimilation*, Mon. Wea. Rev., 143 (2015), pp. 1347–1367.
- [26] P. VAN LEEUWEN, *Nonlinear data assimilation for high-dimensional systems*, in *Frontiers in Applied Dynamical Systems: Reviews and Tutorials*, vol. 2, Springer-Verlag, New York, 2015, pp. 1–73.
- [27] W. WONHAM, *On a matrix Riccati equation of stochastic control*, SIAM J. Contr., 6 (1968), pp. 681–697.
- [28] X. XIONG, I. NAVON, AND B. UZUNGOGLU, *A note on the particle filter with posterior Gaussian resampling*, Tellus, 85A (2006), pp. 456–460.