

变分序贯蒙特卡洛

Variational Sequential Monte Carlo*

Christian A. Naesseth¹ Scott W. Linderman²

Rajesh Ranganath³ David M. Blei²

¹ 林雪平大学 ² 哥伦比亚大学 ³ 纽约大学

摘要

近期大规模概率推断中的许多进展都依赖变分方法。变分方法的成功取决于两点：(i) 构造灵活的参数化分布族；(ii) 优化参数，从该分布族中找到最接近精确后验的成员。本文提出一个新的近似分布族——变分序贯蒙特卡洛 (VSMC) 族，并说明如何在变分推断中优化它。VSMC 融合了变分推断 (VI) 与序贯蒙特卡洛 (SMC)，为实践者提供灵活、准确且强大的贝叶斯推断方法。VSMC 是一种能够任意精确地逼近后验、同时仍可高效优化其参数的变分分布族。我们在状态空间模型、金融数据的随机波动率模型，以及脑神经回路的深度马尔可夫模型上展示了它的用途。

1 引言

自然图像、文本和医疗记录等复杂数据需要精细的模型与算法。近年来，这些具有挑战性的领域中的进展依赖于变分推断 (VI) (Kingma and Welling, 2014; Hoffman et al., 2013; Ranganath et al., 2016a)。变分推断擅长快速近似模型的后验，但近似只有足够准确才有用。挑战在于兼顾忠实的后验近似与快速优化。

我们提出一种新的近似分布族，称为变分序贯蒙特卡洛 (VSMC)。VSMC 融合 VI 与序贯蒙特卡洛 (SMC) (Stewart and McCarty, 1992; Gordon et al., 1993; Kitagawa, 1996)，为实践者提供灵活、准确且强大的近似贝叶斯推断算法。VSMC 是一种高效算法，能够任意精确地逼近后验。

标准 SMC 用从提议分布中迭代抽取的 N 个带权粒子近似隐变量的后验分布。变分 SMC 的思路是：用提议分布的参数索引隐变量上的一个分布族。该变分族中的每个分布都对应某个特定的提议分布；要从中采样，先运行 SMC 生成一组粒子，再按与其权重成正比的概率随机选取一个。与典型的变分族不同，VSMC 族可以在后验近似精度与计算复杂度之间作权衡：粒子数 N 越大，精度越高，计算代价也越大。

*载于第 21 届人工智能与统计国际会议 (AISTATS) 论文集，2018 年，西班牙兰萨罗特岛。PMLR 第 84 卷。版权归作者所有，2018 年。




图 1 VSMC 与 IWAE 的比较。(a) VSMC 用 SMC 构造一组带权粒子轨迹，再根据最终权重抽取一条。点的大小与权重 w_t^i 成正比；灰色箭头表示祖先 a_{t-1}^i ；蓝色箭头表示选中的路径 $b_{1:T}$ 。(b) 重要性加权自编码器 (IWAE) 采取同样的步骤，但不进行重采样。这会随时间增长导致粒子退化：到时刻 T ，只有一个粒子的权重不可忽略。(c) 证据下界 (ELBO) 受这种退化影响： T 较小时各方法相近；随着时间增长，IWAE 相较标准变分贝叶斯 (VB) 的改进很小，而 VSMC 仍能达到接近真实对数边缘似然的值。

我们构造 VSMC 近似分布族，推导相应的变分下界，并设计随机梯度上升算法来优化其参数。我们将 VSMC 与重要性加权自编码器 (IWAE) (Burda et al., 2016) 联系起来，说明 IWAE 下界是 VSMC 下界的特例。作为说明，考虑近似下述关于隐变量 $x_{1:T}$ 与观测 $y_{1:T}$ 的后验：

$$p(x_{1:T} | y_{1:T}) = \prod_{t=1}^T \mathcal{N}(x_t; 0, 1) \mathcal{N}(y_t; x_t^2, 1) / p(y_{1:T}).$$

这是一个简单的高斯状态空间模型 (SSM)，每个时刻的观测值依赖于隐状态的平方。图 1c 展示了 VSMC、IWAE 与标准 VB 的近似能力。随着序列长度 T 增长，朴素重要性采样实际上退化为只使用一个粒子。相比之下，VSMC 维持了粒子集合的多样性，从而得到显著更紧的对数边缘似然 $\log p(y_{1:T})$ 下界。

本文着重讨论状态空间模型与时间序列模型中的推断，但强调 VSMC 与标准 SMC 一样，适用于任意概率模型序列 (Del Moral et al., 2006; Doucet and Johansen, 2009; Naesseth et al., 2014)。

第 5 节用模拟数据与真实数据展示 VSMC 的优势。首先，我们在模拟的线性高斯 SSM 数据上说明，VSMC 可以优于 (局部) 最优提议分布 (Doucet et al., 2001; Doucet and Johansen, 2009)。随后，我们在金融市场汇率的随机波动率模型上比较 VSMC 与 IWAE，发现 VSMC 得到更好的后验推断，并学得更高效率的提议分布。最后，我们用基于循环神经网络的概率模型研究猕猴神经元记录。VSMC 达到与 IWAE 相同的精度，但所需计算更少。

相关工作 已有大量工作致力于为 SMC 学习良好的提议分布 (Cornebise, 2009)。Guarniero et al. (2017) 通过迭代细化自适应地调整提议分布。Naesseth et al. (2015) 对 (局部) 最优提议分布 (Doucet and Johansen, 2009) 作蒙特卡洛近似。Gu et al. (2015) 利用 SMC 样本，最小化从后验到提议分布的 Kullback-Leibler (KL) 散度来学习提议分布；当初始 SMC 提议分布较差时，这一策略可能具

有很高的方差。[Paige and Wood \(2016\)](#) 通过前向模拟并反演模型来学习提议分布。与这些方法不同，VSMC 针对从 SMC 采样过程到后验的 KL 散度直接优化提议分布。

VSMC 在后验近似中使用辅助变量。这与 VI 中的相关工作有关，例如哈密顿变分推断 ([Salimans et al., 2015](#))、变分高斯过程 ([Tran et al., 2016](#))、层次变分模型 ([Ranganath et al., 2016b](#)) 和深度辅助变分自编码器 ([Maaløe et al., 2016](#))。另一类方法用一系列可逆函数，将简单的变分近似变换为复杂近似 ([Rezende and Mohamed, 2015](#); [Dinh et al., 2014](#))。这些丰富的近似形式都可以嵌入 VSMC，以构造更灵活的提议分布。

[Archer et al. \(2015\)](#); [Johnson et al. \(2016\)](#) 为具有共轭动态结构的状态空间模型发展了变分推断；[Krishnan et al. \(2017\)](#) 则为具有非线性动态和加性高斯噪声的模型构造了变分近似。相比之下，VSMC 不依赖于动态和噪声的具体分布选择。

重要性加权自编码器 ([Burda et al., 2016](#)) 得到的下界与变分重要性采样 (VIS) 相同，后者是 VSMC 的一个特例。不过，VIS 提供了一种新的解释，使我们能够得到更准确的变分近似；这与 [Cremer et al. \(2017\)](#); [Bachman and Precup \(2015\)](#) 对 IWAE 的另一种解释有关。变分粒子近似 ([Saeedi et al., 2014](#)) 也会随粒子数增加而改善，但它局限于离散隐变量。

最后，对数边缘似然的下界 (6) 也由 [Maddison et al. \(2017\)](#) 和 [Le et al. \(2017\)](#) 同期独立提出。他们的工作与本文的区别在于下界的推导方式，以及所探讨的推论。[Maddison et al. \(2017\)](#); [Le et al. \(2017\)](#) 对 SMC 的对数边缘似然估计应用 Jensen 不等式得到该下界，重点在于模型参数的近似边缘似然估计。本文则将式 (6) 推导为新变分族 VSMC 的精确 ELBO 的一个可计算下界。这一视角不仅给出对数边缘似然的下界，也提供了一种新的后验变分近似。

2 背景

先介绍 VSMC 的基础。令 $p(x_{1:t}, y_{1:t})$ 表示关于隐变量（未观测变量） $x_{1:t}$ 和数据 $y_{1:t}$ 的概率模型序列，其中 $t = 1, \dots, T$ 。在贝叶斯推断中，我们关注后验分布 $p(x_{1:T} | y_{1:T})$ 的计算。时间序列文献中的两个具体例子是隐马尔可夫模型和状态空间模型 ([Cappé et al., 2005](#))。两者的联合密度都可分解为

$$p(x_{1:T}, y_{1:T}) = f(x_1) \prod_{t=2}^T f(x_t | x_{t-1}) \prod_{t=1}^T g(y_t | x_t),$$

其中 f 是 x 的先验， g 是观测（数据）分布。对大多数模型，后验 $p(x_{1:T} | y_{1:T})$ 的计算不可行，需要 VI、SMC 等近似方法。本文构造将这两种思路结合起来的后验近似。

接下来，我们回顾变分推断和序贯蒙特卡洛，基于 SMC 生成的样本构造变分近似，并建立一个可计算的目标来提升这种 SMC 变分近似的质量。为便于具体说明，我们聚焦于上述状态空间模型。但要强调，VSMC 与标准 SMC 一样，适用于任意概率模型序列 ([Del Moral et al., 2006](#); [Doucet and Johansen, 2009](#); [Naesseth et al., 2014](#))。

变分推断 在变分推断中，我们假定一个具有变分参数 λ 的近似分布族 $q(x_{1:T}; \lambda)$ ，再最小化近似族与后验之间的散度，通常为 KL 散度，使 $q(x_{1:T}; \lambda) \approx p(x_{1:T} | y_{1:T})$ 。这一最小化等价于最大化证据下界 (ELBO) (Jordan et al., 1999):

$$\mathcal{L}(\lambda) = \mathbb{E}_{q(x_{1:T}; \lambda)} [\log p(x_{1:T}, y_{1:T}) - \log q(x_{1:T}; \lambda)]. \quad (1)$$

VI 将后验推断转化成了一个优化问题。

序贯蒙特卡洛 SMC 是一种采样方法，用来近似分布序列 $p(x_{1:t} | y_{1:t})$ ，其中 $t = 1, \dots, T$ ，尤其关注后验 $p(x_{1:T} | y_{1:T})$ 。关于 SMC 的详细介绍，参见 Doucet and Johansen (2009); Doucet et al. (2001); Schön et al. (2015)。

SMC 用带权样本近似 $p(x_{1:t} | y_{1:t})$:

$$p(x_{1:t} | y_{1:t}) \approx \hat{p}(x_{1:t} | y_{1:t}) \triangleq \sum_{i=1}^N \frac{w_t^i}{\sum_{\ell} w_t^{\ell}} \delta_{x_{1:t}^i}, \quad (2)$$

其中 δ_X 是位于 X 的 Dirac 测度。

我们按 $t = 1, \dots, T$ 依次构造带权粒子集合。在 $t = 1$ 时使用标准重要性采样 $x_1^i \sim r(x_1)$ 。对于 $t > 1$ ，每一步先以与重要性权重 w_{t-1}^j 成正比的概率，对辅助的祖先变量 $a_{t-1}^i \in \{1, \dots, N\}$ 进行重采样；再从提议分布抽取新值，将它接在轨迹末端，最后重新赋权：

$$\begin{aligned} \text{重采样: } a_{t-1}^i &\sim \text{Categorical} \left(\frac{w_{t-1}^j}{\sum_{\ell} w_{t-1}^{\ell}} \right), \\ \text{提议: } x_t^i &\sim r(x_t | x_{t-1}^{a_{t-1}^i}), \\ \text{拼接: } x_{1:t}^i &= (x_{1:t-1}^{a_{t-1}^i}, x_t^i), \\ \text{重新赋权: } w_t^i &= \frac{f(x_t^i | x_{t-1}^{a_{t-1}^i}) g(y_t | x_t^i)}{r(x_t^i | x_{t-1}^{a_{t-1}^i})}. \end{aligned}$$

我们将最终的粒子（样本） $x_{1:T}^i$ 称为轨迹。图 1 的 (a)、(b) 展示了带权轨迹集合。点的大小表示权重 w_t^i ，箭头表示祖先 a_{t-1}^i 。重要性采样省略重采样步骤，因此每个粒子的祖先就是前一时刻与它对应的粒子。

轨迹 $x_{1:T}^i$ 与权重 w_T^i 确定了后验的 SMC 近似。关键在于：随着粒子数增加，后验近似可以变得任意精确。SMC 还给出边缘似然的无偏估计：

$$\hat{p}(y_{1:T}) = \prod_{t=1}^T \frac{1}{N} \sum_{i=1}^N w_t^i. \quad (3)$$

这个估计将在 VSMC 的目标中发挥重要作用。

提议分布 $r(x_t | x_{t-1})$ 是关键的设计选择。一种常用选择是模型先验 f ，对应的方法称为自助粒子滤波器 (BPF) (Gordon et al., 1993)。不过，粒子数较少时，直接从先验提议往往产生较差的近似，尤其在 x_t 为高维变量时。变分 SMC 针对这一缺点，学习参数化的提议分布，以实现高效推断。

3 变分序贯蒙特卡洛

我们提出 VSMC：一类基于 SMC 的新变分近似。先定义如何从 VSMC 族采样，再推导其分布。虽然生成样本很直接，但密度难以计算。因此，我们推导一个可计算的目标——ELBO 的新下界，使其适于随机优化。随后给出拟合变分参数的算法，最后探讨如何用变分期望最大化（VEM）学习模型参数。

要从 VSMC 族中采样，先运行 SMC（提议分布由变分参数 λ 参数化），再从后验的经验近似 (2) 中抽取一个样本。由于提议分布 $r(x_t | x_{t-1}; \lambda)$ 依赖 λ ，SMC 的经验近似也依赖它。算法 1 概括了 VSMC 族的生成过程。

算法 1 变分序贯蒙特卡洛

输入： 目标 $p(x_{1:T}, y_{1:T})$ ，提议分布 $r(x_t | x_{t-1}; \lambda)$ ，以及粒子数 N 。

- 1: **对于** $i = 1 \dots N$ **执行**
 - 2: 采样 x_1^i ，分布为 $r(x_1; \lambda)$
 - 3: 设置 $w_1^i = f(x_1^i) g(y_1 | x_1^i) / r(x_1^i; \lambda)$
 - 4: **结束 对于**
 - 5: **对于** $t = 2 \dots T$ **执行**
 - 6: **对于** $i = 1 \dots N$ **执行**
 - 7: 采样 a_{t-1}^i ，其中 $\Pr(a_{t-1}^i = j) = \frac{w_{t-1}^j}{\sum_{\ell} w_{t-1}^{\ell}}$
 - 8: 采样 x_t^i ，分布为 $r(x_t | x_{t-1}^{a_{t-1}^i}; \lambda)$
 - 9: 设置 $x_{1:t}^i = (x_{1:t-1}^{a_{t-1}^i}, x_t^i)$
 - 10: 设置 $w_t^i = f(x_t^i | x_{t-1}^{a_{t-1}^i}) g(y_t | x_t^i) / r(x_t^i | x_{t-1}^{a_{t-1}^i}; \lambda)$
 - 11: **结束 对于**
 - 12: **结束 对于**
 - 13: 采样 b_T ，其中 $\Pr(b_T = j) = w_T^j / \sum_{\ell} w_T^{\ell}$
 - 14: **返回** $x_{1:T} \triangleq x_{1:T}^{b_T}$
-

变分分布 $q(x_{1:T}; \lambda)$ 将采样过程中产生的全部变量边缘化，只保留输出样本 $x_{1:T}$ 。这个边缘分布来自 VSMC 所生成的所有变量的联合分布：

$$\begin{aligned}
 \tilde{\phi}(x_{1:T}^{1:N}, a_{1:T-1}^{1:N}, b_T; \lambda) &= \underbrace{\left[\prod_{i=1}^N r(x_1^i; \lambda) \right]}_{\text{步骤 2}} \\
 &\cdot \prod_{t=2}^T \underbrace{\prod_{i=1}^N \left[\frac{w_{t-1}^{a_{t-1}^i}}{\sum_{\ell} w_{t-1}^{\ell}} r(x_t^i | x_{t-1}^{a_{t-1}^i}; \lambda) \right]}_{\text{步骤 7}} \underbrace{\left[\frac{w_T^{b_T}}{\sum_{\ell} w_T^{\ell}} \right]}_{\text{步骤 13}}. \tag{4}
 \end{aligned}$$

公式下方标注了对应的算法步骤。在这个联合分布中，最终输出样本由第 b_T 条轨迹给出，即 $x_{1:T} = x_{1:T}^{b_T}$ 。注意，数据 $y_{1:T}$ 通过权重进入该分布，也可以通过提议分布进入。这个联合密度容易计算，但变分推断需要的是 $x_{1:T}$ 的边缘分布。下面推导这一分布。

令 $b_t \triangleq a_t^{b_{t+1}}$ ($t \leq T-1$) 表示算法 1 返回的轨迹 $x_{1:T}$ 的祖先索引。令 $\neg b_{1:T}$ 表示各时刻不在 $(b_1, \dots, b_T)$ 这条路径上的粒子索引，也就是算法未返回的粒子。祖先数组中的被保留项为 $a_{t-1}^{b_t} = b_{t-1}$ ，因此未保留的祖先变量记为 $a_{1:T-1}^{\neg b_{2:T}}$ 。在固定返回路径及其索引后，下式中的 $\tilde{\phi}$ 表示其余粒子按原重采样和提议核生成的归一化密度；路径的固定依赖在记号中省略。于是 $x_{1:T} = x_{1:T}^{b_{1:T}} = (x_1^{b_1}, \dots, x_T^{b_T})$ 的边缘分布由下述命题给出。

命题 1 VSMC 在 $x_{1:T}$ 上的近似分布为

$$\begin{aligned} q(x_{1:T} | y_{1:T}; \lambda) \\ = p(x_{1:T}, y_{1:T}) \mathbb{E}_{\tilde{\phi}(x_{1:T}^{\neg b_{1:T}}, a_{1:T-1}^{\neg b_{2:T}}; \lambda)} \left[\hat{p}(y_{1:T})^{-1} \right]. \end{aligned} \quad (5)$$

证明 参见补充材料 A.1 节。 $\square$

这一形式很直观：变分后验的密度，等于精确联合密度乘以归一化常数估计倒数的期望（参见式 (3)）。虽然能用蒙特卡洛方法估计这个期望，但将估计代入对数后，得到的 $\log q(x_{1:T} | y_{1:T}; \lambda)$ 及 ELBO (1) 估计是有偏的。

代理 ELBO 为了得到可计算的目标，我们构造一个同时适于随机优化的 ELBO 下界：

$$\begin{aligned} \tilde{\mathcal{L}}(\lambda) &\triangleq \sum_{t=1}^T \mathbb{E}_{\tilde{\phi}(x_{1:t}^{1:N}, a_{1:t-1}^{1:N}; \lambda)} \left[\log \left(\frac{1}{N} \sum_{i=1}^N w_t^i \right) \right] \\ &= \mathbb{E} [\log \hat{p}(y_{1:T})] \end{aligned} \quad (6)$$

我们称 $\tilde{\mathcal{L}}(\lambda)$ 为代理 ELBO。它是 VSMC 的真实 ELBO 的下界；等价地， $\log p(y_{1:T}) - \tilde{\mathcal{L}}(\lambda)$ 是变分后验到真实后验的 KL 散度的上界。下述定理将这一结论形式化。

定理 1 (代理 ELBO) 当 q 由式 (5) 定义时，代理 ELBO (6) 是 ELBO (1) 的下界，即

$$\log p(y_{1:T}) \geq \mathcal{L}(\lambda) \geq \tilde{\mathcal{L}}(\lambda).$$

证明 参见补充材料 A.2 节。 $\square$

代理 ELBO 是 SMC 对数边缘似然估计的期望。从 VSMC 变分近似中采样（算法 1）时，可以顺便得到它的无偏估计。我们运行该算法，并利用这一估计对代理 ELBO 进行随机优化。

随机优化 虽然代理 ELBO 中的期望仍无闭式表达，但可以用蒙特卡洛方法估计它及其梯度。这就得到一种随机优化算法，用于寻找 VSMC 族的最优变分参数。

假设提议分布 $r(x_t | x_{t-1}; \lambda)$ 可以重参数化，即对某个不依赖 λ 的分布 s ，可以通过设置 $x_t = h(x_{t-1}, \varepsilon_t; \lambda)$ 、 $\varepsilon_t \sim s(\varepsilon_t)$ 来从 r 采样。在这一假设下，利用重参数化技巧 (Kingma and Welling, 2014; Rezende et al., 2014)，可将式 (6) 的梯度改写为

$$\begin{aligned}\nabla \tilde{\mathcal{L}}(\lambda) &= g_{\text{rep}} + g_{\text{score}} \\ g_{\text{rep}} &= \mathbb{E} [\nabla \log \hat{p}(y_{1:T})], \\ g_{\text{score}} &= \mathbb{E} \left[\log \hat{p}(y_{1:T}) \nabla \log \tilde{\phi}(a_{1:T-1}^{1:N} | \varepsilon_{1:T}^{1:N}; \lambda) \right].\end{aligned}\tag{7}$$

该展开来自乘积法则，与 Ruiz et al. (2016) 和 Naesseth et al. (2017) 的广义重参数化推导相同。注意，权重 w_t^i 和 $\hat{p}(y_{1:T})$ 中隐含的所有 x_t^i ，现在都替换成了重参数化表达 $h(\cdot; \lambda)$ 。祖先变量是离散的，无法作这种重参数化，因此式 (7) 中的得分函数项 g_{score} 可能具有很高的方差。

第 5 节将通过实验评估优化时忽略 g_{score} 的影响。我们在一个小型状态空间模型中，比较保留与忽略得分函数项的优化；对这个模型，下述标准方差缩减技术已经足够。注意到祖先变量 a_{t-1} 不影响时刻 t 之前的权重，我们使用 Rao-Blackwell 化 (Robert and Casella, 2004; Ranganath et al., 2014) 来降低方差：

$$g_{\text{score}} = \sum_{t=2}^T \mathbb{E} \left[\log \frac{\hat{p}(y_{1:T})}{\hat{p}(y_{1:t-1})} \left(\sum_{i=1}^N \nabla \log \frac{w_{t-1}^{a_{t-1}^i}}{\sum_{\ell} w_{t-1}^{\ell}} \right) \right].\tag{8}$$

此外，我们将得分函数 $\nabla \log \tilde{\phi}(a_{1:T-1}^{1:N} | \varepsilon_{1:T}^{1:N}; \lambda)$ 与未来各步对数平均权重之和的期望估计结合，用作控制变量 (Ranganath et al., 2014)。

我们发现，忽略祖先变量带来的得分函数项 g_{score} (式 (8)) 会使收敛更快，而最终 ELBO 的差别很小。这相当于用下式近似 $\tilde{\mathcal{L}}$ 的梯度：

$$\nabla \tilde{\mathcal{L}}(\lambda) \approx \mathbb{E} [\nabla \log \hat{p}(y_{1:T})] = g_{\text{rep}}.\tag{9}$$

我们建议用这个梯度优化 VSMC 的变分参数。更多细节见补充材料 A.3 节，其中还给出一般的类得分函数估计器和控制变量。

算法 现在说明优化 VSMC 变分近似的完整算法。我们从 $s(\cdot) \tilde{\phi}(\cdot | \cdot; \lambda)$ 中抽取一个样本，以估计式 (9)，得到随机梯度 $\hat{\nabla} \tilde{\mathcal{L}}(\lambda)$ 。该样本是在 VSMC 采样 (算法 1) 过程中顺便得到的。步长采用 Adam (Kingma and Ba, 2015)，或 Kucukelbir et al. (2017) 提出的序列 ρ^n ：

$$\begin{aligned}\rho^n &= \eta \cdot n^{-1/2+\delta} \cdot (1 + \sqrt{s^n})^{-1}, \\ s^n &= t \left(\widehat{\nabla} \tilde{\mathcal{L}}(\lambda^n) \right)^2 + (1-t)s^{n-1},\end{aligned}\tag{10}$$

其中 n 为迭代次数。我们设置 $\delta = 10^{-16}$ 、 $t = 0.1$ ，并尝试不同的 η 值。算法 2 概括了这一优化算法。¹

算法 2 VSMC 的随机优化

输入： 数据 $y_{1:T}$, 模型 $p(x_{1:T}, y_{1:T})$, 提议分布 $r(x_t | x_{t-1}; \lambda)$, 粒子数 N

输出： 变分参数 λ^*

- 1: **重复**
 - 2: 估计梯度 $\widehat{\nabla} \tilde{\mathcal{L}}(\lambda^n)$ ，其表达式见 (9)
 - 3: 计算步长 ρ^n ，使用式 (10)
 - 4: 更新 $\lambda^{n+1} = \lambda^n + \rho^n \widehat{\nabla} \tilde{\mathcal{L}}(\lambda^n)$
 - 5: **直到** 收敛
-

变分期望最大化 假设目标分布 $p(x_{1:T} | y_{1:T}; \theta)$ 含有一组未知参数 θ 。可以用变分期望最大化 (VEM) (Beal and Ghahramani, 2003) 拟合这些参数。相应的代理 ELBO 满足

$$\log p(y_{1:T}; \theta) \geq \tilde{\mathcal{L}}(\lambda, \theta)\tag{11}$$

此时归一化常数 $p(y_{1:T}; \theta)$ 是参数 θ 的函数。注意， $\tilde{\mathcal{L}}(\lambda, \theta)$ 的表达式与式 (6) 完全相同，只是权重（以及可能的提议分布）现在也依赖模型参数 θ 。类似地，重参数化梯度与式 (9) 具有相同的形式。我们可以对 θ 和 λ 同时作随机优化，最大化式 (11) 的下界。借助数据子采样，VSMC 可以扩展到由条件独立序列组成的大规模数据集 (Hoffman et al., 2013; Titsias and Lázaro-Gredilla, 2014)。

4 理解变分 SMC 的几个视角

我们从几个角度考察 VSMC。先考虑 $N = 1$ 和 $T = 1$ 这两个特例。 $N = 1$ 时，VSMC 退化为结构化变分近似：没有重采样，变分分布恰好就是提议分布。 $T = 1$ 时，VSMC 给出一个我们称为变分重要性采样 (VIS) 的特例，并为 IWAE (Burda et al., 2016) 提供新的解释；本节前半部分将进一步讨论这一点。

随后，我们将 VSMC 采样看成从经过充分优化的 SMC 近似中采样。这意味着过去 25 年发展出的许多 SMC 理论结果都可以应用到 VSMC。本节后半部分将讨论其中一些例子。

¹使用 Adam 的参考实现见 <https://github.com/blei-lab/variational-smc>。




图 2 VIS 用高斯提议分布 $r(x; \lambda)$ 得到 $q(x; \lambda)$ ，以近似多峰分布 $p(x | y)$ 的例子。图中 Density 表示概率密度。

变分重要性采样 (VIS) $T = 1$ 对应不进行任何重采样的 SMC，也就是重要性采样。VSMC 的相应特例是 VIS。VIS 的代理 ELBO 与 IWAE 下界 (Burda et al., 2016) 完全相同。

这一等价关系为理解 IWAE 对隐变量的变分近似提供了新的直觉。如果希望使用通过 IWAE 下界学得的近似 $q(x_{1:T}; \lambda^*)$ ，就应该用算法 1，即 VIS，来生成隐变量样本。对 VIS，可以证明其代理 ELBO 总是不松于标准 VB 得到的下界（标准 VB 等价于 $N = 1$ 的 VIS）(Burda et al., 2016)。这一结果不能直接推广到 VSMC：存在一些情形，重采样反而使下界比标准 VB 或 VIS 更松。不过，在实际应用中，VSMC 下界往往优于 VIS 下界。

图 2 给出 VIS 的一个简单例子。目标多峰分布为 $p(x | y) \propto \mathcal{N}(x; 0, 1) \mathcal{N}(y; x^2/2, e^{x/2})$ ，采用正态提议分布 $r(x; \lambda) = \mathcal{N}(x; \mu, \sigma^2)$ ，并对相应的变分近似 $q(x; \lambda)$ 作核密度估计。粒子数为 $N = 10$ 。采用高斯近似的标准 VB 只能捕获两个峰中的一个，具体是哪一个取决于初始化。由此可见，即使简单的提议分布，也能带来非常灵活的后验近似。更一般的 $T > 1$ 情形，即 VSMC，同样具备这一性质。

理论性质 SMC 采样器对归一化常数的估计 $\hat{p}(y_{1:T})$ 是无偏的 (Del Moral, 2004; Pitt et al., 2012; Naesseth et al., 2014)。结合 Jensen 不等式可知，代理 ELBO $\mathbb{E}[\log \hat{p}(y_{1:T})]$ 是 $\log p(y_{1:T})$ 的下界。在 SMC 一致性所需条件下，若 $\log \hat{p}(y_{1:T})$ 一致可积，则当 $N \rightarrow \infty$ 时 (Del Moral, 2004)，

$$\tilde{\mathcal{L}}(\lambda) \rightarrow \log p(y_{1:T}), \quad \mathcal{L}(\lambda) \rightarrow \log p(y_{1:T}).$$

这意味着定理 1 中的间隙消失，VSMC 返回的轨迹分布趋于真实目标分布 $p(x_{1:T} | y_{1:T})$ 。在所引用结果的正则性条件下，KL 散度满足如下速率界：

$$\text{KL} \left(q(x_{1:T}; \lambda) \parallel p(x_{1:T} | y_{1:T}) \right) \leq \frac{c(\lambda)}{N},$$

其中 $c(\lambda) < \infty$ 为某个常数。这是 Del Moral (2004, 定理 8.3.2) 中“混沌传播”结果的一个特例。

考察式 (5)，也能非严格地理解这一结果：随着粒子数增加，边缘似然估计收敛到真实边缘似然，变分后验也收敛到真实后验。Huggins and Roy (2017) 进一步给出了 SMC 与目标分布之间多种散度和度量的界。

VSMC 与 T 与 SMC 一样，变分序贯蒙特卡洛对 T 具有良好的扩展性。Bérard et al. (2014) 在 $N = bT$ 、 $b > 0$ 且 $T \rightarrow \infty$ 时，为 SMC 近似误差 $\log \hat{p}(y_{1:T}) - \log p(y_{1:T})$ 建立了中心极限定理。在该文相同的条件下，并假设这些中心化对数似然比一致可积，可以得到

$$\begin{aligned} \text{KL} \left(q(x_{1:T}; \lambda) \parallel p(x_{1:T} | y_{1:T}) \right) &\leq -\mathbb{E} \left[\log \frac{\hat{p}(y_{1:T})}{p(y_{1:T})} \right] \\ &\xrightarrow{T \rightarrow \infty} \frac{\sigma^2(\lambda)}{2b}, \quad 0 < \sigma^2(\lambda) < \infty. \end{aligned}$$

这一结论对 VSMC 意义重大。对任意给定精度，可以选择足够大的比例常数 b ，令 $N = bT$ ，从而即使 $T \rightarrow \infty$ ，变分近似的渐近 KL 上界也能任意小；固定 b 并不意味着该上界随 T 自动趋于零。补充材料用图 1 的简单例子展示了实际效果，参见 A.4 节。我们强调，标准 VB 和 IWAE (VIS) 都不具备上述扩展性质。

5 实验研究

线性高斯状态空间模型 线性高斯状态空间模型是时间序列数据中广泛使用的模型，具有高效计算精确后验的算法。我们用它研究 VSMC 的收敛性质及有偏梯度的影响，并验证能否学得良好的提议分布。比较对象包括以先验为提议分布的自助粒子滤波器 (BPF)，以及用似然对先验作倾斜后得到的（局部）最优提议分布。

模型为

$$\begin{aligned} x_t &= Ax_{t-1} + v_t, \\ y_t &= Cx_t + e_t, \end{aligned}$$

其中 $v_t \sim \mathcal{N}(0, Q)$ 、 $e_t \sim \mathcal{N}(0, R)$ 、 $x_1 \sim \mathcal{N}(0, I)$ 。对数边缘似然 $\log p(y_{1:T})$ 可由卡尔曼滤波器计算。

我们研究用有偏梯度 (9) 优化代理 ELBO (6) 的影响。先考虑一个简单标量模型，令 $A = 0.5$ 、 $Q = 1$ 、 $C = 1$ 、 $R = 1$ 、 $T = 2$ 。提议分布采用 $r(x_t | x_{t-1}; \lambda) = \mathcal{N}(x_t; \lambda + 0.5x_{t-1}, 1)$ ，其中 $x_0 \equiv 0$ 。图 3 左侧展示了四个随机生成数据集上的梯度估计：带控制变量的 g_{score} (式 (8)) 及 g_{rep} (式 (9)) 的均值和波动范围随 λ 的变化。

当两个均值之和为零时，得到最优 λ 。忽略得分函数项 g_{score} (式 (8)) 会使最优 λ 发生偏移。然而，即使对这样简单的模型，尽管采用了第 3 节的方差缩减方法，得分函数项（红色）的方差仍比重参数化项（蓝色）高出几个数量级。这种方差会显著影响随机优化的收敛速度。




图 3 左侧：标量线性高斯模型在四个随机生成数据集上的随机梯度分量 g_{score} （式 (8)）与 g_{rep} （式 (9)）的均值和波动范围，粒子数 $N = 2$ 。右侧：四种线性高斯模型的对数边缘似然 $\log p(y_{1:T})$ ，以及使用有偏梯度（蓝色）或无偏梯度（红色）的 VSMC 的 ELBO 随迭代次数的变化。图中 Iterations 表示迭代次数，Var 表示方差。

接下来,我们考察偏移的大小及其对代理 ELBO 的影响。生成数据时设 $T = 10$ 、 $(A)_{ij} = \alpha^{|i-j|+1}$ 、 $\alpha = 0.42$ 、 $Q = I$ 、 $R = I$ 。我们考察了 $d_x = \dim(x_t)$ 、 $d_y = \dim(y_t)$ 和 C 的多种设置。稀疏 C 测量 x_t 的前 d_y 个分量；稠密 C 的元素随机生成， $C_{ij} \sim \mathcal{N}(0, 1)$ 。图 3 右侧展示真实对数边缘似然，以及使用有偏梯度（蓝色）或无偏梯度（红色）的 VSMC 的 ELBO 随迭代次数的变化。提议分布选为

$$r(x_t | x_{t-1}; \lambda) = \mathcal{N}(x_t | \mu_t + \text{diag}(\beta_t) A x_{t-1}, \text{diag}(\sigma_t^2)) .$$

其中 $\lambda = \{\mu_t, \beta_t, \sigma_t^2\}_{t=1}^T$ ，粒子数设为 $N = 4$ 。注意，虽然梯度有偏，所得的代理 ELBO 估计仍无偏。可以看到，无论用有偏还是无偏梯度训练，VSMC 的最终 ELBO 值都很接近，但有偏梯度收敛更快。因此，余下实验均采用有偏梯度。

随后，我们比较 VSMC 学习到的提议分布与 SMC 文献中的标准提议分布。最常用的是从先验 f 采样的 BPF。我们还考虑所谓的最优提议分布 $r \propto f \cdot g$ ，它最小化增量重要性权重的条件方差 (Doucet and Johansen, 2009)。表 1 给出了线性高斯 SSM 的结果，设置为 $T = 25$ 、 $Q = 0.1^2 I$ 、 $R = 1$ 、 $d_x = 10$ 、 $d_y = 1$ 。由于状态维数相对较高，BPF 的对数边缘似然估计表现出显著偏差，而采用最优提议分布的 SMC 好得多。VSMC 优于这两者，学得的准确提议分布使 ELBO 仅比真实对数边缘似然低 0.9 nat。还要强调，对大多数模型，最优提议分布无法直接获得。

随机波动率 金融计量经济学中常用的一类模型是（多元）随机波动率模型 (Chib et al., 2009)。模型为

表 1 BPF、使用（局部）最优提议分布的 SMC，以及 VSMC 的 ELBO。真实对数边缘似然为 $\log p(y_{1:T}) = -236.9$ 。

	BPF	最优提议 SMC	VSMC
ELBO	-6701.4	-253.4	-237.8

表 2 汇率数据上 $T = 119$ 的随机波动率模型的 ELBO。比较 VSMC（本文）、IWAE 与结构化 VI。

	方法	ELBO
	结构化 VI	6905.1
$N = 4$	IWAE	6911.2
	VSMC	6921.6
$N = 8$	IWAE	6912.4
	VSMC	6935.8
$N = 16$	IWAE	6913.3
	VSMC	6936.6

$$x_t = \mu + \phi(x_{t-1} - \mu) + v_t,$$

$$y_t = \beta \exp\left(\frac{x_t}{2}\right) e_t,$$

其中 $v_t \sim \mathcal{N}(0, Q)$ 、 $e_t \sim \mathcal{N}(0, I)$ 、 $x_1 \sim \mathcal{N}(\mu, Q)$ ，且 $\theta = (\mu, \phi, Q, \beta)$ 。（多元情形中的乘法逐元素进行。）该模型的 $\log p(y_{1:T}; \theta)$ 及其梯度难以计算，因此我们用 VEM 近似来寻找未知参数 θ 。我们将 VSMC 与 IWAE、结构化 VI 比较。VSMC 和 IWAE 的提议分布选为

$$r(x_t | x_{t-1}; \lambda, \theta) \propto f(x_t | x_{t-1}; \theta) \mathcal{N}(x_t; \mu_t, \Sigma_t),$$

变分参数为 $\lambda = (\mu_1, \dots, \mu_T, \Sigma_1, \dots, \Sigma_T)$ 。结构化 VI 的变分近似定义为

$$q(x_{1:T}; \lambda, \theta) = \prod_{t=1}^T r(x_t | x_{t-1}; \lambda, \theta).$$

我们研究 22 种国际货币兑美元汇率在 10 年间（2007 年 9 月至 2017 年 8 月）的月收益率，数据来自美国联邦储备系统。表 2 报告了粒子 / 样本数 $N \in \{4, 8, 16\}$ 下优化后的 ELBO（越高越好）。VSMC 相比其他方法，每个时间步改善近 0.2 nat。

理论上，增加样本数 N 可以改善 IWAE 和 VSMC 的下界。这意味着，为了提高计算效率，可以先用较少粒子学习提议分布，再在测试时按需增加 N 以提升精度。我们固定用 $N = 16$ 优化得到

的 θ^* 和 λ^* ，研究增加样本数对 VSMC 与 IWAE 的影响。图 4 表明，IWAE 的收益有限，而 VSMC 的收益可以很显著。




图 4 固定 θ^*, λ^* 后，VSMC (本文) 与 IWAE 的 ELBO 估计及置信带随粒子数 N 的变化。

深度马尔可夫模型 理解神经回路的动态是神经科学中的一个重要问题。我们研究猕猴完成伸手动作时，同步记录到的 105 个运动皮层神经元 (参见 [Gao et al., 2016](#))。每次试验中，猕猴伸手朝向 14 个目标之一；每次试验长 $T = 21$ 个时间步。训练集含 700 次试验，测试集含 84 次。

我们使用循环神经网络同时建模动态与观测。模型为

$$\begin{aligned} x_t &= \mu_\theta(x_{t-1}) + \exp(\sigma_\theta(x_{t-1})/2) v_t, \\ y_t &\sim \text{Poisson}(\exp(\eta_\theta(x_t))), \end{aligned}$$

其中 $v_t \sim \mathcal{N}(0, I)$ 、 $x_0 \equiv 0$ ， μ, σ, η 为由 θ 参数化的神经网络。状态转移动力学中的乘法逐元素进行。这是一个深度马尔可夫模型 ([Krishnan et al., 2017](#))。

在推断中，VSMC 与 IWAE 都使用以下提议分布：

$$\begin{aligned} r(x_t | x_{t-1}, y_t; \lambda) &\propto \mathcal{N}(x_t; \mu_\lambda^x(x_{t-1}), \exp(\sigma_\lambda^x(x_{t-1}))) \\ &\quad \times \mathcal{N}(x_t; \mu_\lambda^y(y_t), \exp(\sigma_\lambda^y(y_t))), \end{aligned}$$

其中 $\mu^x, \sigma^x, \mu^y, \sigma^y$ 为由 λ 参数化的神经网络，提议分布在 x_t 的各分量上因子分解。

图 5 展示了 $d_x \in \{3, 5, 10\}$ 、 $N = 8$ 时的结果。VSMC 更快达到相同的 ELBO。

6 结论

我们提出了 VSMC 族这一新的变分近似族，为实践者提供灵活、准确且强大的近似贝叶斯推断算法。VSMC 融合 VI 与 SMC，得到一种可以在后验近似精度与计算复杂度之间进行权衡的变分近似。




图5 神经元群体测试数据上, VSMC (本文) 与 IWAE 的 ELBO 估计随迭代次数的变化, 其中 $d_x \in \{3, 5, 10\}$ 、 $T = 21$ 。图中 Iterations 表示迭代次数。

致谢

Christian A. Naesseth 获得瑞典研究理事会 (VR) 资助的 Linnaeus 中心 CADICS 支持。Scott W. Linderman 获得西蒙斯基金会 SCGB-418011 支持。本研究获得 ONR N00014-11-1-0651、DARPA PPAML FA8750-14-2-0009、Alfred P. Sloan 基金会及 John Simon Guggenheim 基金会支持。

参考文献

- E. Archer, I. Memming Park, L. Buesing, J. Cunningham, and L. Paninski. Black box variational inference for state space models. *arXiv:1511.07367*, Nov. 2015.
- P. Bachman and D. Precup. Training deep generative models: Variations on a theme. In *NIPS Approximate Inference Workshop*, 2015.
- M. J. Beal and Z. Ghahramani. The variational Bayesian EM algorithm for incomplete data: with application to scoring graphical model structures. *Bayesian statistics*, 2003.
- Y. Burda, R. Grosse, and R. Salakhutdinov. Importance weighted autoencoders. In *International Conference on Learning Representations*, 2016.
- J. Bérard, P. Del Moral, and A. Doucet. A lognormal central limit theorem for particle approximations of normalizing constants. *Electronic Journal of Probability*, 2014.

- O. Cappé, E. Moulines, and T. Rydén. *Inference in Hidden Markov Models*. Springer-Verlag New York, 2005.
- S. Chib, Y. Omori, and M. Asai. *Multivariate Stochastic Volatility*, pages 365–400. Springer Berlin Heidelberg, Berlin, Heidelberg, 2009.
- J. Cornebise. *Adaptive Sequential Monte Carlo Methods*. PhD thesis, University Pierre and Marie Curie–Paris 6, 2009.
- C. Cremer, Q. Morris, and D. Duvenaud. Reinterpreting importance-weighted autoencoders. *arXiv:1704.02916*, Apr. 2017.
- P. Del Moral. *Feynman-Kac Formulae: Genealogical and interacting particle systems with applications*. Springer-Verlag New York, 2004.
- P. Del Moral, A. Doucet, and A. Jasra. Sequential monte carlo samplers. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 2006.
- L. Dinh, D. Krueger, and Y. Bengio. Nice: Non-linear independent components estimation. *arXiv:1410.8516*, 2014.
- A. Doucet and A. M. Johansen. A tutorial on particle filtering and smoothing: Fifteen years later. *Handbook of nonlinear filtering*, 12(656-704):3, 2009.
- A. Doucet, N. De Freitas, and N. Gordon. An introduction to sequential Monte Carlo methods. In *Sequential Monte Carlo methods in practice*. Springer-Verlag New York, 2001.
- Y. Gao, E. W. Archer, L. Paninski, and J. P. Cunningham. Linear dynamical neural population models through nonlinear embeddings. In *Advances in Neural Information Processing Systems*, 2016.
- N. J. Gordon, D. J. Salmond, and A. F. M. Smith. Novel approach to nonlinear/non-Gaussian Bayesian state estimation. *Radar and Signal Processing, IEE Proceedings F*, 140(2):107–113, Apr. 1993.
- S. Gu, Z. Ghahramani, and R. E. Turner. Neural adaptive sequential Monte Carlo. In *Advances in Neural Information Processing Systems*, 2015.
- P. Guarniero, A. M. Johansen, and A. Lee. The iterated auxiliary particle filter. *Journal of the American Statistical Association*, 112(520):1636–1647, 2017.
- M. D. Hoffman, D. M. Blei, C. Wang, and J. Paisley. Stochastic variational inference. *Journal of Machine Learning Research*, 14:1303–1347, May 2013.

- J. H. Huggins and D. M. Roy. Sequential Monte Carlo as approximate sampling: bounds, adaptive resampling via ∞ -ESS, and an application to particle Gibbs. *arXiv:1503.00966v2*, Mar. 2017.
- M. Johnson, D. K. Duvenaud, A. Wiltchko, R. P. Adams, and S. R. Datta. Composing graphical models with neural networks for structured representations and fast inference. In *Advances in Neural Information Processing Systems*, 2016.
- M. I. Jordan, Z. Ghahramani, T. S. Jaakkola, and L. K. Saul. An introduction to variational methods for graphical models. *Machine Learning*, 37(2):183–233, Nov. 1999.
- D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.
- D. P. Kingma and M. Welling. Auto-encoding variational Bayes. In *International Conference on Learning Representations*, 2014.
- G. Kitagawa. Monte Carlo filter and smoother for non-Gaussian nonlinear state space models. *Journal of computational and graphical statistics*, 5(1):1–25, 1996.
- R. Krishnan, U. Shalit, and D. Sontag. Structured inference networks for nonlinear state space models. In *Thirty-First AAAI Conference on Artificial Intelligence*, 2017.
- A. Kucukelbir, D. Tran, R. Ranganath, A. Gelman, and D. M. Blei. Automatic differentiation variational inference. *Journal of Machine Learning Research*, 18(1):430–474, Jan. 2017. ISSN 1532-4435.
- T. A. Le, M. Igl, T. Jin, T. Rainforth, and F. Wood. Auto-Encoding Sequential Monte Carlo. *arXiv:1705.10306*, May 2017.
- L. Maaløe, C. K. Sønderby, S. K. Sønderby, and O. Winther. Auxiliary deep generative models. In *International Conference on Machine Learning*, 2016.
- C. J. Maddison, D. Lawson, G. Tucker, N. Heess, M. Norouzi, A. Mnih, A. Doucet, and Y. Whye Teh. Filtering variational objectives. In *Advances in Neural Information Processing Systems*, 2017.
- C. A. Naesseth, F. Lindsten, and T. B. Schön. Sequential Monte Carlo for graphical models. In *Advances in Neural Information Processing Systems*, 2014.
- C. A. Naesseth, F. Lindsten, and T. B. Schön. Nested sequential Monte Carlo methods. In *International Conference on Machine Learning*, 2015.
- C. A. Naesseth, F. J. R. Ruiz, S. W. Linderman, and D. M. Blei. Reparameterization gradients through acceptance-rejection sampling algorithms. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, 2017.

- B. Paige and F. Wood. Inference networks for sequential Monte Carlo in graphical models. In *International Conference on Machine Learning*, 2016.
- M. K. Pitt, R. dos Santos Silva, P. Giordani, and R. Kohn. On some properties of Markov chain Monte Carlo simulation methods based on the particle filter. *Journal of Econometrics*, 2012.
- R. Ranganath, S. Gerrish, and D. M. Blei. Black box variational inference. In *Artificial Intelligence and Statistics*, 2014.
- R. Ranganath, A. Perotte, N. Elhadad, and D. Blei. Deep survival analysis. In *Proceedings of the 1st Machine Learning for Healthcare Conference*, pages 101–114, 2016a.
- R. Ranganath, D. Tran, and D. M. Blei. Hierarchical variational models. In *International Conference on Machine Learning*, 2016b.
- D. J. Rezende and S. Mohamed. Variational inference with normalizing flows. In *International Conference on Machine Learning*, 2015.
- D. J. Rezende, S. Mohamed, and D. Wierstra. Stochastic backpropagation and approximate inference in deep generative models. In *International Conference on Machine Learning*, 2014.
- C. Robert and G. Casella. *Monte Carlo Statistical Methods*. Springer Texts in Statistics. Springer, 2004.
- F. J. R. Ruiz, M. K. Titsias, and D. M. Blei. The generalized reparameterization gradient. In *Advances in Neural Information Processing Systems*, 2016.
- A. Saeedi, T. D. Kulkarni, V. Mansinghka, and S. Gershman. Variational particle approximations. *arXiv preprint arXiv:1402.5715*, 2014.
- T. Salimans, D. P. Kingma, and M. Welling. Markov chain Monte Carlo and variational inference: Bridging the gap. In *International Conference on Machine Learning*, 2015.
- T. B. Schön, F. Lindsten, J. Dahlin, J. Wågberg, C. A. Naesseth, A. Svensson, and L. Dai. Sequential Monte Carlo methods for system identification. In *Proceedings of the 17th IFAC Symposium on System Identification (SYSID)*, Oct 2015.
- L. Stewart and P. McCarty, Jr. Use of Bayesian belief networks to fuse continuous and discrete information for target recognition, tracking, and situation assessment. In *Proc. SPIE*, volume 1699, pages 177–185, 1992.
- M. Titsias and M. Lázaro-Gredilla. Doubly stochastic variational Bayes for non-conjugate inference. In *Proceedings of the 31st International Conference on Machine Learning*, 2014.
- D. Tran, R. Ranganath, and D. M. Blei. The variational Gaussian process. In *International Conference on Learning Representations*, 2016.

A 变分序贯蒙特卡洛——补充材料

A.1 命题 1 的证明

先注意，VSMC 算法产生的所有随机变量的分布为

$$\tilde{\phi}(x_{1:T}^{1:N}, a_{1:T-1}^{1:N}, b_T; \lambda) = \frac{w_T^{b_T}}{\sum_{\ell} w_T^{\ell}} \prod_{i=1}^N r(x_1^i; \lambda) \cdot \prod_{t=2}^T \prod_{i=1}^N \frac{w_{t-1}^{a_{t-1}^i}}{\sum_{\ell} w_{t-1}^{\ell}} r(x_t^i | x_{t-1}^{a_{t-1}^i}; \lambda). \quad (12)$$

我们关注边缘分布

$$q(x_{1:T}; \lambda) = \sum_{b_{1:T} \in \{1, \dots, N\}^T} \tilde{\phi}(x_{1:T}^{b_{1:T}}, b_{1:T}; \lambda).$$

关键观察是：给定返回轨迹 $x_{1:T}$ 后，其祖先路径索引 $b_{1:T} \mid x_{1:T}$ 在 $\{1, \dots, N\}^T$ 上均匀分布，这是各时刻粒子标签的交换对称性所致。因此，对任意固定的 $b_{1:T}$ ，有

$$q(x_{1:T}; \lambda) = \frac{\tilde{\phi}(x_{1:T}^{b_{1:T}}, b_{1:T}; \lambda)}{\tilde{\phi}(b_{1:T} \mid x_{1:T}; \lambda)} = \frac{1}{N^{-T}} \sum_{a_{1:T-1}^{-b_{2:T}}} \int \tilde{\phi}(x_{1:T}^{b_{1:T}}, x_{1:T}^{-b_{1:T}}, a_{1:T-1}^{-b_{2:T}}; \lambda) dx_{1:T}^{-b_{1:T}}, \quad (13)$$

其中

$$\begin{aligned} & \frac{1}{N^{-T}} \tilde{\phi}(x_{1:T}^{b_{1:T}}, x_{1:T}^{-b_{1:T}}, a_{1:T-1}^{-b_{2:T}}; \lambda) \\ &= N^T \frac{w_1^{b_1}}{\sum_{\ell} w_1^{\ell}} r(x_1^{b_1}; \lambda) \prod_{t=2}^T \frac{w_t^{b_t}}{\sum_{\ell} w_t^{\ell}} r(x_t^{b_t} \mid x_{t-1}^{b_{t-1}}; \lambda) \cdot \prod_{\substack{i=1 \\ i \neq b_1}}^N r(x_1^i; \lambda) \cdot \prod_{t=2}^T \prod_{\substack{i=1 \\ i \neq b_t}}^N \frac{w_{t-1}^{a_{t-1}^i}}{\sum_{\ell} w_{t-1}^{\ell}} r(x_t^i \mid x_{t-1}^{a_{t-1}^i}; \lambda) \\ &= p(x_1^{b_1}, y_1) \prod_{t=2}^T \frac{p(x_{1:t}^{b_{1:t}}, y_{1:t})}{p(x_{1:t-1}^{b_{1:t-1}}, y_{1:t-1})} \prod_{t=1}^T \frac{1}{\frac{1}{N} \sum_{\ell} w_t^{\ell}} \cdot \prod_{\substack{i=1 \\ i \neq b_1}}^N r(x_1^i; \lambda) \cdot \prod_{t=2}^T \prod_{\substack{i=1 \\ i \neq b_t}}^N \frac{w_{t-1}^{a_{t-1}^i}}{\sum_{\ell} w_{t-1}^{\ell}} r(x_t^i \mid x_{t-1}^{a_{t-1}^i}; \lambda) \\ &= p(x_{1:T}^{b_{1:T}}, y_{1:T}) \prod_{t=1}^T \frac{1}{\frac{1}{N} \sum_{\ell} w_t^{\ell}} \cdot \tilde{\phi}(x_{1:T}^{-b_{1:T}}, a_{1:T-1}^{-b_{2:T}}; \lambda). \end{aligned}$$

将上式代入式 (13)，得到

$$\begin{aligned} q(x_{1:T}; \lambda) &= p(x_{1:T}^{b_{1:T}}, y_{1:T}) \sum_{a_{1:T-1}^{-b_{2:T}}} \int \left(\prod_{t=1}^T \frac{1}{N} \sum_{i=1}^N w_t^i \right)^{-1} \cdot \tilde{\phi}(x_{1:T}^{-b_{1:T}}, a_{1:T-1}^{-b_{2:T}}; \lambda) dx_{1:T}^{-b_{1:T}} \\ &= p(x_{1:T}^{b_{1:T}}, y_{1:T}) \mathbb{E}_{\tilde{\phi}(x_{1:T}^{-b_{1:T}}, a_{1:T-1}^{-b_{2:T}}; \lambda)} \left[\left(\prod_{t=1}^T \frac{1}{N} \sum_{i=1}^N w_t^i \right)^{-1} \right]. \end{aligned} \quad (14)$$

□

A.2 定理 1 的证明

利用上面关于 $q(x_{1:T}; \lambda)$ 分布的结果, ELBO 可写为

$$\begin{aligned} \mathcal{L}(\lambda) &= \mathbb{E}_{q(x_{1:T}; \lambda)} [\log p(x_{1:T}, y_{1:T}) - \log q(x_{1:T}; \lambda)] \\ &= - \int \left\{ p(x_{1:T}^{b_{1:T}}, y_{1:T}) \mathbb{E}_{\tilde{\phi}(x_{1:T}^{-b_{1:T}}, a_{1:T-1}^{-b_{2:T}}; \lambda)} \left[\frac{1}{\prod_{t=1}^T \frac{1}{N} \sum_{i=1}^N w_t^i} \right] \right. \\ &\quad \left. \cdot \log \mathbb{E}_{\tilde{\phi}(x_{1:T}^{-b_{1:T}}, a_{1:T-1}^{-b_{2:T}}; \lambda)} \left[\frac{1}{\prod_{t=1}^T \frac{1}{N} \sum_{i=1}^N w_t^i} \right] \right\} dx_{1:T}^{b_{1:T}}. \end{aligned} \quad (15)$$

注意, $-t \log t$ 在 $t > 0$ 上是凹函数, 故条件 Jensen 不等式给出 $-\mathbb{E}[t] \log \mathbb{E}[t] \geq -\mathbb{E}[t \log t]$ 。将其用于式 (15), 得到

$$\begin{aligned} \mathcal{L}(\lambda) &\geq \int \mathbb{E}_{\tilde{\phi}(x_{1:T}^{-b_{1:T}}, a_{1:T-1}^{-b_{2:T}}; \lambda)} \left[\frac{p(x_{1:T}^{b_{1:T}}, y_{1:T})}{\prod_{t=1}^T \frac{1}{N} \sum_{i=1}^N w_t^i} \sum_{t=1}^T \log \left(\frac{1}{N} \sum_{i=1}^N w_t^i \right) \right] dx_{1:T}^{b_{1:T}} \\ &= \mathbb{E}_{\tilde{\phi}(x_{1:T}^{1:N}, a_{1:T-1}^{1:N}; \lambda)} \left[\sum_{t=1}^T \log \left(\frac{1}{N} \sum_{i=1}^N w_t^i \right) \right] = \tilde{\mathcal{L}}(\lambda), \end{aligned}$$

最后一步使用上述分解: $p(x_{1:T}, y_{1:T}) \hat{p}(y_{1:T})^{-1}$ 乘以固定路径之外的生成密度, 等于 N^T 倍的 VSMC 完整联合密度。对路径索引利用交换对称性, 再边缘化最终选择 b_T , 便得到右侧关于全部 SMC 粒子与祖先变量的期望。

□

A.3 随机优化

控制变量采用

$$\sum_{t=2}^T c_t \mathbb{E}_{s(\cdot) \tilde{\phi}(\cdot; \lambda)} \left[\sum_{i=1}^N \nabla \log w_{t-1}^{a_{t-1}^i} - N \sum_{\ell=1}^N \frac{w_{t-1}^\ell}{\sum_m w_{t-1}^m} \nabla \log w_{t-1}^\ell \right]$$

其中

$$c_t = \mathbb{E}_{s(\cdot) \tilde{\phi}(\cdot; \lambda)} \left[\sum_{t'=t}^T \log \left(\frac{1}{N} \sum_{i=1}^N w_{t'}^i \right) \right].$$

实际计算中使用 c_t 的随机估计。为保持控制变量的零均值性质, 基线估计不能额外依赖当前被中心化的祖先抽样; 可使用独立估计或历史估计。

当 $T = 2$ 且 $N > 1$ 时, 可以对祖先变量的得分函数梯度使用留一估计器:

$$\sum_{i=1}^N \mathbb{E}_{s(\cdot) \tilde{\phi}(\cdot; \lambda)} \left[\log \left(\frac{N-1}{N} \frac{\sum_{\ell=1}^N w_2^\ell}{\sum_{j \neq i} w_2^j} \right) \left(\nabla \log w_1^{a_1^i} - \sum_{\ell=1}^N \frac{w_1^\ell}{\sum_m w_1^m} \nabla \log w_1^\ell \right) \right].$$

得分函数梯度 下面推导一种适用于很一般情形的类得分函数估计器。不过，我们发现它在实践中的方差往往较高。

$$\begin{aligned}\nabla \tilde{\mathcal{L}}(\lambda) &= \nabla \mathbb{E}_{\tilde{\phi}(x_{1:T}^{1:N}, a_{1:T-1}^{1:N}; \lambda)} [\log \hat{p}(y_{1:T})] \\ &= \mathbb{E}_{\tilde{\phi}(x_{1:T}^{1:N}, a_{1:T-1}^{1:N}; \lambda)} \left[\nabla \log \hat{p}(y_{1:T}) + \log \hat{p}(y_{1:T}) \nabla \log \tilde{\phi}(x_{1:T}^{1:N}, a_{1:T-1}^{1:N}; \lambda) \right],\end{aligned}$$

其中

$$\nabla \log \hat{p}(y_{1:T}) = \nabla \sum_{t=1}^T \log \left(\frac{1}{N} \sum_{i=1}^N w_t^i \right) = \sum_{t=1}^T \sum_{i=1}^N \frac{w_t^i}{\sum_{\ell} w_t^{\ell}} \nabla \log w_t^i,$$

以及

$$\begin{aligned}\nabla \log \tilde{\phi}(x_{1:T}^{1:N}, a_{1:T-1}^{1:N}; \lambda) \\ = \sum_{i=1}^N \left[\nabla \log r(x_1^i; \lambda) + \sum_{t=2}^T \left[\nabla \log r(x_t^i | x_{t-1}^{a_{t-1}^i}; \lambda) + \nabla \log w_{t-1}^{a_{t-1}^i} - \sum_{\ell=1}^N \bar{w}_{t-1}^{\ell} \nabla \log w_{t-1}^{\ell} \right] \right].\end{aligned}$$

A.4 随维数增长的表现

本节在以下简单模型上比较各方法随维数增长的表现：

$$p(x_{1:T}, y_{1:T}) = \prod_{t=1}^T \mathcal{N}(x_t; 0, 1) \mathcal{N}(y_t; x_t^2, 1).$$

我们研究数据集 $y_t = 3$ (对所有 t)。图 6 展示了 IWAE (VIS) 与 VSMC 的样本数按维数线性增长，即 $N = 2T$ 时的结果。 T 较小时，IWAE 的最优参数接近 λ_{VSMC}^* ； T 较大时，其最优参数则接近标准 VB 的 λ_{VB}^* 。图 6 表明，让 N 与 T 成正比，VSMC 仍能在 T 增长时保持良好的近似。一般地，要将渐近 KL 上界压到任意给定阈值以下，需要进一步选取足够大的比例常数，而非仅固定 $N = 2T$ 。在一定正则条件下，状态空间模型 $p(x_{1:T}, y_{1:T})$ 也具有这一性质 (Bérard et al., 2014)。VIS 不满足这种渐近近似性质；图 6 显示其近似随 T 增长而恶化。

注意，如果趋于无穷的是单个隐状态的维数 $\dim(x_t)$ ，而不是时间点数 T ，则上述结论并不成立。



(a) $\lambda_{\text{IWAE}} = \lambda_{\text{VB}}^*$ (b) $\lambda_{\text{IWAE}} = \lambda_{\text{VSMC}}^*$

图6 简单问题中，标准 VB、IWAE 和 VSMC 的 ELBO 随维数 T 的变化。这里 IWAE 与 VSMC 的样本数设为 $N = 2T$ 。图中 Dimension 表示维数。

翻译说明

本译稿依据 arXiv:1705.11140v2 源码及其 13 页 PDF。以下修订已直接纳入正文，位置按原 PDF 标注。本次未穷尽原文错误，也未复现实验；实验数值及书目保留。

1. **代理 ELBO 与 KL 上界 (原 PDF 第 4 页, 第 3 节)**。原文把代理 ELBO 的下界关系直接称为 KL 散度的上界, 省略了平移和取负。明确写为 $\text{KL}(q\|p) = \log p(y_{1:T}) - \mathcal{L}(\lambda) \leq \log p(y_{1:T}) - \tilde{\mathcal{L}}(\lambda)$ 。
2. **路径之外的祖先索引 (原 PDF 第 4、11–12 页, 式 (5) 及其证明)**。原文使用 $a_{1:T-1}^{-b_{1:T-1}}$ 排除选中路径的祖先变量。然而 a_{t-1}^i 由时刻 t 的子粒子 i 索引, 而选中项是 $a_{t-1}^{b_t} = b_{t-1}$, 故统一改为 $a_{1:T-1}^{-b_{2:T}}$ 。同时明确路径外密度是其他粒子的重采样与提议核乘积, 并非完整联合分布的条件密度; 补全附录末步的索引求和依据。
3. **边缘化中的求和 (原 PDF 第 11 页, A.1 节式 (13) 之前)**。原文写成对 $b_{1:T}$ 取期望的联合密度; 应为对所有 $b_{1:T}$ 的联合密度求和。若再对联合密度取均匀期望, 会错误地多出 N^{-T} 因子。后续利用条件索引分布为 N^{-T} 的推导保留。
4. **控制变量的归一化项 (原 PDF 第 12 页, A.3 节第一式)**。第一项对 N 个祖先求和, 第二项漏乘了 N 。修正为

$$\sum_{i=1}^N \nabla \log w_{t-1}^{a_{t-1}^i} - N \sum_{\ell=1}^N \bar{w}_{t-1}^{\ell} \nabla \log w_{t-1}^{\ell}.$$

每个祖先均贡献一次对数归一化项的导数, 修正后条件期望为零。另补明基线不能额外依赖当前祖先抽样, 留一估计需 $N > 1$ 。

5. **渐近结论的量词与可积性 (原 PDF 第 6、13 页, 第 4 节及 A.4 节)**。将 $N \rightarrow \infty$ 语境中的有限 N 等号写为极限, 并明确采用所引 SMC 结果的正则条件。对于 $T \rightarrow \infty$ 、 $N = bT$, 式中上界趋于 $\sigma^2(\lambda)/(2b)$; 任意精度需要选择足够大的 b , 仅固定比例 (例如 $b = 2$) 并不能推出误差趋零。将用于从分布收敛推至期望收敛的可积性条件明确施加于中心化量 $\log(\hat{p}/p)$ 。
6. **对数似然与无偏性的措辞 (原 PDF 第 2、7 页, 图 1 及实验正文)**。图 1 的 ELBO 比较对象明确为对数边缘似然。实验中“所得 ELBO 无偏”明确为“代理 ELBO 的估计无偏”; 有偏梯度不等于对该目标的蒙特卡洛估计也有偏。BPF 的显著偏差指其对数似然估计, 并不否定边缘似然估计本身的无偏性。

排版约定 采用技能蓝色单栏模板。粗体使用 \bm, 迹运算符使用正体小写 tr, 微分符号使用正体 d; 普通变量 d_x, d_y 保持原义。保留原编号、步骤与引用键; 复用原矢量图。图内 particle、time 分别为粒子、时间, 其余英文含义见图注。文献题名保留原文以便检索。