

# 自编码变分贝叶斯

## Auto-Encoding Variational Bayes

Diederik P. Kingma      Max Welling

阿姆斯特丹大学机器学习组

`dppingma@gmail.com`   `welling.max@gmail.com`

### 摘要

当有向概率模型包含后验分布难以处理的连续潜变量，且数据集规模很大时，如何高效地进行推断和学习？我们提出一种随机变分推断与学习算法，它能够扩展到大规模数据集，并且在满足一些温和的可微条件时，即使面对上述难以处理的情形也能工作。我们的贡献有两个方面。首先，我们表明，对变分下界进行重参数化，可以得到一个能够直接用标准随机梯度方法优化的下界估计量。其次，我们表明，对于每个数据点都带有连续潜变量的独立同分布数据集，可以利用所提出的下界估计量，将一个近似推断模型（也称识别模型）拟合到难以处理的后验分布，从而使后验推断尤其高效。实验结果体现了这些理论优势。

## 1 引言

当有向概率模型中的连续潜变量和 / 或参数具有难以处理的后验分布时，如何高效地进行近似推断和学习？变分贝叶斯 (VB) 方法通过优化一个近似分布来逼近难以处理的后验分布。遗憾的是，常用的均值场方法要求解析计算关于近似后验的期望，而这些期望在一般情况下同样难以处理。我们将说明，如何通过重参数化变分下界，得到一个简单、可微且无偏的下界估计量。这个随机梯度变分贝叶斯 (Stochastic Gradient Variational Bayes, SGVB) 估计量，几乎可以用于任何具有连续潜变量和 / 或参数的模型，以高效地进行近似后验推断，而且可以直接用标准随机梯度上升方法进行优化。

对于每个数据点都带有连续潜变量的独立同分布数据集，我们提出自编码变分贝叶斯 (Auto-Encoding VB, AEVB) 算法。在 AEVB 中，我们利用 SGVB 估计量优化识别模型，使其能够仅通过简单的祖先采样就高效地完成近似后验推断，进而高效学习模型参数，无须对每个数据点执行代价高昂的迭代推断过程 (例如 MCMC)。学到的近似后验推断模型还可用于识别、去噪、表示学习和可视化等诸多任务。当识别模型采用神经网络时，就得到变分自编码器。




图1 本文考虑的有向图模型。实线表示生成模型  $p_{\theta}(z)p_{\theta}(x|z)$ ，虚线表示对难以处理的后验  $p_{\theta}(z|x)$  的变分近似  $q_{\phi}(z|x)$ 。变分参数  $\phi$  与生成模型参数  $\theta$  联合学习。

## 2 方法

本节的方法可以为多种包含连续潜变量的有向图模型推导下界估计量（即随机目标函数）。这里仅考虑一种常见情形：数据集独立同分布，每个数据点具有潜变量；我们希望对（全局）参数进行最大似然（ML）或最大后验（MAP）推断，对潜变量进行变分推断。例如，将这一设定扩展到对全局参数也进行变分推断的情形是直接的；对应算法见附录，其实实验留待未来开展。注意，我们的方法也适用于在线、非平稳的场景，例如流式数据；但为简便起见，这里假设数据集固定。

### 2.1 问题设定

考虑数据集  $\mathbf{X} = \{\mathbf{x}^{(i)}\}_{i=1}^N$ ，它由连续或离散变量  $\mathbf{x}$  的  $N$  个独立同分布样本组成。假设数据由某个随机过程生成，其中涉及一个未观测到的连续随机变量  $\mathbf{z}$ 。该过程分为两步：（1）从先验分布  $p_{\theta^*}(\mathbf{z})$  生成一个值  $\mathbf{z}^{(i)}$ ；（2）从条件分布  $p_{\theta^*}(\mathbf{x}|\mathbf{z})$  生成一个值  $\mathbf{x}^{(i)}$ 。我们假设先验  $p_{\theta^*}(\mathbf{z})$  和似然  $p_{\theta^*}(\mathbf{x}|\mathbf{z})$  分别来自参数化分布族  $p_{\theta}(\mathbf{z})$  和  $p_{\theta}(\mathbf{x}|\mathbf{z})$ ，其概率密度（或质量）函数关于  $\theta$  和  $\mathbf{z}$  几乎处处可微。然而，这个过程的许多部分对我们不可见：真实参数  $\theta^*$  以及潜变量的值  $\mathbf{z}^{(i)}$  均未知。

关键在于，我们不对边缘概率或后验概率作通常的简化假设。相反，我们希望得到一个在以下情形中仍能高效工作的通用算法：

1. 难以处理：边缘似然中的积分  $p_{\theta}(\mathbf{x}) = \int p_{\theta}(\mathbf{z})p_{\theta}(\mathbf{x}|\mathbf{z}) d\mathbf{z}$  难以计算，因此不能计算边缘似然或对其求导；真实后验密度  $p_{\theta}(\mathbf{z}|\mathbf{x}) = p_{\theta}(\mathbf{x}|\mathbf{z})p_{\theta}(\mathbf{z})/p_{\theta}(\mathbf{x})$  难以处理，因此不能直接使用 EM 算法；任何合理的均值场 VB 算法所需的积分也难以计算。这类困难十分常见，似然函数  $p_{\theta}(\mathbf{x}|\mathbf{z})$  只要稍微复杂一些就会出现，例如采用含非线性隐藏层的神经网络时。
2. 大规模数据集：数据量大到使全批量优化代价过高，因此希望使用较小的 minibatch（小批量），甚至单个数据点来更新参数。基于采样的方法，例如蒙特卡洛 EM，通常会过慢，因为它们一般需要对每个数据点执行代价较高的采样循环。

我们关心上述场景中的三个相关问题，并提出相应解法：

1. 对参数  $\theta$  进行高效的近似 ML 或 MAP 估计。参数本身可能就是研究对象，例如分析某种自然

过程时。参数还使我们能够模拟隐藏的随机过程，生成类似真实数据的人工数据。

2. 给定参数  $\theta$  和观测值  $\mathbf{x}$ ，对潜变量  $\mathbf{z}$  进行高效的近似后验推断。这对编码或数据表示任务很有用。
3. 对变量  $\mathbf{x}$  进行高效的近似边缘推断。这样就能完成各类需要  $\mathbf{x}$  的先验分布的推断任务。计算机视觉中的常见应用包括图像去噪、修复和超分辨率。

为解决这些问题，引入识别模型  $q_\phi(\mathbf{z}|\mathbf{x})$ ，用它近似难以处理的真实后验  $p_\theta(\mathbf{z}|\mathbf{x})$ 。注意，与均值场变分推断中的近似后验不同，它不一定按各分量独立分解，其参数  $\phi$  也不是通过某个闭式期望计算得到的。我们将介绍一种方法，联合学习识别模型参数  $\phi$  和生成模型参数  $\theta$ 。

从编码理论的角度看，未观测变量  $\mathbf{z}$  可以解释为潜在表示或编码。因此，本文也将识别模型  $q_\phi(\mathbf{z}|\mathbf{x})$  称为概率编码器：给定数据点  $\mathbf{x}$ ，它产生编码  $\mathbf{z}$  的可能取值上的分布（例如高斯分布），而这些编码都可能生成该数据点。类似地，我们将  $p_\theta(\mathbf{x}|\mathbf{z})$  称为概率解码器，因为给定编码  $\mathbf{z}$ ，它产生相应的  $\mathbf{x}$  的可能取值上的分布。

## 2.2 变分下界

对数边缘似然是各数据点的对数边缘似然之和，即  $\log p_\theta(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}) = \sum_{i=1}^N \log p_\theta(\mathbf{x}^{(i)})$ 。其中每一项均可改写为：

$$\log p_\theta(\mathbf{x}^{(i)}) = D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}^{(i)})||p_\theta(\mathbf{z}|\mathbf{x}^{(i)})) + \mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) \quad (1)$$

右端第一项是近似后验相对于真实后验的 KL 散度。由于该 KL 散度非负，右端第二项  $\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)})$  称为数据点  $i$  的对数边缘似然的（变分）下界，可写为：

$$\log p_\theta(\mathbf{x}^{(i)}) \geq \mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x}^{(i)})} \left[ -\log q_\phi(\mathbf{z}|\mathbf{x}^{(i)}) + \log p_\theta(\mathbf{x}^{(i)}, \mathbf{z}) \right] \quad (2)$$

也可以写成：

$$\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) = -D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}^{(i)})||p_\theta(\mathbf{z})) + \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x}^{(i)})} \left[ \log p_\theta(\mathbf{x}^{(i)}|\mathbf{z}) \right] \quad (3)$$

我们希望对下界  $\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)})$  关于变分参数  $\phi$  和生成参数  $\theta$  求导并优化。然而，关于  $\phi$  的下界梯度不太容易处理。对于不显含  $\phi$  的函数  $f$ ，这类问题通常采用如下朴素蒙特卡洛梯度估计量：

$$\begin{aligned} \nabla_\phi \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x}^{(i)})} [f(\mathbf{z})] &= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x}^{(i)})} \left[ f(\mathbf{z}) \nabla_\phi \log q_\phi(\mathbf{z}|\mathbf{x}^{(i)}) \right] \\ &\simeq \frac{1}{L} \sum_{l=1}^L f(\mathbf{z}^{(l)}) \nabla_\phi \log q_\phi(\mathbf{z}^{(l)}|\mathbf{x}^{(i)}), \quad \mathbf{z}^{(l)} \sim q_\phi(\mathbf{z}|\mathbf{x}^{(i)}). \end{aligned}$$

这个梯度估计量的方差很高（例如见 [BJP12]），不适合我们的用途。

### 2.3 SGVB 估计量与 AEVB 算法

本节介绍一个实用的下界及其参数导数的估计量。我们假定近似后验具有  $q_\phi(\mathbf{z}|\mathbf{x})$  的形式，但这一技术同样适用于  $q_\phi(\mathbf{z})$ ，即不以  $\mathbf{x}$  为条件的情形。对参数后验进行推断的完全变分贝叶斯方法见附录。

对于选定的近似后验  $q_\phi(\mathbf{z}|\mathbf{x})$ ，在第2.4节概述的温和条件下，可以借助（辅助）噪声变量  $\epsilon$  的可微变换  $g_\phi(\epsilon, \mathbf{x})$ ，对随机变量  $\tilde{\mathbf{z}} \sim q_\phi(\mathbf{z}|\mathbf{x})$  进行重参数化：

$$\tilde{\mathbf{z}} = g_\phi(\epsilon, \mathbf{x}) \quad \text{其中} \quad \epsilon \sim p(\epsilon) \quad (4)$$

如何选取合适的分布  $p(\epsilon)$  和函数  $g_\phi(\epsilon, \mathbf{x})$ ，其一般方法见第2.4节。于是，函数  $f(\mathbf{z})$  关于  $q_\phi(\mathbf{z}|\mathbf{x})$  的期望可用如下蒙特卡洛方法估计：

$$\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x}^{(i)})} [f(\mathbf{z})] = \mathbb{E}_{p(\epsilon)} [f(g_\phi(\epsilon, \mathbf{x}^{(i)}))] \simeq \frac{1}{L} \sum_{l=1}^L f(g_\phi(\epsilon^{(l)}, \mathbf{x}^{(i)})) \quad \text{其中} \quad \epsilon^{(l)} \sim p(\epsilon) \quad (5)$$

将该技术用于变分下界，即式 (2)，得到通用的随机梯度变分贝叶斯 (SGVB) 估计量  $\tilde{\mathcal{L}}^A(\theta, \phi; \mathbf{x}^{(i)}) \simeq \mathcal{L}(\theta, \phi; \mathbf{x}^{(i)})$ ：

$$\begin{aligned} \tilde{\mathcal{L}}^A(\theta, \phi; \mathbf{x}^{(i)}) &= \frac{1}{L} \sum_{l=1}^L [\log p_\theta(\mathbf{x}^{(i)}, \mathbf{z}^{(i,l)}) - \log q_\phi(\mathbf{z}^{(i,l)}|\mathbf{x}^{(i)})] \\ \text{其中} \quad \mathbf{z}^{(i,l)} &= g_\phi(\epsilon^{(i,l)}, \mathbf{x}^{(i)}) \quad \text{且} \quad \epsilon^{(i,l)} \sim p(\epsilon) \end{aligned} \quad (6)$$

式 (3) 中的 KL 散度  $D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}^{(i)})||p_\theta(\mathbf{z}))$  通常可以解析积分 (见附录B)，于是只有期望对数重构似然  $\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x}^{(i)})} [\log p_\theta(\mathbf{x}^{(i)}|\mathbf{z})]$  需要通过采样估计。此时，KL 散度项可以解释为对  $\phi$  的正则化，促使近似后验接近先验  $p_\theta(\mathbf{z})$ 。由此得到对应于式 (3) 的第二种 SGVB 估计量  $\tilde{\mathcal{L}}^B(\theta, \phi; \mathbf{x}^{(i)}) \simeq \mathcal{L}(\theta, \phi; \mathbf{x}^{(i)})$ ，其方差通常低于通用估计量：

$$\begin{aligned} \tilde{\mathcal{L}}^B(\theta, \phi; \mathbf{x}^{(i)}) &= -D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}^{(i)})||p_\theta(\mathbf{z})) + \frac{1}{L} \sum_{l=1}^L (\log p_\theta(\mathbf{x}^{(i)}|\mathbf{z}^{(i,l)})) \\ \text{其中} \quad \mathbf{z}^{(i,l)} &= g_\phi(\epsilon^{(i,l)}, \mathbf{x}^{(i)}) \quad \text{且} \quad \epsilon^{(i,l)} \sim p(\epsilon) \end{aligned} \quad (7)$$

对于含  $N$  个数据点的数据集  $\mathbf{X}$ ，可以利用 minibatch 构造整个数据集的对数边缘似然下界估计量：

$$\mathcal{L}(\theta, \phi; \mathbf{X}) \simeq \tilde{\mathcal{L}}^M(\theta, \phi; \mathbf{X}^M) = \frac{N}{M} \sum_{i=1}^M \tilde{\mathcal{L}}(\theta, \phi; \mathbf{x}^{(i)}) \quad (8)$$

其中，minibatch  $\mathbf{X}^M = \{\mathbf{x}^{(i)}\}_{i=1}^M$  是从含  $N$  个数据点的完整数据集  $\mathbf{X}$  中随机抽取的  $M$  个数据点。实验中我们发现，只要 minibatch 大小  $M$  足够大，例如  $M = 100$ ，每个数据点的样本数  $L$  就可以取 1。对其求导得到  $\nabla_{\theta, \phi} \tilde{\mathcal{L}}^M(\theta, \phi; \mathbf{X}^M)$ ，所得梯度可以与 SGD 或 Adagrad[DHS10] 等随机优化方法结合使用。计算随机梯度的基本方法见算法1。

从式 (7) 的目标函数可以清楚地看到它与自编码器的联系。第一项是近似后验相对于先验的 KL 散度的负值，起正则化作用；第二项则是负重构误差的期望。选择函数  $g_\phi(\cdot)$ ，使其将数据点  $\mathbf{x}^{(i)}$

---

**算法 1** 自编码变分贝叶斯 (AEVB) 算法的 minibatch 版本。第 2.3 节的两种 SGVB 估计量均可使用。实验中取  $M = 100$ 、 $L = 1$ 。

---

$\theta, \phi \leftarrow$  初始化参数

**重复**

$\mathbf{X}^M \leftarrow$  从完整数据集中随机抽取  $M$  个数据点组成 minibatch

$\epsilon \leftarrow$  从噪声分布  $p(\epsilon)$  随机采样

$g \leftarrow \nabla_{\theta, \phi} \tilde{\mathcal{L}}^M(\theta, \phi; \mathbf{X}^M, \epsilon)$  (minibatch 估计量 (8) 的梯度)

$\theta, \phi \leftarrow$  利用梯度  $g$  更新参数 (如采用 SGD 或 Adagrad[DHS10])

**直到** 参数  $(\theta, \phi)$  收敛

**返回**  $\theta, \phi$

---

和随机噪声向量  $\epsilon^{(l)}$  映射为该数据点的近似后验样本:  $\mathbf{z}^{(i,l)} = g_\phi(\epsilon^{(l)}, \mathbf{x}^{(i)})$ , 其中  $\mathbf{z}^{(i,l)} \sim q_\phi(\mathbf{z}|\mathbf{x}^{(i)})$ 。随后, 将样本  $\mathbf{z}^{(i,l)}$  输入函数  $\log p_\theta(\mathbf{x}^{(i)}|\mathbf{z}^{(i,l)})$ ; 该函数等于给定  $\mathbf{z}^{(i,l)}$  时, 生成模型下数据点  $\mathbf{x}^{(i)}$  的对数概率密度 (或对数概率质量)。用自编码器的术语说, 这一项就是负的重构误差。

## 2.4 重参数化技巧

为解决上述问题, 我们采用另一种从  $q_\phi(\mathbf{z}|\mathbf{x})$  生成样本的方法。其核心的重参数化技巧很简单。设连续随机变量  $\mathbf{z}$  服从某个条件分布  $q_\phi(\mathbf{z}|\mathbf{x})$ 。通常可以将它表示为  $\mathbf{z} = g_\phi(\epsilon, \mathbf{x})$ , 即辅助变量的确定性函数, 其中  $\epsilon$  的边缘分布  $p(\epsilon)$  不依赖于  $\mathbf{x}$  和  $\phi$ , 而  $g_\phi(\cdot)$  是由  $\phi$  参数化的向量值函数。

这种重参数化之所以有用, 是因为它能改写关于  $q_\phi(\mathbf{z}|\mathbf{x})$  的期望, 使相应的蒙特卡洛估计关于  $\phi$  可微。证明如下: 若映射  $\mathbf{z} = g_\phi(\epsilon, \mathbf{x})$  将分布  $p(\epsilon)$  推前为  $q_\phi(\mathbf{z}|\mathbf{x})$ , 则由期望的换元公式<sup>1</sup>, 有  $\int q_\phi(\mathbf{z}|\mathbf{x}) f(\mathbf{z}) d\mathbf{z} = \int p(\epsilon) f(g_\phi(\epsilon, \mathbf{x})) d\epsilon$ 。在同维可逆可微情形, 这也可写成体积元关系  $q_\phi(\mathbf{z}|\mathbf{x}) \prod_i dz_i = p(\epsilon) \prod_i d\epsilon_i$ 。于是可构造可微估计量:  $\int q_\phi(\mathbf{z}|\mathbf{x}) f(\mathbf{z}) d\mathbf{z} \simeq \frac{1}{L} \sum_{l=1}^L f(g_\phi(\epsilon^{(l)}, \mathbf{x}))$ , 其中  $\epsilon^{(l)} \sim p(\epsilon)$ 。第 2.3 节正是利用这一技巧, 得到了变分下界的可微估计量。

以单变量高斯分布为例, 设  $z \sim p(z|\mathbf{x}) = \mathcal{N}(\mu, \sigma^2)$ 。一个有效的重参数化是  $z = \mu + \sigma\epsilon$ , 其中辅助噪声变量  $\epsilon \sim \mathcal{N}(0, 1)$ 。因此,  $\mathbb{E}_{\mathcal{N}(z;\mu,\sigma^2)} [f(z)] = \mathbb{E}_{\mathcal{N}(\epsilon;0,1)} [f(\mu + \sigma\epsilon)] \simeq \frac{1}{L} \sum_{l=1}^L f(\mu + \sigma\epsilon^{(l)})$ , 其中  $\epsilon^{(l)} \sim \mathcal{N}(0, 1)$ 。

对于哪些  $q_\phi(\mathbf{z}|\mathbf{x})$ , 可以选取这样的可微变换  $g_\phi(\cdot)$  和辅助变量  $\epsilon \sim p(\epsilon)$ ? 有三种基本方法:

1. 逆累积分布函数 (逆 CDF) 可处理。单变量情形取  $\epsilon \sim \mathcal{U}(0, 1)$ , 并令  $g_\phi(\epsilon, \mathbf{x})$  为  $q_\phi(\mathbf{z}|\mathbf{x})$  的逆 CDF; 独立分量可逐分量处理。例子包括指数、柯西、逻辑斯蒂、瑞利、帕累托、威布尔、倒数、冈珀茨、耿贝尔和埃尔朗分布。
2. 与高斯分布的例子类似, 对于任意 “位置—尺度” 分布族, 可以选择相应的标准分布 (位置参数为 0、尺度参数为 1) 作为辅助变量  $\epsilon$  的分布, 并令  $g(\cdot) = \text{位置参数} + \text{尺度参数} \cdot \epsilon$ 。例子包括拉普拉斯、椭圆、Student  $t$ 、逻辑斯蒂、均匀、三角和高斯分布。

---

<sup>1</sup>本文采用微分体积元记号  $d\mathbf{z} = \prod_i dz_i$ 。

3. 复合构造：随机变量通常可表示为辅助变量的不同变换。例如，对数正态变量是正态变量的指数；正整数形状参数的 Gamma 变量可由相互独立、同率的指数变量求和得到；Dirichlet 向量可由具有同一尺度参数的独立 Gamma 变量除以它们的总和得到。其他例子包括 Beta、卡方和  $F$  分布。

若以上三种方法均不适用，仍可寻找逆 CDF 的良好近似，其计算时间复杂度可与概率密度函数相当（一些方法见 [Dev86]）。

### 3 示例：变分自编码器

本节给出一个例子：以神经网络实现概率编码器  $q_\phi(\mathbf{z}|\mathbf{x})$ ，即对生成模型  $p_\theta(\mathbf{x}, \mathbf{z})$  的后验分布的近似，并通过 AEVB 算法联合优化参数  $\phi$  和  $\theta$ 。

设潜变量先验为零均值、各向同性的多元高斯分布  $p_\theta(\mathbf{z}) = \mathcal{N}(\mathbf{z}; \mathbf{0}, \mathbf{I})$ 。注意，此时先验没有需要学习的参数。对于实值数据，令  $p_\theta(\mathbf{x}|\mathbf{z})$  为多元高斯分布；对于二值数据，则令其为伯努利分布。分布参数由  $\mathbf{z}$  经 MLP 计算得到；这里的 MLP 是具有单个隐藏层的全连接神经网络，见附录C。此时真实后验  $p_\theta(\mathbf{z}|\mathbf{x})$  难以处理。虽然  $q_\phi(\mathbf{z}|\mathbf{x})$  的形式有很大选择空间，这里假设真实但难以处理的后验近似为高斯分布，且协方差近似为对角矩阵。因此，可以令变分近似后验为具有对角协方差结构的多元高斯分布<sup>2</sup>：

$$\log q_\phi(\mathbf{z}|\mathbf{x}^{(i)}) = \log \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}^{(i)}, \text{diag}((\boldsymbol{\sigma}^{(i)})^2)) \quad (9)$$

其中，近似后验的均值  $\boldsymbol{\mu}^{(i)}$  和标准差  $\boldsymbol{\sigma}^{(i)}$  是编码 MLP 的输出，即数据点  $\mathbf{x}^{(i)}$  与变分参数  $\phi$  的非线性函数，见附录C。

如第2.4节所述，我们利用  $\mathbf{z}^{(i,l)} = g_\phi(\boldsymbol{\epsilon}^{(l)}, \mathbf{x}^{(i)}) = \boldsymbol{\mu}^{(i)} + \boldsymbol{\sigma}^{(i)} \odot \boldsymbol{\epsilon}^{(l)}$  从后验中采样  $\mathbf{z}^{(i,l)} \sim q_\phi(\mathbf{z}|\mathbf{x}^{(i)})$ ，其中  $\boldsymbol{\epsilon}^{(l)} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，符号  $\odot$  表示逐元素乘积。在该模型中，先验  $p_\theta(\mathbf{z})$  和近似后验  $q_\phi(\mathbf{z}|\mathbf{x})$  均为高斯分布；因此可以使用式 (7) 的估计量，其中 KL 散度可以直接计算并求导，无须采样估计（见附录B）。对于该模型及数据点  $\mathbf{x}^{(i)}$ ，得到的估计量为：

$$\begin{aligned} \mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) &\simeq \frac{1}{2} \sum_{j=1}^J \left( 1 + \log((\sigma_j^{(i)})^2) - (\mu_j^{(i)})^2 - (\sigma_j^{(i)})^2 \right) + \frac{1}{L} \sum_{l=1}^L \log p_\theta(\mathbf{x}^{(i)}|\mathbf{z}^{(i,l)}) \\ \text{其中 } \mathbf{z}^{(i,l)} &= \boldsymbol{\mu}^{(i)} + \boldsymbol{\sigma}^{(i)} \odot \boldsymbol{\epsilon}^{(l)} \quad \text{且} \quad \boldsymbol{\epsilon}^{(l)} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \end{aligned} \quad (10)$$

如上文及附录C所述，解码项  $\log p_\theta(\mathbf{x}^{(i)}|\mathbf{z}^{(i,l)})$  由伯努利或高斯 MLP 给出，具体取决于所建模的数据类型。

<sup>2</sup>这只是一种简化选择，并非本方法的限制。

## 4 相关工作

据我们所知，唤醒—睡眠（wake-sleep）算法 [HDFN95] 是文献中另一个适用于同样广泛的连续潜变量模型的在线学习方法。与我们的方法类似，它使用识别模型来近似真实后验。其缺点是必须同时优化两个目标函数，而两者合起来并不对应于对边缘似然或其下界的优化。唤醒—睡眠算法的一个优点是也适用于离散潜变量模型。它与 AEVB 对每个数据点的计算复杂度相同。

随机变分推断 [HBWP13] 近来受到越来越多的关注。文献 [BJP12] 提出控制变量方法，以降低第2.2节所讨论的朴素梯度估计量的高方差，并将其用于后验的指数族近似。文献 [RGB13] 也引入了降低原始梯度估计量方差的通用方法，即控制变量方法。文献 [SK13] 在一种高效的随机变分推断算法中采用了与本文类似的重参数化，用于学习指数族近似分布的自然参数。

AEVB 算法揭示了以变分目标训练的有向概率模型与自编码器之间的联系。线性自编码器与某类生成式线性高斯模型的联系早已为人所知。文献 [Row98] 表明，当线性高斯模型的先验为  $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 、条件分布为  $p(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mathbf{x}; \mathbf{W}\mathbf{z}, \epsilon\mathbf{I})$ ，且  $\epsilon$  趋于无穷小时，PCA 对应于这一特例的最大似然解。

近期关于自编码器的相关研究 [VLL<sup>+</sup>10] 表明，无正则化自编码器的训练准则对应于最大化输入  $X$  与潜在表示  $Z$  之间互信息的一个下界（参见信息最大化原理 [Lin89]）。当输入分布固定时，关于参数最大化互信息，等价于最大化负条件熵  $-H(X|Z)$ 。自编码模型下数据的期望对数似然，即负重构误差，是该负条件熵的一个下界 [VLL<sup>+</sup>10]。然而，众所周知，单靠重构准则本身不足以学到有用的表示 [BCV13]。为使自编码器学到有用的表示，已有多种正则化技术，例如去噪、收缩和稀疏自编码器 [BCV13]。SGVB 目标中的正则化项由变分下界决定，例如式 (10)，因此不需要通常为学到有用表示而引入的额外正则化超参数。其他相关方法还包括预测稀疏分解 (PSD) [KRL08] 等编码器—解码器架构，我们也从中获得了一些启发。近期提出的生成随机网络 [BTL13] 同样相关：其中的含噪自编码器学习一个马尔可夫链的转移算子，该链从数据分布采样。文献 [SL10] 则利用识别模型提高深度玻尔兹曼机的学习效率。这些方法要么针对未归一化模型，即玻尔兹曼机等无向模型，要么仅限于稀疏编码模型；而我们提出的算法用于学习一大类有向概率模型。


近期提出的 DARN 方法 [GMW13] 也通过自编码结构学习有向概率模型，但其方法适用于二值潜变量。更近的工作 [RMW14] 也利用本文所述的重参数化技巧，将自编码器、有向概率模型和随机变分推断联系起来。他们的工作独立于我们开展，为 AEVB 提供了另一个视角。

## 5 实验

我们使用 MNIST 和 Frey Face 数据集<sup>3</sup>中的图像训练生成模型，并通过变分下界与估计的边缘似然比较不同学习算法。

采用第3节的生成模型（解码器）和变分近似（编码器），其中编码器与解码器的隐藏单元数相

<sup>3</sup>可从<http://www.cs.nyu.edu/~roweis/data.html>获取。



**图 2** 在不同潜在空间维数  $N_z$  下，比较 AEVB 与唤醒—睡眠算法对下界的优化效果。在所有实验中，我们的方法收敛都明显更快，且得到更好的解。有趣的是，增加潜变量并未加重过拟合，这可以用下界的正则化作用来解释。纵轴为估计的每个数据点的平均变分下界；估计量方差很小 ( $< 1$ )，故未绘出。横轴为累计评估的训练数据点数。在有效运算速度为 40 GFLOPS 的 Intel Xeon CPU 上，每处理一百万个训练样本约需 20–40 分钟。

同。由于 Frey Face 数据是连续的，我们采用高斯输出的解码器，其结构与编码器相同，只是在解码器输出端使用 sigmoid 激活函数，将均值限制在 (0,1) 内。注意，隐藏单元指编码器和解码器神经网络中的隐藏层单元。

参数通过随机梯度上升更新。梯度由对下界估计量求导得到，即  $\nabla_{\theta, \phi} \tilde{\mathcal{L}}^M(\theta, \phi; \mathbf{X}^M)$  (见算法1)，并加入一个较小的权重衰减项，对应于先验  $p(\theta) = \mathcal{N}(0, \mathbf{I})$ 。优化该目标相当于近似 MAP 估计，其中用下界梯度近似对数似然梯度。

我们比较了 AEVB 与唤醒—睡眠算法 [HDFN95] 的性能。两者采用相同的编码器，也称识别模型。所有变分参数和生成参数都从  $\mathcal{N}(0, 0.01)$  随机采样初始化，并按 MAP 准则联合进行随机优化。步长使用 Adagrad [DHS10] 自适应调整；其全局步长参数根据最初几轮迭代在训练集上的表现，从 {0.01, 0.02, 0.1} 中选择。minibatch 大小为  $M = 100$ ，每个数据点采样  $L = 1$  次。

**似然下界** 对于 MNIST，我们训练了具有 500 个隐藏单元的生成模型（解码器）及其对应编码器（识别模型）；对于规模小得多的 Frey Face 数据集，为避免过拟合，使用 200 个隐藏单元。隐藏单元数参考了以往的自编码器文献，不同算法的相对性能对这些选择并不十分敏感。图2给出了下界比较结果。有趣的是，多余的潜变量并未导致过拟合，这可以用变分下界的正则化性质解释。

**边缘似然** 当潜在空间维数很低时，可以使用 MCMC 估计量估计学到的生成模型的边缘似然。该估计量的更多信息见附录。编码器和解码器仍采用神经网络，这次使用 100 个隐藏单元和 3 个潜变量；潜在空间维数更高时，估计结果会变得不可靠。这里仍使用 MNIST 数据集。我们将 AEVB 和唤醒—睡眠方法与采用混合蒙特卡洛 (HMC) [DKPR87] 采样器的蒙特卡洛 EM (MCEM) 进行比




图3 在不同训练集规模下，根据估计的边缘似然比较 AEVB、唤醒—睡眠算法和蒙特卡洛 EM。蒙特卡洛 EM 不是在线算法，因此与 AEVB 和唤醒—睡眠算法不同，它无法高效地用于完整 MNIST 数据集。

较，细节见附录。分别在较小和较大的训练集上比较三种算法的收敛速度，结果见图3。

**高维数据可视化** 若选择低维潜在空间，例如二维空间，就可以用学到的编码器（识别模型）将高维数据投影到低维流形。MNIST 和 Frey Face 数据集的二维潜在流形可视化见附录A。

## 6 结论

我们提出了新的变分下界估计量——随机梯度变分贝叶斯 (SGVB)，用于对连续潜变量进行高效近似推断。该估计量可以直接求导，并用标准随机梯度方法优化。对于每个数据点都带有连续潜变量的独立同分布数据集，我们提出了高效的推断与学习算法——自编码变分贝叶斯 (AEVB)，它利用 SGVB 估计量学习近似推断模型。实验结果体现了这些理论优势。

## 7 未来工作

由于 SGVB 估计量和 AEVB 算法几乎适用于所有包含连续潜变量的推断与学习问题，未来可探索的方向很多：(i) 使用深度神经网络，例如卷积网络，作为编码器和解码器，通过 AEVB 联合训练分层生成架构；(ii) 时间序列模型，即动态贝叶斯网络；(iii) 将 SGVB 应用于全局参数；(iv) 带潜变量的监督模型，以学习复杂的噪声分布。

## 参考文献

- [BCV13] Yoshua Bengio, Aaron Courville, and Pascal Vincent. Representation learning: A review and new perspectives. 2013.
- [BJP12] David M Blei, Michael I Jordan, and John W Paisley. Variational Bayesian inference with Stochastic Search. In *Proceedings of the 29th International Conference on Machine Learning (ICML-12)*, pages 1367–1374, 2012.
- [BTL13] Yoshua Bengio and Éric Thibodeau-Laufer. Deep generative stochastic networks trainable by backprop. *arXiv preprint arXiv:1306.1091*, 2013.
- [Dev86] Luc Devroye. Sample-based non-uniform random variate generation. In *Proceedings of the 18th conference on Winter simulation*, pages 260–265. ACM, 1986.
- [DHS10] John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12:2121–2159, 2010.
- [DKPR87] Simon Duane, Anthony D Kennedy, Brian J Pendleton, and Duncan Roweth. Hybrid monte carlo. *Physics letters B*, 195(2):216–222, 1987.
- [GMW13] Karol Gregor, Andriy Mnih, and Daan Wierstra. Deep autoregressive networks. *arXiv preprint arXiv:1310.8499*, 2013.
- [HBWP13] Matthew D Hoffman, David M Blei, Chong Wang, and John Paisley. Stochastic variational inference. *The Journal of Machine Learning Research*, 14(1):1303–1347, 2013.
- [HDFN95] Geoffrey E Hinton, Peter Dayan, Brendan J Frey, and Radford M Neal. The “wake-sleep” algorithm for unsupervised neural networks. *SCIENCE*, pages 1158–1158, 1995.
- [KRL08] Koray Kavukcuoglu, Marc’Aurelio Ranzato, and Yann LeCun. Fast inference in sparse coding algorithms with applications to object recognition. Technical Report CBLL-TR-2008-12-01, Computational and Biological Learning Lab, Courant Institute, NYU, 2008.
- [Lin89] Ralph Linsker. *An application of the principle of maximum information preservation to linear systems*. Morgan Kaufmann Publishers Inc., 1989.
- [RGB13] Rajesh Ranganath, Sean Gerrish, and David M Blei. Black Box Variational Inference. *arXiv preprint arXiv:1401.0118*, 2013.
- [RMW14] Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. Stochastic back-propagation and variational inference in deep latent gaussian models. *arXiv preprint arXiv:1401.4082*, 2014.
- [Row98] Sam Roweis. EM algorithms for PCA and SPCA. *Advances in neural information processing systems*, pages 626–632, 1998.
- [SK13] Tim Salimans and David A Knowles. Fixed-form variational posterior approximation through stochastic linear regression. *Bayesian Analysis*, 8(4), 2013.
- [SL10] Ruslan Salakhutdinov and Hugo Larochelle. Efficient learning of deep boltzmann machines. In *International Conference on Artificial Intelligence and Statistics*, pages 693–700, 2010.
- [VLL<sup>+</sup>10] Pascal Vincent, Hugo Larochelle, Isabelle Lajoie, Yoshua Bengio, and Pierre-Antoine Manzagol. Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion. *The Journal of Machine Learning Research*, 9999:3371–3408, 2010.




图4 通过 AEVB 学到的二维潜在空间生成模型的数据流形可视化。由于潜在空间的先验为高斯分布，将单位正方形内线性等距的坐标通过高斯分布的逆 CDF 变换，得到潜变量  $z$  的取值。对每个  $z$ ，利用学到的参数  $\theta$ ，绘制相应生成分布  $p_{\theta}(x|z)$  的图像。

## A 可视化

图4和图5展示了利用 SGVB 学到的模型的潜在空间及其对应观测空间。




图5 从不同潜在空间维数的 MNIST 生成模型中随机采样得到的图像。

## B 高斯情形下负 KL 散度的解析解

变分下界，即需要最大化的目标，包含一个通常可以解析积分的 KL 项。这里给出先验  $p_{\theta}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$  和近似后验  $q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)})$  均为高斯分布时的解。令  $J$  为  $\mathbf{z}$  的维数， $\boldsymbol{\mu}$  和  $\boldsymbol{\sigma}$  分别表示在数据点  $i$  处计算的变分均值与标准差， $\mu_j$  和  $\sigma_j$  表示相应向量的第  $j$  个分量。以下为简便省略条件  $\mathbf{x}^{(i)}$ ，则有：

$$\begin{aligned} \int q_{\phi}(\mathbf{z}) \log p(\mathbf{z}) d\mathbf{z} &= \int \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2)) \log \mathcal{N}(\mathbf{z}; \mathbf{0}, \mathbf{I}) d\mathbf{z} \\ &= -\frac{J}{2} \log(2\pi) - \frac{1}{2} \sum_{j=1}^J (\mu_j^2 + \sigma_j^2) \end{aligned}$$

以及：

$$\begin{aligned} \int q_{\phi}(\mathbf{z}) \log q_{\phi}(\mathbf{z}) d\mathbf{z} &= \int \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2)) \log \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2)) d\mathbf{z} \\ &= -\frac{J}{2} \log(2\pi) - \frac{1}{2} \sum_{j=1}^J (1 + \log \sigma_j^2) \end{aligned}$$

因此：

$$\begin{aligned} -D_{KL}(q_{\phi}(\mathbf{z})||p_{\theta}(\mathbf{z})) &= \int q_{\phi}(\mathbf{z}) (\log p_{\theta}(\mathbf{z}) - \log q_{\phi}(\mathbf{z})) d\mathbf{z} \\ &= \frac{1}{2} \sum_{j=1}^J (1 + \log((\sigma_j)^2) - (\mu_j)^2 - (\sigma_j)^2) \end{aligned}$$

使用识别模型  $q_{\phi}(\mathbf{z}|\mathbf{x})$  时，均值  $\boldsymbol{\mu}$  与标准差  $\boldsymbol{\sigma}$  就是  $\mathbf{x}$  和变分参数  $\phi$  的函数，正文给出了相应例子。

## C 作为概率编码器和解码器的 MLP

在变分自编码器中，神经网络用作概率编码器和解码器。根据数据及模型类型的不同，编码器和解码器有许多可能的选择。在本文的例子中，我们使用较简单的神经网络，即多层感知机（MLP）。编码器采用高斯输出的 MLP；解码器根据数据类型，采用高斯或伯努利输出的 MLP。

### C.1 作为解码器的伯努利 MLP

此时，令  $p_{\theta}(\mathbf{x}|\mathbf{z})$  为多元伯努利分布，其概率由  $\mathbf{z}$  通过具有单个隐藏层的全连接神经网络计算得到：

$$\begin{aligned} \log p(\mathbf{x}|\mathbf{z}) &= \sum_{i=1}^D [x_i \log y_i + (1 - x_i) \cdot \log(1 - y_i)] \\ \text{其中 } \mathbf{y} &= f_{\sigma}(\mathbf{W}_2 \tanh(\mathbf{W}_1 \mathbf{z} + \mathbf{b}_1) + \mathbf{b}_2) \end{aligned} \tag{11}$$

其中  $f_{\sigma}(\cdot)$  为逐元素 sigmoid 激活函数， $\boldsymbol{\theta} = \{\mathbf{W}_1, \mathbf{W}_2, \mathbf{b}_1, \mathbf{b}_2\}$  为 MLP 的权重与偏置。

## C.2 作为编码器或解码器的高斯 MLP

此时，令编码器或解码器为具有对角协方差结构的多元高斯分布：

$$\begin{aligned}\log p(\mathbf{x}|\mathbf{z}) &= \log \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2)) \\ \text{其中 } \boldsymbol{\mu} &= \mathbf{W}_4 \mathbf{h} + \mathbf{b}_4 \\ \log \boldsymbol{\sigma}^2 &= \mathbf{W}_5 \mathbf{h} + \mathbf{b}_5 \\ \mathbf{h} &= \tanh(\mathbf{W}_3 \mathbf{z} + \mathbf{b}_3)\end{aligned}\tag{12}$$

其中  $\{\mathbf{W}_3, \mathbf{W}_4, \mathbf{W}_5, \mathbf{b}_3, \mathbf{b}_4, \mathbf{b}_5\}$  是 MLP 的权重和偏置；当网络用作解码器时，它们属于  $\boldsymbol{\theta}$ 。注意，若将该网络用作编码器  $q_\phi(\mathbf{z}|\mathbf{x})$ ，则需交换  $\mathbf{z}$  与  $\mathbf{x}$ ，此时权重和偏置属于变分参数  $\phi$ 。

## D 边缘似然估计量

我们推导了如下边缘似然估计量。在采样空间维数较低（小于 5 维）、样本充分的情况下，它能给出良好的边缘似然估计。设所采样的生成模型为  $p_\theta(\mathbf{x}, \mathbf{z}) = p_\theta(\mathbf{z})p_\theta(\mathbf{x}|\mathbf{z})$ ；对于给定数据点  $\mathbf{x}^{(i)}$ ，我们希望估计边缘似然  $p_\theta(\mathbf{x}^{(i)})$ 。

估计过程分为三个阶段：

1. 利用基于梯度的 MCMC，例如混合蒙特卡洛，从后验分布中采样  $L$  个值  $\{\mathbf{z}^{(l)}\}$ ；所用梯度为  $\nabla_{\mathbf{z}} \log p_\theta(\mathbf{z}|\mathbf{x}) = \nabla_{\mathbf{z}} \log p_\theta(\mathbf{z}) + \nabla_{\mathbf{z}} \log p_\theta(\mathbf{x}|\mathbf{z})$ 。
2. 用这些样本  $\{\mathbf{z}^{(l)}\}$  拟合密度估计器  $q(\mathbf{z})$ 。
3. 再从后验分布中采样  $L$  个新值，将这些样本和拟合的  $q(\mathbf{z})$  代入下式：

$$p_\theta(\mathbf{x}^{(i)}) \simeq \left( \frac{1}{L} \sum_{l=1}^L \frac{q(\mathbf{z}^{(l)})}{p_\theta(\mathbf{z}^{(l)})p_\theta(\mathbf{x}^{(i)}|\mathbf{z}^{(l)})} \right)^{-1} \quad \text{其中 } \mathbf{z}^{(l)} \sim p_\theta(\mathbf{z}|\mathbf{x}^{(i)})$$

该估计量的推导如下；这里要求  $q$  归一化，且其支撑集包含于  $p_\theta(\mathbf{x}^{(i)}, \mathbf{z}) > 0$  的区域：

$$\begin{aligned}\frac{1}{p_\theta(\mathbf{x}^{(i)})} &= \frac{\int q(\mathbf{z}) d\mathbf{z}}{p_\theta(\mathbf{x}^{(i)})} = \frac{\int q(\mathbf{z}) \frac{p_\theta(\mathbf{x}^{(i)}, \mathbf{z})}{p_\theta(\mathbf{x}^{(i)}, \mathbf{z})} d\mathbf{z}}{p_\theta(\mathbf{x}^{(i)})} \\ &= \int \frac{p_\theta(\mathbf{x}^{(i)}, \mathbf{z})}{p_\theta(\mathbf{x}^{(i)})} \frac{q(\mathbf{z})}{p_\theta(\mathbf{x}^{(i)}, \mathbf{z})} d\mathbf{z} \\ &= \int p_\theta(\mathbf{z}|\mathbf{x}^{(i)}) \frac{q(\mathbf{z})}{p_\theta(\mathbf{x}^{(i)}, \mathbf{z})} d\mathbf{z} \\ &\simeq \frac{1}{L} \sum_{l=1}^L \frac{q(\mathbf{z}^{(l)})}{p_\theta(\mathbf{z}^{(l)})p_\theta(\mathbf{x}^{(i)}|\mathbf{z}^{(l)})} \quad \text{其中 } \mathbf{z}^{(l)} \sim p_\theta(\mathbf{z}|\mathbf{x}^{(i)})\end{aligned}$$

## E 蒙特卡洛 EM

蒙特卡洛 EM 不使用编码器，而是利用后验梯度从潜变量后验中采样，其中  $\nabla_z \log p_{\theta}(\mathbf{z}|\mathbf{x}) = \nabla_z \log p_{\theta}(\mathbf{z}) + \nabla_z \log p_{\theta}(\mathbf{x}|\mathbf{z})$ 。蒙特卡洛 EM 的一次过程包含 10 个 HMC 蛙跳步，步长自动调整以使接受率达到 90%；随后使用得到的样本执行 5 次权重更新。所有算法均用 Adagrad 步长及相应的退火策略更新参数。

边缘似然在训练集和测试集各自的前 1000 个数据点上估计。对每个数据点，使用含 4 个蛙跳步的混合蒙特卡洛方法，从潜变量后验中采样 50 个值。

## F 完全变分贝叶斯

如正文所述，除对潜变量进行变分推断外，还可以同时对参数  $\theta$  和潜变量  $\mathbf{z}$  进行变分推断。本节推导这种情形下的估计量。

设  $p_{\alpha}(\theta)$  是上述参数的超先验，由  $\alpha$  参数化。对数边缘似然可写为：

$$\log p_{\alpha}(\mathbf{X}) = D_{KL}(q_{\phi}(\theta) || p_{\alpha}(\theta|\mathbf{X})) + \mathcal{L}(\phi; \mathbf{X}) \quad (13)$$

右端第一项是近似后验相对于真实后验的 KL 散度， $\mathcal{L}(\phi; \mathbf{X})$  表示对数边缘似然的变分下界：

$$\mathcal{L}(\phi; \mathbf{X}) = \int q_{\phi}(\theta) (\log p_{\theta}(\mathbf{X}) + \log p_{\alpha}(\theta) - \log q_{\phi}(\theta)) d\theta \quad (14)$$

由于 KL 散度非负，这确实是一个下界；当近似后验与真实后验完全一致时，下界等于真实对数边缘似然。 $\log p_{\theta}(\mathbf{X})$  是各数据点对数边缘似然之和，即  $\log p_{\theta}(\mathbf{X}) = \sum_{i=1}^N \log p_{\theta}(\mathbf{x}^{(i)})$ 。其中每一项均可写成：

$$\log p_{\theta}(\mathbf{x}^{(i)}) = D_{KL}(q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)}) || p_{\theta}(\mathbf{z}|\mathbf{x}^{(i)})) + \mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) \quad (15)$$

右端第一项仍为近似后验相对于真实后验的 KL 散度，而  $\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)})$  是数据点  $i$  的对数边缘似然的变分下界：

$$\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) = \int q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)}) (\log p_{\theta}(\mathbf{x}^{(i)}|\mathbf{z}) + \log p_{\theta}(\mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}^{(i)})) d\mathbf{z} \quad (16)$$

式 (14) 和式 (16) 右端的期望都可写成三个单独期望之和，其中第二项和第三项有时可以解析求解。例如，对潜变量下界而言，当  $p_{\theta}(\mathbf{z})$  和  $q_{\phi}(\mathbf{z}|\mathbf{x})$  均为高斯分布时即可如此；对参数下界，则对应于  $p_{\alpha}(\theta)$  与  $q_{\phi}(\theta)$ 。为保持一般性，这里假设各项期望都难以处理。

对于选定的近似后验  $q_{\phi}(\theta)$  和  $q_{\phi}(\mathbf{z}|\mathbf{x})$ ，在第 2.4 节所述的温和条件下，可将条件样本  $\tilde{\mathbf{z}} \sim q_{\phi}(\mathbf{z}|\mathbf{x})$  重参数化为：

$$\tilde{\mathbf{z}} = g_{\phi}(\epsilon, \mathbf{x}) \quad \text{其中} \quad \epsilon \sim p(\epsilon) \quad (17)$$

选取辅助噪声分布  $p(\epsilon)$  和函数  $g_\phi(\epsilon, \mathbf{x})$ , 使下式成立:

$$\begin{aligned}\mathcal{L}(\theta, \phi; \mathbf{x}^{(i)}) &= \int q_\phi(\mathbf{z}|\mathbf{x}^{(i)}) \left( \log p_\theta(\mathbf{x}^{(i)}|\mathbf{z}) + \log p_\theta(\mathbf{z}) - \log q_\phi(\mathbf{z}|\mathbf{x}^{(i)}) \right) d\mathbf{z} \\ &= \int p(\epsilon) \left( \log p_\theta(\mathbf{x}^{(i)}|\mathbf{z}) + \log p_\theta(\mathbf{z}) - \log q_\phi(\mathbf{z}|\mathbf{x}^{(i)}) \right) \Big|_{\mathbf{z}=g_\phi(\epsilon, \mathbf{x}^{(i)})} d\epsilon\end{aligned}\quad (18)$$

对近似后验  $q_\phi(\theta)$  也可以进行同样的处理:

$$\tilde{\theta} = h_\phi(\zeta) \quad \text{其中} \quad \zeta \sim p(\zeta) \quad (19)$$

与上文类似, 选取辅助噪声分布  $p(\zeta)$  和函数  $h_\phi(\zeta)$ , 使下式成立:

$$\begin{aligned}\mathcal{L}(\phi; \mathbf{X}) &= \int q_\phi(\theta) (\log p_\theta(\mathbf{X}) + \log p_\alpha(\theta) - \log q_\phi(\theta)) d\theta \\ &= \int p(\zeta) (\log p_\theta(\mathbf{X}) + \log p_\alpha(\theta) - \log q_\phi(\theta)) \Big|_{\theta=h_\phi(\zeta)} d\zeta\end{aligned}\quad (20)$$

为简化记号, 引入函数  $f_\phi(\mathbf{x}, \mathbf{z}, \theta)$ :

$$f_\phi(\mathbf{x}, \mathbf{z}, \theta) = N \cdot (\log p_\theta(\mathbf{x}|\mathbf{z}) + \log p_\theta(\mathbf{z}) - \log q_\phi(\mathbf{z}|\mathbf{x})) + \log p_\alpha(\theta) - \log q_\phi(\theta) \quad (21)$$

将式 (20) 中的各个  $\log p_\theta(\mathbf{x}^{(i)})$  替换为式 (18) 中的下界, 得到联合变分下界  $\mathcal{J}(\phi; \mathbf{X})$ 。它满足  $\mathcal{J}(\phi; \mathbf{X}) \leq \mathcal{L}(\phi; \mathbf{X}) \leq \log p_\alpha(\mathbf{X})$ 。对数据点也进行均匀随机采样后, 其蒙特卡洛估计为:

$$\mathcal{J}(\phi; \mathbf{X}) \simeq \frac{1}{L} \sum_{l=1}^L f_\phi(\mathbf{x}^{(l)}, g_\phi(\epsilon^{(l)}, \mathbf{x}^{(l)}), h_\phi(\zeta^{(l)})) \quad (22)$$

其中, 每个  $\mathbf{x}^{(l)}$  均从数据集  $\mathbf{X}$  中独立均匀抽取,  $\epsilon^{(l)} \sim p(\epsilon)$ 、 $\zeta^{(l)} \sim p(\zeta)$ , 且这些随机抽样相互独立。该估计量使用的数据抽样及来自  $p(\epsilon)$ 、 $p(\zeta)$  的噪声样本均不受  $\phi$  影响, 因此可对估计量关于  $\phi$  求导。所得随机梯度可以与 SGD 或 Adagrad [DHS10] 等随机优化方法结合使用。计算随机梯度的基本方法见算法2。

## F.1 示例

令参数和潜变量的先验均为零均值、各向同性的高斯分布, 即  $p_\alpha(\theta) = \mathcal{N}(\theta; \mathbf{0}, \mathbf{I})$  和  $p_\theta(\mathbf{z}) = \mathcal{N}(\mathbf{z}; \mathbf{0}, \mathbf{I})$ 。此时先验没有需要学习的参数。再假设真实后验近似为高斯分布, 协方差近似为对角矩阵。于是, 可将变分近似后验取为具有对角协方差结构的多元高斯分布:

$$\begin{aligned}\log q_\phi(\theta) &= \log \mathcal{N}(\theta; \mu_\theta, \text{diag}(\sigma_\theta^2)) \\ \log q_\phi(\mathbf{z}|\mathbf{x}) &= \log \mathcal{N}(\mathbf{z}; \mu_z, \text{diag}(\sigma_z^2))\end{aligned}\quad (23)$$

其中  $\mu_z$  和  $\sigma_z$  是尚未具体指定的  $\mathbf{x}$  的函数。由于这些分布均为高斯分布, 可以按如下方式重参数化:

$$\begin{aligned}q_\phi(\theta) \quad \text{重参数化为} \quad \tilde{\theta} &= \mu_\theta + \sigma_\theta \odot \zeta & \text{其中} \quad \zeta &\sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \\ q_\phi(\mathbf{z}|\mathbf{x}) \quad \text{重参数化为} \quad \tilde{\mathbf{z}} &= \mu_z + \sigma_z \odot \epsilon & \text{其中} \quad \epsilon &\sim \mathcal{N}(\mathbf{0}, \mathbf{I})\end{aligned}$$

---

**算法 2** 利用本文估计量计算随机梯度的伪代码。函数  $f_\phi$ 、 $g_\phi$  和  $h_\phi$  的含义见正文。

---

**输入：**  $\phi$  (变分参数的当前值)

$g \leftarrow 0$

**对于**  $l = 1, \dots, L$  **执行**

$\mathbf{x} \leftarrow$  从数据集  $\mathbf{X}$  中均匀随机抽取一个数据点

$\epsilon \leftarrow$  从辅助噪声分布  $p(\epsilon)$  中随机采样

$\zeta \leftarrow$  从辅助噪声分布  $p(\zeta)$  中随机采样

$g \leftarrow g + \frac{1}{L} \nabla_\phi f_\phi(\mathbf{x}, g_\phi(\epsilon, \mathbf{x}), h_\phi(\zeta))$

**结束 对于**

**返回**  $g$

---

符号  $\odot$  表示逐元素乘积。将上述表示代入前面定义的下界即可，见式 (21) 和式 (22)。

此时还可以构造一个方差更低的估计量。由于  $p_\alpha(\boldsymbol{\theta})$ 、 $p_\theta(\mathbf{z})$ 、 $q_\phi(\boldsymbol{\theta})$  和  $q_\phi(\mathbf{z}|\mathbf{x})$  均为高斯分布， $f_\phi$  中的四项可以解析求解。令  $J = \dim \mathbf{z}$ 、 $P = \dim \boldsymbol{\theta}$ ，得到：

$$\begin{aligned} \mathcal{J}(\phi; \mathbf{X}) \simeq & \frac{1}{L} \sum_{l=1}^L N \cdot \left[ \frac{1}{2} \sum_{j=1}^J \left( 1 + \log((\sigma_{\mathbf{z},j}^{(l)})^2) - (\mu_{\mathbf{z},j}^{(l)})^2 - (\sigma_{\mathbf{z},j}^{(l)})^2 \right) + \log p_{\theta^{(l)}}(\mathbf{x}^{(l)} | \mathbf{z}^{(l)}) \right] \\ & + \frac{1}{2} \sum_{j=1}^P \left( 1 + \log(\sigma_{\boldsymbol{\theta},j}^2) - \mu_{\boldsymbol{\theta},j}^2 - \sigma_{\boldsymbol{\theta},j}^2 \right) \end{aligned} \quad (24)$$

其中  $\mu_{\mathbf{z},j}^{(l)}$  和  $\sigma_{\mathbf{z},j}^{(l)}$  分别是编码器在随机数据点  $\mathbf{x}^{(l)}$  处输出的均值与标准差的第  $j$  个分量； $\mathbf{z}^{(l)} = \boldsymbol{\mu}_{\mathbf{z}}^{(l)} + \boldsymbol{\sigma}_{\mathbf{z}}^{(l)} \odot \boldsymbol{\epsilon}^{(l)}$ ， $\boldsymbol{\theta}^{(l)} = \boldsymbol{\mu}_{\boldsymbol{\theta}} + \boldsymbol{\sigma}_{\boldsymbol{\theta}} \odot \boldsymbol{\zeta}^{(l)}$ 。 $\boldsymbol{\mu}_{\boldsymbol{\theta}}$  与  $\boldsymbol{\sigma}_{\boldsymbol{\theta}}$  是全局变分参数，不带样本索引。

## 翻译说明

本译稿依据 arXiv:1312.6114v11 (2022 年 12 月 10 日) 官方 TeX 源码及对应的 14 页 PDF, 完整翻译正文、六个附录、图注、算法和原作者脚注, 保留原文公式及对象编号。参考文献保留原始书目信息和引文标识; 原图资产直接复用, 图内英文标签保留。以下页码均指原 PDF。本节为译者新增, 记录已核实并直接修入正文的问题, 不表示已穷尽原文的所有错误。

### 已核实的公式与表述修正

- 第 3 页, 第 2.2 节: 梯度估计式。**原式将梯度的下标写为分布  $q_\phi(\mathbf{z})$ , 求和中的  $f$  也没有代入样本。现统一为关于  $\phi$  的梯度, 并使用  $f(\mathbf{z}^{(l)})$ , 使采样分布与条件保持一致。依据为得分函数恒等式  $\nabla_\phi q_\phi = q_\phi \nabla_\phi \log q_\phi$ 。正文明确  $f$  不显含  $\phi$ ; 若显含, 还须加入  $\mathbb{E}_{q_\phi}[\nabla_\phi f]$ 。
- 第 3–4 页, 式 (2)、(6)、(7) 及其说明。**式 (2) 右端遗漏数据点上标  $i$ , 现与左端统一。式 (6) 的求和范围未用括号包住两个对数项, 现补齐; 式 (6)、(7) 的噪声采样上标统一为  $(i, l)$ 。第 4 页将第一项称为 KL 散度、将  $\log p$  称为概率密度, 现分别改为负 KL 散度和对数概率密度 (或质量)。同时补全 minibatch 梯度中的  $\phi$  和估计量记号。
- 第 4–5 页, 第 2.4 节及第 3 节: 重参数化。**原文两处将  $g_\phi$  的输入顺序颠倒, 现统一为  $g_\phi(\epsilon, \mathbf{x})$ 。原证明直接对任意确定性映射写体积元等式, 现改用推前分布下的期望恒等式, 并把体积元等式限定于同维可逆可微情形, 避免将可逆换元规则误用于一般映射。逆 CDF 方法中的均匀分布原写为  $\mathcal{U}(\mathbf{0}, \mathbf{I})$ , 现明确单变量取  $\mathcal{U}(0, 1)$ , 独立分量逐一处理。
- 第 5 页, 第 2.4 节第 3 项: Gamma 与 Dirichlet 的构造。**独立同率指数变量之和只得到正整数形状参数的 Gamma (埃尔朗) 分布, 不能代表任意形状参数的 Gamma, 现补明限制。Dirichlet 不是 Gamma 变量的“加权和”, 而是同尺度独立 Gamma 变量的归一化向量: 若  $Y_j \sim \text{Gamma}(\alpha_j, \beta)$  独立, 则  $Z_j = Y_j / \sum_k Y_k$  服从  $\text{Dirichlet}(\boldsymbol{\alpha})$ 。正文已按此修正。
- 第 6 页, 第 4 节: 互信息与条件熵的符号。**原文称最大化互信息等价于最大化条件熵, 符号相反。固定输入分布时,  $I(X; Z) = H(X) - H(X | Z)$ , 故应最大化负条件熵。又由条件 KL 散度非负,  $\mathbb{E} \log p_\theta(X | Z) \leq -H(X | Z)$ , 所以期望对数似然下界对应的是负条件熵。正文已修正这两处符号, 并将朴素梯度估计量的节号从 2.1 改为实际所在的 2.2。
- 第 6 页, 第 5 节: 编码器与解码器。**原文把生成模型标为 encoder, 把变分近似标为 decoder, 与第 2.1 节定义颠倒。现分别改为解码器和编码器; 实验设置和数据不变。
- 第 10–11 页, 附录 B 和 C。**附录 B 推导将近似分布误写为  $q_\theta$ , 现统一为  $q_\phi$ , 并删去 KL 记号中多余的左括号。式 (11) 的伯努利对数似然补上求和括号, 使  $x_i \log y_i$  和  $(1 - x_i) \log(1 - y_i)$  两项均对  $i$  求和。
- 第 12 页, 附录 D: 边缘似然估计量。**两处样本求和的分母仍写  $p_\theta(\mathbf{z})$ , 现改为  $p_\theta(\mathbf{z}^{(l)})$ 。补明  $q$  归一化且支撑集位于联合密度为正的区城: 此时  $\mathbb{E}_{p_\theta(\mathbf{z} | \mathbf{x}^{(i)})}[q(\mathbf{z}) / p_\theta(\mathbf{x}^{(i)}, \mathbf{z})] = 1 / p_\theta(\mathbf{x}^{(i)})$ 。有

限样本均值取倒数一般有偏，正文保留“估计”而不增称无偏。

9. **第 13 页，附录 F：分布名、条件与引用。**式 (16)、(18) 的近似后验条件统一为  $\mathbf{x}^{(i)}$ ；说明解析 KL 的高斯条件中，原  $p_{\theta}(\mathbf{x})$  改为潜变量先验  $p_{\theta}(\mathbf{z})$ ，并明确全局参数情形的对应分布。重参数化条件的残缺节号补为 2.4；随机梯度算法引用由算法 1 改为对应的算法 2。例子中的参数先验  $p_{\alpha}(\theta) = \mathcal{N}(\mathbf{z}; \mathbf{0}, \mathbf{I})$  改为  $\mathcal{N}(\theta; \mathbf{0}, \mathbf{I})$ 。
10. **第 13 页，式 (22)：两层下界的区别与数据采样。**原式把替换潜变量对数边缘似然后的联合下界仍记成式 (14) 的  $\mathcal{L}(\phi; \mathbf{X})$ ，同时只说给定单个数据点，却未交代式中的  $\mathbf{x}^{(l)}$  如何产生。现以  $\mathcal{J}$  区分联合下界，并明确  $\mathbf{x}^{(l)}$  从数据集独立均匀抽样。依据为

$$\mathcal{L}(\phi; \mathbf{X}) - \mathcal{J}(\phi; \mathbf{X}) = \sum_{i=1}^N \mathbb{E}_{q_{\phi}(\theta)} \left[ D_{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}^{(i)}) \| p_{\theta}(\mathbf{z} | \mathbf{x}^{(i)})) \right] \geq 0.$$

式 (21) 的  $N$  倍局部项经均匀抽样后的期望正好恢复对全部数据点的求和；只有潜变量近似后验精确时，两层下界才相等。

11. **第 14 页，式 (24)：完全 VB 的高斯估计量。**原重构项写为  $\log p_{\theta}(\mathbf{x}^{(i)} \mathbf{z}^{(i)})$ ，缺少条件符号，数据及潜变量索引与外层求和不一致，也没有明确参数样本。现改为  $\log p_{\theta^{(l)}}(\mathbf{x}^{(l)} | \mathbf{z}^{(l)})$ ，并给出相应重参数化样本。全局参数 KL 项原使用潜变量维数  $J$  且保留游离的样本索引  $l$ ，现改为参数维数  $P$ ，去掉不属于全局变分参数的样本索引。左端同步改为联合下界  $\mathcal{J}$ 。这来自“期望重构对数似然减去局部 KL 与全局 KL”的分解。

## 记号与排版统一

数学粗体统一使用 `\bm`，微分算子统一为正体 `d`；若使用迹运算符，采用小写正体 `tr`。原文以方差向量乘单位矩阵简记对角协方差，现显式写为  $\text{diag}(\sigma^2)$ ，其中平方按分量计算，不改变分布含义。噪声样本  $\zeta^{(l)}$  的向量字形保持一致。原文各处“边缘似然”与“对数边缘似然”按公式实际含义区分。

采用既有蓝色标题中文单栏模板，分页因此与原文不同。原始英文 PDF 和 TeX 源包独立保存，修正仅作用于译稿。书目中的历史元数据按原稿保留；本次未重新验证实验结果，也不把排版统一当作作者勘误。