

重要性加权自编码器

Importance Weighted Autoencoders

Yuri Burda Roger Grosse Ruslan Salakhutdinov

多伦多大学计算机科学系，加拿大安大略省多伦多

{yburda, rgrosse, rsalakhu}@cs.toronto.edu

原稿标注：ICLR 2016 会议论文审稿中

摘要

变分自编码器 (VAE; Kingma & Welling (2014)) 是近期提出的一类生成模型，它将自顶向下的生成网络与自底向上的识别网络相结合，后者近似执行后验推断。这类模型通常对后验推断作出较强假设，例如后验分布近似按维度因子化，其参数可以通过对观测值的非线性回归来近似。我们的实证结果表明，VAE 目标可能产生过度简化的表示，无法充分利用网络的全部建模能力。本文提出重要性加权自编码器 (IWAE)：其架构与 VAE 相同，但使用由重要性加权导出的更紧的对数似然下界。IWAE 的识别网络利用多个样本近似后验，因此能更灵活地表示不满足 VAE 建模假设的复杂后验。实验表明，IWAE 比 VAE 学到更丰富的潜在空间表示，并在密度估计基准上取得更高的测试对数似然。

1 引言

近年来，深度生成模型的学习重新受到关注 (Hinton et al., 2006; Salakhutdinov & E., 2009; Gregor et al., 2014; Kingma & Welling, 2014; Rezende et al., 2014)。多数方法面临的共同困难是训练时需要进行后验推断：大多数潜变量模型的对数似然梯度都由后验统计量定义（例如 Salakhutdinov & E. (2009); Neal (1992); Gregor et al. (2014)）。一种应对方式是在生成模型之外同时训练识别网络 (Dayan et al., 1995)。给定观测值，识别网络预测潜变量的后验分布，而且通常能以远快于 MCMC 等通用推断算法的速度给出粗略近似。

变分自编码器 (VAE; Kingma & Welling (2014); Rezende et al. (2014)) 是近期提出的生成模型，它将自顶向下的生成网络与自底向上的识别网络相结合。两个网络联合训练，以最大化数据对数似然的变分下界。近期，VAE 已成功用于分离风格与内容 (Kingma et al., 2014; Kulkarni et al., 2015)，以及学习以逼真的方式“绘制”图像 (Gregor et al., 2015)。

VAE 对后验分布作出了较强假设。通常，VAE 假定后验近似按维度因子化，而且其参数可通过对观测值的非线性回归来预测。由于训练目标是最大化对数似然的变分下界，模型会倾向于学习

满足这些假设的表示，即后验近似因子化、且能由神经网络预测的表示。这种作用虽有好处，却也有代价：限制后验的形式会限制模型的表达能力。VAE 目标尤其如此：即使识别网络将大部分概率质量放在能够很好解释数据的区域，它仍会严厉惩罚那些难以解释数据的近似后验样本。

本文提出重要性加权自编码器 (IWAE)。它与 VAE 采用相同架构，但使用由重要性加权导出的更紧的对数似然下界进行训练。识别网络生成多个近似后验样本，再对其权重取平均。随着样本数增加，在适当的可积性条件下，该下界趋近真实对数似然。使用多个样本使 IWAE 能更灵活地学习后验分布不满足 VAE 建模假设的生成模型。这一方法与重加权唤醒—睡眠算法 (Bornschein & Bengio, 2015) 有关，但 IWAE 使用单一、统一的目标进行训练。与 VAE 相比，IWAE 能学习具有更多潜在维度的丰富表示，从而在密度估计基准上获得显著更高的对数似然。

2 背景

本节回顾 Kingma & Welling (2014) 的变分自编码器 (VAE) 模型，尤其介绍其架构向多个随机隐藏层的推广。不过，Kingma & Welling (2014) 实际使用了单个随机隐藏层；推广到多层还有其他合理方式，例如 Rezende et al. (2014) 提出的方法。

VAE 通过在一系列隐藏层中进行祖先采样来定义生成过程：

$$p(\mathbf{x}|\boldsymbol{\theta}) = \int p(\mathbf{h}^L|\boldsymbol{\theta})p(\mathbf{h}^{L-1}|\mathbf{h}^L, \boldsymbol{\theta}) \cdots p(\mathbf{x}|\mathbf{h}^1, \boldsymbol{\theta}) d\mathbf{h}. \quad (1)$$

这里， $\boldsymbol{\theta}$ 是变分自编码器的参数向量， $\mathbf{h} = \{\mathbf{h}^1, \dots, \mathbf{h}^L\}$ 表示随机隐藏单元，即潜变量。为使表达清晰，下文常省略对 $\boldsymbol{\theta}$ 的依赖。方便起见，定义 $\mathbf{h}^0 = \mathbf{x}$ 。每一项 $p(\mathbf{h}^\ell|\mathbf{h}^{\ell+1})$ 都可以表示复杂的非线性关系，例如由多层神经网络计算的关系。但我们假定，对每个 $p(\mathbf{h}^\ell|\mathbf{h}^{\ell+1})$ ，采样与概率计算都是可处理的。注意， L 表示随机隐藏层的数量；这里没有显式写出确定性层。我们假定识别模型 $q(\mathbf{h}|\mathbf{x})$ 由类似的分解定义：

$$q(\mathbf{h}|\mathbf{x}) = q(\mathbf{h}^1|\mathbf{x})q(\mathbf{h}^2|\mathbf{h}^1) \cdots q(\mathbf{h}^L|\mathbf{h}^{L-1}), \quad (2)$$

其中，乘积中的每一项都能方便地进行采样与概率计算。

本文采用与 Kingma & Welling (2014) 相同的条件概率分布族。具体而言，先验 $p(\mathbf{h}^L)$ 固定为零均值、单位方差的高斯分布。一般地，每个条件分布 $p(\mathbf{h}^\ell|\mathbf{h}^{\ell+1})$ 和 $q(\mathbf{h}^\ell|\mathbf{h}^{\ell-1})$ 都是具有对角协方差的高斯分布，其均值与协方差参数由确定性的前馈神经网络计算。对于实值观测， $p(\mathbf{x}|\mathbf{h}^1)$ 也定义为这样的高斯分布；对于二值观测，它被定义为均值参数由神经网络计算的伯努利分布。

VAE 的训练目标是最大化由 Jensen 不等式得到的对数似然变分下界：

$$\log p(\mathbf{x}) = \log \mathbb{E}_{q(\mathbf{h}|\mathbf{x})} \left[\frac{p(\mathbf{x}, \mathbf{h})}{q(\mathbf{h}|\mathbf{x})} \right] \geq \mathbb{E}_{q(\mathbf{h}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{h})}{q(\mathbf{h}|\mathbf{x})} \right] = \mathcal{L}(\mathbf{x}). \quad (3)$$

由于 $\mathcal{L}(\mathbf{x}) = \log p(\mathbf{x}) - \text{D}_{\text{KL}}(q(\mathbf{h}|\mathbf{x})||p(\mathbf{h}|\mathbf{x}))$ ，训练必须在数据对数似然 $\log p(\mathbf{x})$ 与近似后验相对于真实后验的 KL 散度之间作出权衡。这有其益处，因为它鼓励模型学习后验推断易于近似的表示。

如果直接从式 (3) 计算识别网络的目标梯度，就会得到类似 REINFORCE 的更新规则。由于没有利用对潜变量求导的对数似然梯度，这种规则训练较慢 (Dayan et al., 1995; Mnih & Gregor,

2014)。因此, Kingma & Welling (2014) 提出用具有固定分布的辅助变量对识别分布重参数化, 使识别模型的样本成为输入与辅助变量的确定性函数。他们针对多种分布介绍了重参数化技巧; 为方便起见, 本文只讨论高斯分布这一特例, 因为本文只需要这一情形。(一般的重参数化技巧也适用于我们的 IWAE。)

本文中, 识别分布 $q(\mathbf{h}^\ell | \mathbf{h}^{\ell-1}, \boldsymbol{\theta})$ 始终是高斯分布 $\mathcal{N}(\mathbf{h}^\ell | \boldsymbol{\mu}(\mathbf{h}^{\ell-1}, \boldsymbol{\theta}), \boldsymbol{\Sigma}(\mathbf{h}^{\ell-1}, \boldsymbol{\theta}))$, 其均值与协方差由上一层隐藏单元的状态及模型参数计算。等价地, 可以先采样辅助变量 $\boldsymbol{\epsilon}^\ell \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 再应用确定性映射

$$\mathbf{h}^\ell(\boldsymbol{\epsilon}^\ell, \mathbf{h}^{\ell-1}, \boldsymbol{\theta}) = \boldsymbol{\Sigma}(\mathbf{h}^{\ell-1}, \boldsymbol{\theta})^{1/2} \boldsymbol{\epsilon}^\ell + \boldsymbol{\mu}(\mathbf{h}^{\ell-1}, \boldsymbol{\theta}). \quad (4)$$

依次对各层应用式 (4), 便可用确定性映射 $\mathbf{h}(\boldsymbol{\epsilon}, \mathbf{x}, \boldsymbol{\theta})$ 表示所有潜变量的联合识别分布 $q(\mathbf{h} | \mathbf{x}, \boldsymbol{\theta})$, 其中 $\boldsymbol{\epsilon} = (\boldsymbol{\epsilon}^1, \dots, \boldsymbol{\epsilon}^L)$ 。由于 $\boldsymbol{\epsilon}$ 的分布不依赖于 $\boldsymbol{\theta}$, 在允许交换求导与期望的通常正则条件下, 可以将梯度算子移入期望, 从而把式 (3) 中下界 $\mathcal{L}(\mathbf{x})$ 的梯度改写为:

$$\nabla_{\boldsymbol{\theta}} \mathbb{E}_{\mathbf{h} \sim q(\mathbf{h} | \mathbf{x}, \boldsymbol{\theta})} \left[\log \frac{p(\mathbf{x}, \mathbf{h} | \boldsymbol{\theta})}{q(\mathbf{h} | \mathbf{x}, \boldsymbol{\theta})} \right] = \nabla_{\boldsymbol{\theta}} \mathbb{E}_{\boldsymbol{\epsilon}^1, \dots, \boldsymbol{\epsilon}^L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\log \frac{p(\mathbf{x}, \mathbf{h}(\boldsymbol{\epsilon}, \mathbf{x}, \boldsymbol{\theta}) | \boldsymbol{\theta})}{q(\mathbf{h}(\boldsymbol{\epsilon}, \mathbf{x}, \boldsymbol{\theta}) | \mathbf{x}, \boldsymbol{\theta})} \right] \quad (5)$$

$$= \mathbb{E}_{\boldsymbol{\epsilon}^1, \dots, \boldsymbol{\epsilon}^L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\nabla_{\boldsymbol{\theta}} \log \frac{p(\mathbf{x}, \mathbf{h}(\boldsymbol{\epsilon}, \mathbf{x}, \boldsymbol{\theta}) | \boldsymbol{\theta})}{q(\mathbf{h}(\boldsymbol{\epsilon}, \mathbf{x}, \boldsymbol{\theta}) | \mathbf{x}, \boldsymbol{\theta})} \right]. \quad (6)$$

若映射 $\mathbf{h}$ 由确定性的前馈神经网络表示, 则固定 $\boldsymbol{\epsilon}$ 后, 期望内部的梯度可用标准反向传播计算。实际中, 通过生成 $\boldsymbol{\epsilon}$ 的 k 个样本, 并使用以下蒙特卡洛估计量, 近似式 (6) 的期望:

$$\frac{1}{k} \sum_{i=1}^k \nabla_{\boldsymbol{\theta}} \log w(\mathbf{x}, \mathbf{h}(\boldsymbol{\epsilon}_i, \mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta}) \quad (7)$$

其中 $w(\mathbf{x}, \mathbf{h}, \boldsymbol{\theta}) = p(\mathbf{x}, \mathbf{h} | \boldsymbol{\theta}) / q(\mathbf{h} | \mathbf{x}, \boldsymbol{\theta})$ 。这是 $\nabla_{\boldsymbol{\theta}} \mathcal{L}(\mathbf{x})$ 的无偏估计。注意, VAE 更新和基本的 REINFORCE 式更新都是同一梯度的无偏估计量; 但 VAE 更新利用了对潜变量求导的对数似然梯度, 因此在实践中通常具有更低的方差。

3 重要性加权自编码器

式 (3) 的 VAE 目标会严厉惩罚不能解释观测的近似后验样本。这对模型构成了较强约束, 因为只有近似满足变分假设, 才能获得良好的下界。具体而言, 后验分布必须近似按维度因子化, 并能由前馈神经网络预测。这样的 VAE 准则可能过于严格: 即使识别网络只有少部分样本 (例如 20%) 落在后验概率较高的区域, 也可能足以进行准确推断。若如此放宽要求, 就可能更灵活地训练后验分布不满足 VAE 假设的生成网络。这正是我们提出重要性加权自编码器 (IWAE) 的动机。

IWAE 使用与 VAE 相同的架构, 同时包含生成网络和识别网络。区别在于, 它通过最大化 $\log p(\mathbf{x})$ 的另一种下界来训练。具体而言, 我们采用以下下界, 它对应于使用 k 个样本的重要性加权对数似然估计:

$$\mathcal{L}_k(\mathbf{x}) = \mathbb{E}_{\mathbf{h}_1, \dots, \mathbf{h}_k \sim q(\mathbf{h} | \mathbf{x})} \left[\log \frac{1}{k} \sum_{i=1}^k \frac{p(\mathbf{x}, \mathbf{h}_i)}{q(\mathbf{h}_i | \mathbf{x})} \right]. \quad (8)$$

这里, $\mathbf{h}_1, \dots, \mathbf{h}_k$ 独立采样自识别模型。求和中的每一项是联合分布的未归一化重要性权重, 记为 $w_i = p(\mathbf{x}, \mathbf{h}_i)/q(\mathbf{h}_i|\mathbf{x})$ 。

在提议分布覆盖目标分布支撑集的条件下, 重要性权重的平均值是 $p(\mathbf{x})$ 的无偏估计量; 结合 Jensen 不等式可知, 这确实是边缘对数似然的下界:

$$\mathcal{L}_k = \mathbb{E} \left[\log \frac{1}{k} \sum_{i=1}^k w_i \right] \leq \log \mathbb{E} \left[\frac{1}{k} \sum_{i=1}^k w_i \right] = \log p(\mathbf{x}), \quad (9)$$

其中, 期望相对于 $q(\mathbf{h}|\mathbf{x})$ 计算。

在高维空间中, 重要性加权竟能提供合理的估计量, 这或许不太直观。但注意, $k=1$ 的特例就等价于式 (3) 的标准 VAE 目标。使用更多样本只会使下界更紧:

定理 1 对所有 k , 下界满足

$$\log p(\mathbf{x}) \geq \mathcal{L}_{k+1} \geq \mathcal{L}_k. \quad (10)$$

进一步, 若存在常数 $0 < c \leq C < \infty$, 使 $c \leq p(\mathbf{h}, \mathbf{x})/q(\mathbf{h}|\mathbf{x}) \leq C$ 几乎处处成立, 则当 k 趋于无穷时, $\mathcal{L}_k$ 趋于 $\log p(\mathbf{x})$ 。

证明 见附录 A. □

下界 $\mathcal{L}_k$ 可以用直接的蒙特卡洛估计量来估计: 从识别网络采样, 对重要性权重取平均后取对数。人们可能担心估计量的方差, 因为当提议分布与目标分布不匹配时, 重要性加权的方差可能极大。不过, 对权重平均值取对数可以控制高估尾部; 附录 B 进一步证明, 其平均绝对偏差受对数估计的偏差控制。这一结论本身不保证方差较小或有限。

3.1 训练过程

为了使用基于随机梯度的优化器训练 IWAE, 我们采用式 (8) 定义的 $\mathcal{L}_k$ 的无偏梯度估计。与 VAE 一样, 我们使用重参数化技巧推导低方差的更新规则:

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_k(\mathbf{x}) = \nabla_{\boldsymbol{\theta}} \mathbb{E}_{\mathbf{h}_1, \dots, \mathbf{h}_k} \left[\log \frac{1}{k} \sum_{i=1}^k w_i \right] = \nabla_{\boldsymbol{\theta}} \mathbb{E}_{\boldsymbol{\epsilon}_1, \dots, \boldsymbol{\epsilon}_k} \left[\log \frac{1}{k} \sum_{i=1}^k w(\mathbf{x}, \mathbf{h}(\boldsymbol{\epsilon}_i, \mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta}) \right] \quad (11)$$

$$= \mathbb{E}_{\boldsymbol{\epsilon}_1, \dots, \boldsymbol{\epsilon}_k} \left[\nabla_{\boldsymbol{\theta}} \log \frac{1}{k} \sum_{i=1}^k w(\mathbf{x}, \mathbf{h}(\boldsymbol{\epsilon}_i, \mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta}) \right] \quad (12)$$

$$= \mathbb{E}_{\boldsymbol{\epsilon}_1, \dots, \boldsymbol{\epsilon}_k} \left[\sum_{i=1}^k \widetilde{w}_i \nabla_{\boldsymbol{\theta}} \log w(\mathbf{x}, \mathbf{h}(\boldsymbol{\epsilon}_i, \mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta}) \right], \quad (13)$$

其中, $\boldsymbol{\epsilon}_1, \dots, \boldsymbol{\epsilon}_k$ 与第 2 节为 VAE 定义的辅助变量相同; $w_i = w(\mathbf{x}, \mathbf{h}(\boldsymbol{\epsilon}_i, \mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta})$ 是写成确定性函数的重要性权重, $\widetilde{w}_i = w_i / \sum_{j=1}^k w_j$ 是归一化重要性权重。

在基于梯度的学习算法中, 我们从识别网络抽取 k 个样本 (等价地, 抽取 k 组辅助变量), 并使用式 (13) 的蒙特卡洛估计:

$$\sum_{i=1}^k \widetilde{w}_i \nabla_{\boldsymbol{\theta}} \log w(\mathbf{x}, \mathbf{h}(\boldsymbol{\epsilon}_i, \mathbf{x}, \boldsymbol{\theta}), \boldsymbol{\theta}). \quad (14)$$

在 $k = 1$ 的特例中，唯一的归一化权重 $\tilde{w}_1$ 等于 1，因此得到 VAE 的更新规则。

下面进一步分析这一更新，因为它与标准 VAE 的更新并不完全对应。¹对数权重的梯度可分解为：

$$\nabla_{\theta} \log w(\mathbf{x}, \mathbf{h}(\epsilon_i, \mathbf{x}, \theta), \theta) = \nabla_{\theta} \log p(\mathbf{x}, \mathbf{h}(\epsilon_i, \mathbf{x}, \theta) | \theta) - \nabla_{\theta} \log q(\mathbf{h}(\epsilon_i, \mathbf{x}, \theta) | \mathbf{x}, \theta). \quad (15)$$

第一项鼓励生成模型在给定 $\mathbf{h}^{\ell+1}$ 时，为各个 $\mathbf{h}^{\ell}$ 赋予较高概率（沿用 $\mathbf{x} = \mathbf{h}^0$ 的约定）。它也鼓励识别网络调整隐藏表示，使生成网络能够更好地预测。在只有一个随机层（即 $L = 1$ ）时，这两种作用的结合等价于随机自编码器中的反向传播。更新的第二项鼓励识别网络给出更分散的预测分布。该更新按与重要性权重成比例的权重在样本间取平均，“重要性加权自编码器”的名称即由此而来。

IWAE 训练的主要计算成本，是计算 $\nabla_{\theta} \log w(\mathbf{x}, \mathbf{h}(\epsilon_i, \mathbf{x}, \theta), \theta)$ 所需的激活值与参数梯度，分别对应反向传播算法的前向与反向过程。在基本的 IWAE 实现中，每个样本都需要独立执行这两个过程，因此运算量随 k 线性增长。在我们的 GPU 实现中，每个训练样本在小批量内复制 k 次，从而并行处理这些采样结果。

引入另一种随机性可以大幅降低计算成本。具体而言，计算重要性权重只需要前向过程。对式 (14) 中的求和，可以按归一化权重 $\tilde{w}_i$ 选取单个样本 ϵ_i ，再计算 $\nabla_{\theta} \log w(\mathbf{x}, \mathbf{h}(\epsilon_i, \mathbf{x}, \theta), \theta)$ ，从而得到随机近似。这样，每个训练样本只需 k 次前向过程和一次反向过程。由于反向过程所需的乘加运算大约是前向过程的两倍，当 k 较大时，这一技巧可将乘加运算量降至约三分之一。代价是更新方差增大，但实证上我们发现这一权衡是有利的。

4 相关工作

训练深度生成模型的方法大致可分为几类。有些模型用玻尔兹曼分布定义 (Smolensky, 1986; Salakhutdinov & E., 2009)，其优点是许多条件分布可处理，但难以从模型采样或计算配分函数始终是主要障碍 (Salakhutdinov & Murray, 2008)。另一些模型用信念网络定义 (Neal, 1992; Gregor et al., 2014)。这类模型易于采样，但解释消除效应会使条件分布中的依赖关系变得复杂。

应对难以处理的后验推断，一种策略是训练近似后验的识别网络。经典方法是用于训练 Helmholtz 机的唤醒—睡眠算法 (Dayan et al., 1995)：生成模型学习识别网络推断出的条件分布，识别网络则学习解释生成网络产生的合成数据。不幸的是，唤醒—睡眠算法用不同的目标函数训练两个网络。深度自回归网络 (Gregor et al., 2014) 由深层生成网络与识别网络组成，使用同一个变分下界训练。神经变分推断与学习 (NVIL; Mnih & Gregor, 2014) 是另一种训练识别网络的算法：它在 REINFORCE 算法 (Williams, 1992) 的框架下训练第三个网络来预测奖励基线，从而减少更新中的随机性。Salakhutdinov & Larochelle (2010) 则使用识别网络近似深度玻尔兹曼机的后验分布。

第 2 节详细介绍的变分自编码器 (Kingma & Welling, 2014; Rezende et al., 2014)，也是生成网

¹Kingma & Welling (2014) 将式 (3) 中的 KL 散度单独分离出来，以得到更简单、方差更低的更新。不幸的是，当 $k > 1$ 时，没有相应的技巧可用。因此，原则上 IWAE 更新的方差可能更高。但在实验中，我们发现当 $k = 1$ 时，两种更新规则的性能没有可辨别的差异。

络与识别网络的组合，其训练使用与 DARN 和 NVIL 相同的变分目标。不过，它不用 REINFORCE，而是巧妙地对随机选择进行重参数化，以降低更新方差。重参数化技巧也称为“通过随机数生成器反向传播” (Williams, 1992)。

VAE 与上述其他模型的一个区别是，模型可以描述为先从简单分布采样、再应用确定性映射，而不是一系列随机选择。已有研究提出了架构相似、训练目标不同的模型。生成对抗网络 (Goodfellow et al., 2014) 训练相互对抗的生成网络与识别网络：识别网络尝试区分训练样本和生成样本，生成模型则尝试产生能够欺骗识别网络的样本。最大均值差异 (MMD) 网络 (Li et al., 2015; Dziugaite et al., 2015) 试图生成在某组统计量上与训练数据匹配的样本。它们可以看成一种对抗网络，其中对手只观察预先选定的一组统计量 (Dziugaite et al., 2015)。与 VAE 不同，对抗网络和 MMD 网络的训练准则不基于数据对数似然。

其他研究者也曾通过重要性采样推导对数概率下界。Tang & Salakhutdinov (2013) 和 Ba et al. (2015) 完全不使用识别网络，而是从先验进行重要性采样来推断。Gogate et al. (2007) 提出了多种基于重要性加权的图模型推断算法。Bornschein & Bengio (2015) 的重加权唤醒—睡眠 (RWS) 是另一种使用识别网络的方法：它结合了原始唤醒—睡眠算法和一种生成网络更新，后者等价于对我们的下界 $\mathcal{L}_k$ 做梯度上升。但 Bornschein & Bengio (2015) 将该更新解释为沿 $\nabla_{\theta} \log p(\mathbf{x})$ 的有偏估计更新，而我们将其解释为沿 $\nabla_{\theta} \mathcal{L}_k$ 的无偏估计更新。IWAE 与 RWS 的另一区别是，生成网络和识别网络都通过最大化同一个目标 $\mathcal{L}_k$ 训练。相比之下，RWS 的 q -唤醒步骤和睡眠步骤似乎与 $\mathcal{L}_k$ 没有联系。最后，IWAE 还使用了重参数化技巧，这也区别于 RWS。

除了本文使用多个近似后验样本的方法，增强后验推断灵活性的另一条路线，是使用比重要性采样更复杂的算法。例如归一化流 (Rezende & Mohamed, 2015)，以及 Salimans et al. (2015) 的哈密顿变分近似。

本文发表后，作者得知 Laurent Dinh 和 Vincent Dumoulin 也独立探索了用重要性加权下界训练变分自编码器的想法，其初步结果已在 2014 年 CIFAR NCAP 深度学习暑期学校上展示。

5 实验结果

我们在两个密度估计基准数据集上，通过留出数据的对数似然比较 VAE 与 IWAE 的生成性能。我们还进一步研究了在 VAE 和 IWAE 中观察到的一个问题：它们学到的潜在空间维数明显低于模型所允许的容量。我们检验了 IWAE 训练方法能否缓解这一现象。

5.1 密度估计评估

我们在两个基准数据集上评估模型：手写数字图像数据集 MNIST (LeCun et al., 1998)，以及包含世界上多种字母系统的手写字符数据集 Omniglot (Lake et al., 2013)。两者的观测均为二值化的

28 × 28 图像。²MNIST 使用标准的 60,000 个训练样本和 10,000 个测试样本划分；Omniglot 使用 24,345 个训练样本和 8,070 个测试样本。

我们训练了两种架构：

1. 单个随机层 h^1 ，含 50 个单元。观测层与随机层之间有两个确定性层，每层含 200 个单元。
2. 两个随机层 h^1 和 h^2 ，分别含 100 和 50 个单元。 x 与 h^1 之间有两个确定性层，每层 200 个单元； h^1 与 h^2 之间有两个确定性层，每层 100 个单元。

所有确定性隐藏单元均采用 tanh 非线性。除可见层采用伯努利分布外，所有随机层均采用对角协方差高斯分布。预测的高斯方差经过 exp 非线性变换。网络架构汇总于附录 C。

所有模型均使用 Glorot & Bengio (2010) 的启发式方法初始化。优化使用 Adam (Kingma & Ba, 2015)，参数为 $\beta_1 = 0.9$ 、 $\beta_2 = 0.999$ 、 $\epsilon = 10^{-4}$ ，小批量大小为 20。对 $i = 0, \dots, 7$ ，以学习率 $0.001 \cdot 10^{-i/7}$ 遍历数据 3^i 次，总计 $\sum_{i=0}^7 3^i = 3280$ 次。该学习率调度根据在 MNIST 上训练单随机层 VAE 的初步实验选定。

对每个样本数 $k \in \{1, 5, 50\}$ ，我们都训练一个按式 (7) 估计 $\mathcal{L}(x)$ 梯度的 VAE，以及一个按式 (14) 估计梯度的 IWAE。对于每个 k ，VAE 与 IWAE 的训练时间大致相同。

所有对数似然数值均通过在测试集上计算 $\mathcal{L}_{5000}$ 的均值来估计。因此，报告值是真实值的随机下界估计，但很可能比训练所用的下界更准确。

对数似然结果见表 1。我们的 VAE 结果与文献此前报告的结果相当。我们观察到，使用 $k > 1$ 训练 VAE 只带来轻微改善；相比之下，多个样本显著改善了 IWAE 在两个数据集上的结果。注意，当 $k = 1$ 时，两种算法相同，因此除随机波动外，结果应当一致。

在 MNIST 上，具有两个随机层、 $k = 50$ 的 IWAE 在不利用像素空间排列结构的设置下取得了 -82.90 的对数似然。作为比较，深度信念网络的对数似然约为 -84.55 nat (Murray & Salakhutdinov, 2009)，深度自回归网络为 -84.13 nat (Gregor et al., 2014)。利用了空间结构的 Gregor et al. (2015) 取得了 -80.97 。我们没有发现过拟合是 VAE 或 IWAE 的严重问题：两者的训练对数似然比测试对数似然高 0.62 至 0.79 nat。模型生成的样本见附录 E。

在 OMNIGLOT 上，表现最好的 IWAE 对数似然为 -103.38 nat，略逊于使用持久对比散度训练、含 500 个隐藏单元的受限玻尔兹曼机所取得的 -100.46 nat (Burda et al., 2015)。使用中心化方法或 FANG 方法训练的 RBM 也取得了约 -100 nat 的相近表现 (Grosse & Salakhutdinov, 2015)。我们训练的模型，其训练对数似然比测试对数似然高 2.39 至 2.65 nat。

5.2 潜在空间表示

我们观察到，VAE 与 IWAE 通常都会学到有效维数远低于其容量的潜在表示。接下来的实验旨在量化这一现象，并确定 IWAE 目标能否缓解它。

²不幸的是，生成建模文献采用的二值化方法并不统一，不同选择可能导致对数似然数值有很大差异。我们遵循 Salakhutdinov & Murray (2008) 的流程：采样二值观测，使其期望等于训练集中的实值。另一种二值化方案见附录 D。

		MNIST				OMNIGLOT			
随机 层数	k	VAE		IWAE		VAE		IWAE	
		NLL	活跃 单元	NLL	活跃 单元	NLL	活跃 单元	NLL	活跃 单元
1	1	86.76	19	86.76	19	108.11	28	108.11	28
	5	86.47	20	85.54	22	107.62	28	106.12	34
	50	86.35	20	84.78	25	107.80	28	104.67	41
2	1	85.33	16+5	85.33	16+5	107.58	28+4	107.56	30+5
	5	85.01	17+5	83.89	21+5	106.31	30+5	104.79	38+6
	50	84.78	17+5	82.90	26+7	106.30	30+5	103.38	44+7

表 1 密度估计结果与活跃潜在维度数。对于具有两个潜变量层的模型，“ $k_1 + k_2$ ”表示第一层有 k_1 个活跃单元、第二层有 k_2 个活跃单元。随着 k 增加，IWAE 的生成性能有所改善，而 VAE 仅略有受益。两层模型的生成性能优于单层模型。

如果某个潜在维度编码了数据的有用信息，我们预期它的分布会随观测而变化。基于这一直觉，我们用统计量 $A_u = \text{Cov}_{\mathbf{x}}(\mathbb{E}_{u \sim q(u|\mathbf{x})}[u])$ 衡量潜在维度 u 的活跃程度。若 $A_u > 10^{-2}$ ，就称该维度为活跃维度。以下两项证据表明，这一判据既明确又有意义：

1. 训练后模型的 A_u 分布由两个相距很远的峰组成，如附录 C 所示。
2. 为确认非活跃维度确实对预测影响很小，我们移除非活跃维度后评估了所有模型。在全部情形下，测试对数似然的变化均小于 0.06 nat。

表 1 报告了所有条件下的活跃单元数。在全部条件下，活跃维度都远少于总维度数。增加潜在维度并没有增加活跃维度数。有趣的是，在两层模型中，第二层利用的建模容量很少：活跃维度数始终小于 10。在所有 $k > 1$ 的情形下，IWAE 学到的活跃潜在维度都多于 VAE。由于这伴随着更高的对数似然，我们推测，更多活跃维度反映了更丰富的潜在表示。

表面上看，非活跃维度现象类似于神经网络和潜变量模型中的“单元失活”问题，后者常被归因于优化困难。例如，一个非活跃单元可能因为优化地形中的平台而始终收不到有意义的梯度信号。在这种情况下，更好的初始化可能避免问题。为判断非活跃单元源于优化问题还是建模问题，我们选取表 1 中的单层 MNIST 模型：VAE ($k = 1$) 与 IWAE ($k = 50$)，然后分别改用 IWAE 目标和 VAE 目标继续训练。两种情况下都以 10^{-4} 的学习率额外遍历数据 3^7 次。

结果见表 2。使用 IWAE 目标继续训练 VAE，会增加活跃维度数并提高测试对数似然；使用 VAE 目标继续训练 IWAE 则产生相反效果。VAE 目标的训练会主动减少活跃维度并降低对数似然，

	第一阶段			第二阶段		
	训练目标	NLL	活跃单元	训练目标	NLL	活跃单元
实验 1	VAE	86.76	19	IWAE, $k = 50$	84.88	22
实验 2	IWAE, $k = 50$	84.78	25	VAE	86.02	23

表 2 改用 IWAE 目标继续训练 VAE，以及反向切换训练目标的结果。用 IWAE 目标训练 VAE，会增加潜在维数并提高测试对数似然；用 VAE 目标训练 IWAE 则产生相反效果。

这强烈表明，潜在维度的非活跃化是由目标函数驱动的，而非仅由优化问题造成。不过，优化似乎也起一定作用，因为表 2 的结果与表 1 并不完全相同。

6 结论

本文提出了重要性加权自编码器：这是 VAE 的一种变体，通过最大化由重要性加权得到的更紧的对数似然下界来训练。实验表明，在架构与训练时间相同的情况下，IWAE 比 VAE 学到更丰富的潜在表示，并取得更好的生成性能。我们相信，这一方法也可能提高其他目前使用 VAE 目标训练的生成模型的灵活性。

7 致谢

本研究得到 NSERC、Fields 研究所和三星公司的支持。

参考文献

- Ba, J. L., Mnih, V., and Kavukcuoglu, K. Multiple object recognition with visual attention. In *International Conference on Learning Representations*, 2015.
- Bornschein, J. and Bengio, Y. Reweighted wake-sleep. *International Conference on Learning Representations*, 2015.
- Burda, Y., Grosse, R. B., and Salakhutdinov, R. Accurate and conservative estimates of MRF log-likelihood using reverse annealing. *Artificial Intelligence and Statistics*, pp. 102–110, 2015.
- Dayan, P., Hinton, G. E., Neal, R. M., and Zemel, R. S. The Helmholtz machine. *Neural Computation*, 7: 889–904, 1995.
- Dziugaite, K. G., Roy, D. M., and Ghahramani, Z. Training generative neural networks via maximum mean discrepancy optimization. In *Uncertainty in Artificial Intelligence*, 2015.

- Glorot, X. and Bengio, Y. Understanding the difficulty of training deep feedforward neural networks. In *Artificial Intelligence and Statistics*, pp. 249–256, 2010.
- Gogate, V., Bidyuk, B., and Dechter, R. Studies in lower bounding probability of evidence using the Markov inequality. In *Uncertainty in Artificial Intelligence*, 2007.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. Generative adversarial nets. In *Neural Information Processing Systems*, 2014.
- Gregor, K., Danihelka, I., Mnih, A., Blundell, C., and Wierstra, D. Deep autoregressive networks. *International Conference on Machine Learning*, 2014.
- Gregor, K., Danihelka, I., Graves, A., Rezende, D. J., and Wierstra, D. DRAW: A recurrent neural network for image generation. In *International Conference on Machine Learning*, pp. 1462–1471, 2015.
- Grosse, R. and Salakhudinov, R. Scaling up natural gradient by sparsely factorizing the inverse fisher matrix. In *International Conference on Machine Learning*, 2015.
- Hinton, G. E., Osindero, S., and Teh, Y. A fast learning algorithm for deep belief nets. *Neural Computation*, 2006.
- Kingma, D. and Ba, J. L. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.
- Kingma, D. P. and Welling, M. Auto-Encoding Variational Bayes. *International Conference on Learning Representations*, 2014.
- Kingma, D. P., Mohamed, S., Rezende, D. J., and Welling, M. Semi-supervised learning with deep generative models. In *Neural Information Processing Systems*, 2014.
- Kulkarni, T. D., Whitney, W., Kohli, P., and Tenenbaum, J. B. Deep convolutional inverse graphics network. arXiv:1503.03167, 2015.
- Lake, B. M., Salakhutdinov, R., and Tenenbaum, J. B. One-shot learning by inverting a compositional causal process. In *Neural Information Processing Systems*, 2013.
- Larochelle, H., Murray I. The neural autoregressive distribution estimator. In *Artificial Intelligence and Statistics*, pp. 29–37, 2011.
- LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- Li, Y., Swersky, K., and Zemel, R. Generative moment matching networks. In *International Conference on Machine Learning*, pp. 1718–1727, 2015.
- Mnih, A. and Gregor, K. Neural variational inference and learning in belief networks. In *International Conference on Machine Learning*, pp. 1791–1799, 2014.

- Murray, I. and Salakhutdinov, R. Evaluating probabilities under high-dimensional latent variable models. In *Neural Information Processing Systems*, pp. 1137–1144, 2009.
- Neal, R. M. Connectionist learning of belief networks. *Artificial Intelligence*, 1992.
- Rezende, D. J. and Mohamed, S. Variational inference with normalizing flows. In *International Conference on Machine Learning*, pp. 1530–1538, 2015.
- Rezende, D. J., Mohamed, S., and Wierstra, D. Stochastic backpropagation and approximate inference in deep generative models. *International Conference on Machine Learning*, pp. 1278–1286, 2014.
- Salakhutdinov, R. and E., Hinton G. Deep Boltzmann machines. In *Neural Information Processing Systems*, 2009.
- Salakhutdinov, R. and Larochelle, H. Efficient learning of deep Boltzmann machines. In *Artificial Intelligence and Statistics*, 2010.
- Salakhutdinov, R. and Murray, I. On the quantitative analysis of deep belief networks. In *International Conference on Machine Learning*, 2008.
- Salimans, T., Kingma, D. P., and Welling, M. Markov chain Monte Carlo and variational inference: bridging the gap. In *International Conference on Machine Learning*, pp. 1218–1226, 2015.
- Smolensky, P. Information processing in dynamical systems: foundations of harmony theory. In Rumelhart, D. E. and McClelland, J. L. (eds.), *Parallel Distributed Processing: Explorations in the Microstructure of Cognition*. MIT Press, 1986.
- Tang, Y. and Salakhutdinov, R. Learning stochastic feedforward neural networks. In *Neural Information Processing Systems*, 2013.
- Williams, R. J. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8:229–256, 1992.

附录 A

定理 1 的证明 我们需要证明对数似然下界 $\mathcal{L}_k$ 的以下性质：

1. $\log p(\mathbf{x}) \geq \mathcal{L}_k$,
2. 当 $k \geq m$ 时, $\mathcal{L}_k \geq \mathcal{L}_m$,
3. 若存在 $0 < c \leq C < \infty$, 使 $c \leq p(\mathbf{h}, \mathbf{x})/q(\mathbf{h}|\mathbf{x}) \leq C$ 几乎处处成立, 则 $\log p(\mathbf{x}) = \lim_{k \rightarrow \infty} \mathcal{L}_k$ 。

下面依次证明：

1. 由 Jensen 不等式可得

$$\mathcal{L}_k = \mathbb{E} \left[\log \frac{1}{k} \sum_{i=1}^k \frac{p(\mathbf{x}, \mathbf{h}_i)}{q(\mathbf{h}_i|\mathbf{x})} \right] \leq \log \mathbb{E} \left[\frac{1}{k} \sum_{i=1}^k \frac{p(\mathbf{x}, \mathbf{h}_i)}{q(\mathbf{h}_i|\mathbf{x})} \right] = \log p(\mathbf{x}) \quad (16)$$

2. 令 $I \subset \{1, \dots, k\}$ 为从 $\{1, \dots, k\}$ 中均匀选出的、含 m 个互不相同指标的子集, 即 $|I| = m$ 。我们将用到一个简单事实：对任意数列 $a_1, \dots, a_k$, 有 $\mathbb{E}_{I=\{i_1, \dots, i_m\}} [(a_{i_1} + \dots + a_{i_m})/m] = (a_1 + \dots + a_k)/k$ 。

结合这一事实与 Jensen 不等式, 得到

$$\mathcal{L}_k = \mathbb{E}_{\mathbf{h}_1, \dots, \mathbf{h}_k} \left[\log \frac{1}{k} \sum_{i=1}^k \frac{p(\mathbf{x}, \mathbf{h}_i)}{q(\mathbf{h}_i|\mathbf{x})} \right] \quad (17)$$

$$= \mathbb{E}_{\mathbf{h}_1, \dots, \mathbf{h}_k} \left[\log \mathbb{E}_{I=\{i_1, \dots, i_m\}} \left[\frac{1}{m} \sum_{j=1}^m \frac{p(\mathbf{x}, \mathbf{h}_{i_j})}{q(\mathbf{h}_{i_j}|\mathbf{x})} \right] \right] \quad (18)$$

$$\geq \mathbb{E}_{\mathbf{h}_1, \dots, \mathbf{h}_k} \left[\mathbb{E}_{I=\{i_1, \dots, i_m\}} \left[\log \frac{1}{m} \sum_{j=1}^m \frac{p(\mathbf{x}, \mathbf{h}_{i_j})}{q(\mathbf{h}_{i_j}|\mathbf{x})} \right] \right] \quad (19)$$

$$= \mathbb{E}_{\mathbf{h}_1, \dots, \mathbf{h}_m} \left[\log \frac{1}{m} \sum_{i=1}^m \frac{p(\mathbf{x}, \mathbf{h}_i)}{q(\mathbf{h}_i|\mathbf{x})} \right] = \mathcal{L}_m \quad (20)$$

3. 考虑随机变量

$$M_k = \frac{1}{k} \sum_{i=1}^k \frac{p(\mathbf{x}, \mathbf{h}_i)}{q(\mathbf{h}_i|\mathbf{x})}.$$

由强大数定律, M_k 几乎必然收敛到 $\mathbb{E}_{q(\mathbf{h}|\mathbf{x})}[p(\mathbf{x}, \mathbf{h})/q(\mathbf{h}|\mathbf{x})] = p(\mathbf{x})$ 。由假设, $c \leq M_k \leq C$, 所以 $|\log M_k| \leq \max\{|\log c|, |\log C|\}$ 。由有界收敛定理, $\mathcal{L}_k = \mathbb{E}[\log M_k]$ 随 $k \rightarrow \infty$ 收敛到 $\log p(\mathbf{x})$ 。

附录 B

众所周知，若提议分布与目标分布不匹配，基于未归一化重要性采样的估计量可能具有极大、甚至无穷的方差。这里研究第 3 节所述 $\mathcal{L}_k$ 蒙特卡洛估计量的波动。更确切地说，我们给出平均绝对偏差 (MAD) 的上界。该上界并不直接控制方差；小 MAD 也不能排除极大乃至无穷的方差。

设 $\hat{Z}$ 是某个正数 Z 的严格正的无偏估计量，并希望用 $\log \hat{Z}$ 估计 $\log Z$ 。假设 $\mathbb{E}[|\log \hat{Z}|] < \infty$ 。由 Jensen 不等式，这是有偏估计，即 $\mathbb{E}[\log \hat{Z}] \leq \log Z$ 。将偏差记为 $\delta = \log Z - \mathbb{E}[\log \hat{Z}]$ 。首先注意， $\log \hat{Z}$ 大幅高估 $\log Z$ 的概率较小；由 Markov 不等式可得：

$$\Pr(\log \hat{Z} > \log Z + b) \leq e^{-b}. \quad (21)$$

令 $(X)_+ = \max(X, 0)$ 。利用上述事实，可得 MAD 的上界：

$$\mathbb{E}[|\log \hat{Z} - \mathbb{E}[\log \hat{Z}]|] = 2\mathbb{E}\left[(\log \hat{Z} - \mathbb{E}[\log \hat{Z}])_+\right] \quad (22)$$

$$= 2\mathbb{E}\left[(\log \hat{Z} - \log Z + \log Z - \mathbb{E}[\log \hat{Z}])_+\right] \quad (23)$$

$$\leq 2\mathbb{E}\left[(\log \hat{Z} - \log Z)_+ + (\log Z - \mathbb{E}[\log \hat{Z}])_+\right] \quad (24)$$

$$= 2\mathbb{E}\left[(\log \hat{Z} - \log Z)_+\right] + 2\delta \quad (25)$$

$$= 2 \int_0^\infty \Pr(\log \hat{Z} - \log Z > t) dt + 2\delta \quad (26)$$

$$\leq 2 \int_0^\infty e^{-t} dt + 2\delta \quad (27)$$


$$= 2 + 2\delta \quad (28)$$

这里，式 (22) 是 MAD 的一般恒等式；式 (26) 使用了非负随机变量 Y 的公式 $\mathbb{E}[Y] = \int_0^\infty \Pr(Y > t) dt$ ；式 (27) 则应用了式 (21) 的上界。因此，MAD 不超过 $2 + 2\delta$ 。在 IWAE 中， δ 对应于 $\log p(\mathbf{x})$ 与 $\mathcal{L}_k$ 之间的差距。

附录 C


网络架构

实验所用网络架构汇总如下。图中的“线性”表示仿射层，“sigm”表示 sigmoid 非线性，“100d”和“200d”分别表示 100 维和 200 维。沿用原图记号， $\sigma_{q,\ell}$ 与 $\sigma_{p,\ell}$ 在这些图中表示对角协方差的对角元素。




活跃度统计量的分布

第 5.2 节定义了活跃度统计量 $A_u = \text{Cov}_{\mathbf{x}}(\mathbb{E}_{u \sim q(u|\mathbf{x})}[u])$ ，并选取 10^{-2} 为判断单元是否活跃的阈值。这样做的一个依据是，在我们考察的所有情形中，该统计量的分布均由两个相距很远的峰组成。下图给出单随机层 VAE 中 $\log A_u$ 的直方图：



后验分布可视化

下面展示潜在空间为二维的 VAE 与 IWAE 模型的真实后验和近似后验示例。热图表示 6 个训练样本的真实后验分布；底行图像展示这些样本，以及从 $q(\mathbf{h}|\mathbf{x})$ 采样所得的重构。左：VAE。中： $k = 5$ 的 IWAE。右： $k = 50$ 的 IWAE。IWAE 倾向于学习形状更不规则的后验，以及更分散的后验预测。



附录 D

固定二值化 MNIST 的结果

此前多项工作采用了 Larochelle (2011) 定义的固定二值化 MNIST 数据集。我们重复实验，在训练集的 50,000 个样本上训练，并在测试集的 10,000 个样本上评估。除此之外，训练流程和超参数与正文实验相同。表 3 表明，在新的实验设置下，关于 VAE 和 IWAE 相对优劣的结论不变。在这一设置中，我们观察到了明显更严重的过拟合。

随机 层数	k	VAE		IWAE	
		NLL	活跃 单元	NLL	活跃 单元
1	1	88.71	19	88.71	19
	5	88.83	19	87.63	22
	50	89.05	20	87.10	24
2	1	88.08	16+5	88.08	16+5
	5	87.63	17+5	86.17	21+5
	50	87.86	17+6	85.32	24+7

表 3 固定二值化 MNIST 数据集上的密度估计结果与活跃潜在维度数。对于具有两个潜变量层的模型，“ $k_1 + k_2$ ”表示第一层有 k_1 个活跃单元、第二层有 k_2 个活跃单元。随着 k 增加，IWAE 的生成性能有所改善，而 VAE 未表现出一致改善。两层模型的生成性能优于单层模型。

附录 E

生成样本

1 5 2 8 3 4 7 7 9 7	7 4 2 8 2 1 9 7 7 7
5 5 3 0 5 7 4 0 9 4	4 5 2 5 2 7 4 4 4 4
0 0 6 2 7 3 6 1 8 0	4 7 0 2 9 1 4 2 6 3
1 2 4 3 0 5 8 8 5 2	3 2 4 0 4 0 6 6 7 2
5 1 6 0 3 7 8 1 9 6	3 7 4 5 8 4 6 1 9 0
4 1 4 7 9 3 8 2 7 9	8 5 7 4 7 7 5 2 7 9
7 0 2 4 3 0 5 0 8 9	0 9 2 0 3 0 2 5 8 3
2 3 3 0 9 6 4 3 0 4	3 3 2 4 9 3 6 4 8 4
7 0 9 5 3 1 8 5 6 4	0 2 4 2 1 7 1 8 6 3
5 3 7 2 0 6 6 3 4 7	3 2 4 7 7 6 5 0 6 2
1 9 2 2 8 8 5 5 4 2	2 1 3 2 1 5 8 8 1 9
0 7 2 2 6 8 1 6 8 1	5 4 5 3 2 8 1 3 1 2
6 8 5 2 2 5 5 3 2 1	1 5 7 2 8 5 2 5 2 3
1 0 8 9 5 9 9 1 4 4	7 9 8 1 0 1 4 7 1 0
9 4 5 5 8 5 9 1 9 5	9 5 6 2 2 2 3 7 3 0
4 1 3 8 9 8 7 6 1 7	6 6 4 8 1 4 8 9 6 6
7 2 3 4 0 9 2 6 4 1	2 8 0 4 2 7 9 4 2 8
6 0 6 5 7 8 5 4 0 2	9 6 5 1 9 3 9 0 9 9
4 0 8 6 7 4 1 4 7 0	6 5 0 8 1 9 1 0 6 5
4 4 2 0 4 3 0 1 9 8	9 7 5 7 8 4 1 6 5 7

表 4 从 VAE (左列) 和 $k = 50$ 的 IWAE (右列) 模型中随机生成的样本。第一行: 单随机层模型。第二行: 双随机层模型。样本以相应伯努利分布的均值表示。

翻译说明

本译稿依据用户提供的 `arXiv-1509.00519v4.tar.gz` 及对应的 arXiv v4 PDF (2016 年 11 月 7 日)。正文、五个附录、原始图件、四张表和参考文献均予保留，采用翻译技能的蓝色标题中文单栏模板重排。下列已核实问题直接修入正文；本次复核不表示已穷尽原文全部问题。

数学与记号修正

1. 第 2 节式 (1)：原文对隐藏状态作求和，但随后明确采用连续高斯潜变量。译稿将边缘化改为对全部潜变量的积分，并补上 $d\mathbf{h}$ ；离散潜变量时才使用求和。
2. 第 2 节式 (5)：原式左端写作 $\nabla_{\boldsymbol{\theta}} \log \mathbb{E}_q[p/q]$ ，实际是边缘对数似然的梯度，并非所讨论的变分下界梯度。改为 $\nabla_{\boldsymbol{\theta}} \mathbb{E}_q[\log(p/q)]$ ，与式 (3) 及后续重参数化推导一致。正文同时明确求导与期望交换的通常正则条件，以及重要性采样所需的支撑集覆盖条件。
3. 第 3.1 节式 (11)–(13)、(15) 及相关文字：源稿交替使用 $\mathbf{h}(\boldsymbol{\epsilon}, \mathbf{x}, \boldsymbol{\theta})$ 与 $\mathbf{h}(\mathbf{x}, \boldsymbol{\epsilon}, \boldsymbol{\theta})$ 。统一为第 2 节定义的 $\mathbf{h}(\boldsymbol{\epsilon}, \mathbf{x}, \boldsymbol{\theta})$ ；归一化权重分母的求和指标改用 j ，避免与自由指标 i 混用。
4. 定理 1 和附录 A 第三步：仅假设权重有上界，不能从强大数定律直接推出对数的期望收敛。例如，独立权重以相同概率取 0 和 2，则 $\mathbb{E}W = 1$ ，但任何有限 k 下平均权重为零的概率都为正，故 $\mathbb{E} \log M_k = -\infty$ 。译稿采用明确的充分条件 $0 < c \leq W \leq C < \infty$ ，并用 $|\log M_k| \leq \max\{|\log c|, |\log C|\}$ 与有界收敛定理补全证明。此条件是为了给出正确且简洁的陈述，并非收敛所必需的最弱条件；下界及单调性结论不需这一双侧界。
5. 第 3 节与附录 B：原文由取对数及 MAD 上界推断估计量不会有大方差，这一推断不成立。译稿保留正确的 $\text{MAD} \leq 2 + 2\delta$ 推导，补充 $\mathbb{E}|\log \hat{Z}| < \infty$ ，并明确它不控制方差。例如，取非负随机变量 Y 满足 $\mathbb{E}Y < \infty$ 、 $\text{Var}(Y) = \infty$ ，令 $\hat{Z} = e^{-Y}/\mathbb{E}[e^{-Y}]$ ，则 $\mathbb{E}\hat{Z} = 1$ ， $\log \hat{Z}$ 的 MAD 有限而方差无穷。

实验文字与排版修正

第 5.2 节称切换目标实验采用“表现最好的”模型，但表 2 的起始数值对应表 1 的单层 MNIST VAE ($k = 1$ ，NLL 为 86.76) 和 IWAE ($k = 50$ ，NLL 为 84.78)，并非表 1 全部模型中的最佳结果。译稿据表格明确所指模型，表中数据不改。

附录 D 表 3 的图注称 VAE 随样本数增加“略有受益”，但单层 VAE 的 NLL 为 88.71、88.83、89.05，且双层结果也非单调改善。译稿改为“未表现出一致改善”，保留全部原数值。

数学粗体使用 `\bm`，微分 d 用正体；迹算子如出现，使用小写正体 `tr`。原图完整保留，其中嵌入的英文标签不作覆盖重绘；可编辑网络图的文字标签已汉化。参考文献保留原文书目信息及作者年引用关系。拼写错误与表格多余空列在翻译排版时更正，不改变内容。