

基于 Brenier 最优输运映射的非线性滤波

Mohammad Al-Jarrah* Niyizhen Jin[†] Bamdad Hosseini[†]
Amirhossein Taghvaei*

arXiv:2310.13886v3 (中文译稿)

摘要

本文研究非线性滤波问题，即在给定带噪部分观测历史的条件下，计算随机动力系统状态的条件分布。在似然退化或状态维数很高时，传统序贯重要性重采样（SIR）粒子滤波器会受到权重退化这一根本限制。本文探索一种替代方法：估计从当前状态先验分布到下一时刻后验分布的 Brenier 最优输运（OT）映射。不同于 SIR 粒子滤波器，OT 表述不需要似然函数的解析形式；它还允许利用神经网络的逼近能力刻画复杂多峰分布，并采用随机优化算法提升可扩展性。本文通过大量数值实验将 OT 方法与 SIR 粒子滤波器和集合卡尔曼滤波器比较，从样本效率、高维可扩展性以及捕获复杂多峰分布的能力等方面评估其性能。

译注：本文按 arXiv:2310.13886v3 官方源码完整翻译；公式、图表、算法、编号与文献键均依原稿保留，仅将版式统一为本项目既有的中文单栏样式。

1 引言

本文关注离散时间非线性滤波问题的数值解法，尤其关注目标分布高度非高斯且呈多峰的情形。为表述滤波问题，考虑两个随机过程：(i) 隐马尔可夫过程 $\{X_t\}_{t=0}^{\infty}$ ，表示动力系统的状态；(ii) 观测随机过程 $\{Y_t\}_{t=1}^{\infty}$ ，表示传感数据。假定状态过程与观测过程满足

$$X_t \sim a(\cdot | X_{t-1}), \quad X_0 \sim \pi_0, \quad (1a)$$

$$Y_t \sim h(\cdot | X_t), \quad (1b)$$

其中 $a(\cdot | \cdot)$ 和 $h(\cdot | \cdot)$ 分别表示在给定 X_t 时 X_{t+1} 与 Y_t 的条件概率核， π_0 表示初始状态 X_0 的概率分布。滤波问题旨在计算给定观测历史 $\mathcal{Y}_t = \{Y_1, Y_2, \dots, Y_t\}$ 时隐状态 X_t 的条件概率分布，记作

$$\pi_t(\cdot) := \mathbb{P}(X_t \in \cdot | \mathcal{Y}_t), \quad t = 1, 2, \dots \quad (1c)$$

*美国华盛顿大学航空航天系, Seattle. 通信邮箱: mohd9485@uw.edu。

[†]美国华盛顿大学应用数学系, Seattle. 通信邮箱: njin2@uw.edu。

条件分布 π_t 也称为后验或信念。

在一般的非线性、非高斯设定下，后验没有显式解析解，因此必须设计数值方法来逼近它。标准序贯重要性重采样 (SIR) 粒子滤波器 (PF) 以粒子的加权经验分布 $\sum_{i=1}^N w_t^i \delta_{X_t^i}$ 逼近后验 π_t [25, 17]，粒子位置与权重按下式更新：

$$\text{(传播)} \quad X_t^i \stackrel{\text{i.i.d.}}{\sim} \sum_{j=1}^N w_{t-1}^j a(\cdot | X_{t-1}^j), \quad (2a)$$

$$\text{(条件化)} \quad w_t^i = \frac{h(Y_t | X_t^i)}{\sum_{j=1}^N h(Y_t | X_t^j)}. \quad (2b)$$

传播步骤先按动力学模型 (1a) 模拟，随后执行重采样¹；条件化步骤则依据观测模型 (1b) 实施贝叶斯法则。

当 $N \rightarrow \infty$ 时，SIR 粒子滤波器给出滤波问题的精确解 [16]。然而，它受到维数灾难 (COD) 的影响：随着状态和观测维数增加，似然会退化并集中到很小的支撑上，使大多数权重变为零。这就是粒子退化，只有让粒子数随维数指数增长才能避免 [6, 4, 36]。这仍是活跃研究方向，参见 [48] 及其中的文献。

维数灾难促使人们开发以耦合或输运步骤替代 SIR 条件化步骤的算法，参见 [14, 12, 37, 50, 18, 38, 15, 52, 31, 32, 39, 34, 46, 9]，近期综述见 [44, 47]，更详细的比较见第 4 节。此时以后验的等权粒子分布 $\frac{1}{N} \sum_{i=1}^N \delta_{X_t^i}$ 作为逼近，并采用一般的粒子更新律

$$\text{(传播)} \quad X_{t|t-1}^i \sim a(\cdot | X_{t-1}^i), \quad (3a)$$

$$\text{(条件化)} \quad X_t^i = T_t(X_{t|t-1}^i, Y_t). \quad (3b)$$

其中 $T_t(\cdot, Y_t)$ 表示从 (先验) 分布 $\mathbb{P}(X_t \in \cdot | \mathcal{Y}_{t-1})$ 到后验分布 $\mathbb{P}(X_t \in \cdot | \mathcal{Y}_t)$ 的 (可能为随机的) 输运映射。

本文开发逼近上述输运映射的算法。具体而言，我们利用近期提出的 OT 方法 [45, 1]，把寻找 T_t 表述为极大—极小随机优化问题 (见式 (11) 与 (10))。该问题仅涉及粒子 $X_{t|t-1}^i$ 及其关联观测 $Y_{t|t-1}^i \sim h(\cdot | X_{t|t-1}^i)$, $i = 1, \dots, N$ 。如图 2 所示，映射 T 由残差神经网络表示，并用随机优化算法训练 (详见算法 3)。该方法结合了条件模拟中的块三角输运 [29, 35, 42, 43] 与估计 OT 映射的极小—极大表述 [30, 21, 41]。它有两个鲜明特点：(i) 可以在完全无似然、仅依靠模拟的设定下实现，因为只需从似然模型采样而不需其解析式；(ii) 可以用神经网络表示输运映射，从而捕获非高斯多峰分布，并使用可随粒子数扩展的随机优化算法。图 1 给出了 OT 与 SIR 粒子滤波器的示例比较。

本文贡献有两点：(1) 对 OT 方法进行理论分析，重点给出命题 2.3 和命题 2.4 所述的一致性与稳定性结果；还在命题 2.7 中针对滤波器的一次条件化步骤，给出 OT 与 SIR 的初步误差比较。(2) 第 3 节给出覆盖玩具示例、Lorenz 基准模型和高维动态图像修复问题的大量数值实验，从样本效率、高维可扩展性以及捕获复杂多峰分布的能力等方面，将 OT 与 SIR 和集合卡尔曼滤波器 (EnKF) 进行比较。

¹实践中通常只在权重方差变大时进行重采样。




图 1. 第 3.1 节静态模型上 OT 与 SIR 的比较。OT 方法求解式 (11) 得到 OT 映射，并以该映射推送先验，从而捕获双峰后验；而似然退化使只有少数 SIR 权重达到 1 的量级，因此 SIR 仅捕获一个峰。

2 最优输运方法

2.1 精确滤波器

在讨论输运映射与 OT 表述之前，先回顾精确滤波器。下文假设 $X_t \in \mathbb{R}^n$ 、 $Y_t \in \mathbb{R}^m$ 。后验分布 (1c) 具有递归更新律，这是设计滤波算法的基础。为表述该递推，引入算子

$$(\text{传播}) \quad \pi \mapsto \mathcal{A}\pi := \int_{\mathbb{R}^n} a(\cdot | x) \pi(x) dx, \quad (4a)$$

$$(\text{条件化}) \quad \pi \mapsto \mathcal{B}_y(\pi) := \frac{h(y | \cdot) \pi(\cdot)}{\int_{\mathbb{R}^n} h(y | x) \pi(x) dx}. \quad (4b)$$

第一个算子按动力学模型 (1a) 更新状态分布，第二个算子依据观测模型 (1b) 实施贝叶斯条件化。于是，精确后验 $\pi_t := \mathbb{P}(X_t \in \cdot | \mathcal{Y}_t)$ 满足序贯更新律 [10]

$$\pi_{t|t-1} = \mathcal{A}\pi_{t-1}, \quad \pi_t = \mathcal{B}_{Y_t}(\pi_{t|t-1}), \quad (4c)$$

其中 $\pi_{t|t-1}(\cdot) := \mathbb{P}(X_t \in \cdot | \mathcal{Y}_{t-1})$ 表示尚未用当前观测 Y_t 条件化时 X_t 的分布。

2.2 利用输运映射进行条件化

输运或耦合方法用粒子集 $\{X_t^i\}_{i=1}^N$ 的经验分布逼近后验 π_t ，粒子按式 (3a)–(3b) 模拟。尽管式中未显式写出，条件化步骤所用的输运映射 T_t 依赖粒子的经验分布，因此式 (3) 表示一个相互作用粒子系统。

我们在平均场极限 ($N = \infty$) 下研究 T_t 的设计。此时假设所有粒子都依照同一平均场分布 π_t

独立同分布。其更新律可写为

$$\bar{\pi}_{t|t-1} = \mathcal{A}\bar{\pi}_{t-1}, \quad \bar{\pi}_t = T_t(\cdot, Y_t)_{\#} \bar{\pi}_{t|t-1}, \quad (5)$$

其中 $\#$ 表示推前算子。应当设计 T_t ，使所有 $t \geq 0$ 上都有 $\bar{\pi}_t = \pi_t$ 。比较式 (5) 与 (4c)，得到如下通用设计问题：

问题：对任意概率分布 π ，寻找映射 T ，使

$$T(\cdot, y)_{\#} \pi = \mathcal{B}_y(\pi), \quad \forall y. \quad (6)$$

我们把这一过程称为利用输运映射进行条件化。下面给出两个说明性例子。

例 2.1 (无噪观测). 设 $X \sim \pi$ 、 $Y = h(X)$ ，其中 h 可逆。条件分布 $\mathcal{B}_y(\pi) = \delta_{h^{-1}(y)}$ 可直接由输运映射 $T(x, y) = h^{-1}(y)$ 表示。

例 2.2 (高斯情形). 设 $X \sim \pi$ 为高斯变量，观测 $Y \sim h(\cdot | X)$ 对应带加性高斯噪声的线性观测模型，即 X, Y 联合高斯。此时条件分布 $\mathcal{B}_y(\pi)$ 为 $N(\mu, \Sigma)$ ，其中

$$\begin{aligned} \mu &= \mathbb{E}[X] + K(y - \mathbb{E}[Y]), \\ \Sigma &= \text{Cov}(X) - \text{Cov}(X, Y) \text{Cov}(Y)^{-1} \text{Cov}(Y, X), \end{aligned}$$

且 $K = \text{Cov}(X, Y) \text{Cov}(Y)^{-1}$ 。随机映射

$$X \mapsto X + K(y - Y) \quad (7)$$

对任意观测值 y 都将 π 输运到 $\mathcal{B}_y(\pi)$ 。这是因为 $X + K(y - Y)$ 是与 $N(\mu, \Sigma)$ 具有相同均值和协方差的高斯随机变量。式 (7) 正是 EnKF 算法的基础，参见 [20, 5, 9]。

一致性条件 (6) 并不能唯一确定 T 。下一小节把寻找有效 T 的问题表述为 OT 问题，并给出本文数值方法所依赖的随机优化形式。

2.3 OT 表述

设 $X \sim \pi$ 、 $Y \sim h(\cdot | X)$ ，并令 $\bar{X} \sim \pi$ 为 X 的独立副本。记 (X, Y) 的联合分布为 $P_{X,Y}$ ，边缘分布为 P_X, P_Y 。条件 (6) 亦即几乎处处成立的 $T(\cdot, y)_{\#} P_X = P_{X|Y}(\cdot | y)$ ，它等价于

$$(T(\bar{X}, Y), Y) \sim P_{X,Y}. \quad (8a)$$

证明见附录 B.1 和 [29, 定理 2.4]。为从满足式 (8a) 的映射中选出唯一一个，考虑（条件）Monge 问题

$$\begin{aligned} \min_{T \in \mathcal{M}(P_X \otimes P_Y)} \quad & \mathbb{E}[c(T(\bar{X}, Y), \bar{X})] \\ \text{s.t.} \quad & \text{式 (8a) 成立,} \end{aligned} \quad (8b)$$

其中 $c(x, x') = \frac{1}{2}\|x - x'\|^2$, $\mathcal{M}(P_X \otimes P_Y)$ 是所有 $P_X \otimes P_Y$ 可测的映射 $\mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^n$ 。式 (8b) 可视为独立耦合 $(\bar{X}, Y) \sim P_X \otimes P_Y$ 与联合分布 $(X, Y) \sim P_{X,Y}$ 之间的 Monge 问题, 其中输运映射受限为块三角形形式 $(x, y) \mapsto (T(x, y), y)$ 。

利用 Kantorovich 对偶性及 c -凹函数的定义², Monge 问题 (8b) 化为

$$\max_{f \in c\text{-Concave}_x} \min_{T \in \mathcal{M}(P_X \otimes P_Y)} J(f, T), \quad (8c)$$

其中

$$J(f, T) = \mathbb{E} \left[f(X, Y) - f(T(\bar{X}, Y), Y) + c(T(\bar{X}, Y), \bar{X}) \right].$$

集合 $c\text{-Concave}_x$ 包含从 $\mathbb{R}^n \times \mathbb{R}^m$ 到 $\mathbb{R}$ 且处处关于第一变量 c -凹的函数。标准 OT 情形下极大—极小表述的严格论证见附录 A.3 及 [30, 41]。下面给出其在条件情形下的推广。

命题 2.3. 假设 π 关于 Lebesgue 测度绝对连续, 其支撑集 $\mathcal{X}$ 为凸集; 对所有 y , $\mathcal{B}_y(\pi)$ 关于 Lebesgue 测度具有密度; 且 $\mathbb{E}[\|X\|^2] < \infty$ 。则优化问题 (8c) 存在唯一解对 $(\bar{f}, \bar{T})$ ($\bar{f}$ 相差加性常数视为等价), 而且几乎处处的 y 上, $\bar{T}(\cdot, y)$ 是从 π 到 $\mathcal{B}_y(\pi)$ 的 OT 映射。

证明概要. 直接应用 [11] 的定理 2.3(iii) 以及标准 OT 情形极大—极小表述的命题 A.3 即得; 详见附录 B.2. $\square$

下面考虑未能精确求解极大—极小问题 (8c) 的情形, 并用最优性间隙界定计算所得 OT 映射的误差。对函数对 (f, T) , 令

$$\begin{aligned} \epsilon(f, T) &:= J(f, T) - \min_S J(f, S) \\ &\quad + \max_g \min_S J(g, S) - \min_S J(f, S) \end{aligned} \quad (9)$$

为极大—极小问题的总最优性间隙。下面的结果可看作在 [41, 定理 4.3] 和 [30, 定理 3.6] 基础上加入观测变量 Y 后的推广, 证明见附录 B.3。

命题 2.4. 考虑命题 2.3 的设定, 最优解对为 $(\bar{f}, \bar{T})$ 。令 (f, T) 为最优性间隙是 $\epsilon(f, T)$ 的任意可能非最优解对。假设对所有 y , 映射 $x \mapsto \frac{1}{2}\|x\|^2 - f(x, y)$ 关于 x 是 α -强凸的。则

$$\mathbb{E}[\|T(\bar{X}, Y) - \bar{T}(\bar{X}, Y)\|^2] \leq \frac{4}{\alpha} \epsilon(f, T).$$

2.4 经验逼近

为数值求解 (8c), 用样本把目标 $J(f, T)$ 经验逼近为

$$\begin{aligned} J^{(N)}(f, T) &:= \frac{1}{N} \sum_{i=1}^N [f(X^i, Y^i) + \frac{1}{2}\|T(\bar{X}^i, Y^i) - X^i\|^2 \\ &\quad - f(T(\bar{X}^i, Y^i), Y^i)], \end{aligned} \quad (10)$$

²在平方损失 c 下, f 为 c -凹函数, 当且仅当 $\frac{1}{2}\|\cdot\|^2 - f$ 为凸函数。




图 2. 所提算法中函数类 $\mathcal{F}$ 与 $\mathcal{T}$ 的神经网络架构。

其中 $X^i, \bar{X}^i \stackrel{\text{i.i.d.}}{\sim} \pi$ 且 $Y^i \sim h(\cdot | X^i)$ 。在滤波问题中, $\{X^i\}_{i=1}^N$ 由粒子 $\{X_{t|t-1}^i\}_{i=1}^N$ 构造, 而 $\{\bar{X}^i\}_{i=1}^N$ 可通过对同一集合进行独立随机置换得到, 由此得到附录 C 中的算法 3。函数 f 与映射 T 分别由参数函数类 $\mathcal{F}$ 与 $\mathcal{T}$ 表示, 于是优化问题为

$$\max_{f \in \mathcal{F}} \min_{T \in \mathcal{T}} J^{(N)}(f, T). \quad (11)$$

本文建议把两个函数空间均取为神经网络类, 架构如图 2 所示, 更多细节见附录 C。

注 2.5. 我们对 $\mathcal{F}$ 的选择没有强制 $f(x, y)$ 关于 x 为 c -凹。这是因为用输入凸网络等方式 [3, 8] 对神经网络施加凸性约束在实践中存在局限。不过, 若计算得到的 f 碰巧是 c -Concave _{x} (可事后检查), 命题 2.4 仍然适用。第 3.1 节给出定性与定量结果, 衡量特定示例中 $\frac{1}{2}\|x\|^2 - f(x, y)$ 的凸性以及映射 T 的单调性。

注 2.6. 可将所提计算过程推广到 Riemann 流形: 以测地距离平方作为代价 c , 并把 T 建模为参数化向量场的指数映射, 参见 [26]。

2.5 与 SIR 的比较

为了比较 OT 与 SIR, 在 (可能随机的) 概率测度 μ, ν 上采用对偶有界 Lipschitz 度量

$$d(\mu, \nu) := \sup_{g \in \mathcal{G}} \sqrt{\mathbb{E} \left| \int g d\mu - \int g d\nu \right|^2},$$

其中 $\mathcal{G}$ 是绝对值不超过 1 且 Lipschitz 常数不超过 1 的函数空间。

对任意概率分布 π , SIR 与 OT 以不同方式逼近条件分布 $\mathcal{B}_y(\pi)$ 。SIR 的后验逼近为

$$\pi^{(\text{SIR})} := \frac{\sum_{i=1}^N h(y | X^i) \delta_{X^i}}{\sum_{i=1}^N h(y | X^i)} = \mathcal{B}_y(S^{(N)}(\pi)), \quad (12a)$$

其中 $X^i \stackrel{\text{i.i.d.}}{\sim} \pi$, 采样算子为 $\pi \mapsto S^{(N)}\pi := \frac{1}{N} \sum_{i=1}^N \delta_{X^i}$ 。另一方面, OT 通过数值求解 (11) 逼近后验。若 $(\hat{f}, \hat{T})$ 为其解, 则

$$\pi^{(\text{OT})} := \hat{T}(\cdot, y)_{\#} \pi. \quad (12b)$$

下面分析其逼近误差。




图 3. 第 3.1 节静态示例的数值结果。(a) 左上: 先验 P_X 的样本 $\{X^i\}_{i=1}^N$; 左下: 联合分布 P_{XY} 的样本 $\{(X^i, Y^i)\}_{i=1}^N$ 与输运样本 $\{(T(X^{\sigma_i}, Y^i), Y^i)\}_{i=1}^N$ 的比较; 其余面板: 不同 N 和三种算法在 $Y = 1$ 时的输运样本。(b) 与 (a) 相同, 但 λ_w 更小。

命题 2.7. 设 $X \sim \pi$ 、 $Y \sim h(\cdot | X)$, 并用上述 SIR 与 OT 方法逼近后验 $\mathcal{B}_Y(\pi)$ 。则

$$\liminf_{N \rightarrow \infty} \sqrt{N} d(\pi^{(\text{SIR})}, \mathcal{B}_Y(\pi)) \geq \sup_{g \in \mathcal{G}} \sqrt{V_h(g)}, \quad (13a)$$

$$d(\pi^{(\text{OT})}, \mathcal{B}_Y(\pi)) \leq \sqrt{\frac{4}{\alpha} \epsilon(\hat{f}, \hat{T})}, \quad (13b)$$

其中 $V_h(g) := \mathbb{E}[\bar{h}(Y | \bar{X})^2 (g(\bar{X}) - \mathbb{E}[g(X) | Y])^2]$, $\bar{h}(x | y) := h(x | y) / \int h(x' | y) d\pi(x')$, $\bar{X}$ 是 X 的独立副本, α 是 $x \mapsto \frac{1}{2} \|x\|^2 - \hat{f}(x, y)$ 的强凸常数, $\epsilon(\hat{f}, \hat{T})$ 是式 (9) 中该解对的最优性间隙。

证明概要. 下界 (13a) 来自重要性采样的中心极限定理 [10, 定理 9.1.8]; 上界 (13b) 来自命题 2.4 和度量 d 的定义。详见附录 B.4。□

考虑特例: $X = [X(1), \dots, X(n)]$ 和 $Y = [Y(1), \dots, Y(n)]$ 均为 n 维且各分量独立同分布。当 N 足够大时, SIR 误差满足

$$d(\pi^{(\text{SIR})}, \mathcal{B}_Y(\pi)) \geq \frac{C\gamma^n}{\sqrt{N}},$$

其中 C 为常数, $\gamma := \mathbb{E}[\bar{h}(Y(1) | \bar{X}(1))^2] > 1$ 。实际通常利用空间相关性或衰减等问题特性规避维数灾难, 参见 [36, 48]。

OT 上界 (13b) 依赖最优性间隙 $\epsilon(\hat{f}, \hat{T})$, 原则上可分为偏差项与方差项。偏差项体现函数类 $\mathcal{F}, \mathcal{T}$ 相对问题复杂度的表达能力; 方差项对应目标函数经验逼近带来的统计泛化误差。预期方差项按 $O(1/\sqrt{N})$ 增长, 其比例常数依赖函数类复杂度而与维数无关。若不对问题作额外假设, OT 原则上也可能遭遇维数灾难; 但相较 SIR, 它提供了更灵活的设计方法, 便于利用特定问题的结构与正则性。




图 4. 动态示例 15 的数值结果。左上图分别给出 EnKF、OT 与 SIR 粒子 $\{X_t^1, \dots, X_t^N\}$ 的轨迹以及真实状态 X_t ；右上图给出相对于精确条件分布的 MMD；下方两图给出 MMD 随维数和粒子数的变化。

3 数值结果

我们通过多组数值实验比较 OT、EnKF 与 SIR 的性能。OT 算法 3 用图 2 所示神经网络表示 f, T ，并求解式 (3) 与 (11)。网络权重通过 Adam 优化器执行梯度上升—下降来学习。由于相邻时刻的 OT 映射预期变化不大，为降低计算成本，优化迭代次数随时间递减。三种算法的计算成本与细节以及更多数值结果见附录 C。复现实验的 Python 代码已在线公开³。

³<https://github.com/Mohd9485/Filtering-with-Optimal-Transport>

3.1 双峰静态示例

第一个数值实验是概念验证，用于展示似然退化时 OT 的样本效率。考虑高斯隐变量 $X \sim N(0, I_n)$ 在给定观测

$$Y = \frac{1}{2}X \odot X + \lambda_w W, \quad W \sim N(0, I_n) \quad (14)$$

时的条件分布，其中 $\odot$ 表示逐元素 (Hadamard) 乘积。该模型特意选来产生双峰后验。由于 $n = 1$ 时 OT 与 SIR 差异不显著，本文只给出 $n = 2$ 的结果。

图 3a 首先给出噪声标准差 $\lambda_w = 0.4$ 的结果。左上图为高斯先验的初始粒子；左下图将块三角映射 $S(x, y) = (T(x, y), y)$ 对 $P_X \otimes P_Y$ 样本的推前与 P_{XY} 样本比较，从而验证该映射满足一致性条件 (8a)。随后固定观测 $Y = 1$ (虚线所示)，比较输运粒子的直方图与精确条件密度。OT 与 SIR 均能捕获双峰后验，而 EnKF 因始终采用高斯逼近而表现不足。

图 3b 将噪声标准差降至 $\lambda_w = 0.04$ ，后验因而更加退化。即使在这一低维情形，SIR 的权重退化也十分明显：粒子全部坍缩到一个峰；OT 仍能捕获双峰后验。该模型的更多结果见附录 C.2。

图 5 还给出固定 $y = 1$ 的一维情形中，学习到的函数 $\frac{1}{2}\|x\|_2^2 - \hat{f}(x, y)$ 和映射 $\hat{T}(x, y)$ 随 x 的变化。前者并非处处凸，尤其在后验概率较小的区域；后者则似乎处处单调。为量化所有 y 上 $x \mapsto \hat{T}(x, y)$ 的单调程度，采用 10^5 个样本的 Monte Carlo 方法估计

$$\begin{aligned} \mathbb{E}_{(X, X', Y) \sim P_X \otimes P_X \otimes P_Y} [\mathbf{1}_{\varrho(\hat{T}(\cdot, Y), X, X') \leq 0}] &\approx 0.0012, \\ \mathbb{E}_{(X, X', Y) \sim P_X \otimes P_X \otimes P_Y} [\varrho(\hat{T}(\cdot, Y), X, X')] &\approx 0.88, \end{aligned}$$

其中，对任意 $S: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 与 $x, x' \in \mathbb{R}^n$ ，定义

$$\varrho(S, x, x') := \frac{(S(x) - S(x'))^\top (x - x')}{\|x - x'\|^2}.$$

若 S 单调，则所有 x, x' 上 $\varrho(S, x, x') \geq 0$ ；若 S 是某个 α -强凸函数的梯度，则 $\varrho(S, x, x') \geq \alpha$ 。第一项表明映射仅在一个小概率集合上非单调，第二项表明平均意义下的“单调程度”为正。

我们还通过考察梯度 $F(x, y) := x - \nabla_x \hat{f}(x, y)$ 的单调性，以类似方式量化 $\frac{1}{2}\|x\|_2^2 - \hat{f}(x, y)$ 的凸性⁴。Monte Carlo 方法得到的相应数值为 0.033 和 1.57，说明该函数在后验测度下的一个小概率集合上非凸。这一经验观察提示，未来可研究把命题 2.4 的凸性假设放宽为：只需在后验测度下的大测度集合上凸。

3.2 双峰动态示例

考虑前述示例的动态版本：

$$X_t = (1 - \alpha)X_{t-1} + 2\lambda V_t, \quad X_0 \sim \mathcal{N}(0, I_n), \quad (15a)$$

$$Y_t = X_t \odot X_t + \lambda W_t, \quad (15b)$$

⁴由于使用 ReLU 激活时 $\hat{f}(x, y)$ 不可微，不能直接检查 Hessian 矩阵的正定性。




图 5. 第 3.1 节双峰静态示例的数值结果。左图给出函数 $\frac{1}{2}x^2 - \hat{f}(x, 1)$ 与条件分布 $P_{X|Y=1}$ ；右图给出映射 $\hat{T}(x, 1)$ 与先验分布 P_X 。




图 6. Lorenz 63 示例的数值结果。左图给出真实状态未观测分量与粒子的轨迹，右图比较 MSE。

其中 $\{V_t, W_t\}_{t=1}^\infty$ 是标准高斯随机变量的独立同分布序列， $\alpha = 0.1$ 、 $\lambda = \sqrt{0.1}$ 。对 Y_t 的选择会使每个时刻的后验 π_t 均为双峰。

图 4(a) 给出三种算法的粒子轨迹，黑色虚线表示真实状态 X_t 。OT 产生双峰粒子分布，EnKF 给出高斯逼近，而 SIR 出现权重坍塌，并在 $t \in [1, 2] \cup [3, 4.5]$ 内遗漏一个峰。图 4(b) 比较各算法粒子分布与精确后验之间的最大均值差异 (MMD)，核函数选择等细节见附录 C.3。精确后验没有显式形式，故以 $N = 10^5$ 的 SIR 模拟来逼近。定量结果印证了图 (a) 的定性观察：OT 后验随时间更好地捕获真实后验。

我们还考察维数 n 和粒子数 N 对三种算法的影响，结果分别见图 4(c)、(d)。相较 SIR，EnKF 与 OT 随维数扩展得更好；但随着粒子数增加，EnKF 误差因其高斯偏差而保持不变，SIR 与 OT 的逼近误差则会下降。





图 7. MNIST 静态示例。左列依次为真实图像、已观测部分与观测窗口（红框）；其后三列为各算法最终时刻随机选取的 16 个粒子。



(a) OT 方法的 16 个粒子。

(b) 数字分布。

图 8. MNIST 静态示例的更多结果。(a) 首行是截至各时刻的累计观测，红线以下各行为 OT 的 16 个粒子，对应图 7 中同一批粒子。(b) 利用高精度 MNIST 分类器评估三种算法粒子所生成数字的直方图随时间的变化。

3.3 Lorenz 63 模型

Lorenz 63 三维模型经常作为非线性滤波算法的基准，其定义见附录 C.4。状态 X_t 为三维，观测 Y_t 为二维，由状态第一、第三分量的带噪测量组成。

图 6 左侧给出真实状态第二分量与粒子的轨迹。OT 和 EnKF 更快收敛到真实状态，但 EnKF 方差较大；右侧状态估计均方误差 (MSE) 进一步验证了这一现象。图中给出 OT 的两种变体：使用或不使用图 2 架构中的 EnKF 模块。加入 EnKF 模块可改善滤波性能，而我们的计算观察表明，移除该模块时数值稳定性更好。

我们还在另一滤波基准 Lorenz 96 模型上进行了实验，见附录 C.5。结果与 Lorenz 63 一致：EnKF 与 OT 优于 SIR，且二者性能相近。

3.4 MNIST 静态图像修复

为评估 OT 的高维可扩展性, 考虑在一个用于生成 MNIST 数字的生成对抗网络 (GAN) 的 100 维潜空间上计算条件分布 [24]。记生成器为 $G: \mathbb{R}^{100} \rightarrow \mathbb{R}^{28 \times 28}$, 模型为

$$Y_t = h(G(X), c_t) + \sigma W_t, \quad X \sim N(0, I_{100}),$$

其中观测函数 $(z, c) \in \mathbb{R}^{28 \times 28} \times \mathbb{R}^2 \mapsto h(z, c) \in \mathbb{R}^{r \times r}$ 定义为像素窗口 $z[c(1):c(1)+r, c(2):c(2)+r]$ 。窗口角点 c_t 从左到右、从上到下移动, 扫描图像中称为已观测部分的区域。为增加难度, 算法接收的是带噪角点位置。真实图像保持不变, 但为避免粒子坍缩, 向粒子加入了人工高斯噪声。细节见附录 C.6。

图 7 左列给出真实图像、已观测部分及以红框标出的 3×3 观测窗口。在窗口移动的 15 个时刻上运行滤波算法, 其余面板给出各算法最终时刻的 16 个随机粒子。SIR 粒子虽与真实图像相似, 却未能像 OT 那样捕获与观测对应的真实不确定性 (数字 0, 3, 8 的下半部与数字 2 相似)。

图 8a 进一步给出 OT 粒子的演化。首行是截至各时刻的全部已观测部分, 之后 16 行为从逼近条件分布的粒子生成的图像。图 8b 则借助高精度 MNIST 分类器展示各算法粒子生成数字的直方图。SIR 和 EnKF 分别对真实数字是 2 和 0 表现得过度自信; OT 给出更为合理的多峰后验, 集中在 $\{0, 2, 3, 8\}$, 这些数字都是观测数据的自然修复结果。

3.5 MNIST 动态图像修复

在前例中加入 GAN 潜变量的动态更新 $X_{t+1} = (1 - \alpha)X_t + \lambda V_t$, 其中 V_t 为标准高斯变量。观测模型不变, 但采用更大的窗口 $r = 12$, 并把窗口纵坐标固定在底部, 横坐标随机选取。

图 9 可视化了结果。前两行依次展示 $t = 1, 2, \dots, 20$ 各时刻的真实图像和观测区域, 之后各行展示三种算法随机选出的四个粒子; 更多粒子见附录 C.7。结果显示: SIR 在所有时刻均发生粒子坍缩; EnKF 收敛到错误分布; OT 能够逼近每个时刻与观测相关的不确定性。附录 C.7 还给出类似图 8b 的数字直方图, 进一步凸显这些现象。




图 9. MNIST 动态示例。前两行给出各时刻的真实图像与观测，其余各行给出每种方法的前四个粒子，代表该时刻的后验。

4 与基于耦合的方法比较

本节与其他基于耦合的滤波方法作全面比较。粒子流方法 [13, 15] 和反馈粒子滤波器 (FPF) [51, 52] 利用常微分方程或随机微分方程更新粒子位置，使粒子概率密度满足给定偏微分方程 (PDE)。粒子方程包含一个未知向量场，需要通过求解特定 PDE 来逼近。这类算法的主要困难，是在每个时刻逼近该向量场；其时间离散常会变得不稳定，尤其在后验多峰或似然退化时。命题 2 (见 [45]) 说明，本文 OT 方法可视作 FPF 的精确时间离散，因而消除了上述时间离散问题。

集合变换粒子滤波器 [37] 针对给定观测值，通过求解离散 OT 线性规划，把均匀先验变为加权后验。当粒子数 N 增大时，线性规划难以求解；而且，用加权经验分布逼近边缘分布仍受重要性采样粒子滤波器同一根本问题的影响。

文献 [44] 的耦合方法与本文最接近：它同样无需似然，也适合神经网络参数化。主要差异在输运映射的形式。本文寻找从先验到后验的 OT 映射，而 [44] 寻找 Knothe–Rosenblatt 重排。因此，本文方法与 OT 问题的半对偶解联系更紧密，可以利用现有理论结果和计算方法。

本文工作建立在 [45] (下称 TH) 提出的贝叶斯法则变分表述上。TH 考虑

$$\min_f \max_g \mathbb{E}[f(X, Y) - f(\nabla_x g(\bar{X}, Y), Y) + \bar{X}^\top \nabla_x g(\bar{X}, Y)],$$

其中 f, g 均为输入凸神经网络 (ICNN)。我们对该方法的初步实验因 ICNN 架构的限制而未得到令人信服的结果 (见注 2.5)。为解决这一问题，我们作了两项改变：将 $f(x, y)$ 表示为 $\frac{1}{2}\|x\|^2 - \tilde{f}(x, y)$ ，将 $\nabla_x g(x, y)$ 表示为 $T(x, y)$ ，其中 $T, \tilde{f}$ 均为 ResNet；同时在 T 的架构中加入 EnKF 模块，使未经训练的方法至少具有 EnKF 的性能。借助这些改进，我们在玩具问题、基准问题和高维问题上得到

一致且优于传统基线的结果。比较 TH 论文的图 1 与本文图 3、图 11，即可清楚看到计算效果的提升。

5 结论、评述与局限

本文给出了基于 OT 的非线性滤波算法，并以理论和数值结果说明其性能。式 (11) 最优性间隙中偏差与方差项的完整刻画仍在研究中，可借助 Wasserstein 度量下经验测度收敛 [22]、OT 映射估计 [27] 和贝叶斯后验扰动分析 [23] 的现有工具推进。

数值实验表明，在专门构造的多峰分布示例上，OT 表现更好；但其原始计算时间更长，而对于 Lorenz-96 这类后验单峰的非线性滤波问题，EnKF 能给出快速且合理的逼近。OT 的一个计算特点是允许用户灵活设定计算预算：不训练时，OT 算法实施 EnKF；增加预算（更多训练迭代和更复杂的网络）则可提高精度，见附录 C.1。通过细调网络架构、优化超参数，并在第一时刻加入离线训练以作为在线阶段后续时刻的热启动，可进一步改善 OT 的计算效率。近期工作 [2] 沿此方向面向遍历状态与观测动力学提出了新的数据驱动非线性滤波算法：昂贵的离线阶段学习静态条件化输运映射；计算便宜的在线阶段直接使用该映射而不再训练，使在线推断时间可以与传统方法竞争。

致谢

作者感谢审稿人提出建设性的评论和反馈，这些意见帮助改进了本文。Mohammad Al-Jarrah 与 Amirhossein Taghvaei 获美国国家科学基金会（NSF）项目 EPCN-2318977 资助；Niyizhen Jin 与 Bamdad Hosseini 获 NSF 项目 DMS-2208535 资助。作者对上述支持表示感谢。

影响声明

本文对非线性滤波、数据同化与不确定性量化领域有所贡献。它有助于有效量化和评估不确定性，从而支持自主系统安全、可靠地运行。

A 预备知识

本节回顾凸分析与 OT 理论的预备知识。

A.1 凸分析预备知识

下面回顾后文所需的凸分析定义；这些定义可见于多数凸分析教材，例如 [40]。

- **凸共轭**：对函数 $\phi : \mathbb{R}^n \mapsto \mathbb{R} \cup \{\pm\infty\}$ ，其凸共轭 ϕ^* 定义为

$$\phi^*(y) = \sup_{x \in \mathbb{R}^n} (x^\top y - \phi(x)). \quad (16)$$

此外， ϕ 为凸函数，当且仅当存在函数 ψ 使 $\phi = \psi^*$ 。

- **强凸性**：若对任意 $x, y \in \mathbb{R}^n$ 和 $t \in [0, 1]$ ，有

$$\phi(tx + (1-t)y) \leq t\phi(x) + (1-t)\phi(y) - \frac{\alpha}{2}t(1-t)\|x - y\|^2,$$

则称 $\phi : \mathbb{R}^n \mapsto \mathbb{R} \cup \{\pm\infty\}$ 是 α -强凸的。

- **光滑性**：若 ϕ 可微，且对任意 $x, y \in \mathbb{R}^n$ 有

$$\phi(y) \leq \phi(x) + \nabla\phi(x)^\top(y - x) + \frac{\beta}{2}\|x - y\|^2,$$

则称 ϕ 是 β -光滑的。

对于下半连续代价函数 $c : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ ，回顾如下定义。

- **下确界 c -卷积**：函数 $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\pm\infty\}$ 的下确界 c -卷积记作 f^c ，定义为

$$f^c(y) = \inf_{x \in \mathbb{R}^n} [c(x, y) - f(x)]. \quad (17)$$

若存在函数 g 使 $f = g^c$ ，则称 f 为 c -凹函数。

注 A.1. 当 $c(x, y) = \frac{1}{2}\|x - y\|_2^2$ 时， c -凹性与凸性存在如下关系：

$$f \text{ 为 } c\text{-凹函数} \iff \phi = \frac{1}{2}\|\cdot\|^2 - f \text{ 为凸函数.}$$

而且下确界 c -卷积与凸共轭满足

$$\frac{1}{2}\|\cdot\|^2 - f^c = (\frac{1}{2}\|\cdot\|^2 - f)^*.$$

再回顾凸函数的次微分和梯度。

- **次微分与梯度**：凸函数 $\phi : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\pm\infty\}$ 在 $x \in \mathbb{R}^n$ 处的次微分记为 $\partial\phi(x)$ ，它包含所有满足

$$\phi(z) \geq \phi(x) + y^\top(z - x), \quad \forall z \in \mathbb{R}^n$$

的向量 $y \in \mathbb{R}^n$ 。此外， ϕ 在 x 处可微且导数为 $\nabla\phi(x)$ ，当且仅当 $\partial\phi(x) = \{\nabla\phi(x)\}$ 。

凸共轭与次微分的定义蕴含关系 [40, 定理 23.5]

$$\phi(x) + \phi^*(y) = x^\top y \iff x \in \partial\phi^*(y) \iff y \in \partial\phi(x).$$

特别地, 若 ϕ^* 在 y 处可微, 则

$$\phi^*(y) = \nabla\phi^*(y)^\top y - \phi(\nabla\phi^*(y)).$$

平方代价下凸性与 c -凹性的关系还表明, 当 f^c 在 y 处可微时,

$$f^c(y) = c(y, y - \nabla f^c(y)) - f(y - \nabla f^c(y)).$$

最后, 强凸性与光滑性互为对偶 (例如见 [28, 定理 6]):

$$\phi \text{ 为 } \alpha\text{-强凸函数} \iff \phi^* \text{ 为 } \frac{1}{\alpha}\text{-光滑函数}.$$

A.2 OT 理论预备知识

本小节回顾 OT 理论的问题表述和主要结果, 完整论述见 [49]。

给定 $\mathbb{R}^n$ 上两个概率分布 P, Q , Monge 最优输运问题旨在寻找映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$, 使其解

$$\inf_{T \in \mathcal{T}(P, Q)} \mathbb{E}_{Z \sim P}[c(Z, T(Z))], \quad (18)$$

其中 $\mathcal{T}(P, Q) := \{T: \mathbb{R}^n \rightarrow \mathbb{R}^n; T_\# P = Q\}$ 是将 P 推前到 Q 的所有输运映射集合, $c: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ 是有下界的下半连续代价函数。将确定性映射放宽为随机耦合, 得到

$$\inf_{\pi \in \Pi(Q, P)} \mathbb{E}_{(Z', Z) \sim \pi}[c(Z', Z)], \quad (19)$$

其中 $\Pi(Q, P)$ 表示边缘分布分别为 Q, P 的所有联合分布。Kantorovich 的这一松弛把 Monge 问题变为线性规划, 其对偶为

$$\sup_{(f, g) \in \text{Lip}_c} \{\mathcal{J}_{\text{dual}}(f, g) := \mathbb{E}_{Z' \sim Q}[f(Z')] + \mathbb{E}_{Z \sim P}[g(Z)]\}, \quad (20)$$

其中 Lip_c 是满足

$$f(z) + g(z') \leq c(z, z'), \quad \forall z, z' \in \mathbb{R}^n$$

的函数对 (f, g) 集合。

Brenier 的著名结果 [7] 通过直接联系 Kantorovich 对偶问题的解, 建立了 Monge 问题解的存在唯一性。

定理 A.2 ([7]). 考虑代价 $c(z, z') = \|z - z'\|^2/2$ 的 Monge 问题 (18)。假设 P, Q 具有有限二阶矩, 且 P 关于 Lebesgue 测度绝对连续。则 Monge 问题有唯一极小解 $\bar{T}(z) = z - \nabla \bar{f}^c(z)$, 其中 $\bar{f}$ 为 c -凹函数, 且 $(\bar{f}, \bar{f}^c)$ 是 Kantorovich 对偶问题 (20) 的唯一极大解 (相差加性常数视为等价)。

A.3 极大—极小表述

本小节给出 Kantorovich 对偶问题 (20) 的极大—极小表述, 它有利于数值逼近 OT 映射 [30, 41]。先作形式推导, 再给出严格命题。

第一步, 利用定理 A.2, 在对偶问题 (20) 中用 f^c 替代 g , 得到

$$\sup_{f \in c\text{-Concave}} \mathcal{J}_{\text{dual}}(f, f^c),$$

其中 $c\text{-Concave}$ 是 $\mathbb{R}^n$ 上所有 c -凹函数的集合。再由式 (17) 中 f^c 的定义,

$$\begin{aligned} \mathbb{E}_{Z \sim P}[f^c(Z)] &= \mathbb{E}_{Z \sim P} \left[\inf_{z \in \mathbb{R}^n} c(z, Z) - f(z) \right] \\ &= \inf_{T \in \mathcal{M}(P)} \mathbb{E}_{Z \sim P}[c(T(Z), Z) - f(T(Z))], \end{aligned}$$

这里假设存在可测映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$, 使

$$T(Z) = \arg \min_{z \in \mathbb{R}^n} c(Z, z) - f(z), \quad \text{几乎处处.}$$

只要 f^c 可微, 对 $T = \text{Id} - \nabla f^c$ 该假设成立。合并以上两步, Kantorovich 对偶问题写成

$$\sup_{f \in c\text{-concave}} \inf_{T \in \mathcal{M}(P)} \{ \mathcal{J}_{\max\text{-min}}(f, T) := \mathbb{E}_{Z' \sim Q}[f(Z')] \quad (21)$$

$$+ \mathbb{E}_{Z \sim P}[c(T(Z), Z) - f(T(Z))] \}. \quad (22)$$

下面的命题推广了 [30, 定理 3.3], 并将极大—极小问题与原 Kantorovich 问题联系起来。

命题 A.3. 在定理 A.2 的假设下考虑问题 (21)。设 $(\bar{f}, \bar{f}^c)$ 为对偶问题 (20) 的最优解对, $\bar{T} = \text{Id} - \nabla \bar{f}^c$ 为从 P 到 Q 的 OT 映射。则 $(\bar{f}, \bar{T})$ 是问题 (21) 的唯一解对 ($\bar{f}$ 相差加性常数视为等价), 即

$$\sup_{f \in c\text{-concave}} \inf_{T \in \mathcal{M}(P)} \mathcal{J}_{\max\text{-min}}(f, T) = \mathcal{J}_{\max\text{-min}}(\bar{f}, \bar{T}). \quad (23)$$

而且若 $\mathcal{J}_{\max\text{-min}}(\bar{f}, \bar{T}) = \mathcal{J}_{\max\text{-min}}(g, S)$, 则 $g = \bar{f} + \text{常数}$ 且 $S = \bar{T}$ 。

证明. 证明分四步。

步骤 1: 由下确界 c -卷积 (17) 的定义, 对所有 $T \in \mathcal{M}(P)$,

$$f^c(Z) \leq c(T(Z), Z) - f(T(Z)), \quad \text{几乎处处.}$$

对 $Z \sim P$ 取期望, 加上 $\mathbb{E}_{Z' \sim Q}[f(Z')]$, 再对 T 取下确界, 得到

$$\mathcal{J}_{\text{dual}}(f, f^c) \leq \inf_{T \in \mathcal{M}(P)} \mathcal{J}_{\max\text{-min}}(f, T).$$

步骤 2: 对任意 c -凹函数 f , 引入 $f_\epsilon := f - \frac{\epsilon}{2} \|\cdot\|^2$ 。这一变换保证其下确界 c -卷积 f_ϵ^c 几乎处处可微: 令 $\phi_\epsilon := \frac{1}{2} \|\cdot\|^2 - f_\epsilon$, 则 $f_\epsilon^c = \frac{1}{2} \|\cdot\|^2 - \phi_\epsilon^*$; 由于 ϕ_ϵ 为 ϵ -强凸函数, ϕ_ϵ^* 为 $1/\epsilon$ -光滑函数。该正则化称为 Moreau–Yosida 逼近 [33]。由于 f_ϵ^c 可微, $f_\epsilon^c(z)$ 定义中的极小值在唯一点 $z - \nabla f_\epsilon^c(z)$ 取得, 故

$$f_\epsilon^c(Z) = c(Z - \nabla f_\epsilon^c(Z), Z) - f_\epsilon(Z - \nabla f_\epsilon^c(Z)), \quad \text{几乎处处.}$$

利用右端的 $f_\epsilon(z) \leq f(z)$, 得到

$$f_\epsilon^c(Z) \geq c(Z - \nabla f_\epsilon^c(Z), Z) - f(Z - \nabla f_\epsilon^c(Z)).$$

对 $Z \sim P$ 取期望并加上 $\mathbb{E}_{Z' \sim Q}[f(Z')]$, 有

$$\mathcal{J}_{\text{dual}}(f, f_\epsilon^c) \geq \mathcal{J}_{\text{max-min}}(f, \text{Id} - \nabla f_\epsilon^c) \geq \inf_{T \in \mathcal{M}(P)} \mathcal{J}_{\text{max-min}}(f, T).$$

再使用 $\mathbb{E}_Q[f] = \mathbb{E}_Q[f_\epsilon] + \epsilon M$, 其中 $M := \mathbb{E}_Q[\frac{1}{2}\|Z'\|^2] < \infty$, 可得

$$\mathcal{J}_{\text{dual}}(f_\epsilon, f_\epsilon^c) + \epsilon M \geq \inf_{T \in \mathcal{M}(P)} \mathcal{J}_{\text{max-min}}(f, T).$$

步骤 3: 合并前两步,

$$\mathcal{J}_{\text{dual}}(f, f^c) \leq \inf_T \mathcal{J}_{\text{max-min}}(f, T) \leq \mathcal{J}_{\text{dual}}(f_\epsilon, f_\epsilon^c) + \epsilon M.$$

对 $f \in c\text{-Concave}$ 取上确界, 并利用 $(\bar{f}, \bar{f}^c)$ 的对偶最优性, 得到

$$\mathcal{J}_{\text{dual}}(\bar{f}, \bar{f}^c) \leq \sup_f \inf_T \mathcal{J}_{\text{max-min}}(f, T) \leq \mathcal{J}_{\text{dual}}(\bar{f}, \bar{f}^c) + \epsilon M.$$

令 $\epsilon \rightarrow 0$, 即得

$$\sup_f \inf_T \mathcal{J}_{\text{max-min}}(f, T) = \mathcal{J}_{\text{dual}}(\bar{f}, \bar{f}^c).$$

由于 $\bar{f}^c$ 几乎处处可微, 且对 $\bar{T} = \text{Id} - \nabla \bar{f}^c$ 有 $\mathcal{J}_{\text{dual}}(\bar{f}, \bar{f}^c) = \mathcal{J}_{\text{max-min}}(\bar{f}, \bar{T})$, 故式 (23) 得证。

步骤 4: 证明唯一性。设 (g, S) 是另一最优解对, 则

$$\mathcal{J}_{\text{max-min}}(g, S) = \sup_f \inf_T \mathcal{J}_{\text{max-min}}(f, T) = \mathcal{J}_{\text{dual}}(\bar{f}, \bar{f}^c). \quad (24)$$

另一方面, 由前述不等式,

$$\mathcal{J}_{\text{dual}}(g, g^c) \leq \mathcal{J}_{\text{max-min}}(g, S) \leq \mathcal{J}_{\text{dual}}(g, g^c).$$

令 $\epsilon \rightarrow 0$ 并应用单调收敛定理, 得到 $\mathcal{J}_{\text{dual}}(g, g^c) = \mathcal{J}_{\text{max-min}}(g, S)$ 。结合式 (24), $\mathcal{J}_{\text{dual}}(g, g^c) = \mathcal{J}_{\text{dual}}(\bar{f}, \bar{f}^c)$ 。由对偶问题解的唯一性及 $\bar{f}^c$ 的可微性, $g = \bar{f} + \text{const.}$, 且 $S = \text{Id} - \nabla \bar{f}^c = \bar{T}$ 。□

B 理论结果的证明

B.1 一致性条件 (8a) 的论证

一致性条件 (8a) 表明, 对任意有界可测函数 $F: \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$,

$$\mathbb{E}[F(T(\bar{X}, Y), Y)] = \mathbb{E}[F(X, Y)].$$

特别取 $F(x, y) = f(x)g(y)$, 则对任意有界可测函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 和 $g: \mathbb{R}^m \rightarrow \mathbb{R}$,

$$\mathbb{E}[f(T(\bar{X}, Y))g(Y)] = \mathbb{E}[f(X)g(Y)].$$

由条件期望的定义,

$$\mathbb{E}[f(T(\bar{X}, Y)) | Y] = \mathbb{E}[f(X) | Y].$$

最后, 由 $\bar{X}$ 与 Y 独立, 几乎处处的 y 上有

$$\mathbb{E}[f(T(\bar{X}, y))] = \mathbb{E}[f(X) | Y = y].$$

该式对所有有界可测 f 成立, 故 $T(\cdot, y)_{\#}P_X = P_{X|Y=y}$ 对几乎处处的 y 成立。

B.2 命题 2.3 的证明

把式 (8c) 的目标写成

$$J(f, T) = \mathbb{E}[\mathcal{J}_{\max-\min}^Y(f(\cdot, Y), T(\cdot, Y))],$$

其中

$$\mathcal{J}_{\max-\min}^y(g, S) = \mathbb{E}_{X \sim P_{X|Y=y}}[g(X)] + \mathbb{E}_{\bar{X} \sim P_X}[c(S(\bar{X}), \bar{X}) - g(S(\bar{X}))]$$

是在边缘分布 $Q = P_{X|Y=y}$ 、 $P = P_X$ 下式 (21) 的极大—极小目标。由命题 A.3,

$$\sup_{g \in c\text{-Concave}} \inf_{S \in \mathcal{M}(P_X)} \mathcal{J}_{\max-\min}^y(g, S) = \mathcal{J}_{\max-\min}^y(\bar{g}_y, \bar{S}_y),$$

其中唯一解对为 $(\bar{g}_y, \bar{S}_y)$, $\bar{S}_y = \text{Id} - \nabla \bar{g}_y^c$ 是从 P_X 到 $P_{X|Y=y}$ 的 OT 映射。文献 [11] 的定理 2.3⁵ 保证可以对 $\bar{g}_y$ 作可测拼接, 构造

$$\bar{f}(x, y) = \bar{g}_y(x), \quad \bar{T}(x, y) = x - \nabla \bar{g}_y^c(x).$$

拼接所得函数解优化问题 (8c), 而 $\bar{T}(\cdot, y)$ 是从 P_X 到 $P_{X|Y=y}$ 的 OT 映射, 即 $\mathcal{B}_y(\pi) = \bar{T}(\cdot, y)_{\#}\pi$ 。

B.3 命题 2.4 的证明

作变量替换 $\phi(x, y) = \frac{1}{2}\|x\|^2 - f(x, y)$ 。此时 $f \in c\text{-Concave}_x$ 等价于 $\phi \in \text{CVX}_x$, 即 ϕ 关于第一变量 x 凸; 式 (8c) 的目标变为

$$J(f, T) = \mathbb{E}_{X \sim P_X}[\|X\|^2] - L(\phi, T), \tag{25}$$

其中

$$L(\phi, T) := \mathbb{E}_{(X, Y) \sim P_{XY}}[\phi(X, Y)] + \mathbb{E}_{(\bar{X}, Y) \sim P_X \otimes P_Y}[\bar{X}^\top T(\bar{X}, Y) - \phi(T(\bar{X}, Y), Y)].$$

⁵本文的对偶函数 f 与 [11] 中的对偶函数 ϕ 通过 $\phi(x, y) = \frac{1}{2}\|x\|^2 - f(x, y)$ 相联系。

将优化间隙分解为 $\epsilon(f, T) = \tilde{\epsilon}(\phi) + \tilde{\delta}(\phi, T)$, 其中

$$\begin{aligned} J(\bar{f}, \bar{T}) - \min_S J(f, S) &= \max_S L(\phi, S) - L(\bar{\phi}, \bar{T}) =: \tilde{\epsilon}(\phi), \\ J(f, T) - \min_S J(f, S) &= \max_S L(\phi, S) - L(\phi, T) =: \tilde{\delta}(\phi, T), \end{aligned}$$

且 $\bar{\phi}(x, y) = \frac{1}{2}\|x\|^2 - \bar{f}(x, y)$; 这里使用了式 (25)。

命题假设 $\phi(x, y)$ 关于 x 为 α -强凸函数。强凸性与光滑性的对偶性意味着: 对任意 y , $\phi(\cdot, y)$ 的凸共轭 $\phi^*(\cdot, y)$ 关于 x 为 $1/\alpha$ -光滑函数。因此

$$\phi^*(w, y) \leq \phi^*(x, y) + \nabla_x \phi^*(x, y)^\top (w - x) + \frac{1}{2\alpha} \|w - x\|^2 =: h(w, y).$$

由 $\phi^*(w, y) \leq h(w, y)$ 可得 $\phi(w, y) \geq h^*(w, y)$, 进而

$$\phi(w, y) \geq -\phi^*(x, y) + w^\top x + \frac{\alpha}{2} \|w - \nabla_x \phi^*(x, y)\|^2. \quad (26)$$

这个不等式是推导 $\tilde{\delta}(\phi, T)$ 与 $\tilde{\epsilon}(\phi)$ 下界的关键。先用式 (26) 得到

$$\begin{aligned} \tilde{\delta}(\phi, T) &= \max_S L(\phi, S) - L(\phi, T) \\ &= L(\phi, \nabla_x \phi^*) - L(\phi, T) \\ &= \mathbb{E}_{P_X \otimes P_Y} [\phi^*(\bar{X}, Y) - \bar{X}^\top T(\bar{X}, Y) + \phi(T(\bar{X}, Y), Y)] \\ &\geq \frac{\alpha}{2} \mathbb{E}_{P_X \otimes P_Y} [\|T(\bar{X}, Y) - \nabla_x \phi^*(\bar{X}, Y)\|^2], \end{aligned}$$

其中第二、第三个等号来自

$$\sup_{z \in \mathbb{R}^n} \{z^\top x - \phi(z, y)\} = \nabla_x \phi^*(x, y)^\top x - \phi(\nabla_x \phi^*(x, y), y) = \phi^*(x, y). \quad (27)$$

再对 $\tilde{\epsilon}(\phi)$ 建立下界:

$$\begin{aligned} \tilde{\epsilon}(\phi) &\stackrel{(1)}{=} \max_S L(\phi, S) - L(\bar{\phi}, \bar{T}) \\ &\stackrel{(2)}{=} L(\phi, \nabla_x \phi^*) - L(\bar{\phi}, \bar{T}) \\ &\stackrel{(3)}{=} \mathbb{E}_{P_{XY}} [\phi(X, Y) - \bar{\phi}(X, Y)] \\ &\quad + \mathbb{E}_{P_X \otimes P_Y} [\phi^*(\bar{X}, Y) - \bar{X}^\top \bar{T}(\bar{X}, Y) + \bar{\phi}(\bar{T}(\bar{X}, Y), Y)] \\ &\stackrel{(4)}{=} \mathbb{E}_{P_X \otimes P_Y} [\phi(\bar{T}(\bar{X}, Y), Y) + \phi^*(\bar{X}, Y) - \bar{X}^\top \bar{T}(\bar{X}, Y)] \\ &\stackrel{(5)}{\geq} \frac{\alpha}{2} \mathbb{E}_{P_X \otimes P_Y} [\|\bar{T}(\bar{X}, Y) - \nabla_x \phi^*(\bar{X}, Y)\|^2]. \end{aligned}$$

步骤 (2)、(3) 使用式 (27); 步骤 (4) 使用 $(\bar{T}(\bar{X}, Y), Y) \sim P_{XY}$; 步骤 (5) 使用式 (26)。

最后用 $(a + b)^2 \leq 2a^2 + 2b^2$, 得到

$$\begin{aligned} &\mathbb{E}_{P_X \otimes P_Y} [\|T(\bar{X}, Y) - \bar{T}(\bar{X}, Y)\|^2] \\ &\leq 2\mathbb{E}[\|T(\bar{X}, Y) - \nabla_x \phi^*(\bar{X}, Y)\|^2] + 2\mathbb{E}[\|\nabla_x \phi^*(\bar{X}, Y) - \bar{T}(\bar{X}, Y)\|^2] \\ &\leq \frac{4}{\alpha} (\tilde{\delta}(\phi, T) + \tilde{\epsilon}(\phi)) = \frac{4}{\alpha} \epsilon(f, T). \end{aligned}$$

B.4 命题 2.7 的证明

B.4.1 下界 (13a) 的证明

对任意一致有界函数 g , 向 $\int g d\pi^{(SIR)} - \int g d\mathcal{B}_Y(\pi)$ 应用中心极限定理即可得到该界, 例如见 [10, 定理 9.1.8]. 由 $\pi^{(SIR)}$ 与 $\mathcal{B}_Y(\pi)$ 的定义,

$$\begin{aligned} \int g d\pi^{(SIR)} &= \frac{\frac{1}{N} \sum_{i=1}^N h(Y | X^i) g(X^i)}{\frac{1}{N} \sum_{i=1}^N h(Y | X^i)} = \frac{\frac{1}{N} \sum_{i=1}^N \bar{h}(Y | X^i) g(X^i)}{\frac{1}{N} \sum_{i=1}^N \bar{h}(Y | X^i)}, \\ \int g d\mathcal{B}_Y(\pi) &= \mathbb{E}[g(X) | Y], \end{aligned}$$

其中 $\bar{h}(y | x) = h(y | x) / \int h(y | x') d\pi(x')$ 是归一化似然。两式相减并乘以 $\sqrt{N}$, 得到

$$\sqrt{N} \left(\int g d\pi^{(SIR)} - \int g d\mathcal{B}_Y(\pi) \right) = \frac{\frac{1}{N} \sum_{i=1}^N \bar{h}(Y | X^i) (g(X^i) - \mathbb{E}[g(X) | Y])}{\frac{1}{N} \sum_{i=1}^N \bar{h}(Y | X^i)}.$$

对分子应用中心极限定理, 对分母应用大数定律, 可得收敛

$$\sqrt{N} \left(\int g d\pi^{(SIR)} - \int g d\mathcal{B}_Y(\pi) \right) \longrightarrow Z \sim N(0, V_h(g)),$$

其中

$$V_h(g) = \mathbb{E}[\bar{h}(Y | \bar{X})^2 (g(\bar{X}) - \mathbb{E}[g(X) | Y])^2],$$

$\bar{X} \sim \pi$ 为 X 的独立副本。因此

$$\lim_{N \rightarrow \infty} \sqrt{N} \mathbb{E} \left[\left(\int g d\pi^{(SIR)} - \int g d\mathcal{B}_Y(\pi) \right)^2 \right]^{1/2} = \sqrt{V_h(g)}.$$

最后利用度量定义,

$$\begin{aligned} \liminf_{N \rightarrow \infty} \sqrt{N} d(\pi^{(SIR)}, \mathcal{B}_Y(\pi)) &= \liminf_{N \rightarrow \infty} \sup_{g \in \mathcal{G}} \sqrt{N} \mathbb{E} \left[\left(\int g d\pi^{(SIR)} - \int g d\mathcal{B}_Y(\pi) \right)^2 \right]^{1/2} \\ &\geq \sup_{g \in \mathcal{G}} \liminf_{N \rightarrow \infty} \sqrt{N} \mathbb{E} \left[\left(\int g d\pi^{(SIR)} - \int g d\mathcal{B}_Y(\pi) \right)^2 \right]^{1/2} \\ &= \sup_{g \in \mathcal{G}} \sqrt{V_h(g)}. \end{aligned}$$

B.4.2 上界 (13b) 的证明

由命题 2.3 及式 (12b), 分别有 $\mathcal{B}_Y(\pi) = \bar{T}(\cdot, Y)_{\#} \pi$ 与 $\pi^{(OT)} = \hat{T}(\cdot, Y)_{\#} \pi$ 。因此

$$\begin{aligned} d(\pi^{(OT)}, \mathcal{B}_Y(\pi)) &= d(\hat{T}(\cdot, Y)_{\#} \pi, \bar{T}(\cdot, Y)_{\#} \pi) \\ &= \sup_{g \in \mathcal{G}} \mathbb{E} \left[\left(\int g d(\hat{T}(\cdot, Y)_{\#} \pi) - \int g d(\bar{T}(\cdot, Y)_{\#} \pi) \right)^2 \right]^{1/2}. \end{aligned}$$

又因为

$$\begin{aligned}\int g d(\hat{T}(\cdot, Y)_{\#}\pi) &= \mathbb{E}[g(\hat{T}(\bar{X}, Y)) | Y], \\ \int g d(\bar{T}(\cdot, Y)_{\#}\pi) &= \mathbb{E}[g(\bar{T}(\bar{X}, Y)) | Y],\end{aligned}$$

其中 $\bar{X} \sim \pi$ 为 X 的独立副本, 所以

$$d(\pi^{(OT)}, \mathcal{B}_Y(\pi)) = \sup_{g \in \mathcal{G}} \mathbb{E} \left[\left(\mathbb{E}[g(\hat{T}(\bar{X}, Y)) | Y] - \mathbb{E}[g(\bar{T}(\bar{X}, Y)) | Y] \right)^2 \right]^{1/2}.$$

应用 Jensen 不等式, 并利用 g 的 Lipschitz 常数不超过 1,

$$\begin{aligned}d(\pi^{(OT)}, \mathcal{B}_Y(\pi)) &\leq \sup_{g \in \mathcal{G}} \mathbb{E}[(g(\hat{T}(\bar{X}, Y)) - g(\bar{T}(\bar{X}, Y)))^2]^{1/2} \\ &\leq \mathbb{E}[\|\hat{T}(\bar{X}, Y) - \bar{T}(\bar{X}, Y)\|^2]^{1/2}.\end{aligned}$$

最后由命题 2.4, 右端不超过 $\sqrt{\frac{4}{\alpha}} \epsilon(\hat{f}, \hat{T})$, 从而得到上界 (13b)。

C 数值细节与补充结果

数值实验模拟了三种滤波算法: (1) 算法 1 所示的集合卡尔曼滤波器 (EnKF) [19, 9]; (2) 算法 2 所示的序贯重要性重采样 (SIR) [17]; (3) 算法 3 所示的 OT 粒子滤波器 (OTPF)。

实现 OTPF 时, 使用图 2 所示 ResNet 架构表示 f, T 。采用 Adam 优化器, 并针对各示例设置不同学习率, 以内循环迭代数恒为 10 来求解极大-极小问题 (10)。三种算法使用相同的粒子数 N 和初始粒子。模拟 EnKF 时额外采用正则项 $\Gamma = \sigma_w^2 I$, 其中 σ_w 是观测信号噪声水平, I 是单位矩阵。实验使用以下两台设备:

1. MacBook M1 Pro: 8 核 CPU、14 核 GPU、16 GB 统一内存;
2. Mac Studio M2 Max: 12 核 CPU、30 核 GPU、64 GB 统一内存。

C.1 计算时间

各主要示例上三种算法的原始计算时间见表 1。OT 比另外两种算法耗时更长。给出这些结果是为完整展示性能; 本文没有集中优化计算时间。通过仔细选择 f, T 的架构、调整超参数, 并加入离线训练阶段为在线训练热启动, 可降低耗时, 这仍是研究课题。初步尝试中, 我们仅牺牲 1.3% 精度便把 OT 在双峰动态示例上的时间降至 2.9151 秒: 先为初始时刻离线训练 10^4 次, 再用所得 f, T 热启动在线滤波, 并把训练迭代降至 8 次。

为进一步研究计算效率, 我们在第 3.2 节双峰动态示例上, 数值评估 OT 与 SIR 计算时间和滤波精度之间的权衡。实现 OT 时, 算法 3 的外循环次数从 $K_{(1)}^{(out)} = 2^{12} = 4096$ 开始, 按 $K_{(t+1)}^{(out)} = K_{(t)}^{(out)}/2$ 递减, 直到预先设定的终止迭代数 K_s 。

算法 1 集合卡尔曼滤波器 (EnKF)

输入: 初始粒子 $\{X_0^i\}_{i=1}^N \sim \pi_0$, 观测信号 $\{Y_t\}_{t=1}^{t_f}$, $\Gamma \succ 0$, 动力学模型 $a(x | x')$, 观测模型 $h(y | x)$ 。

循环 $t = 1$ 至 t_f **执行**

传播:

循环 $i = 1$ 至 N **执行**

$$X_{t|t-1}^i \sim a(\cdot | X_{t-1}^i)$$

$$Y_t^i \sim h(\cdot | X_{t|t-1}^i)$$

循环结束

条件化:

$$\hat{X}_t = \frac{1}{N} \sum_{i=1}^N X_{t|t-1}^i$$

$$\hat{Y}_t = \frac{1}{N} \sum_{i=1}^N Y_t^i$$

$$C_t^{xy} = \frac{1}{N} \sum_{i=1}^N (X_{t|t-1}^i - \hat{X}_t) \otimes (Y_t^i - \hat{Y}_t)$$

$$C_t^{yy} = \frac{1}{N} \sum_{i=1}^N (Y_t^i - \hat{Y}_t) \otimes (Y_t^i - \hat{Y}_t)$$

$$K_t = C_t^{xy} (C_t^{yy} + \Gamma)^{-1}$$

循环 $i = 1$ 至 N **执行**

$$X_t^i = X_{t|t-1}^i + K_t (Y_t - Y_t^i)$$

循环结束

循环结束

输出: $t = 0, \dots, t_f$ 时的粒子 $\{X_t^i\}_{i=1}^N$ 。

结果见图 10, 滤波精度以相对精确后验的 MMD 衡量。图 (a) 给出随维数 n 增加时 MMD 与计算时间的关系, 图 (b) 给出粒子数 N 变化时的对应关系; OT 给出三种 K_s 的结果。图 (a) 表明, OT 的绝对时间虽然高于 SIR, 但随维数扩展得更好。图 (b) 表明, 增加粒子数可以改善 OT 精度, 却不会显著增加其计算时间; SIR 要达到相同精度则需多得多的粒子。

表 1. EnKF、SIR 与 OTPF 的计算时间 (秒)。

示例	EnKF	SIR	OTPF
双峰动态示例	0.0095	0.0108	34.4555
Lorenz 63 (200 步)	0.0542	0.0605	50.9799
Lorenz 96 (200 步)	0.3029	0.3726	79.7705
MNIST 静态图像修复	0.4577	0.3880	529.8863
MNIST 动态图像修复	0.5373	0.3128	728.8051

算法 2 序贯重要性重采样 (SIR)

输入: 初始粒子 $\{X_0^i\}_{i=1}^N \sim \pi_0$, 观测信号 $\{Y_t\}_{t=1}^{t_f}$, 动力学模型 $a(x | x')$, 观测模型 $h(y | x)$ 。

循环 $t = 1$ 至 t_f **执行**

传播:

循环 $i = 1$ 至 N **执行**

$$X_{t|t-1}^i \sim a(\cdot | X_{t-1}^i)$$

循环结束

条件化:

$$w_t^i = \frac{h(Y_t | X_{t|t-1}^i)}{\sum_{j=1}^N h(Y_t | X_{t|t-1}^j)}$$

$$X_t^i \sim \sum_{j=1}^N w_t^j \delta_{X_{t|t-1}^j}$$

循环结束

输出: $t = 0, \dots, t_f$ 时的粒子 $\{X_t^i\}_{i=1}^N$ 。




图 10. 第 3.2 节示例中 OT 与 SIR 的计算时间评估。左图展示维数增加时 MMD 与计算时间的关系，并按第 C.1 节说明给出 OT 的三种终止迭代数 K_s ；右图展示粒子数变化时的同一关系。

C.2 补充静态示例

考虑观测模型

$$Y = X + \sigma_w W, \quad X \sim \frac{1}{2}N(-1, \sigma^2 I_2) + \frac{1}{2}N(+1, \sigma^2 I_2), \quad (28)$$

其中 $W \sim N(0, I_2)$ 、 $\sigma_w = 0.4$ 。先验分布为双峰，观测模型为线性。不同粒子数下的结果见图 11：OT 同样能够把双峰分布推送为单峰分布；由于 EnKF 对先验采用高斯逼近，它不如另外两种方法。

本例以及第 3.1 节各示例在建模 T 时都未采用 EnKF 模块。使用一个块、宽度为 32、采用 ReLU 激活的 ResNet。Adam 学习率为 10^{-3} ，总迭代数 2×10^4 ，批大小 128。

算法 3 OT 粒子滤波器 (OTPF)

输入: 初始粒子 $\{X_0^i\}_{i=1}^N \sim \pi_0$, 观测信号 $\{Y_t\}_{t=1}^{t_f}$, 动力学与观测模型 $a(x | x'), h(y | x)$, 批大小 bs , f, T 的优化器与学习率, 内循环次数 $K^{(\text{in})}$, 外循环次数序列 $K_t^{(\text{out})}$ 。

初始化: 按图 2 初始化神经网络 f, T 及其权重 θ_f, θ_T 。

循环 $t = 1$ 至 t_f 执行

传播:

循环 $i = 1$ 至 N 执行

$$X_{t|t-1}^i \sim a(\cdot | X_{t-1}^i)$$

$$Y_t^i \sim h(\cdot | X_{t|t-1}^i)$$

循环结束

条件化: 生成随机排列 $\{\sigma_i\}_{i=1}^N$ 。

循环 $k = 1$ 至 $K_t^{(\text{out})}$ 执行

从 $(X_{t|t-1}^i, X_{t|t-1}^{\sigma_i}, Y_t^i)$ 中采样 bs 个粒子。

循环 $j = 1$ 至 $K^{(\text{in})}$ 执行

更新 θ_T , 使下式最小:

$$\frac{1}{bs} \sum_{i=1}^{bs} \left[\frac{1}{2} \|T(X_{t|t-1}^{\sigma_i}, Y_t^i) - X_{t|t-1}^{\sigma_i}\|^2 - f(T(X_{t|t-1}^{\sigma_i}, Y_t^i), Y_t^i) \right]$$

循环结束

更新 θ_f , 使下式最小:

$$\frac{1}{bs} \sum_{i=1}^{bs} \left[-f(X_{t|t-1}^i, Y_t^i) + f(T(X_{t|t-1}^{\sigma_i}, Y_t^i), Y_t^i) \right]$$

循环结束

循环 $i = 1$ 至 N 执行

$$X_t^i = T(X_{t|t-1}^i, Y_t^i)$$

循环结束

循环结束

输出: $t = 0, \dots, t_f$ 时的粒子 $\{X_t^i\}_{i=1}^N$ 。

C.3 补充动态示例

考虑模型

$$X_t = (1 - \alpha)X_{t-1} + 2\lambda V_t, \quad X_0 \sim \mathcal{N}(0, I_n), \quad (29a)$$

$$Y_t = h(X_t) + \lambda W_t, \quad (29b)$$

其中 $\{V_t, W_t\}_{t=1}^\infty$ 为标准高斯变量的独立同分布序列, $\alpha = 0.1$, $\lambda = \sqrt{0.1}$ 。这是示例 15 的推广: 观测函数不再是 $h(x) = x \odot x$, 而取线性形式 $h(x) = x$ 或三次形式 $h(x) = x \odot x \odot x$ 。

f, T 的参数化方式与前文相同, 但在 T 中加入 EnKF 模块并使用两个 ResNet 块。 f, T 优化器的学习率分别为 10^{-3} 和 2×10^{-3} 。总迭代数从 1024 开始, 每个滤波时刻后减半, 直至 64。批大小




图 11. 式 (28) 静态示例的结果。左上：先验 P_X 的样本 $\{X^i\}_{i=1}^N$ ；左下：联合分布 P_{XY} 的样本与输运样本 $\{(T(X^{\sigma_i}, Y^i), Y^i)\}_{i=1}^N$ 的比较；其余面板：三种算法在不同 N 下、 $Y = 1$ 时的输运样本。

为 64，粒子数 $N = 1000$ 。

以粒子经验分布和精确后验之间的 MMD 量化算法性能。为准确逼近真实后验，采用 $N = 10^5$ 的 SIR。对经验分布 $\mu = \frac{1}{N_1} \sum_{i=1}^{N_1} \delta_{U^i}$ 与 $\nu = \frac{1}{N_2} \sum_{i=1}^{N_2} \delta_{V^i}$ ，MMD 为

$$\begin{aligned} \text{MMD}_{\text{emp}}(\mu, \nu) &= \frac{1}{N_1^2} \sum_{i,j=1}^{N_1} k(U^i, U^j) + \frac{1}{N_2^2} \sum_{i,j=1}^{N_2} k(V^i, V^j) \\ &\quad - \frac{2}{N_1 N_2} \sum_{i=1}^{N_1} \sum_{j=1}^{N_2} k(U^i, V^j), \end{aligned} \quad (30)$$

其中 k 是 RBF 核，带宽针对各示例分别选取。

线性与三次观测模型的结果分别见图 12、图 13。在线性高斯设定下 EnKF 优于另两种算法，但在三次观测模型上表现不佳。通过细调和增加训练迭代，可进一步改善 OT。

C.4 Lorenz 63 模型细节与补充结果

考虑 Lorenz 63 模型

$$\begin{aligned} \begin{bmatrix} \dot{X}(1) \\ \dot{X}(2) \\ \dot{X}(3) \end{bmatrix} &= \begin{bmatrix} \sigma(X(2) - X(1)) \\ X(1)(\rho - X(3)) - X(2) \\ X(1)X(2) - \beta X(3) \end{bmatrix}, \quad X_0 \sim \mathcal{N}(\mu_0, \sigma_0^2 I_3), \\ Y_t &= \begin{bmatrix} X_t(1) \\ X_t(3) \end{bmatrix} + \sigma_{\text{obs}} W_t. \end{aligned} \quad (31)$$

其中 $[X(1), X(2), X(3)]^\top$ 为隐状态变量， σ, ρ, β 为模型参数。取 $\sigma = 10$ 、 $\rho = 28$ 、 $\beta = 8/3$ 、 $\mu_0 = [25, 25, 25]^\top$ 、 $\sigma_0^2 = 10$ 。观测噪声 W 为二维标准高斯变量，且 $\sigma_{\text{obs}}^2 = 10$ 。




图 12. 式 (29) 中 $h(X_t) = X_t$ 时的结果。左图给出 EnKF、OT 与 SIR 粒子和真实状态的轨迹；右图给出相对精确条件分布的 MMD。




图 13. 式 (29) 中 $h(X_t) = X_t \odot X_t \odot X_t$ 时的结果。左图给出 EnKF、OT 与 SIR 粒子和真实状态的轨迹；右图给出相对精确条件分布的 MMD。

模拟 Lorenz 63 时动力学本身不含噪声，但在各算法的动力学更新中加入人工噪声

$$\mathcal{N}(0, \sigma_{\text{added}}^2 I_3), \quad \sigma_{\text{added}}^2 = 1.$$

为更清楚比较三种滤波器，粒子初始化自均值 $[0, 0, 0]$ 的高斯分布，而真实状态初始化自均值 $[25, 25, 25]$ 的高斯分布。

T 使用含或不含 EnKF 模块、宽度为 64 的两块残差网络。 f, T 优化器的学习率分别为 5×10^{-2} 和 10^{-2} 。总迭代数从 1024 开始，每个时刻后减半，直至 64；每次迭代从 $N = 1000$ 个粒子中随机选取 64 个样本。

图 14 给出所有三种算法的真实状态和粒子轨迹；原文所述右侧 MSE 是 10 次独立模拟的平均




图 14. Lorenz 63 示例 (31)。图中给出粒子 $\{X^i\}$ 与真实状态的轨迹；每列对应一个状态，每行对应一种算法。

状态估计误差。总体而言，含或不含 EnKF 模块的两种 OT 都优于 EnKF 与 SIR。EnKF 模块有助于初始阶段的性能，但需要仔细调整学习率。

C.5 Lorenz 96 模型

考虑 Lorenz-96 模型

$$\dot{X}(k) = (X(k+1) - X(k-2))X(k-1) - X(k) + F + \sigma V, \text{quad} k = 1, \dots, n,$$

$$Y_t = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix} X_t + \sigma W_t. \quad (32)$$

取 $n = 9$, $X_0 \sim \mathcal{N}(\mu_0, \sigma_0^2 I_n)$, 并约定 $X(-1) = X(n-1)$ 、 $X(0) = X(n)$ 、 $X(n+1) = X(1)$ ；强迫常数 $F = 2$ 。模型参数为 $\mu_0 = 25\mathbf{1}_n$ 、 $\sigma_0^2 = 10^2$ ，观测噪声 W 为方差 1 的 n 维标准高斯变量。

本实验以含 EnKF 模块、宽度为 32 的两块残差网络表示 T 。 f, T 优化器学习率分别为 10^{-3} 与 10^{-1} 。总迭代数从 1024 开始，每个时刻后减半，直至 64。批大小为 128，粒子数 $N = 1000$ 。

图 15(a) 各列为未观测状态，各行不同算法；图 (b) 给出 10 次独立模拟平均后的状态估计 MSE。结果表明 OT 与 EnKF 性能相当，而 EnKF 在该问题上表现良好。




图 15. Lorenz 96 示例 (32)。 (a) 粒子与真实状态轨迹，每列对应一个未观测状态，每行对应一种算法； (b) 状态估计 MSE 随时间的比较。

C.6 MNIST 静态图像修复的补充细节与结果

本例在一个用于表示 MNIST 数字的 GAN 的 100 维潜空间上计算条件分布 [24]。记生成器为 $G: \mathbb{R}^{100} \rightarrow \mathbb{R}^{28 \times 28}$ ，考虑

$$Y_t = h(G(X), c_t) + \sigma W_t, \quad X \sim N(0, I_{100}),$$

其中 h 取 $r \times r$ 像素窗口 $z[c(1):c(1)+r, c(2):c(2)+r]$ 。角点 c_t 从左到右、从上到下移动，扫描图像的已观测部分。为增加难度，在每个坐标轴上向角点位置加入 -2 到 2 的均匀随机整数，再把这一带噪位置提供给算法。观测噪声为 $\sigma = 10^{-1}$ ， W_t 各分量服从 $N(0, 1)$ 。真实图像不变，但为避免粒子坍缩，向粒子加入人工高斯噪声 $N(0, \sigma^2 I_{100})$ 。

本例使用公开的 MNIST GAN 代码⁶，以及在 MNIST 测试集上准确率超过 98% 的分类器⁷。 T 是不含 EnKF 模块、宽度为 320 的残差网络； f, T 的学习率均为 10^{-3} ，迭代 $2^{12} = 4096$ 次，批大小 64，粒子数 $N = 1000$ 。

图 16 给出更多结果。首行是截至各时刻的全部已观测部分，之后 16 行为从逼近条件分布的粒子生成的图像。

C.7 MNIST 动态图像修复的补充细节与结果

在前述静态示例上加入潜变量动态更新：

$$\begin{aligned} X_{t+1} &= (1 - \alpha)X_t + \sigma V_t, \\ Y_{t+1} &= h(G(X_{t+1}), c_{t+1}) + \sigma_w W_{t+1}, \end{aligned}$$

⁶<https://github.com/lyeoni/pytorch-mnist-GAN/tree/master>

⁷<https://nextjournal.com/gkoehler/pytorch-mnist>




图 16. MNIST 静态图像修复的补充结果。首行给出截至各时刻的累计观测，红线下方分别为 EnKF 与 SIR 的 16 个粒子。

其中 V_t, W_t 为相应维数的标准高斯变量， $\sigma = \sqrt{2\alpha - \alpha^2}$ 、 $\sigma_w = 10^{-1}$ 、 $\alpha = 0.2$ 。观测函数为 $h_t(G(X_t), c_t) = G(X_t)[28 - r : 28, c_t : c_t + r]$ ， $c_t \sim \text{Unif}_{\text{integer}}(1, 28 - r)$ ， $r = 12$ 。OT 参数与静态情形相似。

图 17(a)-(c) 给出粒子轨迹。首行是真实图像，第二行是各时刻的观测，红线下方 16 行为 EnKF、SIR 与 OT 粒子生成的图像。图 (d) 使用高精度 MNIST 分类器展示各算法粒子生成数字的直方图。




图 17. MNIST 动态图像修复的补充结果。(a) – (c) 首行是真实图像，第二行是各时刻观测，红线以下为 EnKF、SIR 与 OT 的 16 个粒子。(d) 使用高精度 MNIST 分类器评估三种算法粒子生成数字的直方图随时间的变化。

参考文献

- [1] Al-Jarrah, M., Hosseini, B., and Taghvaei, A. Optimal transport particle filters. In *2023 62nd IEEE Conference on Decision and Control (CDC)*, pp. 6798–6805. IEEE, 2023.
- [2] Al-Jarrah, M., Hosseini, B., and Taghvaei, A. Data-driven approximation of stationary nonlinear filters with optimal transport maps. *arXiv preprint arXiv:2403.15630*, 2024.
- [3] Amos, B., Xu, L., and Kolter, J. Z. Input convex neural networks. In *International Conference on Machine Learning*, pp. 146–155. PMLR, 2017.
- [4] Bengtsson, T., Bickel, P., and Li, B. Curse of dimensionality revisited: Collapse of the particle filter in very large scale systems. In *IMS Lecture Notes - Monograph Series in Probability and Statistics: Essays in Honor of David F. Freedman*, volume 2, pp. 316–334. Institute of Mathematical Sciences, 2008.
- [5] Bergemann, K. and Reich, S. An ensemble Kalman-Bucy filter for continuous data assimilation. *Meteorologische Zeitschrift*, 21(3):213, 2012.
- [6] Bickel, P., Li, B., Bengtsson, T., et al. Sharp failure rates for the bootstrap particle filter in high dimensions. In *Pushing the limits of contemporary statistics: Contributions in honor of Jayanta K. Ghosh*, pp. 318–329. Institute of Mathematical Statistics, 2008.
- [7] Brenier, Y. Polar factorization and monotone rearrangement of vector-valued functions. *Communications on pure and applied mathematics*, 44(4):375–417, 1991.
- [8] Bunne, C., Krause, A., and Cuturi, M. Supervised training of conditional Monge maps. *Advances in Neural Information Processing Systems*, 35:6859–6872, 2022.
- [9] Calvello, E., Reich, S., and Stuart, A. M. Ensemble Kalman methods: a mean field perspective. *arXiv preprint arXiv:2209.11371*, 2022.
- [10] Cappé, O., Moulines, E., and Rydén, T. Inference in hidden Markov models. In *Proceedings of EUSFLAT Conference*, pp. 14–16, 2009.
- [11] Carlier, G., Chernozhukov, V., and Galichon, A. Vector quantile regression: an optimal transport approach. *The Annals of Statistics*, 44(3):1165–1192, 2016.
- [12] Crisan, D. and Xiong, J. Approximate McKean-Vlasov representations for a class of SPDEs. *Stochastics An International Journal of Probability and Stochastics Processes*, 82(1):53–68, 2010. doi: 10.1080/17442500902723575.
- [13] Daum, F. and Huang, J. Particle flow and monge-kantorovich transport. In *2012 15th International Conference on Information Fusion*, pp. 135–142. IEEE, 2012.
- [14] Daum, F., Huang, J., and Noushin, A. Exact particle flow for nonlinear filters. In *Signal processing, sensor fusion, and target recognition XIX*, volume 7697, pp. 92–110. SPIE, 2010.
- [15] De Melo, F. E., Maskell, S., Fasiolo, M., and Daum, F. Stochastic particle flow for nonlinear high-dimensional filtering problems. *arXiv preprint arXiv:1511.01448*, 2015.
- [16] Del Moral, P. and Guionnet, A. On the stability of interacting processes with applications to filtering and genetic algorithms. In *Annales de l’Institut Henri Poincaré (B) Probability and Statistics*, volume 37, pp. 155–194. Elsevier, 2001.
- [17] Doucet, A. and Johansen, A. M. A tutorial on particle filtering and smoothing: Fifteen years later.

- Handbook of nonlinear filtering*, 12(3):656–704, 2009.
- [18] El Moselhy, T. A. and Marzouk, Y. M. Bayesian inference with optimal maps. *Journal of Computational Physics*, 231(23):7815–7850, 2012.
 - [19] Evensen, G. The ensemble Kalman filter: Theoretical formulation and practical implementation. *Ocean dynamics*, 53(4):343–367, 2003. doi: 10.1007/s10236-003-0036-9.
 - [20] Evensen, G. *Data Assimilation: The Ensemble Kalman Filter*, volume 2. Springer, 2009.
 - [21] Fan, J., Taghvaei, A., and Chen, Y. Scalable computations of Wasserstein barycenter via input convex neural networks. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pp. 1571–1581. PMLR, 18–24 Jul 2021.
 - [22] Fournier, N. and Guillin, A. On the rate of convergence in Wasserstein distance of the empirical measure. *Probability theory and related fields*, 162(3-4):707–738, 2015.
 - [23] Garbuno-Inigo, A., Helin, T., Hoffmann, F., and Hosseini, B. Bayesian posterior perturbation analysis with integral probability metrics. *arXiv preprint arXiv:2303.01512*, 2023.
 - [24] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. Generative adversarial nets. In *Advances in neural information processing systems*, pp. 2672–2680, 2014.
 - [25] Gordon, N. J., Salmond, D. J., and Smith, A. F. Novel approach to nonlinear/non-Gaussian Bayesian state estimation. In *IEE Proceedings F-radar and signal processing*, volume 140, pp. 107–113. IET, 1993.
 - [26] Grange, D., Al-Jarrah, M., Baptista, R., Taghvaei, A., Georgiou, T. T., Phillips, S., and Tannenbaum, A. Computational optimal transport and filtering on Riemannian manifolds. *IEEE Control Systems Letters*, 2023.
 - [27] Hütter, J.-C. and Rigollet, P. Minimax rates of estimation for smooth optimal transport maps. *The Annals of Statistics*, 49(2):1166–1194, 2021.
 - [28] Kakade, S., Shalev-Shwartz, S., Tewari, A., et al. On the duality of strong convexity and strong smoothness: Learning applications and matrix regularization. *Unpublished Manuscript*, <http://ttic.uchicago.edu/shai/papers/KakadeShalevTewari09.pdf>, 2(1):35, 2009.
 - [29] Kovachki, N., Baptista, R., Hosseini, B., and Marzouk, Y. Conditional sampling with monotone GANs: from generative models to likelihood-free inference. *arXiv preprint arXiv:2006.06755*, 2023.
 - [30] Makkuva, A., Taghvaei, A., Oh, S., and Lee, J. Optimal transport mapping via input convex neural networks. In *International Conference on Machine Learning*, pp. 6672–6681. PMLR, 2020.
 - [31] Marzouk, Y., Moselhy, T., Parno, M., and Spantini, A. Sampling via measure transport: An introduction, in *Handbook of Uncertainty Quantification*. Springer, pp. 1–41, 2016.
 - [32] Mesa, D. A., Tantiengloc, J., Mendoza, M., Kim, S., and P. Coleman, T. A distributed framework for the construction of transport maps. *Neural computation*, 31(4):613–652, 2019.
 - [33] Moreau, J.-J. Proximité and dualité in a Hilbertian space. *Bulletin of the Mathematical Society of France*, 93:273–299, 1965.
 - [34] Pathiraja, S., Reich, S., and Stannat, W. McKean–Vlasov SDEs in nonlinear filtering. *SIAM Journal on Control and Optimization*, 59(6):4188–4215, 2021.
 - [35] Ray, D., Ramaswamy, H., Patel, D. V., and Oberai, A. A. The efficacy and generalizability of condi-

- tional GANs for posterior inference in physics-based inverse problems. *Numerical Algebra, Control and Optimization*, 2022.
- [36] Rebeschini, P. and Van Handel, R. Can local particle filters beat the curse of dimensionality? *The Annals of Applied Probability*, 25(5):2809–2866, 2015.
 - [37] Reich, S. A dynamical systems framework for intermittent data assimilation. *BIT Numerical Analysis*, 51:235–249, 2011. doi: 10.1007/s10543-010-0302-4.
 - [38] Reich, S. A nonparametric ensemble transform method for Bayesian inference. *SIAM Journal on Scientific Computing*, 35(4):A2013–A2024, 2013.
 - [39] Reich, S. Data assimilation: The Schrödinger perspective. *Acta Numerica*, 28:635–711, 2019.
 - [40] Rockafellar, R. T. *Convex analysis*, volume 11. Princeton university press, 1997.
 - [41] Rout, L., Korotin, A., and Burnaev, E. Generative modeling with optimal transport maps. In *International Conference on Learning Representations*, 2022.
 - [42] Shi, Y., De Bortoli, V., Deligiannidis, G., and Doucet, A. Conditional simulation using diffusion Schrödinger bridges. In *Uncertainty in Artificial Intelligence*, pp. 1792–1802. PMLR, 2022.
 - [43] Siahkoohi, A., Rizzuti, G., Louboutin, M., Witte, P. A., and Herrmann, F. J. Preconditioned training of normalizing flows for variational inference in inverse problems. *3rd Symposium on Advances in Approximate Bayesian Inference*, 2021.
 - [44] Spantini, A., Baptista, R., and Marzouk, Y. Coupling techniques for nonlinear ensemble filtering. *SIAM Review*, 64(4):921–953, 2022.
 - [45] Taghvaei, A. and Hosseini, B. An optimal transport formulation of Bayes’ law for nonlinear filtering algorithms. In *2022 IEEE 61st Conference on Decision and Control (CDC)*, pp. 6608–6613. IEEE, 2022.
 - [46] Taghvaei, A. and Mehta, P. G. Optimal transportation methods in nonlinear filtering. *IEEE Control Systems Magazine*, 41(4):34–49, 2021.
 - [47] Taghvaei, A. and Mehta, P. G. A survey of feedback particle filter and related controlled interacting particle systems (CIPS). *Annual Reviews in Control*, 2023.
 - [48] Van Leeuwen, P. J., Künsch, H. R., Nerger, L., Potthast, R., and Reich, S. Particle filters for high-dimensional geoscience applications: A review. *Quarterly Journal of the Royal Meteorological Society*, 145(723):2335–2365, 2019.
 - [49] Villani, C. *Optimal Transport: Old and New*, volume 338. Springer, 2009.
 - [50] Yang, T., Mehta, P. G., and Meyn, S. P. A mean-field control-oriented approach to particle filtering. In *Proceedings of the 2011 American Control Conference*, pp. 2037–2043. IEEE, 2011.
 - [51] Yang, T., Mehta, P. G., and Meyn, S. P. Feedback particle filter. *IEEE transactions on Automatic control*, 58(10):2465–2480, 2013.
 - [52] Yang, T., Laugesen, R. S., Mehta, P. G., and Meyn, S. P. Multivariable feedback particle filter. *Automatica*, 71:10–23, 2016.