

基于熵正则最优传输的可微粒子滤波

Adrien Corenflos* James Thornton* George Deligiannidis[†] Arnaud Doucet[†]

ICML 2021; arXiv:2102.07850v3

摘要

粒子滤波 (PF) 是用于非线性状态空间模型推断的一类成熟方法。重采样是粒子滤波的关键环节，也是获得低方差似然估计和状态估计所必需的步骤。然而，传统重采样方法会使基于粒子滤波的损失函数关于模型参数和粒子滤波参数不可微。在变分推断中，重采样还会导致基于粒子滤波的证据下界产生高方差梯度估计。借助最优传输思想，我们提出一种有原则依据的可微粒子滤波器，并给出其收敛性结果。最后，我们在多种应用中展示了这一新方法。

关键词：蒙特卡洛；粒子滤波；状态空间模型；最优传输

译稿说明。本中文稿依据作者在 arXiv:2102.07850v3 提供的官方 TeX 源完整翻译并改排为单栏；公式、图表、算法、标签、引用键和补充材料结构均予保留。图像直接取自 e-print 的原始绘图文件，不使用论文页面截图。

1 引言

本节简要介绍状态空间模型 (state-space model, SSM) 和粒子滤波 (particle filtering, PF) 方法。随后，我们说明粒子滤波一个广为人知的局限性 [1]：为了得到低方差估计，算法必须执行重采样，但所得估计关于模型参数和粒子滤波参数不可微，因而妨碍端到端训练。我们将讨论计量经济学、统计学和机器学习 (ML) 领域近期用于解决这一问题的方法，概述其局限性以及本文的贡献。

1.1 状态空间模型

状态空间模型是一类表达能力很强的序列模型，广泛用于计量经济学、生态学、机器学习和机器人学等科学领域，参见文献 [2,3,4,5,6,7]。一个状态空间模型可由取值于 $\mathcal{X}$ 的隐 Markov 过程 $(X_t)_{t \geq 1}$ 和取值于 $\mathcal{Y}$ 的观测过程 $(Y_t)_{t \geq 1}$ 描述，其中 $X_1 \sim \mu_\theta(\cdot)$ ，且对 $t \geq 1$ 有

$$X_{t+1} | \{X_t = x\} \sim f_\theta(\cdot | x), \quad Y_t | \{X_t = x\} \sim g_\theta(\cdot | x), \quad (1)$$

*共同第一作者；阿尔托大学电气工程与自动化系。

[†]牛津大学统计系。

其中 $\theta \in \Theta$ 是待研究参数。给定观测 $(y_t)_{t \geq 1}$ 和参数值 θ ，可以通过计算在 $y_{1:t} := (y_1, \dots, y_t)$ 条件下 X_t 的后验分布，在时刻 t 进行状态推断：

$$p_\theta(x_t|y_{1:t-1}) = \int f_\theta(x_t|x_{t-1})p_\theta(x_{t-1}|y_{1:t-1})dx_{t-1},$$

$$p_\theta(x_t|y_{1:t}) = \frac{g_\theta(y_t|x_t)p_\theta(x_t|y_{1:t-1})}{\int g_\theta(y_t|x_t)p_\theta(x_t|y_{1:t-1})dx_t},$$

并约定 $p_\theta(x_1|y_0) := \mu_\theta(x_1)$ 。

于是，对数似然 $\ell(\theta) = \log p_\theta(y_{1:T})$ 为

$$\ell(\theta) = \sum_{t=1}^T \log p_\theta(y_t|y_{1:t-1}),$$

其中 $p_\theta(y_1|y_0) := \int g_\theta(y_1|x_1)\mu_\theta(x_1)dx_1$ ，且对 $t \geq 2$ ，

$$p_\theta(y_t|y_{1:t-1}) = \int g_\theta(y_t|x_t)p_\theta(x_t|y_{1:t-1})dx_t.$$

只有在线性高斯模型等极为有限的状态空间模型中，后验 $p_\theta(x_t|y_{1:t})$ 和对数似然 $p_\theta(y_{1:T})$ 才具有解析表达式。对非线性状态空间模型，粒子滤波可近似这些量。

1.2 粒子滤波

粒子滤波是一类蒙特卡洛方法：随时间传播 N 个加权粒子 $(w_t^i, X_t^i)_{i \in [N]}$ ，其中 $[N] := \{1, \dots, N\}$ ，以近似滤波分布 $p_\theta(x_t|y_{1:t})$ 和对数似然 $\ell(\theta)$ 。这里， $X_t^i \in \mathcal{X}$ 表示时刻 t 第 i 个粒子的取值， $\mathbf{w}_t := (w_t^1, \dots, w_t^N)$ 是满足 $w_t^i \geq 0$ 、 $\sum_{i=1}^N w_t^i = 1$ 的权重。与变分方法不同，在较弱假设下，当 $N \rightarrow \infty$ 时粒子滤波能给出相合近似 [8]。一般而言，在加权和重采样前，时刻 $t = 1$ 的粒子从提议分布 $q_\phi(x_1|y_1)$ 采样，而在 $t \geq 2$ 时从 $q_\phi(x_t|x_{t-1}, y_t)$ 采样。人们常取 $\theta = \phi$ ，但这并非必要条件 [9,10,11]。

算法 1 给出了一般粒子滤波器，其中

$$p_\theta(x_1, y_1) := \mu_\theta(x_1)g_\theta(y_1|x_1),$$

$$p_\theta(x_t, y_t|x_{t-1}) := f_\theta(x_t|x_{t-1})g_\theta(y_t|x_t).$$

算法 1 第 6 步执行重采样：高权重粒子被复制，低权重粒子被丢弃，从而将计算资源集中于“有希望”的区域。算法 1 采用的方案称为多项式重采样；它与分层重采样、系统重采样等传统方案一样 [2] 是无偏的，即对任意 $\psi : \mathcal{X} \rightarrow \mathbb{R}$ ，

$$\mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N \psi(\tilde{X}_t^i) \right] = \mathbb{E} \left[\sum_{i=1}^N w_t^i \psi(X_t^i) \right]. \quad (2)$$

这一性质保证，对任意 N ， $\exp(\hat{\ell}(\theta))$ 都是似然 $\exp(\ell(\theta))$ 的无偏估计。

下文令 $\mathcal{X} = \mathbb{R}^{d_x}$ 、 $\theta \in \Theta = \mathbb{R}^{d_\theta}$ 、 $\phi \in \Phi = \mathbb{R}^{d_\phi}$ 。我们假设，对所有 x, x' 和 $t \in [T]$ ，映射 $\theta \mapsto \mu_\theta(x)$ 、 $\theta \mapsto f_\theta(x'|x)$ 、 $\theta \mapsto g_\theta(y_t|x)$ 均可微，且 $\theta \mapsto \ell(\theta)$ 可微。大量状态空间模型都满足这些假设。我们还假设可用重参数化技巧 [12] 采样粒子，即存在关于 ϕ 可微的映射 Γ_ϕ, Ψ_ϕ ，使得 $\Gamma_\phi(y_1, U) \sim q_\phi(x_1|y_1)$ 、 $\Psi_\phi(y_t, x_{t-1}, U) \sim q_\phi(x_t|x_{t-1}, y_t)$ ；其中 $U \sim \lambda$ ，且 λ 与 ϕ 无关。

算法 1 标准粒子滤波器

- 1: 对 $i \in [N]$, 采样 $X_1^i \stackrel{\text{i.i.d.}}{\sim} q_\phi(\cdot|y_1)$
 - 2: 对 $i \in [N]$, 计算 $\omega_1^i = \frac{p_\theta(X_1^i, y_1)}{q_\phi(X_1^i|y_1)}$
 - 3: $\hat{\ell}(\theta) \leftarrow \frac{1}{N} \sum_{i=1}^N \omega_1^i$
 - 4: **对** $t = 2, \dots, T$ **时**
 - 5: 归一化权重 $w_{t-1}^i \propto \omega_{t-1}^i$, 使 $\sum_{i=1}^N w_{t-1}^i = 1$
 - 6: 对 $i \in [N]$, 重采样 $\tilde{X}_{t-1}^i \sim \sum_{i=1}^N w_{t-1}^i \delta_{X_{t-1}^i}$
 - 7: 对 $i \in [N]$, 采样 $X_t^i \sim q_\phi(\cdot|\tilde{X}_{t-1}^i, y_t)$
 - 8: 对 $i \in [N]$, 计算 $\omega_t^i = \frac{p_\theta(X_t^i, y_t|\tilde{X}_{t-1}^i)}{q_\phi(X_t^i|\tilde{X}_{t-1}^i, y_t)}$
 - 9: 计算 $\hat{p}_\theta(y_t|y_{1:t-1}) = \frac{1}{N} \sum_{i=1}^N \omega_t^i$
 - 10: $\hat{\ell}(\theta) \leftarrow \hat{\ell}(\theta) + \log \hat{p}_\theta(y_t|y_{1:t-1})$
 - 11: **结束对**
 - 12: **返回:** 对数似然估计 $\hat{\ell}(\theta) = \log \hat{p}_\theta(y_{1:T})$
-


1.3 相关工作与本文贡献

令 $\mathbf{U}$ 表示采样和重采样粒子时使用的全部随机变量。由于采用重参数化技巧, $\mathbf{U}$ 的分布与 (θ, ϕ) 无关¹。然而, 即使采样后固定 $\mathbf{U} = \mathbf{u}$, 重采样仍涉及从原子分布中采样; 当 θ, ϕ 变化时, 所选粒子会发生不连续变化。


当 $d_x = 1$ 时, 文献 [13] 先对粒子排序, 再从其累积分布函数的平滑近似中采样, 从而使 $\theta \mapsto \hat{\ell}(\theta; \phi, \mathbf{u})$ 关于 θ 连续。当 $d_x > 1$ 时, 文献 [14] 给出更平滑但仅分段连续的估计。文献 [15] 使用边缘粒子滤波器 [16], 在折叠后的状态空间上执行重要性采样, 由此得到可微对数似然估计 $\hat{\ell}(\theta; \phi, \mathbf{u})$ 。然而, 标准边缘粒子滤波器采用提议 $q_\phi(x_t) := \sum_{i=1}^N w_{t-1}^i q_\phi(x_t|X_{t-1}^i, y_t)$, 对于任意混合分量, 通常无法从中平滑采样。因此, 该工作改用简单高斯分布作为 $q_\phi(x_t)$, 这可能使多峰后验的估计很差。此外, 标准粒子滤波器只需能从转移密度采样; 与之不同, 当转移密度只能采样而无法逐点评估时 (例如使用重参数化技巧时) [17], 边缘粒子滤波器的重要性权重不可计算, 因而无法适用。文献 [18] 的隐式重参数化方法可用于混合提议, 以获得低方差梯度估计, 但它只适用于条件累积分布函数可解析计算的分量分布, 例如高斯分布。也可通过动态规划得到另一种无偏似然估计 [19, 20]; 文献 [20] 指出该估计是可微的。不过, 该方法仍局限于少数提议分布, 例如无权混合提议; 对混合缓慢的时间序列, 其表现可能不佳。

在机器人定位中, 文献 [21, 22, 23] 提出一种称为“软重采样” (SPF) 的修正方案。SPF 的参数为 $\alpha \in [0, 1]$: $\alpha = 1$ 对应常规粒子滤波重采样, $\alpha = 0$ 基本等价于均匀随机采样粒子。所得 PF-net 虽被称为可微, 却在计算梯度时忽略了重采样步骤中的不可微分量。文献 [24] 提出另一种所谓可微的粒子滤波方案, 但同样直接忽略不可微的重采样项, 并根据观测和某个神经网络提出新状态; 该方法不能沿时间传播梯度。最后, 文献 [25] 提出基于 Transformer 的可微重采样方案, 却报告


¹例如, 多项式重采样需要 N 个均匀随机变量。



(a) Kalman 滤波器



(b) 标准粒子滤波器



(c) 可微粒子滤波器

图 1. 左: 小节 5.1 中线性高斯状态空间模型的对数似然 $\ell(\theta)$ 与粒子滤波估计 $\hat{\ell}(\theta; \phi, \mathbf{u})$, 其中 $d_\theta = 2$ 、 $d_x = 2$ 、 $T = 150$ 、 $N = 50$ 。右: $\nabla_\theta \ell(\theta)$ 与 $\nabla_\theta \hat{\ell}(\theta; \phi, \mathbf{u})$ 。

称由于梯度爆炸，不对重采样反向传播时效果最好。因此，现有文献尚未给出完全可微的粒子滤波器 [26]。

粒子滤波也已被有效用于变分推断 (VI) 以估计 θ, ϕ [9, 10, 11]。对标准粒子滤波而言，任意 N, ϕ 下都有 $\mathbb{E}_U[\exp(\hat{\ell}(\theta; \phi, U))] = \exp(\ell(\theta))$ ，即它是 $\exp(\ell(\theta))$ 的无偏估计。因此由 Jensen 不等式，

$$\ell^{\text{ELBO}}(\theta, \phi) := \mathbb{E}_U[\hat{\ell}(\theta; \phi, U)] \leq \ell(\theta). \quad (3)$$

标准证据下界 (ELBO) 对应于 $N = 1$ ；在这一背景下，人们提出了许多用于近似 $p_\theta(x_{1:T}|y_{1:T})$ 的变分族 [27, 28, 29]。粒子滤波诱导的变分族有本质区别：当 $N \rightarrow \infty$ 时， $\ell^{\text{ELBO}}(\theta, \phi) \rightarrow \ell(\theta)$ ，因此所得变分近似收敛到 $p_\theta(x_{1:T}|y_{1:T})$ 。这一优点需要付出计算代价，即粒子滤波方法在后验逼真度与计算复杂度之间进行权衡。

虽然可以计算 PF-ELBO (3) 的无偏梯度估计，但重采样步骤要求使用 REINFORCE 梯度估计 [30]，因而方差很高。因此，文献 [9, 10, 11, 31] 采用忽略这些项的有偏梯度估计；它们仍报告称，随着 N 增大，性能优于标准变分推断方法和重要性加权自编码器 (IWAE) [32]。

最后，如果只关心估计 θ （而不估计另一个不同的 ϕ ），也可使用逐点近似得分向量 $\nabla_\theta \ell(\theta)$ 的粒子方法 [1, 33]。

本文有以下四点贡献：

- 我们提出首个可使用一般提议分布的完全可微粒子滤波器 (DPF)。DPF 给出 $\ell(\theta)$ 的可微估计（见图 1c），并可更一般地给出基于粒子滤波的损失的可微估计。在变分推断实验中，DPF-ELBO 梯度估计的方差也远小于 PF-ELBO。
- 我们给出可微重采样方案的定量收敛结果，并证明 DPF 的相合性。
- 我们证明现有技术给出的梯度估计不相合，且其不消失偏差可能很大，从而在实际中导致不可靠的参数估计。
- 我们在多种应用的端到端参数估计中验证了 DPF 在经验上优于近期替代方法。

相关结果的证明见补充材料。

2 基于最优传输的重采样

2.1 最优传输与 Wasserstein 度量

最优传输 (optimal transport, OT) [34, 35] 是本文方案的核心组成部分，下面先介绍其基础。给定 $\mathcal{X} = \mathbb{R}^{d_x}$ 上两个概率测度 α, β ，二者之间平方 2-Wasserstein 度量为

$$\mathcal{W}_2^2(\alpha, \beta) = \min_{\mathcal{P} \in \mathcal{U}(\alpha, \beta)} \mathbb{E}_{(U, V) \sim \mathcal{P}} [\|U - V\|^2], \quad (4)$$

其中, $\mathcal{U}(\alpha, \beta)$ 是 $\mathcal{X} \times \mathcal{X}$ 上以 α, β 为边缘分布的分布集合; (4) 的最小化解称为最优传输方案, 记作 $\mathcal{P}^{\text{OT}}$ 。任意 $\mathcal{P} \in \mathcal{U}(\alpha, \beta)$ 都可将 α “传输” 为 β (反之亦然), 即

$$\beta(\mathrm{d}v) = \int \mathcal{P}(\mathrm{d}u, \mathrm{d}v) = \int \mathcal{P}(\mathrm{d}v|u)\alpha(\mathrm{d}u).$$

对原子概率测度 $\alpha_N = \sum_{i=1}^N a_i \delta_{u_i}$ 和 $\beta_N = \sum_{j=1}^N b_j \delta_{v_j}$, 令权重为 $\mathbf{a} = (a_i)_{i \in [N]}$ 、 $\mathbf{b} = (b_j)_{j \in [N]}$, 原子为 $\mathbf{u} = (u_i)_{i \in [N]}$ 、 $\mathbf{v} = (v_j)_{j \in [N]}$, 则可证明

$$\mathcal{W}_2^2(\alpha_N, \beta_N) = \min_{\mathbf{P} \in \mathcal{S}(\mathbf{a}, \mathbf{b})} \sum_{i=1}^N \sum_{j=1}^N c_{i,j} p_{i,j}, \quad (5)$$

其中任意 $\mathcal{P} \in \mathcal{U}(\alpha_N, \beta_N)$ 均可写为

$$\mathcal{P}(\mathrm{d}u, \mathrm{d}v) = \sum_{i,j} p_{i,j} \delta_{u_i}(\mathrm{d}u) \delta_{v_j}(\mathrm{d}v),$$

$c_{i,j} = \|u_i - v_j\|^2$, $\mathbf{P} = (p_{i,j})_{i,j \in [N]}$, 且

$$\mathcal{S}(\mathbf{a}, \mathbf{b}) = \left\{ \mathbf{P} \in [0, 1]^{N \times N} : \sum_{j=1}^N p_{i,j} = a_i, \sum_{i=1}^N p_{i,j} = b_j \right\}.$$

此时有

$$\mathcal{P}(\mathrm{d}v|u = u_i) = \sum_j a_i^{-1} p_{i,j} \delta_{v_j}(\mathrm{d}v). \quad (6)$$

优化问题(5)可用线性规划求解, 也可采用其对偶形式

$$\mathcal{W}_2^2(\alpha_N, \beta_N) = \max_{\mathbf{f}, \mathbf{g} \in \mathcal{R}(\mathbf{C})} \mathbf{a}^t \mathbf{f} + \mathbf{b}^t \mathbf{g}, \quad (7)$$

其中 $\mathbf{f} = (f_i)$ 、 $\mathbf{g} = (g_j)$ 、 $\mathbf{C} = (c_{i,j})$, 并且 $\mathcal{R}(\mathbf{C}) = \{(\mathbf{f}, \mathbf{g}) \in \mathbb{R}^N \times \mathbb{R}^N : f_i + g_j \leq c_{i,j}, i, j \in [N]\}$ 。

2.2 集合变换重采样

文献 [36] 率先将最优传输用于粒子滤波重采样。与标准重采样方案 [2,4] 不同, 它不仅使用粒子权重, 还使用粒子位置。

在时刻 t , 执行采样步骤 (算法 1 第 7 步) 后,

$$\alpha_N^{(t)} = \frac{1}{N} \sum_{i=1}^N \delta_{X_t^i}$$

是如下预测分布的粒子近似:

$$\alpha^{(t)} := \int q_\phi(x_t | x_{t-1}, y_t) p_\theta(x_{t-1} | y_{1:t-1}) \mathrm{d}x_{t-1}.$$

相应地, $\beta_N^{(t)} = \sum_i w_i^t \delta_{X_t^i}$ 是 $\beta^{(t)} := p_\theta(x_t | y_{1:t})$ 的近似。在温和的正则条件下, 使 $\mathcal{W}_2(\alpha^{(t)}, \beta^{(t)})$ 最小的最优传输方案具有

$$\mathcal{P}^{\text{OT}}(\mathrm{d}x, \mathrm{d}x') = \alpha^{(t)}(\mathrm{d}x) \delta_{\mathbf{T}^{(t)}(x)}(\mathrm{d}x')$$

的形式, 其中 $\mathbf{T}^{(t)}: \mathcal{X} \rightarrow \mathcal{X}$ 是确定性映射; 即若 $X \sim \alpha^{(t)}$, 则 $\mathbf{T}^{(t)}(X) \sim \beta^{(t)}$ 。文献 [36] 证明, 可用记作 $\mathbf{T}_N^{(t)}$ 的“集合变换” (ensemble transform, ET) 近似这一传输映射。具体做法是求解 $\alpha_N^{(t)}$ 与 $\beta_N^{(t)}$ 之间的最优传输问题(5), 并关于(6)取期望:

$$\tilde{X}_t^i = N \sum_{k=1}^N p_{i,k}^{\text{OT}} X_t^k := \mathbf{T}_N^{(t)}(X_t^i). \quad (8)$$

这里略微滥用了记号, 因为 $\mathbf{T}_N^{(t)}$ 本身是 $X_t^{1:N}$ 的函数。文献 [36] 使用这一更新代替 $\tilde{X}_t^i \sim \sum_{i=1}^N w_t^i \delta_{X_t^i}$; 其依据是, 当 $N \rightarrow \infty$ 时, $\mathbf{T}_N^{(t)}(X_t^i)$ 在某种弱意义下收敛到 $\mathbf{T}^{(t)}(X_t^i)$ [36,37]。与标准重采样方案相比, 集合变换只有在 ψ 为仿射函数时才满足(2)。

这种最优传输重采样需要以 $O(N^3 \log N)$ 的代价求解线性规划(4) [38]。其计算成本高得难以承受, 而且所得集合变换不可微。为解决这两个问题, 可以改用熵正则最优传输 [39]。

3 基于熵正则最优传输的可微重采样

3.1 熵正则最优传输

熵正则最优传输可用于计算关于输入可微、且计算成本低于无正则版本的传输矩阵。具体而言, 对某个 $\epsilon > 0$, 考虑(5)的如下正则化版本 [34,39]:

$$\mathcal{W}_{2,\epsilon}^2(\alpha_N, \beta_N) = \min_{P \in \mathcal{S}(\mathbf{a}, \mathbf{b})} \sum_{i,j=1}^N p_{i,j} \left(c_{i,j} + \epsilon \log \frac{p_{i,j}}{a_i b_j} \right). \quad (9)$$

(9)中被最小化的函数严格凸, 因而具有唯一最小化解 $\mathbf{P}_\epsilon^{\text{OT}} = (p_{\epsilon,i,j}^{\text{OT}})$ 。 $\mathcal{W}_{2,\epsilon}^2(\alpha_N, \beta_N)$ 也可通过正则化对偶问题计算, 即 $\mathcal{W}_{2,\epsilon}^2(\alpha_N, \beta_N) = \max_{\mathbf{f}, \mathbf{g}} \text{DOT}_\epsilon(\mathbf{f}, \mathbf{g})$, 其中

$$\text{DOT}_\epsilon(\mathbf{f}, \mathbf{g}) := \mathbf{a}^t \mathbf{f} + \mathbf{b}^t \mathbf{g} - \epsilon \mathbf{a}^t \mathbf{M} \mathbf{b}, \quad (10)$$

$(\mathbf{M})_{i,j} := \exp(\epsilon^{-1}(f_i + g_j - c_{i,j})) - 1$, 且 $\mathbf{f}, \mathbf{g}$ 不再受约束。对使(10)最大化的对偶变量 $(\mathbf{f}^*, \mathbf{g}^*)$, 有

$$\nabla_{\mathbf{f}, \mathbf{g}} \text{DOT}_\epsilon(\mathbf{f}, \mathbf{g})|_{(\mathbf{f}^*, \mathbf{g}^*)} = \mathbf{0}.$$

由此一阶条件得到

$$f_i^* = \mathcal{T}_\epsilon(\mathbf{b}, \mathbf{g}^*, \mathbf{C}_{i,:}), \quad g_i^* = \mathcal{T}_\epsilon(\mathbf{a}, \mathbf{f}^*, \mathbf{C}_{:,i}), \quad (11)$$

其中 $\mathbf{C}_{i,:}$ (相应地 $\mathbf{C}_{:,i}$) 是 $\mathbf{C}$ 的第 i 行 (相应地第 i 列)。映射 $\mathcal{T}_\epsilon: \mathbb{R}^N \times \mathbb{R}^N \times \mathbb{R}^N \rightarrow \mathbb{R}^N$ 定义为

$$\mathcal{T}_\epsilon(\mathbf{a}, \mathbf{f}, \mathbf{C}_{:,i}) = -\epsilon \log \sum_k \exp \left\{ \log a_k + \epsilon^{-1}(f_k - c_{k,i}) \right\}.$$

于是可恢复正则化传输矩阵:

$$p_{\epsilon,i,j}^{\text{OT}} = a_i b_j \exp \left(\epsilon^{-1}(f_i^* + g_j^* - c_{i,j}) \right). \quad (12)$$

对偶问题可用文献 [39] 在最优传输领域的奠基工作所提出的 Sinkhorn 算法求解。算法 2 给出文献 [40] 的实现，其中对基于(11)的不动点更新进行了稳定化处理。

算法 2 Sinkhorn 算法

```

1: 函数 Potentials( $\mathbf{a}, \mathbf{b}, \mathbf{u}, \mathbf{v}$ )
2: 局部变量:  $\mathbf{f}, \mathbf{g} \in \mathbb{R}^N$ 
3: 初始化:  $\mathbf{f} = \mathbf{0}, \mathbf{g} = \mathbf{0}$ 
4: 令  $\mathbf{C} \leftarrow \mathbf{u}\mathbf{u}^t + \mathbf{v}\mathbf{v}^t - 2\mathbf{u}\mathbf{v}^t$ 
5: 当 尚未满足停止准则 时
6:   对  $i \in [N]$  时
7:      $f_i \leftarrow \frac{1}{2} (f_i + \mathcal{T}_\epsilon(\mathbf{b}, \mathbf{g}, \mathbf{C}_{i,:}))$ 
8:      $g_i \leftarrow \frac{1}{2} (g_i + \mathcal{T}_\epsilon(\mathbf{a}, \mathbf{f}, \mathbf{C}_{:,i}))$ 
9:   结束对
10: 结束当
11: 返回  $\mathbf{f}, \mathbf{g}$ 

```

随后, 可对所得对偶向量 $(\mathbf{f}^*, \mathbf{g}^*)$ 求导。例如, 可对 Sinkhorn 算法循环直接自动微分 [41]; 也可像本文一样, 在收敛后的对偶向量上使用更高效的“梯度拼接” (详见文献 [40])。结合(11)与(12)的导数, 便可通过自动微分直接得到 $\mathbf{P}_\epsilon^{\text{OT}}$ 的导数, 而无额外计算成本。

3.2 可微集合变换重采样

在时刻 t , 对加权粒子 $(\mathbf{X}_t, \mathbf{w}_t, N)$ 使用算法 3 计算熵正则最优传输, 可得到记作 $\mathbf{T}_{N,\epsilon}^{(t)}$ 的可微集合变换 (differentiable ensemble transform, DET):

$$\tilde{\mathbf{X}}_t^i = N \sum_{k=1}^N p_{\epsilon,i,k}^{\text{OT}} \mathbf{X}_t^k := \mathbf{T}_{N,\epsilon}^{(t)}(\mathbf{X}_t^i). \quad (13)$$

算法 3 DET 重采样

```

1: 函数 EnsembleTransform( $\mathbf{X}, \mathbf{w}, N$ )
2:  $\mathbf{f}, \mathbf{g} \leftarrow \text{Potentials}(\mathbf{w}, \frac{1}{N}\mathbf{1}, \mathbf{X}, \mathbf{X})$ 
3: 对  $i \in [N]$  时
4:   对  $j \in [N]$  时
5:      $p_{\epsilon,i,j}^{\text{OT}} = \frac{w_j}{N} \exp\left(\frac{f_i + g_j - c_{i,j}}{\epsilon}\right)$ 
6:   结束对
7: 结束对
8: 返回  $\tilde{\mathbf{X}} = N \mathbf{P}_\epsilon^{\text{OT}} \mathbf{X}$ 

```

与集合变换相比, DET 可微; 由于依赖 Sinkhorn 算法, 其计算成本为 $O(N^2)$ 。该算法收敛很快 [42], 尤其适合在 GPU 上实现。

本文提出的 DPF 与算法 1 相似, 区别在于我们通过重参数化技巧从提议分布 q_ϕ 采样, 并以 DET 替换第 6 步。尽管机器学习领域此前已提出集合变换的这种可微近似 [43, 44], 但从未有人意识到可借此构造可微粒子滤波器。具体而言, 我们得到滤波分布下期望关于 θ, ϕ 的可微估计; 对固定的“种子” $\mathbf{U} = \mathbf{u}^2$, 还可得到对数似然函数 $\theta \mapsto \hat{\ell}_\epsilon(\theta; \phi, \mathbf{u})$ 的可微估计。

与集合变换一样, DET 也只有在 ψ 为仿射函数时才满足(2)。与 $\mathbf{P}^{\text{OT}}$ 不同, $\mathbf{P}_\epsilon^{\text{OT}}$ 对 $\mathbf{X}_t$ 的尺度敏感。为缓解这种敏感性, 对 $\mathbf{X}_t \in \mathbb{R}^{N \times d_x}$ 可计算

$$\delta(\mathbf{X}_t) = \sqrt{d_x} \max_{k \in [d_x]} \text{std}_i(X_{t,k}^i),$$

并据此缩放 $\mathbf{C}$, 使 ϵ 近似独立于问题的尺度与维数。

4 理论分析

本节证明, 若在基于粒子滤波的损失中忽略重采样引起的梯度项, 则所得梯度估计不相合, 并可能具有很大的不消失偏差。相反, 我们证明 DPF 可对滤波分布和对数似然函数给出相合且可微的估计。为此, 我们建立了 DET 的新定量收敛结果。

4.1 忽略重采样项所致的梯度偏差

我们先研究从粒子滤波损失计算梯度时丢弃重采样梯度项所产生的渐近偏差; 文献 [9, 10, 11, 21, 23, 24, 31] 均采用了这种做法。此处仅讨论 ELBO 损失; 对机器人学中使用的不可微重采样方案和损失, 也可作类似分析。

命题 4.1. 考虑算法 1 中的粒子滤波器, 并设 ϕ 与 θ 不同。在正则条件下, 文献 [9, 10, 11] 所研究的、忽略重采样项的 ELBO 梯度估计 $\hat{\nabla}_\theta \ell^{\text{ELBO}}(\theta, \phi)$ 的期望在 $N \rightarrow \infty$ 时收敛到

$$\begin{aligned} \mathbb{E}[\hat{\nabla}_\theta \ell^{\text{ELBO}}(\theta, \phi)] &\longrightarrow \int \nabla_\theta \log p_\theta(x_1, y_1) p_\theta(x_1 | y_1) dx_1 \\ &\quad + \sum_{t=2}^T \int \nabla_\theta \log p_\theta(x_t, y_t | x_{t-1}) p_\theta(x_{t-1:t} | y_{1:t}) dx_{t-1:t}, \end{aligned}$$

而 Fisher 恒等式给出

$$\begin{aligned} \nabla_\theta \ell(\theta) &= \int \nabla_\theta \log p_\theta(x_1, y_1) p_\theta(x_1 | y_{1:T}) dx_1 \\ &\quad + \sum_{t=2}^T \int \nabla_\theta \log p_\theta(x_t, y_t | x_{t-1}) p_\theta(x_{t-1:t} | y_{1:T}) dx_{t-1:t}. \end{aligned} \tag{14}$$

因此, 虽然在正则假设下 $N \rightarrow \infty$ 时有 $\nabla_\theta \ell^{\text{ELBO}}(\theta, \phi) \rightarrow \nabla_\theta \ell(\theta)$, 但只有当 $p_\theta(x_{t-1:t} | y_{1:t}) = p_\theta(x_{t-1:t} | y_{1:T})$ 时, $\hat{\nabla}_\theta \ell^{\text{ELBO}}(\theta, \phi)$ 的渐近偏差才会消失; 这对应于各 X_t 相互独立的模型。若给定

²这里 $\mathbf{U}$ 仅表示生成粒子时使用、且与 θ, ϕ 无关的随机变量集合; 不同于标准粒子滤波, DET 重采样不依赖任何额外随机变量。

$y_{t:T}$ 后, $y_{t+1:T}$ 不再为 X_t 提供太多信息, 那么这种近似是合理的; 文献 [9,10,11] 所研究的模型即属此类, 这解释了其报告的良好表现。然而, 节 5 将表明, 该偏差在实际中也可能导致不准确的参数估计。

4.2 DET 的定量界

已有工作分别建立了集合变换 [36,37] 和 DET [44] 的弱收敛结果。基于文献 [45,46] 的结果, 我们在此首次给出对任意 $N \geq 1$ 都成立的集合变换 ($\epsilon = 0$) 与 DET ($\epsilon > 0$) 定量界。对任意测度 ν 和函数 ψ , 记 $\nu(\psi) := \int \psi(x)\nu(dx)$ 。

命题 4.2. 考虑原子概率测度 $\alpha_N = \sum_{i=1}^N a_i \delta_{Y^i}$ (其中 $a_i > 0$) 与 $\beta_N = \sum_{i=1}^N b_i \delta_{X^i}$, 二者的支撑均为 $\mathcal{X} \subset \mathbb{R}^d$ 。令 $\tilde{\beta}_N = \sum_{i=1}^N a_i \delta_{\tilde{X}_{N,\epsilon}^i}$, 其中 $\tilde{X}_{N,\epsilon} = \Delta^{-1} P_\epsilon^{\text{OT}} \mathbf{X}$ 、 $\Delta = \text{diag}(a_1, \dots, a_N)$, 并且 P_ϵ^{OT} 是 α_N 与 β_N 间 ϵ 正则最优传输耦合 $\mathcal{P}_\epsilon^{\text{OT},N}$ 对应的传输矩阵。再令 α, β 为另外两个同样支撑在 $\mathcal{X}$ 上的概率测度, 并假设二者间存在唯一的 λ -Lipschitz 最优传输映射 $\mathbf{T}$ 。则对任意有界 1-Lipschitz 函数 ψ ,

$$\begin{aligned} |\beta_N(\psi) - \tilde{\beta}_N(\psi)| &\leq 2\lambda^{1/2} \mathcal{E}^{1/2} [\mathfrak{d}^{1/2} + \mathcal{E}]^{1/2} \\ &\quad + \max\{\lambda, 1\} [\mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta)], \end{aligned} \quad (15)$$

其中 $\mathfrak{d} := \sup_{x,y \in \mathcal{X}} |x - y|$, 且

$$\mathcal{E} = \mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta) + \sqrt{2\epsilon \log N}.$$

若 $\mathcal{W}_2(\alpha_N, \alpha), \mathcal{W}_2(\beta_N, \beta) \rightarrow 0$, 并取 $\epsilon_N = o(1/\log N)$, 则(15)中的界随 $N \rightarrow \infty$ 而消失。这里建议的 ϵ 对 N 的依赖来自熵半径; 参见补充材料中的引理 C.1 和文献 [46]。它与熵正则最优传输对 $\mathbf{X}$ 的尺度敏感这一事实密切相关。等价地, 在计算代价矩阵时可将 $\mathbf{X}$ 缩放 $\log N$ 倍。特别地, 当 α_N, β_N 分别是 α, β 的蒙特卡洛近似时, 我们预期以高概率有 $\mathcal{W}_2(\alpha_N, \alpha), \mathcal{W}_2(\beta_N, \beta) = O(N^{-1/d})$ [47]。

4.3 DPF 的相合性

本小节固定参数 θ, ϕ 并从记号中省略它们。我们证明 DPF 的相合性: 所得 $\beta^{(t)} = p(x_t|y_{1:t})$ 的粒子近似 $\tilde{\beta}_N^{(t)} = \frac{1}{N} \sum_{i=1}^N \delta_{\tilde{X}_i^{(t)}}$ 是相合的, 相应的 $\log p(y_{1:T})$ 的对数似然近似 $\log \hat{p}_N(y_{1:T})$ 也是相合的。为简化讨论, 我们只研究提议分布等于转移分布 $q = f$ 的情形, 此时 $\omega(x_{t-1}, x_t, y_t) = g(y_t|x_t)$; 这称为 bootstrap 粒子滤波。我们具体研究文献 [48] 提出的一个略非标准版本, 细节见 Appendix D。

相合性在补充材料所列正则假设下成立。假设 B.1 要求空间 $\mathcal{X} \subset \mathbb{R}^d$ 具有有限直径 $\mathfrak{d}$ 。假设 B.2 蕴含提议分布在 Wasserstein 意义下以速率 κ 指数混合; 考虑到紧致性, 这一条件是合理的, 也是防止误差累积所必需的。假设 B.3 要求重要性权重函数有界, 即 $g(y_t|x_t) \in [\Delta, \Delta^{-1}]$; 在紧致性下, 这同样并非不合理。假设 B.4 规定, 每个时刻 $\alpha^{(t)}$ 与 $\beta^{(t)}$ 间的最优传输问题都由一个确定性的全局 Lipschitz 映射唯一求解。唯一性对下一命题的定量稳定性结果至关重要。

命题 4.3. 在假设 B.1 to B.4 成立时, 对任意 $\delta > 0$, 关于采样步骤以至少 $1 - 2\delta$ 的概率, 对任意有界 1-Lipschitz 函数 ψ 和任意 $t \in [1 : T]$, bootstrap DPF 所计算的滤波分布近似和对数似然近似满足

$$\begin{aligned} \left| \tilde{\beta}_N^{(t)}(\psi) - \beta^{(t)}(\psi) \right| &\leq \mathfrak{G}_{\epsilon, \delta/T, N, d}^{(t)}(\lambda(c, C, d, T, N, \delta)), \\ \left| \log \frac{\hat{p}_N(y_{1:T})}{p(y_{1:T})} \right| &\leq \frac{\kappa}{\Delta} \max_{t \in [1:T]} \text{Lip}[g(y_t | \cdot)] \\ &\quad \times \sum_{t=1}^T \mathfrak{G}_{\epsilon, \delta/T, N, d}^{(t)}(\lambda(c, C, d, T, N, \delta)), \end{aligned}$$

其中

$$\lambda(c, C, d, T, N, \delta) = \sqrt{f_d^{-1}\left(\frac{\log(CT/\delta)}{cN}\right)}.$$

c, C 是与 T 无关的有限常数, $\text{Lip}[f]$ 表示函数 f 的 Lipschitz 常数; $\mathfrak{G}_{N, \epsilon}^{(t)}$ 与 f_d 是 Appendix D 所定义的两个函数。若取 $\epsilon_N = o(1/\log N)$, 则依概率有

$$\left| \tilde{\beta}_N^{(t)}(\psi) - \beta^{(t)}(\psi) \right| \rightarrow 0, \quad \left| \log \frac{\hat{p}_N(y_{1:T})}{p(y_{1:T})} \right| \rightarrow 0.$$

上述界显然并不尖锐。仔细考察补充材料中命题 D.1 所涉及的量, 可以初步了解这些界关于 T 的行为。特别地, 当 κ 足够小时, 结果表明对数似然估计误差的界随 T 线性增长, 这与混合假设下的标准粒子滤波一致。还可得到更尖锐的界, 例如使用文献 [45] 定理 3.5 的 L_1 版本。放宽假设同样值得研究, 尤其是移除有界空间假设; 不过, 为得到定量界, 粒子滤波文献常采用这一假设, 参见文献 [3, 8]。上述表达式没有明确显示, 界对状态维数 d_x 存在指数依赖; 但这是不可避免的, 也是粒子滤波方法的已知局限。

最后需指出, 与标准粒子滤波不同, DPF 给出的是有偏似然估计。因此无法保证其对数的期望

$$\ell_\epsilon^{\text{ELBO}}(\theta, \phi) := \mathbb{E}_U[\hat{\ell}_\epsilon(\theta; \phi, \mathbf{U})]$$

确实是合法 ELBO。不过在我们的全部实验中 (例如小节 5.1), $|\ell_\epsilon^{\text{ELBO}}(\theta, \phi) - \ell^{\text{ELBO}}(\theta, \phi)|$ 都显著小于 $\ell(\theta) - \ell^{\text{ELBO}}(\theta, \phi)$, 因而 $\ell_\epsilon^{\text{ELBO}}(\theta, \phi) < \ell(\theta)$ 。据此, 我们仍沿用 ELBO 这一术语。

5 实验

在小节 5.1 中, 我们评估 DPF 对正则化参数 ϵ 的敏感性。本文其余 DPF 实验均采用算法 3 所述的 DET 重采样, 并取 $\epsilon = 0.5$; 该取值既能保证梯度计算稳定, 又只会在相对于标准粒子滤波计算 ELBO 时引入很小偏差。我们分别用 PyTorch 和 TensorFlow 实现了该方法; 复现实验的代码及更多实验见 <https://github.com/JTT94/filterflow>。

5.1 线性高斯状态空间模型

首先考虑一个简单的二维线性高斯状态空间模型，其精确似然可由 Kalman 滤波器计算：

$$X_{t+1}|\{X_t = x\} \sim \mathcal{N}(\text{diag}(\theta_1, \theta_2)x, 0.5\mathbf{I}_2),$$

$$Y_t|\{X_t = x\} \sim \mathcal{N}(x, 0.1\mathbf{I}_2).$$

我们用 $\theta = (\theta_1, \theta_2) = (0.5, 0.5)$ 模拟 $T = 150$ 个观测，并分别在 $\theta = (0.25, 0.25)$ 、 $\theta = (0.5, 0.5)$ 和 $\theta = (0.75, 0.75)$ 处评估 ELBO。更具体地，使用 $N = 25$ 个粒子的标准粒子滤波器，在 $\mathbf{U}$ 的 100 次实现上计算 $\frac{1}{T}(\hat{\ell}(\theta; \mathbf{U}) - \ell(\theta))$ 的均值和标准差。该均值估计 ELBO 与真实对数似然之差（再乘以 $1/T$ ）。随后，我们用相同粒子数，分别取 $\epsilon = 0.25, 0.5, 0.75$ ，对 DPF 重复计算。

如小节 3.2 and 4.3 所述，DET 重采样仅在 ψ 为仿射函数时满足(2)，因此 DPF 给出的是有偏似然估计，不能保证相应对数似然估计的期望是严格意义上的 ELBO。不过从表 1 可见，对三种 ϵ ，PF 与 DPF 所计算 ELBO 估计之间的差异均可忽略；两者对数似然估计的标准差也很接近。

表 1. $\frac{1}{T}(\hat{\ell}(\theta; \mathbf{U}) - \ell(\theta))$ 的均值与标准差

θ_1, θ_2		0.25	0.5	0.75
PF	均值	-1.13	-0.93	-1.05
	标准差	0.20	0.18	0.17
DPF ($\epsilon = 0.25$)	均值	-1.14	-0.94	-1.07
	标准差	0.20	0.18	0.19
DPF ($\epsilon = 0.5$)	均值	-1.14	-0.94	-1.08
	标准差	0.20	0.18	0.18
DPF ($\epsilon = 0.75$)	均值	-1.14	-0.94	-1.08
	标准差	0.20	0.18	0.18

这里还需指出，也可以用粒子平滑算法近似(14)，以估计得分向量 $\nabla_{\theta}\ell(\theta)$ [1,33]，进而估计 θ 。

5.2 学习提议分布

我们考虑与文献 [11] 相似的例子：对如下线性高斯状态空间模型，用 ELBO 学习提议分布的参数 ϕ ：

$$X_{t+1}|\{X_t = x\} \sim \mathcal{N}(\mathbf{A}x, \mathbf{I}_{d_x}), \quad (16)$$

$$Y_t|\{X_t = x\} \sim \mathcal{N}(\mathbf{I}_{d_y, d_x}x, \mathbf{I}_{d_y}), \quad (17)$$

其中 $\mathbf{A} = (0.42^{|i-j|+1})_{1 \leq i, j \leq d_x}$; $\mathbf{I}_{d_y, d_x}$ 是 $d_y \times d_x$ 矩阵, 其前 d_y 行的对角元为 1, 其余元素为 0。对 $\phi \in \mathbb{R}^{d_x+d_y}$, 考虑

$$q_\phi(x_t|x_{t-1}, y_t) = \mathcal{N}(x_t | \Delta_\phi^{-1}(\mathbf{A}x_{t-1} + \Gamma_\phi y_t), \Delta_\phi),$$

其中 $\Delta_\phi = \text{diag}(\phi_1, \dots, \phi_{d_x})$, $\Gamma_\phi = \text{diag}_{d_x, d_y}(\phi_1, \dots, \phi_{d_x})$ 是 $d_x \times d_y$ 矩阵: 前 d_x 行的对角元为 ϕ_i , 其余元素为 0。文献 [49] 中的局部最优提议 $p(x_t|x_{t-1}, y_t) \propto g(y_t|x_t)f(x_t|x_{t-1})$ 对应于 $\phi = \mathbf{1}$, 即维数 $d_\phi = d_x + d_y$ 的全 1 向量。

取 $d_x = 25, d_y = 1$, 按 (16)–(17) 生成 $M = 100$ 组长度为 $T = 100$ 的观测。在每组数据上, 我们用学习率 0.1 进行 100 步随机梯度上升来学习 ϕ 。一方面, 用标准粒子滤波器和文献 [9, 10, 11] 所述有偏梯度优化 $\ell^{\text{ELBO}}(\phi)$; 另一方面, 用四个相互独立的 DPF 优化 $\ell^{\text{ELBO}}(\phi)$ 。为匹配计算复杂度, 标准粒子滤波使用 $N = 500$, DPF 使用 $N = 25$ 。虽然不能保证 $p(x_t|x_{t-1}, y_t)$ 使 ELBO 最大, 但实验表明它优于优化所得的提议。因此, 我们以 $\phi = \mathbf{1}$ 的均方根误差 (RMSE) 和平均有效样本量 (ESS) [49] 作为代理性能指标。DPF 在两个指标上均优于标准粒子滤波: 100 次实验的 RMSE, DPF 为 0.11, 标准粒子滤波为 0.22; 收敛后的平均 ESS, DPF 约为 60%, 标准粒子滤波约为 25%。两种方法每次迭代平均都约需 15 秒。

5.3 变分循环神经网络 (VRNN)

VRNN 是文献 [50] 提出的一种状态空间模型。它在 LSTM (长短期记忆网络) 的隐藏状态中加入随机分量, 从而将变分自编码器推广到序列情形。令隐状态 $X_t = (R_t, Z_t)$, 其中 R_t 是 RNN 状态, Z_t 是潜在高斯变量; Y_t 是二值观测向量。具体模型如下。RNN $_\theta$ 表示 LSTM 单元的前向调用: 在时刻 t 输出下一 RNN 状态 R_{t+1} 和输出 O_{t+1} 。 $E_\theta, h_\theta, \mu_\theta, \sigma_\theta$ 均为全连接神经网络, 完整细节见补充材料。

我们在复调音乐基准数据集 [51] 上训练该模型, 其中 Y_t 表示当前激活的音符。每个数据集的观测序列截断到长度 150, 每个观测的维数为 88。取潜在状态维数 $d_z = 8$ 、RNN 状态维数 $d_r = 16$, 故 $d_x = 24$ 。采用 $q_\phi(x_t|x_{t-1}, y_t) = f_\theta(x_t|x_{t-1})$:

$$\begin{aligned} (R_{t+1}, O_{t+1}) &= \text{RNN}_\theta(R_t, Y_{1:t}, E_\theta(Z_t)), \\ Z_{t+1} &\sim \mathcal{N}(\mu_\theta(O_{t+1}), \sigma_\theta(O_{t+1})), \\ \hat{p}_{t+1} &= h_\theta(E_\theta(Z_{t+1}), O_{t+1}), \\ Y_t|X_t &\sim \text{Ber}(\hat{p}_t). \end{aligned}$$

VRNN 模型通过 DPF 最大化 $\ell_\epsilon^{\text{ELBO}}(\theta)$ 来训练。我们将其与两种训练方式比较: 用标准粒子滤波计算 $\ell^{\text{ELBO}}(\theta)$ 并最大化 [10]; 以及采用文献 [21] 提出、小节 1.3 介绍的“软重采样” (SPF) 训练。这里 SPF 取 $\alpha = 0.1$ 。与常规重采样不同, SPF 在重采样步骤中部分保留梯度; 但它仍包含不可微操作, 所得梯度仍然有偏。由于重采样后的近似并非等权, SPF 还会产生更高方差的估计; 它实质上在 PF 与 IWAE 之间插值。

三种方法均使用 $N = 32$ 个粒子。虽然 DET 的计算成本高于其他重采样方案, 但主要复杂度来

表 2. 在测试数据上评估的 ELBO $\pm$ 标准差

	MuseData	JSB	Nottingham
DPF	$-7.59_{\pm 0.01}$	$-7.67_{\pm 0.08}$	$-3.79_{\pm 0.02}$
PF	$-7.60_{\pm 0.06}$	$-7.92_{\pm 0.13}$	$-3.81_{\pm 0.02}$
SPF	$-7.73_{\pm 0.14}$	$-8.17_{\pm 0.07}$	$-3.91_{\pm 0.05}$

自神经网络运算, 因此 DPF、PF 与 SPF 的实际计算时间很接近。随后, 统一采用多项式重采样在测试数据上评估所学模型, 以获得可比较的 ELBO 结果。由于观测模型为 $\text{Ber}(\hat{p}_t)$, 该指标对应于负的对数预测交叉熵。

表 2 展示了在 JSB 数据集上 DPF 相对于标准 PF 和 SPF 的优势。在其余数据集上, DPF 与其他启发式方法相比仍具竞争力, 但差异较小。我们推测, 启发式方法之所以能取得这种表现, 可能是因为给定前一观测后, 下一观测的预测不确定性较低。

5.4 机器人定位

考虑迷宫中的机器人 (或智能体) [21, 24]。给定智能体初始状态 S_1 和输入 a_t , 希望根据观测 O_t 推断任意时刻的智能体位置。令隐状态 $S_t = (X_t^{(1)}, X_t^{(2)}, \gamma_t)$, 其中 $(X_t^{(1)}, X_t^{(2)})$ 是位置坐标, γ_t 是机器人朝向。在本文设置中, 观测 O_t 为图像; 神经网络 E_θ 对其编码以提取有用特征, 即 $Y_t = E_\theta(O_t)$ 。该问题需要学习机器人位置、朝向和观测之间的关系。给定动作 $a_t = (v_t^{(1)}, v_t^{(2)}, \omega_t)$, 有

$$\begin{aligned} S_{t+1} &= F_\theta(S_t, a_t) + \nu_t, & \nu_t &\stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mathbf{0}, \Sigma_F), \\ Y_t &= G_\theta(S_t) + \epsilon_t, & \epsilon_t &\stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mathbf{0}, \sigma_G^2 \mathbb{I}_{e_d}), \end{aligned}$$

其中 $\Sigma_F = \text{diag}(\sigma_x^2, \sigma_x^2, \sigma_\theta^2)$, 状态 S_t 与图像编码 Y_t 之间的关系由另一个神经网络 G_θ 参数化。动力学采用如下简单模型:

$$F(S_t, a_t) = \begin{bmatrix} X_t^{(1)} + v_t^{(1)} \cos(\gamma_t) + v_t^{(2)} \sin(\gamma_t) \\ X_t^{(2)} + v_t^{(1)} \sin(\gamma_t) - v_t^{(2)} \cos(\gamma_t) \\ \gamma_t + \omega_t \end{bmatrix}.$$

D_θ 表示将编码映射回原图像的解码神经网络。训练 $E_\theta, G_\theta, D_\theta$ 时, 损失函数由粒子滤波估计的负对数似然 $\hat{\mathcal{L}}_{\text{PF}}$ 、基于粒子滤波的均方误差 $\hat{\mathcal{L}}_{\text{MSE}}$ 和自编码器损失 $\hat{\mathcal{L}}_{\text{AE}}$ 组成; 按照文献 [52], 每个批次的损失为

$$\begin{aligned} \hat{\mathcal{L}}_{\text{MSE}} &:= \frac{1}{T} \sum_{t=1}^T \left\| X_t^* - \sum_{i=1}^N w_t^i X_t^i \right\|^2, & \hat{\mathcal{L}}_{\text{PF}} &:= -\frac{1}{T} \hat{\ell}(\theta), \\ \hat{\mathcal{L}}_{\text{AE}} &:= \sum_{t=1}^T \|D_\theta(E_\theta(O_t)) - O_t\|^2. \end{aligned}$$

其中 X_t^* 是训练数据中可获得真实状态, $\sum_{i=1}^N w_t^i X_t^i$ 是 $\mathbb{E}[X_t|y_{1:t}]$ 的粒子滤波估计。自编码器(重构)损失 $\hat{\mathcal{L}}_{\text{AE}}$ 保证编码器含有信息, 并避免 G_θ, E_θ 都映射到常数。采用传统重采样时, 基于粒子滤波的损失项 $\hat{\mathcal{L}}_{\text{MSE}}$ 和 $\hat{\mathcal{L}}_{\text{PF}}$ 关于 θ 不可微。




图 2. 左: 粒子 $(X_t^{(1),i}, X_t^{(2),i})$ (绿色)、 $\mathbb{E}[X_t|y_{1:t}]$ 的粒子滤波估计 (蓝色) 和真实状态 X_t^* (红色)。右: 观测 O_t 。

表 3. 测试数据上的 MSE $\pm$ 标准差; 越低越好

	迷宫 1	迷宫 2	迷宫 3
DPF	3.55$\pm$0.20	4.65$\pm$0.50	4.44$\pm$0.26
PF	10.71 $\pm$ 0.45	11.86 $\pm$ 0.57	12.88 $\pm$ 0.65
SPF	9.14 $\pm$ 0.39	10.12 $\pm$ 0.40	11.42 $\pm$ 0.37

我们采用文献 [24] 的设置和 DeepMind Lab 数据 [53], 其中包含 3 个大小不同的迷宫布局。每个迷宫都有一条长度为 1,000 步的“真实”轨迹; 每一步都具有上文所述的状态、动作和观测图像。视觉观测 O_t 是 32×32 RGB 像素图像, 压缩为 24×24 , 如图 2 所示。每次训练迭代都随机抽取带噪声的定长子序列。为体现本文方法的优势, 我们将子序列长度设为 50, 而文献 [24] 采用 20。学习率、训练步数及 $E_\theta, G_\theta, D_\theta$ 的神经网络结构等训练细节见附录。

我们将 DPF 与文献 [10] 采用的标准 PF, 以及文献 [21,22,23] 采用的软 PF (SPF) 比较; SPF 的软重采样参数取 $\alpha = 0.1$ 。由于大部分计算复杂度来自神经网络运算, DPF、SPF 和 PF 的总体计算成本相近。如表 3 and 图 3 所示, 在该实验中 DPF 显著优于此前研究的粒子滤波方法。对更长序列, 重采样和加权使观测模型愈发重要。事实上, 从图 4 可见, 两种模型在序列开始阶段误差都很小, 但在序列后段, 用 DPF 训练的模型误差明显更小。




图 3. 训练过程中在测试数据上评估的 PF（红色）、SPF（绿色）和 DPF（蓝色）估计的 MSE。




图 4. 示例：测试数据中一条 50 步轨迹上的粒子滤波路径估计与真实路径（黑色）的比较。

6 讨论

本文提出首个有原则依据、可使用一般提议分布的完全可微粒子滤波器 (DPF)。它给出对数似然函数的可微估计, 并可更一般地给出基于粒子滤波的损失的可微估计, 从而允许通过端到端梯度优化推断状态空间模型和提议分布的参数。它还使粒子滤波程序能够嵌入一般的可微编程流水线, 特别是可作为概率编程语言中用于推断的可微采样方法 [54,55,56]。

给定粒子数 N , 忽略重采样梯度项的现有粒子滤波方法复杂度为 $O(N)$ 。然而, 采用这类重采样方案的训练并不可靠; 由于梯度估计不相合且极限偏差可能很大, 增大 N 也不能改善性能。DPF 的训练复杂度为 $O(N^2)$, 但在训练大型神经网络时, 这部分开销通常相形见绌。此外, 模型训练完成后, 仍可用复杂度为 $O(N)$ 的标准粒子滤波运行。实验结果证实了 DPF 的优势: 即使使用相同计算预算, 它仍优于现有技术。近期工作还提出了加速 Sinkhorn 算法的方法 [57,58]; 该算法是 DPF 的核心, 因而这些方法有望进一步降低 DPF 的复杂度。

实验中我们没有细调正则化参数 ϵ 。未来若能得到更尖锐的 DPF 定量界, 便可为选择 ϵ 提供有原则的指导, 并进一步提高性能。最后, 本文聚焦于利用可微集合变换构造可微重采样方案, 但也可研究其他最优传输方法, 例如文献 [59] 二阶集合变换的可微版本、依赖 Sinkhorn 散度 [60] 或切片 Wasserstein 度量的点云优化技术 [34,43]。其他非熵正则化, 例如近期提出的高斯平滑最优传输 [61], 也可能产生值得研究的 DPF。

致谢

Adrien Corenflos 得到芬兰科学院项目 321900 和 321891 的资助。Arnaud Doucet 得到英国工程与自然科学研究理事会 CoSInES (COmputational Statistical INference for Engineering and Security) 项目 EP/R034710/1 的资助; James Thornton 得到 OxWaSP 博士训练中心项目 EP/L016710/1 的资助。计算资源由 Google Cloud Research Credits Programme 提供。作者感谢 Valentin De Bortoli 和 Yuyang Shi 的意见, 并感谢 Laurence Aitchison 提醒作者关注文献 [20]。

参考文献

- [1] Nikolas Kantas, Arnaud Doucet, Sumeetpal S Singh, Jan Maciejowski, and Nicolas Chopin. On particle methods for parameter estimation in state-space models. *Statistical Science*, 30(3):328–351, 2015.
- [2] Nicolas Chopin and Omiros Papaspiliopoulos. *An Introduction to Sequential Monte Carlo*. Springer, 2020.
- [3] Randal Douc, Eric Moulines, and David Stoffer. *Nonlinear Time Series: Theory, Methods and Applications with R Examples*. CRC press, 2014.
- [4] Arnaud Doucet and Anthony Lee. Sequential Monte Carlo methods. *Handbook of Graphical Models*, pages 165–189, 2018.
- [5] Genshiro Kitagawa and Will Gersch. *Smoothness Priors Analysis of Time Series*, volume 116. Springer Science & Business Media, 1996.
- [6] Fredrik Lindsten and Thomas B Schön. Backward simulation methods for Monte Carlo statistical inference. *Foundations and Trends® in Machine Learning*, 6(1):1–143, 2013.
- [7] Sebastian Thrun, Wolfram Burgard, and Dieter Fox. *Probabilistic Robotics*. MIT Press, 2005.
- [8] Pierre Del Moral. *Feynman-Kac Formulae*. Springer, 2004.
- [9] Tuan Anh Le, Maximilian Igl, Tom Rainforth, Tom Jin, and Frank Wood. Auto-encoding sequential Monte Carlo. In *International Conference on Learning Representations*, 2018.
- [10] Chris J Maddison, Dietrich Lawson, George Tucker, Nicolas Heess, Mohammad Norouzi, Andriy Mnih, Arnaud Doucet, and Yee Whye Teh. Filtering variational objectives. In *Advances in Neural Information Processing Systems*, 2017.
- [11] Christian A Naesseth, Scott W Linderman, Rajesh Ranganath, and David M Blei. Variational sequential Monte Carlo. In *International Conference on Artificial Intelligence and Statistics*, 2018.
- [12] Diederik P Kingma and Max Welling. Auto-encoding variational Bayes. In *International Conference on Learning Representations*, 2014.
- [13] Sheheryar Malik and Michael K Pitt. Particle filters for continuous likelihood evaluation and maximisation. *Journal of Econometrics*, 165(2):190–209, 2011.
- [14] Anthony Lee. Towards smooth particle filters for likelihood estimation with multivariate latent variables. Master’s thesis, University of British Columbia, 2008.

- [15] David N DeJong, Roman Liesenfeld, Guilherme V Moura, Jean-François Richard, and Hariharan Dharmarajan. Efficient likelihood evaluation of state-space representations. *Review of Economic Studies*, 80(2):538–567, 2013.
- [16] Mike Klaas, Nando De Freitas, and Arnaud Doucet. Toward practical N^2 Monte Carlo: the marginal particle filter. *Uncertainty in Artificial Intelligence*, 2005.
- [17] Lawrence M Murray, Emlyn M Jones, and John Parslow. On disturbance state-space models and the particle marginal Metropolis–Hastings sampler. *SIAM/ASA Journal on Uncertainty Quantification*, 1(1):494–521, 2013.
- [18] Alex Graves. Stochastic backpropagation through mixture density distributions. *arXiv preprint arXiv:1607.05690*, 2016.
- [19] Axel Finke, Arnaud Doucet, and Adam M Johansen. On embedded hidden Markov models and particle Markov chain Monte Carlo methods. *arXiv preprint arXiv:1610.08962*, 2016.
- [20] Laurence Aitchison. Tensor Monte Carlo: particle methods for the GPU era. *Advances in Neural Information Processing Systems*, 2019.
- [21] Peter Karkus, David Hsu, and Wee Sun Lee. Particle filter networks with application to visual localization. In *Conference on Robot Learning*, 2018.
- [22] Xiao Ma, Peter Karkus, David Hsu, and Wee Sun Lee. Particle filter recurrent neural networks. In *AAAI Conference on Artificial Intelligence*, 2020.
- [23] Xiao Ma, Peter Karkus, Nan Ye, David Hsu, and Wee Sun Lee. Discriminative particle filter reinforcement learning for complex partial observations. In *International Conference on Learning Representations*, 2020.
- [24] Rico Jonschkowski, Divyam Rastogi, and Oliver Brock. Differentiable particle filters: End-to-end learning with algorithmic priors. In *Proceedings of Robotics: Science and Systems*, 2018.
- [25] Michael Zhu, Kevin Murphy, and Rico Jonschkowski. Towards differentiable resampling. *arXiv preprint arXiv:2004.11938*, 2020.
- [26] Alina Kloss, Georg Martius, and Jeannette Bohg. How to train your differentiable filter. *arXiv preprint arXiv:2012.14313*, 2020.
- [27] Evan Archer, Il Memming Park, Lars Buesing, John Cunningham, and Liam Paninski. Black box variational inference for state space models. *arXiv preprint arXiv:1511.07367*, 2015.
- [28] Rahul G Krishnan, Uri Shalit, and David Sontag. Structured inference networks for nonlinear state space models. In *AAAI Conference on Artificial Intelligence*, pages 2101–2109, 2017.

- [29] Syama Sundar Rangapuram, Matthias W Seeger, Jan Gasthaus, Lorenzo Stella, Yuyang Wang, and Tim Januschowski. Deep state space models for time series forecasting. In *Advances in Neural Information Processing Systems*, pages 7785–7794, 2018.
- [30] Ronald J Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3-4):229–256, 1992.
- [31] Marcel Hirt and Petros Dellaportas. Scalable Bayesian learning for state space models using variational inference with SMC samplers. In *International Conference on Artificial Intelligence and Statistics*, pages 76–86, 2019.
- [32] Yuri Burda, Roger B Grosse, and Ruslan Salakhutdinov. Importance weighted autoencoders. In *International Conference on Learning Representations*, 2016.
- [33] George Poyiadjis, Arnaud Doucet, and Sumeetpal S Singh. Particle approximations of the score and observed information matrix in state space models with application to parameter estimation. *Biometrika*, 98(1):65–80, 2011.
- [34] Gabriel Peyré and Marco Cuturi. Computational optimal transport. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607, 2019.
- [35] Cédric Villani. *Optimal Transport: Old and New*, volume 338. Springer Science & Business Media, 2008.
- [36] Sebastian Reich. A nonparametric ensemble transform method for Bayesian inference. *SIAM Journal on Scientific Computing*, 35(4):A2013–A2024, 2013.
- [37] Aaron Myers, Alexandre H. Thiery, Kainan Wang, and Tan Bui-Thanh. Sequential ensemble transform for Bayesian inverse problems. *Journal of Computational Physics*, 427:110055, 2021.
- [38] Dimitris Bertsimas and John N Tsitsiklis. *Introduction to Linear Optimization*. Athena Scientific Belmont, MA, 1997.
- [39] Marco Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. In *Advances in Neural Information Processing Systems*, pages 2292–2300, 2013.
- [40] Jean Feydy, Thibault Séjourné, François-Xavier Vialard, Shun-Ichi Amari, Alain Trounev, and Gabriel Peyré. Interpolating between optimal transport and MMD using Sinkhorn divergences. In *International Conference on Artificial Intelligence and Statistics*, 2019.
- [41] Rémi Flamary, Marco Cuturi, Nicolas Courty, and Alain Rakotomamonjy. Wasserstein discriminant analysis. *Machine Learning*, 107(12):1923–1945, 2018.

- [42] Jason Altschuler, Jonathan Niles-Weed, and Philippe Rigollet. Near-linear time approximation algorithms for optimal transport via Sinkhorn iteration. In *Advances in Neural Information Processing Systems*, pages 1964–1974, 2017.
- [43] Marco Cuturi and Arnaud Doucet. Fast computation of Wasserstein barycenters. In *International Conference on Machine Learning*, pages 685–693, 2014.
- [44] Vivien Seguy, Bharath Bhushan Damodaran, Rémi Flamary, Nicolas Courty, Antoine Rolet, and Mathieu Blondel. Large-scale optimal transport and mapping estimation. In *International Conference on Learning Representations*, 2018.
- [45] Wenbo Li and Ricardo H. Nochetto. Quantitative stability and error estimates for optimal transport plans. *IMA Journal of Numerical Analysis*, 2021.
- [46] Jonathan Weed. An explicit analysis of the entropic penalty in linear programming. In *Proceedings of the 31st Conference On Learning Theory*, 2018.
- [47] Nicolas Fournier and Arnaud Guillin. On the rate of convergence in Wasserstein distance of the empirical measure. *Probability Theory and Related Fields*, 162(3):707–738, 2015.
- [48] Pierre Del Moral and Alice Guionnet. On the stability of interacting processes with applications to filtering and genetic algorithms. In *Annales de l’Institut Henri Poincaré (B) Probability and Statistics*, volume 37, pages 155–194, 2001.
- [49] Arnaud Doucet and Adam M Johansen. A tutorial on particle filtering and smoothing: Fifteen years later. *Handbook of Nonlinear Filtering*, 12:656–704, 2009.
- [50] Junyoung Chung, Kyle Kastner, Laurent Dinh, Kratarth Goel, Aaron C Courville, and Yoshua Bengio. A recurrent latent variable model for sequential data. In *Advances in Neural Information Processing Systems*, pages 2980–2988, 2015.
- [51] Nicolas Boulanger-Lewandowski, Yoshua Bengio, and Pascal Vincent. Modeling temporal dependencies in high-dimensional sequences: Application to polyphonic music generation and transcription. In *International Conference on Machine Learning*, pages 1881–1888, 2012.
- [52] Hao Wen, Xiongjie Chen, Georgios Papagiannis, Conghui Hu, and Yunpeng Li. End-to-end semi-supervised learning for differentiable particle filters. *arXiv preprint arXiv:2011.05748*, 2020.
- [53] Charles Beattie, Joel Z. Leibo, Denis Teplyashin, Tom Ward, Marcus Wainwright, Heinrich Küttler, Andrew Lefrancq, Simon Green, Víctor Valdés, Amir Sadik, Julian Schrittwieser, Keith Anderson, Sarah York, Max Cant, Adam Cain, Adrian Bolton, Stephen Gaffney, Helen King, Demis Hassabis, Shane Legg, and Stig Petersen. DeepMind Lab, 2016.

- [54] Joshua V. Dillon, Ian Langmore, Dustin Tran, Eugene Brevdo, Srinivas Vasudevan, Dave Moore, Brian Patton, Alex Alemi, Matt Hoffman, and Rif A. Saurous. Tensorflow distributions. *arXiv preprint arXiv:1711.10604*, 2017.
- [55] Hong Ge, Kai Xu Xu, and Zoubin Ghahramani. Turing: A language for flexible probabilistic inference. In *International Conference on Artificial Intelligence and Statistics*, pages 1682–1690, 2018.
- [56] Jan-Willem van de Meent, Brooks Paige, Yang Hongseok, and Frank Wood. An introduction to probabilistic programming. *arXiv preprint arXiv:1809.10756*, 2018.
- [57] Jason Altschuler, Francis Bach, Alessandro Rudi, and Jonathan Niles-Weed. Massively scalable Sinkhorn distances via the Nyström method. In *Advances in Neural Information Processing Systems*, pages 4429–4439, 2019.
- [58] Meyer Scetbon and Marco Cuturi. Linear time Sinkhorn divergences using positive features. In *Advances in Neural Information Processing Systems*, 2020.
- [59] Walter Acevedo, Jana de Wiljes, and Sebastian Reich. Second-order accurate ensemble transform particle filters. *SIAM Journal on Scientific Computing*, 39(5):A1834–A1850, 2017.
- [60] Aude Genevay, Gabriel Peyré, and Marco Cuturi. Learning generative models with Sinkhorn divergences. In *International Conference on Artificial Intelligence and Statistics*, pages 1608–1617, 2018.
- [61] Ziv Goldfeld and Kristjan Greenewald. Gaussian-smooth optimal transport: Metric structure and statistical efficiency. *arXiv preprint arXiv 2001.09206*, 2020.

A 渐近 ELBO 梯度命题的证明

采用多项式重采样的粒子滤波器由如下联合分布定义：

$$\bar{q}_{\theta,\phi}(x_{1:T}^{1:N}, a_{1:T-1}^{1:N}) = \prod_{i=1}^N q_{\phi}(x_1^i) \prod_{t=2}^T \prod_{i=1}^N w_{t-1}^{a_{t-1}^i} q_{\phi}(x_t^i | x_{t-1}^{a_{t-1}^i}),$$

其中 $a_{t-1}^i \in \{1, \dots, N\}$ 是粒子 x_t^i 的祖先索引，并且

$$\omega_{\theta,\phi}(x_1, y_1) = \frac{p_{\theta}(x_1, y_1)}{q_{\phi}(x_1)}, \quad \omega_{\theta,\phi}(x_{t-1}, x_t, y_t) = \frac{p_{\theta}(x_t, y_t | x_{t-1})}{q_{\phi}(x_t | x_{t-1})}.$$

最后， $w_t^i \propto \omega_{\theta,\phi}(x_{t-1}^{a_{t-1}^i}, x_t^i, y_t)$ ，且 $\sum_{i=1}^N w_t^i = 1$ 。为简化记号，我们没有特别标出权重 $w_{t-1}^{a_{t-1}^i}$ 对 θ, ϕ 和观测的依赖。

ELBO 为

$$\begin{aligned} \ell^{\text{ELBO}}(\theta, \phi) &= \mathbb{E}_{\bar{q}_{\theta,\phi}}[\log \hat{p}_{\theta}(y_{1:T})] \\ &= \mathbb{E}_{\bar{q}_{\theta,\phi}} \left[\log \left(\frac{1}{N} \sum_{i=1}^N \omega_{\theta,\phi}(X_1^i, y_1) \right) + \sum_{t=2}^T \log \left(\frac{1}{N} \sum_{i=1}^N \omega_{\theta,\phi}(X_{t-1}^{A_{t-1}^i}, X_t^i, y_t) \right) \right]. \end{aligned}$$

下面计算 $\nabla_{\theta} \ell^{\text{ELBO}}(\theta, \phi)$ 。与文献 [9, 10, 11] 一样，以下假设允许交换期望和微分算子的正则条件成立。利用乘积法则拆分梯度，再应用对数导数技巧，得到

$$\begin{aligned} \nabla_{\theta} \ell^{\text{ELBO}}(\theta, \phi) &= \mathbb{E}_{\bar{q}_{\theta,\phi}} [\nabla_{\theta} \log \hat{p}_{\theta}(y_{1:T})] \\ &\quad + \mathbb{E}_{\bar{q}_{\theta,\phi}} \left[\log \hat{p}_{\theta}(y_{1:T}) \nabla_{\theta} \log \bar{q}_{\theta,\phi}(X_{1:T}^{1:N}, A_{1:T-1}^{1:N}) \right] \\ &= \mathbb{E}_{\bar{q}_{\theta,\phi}} \left[\nabla_{\theta} \log \left(\frac{1}{N} \sum_{i=1}^N \omega_{\theta,\phi}(X_1^i, y_1) \right) \right. \\ &\quad \left. + \sum_{t=2}^T \nabla_{\theta} \log \left(\frac{1}{N} \sum_{i=1}^N \omega_{\theta,\phi}(X_{t-1}^{A_{t-1}^i}, X_t^i, y_t) \right) \right] \end{aligned} \tag{18}$$

$$+ \mathbb{E}_{\bar{q}_{\theta,\phi}} \left[\log \hat{p}_{\theta}(y_{1:T}) \left\{ \sum_{t=2}^T \sum_{i=1}^N \nabla_{\theta} \log w_{t-1}^{A_{t-1}^i} \right\} \right]. \tag{19}$$

对 ELBO 梯度的第一部分(18)，有

$$\begin{aligned} \nabla_{\theta} \log \left(\frac{1}{N} \sum_{i=1}^N \omega_{\theta,\phi}(X_1^i, y_1) \right) &= \sum_{i=1}^N w_1^i \nabla_{\theta} \log \omega_{\theta,\phi}(X_1^i, y_1) \\ &= \sum_{i=1}^N w_1^i \nabla_{\theta} \log p_{\theta}(X_1^i, y_1), \end{aligned}$$

以及

$$\begin{aligned}
& \nabla_{\theta} \log \left(\frac{1}{N} \sum_{i=1}^N \omega_{\theta, \phi}(X_{t-1}^{A_{t-1}^i}, X_t^i, y_t) \right) \\
&= \sum_{i=1}^N w_t^i \nabla_{\theta} \log \omega_{\theta, \phi}(X_{t-1}^{A_{t-1}^i}, X_t^i, y_t) \\
&= \sum_{i=1}^N w_t^i \nabla_{\theta} \log p_{\theta}(X_t^i, y_t | X_{t-1}^{A_{t-1}^i}).
\end{aligned}$$

因此

$$\begin{aligned}
\nabla_{\theta} \ell^{\text{ELBO}}(\theta, \phi) &= \mathbb{E}_{\bar{q}_{\theta, \phi}} \left[\sum_{i=1}^N w_1^i \nabla_{\theta} \log p_{\theta}(X_1^i, y_1) \right. \\
&\quad \left. + \sum_{t=2}^T \sum_{i=1}^N w_t^i \nabla_{\theta} \log p_{\theta}(X_t^i, y_t | X_{t-1}^{A_{t-1}^i}) \right] \tag{20}
\end{aligned}$$

$$+ \mathbb{E}_{\bar{q}_{\theta, \phi}} \left[\log \hat{p}_{\theta}(y_{1:T}) \left\{ \sum_{t=2}^T \sum_{i=1}^N \nabla_{\theta} \log w_{t-1}^{A_{t-1}^i} \right\} \right]. \tag{21}$$

若按照文献 [9, 10, 11, 31] 的做法, 忽略与 (21) 对应的重采样梯度项, 就只使用第一项 (20) 的如下无偏估计:

$$\begin{aligned}
\hat{\nabla}_{\theta} \ell^{\text{ELBO}}(\theta, \phi) &:= \sum_{i=1}^N w_1^i \nabla_{\theta} \log p_{\theta}(X_1^i, y_1) \\
&\quad + \sum_{t=2}^T \sum_{i=1}^N w_t^i \nabla_{\theta} \log p_{\theta}(X_t^i, y_t | X_{t-1}^{A_{t-1}^i}), \tag{22}
\end{aligned}$$

其中 $(X_{1:T}^{1:N}, A_{1:T-1}^{1:N}) \sim \bar{q}_{\theta, \phi}(\cdot)$ 。

现在假设保证粒子滤波估计几乎必然收敛的温和条件成立 (例如参见文献 [8])。在这些条件下, 当 $N \rightarrow \infty$ 时, 估计量 (22) 几乎必然收敛到

$$\begin{aligned}
& \int \nabla_{\theta} \log p_{\theta}(x_1, y_1) p_{\theta}(x_1 | y_1) dx_1 \\
&+ \sum_{t=2}^T \int \nabla_{\theta} \log p_{\theta}(x_t, y_t | x_{t-1}) p_{\theta}(x_{t-1:t} | y_{1:t-1}) dx_{t-1:t}. \tag{23}
\end{aligned}$$

若再对 $\hat{\nabla}_{\theta} \ell^{\text{ELBO}}(\theta, \phi)$ 施加一致可积条件, 则 $\mathbb{E}_{\bar{q}_{\theta, \phi}}[\hat{\nabla}_{\theta} \ell^{\text{ELBO}}(\theta, \phi)]$ 也收敛到 (23)。另一方面, 由 Fisher 恒等式, 真实得分为

$$\begin{aligned}
& \int \nabla_{\theta} \log p_{\theta}(x_1, y_1) p_{\theta}(x_1 | y_{1:T}) dx_1 \\
&+ \sum_{t=2}^T \int \nabla_{\theta} \log p_{\theta}(x_t, y_t | x_{t-1}) p_{\theta}(x_{t-1:t} | y_{1:T}) dx_{t-1:t}.
\end{aligned}$$

由此完成命题 4.1 的证明。

B 记号与假设

B.1 滤波记号

回顾 $\mathcal{X} = \mathbb{R}^{d_x}$ 。以 $\mathcal{B}(\mathcal{X})$ 表示 $\mathcal{X}$ 的 Borel 集, 以 $\mathcal{P}(\mathcal{X})$ 表示 $(\mathcal{X}, \mathcal{B}(\mathcal{X}))$ 上的 Borel 概率测度集合。我们略微滥用记号, 用同一个符号表示概率测度及其相对于 Lebesgue 测度的密度, 即 $\nu(dx) = \nu(x)dx$ 。对任意测试函数 ψ , 还采用标准记号 $\nu(\psi) = \int \psi(x)\nu(x)dx$ 。为使后续推导的记号更清楚, 在不必要时省略下标 θ, ϕ 。

以 $\{\alpha^{(t)}\}_{t \geq 0}$ 表示预测分布, 其中对 $t > 1$, $\alpha^{(t)}(x_t) = p(x_t|y_{1:t-1})$, 并且 $\alpha^{(1)}(x_1) = \mu(x_1)$; 以 $\{\beta^{(t)}\}_{t \geq 1}$ 表示滤波分布, 即对 $t \geq 1$, $\beta^{(t)}(x_t) = p(x_t|y_{1:t})$ 。采用这些记号, 有

$$\begin{aligned}\alpha^{(t)}(\psi) &= \int \psi(x_t) f(x_t|x_{t-1}) \beta^{(t-1)}(x_{t-1}) dx_{t-1} dx_t := \beta^{(t-1)} f(\psi), \\ \beta^{(t)}(\psi) &= \frac{\alpha^{(t)}(g(y_t|\cdot)\psi)}{\alpha^{(t)}(g(y_t|\cdot))} = \frac{\beta^{(t-1)}(f(g(y_t|\cdot)\psi))}{\beta^{(t-1)}(f(g(y_t|\cdot)))}.\end{aligned}\quad (24)$$

更一般地, 若提议分布 $q(x_t|x_{t-1}, y_t) \neq f(x_t|x_{t-1})$ 且参数 $\phi \neq \theta$, 则有递推式

$$\beta^{(t)}(\psi) = \frac{\beta^{(t-1)}(q(\omega_t\psi))}{\beta^{(t-1)}(q(\omega_t))}, \quad (25)$$

其中

$$\begin{aligned}\omega_t(x_{t-1}, x_t) &:= \omega(x_{t-1}, x_t, y_t) \\ &= \frac{g(y_t|x_t)f(x_t|x_{t-1})}{q(x_t|x_{t-1}, y_t)}.\end{aligned}\quad (26)$$

为简化叙述, 下面只分析 $\phi = \theta$ 且 $q(x_t|x_{t-1}, y_t) = f(x_t|x_{t-1})$ 的情形, 即研究(24); 此时 $\omega_t(x_{t-1}, x_t) = g(y_t|x_t)$ 。在这种情况下, μ 的粒子近似记作 μ_N ; 对 $t > 1$, $\alpha^{(t)}$ 和 $\beta^{(t)}$ 的随机测度近似为

$$\begin{aligned}\alpha_N^{(t)}(\psi) &= \frac{1}{N} \sum_{i=1}^N \psi(X_t^i), & \beta_N^{(t)}(\psi) &= \sum_{i=1}^N w_t^i \psi(X_t^i), \\ \tilde{\beta}_N^{(t)}(\psi) &= \frac{1}{N} \sum_{i=1}^N \psi(\tilde{X}_t^i).\end{aligned}\quad (27)$$

其中 $w_t^i \propto g(y_t|X_t^i)$ 、 $\sum_{i=1}^N w_t^i = 1$, 粒子按 $X_t^i \sim f(\cdot|\tilde{X}_{t-1}^i)$ 抽取。这里, $\beta_N^{(t)}$ 表示 $\beta^{(t)}$ 的加权粒子近似, 而 $\tilde{\beta}_N^{(t)}$ 是经小节 3.2 所述 DET 变换后得到的等权近似。

B.2 最优传输记号

回顾小节 2.1, $\mathcal{P}_t^{\text{OT}}$ 表示 $\alpha^{(t)}$ 与 $\beta^{(t)}$ 之间的传输, 其对应映射为 $\mathbf{T}^{(t)}$ 。 $\mathcal{P}_t^{\text{OT}, N}$ 表示粒子近似 $\alpha_N^{(t)}$ 与 $\beta_N^{(t)}$ 之间的最优传输; 其对应传输矩阵为 $\mathbf{P}^{\text{OT}}$, 第 (i, j) 个元素为 $p_{i,j}^{\text{OT}}$ 。不致混淆时省略上标 t 。

类似地, 由小节 3.1, $\mathcal{P}_\epsilon^{\text{OT}, N}$ 表示 $\alpha_N^{(t)}$ 与 $\beta_N^{(t)}$ 之间的正则化传输; 相应矩阵 $\mathbf{P}_\epsilon^{\text{OT}}$ 的第 (i, j) 个元素为 $p_{\epsilon, i, j}^{\text{OT}}$ 。回顾在 DET 下,

$$\tilde{\beta}_N^{(t)} = \frac{1}{N} \sum_{i=1}^N \delta_{\tilde{X}^i}$$

是 $\beta^{(t)}$ 的等权粒子近似, 其中

$$\tilde{X}^i = \mathbf{T}_{N, \epsilon}^{(t)}(X^i) = \int y \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}y | x^i).$$

与其他重采样方案比较时, 如需消除歧义, 将使用记号 $\tilde{X}_{N, \epsilon}^i$ 。

还需回顾, 对 $p > 0$,

$$\mathcal{W}_p^p(\alpha, \beta) = \min_{\mathcal{P} \in \mathcal{U}(\alpha, \beta)} \mathbb{E}_{(U, V) \sim \mathcal{P}} [\|U - V\|^p], \quad (28)$$

其中 $\mathcal{U}(\alpha, \beta)$ 是以 α, β 为边缘分布的耦合集合。

B.3 假设

本文结果依赖以下四个假设。

假设 B.1. $\mathcal{X} \subset \mathbb{R}^d$ 是紧集, 其直径为

$$\mathfrak{d} := \sup_{x, y \in \mathcal{X}} |x - y|.$$

假设 B.2. 存在 $\kappa \in (0, 1)$, 使得对 $\mathcal{X}$ 上任意两个概率测度 π, ρ ,

$$\mathcal{W}_k(\pi f, \rho f) \leq \kappa \mathcal{W}_k(\pi, \rho), \quad k = 1, 2.$$

假设 B.3. 对所有 t , 权重函数 $\omega^{(t)} : \mathcal{X} \rightarrow [\Delta, \Delta^{-1}]$ 均为 1-Lipschitz。

假设 B.4. 存在 $\lambda > 0$, 使得对所有 $t \geq 0$, $\alpha^{(t)}$ 与 $\beta^{(t)}$ 之间唯一的最优传输方案均由确定性的 λ -Lipschitz 映射 $\mathbf{T}^{(t)}$ 给出。

C 辅助结果与 DET 定量界命题的证明

我们先建立两个关键辅助结果, 再用它们证明命题 4.2。

C.1 辅助结果

按照小节 2.1, 以 $\mathcal{S}(\alpha_N, \beta_N)$ 表示 $\alpha_N = \sum_{i=1}^N a_i \delta_{Y^i}$ (其中 $a_i > 0$) 与 $\beta_N = \sum_{i=1}^N b_i \delta_{X^i}$ 之间的耦合矩阵集合。对 $\mathbf{P} = (p_{i, j})_{i, j} \in \mathcal{S}(\alpha_N, \beta_N)$, 还记其熵为 $H(\mathbf{P}) = \sum_{i, j} p_{i, j} \log(1/p_{i, j})$ 。

引理 C.1. 单纯形 $\mathcal{S}(\alpha_N, \beta_N)$ 的熵半径 R_H 可由下式上界:

$$R_H := \max_{\mathbf{P}_1, \mathbf{P}_2 \in \mathcal{S}(\alpha_N, \beta_N)} [H(\mathbf{P}_1) - H(\mathbf{P}_2)] \leq 2 \log N.$$

证明. 注意 $-H(\mathbf{P})$ 为凸函数, 故 $H(\mathbf{P})$ 为凹函数。于是

$$\begin{aligned} \sum_{i,j} p_{i,j} \log\left(\frac{1}{p_{i,j}}\right) &= N^2 \sum_{i,j} \frac{1}{N^2} p_{i,j} \log\left(\frac{1}{p_{i,j}}\right) \\ &\leq N^2 H\left(\frac{1}{N^2} \sum_{i,j} p_{i,j}\right) \\ &= N^2 H(1/N^2) = 2 \log N. \end{aligned}$$

此外, 对所有 i, j 都有 $p_{i,j} \leq 1$, 所以 $H(\mathbf{P}) \geq 0$ 。因此

$$R_H \leq \max_{\mathbf{P}_1 \in \mathcal{S}(\alpha_N, \beta_N)} H(\mathbf{P}_1) \leq 2 \log N.$$

□

引理 C.2. 设 $\mathcal{X} \subset \mathbb{R}^d$ 为直径 $\mathfrak{d} > 0$ 的紧集。给定 $\mathcal{X}$ 上两个概率测度 α, β , 假设二者之间存在唯一的确定性 λ -Lipschitz 最优传输映射 $\mathbf{T}$ 。再设 $\alpha_N = \sum_{i=1}^N a_i \delta_{Y^i}$ (其中 $a_i > 0$) 和 $\beta_N = \sum_{i=1}^N b_i \delta_{X^i}$ 。分别以 $\mathcal{P}^{\text{OT}, N}$ 和 $\mathcal{P}_\epsilon^{\text{OT}, N}$ 表示 α_N, β_N 之间的最优耦合与 ϵ 正则最优传输方案。则

$$\begin{aligned} &\left[\int \|y - \mathbf{T}(x)\|^2 \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}y) \right]^{1/2} \\ &\leq 2\lambda^{1/2} \mathcal{E}^{1/2} [\mathfrak{d}^{1/2} + \mathcal{E}]^{1/2} + \max\{\lambda, 1\} [\mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta)], \end{aligned}$$

其中

$$\mathcal{E} := \mathcal{E}(N, \epsilon, \alpha, \beta) := \mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta) + \sqrt{2\epsilon \log N}.$$

证明. 由文献 [45] 的推论 3.8,

$$\begin{aligned} &\left[\int \|\mathbf{T}(x) - y\|^2 \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}y) \right]^{1/2} \\ &\leq 2\lambda^{1/2} \sqrt{\tilde{e}_{N, \epsilon}} [\mathcal{W}_2(\alpha, \beta) + \tilde{e}_{N, \epsilon}]^{1/2} + \lambda \mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta), \end{aligned}$$

其中 λ 是把 α 传输到 β 的最优传输映射 $\mathbf{T}$ 的 Lipschitz 常数, 且

$$\begin{aligned} \tilde{e}_{N, \epsilon} &:= \mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta) \\ &\quad + \left[\int \|x - y\|^2 \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}y) \right]^{1/2} - \mathcal{W}_2(\alpha_N, \beta_N). \end{aligned} \tag{29}$$

由文献 [46] 的命题 4,

$$\sum_{i,j=1}^N p_{\epsilon, i, j}^{\text{OT}} |Y_i - X_j|^2 - \mathcal{W}_2^2(\alpha_N, \beta_N) \leq \epsilon R_H,$$

其中 R_H 是引理 C.1 定义的熵半径。因此, 由引理 C.1,

$$\int \|x - y\|^2 \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}y) - \mathcal{W}_2^2(\alpha_N, \beta_N) \leq 2\epsilon \log N.$$

由于 $x \mapsto \sqrt{x}$ 次可加, 对 $r, s > 0$ 有 $\sqrt{r} - \sqrt{s} \leq \sqrt{r-s}$, 故

$$\left[\int \|x - y\|^2 \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}y) \right]^{1/2} - \mathcal{W}_2(\alpha_N, \beta_N) \leq \sqrt{2\epsilon \log N}.$$

于是

$$\tilde{\epsilon}_{N, \epsilon} \leq \mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta) + \sqrt{2\epsilon \log N}.$$

另外, 由假设 B.1 有 $\mathcal{W}_2(\alpha, \beta) \leq \mathfrak{d}^{1/2}$, 结论随即成立。□

C.2 DET 定量界命题的证明

命题 4.2 的证明. 按照定义,

$$\tilde{\beta}_N(\mathrm{d}\tilde{x}) = \int \alpha_N(\mathrm{d}x) \delta_{\mathbf{T}_{N, \epsilon}(x)}(\mathrm{d}\tilde{x}),$$

其中 $\mathbf{T}_{N, \epsilon}(x) := \int \tilde{x} \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}\tilde{x}|x)$ 。另一方面, 因为 $\mathcal{P}_\epsilon^{\text{OT}, N} \in \mathcal{U}(\alpha_N, \beta_N)$, 也有

$$\beta_N(\mathrm{d}\tilde{x}) = \int \alpha_N(\mathrm{d}x) \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}\tilde{x}|x).$$

于是, 对任意 1-Lipschitz 函数 ψ ,

$$\begin{aligned} |\beta_N(\psi) - \tilde{\beta}_N(\psi)| &= \left| \int \left[\int \{\psi(\tilde{x}) - \psi(\mathbf{T}_{N, \epsilon}(x))\} \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}\tilde{x}|x) \right] \alpha_N(\mathrm{d}x) \right| \\ &\leq \iint |\psi(\tilde{x}) - \psi(\mathbf{T}_{N, \epsilon}(x))| \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}\tilde{x}) \\ &\leq \iint \|\tilde{x} - \mathbf{T}_{N, \epsilon}(x)\| \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}\tilde{x}) \\ &\leq \left(\iint \|\tilde{x} - \mathbf{T}_{N, \epsilon}(x)\|^2 \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}\tilde{x}) \right)^{1/2} \\ &\leq \left(\iint \|\tilde{x} - \mathbf{T}(x)\|^2 \mathcal{P}_\epsilon^{\text{OT}, N}(\mathrm{d}x, \mathrm{d}\tilde{x}) \right)^{1/2}. \end{aligned}$$

最后一个不等式来自如下事实: 对任意随机向量 V , 映射 $v \mapsto \mathbb{E}[\|V - v\|^2]$ 在 $v = \mathbb{E}[V]$ 处取最小值。再应用引理 C.2 即得所述结果。□

D DPF 相合性命题的证明

出于技术原因, 我们分析如下略作修改的粒子滤波算法:

$$\alpha_N^{(t)} = \frac{1}{N} \sum_{j=1}^N \delta_{X_t^j}, \quad X_t^j \stackrel{\text{i.i.d.}}{\sim} \tilde{\beta}_N^{(t-1)} f = \frac{1}{N} \sum_{j=1}^N f(\cdot | \tilde{X}_{t-1}^j). \quad (30)$$

标准版本则使用

$$\alpha_N^{(t)} = \frac{1}{N} \sum_{j=1}^N \delta_{X_t^j}, \quad X_t^j \sim f(\cdot | \tilde{X}_{t-1}^j).$$

文献 [48] 等工作分析过 bootstrap 粒子滤波的这一修正版本。这里的分析确实刻画了用 DET 替代重采样所引入的额外误差；对标准粒子滤波算法应能得到类似结果。分析修正算法的主要技术原因，是我们依赖文献 [47] 的定理 2；分析标准算法还需要该结果针对分层采样的版本，留待未来工作完成。

命题 D.1. 假设假设 B.1 to B.3 成立，并且给定 $\tilde{\beta}_N^{(t-1)}$ 后， $\alpha_N^{(t)}$ 由 (30) 定义。定义

$$\begin{aligned} \mathcal{F}(x) &:= x + \sqrt{\mathfrak{d}K_1(\Delta, \mathfrak{d})}x, \\ f_d(x) &:= \begin{cases} x, & d < 4, \\ \frac{x}{\log(2 + 1/x)}, & d = 4, \\ x^{d/2}, & d > 4, \end{cases} \\ \mathcal{F}_{N,\epsilon,\delta,d}(x) &:= \mathcal{F}\left(\kappa x + \sqrt{f_d^{-1}\left(\frac{\log(C/\delta)}{cN}\right)}\right), \\ \frac{1}{\mathfrak{d}}\mathfrak{G}_{\epsilon,\delta,N,d}^2(x) &:= 2\lambda^{1/2} \left[\mathcal{F}_{N,\epsilon,\delta,d}(x) + \sqrt{2\epsilon \log N}\right]^{1/2} \\ &\quad \times \left[\mathfrak{d}^{1/2} + \mathcal{F}_{N,\epsilon,\delta,d}(x) + \sqrt{2\epsilon \log N}\right]^{1/2} \\ &\quad + \lambda\kappa\mathcal{F}_{N,\epsilon,\delta,d}(x) + \max\{\lambda, 1\}\mathcal{F}_{N,\epsilon,\delta,d}(x). \end{aligned} \quad (31)$$

$$(32)$$

则对任意 $\epsilon, \delta > 0$ ，关于 (30) 中的采样步骤，以至少 $1 - \delta$ 的概率有

$$\mathcal{W}_2(\tilde{\beta}_N^{(t)}, \beta^{(t)}) \leq \mathfrak{G}_{\epsilon,\delta,N,d} \left[\mathcal{W}_2(\tilde{\beta}_N^{(t-1)}, \beta^{(t-1)}) \right]. \quad (33)$$

特别地，若当 $N \rightarrow \infty$ 时 $\mathcal{W}_2(\tilde{\beta}_N^{(t-1)}, \beta^{(t-1)}) \rightarrow 0$ 且 $\epsilon_N = o(1/\log N)$ ，则依概率有

$$\mathcal{W}_2(\tilde{\beta}_N^{(t)}, \beta^{(t)}) \rightarrow 0.$$

命题 D.1 的证明. 为使记号简洁，对 $N \geq 1$ 写作

$$\alpha_N := \alpha_N^{(t)}, \quad \alpha'_N := \tilde{\beta}_N^{(t-1)} f, \quad \beta_N := \beta_N^{(t)}, \quad \tilde{\beta}_N := \tilde{\beta}_N^{(t-1)}.$$

控制 $\mathcal{W}_1(\beta_N, \beta)$. 设 ψ 为 1-Lipschitz。不失一般性，可假设 $\psi(0) = 0$ ；否则减去一个常数即可。于是

$$\begin{aligned} |\beta_N(\psi) - \beta(\psi)| &= \left| \frac{\alpha_N(\omega\psi)}{\alpha_N(\omega)} - \frac{\alpha(\omega\psi)}{\alpha(\omega)} \right| \\ &\leq \left| \frac{\alpha_N(\omega\psi)}{\alpha_N(\omega)} - \frac{\alpha(\omega\psi)}{\alpha_N(\omega)} \right| + \left| \frac{\alpha(\omega\psi)}{\alpha_N(\omega)} - \frac{\alpha(\omega\psi)}{\alpha(\omega)} \right| \\ &\leq \Delta^{-1} |\alpha_N(\omega\psi) - \alpha(\omega\psi)| + \Delta^{-2} \alpha(\omega\psi) |\alpha_N(\omega) - \alpha(\omega)|. \end{aligned}$$

注意

$$|(\omega\psi)'| \leq |\omega'\psi| + |\omega\psi'| \leq \|\psi\|_\infty + \|\omega\|_\infty.$$

又因为 $|\psi(x)| = |\psi(x) - \psi(0)| \leq |x| \leq \mathfrak{d}$, 所以 $|(\omega\psi)'| \leq \mathfrak{d} + \Delta^{-1}$, 即 $\omega\psi$ 为 $(\mathfrak{d} + \Delta^{-1})$ -Lipschitz。由此

$$\begin{aligned} |\beta_N(\psi) - \beta(\psi)| &\leq \Delta^{-1}(\mathfrak{d} + \Delta^{-1})\mathcal{W}_1(\alpha_N, \alpha) + \Delta^{-3}\mathfrak{d}\mathcal{W}_1(\alpha_N, \alpha) \\ &=: K_1(\Delta, \mathfrak{d})\mathcal{W}_1(\alpha_N, \alpha). \end{aligned}$$

因此

$$\mathcal{W}_1(\beta_N, \beta) \leq K_1(\Delta, \mathfrak{d})\mathcal{W}_1(\alpha_N, \alpha). \quad (34)$$

利用状态空间的紧致性, 还容易得到

$$\begin{aligned} \mathcal{W}_2(\beta_N, \beta) &\leq \sqrt{\mathfrak{d}\mathcal{W}_1(\beta_N, \beta)} \\ &\leq \sqrt{\mathfrak{d}K_1(\Delta, \mathfrak{d})\mathcal{W}_1(\alpha_N, \alpha)} \\ &\leq \sqrt{\mathfrak{d}K_1(\Delta, \mathfrak{d})\mathcal{W}_2(\alpha_N, \alpha)}, \end{aligned} \quad (35)$$

其中用到了任意概率测度 ρ, σ 都满足 $\mathcal{W}_1(\rho, \sigma) \leq \mathcal{W}_2(\rho, \sigma)$ 。

控制 $\mathcal{W}_1(\tilde{\beta}_{N,\epsilon}, \tilde{\beta})$ 。 仍设 ψ 为 1-Lipschitz 且 $\psi(0) = 0$, 则

$$\begin{aligned} |\tilde{\beta}_N(\psi) - \tilde{\beta}(\psi)| &= \left| \int \psi(\mathbf{T}_{N,\epsilon}(x))\alpha_N(dx) - \int \psi(\mathbf{T}(x))\alpha(dx) \right| \\ &\leq \left| \int \psi(\mathbf{T}_{N,\epsilon}(x))\alpha_N(dx) - \int \psi(\mathbf{T}(x))\alpha_N(dx) \right| \\ &\quad + \left| \int \psi(\mathbf{T}(x))\alpha_N(dx) - \int \psi(\mathbf{T}(x))\alpha(dx) \right|. \end{aligned}$$

对第二项, 由于 $\mathbf{T}$ 和 ψ 分别为 λ -Lipschitz 与 1-Lipschitz, $\psi \circ \mathbf{T}$ 为 λ -Lipschitz, 所以

$$\left| \int \psi(\mathbf{T}(x))\alpha_N(dx) - \int \psi(\mathbf{T}(x))\alpha(dx) \right| \leq \lambda\mathcal{W}_1(\alpha_N, \alpha) \leq \lambda\mathcal{W}_2(\alpha_N, \alpha).$$

对第一项, 由 Cauchy-Schwarz 与 Jensen 不等式,

$$\begin{aligned} &\left| \int \psi(\mathbf{T}_{N,\epsilon}(x))\alpha_N(dx) - \int \psi(\mathbf{T}(x))\alpha_N(dx) \right| \\ &\leq \int |\mathbf{T}_{N,\epsilon}(x) - \mathbf{T}(x)|\alpha_N(dx) \\ &\leq \int \left| \int y \mathcal{P}_{N,\epsilon}(x, dy) - \mathbf{T}(x) \right| \alpha_N(dx) \\ &\leq \iint |y - \mathbf{T}(x)|\alpha_N(dx)\mathcal{P}_{N,\epsilon}(x, dy) \\ &\leq \left[\iint |y - \mathbf{T}(x)|^2 \alpha_N(dx)\mathcal{P}_{N,\epsilon}(x, dy) \right]^{1/2}. \end{aligned}$$

直接应用引理 C.2, 得到

$$\begin{aligned} &\left[\iint |y - \mathbf{T}(x)|^2 \alpha_N(dx)\mathcal{P}_{N,\epsilon}(x, dy) \right]^{1/2} \\ &\leq 2\lambda^{1/2}\mathcal{E}^{1/2}[\mathfrak{d}^{1/2} + \mathcal{E}]^{1/2} + \max\{\lambda, 1\}[\mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta)], \end{aligned}$$

其中

$$\mathcal{E} := \mathcal{E}(N, \epsilon, \alpha, \beta) := \mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta) + \sqrt{2\epsilon \log N}.$$

由(35),

$$\mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta) \leq \mathcal{W}_2(\alpha_N, \alpha) + \sqrt{\mathfrak{d}K_1(\Delta, \mathfrak{d})\mathcal{W}_2(\alpha_N, \alpha)}.$$

接下来对 $\mathcal{W}_2(\alpha_N, \alpha)$ 求界。首先, 由假设 B.2,

$$\begin{aligned} \mathcal{W}_2(\alpha_N, \alpha) &\leq \mathcal{W}_2(\alpha_N, \alpha'_N) + \mathcal{W}_2(\alpha'_N, \alpha) \\ &\leq \mathcal{W}_2(\alpha_N, \alpha'_N) + \kappa \mathcal{W}_2(\tilde{\beta}_N^{(t-1)}, \beta^{(t-1)}). \end{aligned}$$

为控制第一项, 我们使用文献 [47] 对 $\mathcal{W}_2(\alpha_N, \alpha'_N)$ 给出高概率界。具体地, 由该文定理 2, 在紧致区域中取矩参数为无穷大, 则存在正常数 C, c , 使得

$$\mathbb{P}[\mathcal{W}_2^2(\alpha_N, \alpha'_N) \geq x] \leq C \exp[-cN f_d^2(x)], \quad (36)$$

其中

$$f_d(x) := \begin{cases} x, & d < 4, \\ \frac{x}{\log(2 + 1/x)}, & d = 4, \\ x^{d/2}, & d > 4. \end{cases} \quad (37)$$

特别地, 对任意 $\delta > 0$, 关于 F_N 中的采样步骤, 以至少 $1 - \delta$ 的概率有

$$\mathcal{W}_2(\alpha_N, \alpha'_N) \leq \sqrt{f_d^{-1}\left(\frac{\log(C/\delta)}{cN}\right)}. \quad (38)$$

当 $d \geq 4$ 时, 其速率如预期为 $N^{-1/d}$ 。

因此, 关于采样步骤, 以至少 $1 - \delta$ 的概率有

$$\mathcal{W}_2(\alpha_N, \alpha) + \mathcal{W}_2(\beta_N, \beta) \leq \mathcal{F}_{N, \epsilon, \delta, d}(\mathcal{W}_2(\tilde{\beta}_N^{(t-1)}, \beta^{(t-1)})),$$

其中

$$\begin{aligned} \mathcal{F}_{N, \epsilon, \delta, d}(x) &= \mathcal{F}\left(\kappa x + \sqrt{f_d^{-1}\left(\frac{\log(C/\delta)}{cN}\right)}\right), \\ \mathcal{F}(x) &:= x + \sqrt{\mathfrak{d}K_1(\Delta, \mathfrak{d})x}. \end{aligned} \quad (39)$$

综合以上结果, 关于采样步骤, 以至少 $1 - \delta$ 的概率有

$$\begin{aligned} \mathcal{W}_2(\tilde{\beta}_{N, \epsilon}, \tilde{\beta}) &\leq \sqrt{\mathfrak{d} \mathcal{W}_1(\tilde{\beta}_{N, \epsilon}, \tilde{\beta})} \\ &\leq \mathfrak{G}_{\epsilon, \delta, N, d}(\mathcal{W}_2(\tilde{\beta}_N^{(t-1)}, \beta^{(t-1)})), \end{aligned}$$

其中

$$\begin{aligned} \frac{1}{\mathfrak{d}} \mathfrak{G}_{\epsilon, \delta, N, d}^2(x) &:= 2\lambda^{1/2} [\mathcal{F}_{N, \epsilon, \delta, d}(x) + \sqrt{2\epsilon \log N}]^{1/2} \\ &\quad \times [\mathfrak{d}^{1/2} + \mathcal{F}_{N, \epsilon, \delta, d}(x) + \sqrt{2\epsilon \log N}]^{1/2} \\ &\quad + \lambda \kappa \mathcal{F}_{N, \epsilon, \delta, d}(x) + \max\{\lambda, 1\} \mathcal{F}_{N, \epsilon, \delta, d}(x). \end{aligned}$$

特别地, 若令 $\epsilon_N = o(1/\log N)$ 且 $x_N = o(1)$, 则

$$\mathfrak{G}_{\epsilon_N, \delta, N, d}(x_N) \rightarrow 0.$$

因此, 若 $\epsilon_N = o(1/\log N)$ 且 $\mathcal{W}_2(\mu_N, \mu) \rightarrow 0$, 则对任意 $x > 0$, 存在与 N 无关的 x' , 使

$$\mathbb{P}[\mathcal{W}_2(\tilde{\beta}_{N, \epsilon}, \tilde{\beta}) \geq x] \leq \mathbb{P}[\mathcal{W}_2(\alpha'_N, \alpha_N) \geq x'].$$

这里概率均关于采样步骤。于是得到依概率收敛。 $\square$

命题 D.2. 令 $\mu_N = \frac{1}{N} \sum_{i=1}^N \delta_{X_1^i}$, 其中对 $i \in [N]$, $X_1^i \stackrel{\text{i.i.d.}}{\sim} \mu := q(\cdot | y_1)$; 并假设对 $t \geq 1$, $\alpha_N^{(t)}$ 由(30)定义。在假设 B.1 to B.4 下, 对任意 $\delta > 0$, 关于采样步骤以至少 $1 - 2\delta$ 的概率, 对任意有界 1-Lipschitz 函数 ψ 和任意 $t \in [1 : T]$, DPF 所计算的滤波分布近似与对数似然近似满足

$$|\tilde{\beta}_N^{(t)}(\psi) - \beta^{(t)}(\psi)| \leq \mathfrak{G}_{\epsilon, \delta/T, N, d}^{(t)} \left(\sqrt{f_d^{-1} \left(\frac{\log(CT/\delta)}{cN} \right)} \right), \quad (40)$$

$$\begin{aligned} \left| \log \frac{\hat{p}_N(y_{1:T})}{p(y_{1:T})} \right| &\leq \frac{\kappa}{\Delta} \max_{t \in [1:T]} \text{Lip}[g(y_t | \cdot)] \\ &\quad \times \sum_{t=1}^T \mathfrak{G}_{\epsilon, \delta/T, N, d}^{(t)} \left(\sqrt{f_d^{-1} \left(\frac{\log(CT/\delta)}{cN} \right)} \right). \end{aligned} \quad (41)$$

其中 C 是与 T 无关的有限常数, $\mathfrak{G}_{\epsilon, \delta/T, N, d}$ 和 f_d 由(32)定义, $\text{Lip}[f]$ 表示函数 f 的 Lipschitz 常数; $\mathfrak{G}_{\epsilon, \delta/T, N, d}^{(t)}$ 表示函数 $\mathfrak{G}_{\epsilon, \delta/T, N, d}$ 的 t 次复合。特别地, 若取 $\epsilon_N = o(1/\log N)$, 则依概率有

$$\left| \log \frac{\hat{p}_N(y_{1:T})}{p(y_{1:T})} \right| \rightarrow 0.$$

命题 D.2 的证明. 沿用命题 D.1 的证明, 定义 $\alpha_N^{(t)'} = \tilde{\beta}_N^{(t-1)} f$, 并对 $t \in [1 : T]$ 定义事件

$$A_t := \left\{ \mathcal{W}_2(\alpha_N^{(t)}, \alpha_N^{(t)'}) \leq \sqrt{f_d^{-1} \left(\frac{\log(CT/\delta)}{cN} \right)} \right\}.$$

由文献 [47] 的定理 2, $\mathbb{P}(A_t) \geq 1 - \delta/T$, 其中概率关于采样步骤。特别地,

$$\begin{aligned} \mathbb{P} \left[\bigcap_{t=1}^T A_t \right] &= 1 - \mathbb{P} \left[\bigcup_{t=1}^T A_t^c \right] \\ &\geq 1 - \sum_{t=1}^T \mathbb{P}[A_t^c] \geq 1 - T \frac{\delta}{T} = 1 - \delta. \end{aligned}$$

在事件 $\bigcap_{t=1}^T A_t$ 上, 迭代(33), 以至少 $1 - \delta$ 的概率得到

$$\mathcal{W}_2(\tilde{\beta}_N^{(t)}, \beta^{(t)}) \leq \mathfrak{G}_{\epsilon, \delta/T, N, d}^{(t)}[\mathcal{W}_2(\mu_N, \mu)].$$

再由文献 [47] 的定理 2, 以至少 $1 - \delta$ 的概率有

$$\mathcal{W}_2(\mu_N, \mu) \leq \sqrt{f_d^{-1}\left(\frac{\log(CT/\delta)}{cN}\right)}.$$

因此, 以至少 $1 - 2\delta$ 的概率得到(40)。

还需证明(41)。对任意 $x, y > 0$, $|\log x - \log y| \leq |x - y|/\min\{x, y\}$, 所以

$$\begin{aligned} |\log \hat{p}(y_{1:T}) - \log p(y_{1:T})| &\leq \sum_{t=1}^T |\log \hat{p}(y_t|y_{1:t-1}) - \log p(y_t|y_{1:t-1})| \\ &\leq \sum_{t=1}^T \left| \frac{\hat{p}(y_t|y_{1:t-1}) - p(y_t|y_{1:t-1})}{\min\{\hat{p}(y_t|y_{1:t-1}), p(y_t|y_{1:t-1})\}} \right| \\ &\leq \Delta^{-1} \sum_{t=1}^T |\hat{p}(y_t|y_{1:t-1}) - p(y_t|y_{1:t-1})|. \end{aligned} \quad (42)$$

其中 Δ 由假设 B.3 定义。

(42) 中的差可写成

$$\begin{aligned} &\hat{p}(y_t|y_{1:t-1}) - p(y_t|y_{1:t-1}) \\ &= \iint g(y_t|x_t) f(dx_t|\tilde{x}_{t-1}) \tilde{\beta}_N^{(t-1)}(d\tilde{x}_{t-1}) \\ &\quad - \iint g(y_t|x_t) f(dx_t|\tilde{x}_{t-1}) \tilde{\beta}^{(t-1)}(d\tilde{x}_{t-1}) \\ &= \tilde{\beta}_N^{(t-1)}(h) - \beta^{(t-1)}(h), \end{aligned}$$

其中

$$\Delta^2 \leq h(x) := \int g(y_t|x') f(x'|x) dx' \leq \Delta^{-2}.$$

还需注意

$$\begin{aligned} h(x) - h(x') &= \int f(dw|x) g(y_t|w) - \int f(dw|x') g(y_t|w) \\ &= [\delta_x f][g(y_t | \cdot)] - [\delta_{x'} f][g(y_t | \cdot)] \\ &\leq \text{Lip}[g(y_t | \cdot)] \mathcal{W}_1(\delta_x f, \delta_{x'} f) \\ &\leq \kappa \text{Lip}[g(y_t | \cdot)] \mathcal{W}_1(\delta_x, \delta_{x'}) \\ &= \kappa \text{Lip}[g(y_t | \cdot)] |x - x'|, \end{aligned}$$

其中最后一步使用假设 B.2。因此 h 为 Lipschitz 函数, 进而

$$\begin{aligned} \hat{p}(y_t|y_{1:t-1}) - p(y_t|y_{1:t-1}) &= \tilde{\beta}_N^{(t-1)}(h) - \beta^{(t-1)}(h) \\ &\leq \kappa \text{Lip}[g(y_t | \cdot)] \mathcal{W}_1(\beta_N^{(t-1)}, \beta^{(t-1)}). \end{aligned}$$

结合(40)与(42)，并使用 $\mathcal{W}_1 \leq \mathcal{W}_2$ ，得到

$$\begin{aligned} |\log \hat{p}(y_{1:T}) - \log p(y_{1:T})| &\leq \Delta^{-1} \kappa \sum_{t=1}^T \text{Lip}[g(y_t | \cdot)] \mathcal{W}_1(\tilde{\beta}_N^{(t-1)}, \beta^{(t)}) \\ &\leq \Delta^{-1} \kappa \max_{t \in [1:T]} \text{Lip}[g(y_t | \cdot)] \\ &\quad \times \sum_{t=1}^T \mathfrak{G}_{\epsilon, \delta/T, N, d}^{(t)} \left(\sqrt{f_d^{-1} \left(\frac{\log(CT/\delta)}{cN} \right)} \right). \end{aligned}$$

最后一个不等式关于采样步骤以至少 $1 - \delta$ 的概率成立。依概率收敛性由命题 D.1 中的相应结论得到。□

E 补充实验与细节

E.1 线性高斯模型

首先考虑如下二维线性高斯状态空间模型；可用 Kalman 方法执行精确推断：

$$X_t | \{X_{t-1} = x\} \sim \mathcal{N}(\text{diag}(\theta_1, \theta_2)x, 0.5\mathbf{I}_2), \quad Y_t | \{X_t = x\} \sim \mathcal{N}(x, 0.1\mathbf{I}_2). \quad (43)$$

我们用 $\theta = (\theta_1, \theta_2) = (0.5, 0.5)$ 模拟 $T = 150$ 个观测。由于隐过程混合很快，预期此时滤波分布 $p_\theta(x_t | y_{1:t})$ 与平滑分布 $p_\theta(x_t | y_{1:T})$ 差别不大。根据命题 4.1，这对忽略重采样梯度项的方法是有利情形，因为偏差应当不大。前文图 1 给出了由 Kalman 方法得到的 $\ell(\theta)$ ，以及采用相同粒子数 $N = 25$ 、取 $q_\phi(x_t | x_{t-1}, y_t) = f_\theta(x_t | x_{t-1})$ 时由标准 PF 和 DPF 计算的 $\hat{\ell}(\theta; \mathbf{u})$ 。对应的梯度向量场见图 1；标准 PF 的梯度采用文献 [9, 10, 11] 中的有偏梯度计算。

接下来比较估计量 $\hat{\theta}_{\text{SMLE}}$ （用于 DPF）以及 $\hat{\theta}_{\text{ELBO}}$ （用于标准 PF 与 DPF）与通过 Kalman 导数计算的 $\hat{\theta}_{\text{MLE}}$ 之间的性能。前两类估计量均用学习率 10^{-4} 进行 100 步梯度学习；DPF 使用 $N = 25$ ，标准 PF 使用 $N = 500$ 。我们用 $\theta = (\theta_1, \theta_2) = (0.5, 0.5)$ 模拟 $M = 50$ 组长度为 $T = 150$ 的观测。对标准 PF，ELBO 随机梯度采用文献 [9, 10, 11] 中忽略重采样步骤贡献的 $\ell_{\text{ELBO}}(\theta)$ 有偏梯度估计（回顾无偏估计方差极高）；对 DPF，则使用 $\ell^{\text{ELBO}}(\theta)$ 的无偏梯度。

我们对 B 个并行 PF 求平均，以降低 ELBO 梯度的方差；同时用 B 个随机种子固定的 PF 计算

$$\hat{\ell}_{\text{SMLE}}(\theta; \mathbf{u}_{1:B}) := \frac{1}{B} \sum_{b=1}^B \hat{\ell}(\theta; \mathbf{u}_b)$$

的梯度。结果见表 4。在本例中，使 $\ell_{\text{DPF}}^{\text{ELBO}}(\theta)$ 最大的 $\hat{\theta}_{\text{ELBO}}^{\text{DPF}}$ 优于 $\hat{\theta}_{\text{ELBO}}^{\text{PF}}$ 和 $\hat{\theta}_{\text{SMLE}}$ 。不过，随着 B 增大， $\hat{\theta}_{\text{SMLE}}$ 逐渐接近 $\hat{\theta}_{\text{ELBO}}^{\text{DPF}}$ ；这是预期现象，因为 $\hat{\ell}_{\text{SMLE}}(\theta; \mathbf{u}_{1:B}) \rightarrow \ell^{\text{ELBO}}(\theta)$ 。

表 4. 50 个数据集上的 $10^3 \times \text{RMSE}$ ；越低越好

B	$\hat{\theta}_{\text{ELBO}}^{\text{PF}}$	$\hat{\theta}_{\text{ELBO}}^{\text{DPF}}$	$\hat{\theta}_{\text{SMLE}}$
1	1.94	1.30	7.94
4	2.40	1.35	3.28
10	2.80	1.37	2.18

注：均方根误差定义为 $\sqrt{\frac{1}{M} \sum_{i=1}^2 \sum_{k=1}^M (\hat{\theta}_i^k - \hat{\theta}_{\text{MLE},i}^k)^2}$ 。

E.2 变分循环神经网络

训练使用 $N = 32$ 个粒子，正则化参数取 $\epsilon = 0.5$ 。对每一种重采样或 DET 过程，都以按序列长度缩放的 ELBO 为最大化目标。在测试数据上，用 $N = 500$ 个粒子和多项式重采样评估 ELBO。当有效样本量（ESS）低于 $N/2$ 时执行重采样或 DET 操作。Adam 优化器的学习率为 0.001。

回顾状态空间模型为

$$\begin{aligned}
 (R_t, O_t) &= \text{RNN}_{\theta}(R_{t-1}, Y_{1:t-1}, E_{\theta}(Z_{t-1})), \\
 Z_t &\sim \mathcal{N}(\mu_{\theta}(O_t), \sigma_{\theta}(O_t)), \\
 \hat{p}_t &= h_{\theta}(E_{\theta}(Z_t), O_t), \\
 Y_t | X_t &\sim \text{Ber}(\hat{p}_t).
 \end{aligned}$$

网络结构和数据预处理步骤大致参照文献 [10]。由于数据量较小且观测稀疏，为防止过拟合，这里采用较小的神经网络；更复杂的机器人实验采用较大的网络。

R_t 的维数为 $d_r = 16$ ， Z_t 的维数为 $d_z = 8$ 。 E_{θ} 是单隐藏层全连接网络，隐藏层宽度为 16，输出维数为 16，使用 ReLU 激活。 μ_{θ} 和 σ_{θ} 均为具有两个隐藏层的全连接神经网络，每层 16 个单元并使用 ReLU 激活； μ_{θ} 的最终输出不施加激活函数，而 σ_{θ} 的输出施加 softplus，并作为用于采样 Z_t 的正态分布协方差矩阵的对角元。 h_{θ} 是具有两个隐藏层的全连接网络，每层宽度为 16，并使用 ReLU 激活；最终输出不经过 ReLU，而作为观测 Bernoulli 分布的 logits。

E.3 机器人定位

与 VRNN 实验类似，训练使用 $N = 32$ 个粒子，正则化参数取 $\epsilon = 0.5$ ；当 ESS 低于 $N/2$ 时执行重采样或 DET 操作。Adam 优化器的学习率为 0.001。

网络结构和数据预处理大致参照文献 [24]。共使用三个神经网络：

- 编码器 E_{θ} 将 24×24 的 RGB 像素图像（输入维数为 $3 \times 24 \times 24$ ）映射为大小 $d_E = 128$ 的编码。该网络由核大小为 3 的卷积神经网络（CNN），以及隐藏层宽度为 128、采用 ReLU 激活的单隐藏层全连接网络组成。

- 解码器 D_θ 将编码映射回原图像。它先使用具有三个隐藏层的全连接神经网络, 每层宽度为 128 并采用 ReLU 激活; 随后接一个规格与编码器 CNN 对应的转置卷积网络, 输出与观测图像相同的维数 $3 \times 24 \times 24$ 。
- 网络 G_θ 将状态 $S_t = (X_t^{(1)}, X_t^{(2)}, \gamma_t)$ 映射为 128 维编码。首先把角度 γ_t 转换为 $\sin(\gamma_t), \cos(\gamma_t)$; 再将增广状态 $(X_t^{(1)}, X_t^{(2)}, \sin(\gamma_t), \cos(\gamma_t))$ 输入三隐藏层全连接网络。三个隐藏层的维数依次为 16、32、64, 均使用 ReLU 激活, 最终输出维数为 128。