

粒子滤波器中的路径存储

Pierre E. Jacob¹ Lawrence M. Murray²

Sylvain Rubenthaler³

收稿：日期 / 录用：日期

¹ 新加坡国立大学，统计与应用概率系

Block S16, Level 7, 6 Science Drive 2, Singapore 117546

pierre.jacob.work@gmail.com

²CSIRO 数学、信息学与统计部

Private Bag 5, WA 6913, Australia

lawrence.murray@csiro.au

³ 尼斯索菲亚·安蒂波利斯大学

Parc Valrose, 06108 Nice cedex 02, France

Sylvain.Rubenthaler@unice.fr

摘要

本文研究粒子滤波器以及更一般的序贯蒙特卡洛算法所生成路径的存储问题。我们给出一个理论结果，将期望内存开销上界限定为 $T + CN \log N$ ，其中 T 为时间跨度， N 为粒子数， C 为常数；同时提出实现这一结果的高效算法。我们通过数值实验展示该理论结果和算法。

关键词：序贯蒙特卡洛；粒子滤波；内存开销；并行计算

1 引言

考虑状态空间模型中的滤波问题 (Cappé et al, 2005)。模型由 $X_0 \sim \mu(\cdot)$ 以及对 $t = 1, \dots, T$ 成立的下式定义：

$$X_t \mid X_{t-1} = x_{t-1} \sim f(\cdot \mid x_{t-1}),$$

$$Y_t \mid X_t = x_t \sim g(\cdot \mid x_t).$$

这里， $X_{0:T}$ 是空间 $\mathcal{X}$ 上的隐马尔可夫链，其初始分布为 μ ，转移密度为 f 。给定 $x_{1:T}$ 后，空间 $\mathcal{Y}$ 中的观测 $Y_{1:T}$ 条件独立，观测密度为 g 。对任意向量 v ，引入记号 $v_{1:n} = (v_1, \dots, v_n)$ 和 $v^{1:n} = (v^1, \dots, v^n)$ 。

用 p_t 表示给定时刻 t 可用观测 $y_{1:t}$ 后路径 $X_{0:t}$ 的分布；给定 $y_{1:t}$ 后 X_t 的滤波分布记为 π_t ，它是 p_t 的一个边缘分布。算法 1 描述的自举粒子滤波器 (Gordon et al, 1993) 递归地近似分布 $p_{1:T}$ ，

算法 1 具有 N 个粒子的自举粒子滤波器

抽取初始样本 $x_0^{1:N} \stackrel{iid}{\sim} \mu$ 。

对 $k = 1, \dots, N$, 令 $\bar{x}_0^k = x_0^k$ 且 $w_0^k = 1/N$ 。

对 $t = 1, \dots, T$

[重采样] 抽取祖先索引 $a_t^{1:N} \sim \mathcal{R}(w_{t-1}^{1:N})$ 。

对每个 $k \in \{1, \dots, N\}$

[转移] 抽取新样本 $x_t^k \sim f(\cdot | x_{t-1}^{a_t^k})$ 。

扩展路径 $\bar{x}_{0:t}^k = (\bar{x}_{0:t-1}^{a_t^k}, x_t^k)$ 。

[加权] 计算未归一化权重 $\tilde{w}_t^k = g(y_t | x_t^k)$ 。

对 $k = 1, \dots, N$ 归一化权重: $w_t^k = \tilde{w}_t^k / \sum_{j=1}^N \tilde{w}_t^j$ 。




图 1. 使用多项式重采样的粒子滤波器生成的典型祖先树, $N = 20$, $T = 50$ 。

并衍生出各种其他序贯蒙特卡洛方法 (Doucet et al, 2001; Doucet and Johansen, 2011)。算法 1 中的重采样步骤依赖于 $\{1, \dots, N\}^N$ 上的某个分布 $\mathcal{R}$, 该分布以归一化权重为参数。

在每个时刻 t , 算法 1 用下列经验分布近似 p_t 和 π_t :

$$p_t^N(dx_{0:t}) = w_t^1 \delta_{\bar{x}_{0:t}^1}(dx_{0:t}) + \dots + w_t^N \delta_{\bar{x}_{0:t}^N}(dx_{0:t})$$

$$\text{以及 } \pi_t^N(dx_t) = w_t^1 \delta_{x_t^1}(dx_t) + \dots + w_t^N \delta_{x_t^N}(dx_t).$$

Whiteley (2011); Douc et al (2012); van Handel (2009) 以及 Del Moral (2004) 的定理 7.4.4 已经证明: 在对模型分布 (μ, f, g) 施加温和条件时, π_t^N 随 N 增大收敛于 π_t , 且蒙特卡洛误差相对于 t 保持恒定。然而, 众所周知, 路径测度 p_t^N 虽然也随 N 增大收敛于 p_t , 其蒙特卡洛误差却通常至少随时间 t 呈二次增长 (Del Moral and Doucet, 2003; Poyiadjis et al, 2011)。实际上, 由于重采样步骤, 各条路径会迅速合并, 因此当 $t - s$ 较大时, 对边缘分布 $p(dx_s | y_{1:t})$ 的近似很差。下文将路径集合 $\bar{x}_{0:t}^{1:N}$ 称为祖先树, 将每个 x_s^k ($k = 1, \dots, N$, $s = 0, \dots, t$) 称为节点, 更具体地将每个 x_t^k 称为叶节点, 并将路径称为分支。

图 1 有助于直观理解粒子滤波器生成的祖先树的典型形状。所有分支合并的时刻记为 c_T ；它将从 $t = 0$ 到 $t = c_T - 1$ 、由唯一分支组成的“树干”，与从 $t = c_T$ 到 $t = T$ 、由所有分支组成的“树冠”分隔开来。尽管粒子退化现象不利于滤波量的估计，但它使树冠保持较小，从而允许以较低内存开销存储整棵树。在需要粒子滤波器完整路径的场合，这一点十分有益，例如 [Andrieu et al \(2010\)](#) 首次提出、[Chopin and Singh \(2013\)](#) 进一步研究，并在 [Chopin et al \(2013\)](#) 和 [Lindsten et al \(2012\)](#) 中广泛使用的条件序贯蒙特卡洛算法与粒子 Gibbs 算法。另一个需要存储路径的序贯蒙特卡洛方法由 [Wang et al \(2014\)](#) 在计算生物学背景下提出。本文使用滤波术语介绍算法与结果，但它们可以直接推广到 Feynman–Kac 模型的任意序贯蒙特卡洛方法 ([Del Moral, 2004](#))。

第 2 节提出在粒子滤波器运行期间递归存储祖先树的高效算法。第 3 节给出祖先树大小上界的新理论结果，以界定存储算法的期望内存需求。最后，第 4 节通过数值实验检验理论结果与算法性能。

2 算法

本节介绍一种节省内存的数据结构及其配套算法，用于仅存储在时刻 t 仍有支撑的路径。这些算法按并行执行设计，与序贯蒙特卡洛采样器其他组成部分普遍具有的可并行性一致 ([Lee et al, 2010](#); [Murray, 2013](#))。

2.1 所提出的方案

截至时刻 t ，粒子滤波器生成粒子 $x_{1:t}^{1:N}$ 和祖先 $a_{1:t}^{1:N}$ 。由 $a_{1:t}^{1:N}$ 可以方便地得到后代计数 $o_{1:t}^{1:N}$ ([Murray et al, 2013](#))，其中 o_t^i 表示粒子 x_{t-1}^i 在第 t 代的子节点数。令 $x_*^{1:M}$ 表示内存中用于存储粒子的 M 个槽位。在任一时刻，其中一部分槽位为空，其余槽位存储树中的节点。令 $a_*^{1:M}$ 为祖先向量：若 x_*^i 为空或为根节点，则 $a_*^i = 0$ ；否则， $a_*^i = j$ 表示 x_*^j 中的粒子是 x_*^i 中粒子的父节点。令 $o_*^{1:M}$ 为与 $a_*^{1:M}$ 对应的后代向量，其中 $o_*^i = n$ 表示 x_*^i 有 n 个子节点。最后，令 $l_*^{1:N}$ 给出 $x_*^{1:M}$ 中存储最新一代粒子的 N 个槽位的编号；这些粒子是树的叶节点。

树的基本操作包括初始化、插入新一代粒子，以及剪除那些在最新一代中已无存活后代的较老粒子。算法 2 描述这些操作。其描述依赖于算法 3 定义的基本操作原语。这些原语在串行和并行情形下的高效实现都已得到充分研究，因此可作为构建高层算法的有用组件。

首先，按算法 2 的 INIT 过程，用第一代的 N 个粒子初始化树的 M 个空槽位中的前若干个。暂且假设 M 足够大，可以容纳后续对树的所有操作；另见下文第 2.2 节的讨论。

按算法 2 的 INSERT 过程插入新一代新粒子。该过程搜索在当前一代中没有后代的节点，并用新的叶节点替换它们。引入向量 z_* ，其中 z_*^i 等于编号从 1 到 i 的节点中没有后代的节点数。然后通过搜索 z_* 的增量来定位待替换的节点，并在这些位置插入新一代粒子。

最后，在插入新一代新粒子 t 之前，使用算法 2 的 PRUNE 过程剪枝。该过程需要新一代的后代向量 o_t 。算法确定哪些当前叶节点在新一代中没有后代，递减其父节点的后代计数；若父节点也已

算法 2 祖先树基本操作的并行算法：用第一代粒子初始化、插入新一代粒子，以及在插入新一代之前剪枝。

```

INIT( $x_0^{1:N}$ )
  对每个  $i \in \{1, \dots, M\}$ 
     $a_*^i \leftarrow 0$ 
     $o_*^i \leftarrow 0$ 
  对每个  $i \in \{1, \dots, N\}$ 
     $x_*^i \leftarrow x_0^i$ 
     $l_*^i \leftarrow i$ 

INSERT( $x_t^{1:N}, a_t^{1:N}$ )
   $b_t \leftarrow \text{GATHER}(l_*, a_t)$ 
   $z_* \leftarrow \text{TRANSFORM-PREFIX-SUM}(o_*, \mathbf{1}_{\{0\}})$ 
   $l_* \leftarrow \text{LOWER-BOUND}(z_*, (1, \dots, N))$ 
   $a_* \leftarrow \text{SCATTER}(b_t, l_*)$ 
   $x_* \leftarrow \text{SCATTER}(x_t, l_*)$ 

PRUNE( $o_t^{1:N}$ )
   $o_* \leftarrow \text{SCATTER}(o_t, l_*)$ 
  对每个  $i \in \{1, \dots, N\}$ 
     $j \leftarrow l_*^i$ 
    当  $j > 0$  且  $o_*^j = 0$ 
       $j \leftarrow a_*^j$ 
      若  $j > 0$ 
         $o_*^j \leftarrow o_*^j - 1$ 

```

没有剩余后代，则继续沿树向上递归处理。每个非叶节点 i 若满足 $o_*^i = 0$ ，就被视为已剪除，并可在以后调用 INSERT 时被覆盖。

2.2 说明与改进

算法 2 的 INSERT 过程假设至少存在 N 个空槽位，以放置最新节点。若不满足这一条件，可以分配更大的内存块，将祖先树的内容复制过去，并将向量 o_* 和 a_* 的新增区域填零，以扩大缓冲区。可使用各种启发式方法确定新的大小 M ，目标是减少内存碎片和将来再次扩容的概率。由于重新分配内存涉及代价较高的复制，值得将 M 增加到超过当前严格所需的大小，以推迟后续的重新分配。例如，C++ Standard Template Library 的实现通常会在向量仅增加一个元素时，将其存储容量

算法 3 伪代码中使用的基本操作原语。

$\text{GATHER}(p^{1:P}, q^{1:Q}) \rightarrow r^{1:Q}$

对每个 $i \in \{1, \dots, Q\}$

$r^i \leftarrow p^{q^i}$

$\text{SCATTER}(p^{1:P}, q^{1:P}) \rightarrow r^{1:Q}$

对每个 $i \in \{1, \dots, P\}$

$r^{q^i} \leftarrow p^i$

$\text{TRANSFORM-PREFIX-SUM}(p^{1:P}, f) \rightarrow r^{1:P}$

对每个 $i \in \{1, \dots, P\}$

$r^i \leftarrow \sum_{j=1}^i f(p^j)$

$\text{LOWER-BOUND}(p^{1:P}, q^{1:Q}) \rightarrow r^{1:Q}$

对每个 $i \in \{1, \dots, Q\}$

$r^i \leftarrow \min\{j : q^i \leq p^j\}$

翻倍，以应对预期的进一步扩展。更保守的策略是，初始时令 M 为 N 的一个较小倍数，并在必要时增加 N 个槽位。总体而言，我们没有发现具体的扩容策略会显著影响执行时间；尤其是，如后续理论结果所示，祖先树树冠的大小与 T 无关，因此随着 t 增大，重新分配内存的需求会减少。

根据第 3 节的结果，树大小的期望随 T 线性增长，但这仅仅源于树干。树冠大小与 T 无关。可以考虑识别树干上的节点并单独存储，以改进算法，因为这些节点永远不会被后续插入操作覆盖。在这种修改后的方案中，需要存储一条独立的、不断增长的树干，但不必搜索它；树冠节点则需要每个时间步存储和搜索。根据第 3 节的定理 1，树冠节点数的期望保持恒定。因此，这一修改带来相对于 T 而言期望计算开销恒定的方案，适用于时间跨度非常长的应用，不过识别树干也会引入额外开销。第 4 节的图 3(b) 给出了所提方法的计算开销。单独存储树干也会减少内存重新分配。

我们在第 3 节证明，树大小的期望被 $T + \Delta_2 N \log N$ 所界定，其中 Δ_2 为某个常数。数据结构的大小 M 必须至少与此相当。我们假设采用合理的扩容策略后，它不会超过该量的某个常数倍，因此期望内存复杂度为 $\mathcal{O}(T + \Delta_2 N \log N)$ 。

INIT 的计算复杂度与数据结构大小成线性关系，为 $\mathcal{O}(T + \Delta_2 N \log N)$ 。 INSERT 的串行实现允许线性时间的前缀和计算与搜索，因此 INSERT 也是 $\mathcal{O}(T + \Delta_2 N \log N)$ 。并行情形仍能实现线性前缀和 (Sengupta et al, 2008)，但搜索变成 N 次二分查找，每次相对于数据结构大小为对数复杂度；总体为 $\mathcal{O}(N \log(T + \Delta_2 N \log N))$ 。

对于 PRUNE ，先考虑最佳情形：上一代的所有粒子在新一代中都有后代。此时复杂度为 $\mathcal{O}(N)$ ：算法处理 N 个新节点中的每一个，但不会进一步遍历树。再考虑最坏情形：第 t 代只有一个粒子

在新一代 $t + 1$ 中有后代。此时，现有树中除 t 个节点外，其余节点全部被剪除，因此复杂度为 $\mathcal{O}(T + \Delta_2 N \log N - t)$ ，即与数据结构大小成线性关系，而且可以并行化。

最后，INSERT 中对整个向量 o_* 执行 TRANSFORM-PREFIX-SUM 是冗余的。一旦和达到 N ，就可以截断计算，因为此时已经找到足够多的空槽位。串行情形很容易实现这一点，但并行情形如何实现并不显然。启发式方法包括：每次只考虑 o_* 的一个子集，迭代到找到足够多的空槽位；以及从上一次调用 INSERT 时最后填入的槽位之后开始计算累积和。不过，在实践中，使用这些启发式方法所带来的执行时间变化几乎可以忽略，因此本文选择介绍最简单的版本。

3 祖先树的大小

3.1 结果

从理论角度看，种群遗传学已经研究过类似的随机树 [Del Moral et al \(2009\)](#); [Möhle \(2004\)](#)，但其设定对应于给所有路径赋予相同权重的状态空间模型，相关结果不能直接用于这里。为界定祖先树中的期望节点数，我们首先研究最终时刻 T 与所有路径合并的完全合并时刻 c_T 之间的距离 $d_T = T - c_T$ 。定理 1 给出 d_T 期望的一个上界，该上界与 T 无关，并显式依赖于 N 。

假设 1. 存在 $\epsilon \in [0, 1]$ ，使得对所有 $y \in \mathcal{Y}$ 和所有 $x \in \mathcal{X}$ ，有

$$\sqrt{\epsilon} \leq g(y | x) \leq \frac{1}{\sqrt{\epsilon}}.$$

定理 1. 在假设 1 下，到最近共同祖先的距离 d_T 满足

$$\mathbb{E}[d_T] \leq \Delta_1 N \log N$$

其中 $\Delta_1 > 0$ 不依赖于 N 或 T 。

树中的期望节点数可以用 N 和 T 显式界定，如定理 2 所示。

定理 2. 这里假定 $N \geq 3$ 。在假设 1 下，时刻 T 的节点数记为 n_T ，其满足

$$\mathbb{E}[n_T] \leq T + \Delta_2 N \log N$$

其中 $\Delta_2 > 0$ 不依赖于 N 或 T 。

这些结果量化了两种存储方式在实践中的差别：存储所有生成的粒子需要确定性的 $T \times N$ 个内存单位；而只存储存活粒子的开销是随机的，其期望被 $T + \Delta_2 N \log N$ 所界定。

在非紧空间中，假设 1 非常强，例如它甚至不涵盖线性高斯情形；不过，第 4 节的实验表明，类似结果可能对非线性、非高斯情形也成立。数值实验表明，该上界对 N 的依赖是准确的，因此即使证明中使用的某些不等式看起来相当粗糙，整体结果仍然精确。然而，这些结果并没有刻画树的形状如何随 ϵ 变化，因此我们写出常数 Δ_1 和 Δ_2 时，没有显式标出它们对 ϵ 的依赖。例如在定理 1

中，可以令 $\Delta_1 = 1 + 8/\epsilon$ ，这一点将在第 3.3 节证明。若该上界对 ϵ 的依赖是紧的，那么当 ϵ 趋于零时，到完全合并的时间就会趋于无穷。但对于较小的 ϵ ，粒子权重允许有更大的变动，路径退化理应更加严重。因此， Δ_1 对 ϵ 的依赖并不符合实际。我们认为，这些上界实际上可能与 ϵ 无关：可以将 $\epsilon = 1$ 视为对应于 d_T 和 n_T 期望最大的情形；本文并未证明这一主张。

此外，所提出的证明依赖于多项式重采样，而大多数实践者偏好更复杂的方案 (Carpenter et al, 1999; Liu and Chen, 1998; Kitagawa, 1998; Doucet and Johansen, 2011)。第 4 节的图 3(a) 表明，类似结果对这些其他重采样方案也成立。不过也存在一些明显反例，例如观测密度为常数，导致每一步的权重相等（等价于 $\epsilon = 1$ ）。此时，上述结果对多项式重采样成立，但系统重采样会完全消除路径退化现象。描述一般重采样方案所对应祖先树的特征，将是一个有趣的研究方向。

本节余下部分将证明定理 1 和定理 2。

3.2 从非均匀权重到均匀权重

我们首先将使用多项式重采样的粒子滤波器所对应的祖先过程，与中性情形下的祖先过程联系起来；在中性情形中，每个时间步的全部权重都等于 N^{-1} 。为此，我们引入若干中间过程：首先是记为 $(A_t)_{t \geq 0}$ 的精确多项式重采样过程；然后是由 $(A'_t)_{t \geq 0}$ 表示、提供几乎必然上界的近似过程；最后，对固定时间跨度 T ，引入在中性情形中计数第 $T - k$ 代节点数的过程 $(Z_k)_{k \geq 0}$ 。

下面给出多项式重采样方案的另一种表示。在时刻 t ，对每个粒子索引 $j = 1, \dots, N$ ，从 $[0, 1]$ 上均匀抽取 V_t^j 。若 $V_t^j \leq \epsilon$ ，则抽取 $U_t^j \sim \mathcal{U}([0, 1])$ ，并令 $a_t^j = k$ ，其中 k 满足 $U_t^j \in [(k-1)/N, k/N]$ 。若 $V_t^j > \epsilon$ ，则从 $\sum_{1 \leq i \leq N} (w_{t-1}^i - \epsilon/N)(1-\epsilon)^{-1} \delta_i(\cdot)$ 中抽取 a_t^j 。可以验证，假设 1 保证对每个 $1 \leq i \leq N$ 都有 $w_{t-1}^i - \epsilon/N \geq 0$ ，且上述方案给出 $\mathbb{P}(a_t^j = k) = w_{t-1}^k$ ，与多项式重采样相同。这一表示等价于两个步骤的混合：当 $V_t^j \leq \epsilon$ 时，执行不考虑权重的步骤；当 $V_t^j > \epsilon$ 时，执行使用权重的步骤。从这一角度出发，可以引入由下述过程 $(A'_t)_{t \geq 0}$ 表示的近似重采样方案。

对每个时刻 t ，定义 $A_t : j \in \{1, \dots, N\} \mapsto a_t^j \in \{1, \dots, N\}$ ，然后按如下方式定义 $A'_t : \{1, \dots, N\} \rightarrow \{1, \dots, N\}$ 。对 $C_t = \{k \in \{1, \dots, N\} : V_t^k \leq \epsilon\}$ 中的所有 j ，令 $A'_t(j) = a_t^j$ 。将集合 $\{j \in \{1, \dots, N\} : V_t^j > \epsilon\}$ 中剩余的 p 个索引排序为 $\{j_1 < \dots < j_p\}$ ，令 $A'_t(j_1) = \inf(\{1, \dots, N\} \setminus A'_t(C_t))$ ，然后递归地令

$$A'_t(j_k) = \inf(\{1, \dots, N\} \setminus (A'_t(C_t) \cup \{A'_t(j_1), \dots, A'_t(j_{k-1})\})).$$

由构造可知，这样的函数 A'_t 几乎必然映射到比 A_t 更多的不同取值。它可以像上述 A_t 一样，被看作两个步骤的混合，但这次两个步骤都不依赖于权重的取值。

用 $|u|$ 表示函数 $u : \{1, \dots, N\} \rightarrow \{1, \dots, N\}$ 的像的基数。利用函数 $(A_k)_{k \leq T-1}$ ，完全合并时刻 c_T 可以定义为

$$c_T = \sup\{0 \leq k \leq T-1 : |A_k \circ A_{k+1} \circ \dots \circ A_{T-1}| = 1\},$$

约定当每个 $0 \leq k \leq T-1$ 都满足 $|A_k \circ A_{k+1} \circ \dots \circ A_{T-1}| > 1$ 时， $c_T = 0$ 。它几乎必然满足 $c_T \geq c'_T$ ，其中

$$c'_T = \sup\{k \leq T-1 : |A'_k \circ A'_{k+1} \circ \dots \circ A'_{T-1}| = 1\}.$$

事实上, 由于每个时刻 t 的 A'_t 都映射到比 A_t 更多的不同取值, 所以对任意 k , 数量 $|A'_k \circ \cdots \circ A'_{T-1}|$ 几乎必然大于 $|A_k \circ \cdots \circ A_{T-1}|$ 。前者计数的是使用重采样方案 A' 时, 时刻 T 的粒子在第 k 代中不同祖先的数量。因此, 与使用 A 相比, 使用 A' 时到达完全合并需要更长的时间。

根据 Del Moral et al (2009) 第 4 节和 Möhle (2004), 序列 $(K_k)_{k \geq 0} = (|A'_{T-k} \circ \cdots \circ A'_{T-1}|)_{k \geq 0}$ 是关于滤过 $(\mathcal{F}_k)_{k \geq 1}$ 的马尔可夫链, 其中

$$\mathcal{F}_k = \sigma(V_r^{1:N}, U_r^{1:N})_{T-k \leq r \leq T-1},$$

并约定 $K_0 = N$ 。对所有 $k \geq 0$, $q \in \{1, \dots, N\}$ 和 $p < q$, 其转移分布满足

$$\mathbb{P}(K_{k+1} = p \mid K_k = q) \quad (1)$$

$$= \sum_{q'=q-p+1}^q \binom{q}{q'} \epsilon^{q'} (1-\epsilon)^{q-q'} \left\{ \frac{q'}{q' - q + p} \right\} \frac{(N)_{q'-q+p}}{N^{q'}}$$

$$\text{以及 } p_{N,q} = \mathbb{P}(K_{k+1} = q \mid K_k = q)$$

$$= \sum_{q'=0}^q \binom{q}{q'} \epsilon^{q'} (1-\epsilon)^{q-q'} \frac{(N)_{q'}}{N^{q'}} \quad (2)$$

其中, $\{q_p\}$ 是第二类 Stirling 数, 给出将集合 $\{1, \dots, q\}$ 划分成 p 个非空块的方式数; 且 $(N)_p = N!/(N-p)!$ 。注意, 式 (2) 是式 (1) 的一个特例。

下面进一步解释式 (1) 和 (2)。首先考虑 $p_{N,q}$ 的表达式。索引 q' 表示对应的 V_{T-k-1} 实现值小于 ϵ 的粒子数。因此, 它是在第 $T-k-1$ 步中, 其祖先 A'_{T-k-1} 按 $\{1, \dots, N\}$ 上均匀分布选取的粒子数; 其余 $q-q'$ 个祖先按确定性方式选择, 见 (A'_t) 的定义。项 $\binom{q}{q'} \epsilon^{q'} (1-\epsilon)^{q-q'}$ 对应于时刻 $T-k$ 的 q 个粒子中, 有 q' 个均匀抽取的 V_{T-k-1} 取值小于 ϵ 的概率。项 $(N)_{q'}/N^{q'}$ 对应于这 q' 个在 $\{1, \dots, N\}$ 上均匀抽取的祖先恰好落在 q' 个不同取值上的概率。现在考虑某个 $p < q$ 的概率 $\mathbb{P}(K_{k+1} = p \mid K_k = q)$ 。

要使 K_k 在下一步由 q 降到 p , 必须消失 $q-p$ 个不同粒子; 由于对应于 $V_{T-k-1} > \epsilon$ 的粒子不会消失, 因此必须至少有 $q-p+1$ 个粒子对应于 $V_{T-k-1} \leq \epsilon$ 。

因此, 仍表示 V_{T-k-1} 实现值小于 ϵ 的粒子数的索引 q' , 现在从 $q-p+1$ 开始。二项式项与 $p=q$ 的情形类似。在这 q' 个 V_{T-k-1} 实现值小于 ϵ 的粒子中, 必须有 $p' = p - (q-q')$ 个选择不同的祖先, 另外 $q-p$ 个则必须合并。Stirling 数 $\{q'_p\}$ 正好计数将 $\{1, \dots, q'\}$ 划分为 p' 个非空块的方式数; 这些块是即将合并的粒子组, 每一块对应一个不同祖先。

注意, 在给定 $K_k = q$ 的条件下, 变量 $V^{1:q}$ 中取值小于 ϵ 的个数可以是任意 $I \in \{1, \dots, q\}$ 。可将 $\mathbb{E}[K_{k+1} \mid K_k = q]$ 写成

$$\sum_{i=0}^q \binom{q}{i} \epsilon^i (1-\epsilon)^{q-i} \mathbb{E}[K_{k+1} \mid K_k = q, I = i].$$

现在考察 $\mathbb{E}[K_{k+1} \mid K_k = q, I = i]$, 即在 q 个不同粒子中, 给定其中 i 个在 $\{1, \dots, N\}$ 上均匀选择祖先, 而 $q-i$ 个各有一个独特祖先时, 祖先数量的期望。当然, 难点来自随机部分, 即均匀选择祖

先的 i 个粒子。在 $\mathbb{N}$ 上引入过程 $(Z_k)_{k \geq 0}$ ，它对应于仅采用这些均匀选择时的祖先数量，这等价于具有均匀权重的多项式重采样方案。更形式化地，沿用推导 $(K_k)_{k \geq 0}$ 转移概率的相同推理， $(Z_k)_{k \geq 0}$ 的转移满足

$$\mathbb{P}(Z_{k+1} = p \mid Z_k = q) = \left\{ \frac{q}{p} \right\} \frac{(N)_p}{N^q}, \quad (3)$$

下文不使用 Z_0 的初始分布，因此无需指定。 $(Z_k)_{k \geq 0}$ 与 $(K_k)_{k \geq 0}$ 之间的联系显式地由下式给出：

$$\mathbb{E}[K_{k+1} \mid K_k = q, I = i] = (q - i) + \mathbb{E}[Z_{k+1} \mid Z_k = i]$$

从而有

$$\begin{aligned} \mathbb{E}[K_{k+1} \mid K_k = q] \\ = q(1 - \epsilon) + \sum_{i=0}^q \binom{q}{i} \epsilon^i (1 - \epsilon)^{q-i} \mathbb{E}[Z_{k+1} \mid Z_k = i]. \end{aligned} \quad (4)$$

注意，过程 $(Z_k)_{k \geq 0}$ 不用于定理 1 的证明，那里将重新从 $(K_k)_{k \geq 0}$ 出发；但它对定理 2 的证明至关重要。

3.3 到最近共同祖先的距离

先证明定理 1。在 $\mathbb{N}$ 上定义马尔可夫链 $(L_k)_{k \geq 0}$ ，使得 $L_0 = N$ ，且其转移满足

$$\mathbb{P}(L_{k+1} = q - 1 \mid L_k = q) = \sum_{p < q} \mathbb{P}(K_{k+1} = p \mid K_k = q)$$

因此，对所有 $k \geq 0$ 和 $p \leq q$ ，

$$\mathbb{P}(L_{k+1} = p \mid L_k = q) = \begin{cases} p_{N,q} & \text{若 } p = q, \\ 1 - p_{N,q} & \text{若 } p = q - 1, \end{cases}$$

其中 $p_{N,q}$ 由式 (2) 定义。此外，通过作出以下假设，将 $(L_k)_{k \geq 0}$ 与 $(K_k)_{k \geq 0}$ 耦合：

- $[L_k = K_k] \Rightarrow [L_{k+1} < L_k \Leftrightarrow K_{k+1} < K_k]$ (若两条链处于同一点，则其中一条下降时，另一条也下降)。
- $[L_k \neq K_k] \Rightarrow$ 给定 L_k, K_k 后， K_{k+1} 与 L_{k+1} 条件独立。

根据构造，对所有 $k \geq 0$ ，几乎必然有 $L_k \geq K_k$ 。因此，令 $\mathcal{D}_T = \inf\{k \geq 1 : L_k = 1\}$ ，则 $c'_T \geq T - \mathcal{D}_T$ ，进而几乎必然有 $d_T = T - c_T \leq T - c'_T \leq \mathcal{D}_T$ 。

对 $q = 2, \dots, N$ ，用 $J_q^{(N)}$ 表示 $(L_k)_{k \geq 0}$ 从 q 跳到 $q - 1$ 所需的时间。每个 $J_q^{(N)}$ 都服从参数为 $(1 - p_{N,q})$ 的几何分布，且 $\mathcal{D}_T = \sum_{q=2}^N J_q^{(N)}$ ，因此 $\mathbb{E}[\mathcal{D}_T] = \sum_{q=2}^N (1 - p_{N,q})^{-1}$ 。为完成证明，对这个和进行如下处理。对任意 $k = 1, \dots, N$ ， $\exp\{-k/2N\}$ 给出 $(N)_k/N^k$ 的一个粗略上界，由此得到

$$p_{N,q} \leq \left(1 - \epsilon(1 - e^{-1/2N})\right)^q.$$

对所有 N , 有 $(8N)^{-1} \leq 1 - \exp\{-1/2N\}$; 对所有 $x \geq 1$ 和 $\varepsilon \in (0, 1)$, 有 $(1 - \varepsilon/x)^x \leq \exp(-\varepsilon)$ 。结合这些不等式, 得到

$$\mathbb{E}[\mathcal{D}_T] \leq \sum_{q=2}^N (1 - \alpha^{q/N})^{-1}$$

其中 $\alpha = \exp(-\varepsilon/8)$ 。现在将 $\alpha^{q/N} = \exp\{(q/N) \log \alpha\}$ 展开成交错级数, 并始终用它的某个部分和界定该交错级数, 即可界定上述级数:

$$\begin{aligned} & \sum_{q=2}^N (1 - \alpha^{q/N})^{-1} \\ & \leq \sum_{q=2}^N \left(\frac{q}{N} (-\log \alpha) - \frac{1}{2!} \left(\frac{q}{N} \right)^2 (\log \alpha)^2 \right)^{-1} \\ & \leq -\frac{N}{\log \alpha} \log N + (N-1) \leq \left(1 + \frac{8}{\varepsilon} \right) N \log N, \end{aligned}$$

至此完成定理 1 的证明。

注意, 用 $(L_k)_{k \geq 0}$ 几乎必然地界定 $(K_k)_{k \geq 0}$ 看起来非常粗糙, 因为 K_k 可能一步就从 q 跳到 $p \ll q$, 而 L_k 只能从 q 跳到 $q-1$ 。但合并时间主要由最后几次跳跃所支配, 因为当 N 相对于 q 很大且 $p < q$ 时, 概率 $\mathbb{P}(K_{k+1} = p \mid K_k = q)$ 接近 0。换言之, 经过几个时间步后, q 相对于 N 已经很小, 此后 $(K_k)_{k \geq 0}$ 即使发生跳跃, 也主要是从 q 跳到 $q-1$, 因此 (L_k) 提供了准确的上界过程。用来界定 $p_{N,q}$ 进而界定 $\mathbb{E}[\mathcal{D}_T]$ 的其他近似, 也应在 q 相对于 N 较小的情形下考察; 在这一情形中, 它们足够准确, 能够得到所需的 $N \log N$ 结果。

3.4 祖先树中的节点数

下面证明定理 2。用 m_T 表示树冠中的节点数。定理 1 对 d_T 的界给出第一个粗略上界:

$$\mathbb{E}[m_T] \leq \Delta_1 N^2 \log N$$

这是将树冠中每一代的大小都用 N 界定而得到的。不过, 利用以下论证可以得到更好的 $N \log N$ 上界。

此前已经引入过程 $(K_k)_{k \geq 0}$ 来界定 $\mathbb{E}[d_T]$, 也可以自然地用它界定 $\mathbb{E}[m_T]$, 因为几乎必然有

$$m_T \leq \sum_{k=0}^{\tau_T} K_k$$

其中 $\tau_T = \inf\{k \leq T : K_k = 1\}$; 注意 $\tau_T = T - c'_T$ 。为界定 $\mathbb{E}[K_k]$, 使用式 (3) 定义的链 $(Z_k)_{k \geq 0}$ 。

根据 $(Z_k)_{k \geq 0}$ 的定义, 并令 $(C_j)_{j=1}^N$ 为 $\{1, \dots, N\}$ 上相互独立的均匀随机变量, 可得

$$\begin{aligned} \mathbb{E}[Z_{k+1} \mid Z_k = q] &= \mathbb{E}\left[\sum_{j=1}^N \mathbb{1}_{\{\exists k \in \{1, \dots, q\}: C_k = j\}}\right] \\ &= N - \sum_{j=1}^N \mathbb{E}[\mathbb{1}_{\{\forall k \in \{1, \dots, q\}: C_k \neq j\}}] \\ &= N - N \left(1 - \frac{1}{N}\right)^q \end{aligned} \quad (5)$$

结合式 (4), 得到

$$\mathbb{E}[K_{k+1} \mid K_k = q] = q(1 - \epsilon) + N \left(1 - \left(1 - \frac{\epsilon}{N}\right)^q\right).$$

将 $(1 - (1 - \epsilon/N)^q)$ 展开成交错级数, 并用其第三个部分和给出上界, 可得

$$\mathbb{E}[K_{k+1} \mid K_k = q] \leq q - \frac{\epsilon^2}{2N} q(q-1) + \frac{\epsilon^3}{6N^2} q(q-1)(q-2).$$

现在对 $x \in [1, N]$, 定义函数 $g_{N,\epsilon}$:

$$g_{N,\epsilon}(x) = x - \frac{\epsilon^2}{2N} x(x-1) + \frac{\epsilon^3}{6N^2} x(x-1)(x-2). \quad (6)$$

注意到 $g_{N,\epsilon}$ 是凹函数, 并应用 Jensen 不等式, 得到

$$\mathbb{E}[K_{k+1}] = \mathbb{E}[\mathbb{E}[K_{k+1} \mid K_k]] \leq g_{N,\epsilon}(\mathbb{E}[K_k]). \quad (7)$$

引入序列 $u_0 = N$, 并对 $n > 0$ 令 $u_{n+1} = g_{N,\epsilon}(u_n)$ 。根据上述不等式以及 $g_{N,\epsilon}$ 的单调不减性, 对所有 k 都有 $\mathbb{E}[K_k] \leq u_k$ 。最终可以如下界定树冠中的期望节点数:

$$\begin{aligned} \mathbb{E}\left[\sum_{k=0}^{\tau_T} K_k\right] &= \mathbb{E}\left[\mathbb{E}\left[\sum_{k=0}^{\tau_T} (K_k - 1)\right] + \tau_T\right] \\ &\leq \sum_{k=0}^{\infty} (u_k - 1) + \Delta_1 N \log N \end{aligned} \quad (8)$$

其中使用定理 1 界定 $\mathbb{E}[\tau_T]$ 。我们利用以下技术引理界定 $\sum_{k=0}^{\infty} (u_k - 1)$ 。

引理 1. 设 $N \in \mathbb{N}$ 、 $N \geq 6$ 且 $\epsilon \in (0, 1)$ 。考虑序列 $(u_k)_{k \geq 0}$, 满足 $u_0 = N$, 并且对 $k \geq 1$,

$$u_k = u_{k-1} - \frac{\epsilon^2}{2N} u_{k-1}(u_{k-1} - 1) + \frac{\epsilon^3}{6N^2} u_{k-1}(u_{k-1} - 1)(u_{k-1} - 2).$$

则存在与 N 无关的 $C > 0$, 使得

$$\sum_{k=0}^{\infty} (u_k - 1) \leq CN \log N.$$

引理 1 的证明基于初等实分析, 见附录 A。利用引理 1 与式 (8), 取 $\Delta_2 = C + \Delta_1$, 即得定理 2。


4 数值实验

本节通过数值实验说明第 3 节的结果，以及第 2 节算法的效率。结果汇总了 $K = 500$ 次独立运行，使用 $N = 128$ 个粒子和 $T \leq 1000$ 个时间步。每次运行都会生成新的合成数据集，并使用不同的随机种子。默认重采样方案是在每个时间步应用多项式重采样。第 2 节的算法已在 LibBi 中实现 (Murray, 2013, www.libbi.org)，本文的数值结果使用该实现获得。


我们使用 Jones et al (2010) 和 Murray et al (2012) 描述的浮游植物—浮游动物 (PZ) 模型。浮游植物浓度 (P_t)、浮游动物浓度 (Z_t) 与浮游植物随机生长率 (α_t) 共同构成隐状态。状态遵循连续时间动力学 $dP/dt = \alpha_t P - cPZ$ 和 $dZ/dt = ecPZ - m_l Z - m_q Z^2$ ，在每个整数时刻 t 抽取 $\alpha_t \sim \mathcal{N}(\mu, \sigma^2)$ 。初始条件为 $\log P_0 \sim \mathcal{N}(\log(2), 0.2)$ 、 $\log Z_0 \sim \mathcal{N}(\log(2), 0.1)$ 。观测 (Y_t) 通过带加性对数正态噪声的方式测量 (P_t)，即 $\log Y_t \sim \mathcal{N}(\log P_t, \sigma_y)$ 。参数设置为 $\mu = 0.4$ 、 $\sigma = 0.2$ 、 $c = 0.25$ 、 $e = 0.3$ 、 $m_l = m_q = 0.1$ 和 $\sigma_y = 0.2$ 。

为展示引理 2，定义调整后的节点数 $\tilde{n}_T = (n_T - T)/N$ ：图 2(a) 绘制不同 N 下该量随 T 的变化，图 2(b) 绘制不同 T 下该量随 N 的变化。该量取 K 次独立运行的平均值。根据该引理， $\tilde{n}_T$ 作为 T 的函数应一致有界，而作为 N 的函数应按对数增长；图中结果证实了这一点。图 3(a) 表明，分层重采样、系统重采样等其他方案也预期有类似表现，仅 Δ_2 的取值不同。

为说明第 2 节各过程的效率，图 3(b) 给出了不同 T 和 N 下，每个时间步执行剪枝与插入算法的总耗时。结果表明，计算开销受 T 的影响不大，而相对于 N 接近线性：这说明实际实现的复杂度可与粒子滤波器本身相当。




(a) 不同 N 下，调整后的节点数 $\tilde{n}_T = (n_T - T)/N$ 随 T 的变化。




(b) 不同 T 下，调整后的节点数 $\tilde{n}_T = (n_T - T)/N$ 随 N (对数刻度) 的变化。

图 2. PZ 模型中，不同 N 下调整后的节点数 $\tilde{n}_T = (n_T - T)/N$ 随 T 的变化 (上)，以及不同时刻 T 下该量随 N 的变化 (下)。



(a) 不同重采样方案下，调整后的节点数 $\hat{n}_T = (n_T - T)/N$ 随 T 的变化。



(b) 不同 T 下，路径保留算法的计算时间（微秒）随 N 的变化。

图 3. PZ 模型中，重采样方案对节点数的影响（上），以及不同 N 和 T 下路径保留算法的计算时间（下）。

5 结论

我们给出了粒子滤波器生成的祖先树中期望节点数的上界。第 4 节的数值实验表明，即使超出理论研究所作假设的适用范围，该结果仍然准确；而且，所提出的树存储算法在计算上是高效的。

A 引理 1 的证明

设 $N \in \mathbb{N}$ 且 $\epsilon \in (0, 1)$ ，按引理陈述定义 $(u_k)_{k \geq 0}$ ，按式 (6) 定义 $g_{N,\epsilon}$ 。我们关心 $\sum_{k \geq 0} (u_k - 1)$ 。首先注意， $g_{N,\epsilon}$ 是压缩映射且满足 $g_{N,\epsilon}(1) = 1$ ，所以由 Banach 不动点定理， u_k 趋于 1。 $g_{N,\epsilon}$ 的压缩系数可界定为

$$\sup_x |g'_{N,\epsilon}(x)| \leq g'_{N,\epsilon}(1) = 1 - \frac{\epsilon^2}{2N} < 1,$$

然而，这个压缩系数依赖于 N ，直接使用它得到的 $\sum_{k \geq 0} (u_k - 1)$ 上界并非 $N \log N$ 量级。

还要注意，尽管 u_k 趋于 1，我们可以只关注部分和 $\sum_{k=0}^{\sigma_2} (u_k - 1)$ ，其中 $\sigma_2 = \inf\{k : u_k \leq 2\}$ ，因为 $\sum_{k=\sigma_2}^{\infty} (u_k - 1)$ 本质上可以由 N 界定。事实上，对 $1 \leq u \leq 2$ ，有 $(\epsilon^3/6N^2)u(u-1)(u-2) \leq 0$ ，从而

$$u_k - 1 \leq u_{k-1} - 1 - \frac{\epsilon^2}{2N} u_{k-1} (u_{k-1} - 1) \leq (u_{k-1} - 1) \left(1 - \frac{\epsilon^2}{2N}\right),$$

因此 $\sum_{k=\sigma_2}^{\infty} (u_k - 1) \leq (2N/\epsilon^2)$ 。

所以，我们可以集中于用 $N \log N$ 界定 $\sum_{k=0}^{\sigma_2} (u_k - 1)$ 。将这个和分为若干部分和：第一部分对满足 $N/2 \leq u_k \leq N$ 的索引 k 求和，第二部分对满足 $N/4 \leq u_k \leq N/2$ 的索引求和，依此类推。更形式化地，引入 $(k_j)_{j=0}^J$ ，使得 $k_0 = 0$ ， $k_1 = \inf\{k : u_k \leq N/2\}$ ， $\dots$ ， $k_j = \inf\{k : u_k \leq N/2^j\}$ ，直到 $k_J = \inf\{k : u_k \leq N/2^J\}$ ，其中 J 满足 $N/2^J \leq 2$ ，等价地， $\log N / \log 2 - 1 \leq J$ 。例如，可以取 $J = \lfloor \log N / \log 2 \rfloor$ 。这样就把 $\sum_{k=0}^{\sigma_2} (u_k - 1)$ 分成了 J 个形如 $\sum_{k=k_j}^{k_{j+1}-1} (u_k - 1)$ 的部分和。接下来，将用同一个量 $C(\epsilon)N$ 界定每个部分和，其中 $C(\epsilon)$ 仅依赖于 ϵ 。

为此，考虑 $(u_k)_{k \geq 0}$ 从 N/m_j 降到 N/m_{j+1} 所需的时间，其中 $m_{j+1} > m_j$ ；稍后将取 $m_j = 2^j$ 、 $m_{j+1} = 2^{j+1}$ 。注意，对任意 m ，有

$$g_{N,\epsilon}\left(\frac{N}{m}\right) = \frac{N}{m} \left(1 - \frac{1}{m} \left[\frac{\epsilon^2}{2} - \frac{m\epsilon^2}{2N} - \frac{\epsilon^3}{6m} + \frac{\epsilon^3}{2N} - \frac{m\epsilon^3}{3N^2}\right]\right).$$

定义

$$\beta(N, m, \epsilon) = \frac{\epsilon^2}{2} - \frac{m\epsilon^2}{2N} - \frac{\epsilon^3}{6m} + \frac{\epsilon^3}{2N} - \frac{m\epsilon^3}{3N^2}$$

并注意，对任意 $N \geq 6$ 和 $m \leq N/2$ ，有

$$\underline{\beta}(\epsilon) := \frac{\epsilon^2}{4} \leq \beta(N, m, \epsilon),$$

这一点很清楚: $\beta(N, m, \epsilon)$ 作为 $m \in [1, N/2]$ 的函数是凹函数, 因此在 1 或 $N/2$ 处取得最小值; 只要 $N \geq 6$, 该最小值就大于 $\epsilon^2/4$ 。对任意 $x \geq N/m_{j+1}$, 可以验证

$$g_{N,\epsilon}(x) \leq \frac{g_{N,\epsilon}(N/m_{j+1})}{N/m_{j+1}} \times x$$

因为 $g_{N,\epsilon}$ 是凹函数, 且对 $x \in [0, N]$ 有 $g_{N,\epsilon}(x) \leq x$ 。因此, 对于满足 $u_{k-1} \geq N/m_{j+1}$ 的 $k \geq 0$, 有

$$u_k \leq \left(1 - \frac{1}{m_{j+1}} \underline{\beta}(\epsilon)\right) u_{k-1}.$$

现在假设对某个 $k_j \geq 0$, 有 $u_{k_j} \leq N/m_j$ 。我们寻找使 $u_{k_j+K} \leq N/m_{j+1}$ 的 K 。只需找到满足下式的 K :

$$\begin{aligned} \left(1 - \frac{1}{m_{j+1}} \underline{\beta}(\epsilon)\right)^K \frac{N}{m_j} &\leq \frac{N}{m_{j+1}} \\ \Leftrightarrow K &\geq \log \frac{m_{j+1}}{m_j} \left(-\log \left(1 - \frac{1}{m_{j+1}} \underline{\beta}(\epsilon)\right)\right)^{-1}. \end{aligned}$$

最后, 利用

$$\forall x \in (0, 1) \quad \frac{1}{x} - 1 \leq \frac{1}{-\log(1-x)} \leq \frac{1}{x}$$

可以断定, 按下式定义的 K

$$K = \left\lceil \left(\log \frac{m_{j+1}}{m_j}\right) \frac{m_{j+1}}{\underline{\beta}(\epsilon)} \right\rceil$$

保证不等式 $u_{k_j+K} \leq N/m_{j+1}$ 成立。换言之, $(u_k)_{k \geq 0}$ 从 N/m_j 降到 N/m_{j+1} 所需的步数小于 K 。对 k_j 到 $k_j + K$ 之间的项求和, 得到

$$\sum_{k=k_j}^{k_j+K} u_k \leq K \frac{N}{m_j} \leq \left[\left(\log \frac{m_{j+1}}{m_j}\right) \frac{m_{j+1}}{\underline{\beta}(\epsilon)} + 1 \right] \frac{N}{m_j}.$$

取 $m_j = 2^j$ 和 $m_{j+1} = 2^{j+1}$, 有 $k_{j+1} \leq k_j + K$, 因而得到

$$\sum_{k=k_j}^{k_{j+1}} u_k \leq \sum_{k=k_j}^{k_j+K} u_k \leq \left[(\log 2) \frac{2}{\underline{\beta}(\epsilon)} + \frac{1}{2^j} \right] N = C(\epsilon)N$$

其中 $C(\epsilon)$ 与 N 无关。于是, 整个和被界定为

$$\begin{aligned} \sum_{k \geq 0} (u_k - 1) &\leq \sum_{k=0}^{\sigma_2} (u_k - 1) + \sum_{k \geq \sigma_2} (u_k - 1) \\ &\leq \left\lceil \frac{\log N}{\log 2} \right\rceil C(\epsilon)N + \frac{2N}{\epsilon^2} \leq D(\epsilon)N \log N \end{aligned}$$

其中 $D(\epsilon)$ 与 N 无关。

参考文献

- Andrieu C, Doucet A, Holenstein R (2010) Particle Markov chain Monte Carlo (with discussion). *J Royal Statist Society Series B* 72(4):357–385
- Cappé O, Moulines E, Rydén T (2005) *Inference in Hidden Markov Models*. Springer-Verlag, New York
- Carpenter J, Clifford P, Fearnhead P (1999) Improved particle filter for nonlinear problems. *IEE Proc Radar, Sonar Navigation* 146(1):2–7
- Chopin N, Singh SS (2013) On the particle Gibbs sampler. *ArXiv e-prints* [1304.1887](#)
- Chopin N, Jacob P, Papaspiliopoulos O (2013) SMC²: an efficient algorithm for sequential analysis of state space models. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 75(3):397–426
- Del Moral P (2004) *Feynman-Kac formulae*. Springer
- Del Moral P, Doucet A (2003) On a class of genealogical and interacting metropolis models. *Séminaire de Probabilités XXXVII* pp 415–446
- Del Moral P, Miclo L, Patras F, Rubenthaler S (2009) The convergence to equilibrium of neutral genetic models. *Stochastic Analysis and Applications* 28(1):123–143
- Douc R, Moulines E, Olsson J (2012) Long-term stability of sequential Monte Carlo methods under verifiable conditions. *ArXiv e-prints*; to appear in *Annals of Applied Probability* [1203.6898](#)
- Doucet A, Johansen A (2011) A tutorial on particle filtering and smoothing: Fifteen years later. In: *Handbook of Nonlinear Filtering*, Oxford, UK: Oxford University Press
- Doucet A, de Freitas N, Gordon N (2001) *Sequential Monte Carlo methods in practice*. Springer-Verlag, New York
- Gordon N, Salmond J, Smith A (1993) A novel approach to non-linear/non-Gaussian Bayesian state estimation. *IEEE Proceedings on Radar and Signal Processing* 140:107–113
- van Handel R (2009) Uniform time average consistency of monte carlo particle filters. *Stochastic Processes and their Applications* 119(11):3835 – 3861
- Jones EM, Parslow J, Murray LM (2010) A Bayesian approach to state and parameter estimation in a phytoplankton-zooplankton model. *Australian Meteorological and Oceanographic Journal* 59:7–16

- Kitagawa G (1998) A self-organizing state-space model. *J American Statist Assoc* 93:1203–1215
- Lee A, Yau C, Giles MB, Doucet A, Holmes CC (2010) On the utility of graphics cards to perform massively parallel simulation of advanced Monte Carlo methods. *Journal of Computational and Graphical Statistics* 19:769–789
- Lindsten F, Jordan M, Schön T (2012) Ancestor sampling for particle Gibbs. *ArXiv e-prints* [1210.6911](#)
- Liu J, Chen R (1998) Sequential Monte Carlo methods for dynamic systems. *J American Statist Assoc* 93:1032–1044
- Möhle M (2004) The time back to the most recent common ancestor in exchangeable population models. *Advances in Applied Probability* pp 78–97
- Murray LM (2013) Bayesian state-space modelling on high-performance hardware using LibBi. *ArXiv e-prints* [1306.3277](#)
- Murray LM, Jones EM, Parslow J (2012) On collapsed state-space models and the particle marginal Metropolis-Hastings sampler. *ArXiv e-prints* [1202.6159](#)
- Murray LM, Lee A, Jacob PE (2013) Rethinking resampling in the particle filter on graphics processing units. *ArXiv e-prints* [1301.4019](#)
- Poyiadjis G, Doucet A, Singh S (2011) Particle approximations of the score and observed information matrix in state space models with application to parameter estimation. *Biometrika* 98(1):65–80
- Sengupta S, Harris M, Garland M (2008) Efficient parallel scan algorithms for GPUs. Tech. Rep. NVR-2008-003, NVIDIA
- Wang J, Jasra A, De Iorio M (2014) Computational methods for a class of network models. *Journal of Computational Biology*
- Whiteley N (2011) Stability properties of some particle filters. *ArXiv e-prints*; to appear in *Annals of Applied Probability* [1109.6779](#)