

迈向可微重采样

Towards Differentiable Resampling

Michael Zhu*

斯坦福大学

mhzhu@stanford.edu

Kevin Murphy

Google AI

kpmurphy@google.com

Rico Jonschkowski

Google 机器人团队

rjon@google.com

摘要

重采样是粒子滤波中基于样本的递归状态估计的关键组成部分。近期研究探索了用于端到端学习的可微粒子滤波器 [2, 3]。然而，重采样本身不可微，因此在这些工作中仍然是一项挑战。我们用学习得到的神经网络重采样器替代传统重采样，以应对这一挑战。我们提出一种新的网络架构——粒子 *Transformer*，并利用定义在粒子集合上的、基于似然的损失函数训练其执行粒子重采样。将该模型嵌入可微粒子滤波器后，即可通过梯度下降，与粒子滤波器的其他组成部分联合进行端到端优化。结果表明，在合成数据和模拟机器人定位任务上，学习得到的重采样器优于传统重采样技术。

1 引言

状态估计，即给定过去的观测和动作，估计当前状态的后验分布，仍然是机器人学中的关键问题。这一问题通常使用粒子滤波器 [1, 5] 解决：用一组带权样本（粒子）近似后验，并在每个时间步更新。粒子依据运动模型对当前动作的预测而移动，其权重则依据测量模型更新，后者估计每个粒子处当前观测的似然。最后，根据权重对粒子进行重采样，使后验的近似集中于高概率区域。传统粒子滤波器需要手工定义或单独学习运动模型与测量模型。

近期关于可微粒子滤波器（DPF）的研究 [2, 3] 用神经网络替代传统的手工模型，并以能够通过微分计算梯度的方式实现粒子滤波算法。因此，DPF 可以利用梯度下降，为端到端状态估计优化模型。DPF 也可视为循环神经网络（RNN）：它利用状态估计问题的结构，提高数据效率和泛化能力 [2]。

尽管已取得有希望的结果，DPF 仍受限于本质上不可微的重采样步骤。这一步不可或缺，因为反复更新粒子的位置和权重最终会导致退化问题：大多数粒子的权重接近零，只有少数粒子对近似后验有用。为缓解这一问题，根据权重对粒子进行有放回的随机重采样，生成表示相同后验的等权

*本工作于作者在 Google 机器人团队期间完成。

粒子集合，再将其用作下一时间步的先验。重采样粒子相对于其复制来源的输入粒子（祖先粒子）的位姿是可微的，但相对于输入权重不可微。因此，传统重采样无法让可微粒子滤波器中的梯度跨多个时间步反向传播。以往工作通过在单步后截断反向传播 [2]、在可行情形下不进行任何重采样来训练（例如从已知状态开始跟踪） [3]，或采用软重采样 [3] 来回避这一问题。软重采样牺牲重采样质量，以换取有偏的梯度估计（见第 3.1 节）。这些措施都未解决可微性问题，因此我们研究用学习得到的神经网络重采样器替代传统重采样。

除了实现可微性，我们的方法还引出了一个重要问题：传统重采样对于状态估计是否最优，尤其是在模型通过端到端方式学习时？例如，实践经验 [8, p. 118] 以及端到端学习的实证结果 [2] 都表明，当运动模型和测量模型高估系统噪声时，粒子滤波器表现最好。其中一个可能原因是，这提高了对未建模效应的鲁棒性。但增大噪声也可能通过补偿粒子重采样产生的近似误差而起作用。

由于重采样会精确复制高权重粒子，运动模型必须包含噪声，才能使这些粒子散开，让测量更新能够给它们赋予不同权重，即便真实运动是确定性的。可以设想另一种重采样方式：它不复制粒子，而是在粒子之间进行插值，从一开始就将粒子分散开，从而可能减少运动模型所需的噪声。尽管重要性重采样在某些假设下是最优的 [8]，但是否存在一种重采样形式，在实际中（某些假设可能不成立时）表现更好，仍是一个值得探究的问题。

我们的贡献如下：（1）用神经网络替代现有重采样机制，实现可微性，并研究学习模型是否能够优于传统重采样。（2）提出粒子 *Transformer*，一种专为粒子重采样设计的新网络架构。（3）给出训练该模型执行重采样的两种方式：（3a）使用粒子集合之间基于似然的损失函数；（3b）将重采样模型作为可微粒子滤波器的一部分进行端到端训练。实验表明，学习得到的模型在合成数据和模拟定位任务上均优于现有重采样方法。

2 相关工作

可微粒子滤波器 [2] 和粒子滤波网络 [3] 将粒子滤波算法与可学习的运动模型、测量模型相结合，并通过梯度下降进行端到端训练。粒子滤波 RNN [6] 将这种方法推广到经典状态估计问题之外：其架构更接近普通 RNN，但维护的是基于粒子的隐分布，而非一个隐向量。正如引言和第 3.1 节所述，可微重采样仍然是一项关键挑战；本工作提出在神经网络中学习重采样，以应对这一挑战。

神经网络可以先逐点进行变换，再通过池化聚合得到的点特征，从而对点集建模 [7, 10]。集合 *Transformer* [4] 在这些思想之上构建，采用利用多头注意力 [9] 的置换不变编码器—解码器架构。我们通过引入加权注意力和尺度等变性，将集合 *Transformer* 扩展至重采样任务。

3 背景

3.1 粒子滤波中的重采样

粒子滤波器根据观测和动作序列，递归估计状态的后验概率。它们用一组带权样本 $\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n$ (也称粒子) 表示这一后验，其中 $\mathbf{x}^{(i)} \in \mathbb{R}^d$ 表示 d 维样本位置， $w^{(i)} \in \mathbb{R}$ 表示粒子 i 的归一化权重，满足 $\sum_{i=1}^n w^{(i)} = 1$ 。若不重采样而反复执行运动和测量更新，粒子会逐渐散开，大多数权重会不断减小，直至只有少数粒子的权重不可忽略。此时粒子集合发生退化，无法再恰当地估计后验。重采样通过将粒子集中于高概率区域来解决这一问题 [8]。传统粒子滤波器使用多项式重采样或系统重采样。软重采样是这些思想的一个可微版本 [3]。所有这些方法都通过删除或复制已有粒子来进行重采样。

多项式重采样依据粒子权重所表示的离散分布，有放回地抽取粒子。系统重采样（也称随机通用采样）将粒子权重转化为累积分布，均匀抽取偏移量 $\delta \in [0, \frac{1}{n})$ ；对于整数 $k \in [0, n-1]$ ，若某粒子对应的累积分布区间包含 $\delta + \frac{k}{n}$ ，则抽取该粒子。通过在生成的样本之间引入依赖，这一过程提高了粒子集合的稳定性，因为任何归一化权重大于 $\frac{c}{n}$ 的粒子都保证至少被抽取 c 次。软重采样 [3] 是一种可微近似：先对权重分布与均匀分布的混合进行多项式重采样，再将被抽中的祖先粒子权重混入重采样粒子的均匀权重中。这使重采样粒子的权重相对于其祖先粒子的权重可微。遗憾的是，软重采样会使重采样过程及估计梯度都产生偏差，而且仅为被抽中的输入粒子提供梯度。

3.2 Transformer / 集合 Transformer 模型

Transformer [9] 是一种以注意力函数为核心的神经网络架构。该函数将一个查询和一组键值对映射为值的加权和，其中各权重由查询与键的相似度计算得到（第 4.1 节将进一步说明）。Transformer 将这一思想推广为多头注意力：以 h 种不同方式线性投影每个查询、键和值，对全部 h 个查询—键—值三元组应用注意力函数，将结果拼接后再次进行线性投影。Transformer 将多头注意力与逐点前馈层、残差连接和层归一化交织组合，构成编码器—解码器架构。在自然语言处理应用中，输入词由学习得到的嵌入及其位置编码表示。

集合 Transformer [4] 扩展了 Transformer，利用注意力学习点集中的交互。为实现输入集合的置换不变性，该模型省略位置编码。在解码器一侧，集合 Transformer 提出多头注意力池化 (PMA)，将 k 个可学习向量用作多头注意力中查询的种子。解码器通过具有 k 个种子向量的 PMA、多头自注意力和逐点前馈层聚合编码器输出，生成 k 个输出。

4 用于可微重采样的粒子 Transformer

4.1 粒子 Transformer

我们提出粒子 *Transformer*，一种用于粒子重采样的神经网络架构。它同时具有置换不变性和尺度等变性，并将粒子权重融入注意力机制。模型建立在上述集合 Transformer [4] 之上。但它不是把 n 个点的集合映射到 k 个输出向量，而是把 n 个带权点的集合映射到新的 n 个点的集合，并通过引入尺度等变性和加权注意力，进一步利用粒子重采样的问题结构。

为恰当地建模粒子权重，我们引入加权注意力机制，对点积注意力进行推广。设查询向量为 $\mathbf{q} \in \mathbb{R}^{d_k}$ ，并有 m 对键 $\mathbf{k}^{(i)} \in \mathbb{R}^{d_k}$ 和值 $\mathbf{v}^{(i)} \in \mathbb{R}^{d_v}$ ，其中 $i \in [1, m]$ 。缩放点积注意力函数计算

$$\frac{\sum_{i=1}^m \exp(\mathbf{q} \cdot \mathbf{k}^{(i)} / \sqrt{d_k}) \mathbf{v}^{(i)}}{\sum_{j=1}^m \exp(\mathbf{q} \cdot \mathbf{k}^{(j)} / \sqrt{d_k})}.$$

我们对该函数进行推广，为 m 个键值对 $\mathbf{k}^{(i)}, \mathbf{v}^{(i)}$ 中的每一对引入权重 $w^{(i)} \in \mathbb{R}$ ，得到

$$\frac{\sum_{i=1}^m w^{(i)} \exp(\mathbf{q} \cdot \mathbf{k}^{(i)} / \sqrt{d_k}) \mathbf{v}^{(i)}}{\sum_{j=1}^m w^{(j)} \exp(\mathbf{q} \cdot \mathbf{k}^{(j)} / \sqrt{d_k})}.$$

与多头注意力 [9] 类似，使用多个键—值—查询三元组，即可将这一思想扩展为加权多头注意力。

模型同时使用加权和普通多头注意力，如图 1 所示。编码器接收 n 个带权向量组成的集合 $\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n$ ，根据各输入维度的最小值与最大值，将每一维缩放至 $[-1, 1]$ ，然后将每个向量线性变换为隐表示。接着，两次应用加权多头自注意力和逐点前馈层。到这一步，每个编码向量仍与其原始权重关联。解码器将这些编码后的粒子与 n 个充当“种子向量” [4] 的可学习向量 $\mathbf{z}^{(i)}$ 一起作为输入，生成 n 个新粒子。解码器将以下操作重复两次：多头自注意力、加权多头注意力，以及逐点前馈层。其中，加权多头注意力使用编码后的粒子计算键和值，使用解码器的隐表示计算查询。最终得到的 n 个向量经线性变换后与输入维数一致，再按维度缩放回原始最小值与最大值对应的范围。整个模型的隐维度为 256，多头注意力使用 8 个头。

4.2 单独训练的损失函数

前文介绍了将 n 个带权粒子映射为 n 个等权粒子的粒子 Transformer，现在定义训练该模型执行重采样的损失函数。其思想是，在给定重采样粒子的条件下，最大化一组目标粒子的似然。为了将粒子集合转化为概率密度函数，我们应用核密度估计，构造高斯混合分布（每个粒子对应一个高斯分量） [2]。设 $q_{\mathbf{r}\theta}(\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n)$ 表示参数为 θ 的模型从输入粒子 $\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n$ 重采样得到的 n 个粒子所对应的高斯混合分布， $\{\mathbf{y}^{(i)}, v^{(i)}\}_{i=1}^n$ 表示一组目标粒子。该损失可由预测分布与目标分布之间的 Kullback–Leibler (KL) 散度推导得到（见附录 A.1）。它对 n 个目标粒子位置处的 q 值进行适当加权后求和：

$$L(\theta) = - \sum_{i=1}^n \frac{v^{(i)}}{\sum_{j=1}^n v^{(j)}} \log q_{\mathbf{r}\theta}(\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n)(\mathbf{y}^{(i)}). \quad (1)$$




图 1. 粒子 Transformer 架构。多头注意力模块接收三个输入：从左至右依次为键、值和查询。种子向量通过学习得到。

目标粒子集合采用以下两者之一：(i) 输入粒子 $\{x^{(i)}, w^{(i)}\}_{i=1}^n$ ；(ii) 传统重采样器对该输入产生的输出。注意，(i) 之所以可行，只是因为粒子 Transformer 被约束为输出等权粒子，从而无法学成恒等映射。

4.3 粒子滤波器中的单独训练与端到端训练

为研究可微重采样与粒子滤波端到端训练之间的相互作用，我们将粒子 Transformer 与已有的可微粒子滤波器（DPF）工作 [2] 相结合。我们遵循其方案，先单独训练粒子滤波器的各组成部分，再进行端到端训练。由于重采样器的单独训练需要输入与目标粒子集合的样例，我们在所关注的问题上，使用单独训练的运动模型、测量模型和标准重采样器运行滤波器，以收集这样的数据集。在粒子滤波器中收集这些样例，可以确保训练时粒子集合的分布与滤波过程中遇到的分布相近。单独训练与端到端训练的具体步骤如下：

1. 单独训练运动模型和测量模型。
2. 使用标准重采样器运行步骤 1) 中的粒子滤波器，收集重采样器的输入与输出粒子集合。
3. 利用步骤 2) 中的训练样例，单独训练粒子 Transformer 进行重采样。
4. 对 DPF 进行端到端训练，联合优化运动模型、测量模型和重采样器。

5 实验




图 2. 合成数据上的定性结果（展示五个维度中的一个）。圆表示粒子位置和权重，曲线表示核密度估计。




图 3. 不同重采样方法在合成数据上的比较。

5.1 合成数据

我们首先在合成粒子集合数据集上，将粒子 Transformer 与其他重采样技术进行比较。通过随机生成成对的概率分布来构造这一数据集：一个分布用于生成样本，另一个分布用于给这些样本赋权。我们将这些分布定义为五维空间中三个高斯分布的混合，并对每一维分别从 $[-5, 5]$ 和 $[1, 3]$ 中随机抽取均值与标准差。前两个高斯分量的混合概率从 $[0.2, 0.4]$ 中抽取，最后一个高斯分量的概率由此确定，使三者之和为一。我们从这些分布抽取 32 个粒子，同时作为输入集合与目标集合，共生成 6 万个粒子集合，其中 5 万个用于训练，1 万个用于评估。

图 2 展示了粒子 Transformer 在五维分布的一维切片上的定性结果（橙色为输入，蓝色为输出）。输出粒子被约束为具有相等权重，以迫使它们集中于高概率区域。尽管这一约束妨碍了对输入分布的近似，重采样粒子仍捕获了所有模态。注意，与复制或删除粒子的传统重采样技术不同，学习得到的重采样器会在原先没有输入粒子的位置放置粒子，从而增加粒子多样性（例如最右侧的模态）。

图 3 依据式 (1) 定义的损失，在评估集上比较粒子 Transformer 与其他重采样技术：多项式重

采样、系统重采样及软重采样。我们针对不同核带宽计算该损失；核带宽控制估计 q 时以各粒子为中心的高斯分量的宽度。结果表明，粒子 Transformer 在所有核带宽下均取得最低损失，尤其是在较小带宽下，其损失约为 -0.2 ，其他方法则为 0.3 至 0.8 。多项式重采样最激进地删除粒子，因此在这一场景中表现不佳。将权重与均匀分布混合的软重采样带来了小幅改善。保留权重超过一定阈值的输入粒子的系统重采样表现更好。然而，我们学习得到的重采样策略不受限于复制或删除粒子，显著优于所有其他方法。

5.2 用于粒子滤波器的可微重采样

为在粒子滤波器中测试学习得到的重采样器，我们考虑模拟迷宫环境中的机器人定位问题。机器人在迷宫中移动时，目标是根据相机观测和里程计测量序列估计机器人的位姿。我们使用 Jonschkowski 等人 [2] 的数据集和可微粒子滤波器实现，但仅在第一个时间步使用其粒子提议网络初始化粒子。在所有其他时间步，使用粒子 Transformer 对全部 100 个粒子进行重采样（与其他方法比较时则使用相应方法）。

表 1. 粒子滤波结果：单独训练 → 端到端训练

重采样方法	最后时间步的错误率	最后时间步的 MSE
不重采样	$70.0 \pm 0.3\% \rightarrow 58.0 \pm 0.3\%$	$7.0 \pm 0.2 \rightarrow 3.5 \pm 0.03$
软重采样	$11.4 \pm 0.4\% \rightarrow 6.9 \pm 0.2\%$	$4.9 \pm 0.2 \rightarrow 5.7 \pm 0.2$
软重采样（使用 BPTT）	$11.4 \pm 0.4\% \rightarrow 6.6 \pm 0.2\%$	$4.9 \pm 0.2 \rightarrow 5.5 \pm 0.2$
系统重采样	$7.0 \pm 0.2\% \rightarrow 4.9 \pm 0.1\%$	$2.9 \pm 0.2 \rightarrow 3.9 \pm 0.1$
粒子 Transformer（冻结）	$12.0 \pm 0.7\% \rightarrow 4.7 \pm 0.2\%$	$2.6 \pm 0.1 \rightarrow 2.3 \pm 0.08$
粒子 Transformer	$12.0 \pm 0.7\% \rightarrow 1.2 \pm 0.2\%$	$2.6 \pm 0.1 \rightarrow 0.38 \pm 0.06$

我们首先单独训练粒子滤波器的所有组成部分，再按照第 4.3 节所述进行端到端优化。本实验阻断跨时间步的梯度，因此不进行随时间反向传播（BPTT）；唯一例外是软重采样，我们分别评估使用和不使用 BPTT 的情形。系统重采样不可微，因而无法使用 BPTT。粒子 Transformer 的设计目标是为 BPTT 提供梯度，但目前在这方面受到梯度爆炸的限制（见附录 A.2）。

表 1 给出了不同重采样算法的测试结果，采用错误率和均方误差（MSE）两项指标，分别在单独训练后及进一步端到端训练后评估。所有结果均附有在 Maze 1 [2] 上进行五次独立试验得到的标准误。错误率结果表明，重采样对于这一定位问题至关重要：单独训练后的错误率从 70% 降至 7%，端到端训练后则从 58% 降至 1.2%。同时，系统重采样始终优于软重采样（7% 对 11.4%，以及 4.9% 对 6.6%）；在软重采样中使用 BPTT 仅带来小幅收益（6.6% 对 6.9%），这可能源于第 3.1 节所述的有偏梯度。如果所有模型（重采样模型、运动模型和测量模型）均单独训练，系统重采样也优于学习得到的重采样器（7% 对 12%），显然是因为运动模型和测量模型的单独学习目标与这种传统重采样方式更为一致。然而，端到端训练后结果发生了变化。当端到端训练运动模型和测量模型、

但冻结重采样模型时，我们的模型取得了相当的错误率（4.7% 对 4.9%）和更低的均方误差（2.3 对 3.9）。如果再对重采样模型进行端到端训练，结果又有显著改善。与系统重采样相比，我们的模型将错误率从 4.9% 降至 1.2%，将均方误差从 3.9 降至 0.38（定性结果见附录 A.3）。

6 结论

我们展示了粒子滤波中实现可微重采样的进展，并检验了学习模型能否提供比传统方法更好的重采样。为探索重采样问题中的学习方法，我们提出粒子 Transformer：一种具有置换不变性、尺度等变性和加权注意力的模型，可针对端到端状态估计进行优化。结果表明，这一学习模型在合成数据和模拟定位任务上均显著优于传统重采样方法。未来仍需进一步研究如何实现随时间反向传播，以充分发挥可微重采样的潜力。

A 附录

A.1 损失函数的推导

下面推导单个训练样例的损失函数。设 p 为目标分布，由 n 个粒子的位置及其相应权重 $\{\mathbf{y}^{(i)}, v^{(i)}\}_{i=1}^n$ 所定义的概率测度给出：

$$p(\mathbf{y}) = \sum_{i=1}^n \frac{v^{(i)}}{\sum_{j=1}^n v^{(j)}} \delta_{\mathbf{y}^{(i)}}(\mathbf{y}),$$

其中， $\delta_{\mathbf{y}^{(i)}}(\mathbf{y})$ 表示位于粒子 i 的位置 $\mathbf{y}^{(i)}$ 处的狄拉克 δ 函数。

设 $q_{\mathbf{r}\theta}(\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n)$ 为参数为 θ 的粒子 Transformer 在输入粒子 $\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n$ 下输出的 n 个粒子的高斯核密度估计（混合分布）。我们希望最小化 p 与 $q_{\mathbf{r}\theta}(\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n)$ 之间的 KL 散度，等价地，最小化交叉熵：

$$\min_{\theta} \text{KL}(p \| q_{\mathbf{r}\theta}(\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n)) = \min_{\theta} H(p \| q_{\mathbf{r}\theta}(\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n)).$$

因此，单个训练样例的损失函数为

$$\begin{aligned} L(\theta) &= - \int p(\mathbf{x}) \log q_{\mathbf{r}\theta}(\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n)(\mathbf{x}) d\mathbf{x} \\ &= - \sum_{i=1}^n \frac{v^{(i)}}{\sum_{j=1}^n v^{(j)}} \log q_{\mathbf{r}\theta}(\{\mathbf{x}^{(i)}, w^{(i)}\}_{i=1}^n)(\mathbf{y}^{(i)}). \end{aligned}$$

A.2 迈向随时间反向传播

由于粒子 Transformer 完全可微，原则上它支持使用随时间反向传播（BPTT）的端到端学习。也就是说，可以将采用粒子 Transformer 重采样的可微粒子滤波器沿多个时间步展开，让梯度流经学习得到的重采样机制，以估计时刻 t 的模型参数如何影响时刻 $t+d$ 的粒子滤波器输出。这正是本工作最初的动机：根据粒子滤波器各组成部分对所有未来时间步的影响来优化它们。遗憾的是，BPTT

并未改善性能。因此，在评估可微粒子滤波器中粒子 Transformer 的端到端训练时，我们阻断了跨时间步的梯度传播（结果见表 1）。

为更好地理解这一问题，我们在端到端训练中分别冻结或不冻结重采样器，并每隔 k 个时间步截断梯度。也就是说，当 $t \bmod k = 0$ 时，在第 t 步重采样后截断梯度。表 2 列出了 $k \in \{1, 3, 5\}$ 的结果：若冻结重采样器，采用 $k = 3$ 的这种截断 BPTT，比在每个时间步都截断梯度表现更好。这支持了跨时间梯度有益于端到端训练的观点。当 k 更大，或在端到端训练中更新（未冻结的）重采样器参数时，性能随 k 增大而下降。 $k = 5$ 时，错误率分别为 9.9% 和 10.6%，说明端到端训练不稳定，因为相较于表 1 中单独训练的 12% 错误率，端到端训练仅带来了轻微改善。

表 2. 每隔 k 步截断梯度时的 DPF 测试结果

k	冻结重采样器		不冻结重采样器	
	错误率	MSE	错误率	MSE
1	4.7±0.2%	2.3±0.1	1.2±0.2%	0.4±0.1
3	4.3±0.2%	2.1±0.1	4.9±0.3%	1.8±0.1
5	9.9±0.2%	2.8±0.1	10.6±0.6%	2.5±0.2

表 3. 采用梯度裁剪且每隔 k 步截断梯度时的 DPF 测试结果

k	冻结重采样器	不冻结重采样器
1	4.7±0.2%	1.1±0.07%
2	3.5±0.1%	1.2±0.14%
3	3.7±0.2%	1.9±0.2%
4	3.9±0.1%	5.4±1.6%
5	4.4±0.1%	9.8±0.1%

我们怀疑这种不稳定性由梯度爆炸引起，因此分析了 DPF 各组成部分的梯度范数中位数如何依赖于 k （见图 4）。注意纵轴采用对数尺度：梯度范数几乎随 k 指数增长。

为解决这一问题，我们将梯度范数裁剪到 10，得到表 3 中的结果。与表 2 比较可见，梯度裁剪总体上改善了性能。例如，当 $k = 3$ 时，错误率从 4.3% 降至 3.7%（冻结重采样器），以及从 4.9% 降至 1.9%（不冻结重采样器）。采用梯度裁剪后，若在端到端训练中冻结重采样器， $k \in \{2, 3, 4\}$ 时的 BPTT 相较于 $k = 1$ 有显著改善。然而，随着 k 增大，以及在不冻结重采样器时，性能仍然恶化。最佳结果仍来自在 $k = 1$ 时端到端训练重采样器，即不进行 BPTT。尽管梯度裁剪显示出潜力，仍需进一步研究，才能跨多个时间步恰当地端到端训练采用粒子 Transformer 的可微粒子滤波器。




图 4. 不同 DPF 组成部分的梯度范数中位数随 k 的变化； k 为截断 BPTT 的时间步间隔。

A.3 定性结果

表 1 中的定量结果表明，在模拟定位任务中，使用端到端学习的粒子 Transformer 进行重采样，比使用系统重采样的性能显著更好。为理解学习模型与传统重采样器的行为有何不同，下面考察定性结果。

图 5 通过两个样例，并排定性比较了系统重采样与粒子 Transformer 重采样。在第一个样例（上排）中，输入（a）由上方的一组高权重粒子（紫色）和下方权重接近零的粒子（黄色）组成。结果表明，系统重采样器和粒子 Transformer 都从高权重区域抽取了大部分粒子。但系统重采样器完全丢弃了低权重区域，而粒子 Transformer 在其中生成了少量样本。在第二个样例（下排）中，输入粒子（d）的分布是多模态的。与系统重采样相比，我们再次看到粒子 Transformer 会在没有高权重输入的区域放置粒子。此外，粒子 Transformer 在分布的模式附近生成了更多样的粒子集合。

在低权重区域生成额外粒子，并产生更多样的粒子集合，可能会提高对建模误差的鲁棒性。运动模型和测量模型从数据中学习，例如，若训练期间没有见过当前观测与状态的组合，就可能错误地将粒子权重设得很低。粒子 Transformer 可能通过比传统重采样方法更强地抵御这些问题来改善性能。

图 6 给出了一个代表性样例，说明鲁棒性的提升如何对多步滤波过程产生重大影响。我们对同一观测与动作序列进行粒子滤波，分别采用系统重采样（a）和粒子 Transformer（b）。两次滤波都在第一步（左上角迷宫）从相似的初始粒子集合出发，并在第二步和第三步估计出具有大约三个模态的多模态后验。在第三步，（b）中更多样的粒子集合使真实位姿附近的一些粒子获得了高权重，而（a）中的权重则高度集中于错误假设（从机器人的局部视角看，它们难以区分）。到第四步，采




图 5. 两个粒子集合样例在二维位置和角度上的定性结果。给定输入粒子集合（左），展示系统重采样（中）与粒子 Transformer（右）的输出。粒子按其权重着色。

用传统重采样器的粒子滤波器（a）几乎不再将粒子放在真实位姿附近，随后无法定位机器人。采用学习重采样器的粒子滤波器（b）则在第四步将大多数粒子分布于两个有效假设周围，因而之后能够选出正确假设并成功跟踪。




图 6. 采用两种不同重采样方法，在同一数据上进行机器人定位的粒子滤波可视化（俯视图）。共有 19 个时间步，每行 5 个，最后一个框汇总粒子滤波估计轨迹（绿色）与机器人真实位姿轨迹（红色）。每个时间步的机器人真实位置和角度分别由黑色圆圈与红色箭头表示。按权重着色的粒子表示对机器人所在位置的信念。

致谢

感谢 Anelia Angelova 和 Vincent Vanhoucke 对本工作的有益意见，以及 Chad Richards 对文稿的编辑和校对。

参考文献

- [1] Neil J Gordon, David J Salmond, and Adrian FM Smith. Novel approach to nonlinear/non-Gaussian Bayesian state estimation. *IEE Proceedings F (Radar and Signal Processing)*, 140(2):107–113, 1993.
- [2] Rico Jonschkowski, Divyam Rastogi, and Oliver Brock. Differentiable particle filters: End-to-end learning with algorithmic priors. In *Proceedings of Robotics: Science and Systems*, 2018.
- [3] Peter Karkus, David Hsu, and Wee Sun Lee. Particle filter networks with application to visual localization. In *Proceedings of the Conference on Robot Learning*, pages 169–178, 2018.
- [4] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam Kosior, Seungjin Choi, and Yee Whye Teh. Set transformer: A framework for attention-based permutation-invariant neural networks. In *Proceedings of the International Conference on Machine Learning*, pages 3744–3753, 2019.
- [5] Jun S Liu and Rong Chen. Sequential Monte Carlo methods for dynamic systems. *Journal of the American Statistical Association*, 93(443):1032–1044, 1998.
- [6] Xiao Ma, Peter Karkus, David Hsu, and Wee Sun Lee. Particle filter recurrent neural networks. *arXiv preprint arXiv:1905.12885*, 2019.
- [7] Charles R Qi, Hao Su, Kaichun Mo, and Leonidas J Guibas. PointNet: Deep learning on point sets for 3D classification and segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 652–660, 2017.
- [8] Sebastian Thrun, Wolfram Burgard, and Dieter Fox. *Probabilistic robotics*. MIT Press, Cambridge, Mass., 2005.
- [9] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008, 2017.
- [10] Manzil Zaheer, Satwik Kottur, Siamak Ravanbakhsh, Barnabas Poczos, Ruslan R Salakhutdinov, and Alexander J Smola. Deep sets. In *Advances in Neural Information Processing Systems*, pages 3391–3401, 2017.